

# PDI&VC

## Processamento Digital de Imagens e Visão Computacional


SUNFLOWER | B 86 CONF. →



SUNFLOWER | 0.98 CONF. (PDI->VC)



PDI PROCESS | EDGE DET.



GIRASSOL | 95% (VC USE)



Fundamentos, Algoritmos  
e Aplicações Integradas

AUTOR: FRANCISCO DE ASSIS ZAMPIROLI



# Processamento Digital de Imagens e Visão Computacional

Livro interativo com Python

Francisco de Assis Zampiroli

# Sumário

|                                                                                                                                                       |           |
|-------------------------------------------------------------------------------------------------------------------------------------------------------|-----------|
| <b>PDI e VC — Python</b>                                                                                                                              | <b>22</b> |
| Organização . . . . .                                                                                                                                 | 22        |
| <b>Prefácio</b>                                                                                                                                       | <b>23</b> |
| Como este livro é produzido . . . . .                                                                                                                 | 23        |
| Idiomas e Conversão de Código . . . . .                                                                                                               | 24        |
| Uso de ferramentas de Inteligência Artificial . . . . .                                                                                               | 24        |
| A biblioteca <code>morph.py</code> . . . . .                                                                                                          | 24        |
| Exercícios de Programação (EPs) e Validação Automática . . . . .                                                                                      | 26        |
| Código aberto . . . . .                                                                                                                               | 26        |
| Guia do Professor: Publicação de EPs no Moodle . . . . .                                                                                              | 26        |
| Integração com o Moodle (VPL) . . . . .                                                                                                               | 26        |
| Como Publicar no Moodle . . . . .                                                                                                                     | 27        |
| Antes de começar: <i>Notebooks</i> em Python . . . . .                                                                                                | 27        |
| <b>I Parte I — Fundamentos de PDI</b>                                                                                                                 | <b>28</b> |
| <b>1 Fundamentos e Primeiros Passos</b>                                                                                                               | <b>29</b> |
| 1.1 Objetivos . . . . .                                                                                                                               | 29        |
| 1.2 Antes de começar: <i>Notebooks</i> em Python . . . . .                                                                                            | 29        |
| 1.3 Fundamentos . . . . .                                                                                                                             | 29        |
| 1.3.1  Visão Computacional . . . . .                               | 30        |
| 1.3.2  Processamento Digital de Imagens (PDI) . . . . .            | 30        |
| 1.4 Etapas do PDI . . . . .                                                                                                                           | 31        |
| 1.5 Formação da Imagem e o Espectro . . . . .                                                                                                         | 31        |
| 1.6 O que é uma Imagem Digital? . . . . .                                                                                                             | 34        |
| Representação Matemática . . . . .                                                                                                                    | 34        |
| 1.7 Configuração do Ambiente . . . . .                                                                                                                | 35        |
| 1.8 Fundamentos de Matrizes - atenção à cópia de referências . . . . .                                                                                | 36        |
| 1.9 Lendo e Exibindo Imagens . . . . .                                                                                                                | 37        |
| Alternativa: <i>Download</i> da Imagem para Armazenamento Local . . . . .                                                                             | 38        |
| 1.10 Conversão de Tipos e Limiarização . . . . .                                                                                                      | 39        |
| Conversão para Tons de Cinza . . . . .                                                                                                                | 39        |
| Limiarização ( <i>Thresholding</i> ) . . . . .                                                                                                        | 39        |
| Exemplo prático de conversão e limiarização . . . . .                                                                                                 | 39        |
| 1.11 Limiarização pelo método de Otsu . . . . .                                                                                                       | 40        |
| 1.12 Acesso a Pixels . . . . .                                                                                                                        | 41        |
| 1.13 Resumo . . . . .                                                                                                                                 | 43        |
| 1.14  Uso do Gemini Notebook como Tutor Complementar . . . . .     | 43        |
| Funcionalidades Disponíveis na Plataforma . . . . .                                                                                                   | 43        |
| 1.15 Lista de Exercícios . . . . .                                                                                                                    | 44        |
| Referências do Capítulo . . . . .                                                                                                                     | 45        |
| 1.16  <b>Parte Prática com Exercícios de Programação</b> . . . . . | 45        |
| 🎯 Objetivo deste Caderno . . . . .                                                                                                                    | 45        |
| § Instruções Passo a Passo . . . . .                                                                                                                  | 45        |



|                                                                                   |                                                                                                                                                              |           |
|-----------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------|
|  | Importante: Regras e Boas Práticas                                                                                                                           | 47        |
| 1.16.1                                                                            | EP01_01  Três métricas de distância em PDI                                  | 47        |
| 1.16.2                                                                            | EP01_02  Desempenho Preditivo — Métricas de ML em VC                        | 54        |
| 1.16.3                                                                            | EP01_03  <i>Mean Average Precision</i> (mAP) — Curva Precisão-Sensibilidade | 56        |
| 1.16.4                                                                            | EP01_04  Leitura e Informações de uma Imagem em Matriz                      | 60        |
| 1.16.5                                                                            | EP01_05  Negativo de uma Imagem em Tons de Cinza                            | 61        |
| 1.16.6                                                                            | EP01_06  Conversão RGB → Tons de Cinza (ITU-R BT.601)                       | 63        |
| 1.16.7                                                                            | EP01_07  Limiarização Manual: Imagem Binária                                | 65        |
| 1.16.8                                                                            | EP01_08  Remapeamento por Faixa de Intensidade                              | 66        |
| 1.16.9                                                                            | EP01_09  Padrão de Tabuleiro: Matriz de Xadrez                              | 69        |
| 1.16.10                                                                           | EP01_10  Metadados: Leitura de Arquivo PGM                                  | 70        |
| 1.16.11                                                                           | EP01_11  Análise de Vizinhança: Filtro de Máximo 1D                         | 72        |
| <b>2</b>                                                                          | <b>Da Captura ao Pixel - Amostragem, Quantização e Conectividade</b>                                                                                         | <b>75</b> |
| 2.1                                                                               | Objetivos                                                                                                                                                    | 75        |
| 2.2                                                                               | O Olho e a Câmera - Elementos da Percepção Visual                                                                                                            | 75        |
| 2.2.1                                                                             | Visão humana                                                                                                                                                 | 75        |
| 2.2.2                                                                             | Sensores digitais                                                                                                                                            | 75        |
| 2.3                                                                               | Ilusões de Ótica: Os Desafios da Percepção Visual                                                                                                            | 76        |
| 2.3.1                                                                             | Ambiguidade e Contexto                                                                                                                                       | 76        |
| 2.3.2                                                                             | Brilho e Contraste Local                                                                                                                                     | 77        |
| 2.3.3                                                                             | Geometria e Perspectiva                                                                                                                                      | 77        |
| 2.4                                                                               | O Modelo Matemático da Formação da Imagem                                                                                                                    | 77        |
| 2.4.1                                                                             | Representação Digital e Canais Espectrais                                                                                                                    | 78        |
| 2.4.2                                                                             | Preparando o Ambiente Prático                                                                                                                                | 79        |
| 2.4.3                                                                             | Implementação da Leitura de Imagem em <code>morph.py</code>                                                                                                  | 79        |
| 2.4.4                                                                             | RGB e RGBA: Exemplo Prático com a Imagem Mandrill                                                                                                            | 80        |
| 2.5                                                                               | Digitalização: Amostragem e Quantização                                                                                                                      | 81        |
| 2.5.1                                                                             | Amostragem - Discretização do espaço                                                                                                                         | 81        |
| 2.5.2                                                                             | Quantização - Discretização da intensidade                                                                                                                   | 82        |
| 2.5.3                                                                             | Efeitos da amostragem e quantização                                                                                                                          | 82        |
| 2.5.4                                                                             | Análise Técnica                                                                                                                                              | 84        |
| 2.6                                                                               | Relações entre Pixels - Topologia da Imagem                                                                                                                  | 85        |
| 2.6.1                                                                             | Vizinhança                                                                                                                                                   | 85        |
| 2.6.2                                                                             | Adjacência, conectividade e caminhos                                                                                                                         | 85        |
| 2.6.3                                                                             | Distâncias entre pixels                                                                                                                                      | 86        |
| 2.7                                                                               | Armazenamento de Imagens                                                                                                                                     | 86        |
| 2.7.1                                                                             | Exemplo: Extração de Metadados e Localização GPS                                                                                                             | 87        |
| 2.7.2                                                                             | Por que esta separação é importante?                                                                                                                         | 89        |
| 2.8                                                                               | Transformações Geométricas Básicas                                                                                                                           | 89        |
| 2.8.1                                                                             | Translação                                                                                                                                                   | 90        |
| 2.8.2                                                                             | Rotação                                                                                                                                                      | 91        |
| 2.8.3                                                                             | Escala (Redimensionamento)                                                                                                                                   | 92        |
| 2.8.4                                                                             | Cisalhamento ( <i>Shear</i> )                                                                                                                                | 93        |
| 2.9                                                                               | Resumo                                                                                                                                                       | 94        |
| 2.10                                                                              |  Uso do Gemini Notebook como Tutor Complementar                           | 94        |
| 2.11                                                                              | Lista de Exercícios                                                                                                                                          | 95        |
|                                                                                   | Referências do Capítulo                                                                                                                                      | 95        |
| 2.12                                                                              |  <b>Parte Prática com Exercícios de Programação</b>                       | 95        |
|                                                                                   |  Objetivo deste Caderno                                                   | 95        |
| 2.12.1                                                                            | EP02_01  Ajuste de Brilho e Contraste                                     | 96        |
| 2.12.2                                                                            | EP02_02  Subamostragem Espacial                                           | 98        |
| 2.12.3                                                                            | EP02_03  Quantização de Níveis de Cinza                                   | 100       |
| 2.12.4                                                                            | EP02_04  Transformada de Distância em Imagem Binária                      | 102       |



|          |         |                                                                                                                                        |            |
|----------|---------|----------------------------------------------------------------------------------------------------------------------------------------|------------|
| 2.12.5   | EP02_05 |  Translação de Imagem                                 | 104        |
| 2.12.6   | EP02_06 |  Rotação de Imagem                                    | 105        |
| 2.12.7   | EP02_07 |  Redimensionamento (Escala)                           | 107        |
| 2.12.8   | EP02_08 |  Cisalhamento (Shear)                                 | 111        |
| 2.12.9   | EP02_09 |  Transformação Afim Genérica                          | 112        |
| 2.12.10  | EP02_10 |  Correção de Perspectiva (Homografia)                 | 116        |
| 2.12.11  | EP02_11 |  Correção de Perspectiva (Homografia) em Imagem Real  | 118        |
| <b>3</b> |         | <b>Operações Espaciais: Intensidade, Histograma e Filtragem</b>                                                                        | <b>123</b> |
| 3.1      |         | Objetivos                                                                                                                              | 123        |
| 3.2      |         | Operações em Nível de Intensidade                                                                                                      | 123        |
| 3.2.1    |         | Preparando o Ambiente Prático                                                                                                          | 124        |
| 3.2.2    |         | Operações Aritméticas                                                                                                                  | 125        |
| 3.2.3    |         | Mistura Ponderada ( <i>Alpha Blending</i> )                                                                                            | 126        |
| 3.2.4    |         | Operações Lógicas e Máscaras Bit a Bit                                                                                                 | 128        |
| 3.3      |         | Histograma de Imagens                                                                                                                  | 129        |
| 3.3.1    |         | Equalização de Histograma                                                                                                              | 130        |
| 3.3.2    |         | Especificação de Histograma                                                                                                            | 134        |
| 3.4      |         | Fundamentos Espaciais: Vizinhança, Convolução e <i>Kernels</i>                                                                         | 135        |
| 3.4.1    |         | Vizinhança                                                                                                                             | 135        |
| 3.4.2    |         | Tratamento de Bordas                                                                                                                   | 136        |
| 3.4.3    |         | Correlação e Convolução                                                                                                                | 138        |
| 3.4.4    |         | Correlação vs. Convolução no OpenCV                                                                                                    | 138        |
| 3.4.5    |         | O Papel do <i>Kernel</i>                                                                                                               | 140        |
| 3.4.6    |         | Exemplo Numérico: Correlação Passo a Passo                                                                                             | 142        |
| 3.5      |         | Filtragem Espacial de Suavização                                                                                                       | 143        |
| 3.5.1    |         | Filtro de Média ( <i>Box Filter</i> )                                                                                                  | 143        |
| 3.5.2    |         | Filtro Gaussiano                                                                                                                       | 144        |
| 3.6      |         | Filtragem Espacial de Realce                                                                                                           | 146        |
| 3.6.1    |         | Laplaciano                                                                                                                             | 147        |
| 3.6.2    |         | Operador de Sobel                                                                                                                      | 150        |
| 3.6.3    |         | Operador de Prewitt                                                                                                                    | 152        |
| 3.6.4    |         | <i>Unsharp Masking</i> (USM)                                                                                                           | 153        |
| 3.6.5    |         | Detector de Canny                                                                                                                      | 155        |
| 3.7      |         | Filtros de Ordem: Filtro da Mediana                                                                                                    | 156        |
| 3.7.1    |         | Ruído Impulsivo: Sal e Pimenta                                                                                                         | 156        |
| 3.7.2    |         | Filtro da Mediana                                                                                                                      | 157        |
| 3.8      |         | Aplicação Prática: Pré-processamento para Segmentação                                                                                  | 160        |
| 3.9      |         | Resumo                                                                                                                                 | 161        |
| 3.10     |         |  Uso do Gemini Notebook como Tutor Complementar     | 161        |
| 3.11     |         | Lista de Exercícios                                                                                                                    | 162        |
|          |         | Referências do Capítulo                                                                                                                | 163        |
| 3.12     |         |  <b>Parte Prática com Exercícios de Programação</b> | 163        |
|          |         |  Objetivo deste Caderno                             | 163        |
| 3.12.1   | EP03_01 |  Adição Saturada de Constante                       | 164        |
| 3.12.2   | EP03_02 |  <i>Alpha Blending</i> de Duas Imagens              | 166        |
| 3.12.3   | EP03_03 |  Inversão de Imagem (Negativo Fotográfico)          | 167        |
| 3.12.4   | EP03_04 |  Equalização de Histograma (L bits)                 | 169        |
| 3.12.5   | EP03_05 |  Aplicação de Máscara AND Binária                   | 170        |
| 3.12.6   | EP03_06 | Filtro de Média com <i>Kernel</i> $N \times N$                                                                                         | 173        |
| 3.12.7   | EP03_07 |  Operador Laplaciano (w4) para Realce de Bordas     | 176        |
| 3.12.8   | EP03_08 |  Gradiente de Sobel: $G_x$ e $G_y$                  | 177        |
| 3.12.9   | EP03_09 |  Filtro da Mediana $3 \times 3$                     | 181        |
| 3.12.10  | EP03_10 |  <i>Unsharp Masking</i> (USM)                       | 182        |

|          |                                                                                                                                                 |            |
|----------|-------------------------------------------------------------------------------------------------------------------------------------------------|------------|
| <b>4</b> | <b>Morfologia Matemática e Segmentação de Imagens</b>                                                                                           | <b>185</b> |
| 4.1      | Objetivos                                                                                                                                       | 185        |
| 4.2      | Limiarização                                                                                                                                    | 186        |
| 4.2.1    | Imagem de Moedas                                                                                                                                | 187        |
| 4.2.2    | Escolha do Pré-processamento para o Otsu                                                                                                        | 188        |
| 4.2.3    | Resultado: CLAHE como Melhor Pré-processamento                                                                                                  | 190        |
| 4.3      | Morfologia Matemática                                                                                                                           | 191        |
| 4.3.1    | Erosão e Dilatação                                                                                                                              | 191        |
| 4.3.2    | Abertura e Fechamento                                                                                                                           | 198        |
| 4.3.3    | Operadores Geodésicos                                                                                                                           | 201        |
| 4.3.4    | Reconstrução Morfológica                                                                                                                        | 205        |
| 4.3.5    | Preenchimento de Buracos e Remoção de Bordas                                                                                                    | 207        |
| 4.3.6    | <i>Pipeline</i> de Limpeza Binária com CLAHE                                                                                                    | 210        |
| 4.3.7    | Morfologia em Tons de Cinza                                                                                                                     | 211        |
| 4.4      | Segmentação de Imagens: Fundamentação e Taxonomia                                                                                               | 214        |
| 4.4.1    | Rotulação                                                                                                                                       | 215        |
| 4.4.2    | Transformada de Distância                                                                                                                       | 218        |
| 4.4.3    | Transformada de Distância Euclidiana em quatro passos                                                                                           | 222        |
| 4.4.4    | Segmentação por <i>Watershed</i>                                                                                                                | 224        |
| 4.5      | Extração de Componentes e Descritores de Forma                                                                                                  | 230        |
| 4.5.1    | Rotulação e Estatísticas de Componentes                                                                                                         | 231        |
| 4.5.2    | Descritores de Forma                                                                                                                            | 232        |
| 4.5.3    | Conexão com Detecção de Objetos Moderna                                                                                                         | 234        |
| 4.6      | Resumo                                                                                                                                          | 236        |
| 4.7      |  Uso do Gemini Notebook como Tutor Complementar              | 237        |
| 4.8      | Lista de Exercícios                                                                                                                             | 237        |
|          | Referências do Capítulo                                                                                                                         | 238        |
| 4.9      |  <b>Parte Prática com Exercícios de Programação</b>          | 238        |
|          |  Objetivo deste Caderno                                      | 239        |
| 4.9.1    | EP04_01 Limiarização Global por Limiar Fixo                                                                                                     | 239        |
| 4.9.2    | EP04_02  Limiarização Automática de Otsu                     | 241        |
| 4.9.3    | EP04_03  Dilatação Binária Plana (mm.dil0)                   | 244        |
| 4.9.4    | EP04_04  Erosão Binária Plana (mm.ero0)                      | 245        |
| 4.9.5    | EP04_05  Abertura Morfológica (Remoção de Ruído)             | 249        |
| 4.9.6    | EP04_06  Fechamento Morfológico (Preenchimento de Falhas)    | 251        |
| 4.9.7    | EP04_07 Dilatação e Erosão com Pesos (mm.dil1 / mm.ero1)                                                                                        | 253        |
| 4.9.8    | EP04_08  Gradiente Morfológico, Top-hat e Black-hat          | 255        |
| 4.9.9    | EP04_09 Transformada de Distância e o “Miolo” do Objeto                                                                                         | 257        |
| 4.9.10   | EP04_10  Separação de <i>Blobs</i> , Rotulação e Descritores | 258        |
| <b>5</b> | <b>Transformadas e Compressão</b>                                                                                                               | <b>262</b> |
| 5.1      | Objetivos                                                                                                                                       | 262        |
| 5.2      | Configuração do Ambiente                                                                                                                        | 263        |
| 5.3      | Transformada de Fourier Discreta 2D                                                                                                             | 263        |
| 5.3.1    | Simulador: Reconstruindo Sinais com Senoides                                                                                                    | 263        |
| 5.3.2    | Interpretação do espectro de frequência                                                                                                         | 264        |
| 5.3.3    | O Experimento da Grade: Construindo uma Imagem a partir de um Único Coeficiente                                                                 | 266        |
| 5.3.4    | Definição Matemática                                                                                                                            | 267        |
| 5.3.5    | Magnitude e Fase                                                                                                                                | 268        |
| 5.3.6    | O que a Magnitude e a Fase carregam?                                                                                                            | 269        |
| 5.4      | Teorema da Convolução e Estratégias de Filtragem                                                                                                | 271        |
| 5.4.1    | <i>Kernel</i> Separável vs. Não Separável                                                                                                       | 271        |
| 5.4.2    | Análise de Eficiência Computacional                                                                                                             | 272        |
| 5.4.3    | Discussão dos resultados experimentais                                                                                                          | 272        |

|        |                                                                                    |     |
|--------|------------------------------------------------------------------------------------|-----|
| 5.5    | Filtros no Domínio da Frequência . . . . .                                         | 276 |
| 5.5.1  | Filtros Passa-Baixa . . . . .                                                      | 277 |
| 5.5.2  | Filtros Passa-Alta e Passa-Banda . . . . .                                         | 277 |
| 5.5.3  | Remoção de Ruído Periódico . . . . .                                               | 281 |
|        | ✚ Síntese — Filtros Espectrais . . . . .                                           | 283 |
| 5.6    | <i>Wavelets</i> e Multirresolução . . . . .                                        | 283 |
| 5.6.1  | O Limite da Transformada de Fourier: localização espacial . . . . .                | 283 |
| 5.6.2  | Transformada <i>Wavelet</i> Discreta 2D . . . . .                                  | 284 |
| 5.6.3  | Famílias de <i>Wavelets</i> . . . . .                                              | 284 |
| 5.6.4  | Análise Multirresolução com a DWT 2D . . . . .                                     | 288 |
|        | Síntese — Fourier vs. <i>Wavelets</i> : quando utilizar cada abordagem? . . . . .  | 293 |
| 5.7    | Compressão de Imagens . . . . .                                                    | 294 |
| 5.7.1  | Taxonomia das Redundâncias . . . . .                                               | 294 |
| 5.7.2  | Transformada de Cossenos Discreta (DCT-II 2D) . . . . .                            | 295 |
| 5.7.3  | As Funções de Base da DCT . . . . .                                                | 295 |
| 5.7.4  | Concentração de Energia e Reconstrução Progressiva . . . . .                       | 296 |
| 5.7.5  | O <i>Pipeline</i> de Compressão JPEG . . . . .                                     | 298 |
| 5.7.6  | Simulador Interativo: Quantização DCT . . . . .                                    | 301 |
| 5.8    | Comparação de Formatos de Imagem . . . . .                                         | 302 |
| 5.8.1  | Características dos Formatos . . . . .                                             | 302 |
| 5.8.2  | Métricas de Avaliação de Qualidade . . . . .                                       | 302 |
| 5.8.3  | Inspeção Visual: Natureza dos Artefatos de Compressão . . . . .                    | 303 |
| 5.8.4  | Avaliação Quantitativa e Espacial da Compressão . . . . .                          | 304 |
|        | Síntese — Compressão JPEG . . . . .                                                | 309 |
| 5.9    | Aplicação Prática: Remoção de Ruído por Filtragem Híbrida . . . . .                | 310 |
| 5.9.1  | Análise de Desempenho e Conclusão do Capítulo . . . . .                            | 310 |
| 5.10   | Resumo do Capítulo . . . . .                                                       | 312 |
|        | Fundamentos Essenciais . . . . .                                                   | 312 |
| 5.11   | 📖 Uso do Gemini Notebook como Tutor Complementar . . . . .                         | 314 |
| 5.12   | Lista de Exercícios . . . . .                                                      | 314 |
|        | Referências do Capítulo . . . . .                                                  | 315 |
| 5.13   | 🖥️ <b>Parte Prática com Exercícios de Programação</b> . . . . .                    | 315 |
|        | 🎯 Objetivo deste Caderno . . . . .                                                 | 316 |
| 5.13.1 | EP05_01 🟢 Filtro Passa-Baixa Ideal por Distância no Espectro . . . . .             | 317 |
| 5.13.2 | EP05_02 🟡 Filtro <i>Notch</i> : Removendo Picos Periódicos . . . . .               | 318 |
| 5.13.3 | EP05_03 🟠 Quantização DCT: a Verdadeira Fonte de Compressão . . . . .              | 320 |
| 5.13.4 | EP05_04 🔴 Implementando a DFT 2D a Partir da Definição . . . . .                   | 322 |
| 5.13.5 | EP05_05 🏆 <i>Pipeline</i> JPEG Completo: DCT, Quantização e Reconstrução . . . . . | 325 |

## II Parte II — Visão Computacional 328

|       |                                                                                     |     |
|-------|-------------------------------------------------------------------------------------|-----|
| 6     | <b>Análise de Documentos e Inspeção Industrial</b>                                  | 329 |
| 6.1   | Objetivos do Capítulo . . . . .                                                     | 329 |
| 6.2   | Configuração do Ambiente . . . . .                                                  | 330 |
| 6.3   | Bases de Imagens para Experimentação . . . . .                                      | 331 |
| 6.3.1 | Imagens Públicas com <code>skimage.data</code> . . . . .                            | 331 |
| 6.4   | Normalização de Fundo e Equalização Local de Contraste . . . . .                    | 333 |
| 6.5   | Reconhecimento Óptico de Caracteres (OCR) . . . . .                                 | 335 |
| 6.6   | Tradução Automática do Texto Reconhecido . . . . .                                  | 338 |
| 6.7   | Fundamentos de OMR e Inspeção Industrial . . . . .                                  | 340 |
| 6.8   | Projetos Práticos: Construção de um <i>Pipeline</i> de Análise Documental . . . . . | 340 |
| 6.8.1 | Alinhamento Automático de Documentos ( <i>OCR/OMR Pre-processing</i> ) . . . . .    | 341 |
| 6.8.2 | Algoritmo de Retificação de Inclinação ( <i>Deskew</i> ) . . . . .                  | 342 |



|          |                                                                                                                                                                                   |            |
|----------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------|
| 6.8.3    | Modelagem Matemática . . . . .                                                                                                                                                    | 342        |
| 6.8.4    | Limitações Práticas . . . . .                                                                                                                                                     | 346        |
| 6.8.5    | Detecção de Bordas e Contornos . . . . .                                                                                                                                          | 347        |
| 6.8.6    | Isolamento, Segmentação e Decodificação do <i>QRCode</i> . . . . .                                                                                                                | 349        |
| 6.8.7    | Decodificação de Códigos de Barras . . . . .                                                                                                                                      | 354        |
| 6.9      | O MCTest como Estudo de Caso: do Protótipo ao Sistema em Produção . . . . .                                                                                                       | 355        |
| 6.9.1    | Obtenção e Preparação do Módulo . . . . .                                                                                                                                         | 355        |
| 6.9.2    | Extração da Área de Respostas . . . . .                                                                                                                                           | 356        |
| 6.9.3    | Segmentação do <i>QRCode</i> . . . . .                                                                                                                                            | 358        |
| 6.9.4    | Localização dos Quadros de Respostas . . . . .                                                                                                                                    | 360        |
| 6.9.5    | Leitura Automática das Respostas . . . . .                                                                                                                                        | 360        |
| 6.10     | Inspeção Industrial Automatizada . . . . .                                                                                                                                        | 362        |
| 6.10.1   | Referências e <i>Datasets</i> Públicos . . . . .                                                                                                                                  | 363        |
| 6.10.2   | Detecção de Defeitos por Análise de Textura . . . . .                                                                                                                             | 364        |
| 6.11     | Resumo . . . . .                                                                                                                                                                  | 367        |
|          | Próximos Passos . . . . .                                                                                                                                                         | 368        |
| 6.12     |  Uso do Gemini Notebook como Tutor Complementar . . . . .                                        | 368        |
| 6.13     | Lista de Exercícios . . . . .                                                                                                                                                     | 369        |
|          | Referências do Capítulo . . . . .                                                                                                                                                 | 369        |
| 6.14     |  Parte Prática com Exercícios de Programação . . . . .                                           | 370        |
|          | Legenda de Dificuldade . . . . .                                                                                                                                                  | 370        |
|          |  Objetivo deste Caderno . . . . .                                                                | 371        |
| 6.14.1   | EP06_01  Avaliação de Segmentação por IoU ( <i>Intersection over Union</i> ) . . . . .           | 372        |
| 6.14.2   | EP06_02  Filtro de Marcadores por Circularidade . . . . .                                       | 375        |
| 6.14.3   | EP06_03  Classificação de Marcações em Folhas de Resposta (OMR) . . . . .                      | 377        |
| 6.14.4   | EP06_04  Estimador de Inclinação por Mediana Angular ( <i>Deskew</i> ) . . . . .               | 379        |
| 6.14.5   | EP06_05  Normalização de Fundo por Divisão (Correção de Iluminação) . . . . .                  | 380        |
| 6.14.6   | EP06_06  Mapa de Variância Local para Detecção de Textura . . . . .                            | 382        |
| 6.14.7   | EP06_07  <i>Pipeline</i> de Inspeção Industrial: Registro por Translação e Subtração . . . . . | 384        |
| 6.14.8   | EP06_08  Segmentação e Decodificação Real de <i>QRCode</i> com OpenCV . . . . .                | 386        |
| <b>7</b> | <b>Classificação de Imagens e Reconhecimento de Padrões</b>                                                                                                                       | <b>391</b> |
| 7.1      | Objetivos do Capítulo . . . . .                                                                                                                                                   | 391        |
| 7.2      | Configuração do Ambiente . . . . .                                                                                                                                                | 391        |
| 7.3      | Um Problema Concreto: Classificação de Frutas . . . . .                                                                                                                           | 393        |
| 7.4      | Panorama do Capítulo: O <i>Pipeline</i> Clássico de Classificação de Imagens . . . . .                                                                                            | 395        |
| 7.5      | Fundamentos de Reconhecimento de Padrões . . . . .                                                                                                                                | 395        |
| 7.6      | Extração de Descritores Clássicos . . . . .                                                                                                                                       | 396        |
| 7.6.1    | <i>Local Binary Patterns</i> (LBP) . . . . .                                                                                                                                      | 397        |
| 7.6.2    | <i>Histogram of Oriented Gradients</i> (HOG) . . . . .                                                                                                                            | 399        |
| 7.6.3    | O Impacto da Escala e a Normalização de Características . . . . .                                                                                                                 | 401        |
| 7.7      |  Mapa Conceitual . . . . .                                                                     | 403        |
| 7.8      | Descritores na Prática . . . . .                                                                                                                                                  | 403        |
| 7.9      | Um Problema Concreto: Simulando Descritores de Frutas . . . . .                                                                                                                   | 408        |
| 7.10     | Classificador k-NN: Como Funciona por Dentro . . . . .                                                                                                                            | 411        |
| 7.10.1   | Métrica de Distância . . . . .                                                                                                                                                    | 412        |
| 7.10.2   | Regra de Decisão . . . . .                                                                                                                                                        | 412        |
| 7.10.3   | O Papel do Parâmetro $k$ . . . . .                                                                                                                                                | 414        |
| 7.11     | Projeto Prático 1: Classificação de Dígitos Manuscritos com k-NN . . . . .                                                                                                        | 415        |
| 7.11.1   | Classificação com Vetores de Intensidade . . . . .                                                                                                                                | 416        |
| 7.11.2   | Classificação com Descritores HOG . . . . .                                                                                                                                       | 417        |
| 7.12     | Avaliação de Classificadores . . . . .                                                                                                                                            | 419        |
| 7.12.1   | Escolha de $k$ por Validação Cruzada . . . . .                                                                                                                                    | 419        |
| 7.12.2   | O Compromisso entre Viés e Variância: Diagnóstico de <i>Overfitting</i> e <i>Underfitting</i> . . . . .                                                                           | 420        |

|        |                                                                                                                                                                           |     |
|--------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 7.13   | Projeto Prático 2: Comparação de Descritores para Classificação de Texturas . . . . .                                                                                     | 422 |
| 7.13.1 | <i>Pipeline</i> de Extração de Características e Avaliação Comparativa . . . . .                                                                                          | 424 |
| 7.13.2 | Diagnóstico Fino do Classificador: Precisão, Revocação e F1-Score . . . . .                                                                                               | 427 |
| 7.14   | Limitações dos Descritores Artesanais . . . . .                                                                                                                           | 429 |
| 7.15   | Resumo . . . . .                                                                                                                                                          | 430 |
| 7.16   |  Uso do Gemini Notebook como Tutor . . . . .                                             | 430 |
| 7.17   | Lista de Exercícios . . . . .                                                                                                                                             | 430 |
|        | Referências do Capítulo . . . . .                                                                                                                                         | 431 |
| 7.18   |  <b>Parte Prática com Exercícios de Programação</b> . . . . .                            | 431 |
|        |  Objetivo deste Caderno . . . . .                                                        | 432 |
|        | <i>Download</i> . . . . .                                                                                                                                                 | 432 |
|        | Resumo dos Métodos do <code>morph.py</code> (Cap. 7) . . . . .                                                                                                            | 433 |
| 7.18.1 | EP07_01  Classificador k-NN Passo a Passo . . . . .                                      | 433 |
| 7.18.2 | EP07_02  Normalização <i>Z-score</i> e Robustez do k-NN a Escalas Distintas . . . . .    | 435 |
| 7.18.3 | EP07_03  Avaliação por Matriz de Confusão . . . . .                                      | 438 |
| 7.18.4 | EP07_04  Codificação Manual do Descritor LBP . . . . .                                   | 440 |
| 7.18.5 | EP07_05  Histograma de Orientações de uma Célula HOG . . . . .                           | 442 |
| 7.18.6 | EP07_06  <i>Pipeline</i> Completo: Descritores + k-NN + Avaliação Multi-Classe . . . . . | 445 |
| 7.18.7 | EP07_07  Classificação Real de um Mosaico de Texturas via LBP + k-NN . . . . .           | 448 |
| 8      | <b>Compreendendo Cenas: Correspondência de Características, Detecção e Segmentação</b> 454                                                                                |     |
| 8.1    | Objetivos do Capítulo . . . . .                                                                                                                                           | 454 |
| 8.2    | Configuração do Ambiente . . . . .                                                                                                                                        | 455 |
| 8.3    | Detectores e Descritores Locais de Características . . . . .                                                                                                              | 456 |
| 8.3.1  | O Algoritmo ORB ( <i>Oriented FAST and Rotated BRIEF</i> ) . . . . .                                                                                                      | 456 |
| 8.3.2  | Explorando o Simulador do ORB . . . . .                                                                                                                                   | 457 |
| 8.4    | Correspondência de Características e Homografia com ORB . . . . .                                                                                                         | 458 |
| 8.4.1  | Detectando e Correspondendo Características com ORB . . . . .                                                                                                             | 460 |
| 8.5    | Modelagem Matemática: Homografia e RANSAC . . . . .                                                                                                                       | 462 |
| 8.5.1  | Homografia . . . . .                                                                                                                                                      | 462 |
| 8.5.2  | RANSAC . . . . .                                                                                                                                                          | 462 |
| 8.5.3  | Estimando a Homografia com RANSAC . . . . .                                                                                                                               | 464 |
| 8.5.4  | Registrando a Imagem . . . . .                                                                                                                                            | 465 |
| 8.6    | Detecção de Objetos: <i>Haar Cascade</i> (Viola-Jones) . . . . .                                                                                                          | 467 |
| 8.7    | Detecção de Objetos: Caixas Delimitadoras, IoU e NMS . . . . .                                                                                                            | 469 |
| 8.7.1  | <i>Intersection over Union</i> (IoU) . . . . .                                                                                                                            | 470 |
| 8.7.2  | Supressão de Não-Máximos (NMS) . . . . .                                                                                                                                  | 470 |
| 8.8    | Segmentação Visual: Semântica, de Instâncias e Panóptica . . . . .                                                                                                        | 472 |
| 8.8.1  | Segmentação Semântica por Limiarização . . . . .                                                                                                                          | 472 |
| 8.8.2  | Segmentação de Instâncias por Rotulação . . . . .                                                                                                                         | 472 |
| 8.8.3  | Alternativa: Transformada de Distância + <i>Watershed</i> . . . . .                                                                                                       | 474 |
| 8.8.4  | Medição e Extração de Atributos com <code>mm.measure</code> . . . . .                                                                                                     | 476 |
| 8.8.5  | Exportação de Anotações: de <code>mm.measure</code> ao Formato YOLO . . . . .                                                                                             | 478 |
| 8.8.6  | Validação de Anotações por IoU: <code>mm.verifyBoundingBox</code> . . . . .                                                                                               | 479 |
| 8.8.7  | Visualização de Anotações Salvas: <code>mm.showBoundingBox</code> . . . . .                                                                                               | 479 |
| 8.9    | Visão Geral dos Modelos Modernos . . . . .                                                                                                                                | 480 |
| 8.10   | Limitações das Abordagens Clássicas e Motivação para o <i>Deep Learning</i> . . . . .                                                                                     | 482 |
| 8.11   | Resumo . . . . .                                                                                                                                                          | 482 |
|        | Próximos Passos . . . . .                                                                                                                                                 | 483 |
| 8.12   |  Uso do Gemini Notebook como Apoio ao Estudo . . . . .                                 | 483 |
| 8.13   | Lista de Exercícios . . . . .                                                                                                                                             | 483 |
|        | Referências do Capítulo . . . . .                                                                                                                                         | 484 |
| 8.14   |  <b>Parte Prática com Exercícios de Programação</b> . . . . .                          | 484 |
|        |  Objetivo deste Caderno . . . . .                                                      | 485 |

|                                                                                                                                                                   |            |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------|
| Download                                                                                                                                                          | 485        |
| Resumo dos Métodos do <code>morph.py</code> (Cap. 8)                                                                                                              | 485        |
| 8.14.1 EP08_01  Distância de Hamming e Correspondência de Descritores Binários   | 486        |
| 8.14.2 EP08_02  Homografia e RANSAC: A Votação por <i>Inliers</i>                | 487        |
| 8.14.3 EP08_03  Imagem Integral: Somas Retangulares em Tempo Constante           | 490        |
| 8.14.4 EP08_04  IoU e Supressão de Não-Máximos (NMS)                             | 493        |
| 8.14.5 EP08_05  Rotulação de Componentes Conectados: Segmentação de Instâncias   | 495        |
| 8.14.6 EP08_06  Segmentação de Instâncias em Imagem Real: Objetos Geométricos    | 497        |
| <b>9 Aprendizado Profundo para Visão Computacional</b>                                                                                                            | <b>502</b> |
| 9.1 Objetivos do Capítulo                                                                                                                                         | 502        |
| 9.2 Panorama: Classificação, Detecção e Segmentação                                                                                                               | 503        |
| 9.3 Configuração do Ambiente                                                                                                                                      | 504        |
| 9.4 Da Convolução Fixa à Convolução Aprendida                                                                                                                     | 505        |
| 9.4.1 Neurônio Artificial                                                                                                                                         | 506        |
| 9.4.2 Camada Convolucional                                                                                                                                        | 508        |
| 9.4.3 Função de Ativação                                                                                                                                          | 508        |
| 9.4.4 <i>Pooling</i>                                                                                                                                              | 510        |
| 9.4.5 Treinamento de Redes Neurais: Como as CNNs Aprendem                                                                                                         | 510        |
| 9.4.6 Arquitetura de uma CNN                                                                                                                                      | 513        |
| 9.5 Projeto Prático 1: Uma CNN do Zero para os Dígitos do Capítulo 7                                                                                              | 515        |
| 9.5.1 Comparando com o Capítulo 7                                                                                                                                 | 518        |
| 9.6 Transferência de Aprendizado                                                                                                                                  | 519        |
| 9.7 Aplicações em Larga Escala com Modelos Pré-treinados                                                                                                          | 523        |
| 9.7.1 Classificação de Imagens                                                                                                                                    | 523        |
| 9.7.2 Detecção de Objetos                                                                                                                                         | 523        |
| 9.7.3 Segmentação Semântica                                                                                                                                       | 524        |
| 9.8 Projeto Prático 2: Detecção de Objetos com YOLO e Transferência de Aprendizado                                                                                | 525        |
| 9.8.1 Gerando um Conjunto de Dados Sintético de Objetos Geométricos                                                                                               | 525        |
| 9.8.2 Ajuste Fino de um YOLO Pré-treinado                                                                                                                         | 528        |
| 9.8.3 Usando um Conjunto de Dados Real                                                                                                                            | 539        |
| 9.9 Projeto Prático 3: Segmentação Semântica com U-Net                                                                                                            | 540        |
| 9.9.1 Um Conjunto Sintético de Imagens com Nódulos                                                                                                                | 540        |
| 9.9.2 Linha de Base Clássica: Limiarização com <i>Kernel</i> Fixo                                                                                                 | 541        |
| 9.9.3 Arquitetura U-Net: Codificador-Decodificador com Conexões de Atalho                                                                                         | 542        |
| 9.9.4 Comparando com a Linha de Base Clássica                                                                                                                     | 545        |
| 9.9.5 Aplicando a Mesma Pipeline a um Conjunto de Dados Real: Roboflow                                                                                            | 548        |
| 9.10 Integrando Geometria e Aprendizado Profundo                                                                                                                  | 550        |
| 9.10.1 Realidade Aumentada                                                                                                                                        | 550        |
| 9.10.2 Fotogrametria e Referência de Escala                                                                                                                       | 550        |
| 9.10.3 Visão Estereoscópica                                                                                                                                       | 553        |
| 9.11 Resumo                                                                                                                                                       | 554        |
| 9.12  Uso do Gemini Notebook como Tutor Complementar                           | 554        |
| 9.13 Lista de Exercícios                                                                                                                                          | 554        |
| 9.14 Encerramento da Parte II                                                                                                                                     | 555        |
| Referências do Capítulo                                                                                                                                           | 556        |
| 9.15  <b>Parte Prática com Exercícios de Programação</b>                       | 556        |
|  Objetivo deste Caderno                                                        | 557        |
| 9.15.1 EP09_01  Convolução 2D Manual (Forward de uma Camada Aprendida)         | 558        |
| 9.15.2 EP09_02  <i>Pooling</i> Manual (Máximo e Média)                         | 560        |
| 9.15.3 EP09_03  Contagem de Parâmetros Treináveis de uma CNN                   | 562        |
| 9.15.4 EP09_04  Interseção sobre União (IoU) e Supressão de Não-Máximos (NMS)  | 564        |
| 9.15.5 EP09_05  <i>Pipeline</i> Integrado: Da Detecção à Medição do Mundo Real | 567        |

---

**Referências****570**



# Lista de Figuras

|      |                                                                                                                                                                                                                                                                                                                                                 |    |
|------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 1    | Botão clicável <b>Executar Colab</b> , disponível no início das partes <b>Teórica</b> e <b>Prática</b> de cada capítulo, permitindo a execução interativa dos exemplos e exercícios. . . . .                                                                                                                                                    | 24 |
| 1.1  | Diagrama relacional detalhando as distinções fundamentais, sinergias e interconexões entre PDI e VC no contexto de sistemas baseados em imagens. . . . .                                                                                                                                                                                        | 30 |
| 1.2  | Representação do fluxo sequencial de processamento: a saída de cada nível torna-se a entrada do nível subsequente. . . . .                                                                                                                                                                                                                      | 32 |
| 1.3  | Fluxo detalhado do PDI: da aquisição sensorial à extração de atributos e reconhecimento automatizado, incluindo em processamento colorido e compressão. . . . .                                                                                                                                                                                 | 32 |
| 1.4  | Representação do espectro visível e sua posição em relação às demais radiações eletromagnéticas, destacando a variação dos comprimentos de onda de 380 nm a 750 nm. . . . .                                                                                                                                                                     | 33 |
| 1.5  | (A) Espectro eletromagnético completo em escala logarítmica, com destaque para a faixa visível. (B) Detalhe da luz visível (380-750 nm) e suas cores. (C) Decomposição da luz branca pelo prisma: menor comprimento de onda sofre maior refração, separando UV, visível e infravermelho. . . . .                                                | 33 |
| 1.6  | Exemplos de imagens sintéticas representadas matricialmente. . . . .                                                                                                                                                                                                                                                                            | 37 |
| 1.7  | Mandrill (Mandrillus sphinx) em ambiente natural. Crédito: Julien Renoult (CC BY 4.0). . .                                                                                                                                                                                                                                                      | 38 |
| 1.8  | Processamento básico de imagens: (a) imagem original, (b) imagem em tons de cinza, (c) imagem binarizada por limiar ( $T=128$ ). . . . .                                                                                                                                                                                                        | 40 |
| 1.9  | Comparação entre limiarização manual ( $T=128$ ) e automática (Otsu) sobre a imagem em tons de cinza. . . . .                                                                                                                                                                                                                                   | 41 |
| 1.10 | Acesso a um pixel específico ( $r, c$ ) e a representação de sua vizinhança na imagem. . . . .                                                                                                                                                                                                                                                  | 42 |
| 1.11 | Estúdio do Gemini Notebook. . . . .                                                                                                                                                                                                                                                                                                             | 44 |
| 1.12 | Simulador: Distâncias Euclidiana, <i>City-block</i> e <i>Chessboard</i> . . . . .                                                                                                                                                                                                                                                               | 49 |
| 1.13 | Simulador: Desempenho Preditivo — Métricas de ML . . . . .                                                                                                                                                                                                                                                                                      | 56 |
| 1.14 | Simulador: <i>Mean Average Precision</i> (mAP) - Curva P.S . . . . .                                                                                                                                                                                                                                                                            | 59 |
| 1.15 | Simulador: Estatísticas de Pixels . . . . .                                                                                                                                                                                                                                                                                                     | 61 |
| 1.16 | Simulador: Transformação de Negativo . . . . .                                                                                                                                                                                                                                                                                                  | 63 |
| 1.17 | Simulador: Percepção de Cor e Pesos ITU-R . . . . .                                                                                                                                                                                                                                                                                             | 64 |
| 1.18 | Simulador: Limiarização Interativa . . . . .                                                                                                                                                                                                                                                                                                    | 66 |
| 1.19 | Simulador: Ajuste de Brilho e Contraste . . . . .                                                                                                                                                                                                                                                                                               | 68 |
| 1.20 | Simulador: Gerador de Xadrez . . . . .                                                                                                                                                                                                                                                                                                          | 70 |
| 1.21 | Simulador: Estrutura do Arquivo PGM . . . . .                                                                                                                                                                                                                                                                                                   | 72 |
| 1.22 | Simulador: Filtro de Máximo Local 1D . . . . .                                                                                                                                                                                                                                                                                                  | 74 |
| 2.1  | Comparativo didático entre o sistema visual biológico e o eletrônico: no topo, a anatomia do olho humano destacando a retina e os fotorreceptores (cones e bastonetes); abaixo, a estrutura de uma câmera digital detalhando o sensor CMOS, a matriz de filtros de Bayer (RGGB) e o processo de quantização digital realizado pelo ADC. . . . . | 76 |
| 2.2  | Coletânea de desafios perceptivos: (topo esquerdo) Vaso de Rubin — ambiguidade figura-fundo; (topo central) Elefante de Shepard — incongruência geométrica; (topo direita) Sombra de Adelson — constância de brilho baseada no contexto; (inferior esquerdo) Grade de pontos — inibição lateral; (inferior direito) Escada de Schröder. . . . . | 77 |
| 2.3  | Imagem RGB (3 canais, $M \times N \times 3$ ) e versão RGBA (4 canais, $M \times N \times 4$ ) com transparência alfa gradual da esquerda para a direita. Imagem Mandrill — <a href="#">USC SIPI Image Database</a> (domínio público). . . . .                                                                                                  | 81 |

|      |                                                                                                                                                                                                                                                                                          |     |
|------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 2.4  | Efeito da subamostragem. Os títulos exibem as dimensões (W x H) e o tamanho da matriz em memória (KB). . . . .                                                                                                                                                                           | 83  |
| 2.5  | Efeito da redução da profundidade de bits. Os títulos exibem a quantidade de bits, níveis e o tamanho em memória (KB). . . . .                                                                                                                                                           | 84  |
| 2.6  | Ilustração de vizinhanças 4 em uma matriz 3x3. No centro (1,1), o pixel de interesse. . . . .                                                                                                                                                                                            | 85  |
| 2.7  | Area de Proteção Ambiental Quilombos do Médio Ribeira - Barbudo-rajado ( <i>Malacoptila striata</i> ). Crédito: Thomas Fuhrmann (CC BY-SA 4.0). . . . .                                                                                                                                  | 88  |
| 2.8  | Exemplo de translação da imagem do pássaro com deslocamentos (50,50) e (100,50). . . . .                                                                                                                                                                                                 | 90  |
| 2.9  | Exemplo de rotação da imagem do pássaro em 30° e 45° usando interpolação bilinear. . . . .                                                                                                                                                                                               | 91  |
| 2.10 | Comparação de interpolação com zoom no detalhe do olho (recorte 60x60, ampliado 4x). Note o efeito de blocos no vizinho mais próximo vs. a suavização na bilinear. . . . .                                                                                                               | 93  |
| 2.11 | Exemplo de cisalhamento da imagem do pássaro: horizontal (shx=0.3), vertical (shy=0.3) e combinado (shx=0.2, shy=0.2). . . . .                                                                                                                                                           | 94  |
| 2.12 | Simulador: Ajuste de Brilho e Contraste . . . . .                                                                                                                                                                                                                                        | 98  |
| 2.13 | Simulador: Subamostragem . . . . .                                                                                                                                                                                                                                                       | 100 |
| 2.14 | Simulador: Quantização . . . . .                                                                                                                                                                                                                                                         | 102 |
| 2.15 | Simulador: Ajuste de Brilho e Contraste . . . . .                                                                                                                                                                                                                                        | 104 |
| 2.16 | Simulador: Translação (tx, ty) . . . . .                                                                                                                                                                                                                                                 | 106 |
| 2.17 | Simulador: Rotação (ângulo) . . . . .                                                                                                                                                                                                                                                    | 108 |
| 2.18 | Simulador: Redimensionamento (Nearest vs Bilinear) . . . . .                                                                                                                                                                                                                             | 110 |
| 2.19 | Simulador: Cisalhamento (shx, shy) . . . . .                                                                                                                                                                                                                                             | 113 |
| 2.20 | Simulador: Transformação Afim (matriz 2x3) . . . . .                                                                                                                                                                                                                                     | 115 |
| 2.21 | Simulador: Correção de Perspectiva (Homografia) . . . . .                                                                                                                                                                                                                                | 117 |
| 2.22 | Aquisição da imagem de um Sudoku à esquerda. À direita, conversão para tons de cinza e redimensionamento. Crédito: Héctor Rodríguez de Guardamar, Espanha (CC BY 2.0). . . . .                                                                                                           | 119 |
| 2.23 | Correção de perspectiva: original e vista frontal retificada. . . . .                                                                                                                                                                                                                    | 120 |
| 2.24 | Simulador: correção de perspectiva do Sudoku. . . . .                                                                                                                                                                                                                                    | 121 |
| 3.1  | <i>Mandrill</i> ( <i>Mandrillus sphinx</i> ) fotografado em ambiente natural na África do Sul. A imagem possui resolução de 500 px e contém metadados EXIF com coordenadas GPS aproximadas (-26.20473, 28.22662). Crédito: Carlos Guilherme Rodrigues (CC BY-SA 3.0). . . . .            | 125 |
| 3.2  | Operações aritméticas saturadas: adição de constante (clareamento) e subtração de constante (escurecimento com saturação em 0). . . . .                                                                                                                                                  | 126 |
| 3.3  | Retrato de um leopardo ( <i>Panthera pardus</i> ) em ambiente natural. Crédito: C. Brück (CC BY-SA 4.0). . . . .                                                                                                                                                                         | 127 |
| 3.4  | <i>Alpha blending</i> entre recortes alinhados de mandrill e do leopardo (Figure 3.3) para diferentes valores de $\alpha$ . Em $\alpha=1$ vê-se apenas mandrill; em $\alpha=0$ , apenas o leopardo; valores intermediários fundem os olhares das duas imagens proporcionalmente. . . . . | 128 |
| 3.5  | Operações lógicas bit a bit com máscara circular: AND (isolamento da ROI), OR (iluminação da ROI) e NOT (negativo). . . . .                                                                                                                                                              | 129 |
| 3.6  | Histogramas da imagem original, de uma versão escurecida e de uma versão clareada. Os valores na segunda linha indicam a quantidade de pixels saturados em 0 (preto) e 255 (branco). . . . .                                                                                             | 130 |
| 3.7  | Equalização de histograma em imagem 5x5 com 3 bits (L=8): imagem original com tons concentrados em {2,3,4}, imagem equalizada com tons redistribuídos para {1,5,7}, e os respectivos histogramas evidenciando o espalhamento das frequências. . . . .                                    | 132 |
| 3.8  | Equalização de histograma: mm.equalize (global via CDF) vs. CLAHE (adaptativa com limitação de contraste). Os histogramas revelam o espalhamento progressivo das intensidades. . . . .                                                                                                   | 134 |
| 3.9  | Especificação de histograma: mandril mapeada para o perfil tonal do leopardo. A CDF da saída aproxima a CDF de referência. . . . .                                                                                                                                                       | 135 |
| 3.10 | Correlação com <i>kernel</i> de média 3x3: versão didática (mm.conv0) vs. vetorizada (mm.conv via cv2.filter2D). A diferença máxima de 39 ocorre nas bordas. . . . .                                                                                                                     | 142 |
| 3.11 | <i>Patch</i> 5x5 extraído da imagem do leopardo (posição [250:255, 250:255]). A janela amarela destaca a vizinhança 3x3 centrada no pixel [1,1] onde a correlação será calculada. . . . .                                                                                                | 143 |

|      |                                                                                                                                                                                                                                               |     |
|------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 3.12 | Filtro de média com <i>kernels</i> de tamanho crescente ( $3\times 3$ , $7\times 7$ , $15\times 15$ ). O borramento das bordas aumenta com o tamanho do <i>kernel</i> . . . . .                                                               | 144 |
| 3.13 | <i>Kernel</i> Gaussiano $5\times 5$ ( $=1$ ): pesos normalizados, maiores no centro e decrescentes radialmente. A grade facilita a leitura de cada coeficiente. . . . .                                                                       | 145 |
| 3.14 | Comparação entre filtro de média e Gaussiano ( <i>kernel</i> $9\times 9$ , $=0$ ). O Gaussiano preserva melhor as bordas, visível no detalhe do rosto. . . . .                                                                                | 146 |
| 3.15 | Simulador: Filtragem Espacial de Realce 1D. . . . .                                                                                                                                                                                           | 147 |
| 3.16 | <i>Kernel</i> Laplaciano w4 aplicado ao <i>patch</i> $5\times 5$ : a janela amarela destaca a vizinhança $3\times 3$ onde o operador de segunda derivada é calculado. . . . .                                                                 | 149 |
| 3.17 | Laplaciano aplicado à imagem do leopardo: resposta bruta (bordas detectadas) com w4 e w8, e imagens realçadas pela subtração do Laplaciano. w8 é mais sensível às diagonais. . . . .                                                          | 150 |
| 3.18 | Operador de Sobel na imagem do leopardo: Gx detecta bordas verticais, Gy detecta bordas horizontais, e a magnitude $ f $ combina ambos, revelando todas as bordas independente de direção. . . . .                                            | 152 |
| 3.19 | Operador de Prewitt: Gx, Gy e magnitude — comparável ao Sobel, mas sem ponderação Gaussiana perpendicular. . . . .                                                                                                                            | 152 |
| 3.20 | Realce de nitidez por <i>Unsharp Masking</i> na imagem do leopardo: a imagem suavizada é subtraída da original para gerar a máscara de alta frequência, que é então reintroduzida para realçar bordas e detalhes. . . . .                     | 154 |
| 3.21 | <i>Unsharp Masking</i> na imagem do leopardo com $=1$ e k variando de 0.5 a 8.0. Para $k>2$ surgem artefatos nas bordas (halos) e o ruído de fundo começa a ser visível. . . . .                                                              | 155 |
| 3.22 | Detector de Canny com diferentes pares de limiar: limiares baixos capturam mais bordas (inclusive ruído); limiares altos retêm apenas as bordas mais fortes. . . . .                                                                          | 156 |
| 3.23 | Ruído sal e pimenta com densidades crescentes (2%, 5%, 10%). O parâmetro prob indica a fração total de pixels corrompidos, metade sal (255) e metade pimenta (0). . . . .                                                                     | 157 |
| 3.24 | Comparação de filtros para remoção de ruído sal e pimenta (10%): Gaussiano, Média, Mediana, Bilateral e Morfológico. Linha superior: imagens completas; linha inferior: crop da região de interesse. . . . .                                  | 160 |
| 3.25 | <i>Pipeline</i> de pré-processamento: CLAHE $\rightarrow$ Gaussiano $\rightarrow$ Canny. Cada etapa prepara a imagem para a seguinte, resultando em bordas limpas e bem definidas. . . . .                                                    | 161 |
| 3.26 | Simulador: Adição Saturada de Constante . . . . .                                                                                                                                                                                             | 165 |
| 3.27 | Simulador: Alpha <i>Blending</i> de Duas Imagens . . . . .                                                                                                                                                                                    | 167 |
| 3.28 | Simulador: Inversão de Imagem (Negativo Fotográfico) . . . . .                                                                                                                                                                                | 169 |
| 3.29 | Simulador: Equalização de Histograma (L bits) . . . . .                                                                                                                                                                                       | 171 |
| 3.30 | Simulador: Aplicação de Máscara AND Binária . . . . .                                                                                                                                                                                         | 173 |
| 3.31 | Simulador: Filtro de Média com <i>Kernel</i> $N\times N$ . . . . .                                                                                                                                                                            | 175 |
| 3.32 | Simulador: Operador Laplaciano (w4) para Realce de Bordas . . . . .                                                                                                                                                                           | 178 |
| 3.33 | Simulador: Gradiente de Sobel: Gx e Gy . . . . .                                                                                                                                                                                              | 180 |
| 3.34 | Simulador: Filtro da Mediana $3\times 3$ . . . . .                                                                                                                                                                                            | 182 |
| 3.35 | Simulador: <i>Unsharp Masking</i> (USM) . . . . .                                                                                                                                                                                             | 184 |
| 4.1  | Imagem com moedas de vários tipos. Crédito: GAZI.MD.AHAD (CC BY-SA 4.0). . . . .                                                                                                                                                              | 187 |
| 4.2  | Comparação dos pré-processamentos: imagem   histograma+T*   $^2B(T)$   Otsu. A melhor separação bimodal indica o limiar mais confiável. . . . .                                                                                               | 190 |
| 4.3  | Elemento estruturante em formato de cruz ( $B_{\text{cruz}}$ ) utilizado para conectividade-4. . . . .                                                                                                                                        | 192 |
| 4.4  | Erosão e dilatação em imagem binária $10\times 10$ com elemento estruturante 'L' assimétrico $3\times 3$ . Validação da dualidade erosão–dilatação. . . . .                                                                                   | 198 |
| 4.5  | Simulador interativo de erosão morfológica: visualização do critério de inclusão do elemento estruturante assimétrico $B_L$ sobre a imagem binária A. . . . .                                                                                 | 199 |
| 4.6  | Abertura, fechamento, composição e filtro sequencial alternado aplicados à binarização Otsu das moedas com CLAHE. Elemento estruturante: disco $13\times 13$ . . . . .                                                                        | 201 |
| 4.7  | Simulador interativo de dilatação geodésica: o marcador $f$ (verde) propaga-se passo a passo pelos caminhos livres da máscara $g$ , sem atravessar paredes — ilustrando como $\text{delta}_g^{(n)}(f)$ encontra a saída do labirinto. . . . . | 202 |

|      |                                                                                                                                                                                                                                                                                                                 |     |
|------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 4.8  | Resolução de labirinto via Operações Complementares: Invertendo a máscara e o marcador no início do <i>pipeline</i> , o fluxo é resolvido diretamente no domínio complementar através de <i>mm.cero</i> e <i>mm.suprec</i> , eliminando re-inversões redundantes. . . . .                                       | 205 |
| 4.9  | <i>Pipeline</i> de Reconstrução Morfológica por Dilatação Condicionada: a máscara contém dois objetos, o marcador isola apenas o núcleo do objeto principal, e as iterações subsequentes em laço reconstroem sua forma exata até a convergência. . . . .                                                        | 207 |
| 4.10 | <i>Pipeline</i> de preenchimento de buracos ( <i>clohole</i> ): o marcador é obtido a partir da borda da imagem e restringido ao complemento $f^c$ . As iterações de dilatação geodésica reconstruem o fundo externo; após a complementação final, os buracos internos ficam preenchidos. . . . .               | 209 |
| 4.11 | <i>Pipeline</i> de eliminação de estruturas de borda ( <i>edgeoff</i> ): o marcador captura as raízes conectadas às extremidades da matriz, a reconstrução delimita a extensão desses elementos e a subtração booleana preserva unicamente os objetos totalmente internos. . . . .                              | 210 |
| 4.12 | <i>Pipeline</i> completo de segmentação com CLAHE: Otsu → abertura ( $r=9$ ) → <i>clohole</i> → abertura ( $r=33$ ) → <i>edgeoff</i> . . . . .                                                                                                                                                                  | 211 |
| 4.13 | Simulador interativo avançado de morfologia com elemento estruturante editável e perfil 1D. . . . .                                                                                                                                                                                                             | 212 |
| 4.14 | Morfologia em tons de cinza e seus respectivos histogramas. A erosão reduz intensidades locais, a dilatação as amplia, o gradiente destaca bordas, e os operadores Top-hat e Black-hat evidenciam detalhes locais brilhantes e escuros. Elemento estruturante: disco de diâmetro 19. . . . .                    | 214 |
| 4.15 | Algoritmo de rotulação por <i>flood-fill</i> com pilha: passo a passo, cards, linha do tempo, código Python e fluxograma. . . . .                                                                                                                                                                               | 216 |
| 4.16 | Simulador interativo de rotulação de componentes conexas ( <i>connected component labeling</i> ): visualização da expansão <i>flood-fill</i> , conectividade-4 e conectividade-8. . . . .                                                                                                                       | 217 |
| 4.17 | Efeito da conectividade na rotulação: a imagem binária $10 \times 10$ contém pixels diagonalmente adjacentes. Com conectividade-4, esses pixels formam componentes distintas; com conectividade-8, fundem-se em uma única componente. . . . .                                                                   | 218 |
| 4.18 | Algoritmo da Transformada de Distância: passo a passo, cards, linha do tempo, código Python e fluxograma. . . . .                                                                                                                                                                                               | 220 |
| 4.19 | Simulador interativo da Transformada de Distância (TD) iterativa via erosão em tons de cinza. Pixels fora da imagem agora assumem o valor máximo (144), propagando os custos apenas a partir do fundo interno. . . . .                                                                                          | 221 |
| 4.20 | Transformada de Distância em imagem binária $10 \times 10$ . Esquerda: imagem original ( <i>foreground</i> = 255). Centro: <i>mm.dist1</i> iterativa (erosões com elemento cruz). Direita: <i>mm.dist</i> (L2 Euclidiana). . . . .                                                                              | 222 |
| 4.21 | Simulador interativo 2D ( $4 \times 4$ ) com sincronização estrita de filas de propagação horizontal (b) para obter a convergência exata descrita no artigo. . . . .                                                                                                                                            | 223 |
| 4.22 | Menor caminho geodésico em um labirinto. As distâncias geodésicas são calculadas a partir da entrada e da saída usando <i>mm.gdist</i> . Os pixels cujo somatório das duas distâncias é igual à distância mínima entre os marcadores pertencem a um caminho ótimo. . . . .                                      | 224 |
| 4.23 | Algoritmo Didático de <i>Watershed</i> por Crescimento de Regiões Limitado por Máscara: passo a passo, cards, linha do tempo, código Python e fluxograma. . . . .                                                                                                                                               | 226 |
| 4.24 | Simulador interativo do Algoritmo <i>Watershed</i> por propagação morfológica. Desenhe a máscara, posicione os marcadores e ajuste o Elemento Estruturante para observar a inundação. Quando as bacias se encontram simultaneamente, o empate é resolvido assumindo uma das regiões de forma aleatória. . . . . | 227 |
| 4.25 | <i>Pipeline watershed</i> delimitado por máscara em imagem binária $20 \times 20$ . . . . .                                                                                                                                                                                                                     | 228 |
| 4.26 | <i>Pipeline Watershed</i> para separação de moedas sobrepostas: da máscara binária dilatada até os contornos finais anotados sobre a imagem original. . . . .                                                                                                                                                   | 230 |
| 4.27 | Componentes conexas extraídos após o <i>pipeline</i> CLAHE → Otsu → limpeza morfológica. Cada objeto é colorido com cor distinta e anotado com sua área em pixels. . . . .                                                                                                                                      | 232 |
| 4.28 | Contornos extraídos com <i>findContours</i> . Cada moeda é anotada com sua circularidade — valores próximos de 1 confirmam forma circular. . . . .                                                                                                                                                              | 234 |



|      |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |     |
|------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 4.29 | <i>Bounding boxes</i> derivadas dos componentes conexos sobrepostas à imagem original. As anotações são exportadas no formato YOLO ( <i>classe cx cy w h</i> ), com coordenadas normalizadas para o intervalo $[0,1]$ . . . . .                                                                                                                                                                                                                                                                                                                                                                                          | 235 |
| 4.30 | Simulador: Limiarização Global por Limiar Fixo . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 | 241 |
| 4.31 | Simulador: Limiarização Automática de Otsu . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     | 243 |
| 4.32 | Simulador: Dilatação Binária Plana (mm.dil0) . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   | 246 |
| 4.33 | Simulador: Erosão Binária Plana (mm.ero0) . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      | 248 |
| 4.34 | Simulador: Abertura Morfológica (erosão + dilatação) . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           | 250 |
| 4.35 | Simulador: Fechamento Morfológico (dilatação + erosão) . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         | 252 |
| 4.36 | Simulador: Dilatação e Erosão com Pesos (mm.dil1 / mm.ero1) . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    | 254 |
| 4.37 | Simulador: Gradiente Morfológico, Top-hat e Black-hat . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          | 256 |
| 4.38 | Simulador: Transformada de Distância . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           | 259 |
| 4.39 | Simulador: Separação de Blobs, Rotulação e Descritores . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         | 261 |
| 5.1  | Decomposição de Fourier 1D: uma onda quadrada (linha tracejada) é aproximada pela soma das primeiras senoides (linhas coloridas). Quanto mais termos, melhor a aproximação. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                      | 263 |
| 5.2  | Simulador interativo da decomposição de Fourier 1D: visualização da soma de senoides com diferentes frequências, amplitudes e fases. Adicione termos e observe a convergência para formas de onda arbitrárias. . . . .                                                                                                                                                                                                                                                                                                                                                                                                   | 265 |
| 5.3  | Toda frequência no espectro (ponto isolado) corresponde a uma onda senoidal 2D rotacionada no domínio espacial. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  | 266 |
| 5.4  | Simulador interativo da síntese de Fourier 2D. Altere a posição horizontal ( $u$ ) e vertical ( $v$ ) do coeficiente no espectro de frequências centrado e observe como a distância em relação ao centro dita a frequência espacial (espessura) e o ângulo dita a orientação da onda senoidal gerada. . . . .                                                                                                                                                                                                                                                                                                            | 267 |
| 5.5  | Diagrama conceitual do espectro de Fourier 2D centrado. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          | 268 |
| 5.6  | Experimento de troca de fase: Imagem A (moedas) e Imagem B (padrão geométrico) reconstruídas com magnitudes e fases trocadas. O resultado mostra que a estrutura visual é <b>muito mais sensível à fase</b> do que à magnitude: quando a fase de B é mantida, a imagem resultante preserva a organização espacial de B, mesmo com a magnitude de A. A magnitude, por sua vez, influencia principalmente o contraste e a textura. Observe que a qualidade da reconstrução não é perfeita — há artefatos visíveis —, evidenciando a interdependência entre fase e magnitude para uma representação fiel da imagem. . . . . | 271 |
| 5.7  | Comparação de eficiência: Convolução Não Separável (Espacial 2D), Separável (Espacial 1D) e via FFT. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | 273 |
| 5.8  | Sem <i>padding</i> , um deslocamento severo faz a imagem vazar para o lado oposto (convolução circular). . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         | 274 |
| 5.9  | Verificação do Teorema da Convolução: a diferença pixel a pixel entre a convolução espacial (cv2.filter2D) e a multiplicação em frequência (FFT) é numericamente nula — confirmando a equivalência teórica. . . . .                                                                                                                                                                                                                                                                                                                                                                                                      | 275 |
| 5.10 | A Dualidade Perigosa: O corte abrupto na Frequência (Cilindro) transforma-se obrigatoriamente numa Sinc espacial. Suas ondulações causam o <i>ringing</i> fantasma nas bordas da imagem. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                         | 276 |
| 5.11 | Filtros passa-baixa. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | 277 |
| 5.12 | Simulador interativo de filtros no domínio da frequência. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        | 278 |
| 5.13 | Comparação entre filtros passa-baixa: Ideal ( $D=30$ ), Gaussiano ( $D=30$ ) e Butterworth ( $D=30$ , $n=2$ ). Perfis de $H(u,v)$ ao longo de uma linha central e imagens filtradas correspondentes. . . . .                                                                                                                                                                                                                                                                                                                                                                                                             | 280 |
| 5.14 | Filtro passa-alta Gaussiano. (a) Original; (b) Filtro passa-alta ( $D=30$ ) - as bordas das moedas e fundo texturizado são realçados. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                            | 281 |
| 5.15 | Remoção de ruído periódico via filtro <i>notch</i> no domínio da frequência: (a) imagem com ruído senoidal, (b) espectro mostrando os picos do ruído, (c) máscara <i>notch</i> centrada nos picos, (d) imagem restaurada. . . . .                                                                                                                                                                                                                                                                                                                                                                                        | 282 |
| 5.16 | Fourier global é cego para a posição. Os espectros não dizem onde as bordas estão. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               | 284 |

|      |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     |     |
|------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 5.17 | Funções da <i>Wavelet</i> ( ). Note como elas rapidamente decaem para zero (suporte compacto), ao contrário das senoides infinitas de Fourier. . . . .                                                                                                                                                                                                                                                                                                                                                              | 286 |
| 5.18 | Diagrama da decomposição <i>wavelet</i> 2D em dois níveis. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                  | 286 |
| 5.19 | Simulação da decomposição <i>wavelet</i> 2D. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                | 287 |
| 5.20 | Decomposição <i>wavelet</i> 2D de 2 níveis com <i>wavelet</i> Haar: subbandas LL, LH, HL, HH em cada nível. As subbandas de detalhe revelam estruturas orientadas em diferentes escalas utilizando um padrão sintético. . . . .                                                                                                                                                                                                                                                                                     | 289 |
| 5.21 | Comparação entre famílias de <i>wavelets</i> : Haar, db4, sym4 e bior2.2. Subbanda LL (aproximação) e HH (diagonal) para cada escolha, ilustrando o compromisso entre compactação e suavidade com base no padrão sintético. . . . .                                                                                                                                                                                                                                                                                 | 291 |
| 5.22 | Reconstrução <i>wavelet</i> com limiarização de coeficientes ( <i>hard thresholding</i> ): à medida que o limiar aumenta, mais detalhes são zerados, produzindo imagens progressivamente mais suaves. Métrica PSNR quantifica a perda de qualidade sobre o padrão sintético. . . . .                                                                                                                                                                                                                                | 293 |
| 5.23 | O Alfabeto Visual do JPEG: As 64 funções de base da DCT-II. O coeficiente DC fica no topo esquerdo (suave). Ao descer e avançar à direita, a oscilação espacial aumenta drasticamente. . . . .                                                                                                                                                                                                                                                                                                                      | 296 |
| 5.24 | DCT 2D em bloco 8×8: coeficientes e reconstrução progressiva. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                               | 298 |
| 5.25 | <i>Pipeline</i> JPEG simplificado aplicado à imagem clássica do <i>Cameraman</i> : DCT em blocos 8×8, quantização com diferentes fatores de qualidade e reconstrução via IDCT. Os artefatos de bloco ( <i>blocking artifacts</i> ) tornam-se visualmente evidentes em fatores de qualidade reduzidos ( $Q = 10$ e $Q = 25$ ). . . . .                                                                                                                                                                               | 301 |
| 5.26 | Simulador interativo de compressão DCT-JPEG: ajuste o fator de qualidade e visualize em tempo real os coeficientes zerados, o bloco reconstruído e o erro de quantização. . . . .                                                                                                                                                                                                                                                                                                                                   | 302 |
| 5.27 | Análise comparativa de artefatos de compressão sob fator de qualidade reduzido ( $Q = 10$ ). À esquerda, observa-se o artefato de bloco característico da discretização por DCT no JPEG. À direita, evidencia-se o efeito de atenuação e suavização de bordas intrínseco ao padrão WebP. . . . .                                                                                                                                                                                                                    | 304 |
| 5.28 | Curva taxa-distorção: PSNR vs tamanho de arquivo para JPEG, WebP e PNG aplicada à imagem do <i>Cameraman</i> . . . . .                                                                                                                                                                                                                                                                                                                                                                                              | 306 |
| 5.29 | Análise espacial de degradação: imagens reconstruídas e respectivos mapas de erro absoluto normalizados para diferentes fatores de qualidade JPEG. . . . .                                                                                                                                                                                                                                                                                                                                                          | 308 |
| 5.30 | <i>Pipeline</i> completo de remoção de ruído misto: (1) adição de ruído gaussiano e periódico; (2) identificação de picos de interferência no espectro de frequências; (3) aplicação de máscara <i>notch</i> com atenuação gaussiana suave; (4) pós-processamento via filtro bilateral para eliminação do ruído estocástico residual. . . . .                                                                                                                                                                       | 312 |
| 5.31 | Mapa conceitual das transformações e propriedades no domínio da frequência. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                 | 313 |
| 5.32 | Simulador: Filtro Passa-Baixa Ideal no Espectro . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                           | 319 |
| 5.33 | Simulador: Filtro Notch . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   | 321 |
| 5.34 | Simulador: Quantização DCT (round-trip) . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                   | 323 |
| 5.35 | Simulador: DFT 2D manual . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  | 324 |
| 5.36 | Simulador: <i>Pipeline</i> JPEG completo em bloco . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                         | 327 |
| 6.1  | Amostra de imagens públicas do <i>skimage.data</i> , agrupadas por área de aplicação. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                       | 333 |
| 6.2  | Comparação entre estratégias de pré-processamento para binarização da imagem de texto: (a) imagem original; (b) limiarização direta pelo método de Otsu; (c) fundo estimado por filtragem Gaussiana; (d) imagem após normalização de fundo (divisão pela imagem suavizada); (e) CLAHE seguido de limiarização por Otsu; e (f) normalização de fundo seguida de limiarização por Otsu. As imagens ilustram o efeito de cada técnica na compensação de variações de iluminação e na qualidade da segmentação. . . . . | 335 |
| 6.3  | Comparação do texto extraído pelo Tesseract a partir de quatro versões da mesma imagem: (a) imagem original; (b) CLAHE seguido de limiarização por Otsu; (c) normalização de fundo seguida de limiarização por Otsu; e (d) normalização de fundo em tons de cinza, sem limiarização. A comparação evidencia que a binarização externa nem sempre favorece o reconhecimento, uma vez que o Tesseract já realiza sua própria binarização adaptativa internamente. . . . .                                             | 338 |

|      |                                                                                                                                                                                                                                                                                                                                                                                    |     |
|------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 6.4  | Fluxo de reconhecimento e tradução automática. A imagem pré-processada por normalização de fundo, sem limiarização, é utilizada como entrada para o Tesseract OCR, e o texto reconhecido é traduzido do inglês para o português por meio da biblioteca <i>deep-translator</i> . . . . .                                                                                            | 339 |
| 6.5  | <i>Pipeline</i> de ingestão de documentos: rasterização adaptativa de páginas PDF para matrizes discretas em formato PNG, exibindo a página dois. . . . .                                                                                                                                                                                                                          | 342 |
| 6.6  | Simulador interativo de correção de inclinação ( <i>deskew</i> ): mova o <i>slider</i> para inclinar o documento e observe as três etapas do <i>pipeline</i> — imagem inclinada, bordas Canny e resultado corrigido. . . . .                                                                                                                                                       | 345 |
| 6.7  | <i>Pipeline</i> de retificação axial: exibição comparativa entre a entrada rotacionada original, o mapa de gradientes estruturais de Canny e o resultado final alinhado com fundo normalizado em branco. . . . .                                                                                                                                                                   | 346 |
| 6.8  | Deteção dos discos marcadores, extração de contornos e retificação por transformação de perspectiva. . . . .                                                                                                                                                                                                                                                                       | 349 |
| 6.9  | Simulador interativo de filtragem por circularidade: mova o <i>slider</i> para ajustar o limiar C e observe quais componentes são aceitos (verde) ou rejeitados (vermelho). . . . .                                                                                                                                                                                                | 350 |
| 6.10 | <i>Pipeline</i> de processamento do <i>QRCode</i> : limiarização, abertura morfológica, inversão e recorte final para decodificação. . . . .                                                                                                                                                                                                                                       | 352 |
| 6.11 | Simulador interativo do <i>pipeline</i> de isolamento do <i>QRCode</i> : navegue pelas etapas de filtragem, ajuste o elemento estruturante do fechamento morfológica e veja a detecção do contorno quadrado sobre a imagem original do gabarito. . . . .                                                                                                                           | 353 |
| 6.12 | Decodificação de código de barras linear com <i>pyzbar</i> : imagem de entrada e dados extraídos. . . . .                                                                                                                                                                                                                                                                          | 355 |
| 6.13 | Imagem da folha de respostas em escala de cinza carregada a partir do PDF rasterizado. . . . .                                                                                                                                                                                                                                                                                     | 357 |
| 6.14 | Área de respostas extraída por <i>getAnswerArea</i> : região retificada contendo os quadros de marcação. . . . .                                                                                                                                                                                                                                                                   | 358 |
| 6.15 | Região do <i>QRCode</i> isolada por <i>segmentQRcode</i> dentro da área de respostas retificada. . . . .                                                                                                                                                                                                                                                                           | 359 |
| 6.16 | Recorte inferior da área de respostas, concentrando os quadros de bolhas a serem segmentados. . . . .                                                                                                                                                                                                                                                                              | 360 |
| 6.17 | Respostas lidas automaticamente pelo MCTest após segmentação e classificação de todas as bolhas. . . . .                                                                                                                                                                                                                                                                           | 362 |
| 6.18 | Deteção de defeito por subtração de imagem: produto de referência, imagem com defeito simulado e máscara de anomalia detectada. . . . .                                                                                                                                                                                                                                            | 364 |
| 6.19 | Simulador interativo de inspeção industrial por subtração de imagens: controle as distorções geométricas de desalinhamento (registro) e o limiar de detecção para observar o impacto nos falsos positivos. . . . .                                                                                                                                                                 | 365 |
| 6.20 | Deteção de heterogeneidade de textura: mapa de variância local e máscara de anomalia. . . . .                                                                                                                                                                                                                                                                                      | 367 |
| 6.21 | Simulador: IoU entre máscara de referência e máscara predita . . . . .                                                                                                                                                                                                                                                                                                             | 374 |
| 6.22 | Simulador: Filtro de Marcadores por Circularidade . . . . .                                                                                                                                                                                                                                                                                                                        | 376 |
| 6.23 | Simulador: Classificação de Marcações OMR . . . . .                                                                                                                                                                                                                                                                                                                                | 378 |
| 6.24 | Simulador: Estimador de Inclinação por Mediana Angular . . . . .                                                                                                                                                                                                                                                                                                                   | 380 |
| 6.25 | Simulador: Normalização de Fundo por Divisão . . . . .                                                                                                                                                                                                                                                                                                                             | 382 |
| 6.26 | Simulador: Mapa de Variância Local para Deteção de Textura . . . . .                                                                                                                                                                                                                                                                                                               | 384 |
| 6.27 | Simulador: <i>Pipeline</i> de Inspeção — Registro por Translação e Subtração . . . . .                                                                                                                                                                                                                                                                                             | 387 |
| 6.28 | Simulador: Segmentação Geométrica + Verificação por Decodificação de <i>QRCode</i> . . . . .                                                                                                                                                                                                                                                                                       | 390 |
| 7.1  | Exemplo motivacional: diferentes frutas formando agrupamentos distintos em um espaço de características. . . . .                                                                                                                                                                                                                                                                   | 394 |
| 7.2  | Panorama do <i>pipeline</i> clássico de classificação de imagens: extração de descritores (LBP, HOG), formação do espaço de características e classificação via k-NN. Não se aplica a modelos de <i>deep learning</i> (CNNs, YOLO), que aprendem <i>features end-to-end</i> diretamente dos pixels. <b>Fonte:</b> elaborado com auxílio do Gemini Notebook (Google, 2025). . . . . | 395 |
| 7.3  | Comparação visual de diferentes descritores aplicados à mesma imagem. Cada descritor revela aspectos distintos da cena. . . . .                                                                                                                                                                                                                                                    | 397 |
| 7.4  | Histograma dos códigos LBP da imagem do cameramen. Cada barra representa a frequência relativa de um código LBP, formando o vetor de características utilizado para descrever a textura. . . . .                                                                                                                                                                                   | 398 |

|      |                                                                                                                                                                                                                                                                                                                                                                                                                                             |     |
|------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 7.5  | Primeiros 100 componentes do vetor de características HOG. . . . .                                                                                                                                                                                                                                                                                                                                                                          | 400 |
| 7.6  | Importância da normalização das características para o classificador k-NN. . . . .                                                                                                                                                                                                                                                                                                                                                          | 403 |
| 7.7  | Mapa conceitual do processo de classificação de imagens utilizando descritores clássicos (LBP, HOG, pixels brutos) e classificador tradicional (k-NN). Não se aplica a modelos de <i>deep learning</i> (CNNs, YOLO), que aprendem <i>features end-to-end</i> diretamente dos pixels. . . . .                                                                                                                                                | 404 |
| 7.8  | Matrizes de confusão obtidas pelo classificador k-NN utilizando três descritores diferentes. As linhas representam a classe real (Maçã, Banana e Laranja) e as colunas a classe predita. Quanto maior a concentração de valores na diagonal principal, melhor o desempenho do descritor. . . . .                                                                                                                                            | 407 |
| 7.9  | Comparação detalhada de acurácia global em cenário realista. Observe como os descritores extraídos estruturalmente (LBP e HOG) superam o uso de intensidades puras de pixels brutos. . . . .                                                                                                                                                                                                                                                | 408 |
| 7.10 | Ilustração do processo de geração de dados sintéticos com <i>make_classification</i> . À esquerda, visualização das três classes em um espaço bidimensional formado por duas características informativas. À direita, importância relativa de cada característica para a classificação, evidenciando que apenas 7 das 10 características são efetivamente discriminativas, enquanto as demais são redundantes (2) ou repetidas (1). . . . . | 411 |
| 7.11 | Classificação de uma nova amostra pelo algoritmo k-NN. O ponto de teste (estrela) é classificado a partir dos três vizinhos mais próximos, destacados por círculos. . . . .                                                                                                                                                                                                                                                                 | 414 |
| 7.12 | Simulador interativo da fronteira de decisão do k-NN: adicione pontos de treinamento e ajuste o valor de k para observar o efeito sobre a região de decisão. . . . .                                                                                                                                                                                                                                                                        | 415 |
| 7.13 | Amostra de dígitos manuscritos da base <i>load_digits</i> , utilizada como estudo de caso de classificação. . . . .                                                                                                                                                                                                                                                                                                                         | 416 |
| 7.14 | Matriz de confusão do classificador k-NN treinado com vetores de intensidade brutos (pixels). . . . .                                                                                                                                                                                                                                                                                                                                       | 417 |
| 7.15 | Comparação de acurácia entre descritores de pixels brutos e HOG para o classificador k-NN (k=3) na base de dígitos. . . . .                                                                                                                                                                                                                                                                                                                 | 418 |
| 7.16 | Acurácia média por validação cruzada (5 partições) em função do parâmetro k, para a base de dígitos com vetores de intensidade brutos. . . . .                                                                                                                                                                                                                                                                                              | 420 |
| 7.17 | Acurácia nos conjuntos de treinamento e teste para diferentes valores de k. As regiões coloridas representam, de forma conceitual, tendências de comportamento do classificador: maior risco de sobreajuste (vermelho), compromisso entre viés e variância (verde) e maior risco de subajuste (azul). . . . .                                                                                                                               | 422 |
| 7.18 | Amostras sintéticas das três classes de textura utilizadas no experimento de classificação, geradas com ruído gaussiano e variabilidade intra-classe. . . . .                                                                                                                                                                                                                                                                               | 424 |
| 7.19 | Acurácia média obtida via validação cruzada (5-fold) para os descritores de Pixels Brutos, LBP e HOG aplicados à base de texturas sintéticas. . . . .                                                                                                                                                                                                                                                                                       | 426 |
| 7.20 | Métricas de avaliação detalhadas para o classificador k-NN com descritores LBP . . . . .                                                                                                                                                                                                                                                                                                                                                    | 429 |
| 7.21 | Simulador: Classificador k-NN Passo a Passo . . . . .                                                                                                                                                                                                                                                                                                                                                                                       | 435 |
| 7.22 | Simulador: Efeito da Normalização Z-score na Distância k-NN . . . . .                                                                                                                                                                                                                                                                                                                                                                       | 437 |
| 7.23 | Simulador: Precisão x Revocação . . . . .                                                                                                                                                                                                                                                                                                                                                                                                   | 439 |
| 7.24 | Simulador: Código LBP . . . . .                                                                                                                                                                                                                                                                                                                                                                                                             | 441 |
| 7.25 | Simulador Didático: Histograma HOG de uma Celula (mapeamento de ângulos para bins) . . . . .                                                                                                                                                                                                                                                                                                                                                | 444 |
| 7.26 | Simulador: Pipeline k-NN Multi-Classe (votacao, desempate e matriz de confusao) . . . . .                                                                                                                                                                                                                                                                                                                                                   | 447 |
| 7.27 | Mosaicos de referência (formato PGM ASCII) utilizados no EP07_07. Caso 1: grade 2x2 com uma amostra de cada classe. Caso 2: grade 3x3 com classes repetidas e maior variabilidade. . . . .                                                                                                                                                                                                                                                  | 452 |
| 7.28 | Simulador: Classificação de um Mosaico de Texturas via LBP + k-NN . . . . .                                                                                                                                                                                                                                                                                                                                                                 | 453 |
| 8.1  | Visão geral dos principais conceitos abordados neste capítulo, incluindo correspondência de características, detecção de objetos, segmentação de imagens e suas relações com abordagens modernas baseadas em <i>Deep Learning</i> . <b>Fonte:</b> elaborado com auxílio do Gemini Notebook (Google, 2025). . . . .                                                                                                                          | 455 |
| 8.2  | Comparação do desempenho de diferentes implementações da distância de Hamming. . . . .                                                                                                                                                                                                                                                                                                                                                      | 458 |
| 8.3  | Simulador interativo do descritor ORB: explore a lógica de rotação e construção do descritor binário. Altere a rotação para observar como o padrão de amostragem de testes binários do BRIEF (linhas verdes e vermelhas) se orienta dinamicamente para garantir a invariância angular. . . . .                                                                                                                                              | 459 |
| 8.4  | Imagem original gerada pelo Gemini e versão rotacionada (20°), simulando uma mudança de ponto de vista. . . . .                                                                                                                                                                                                                                                                                                                             | 460 |



|      |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      |     |
|------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 8.5  | As 5 melhores correspondências de características ORB entre a imagem original e a cena sintética, antes da filtragem por RANSAC. . . . .                                                                                                                                                                                                                                                                                                                                                                             | 462 |
| 8.6  | Simulador interativo do algoritmo RANSAC: ajuste o limiar de distância e execute o algoritmo para observar a separação entre <i>inliers</i> e <i>outliers</i> . . . . .                                                                                                                                                                                                                                                                                                                                              | 463 |
| 8.7  | Simulador interativo do RANSAC aplicado ao registro de imagens: pontos-chave de duas imagens são casados por um descritor, algumas correspondências são espúrias ( <i>outliers</i> ), e o RANSAC estima a transformação de similaridade que alinha a maioria delas. . . . .                                                                                                                                                                                                                                          | 464 |
| 8.8  | Correspondências classificadas como <i>inliers</i> (verde) pelo RANSAC ao estimar a homografia entre as duas imagens. . . . .                                                                                                                                                                                                                                                                                                                                                                                        | 465 |
| 8.9  | Registro da imagem da cena utilizando a homografia inversa estimada pelo RANSAC. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                             | 466 |
| 8.10 | Deteção de faces e olhos com <i>Haar Cascade</i> . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                           | 469 |
| 8.11 | Efeito da Supressão de Não-Máximos (NMS): múltiplas detecções redundantes (esquerda) são reduzidas a uma detecção por objeto (direita). . . . .                                                                                                                                                                                                                                                                                                                                                                      | 471 |
| 8.12 | Segmentação clássica (não baseada em aprendizado profundo): máscara semântica (moeda x fundo) via limiarização de Otsu, e segmentação de instâncias via rotulação de componentes conectados. . . . .                                                                                                                                                                                                                                                                                                                 | 474 |
| 8.13 | Separação de moedas que se tocam via transformada de distância + <i>watershed</i> , sem erosão do contorno das moedas. . . . .                                                                                                                                                                                                                                                                                                                                                                                       | 476 |
| 8.14 | <i>Bounding boxes</i> reconstruídas a partir do arquivo de anotações YOLO exportado por <i>mm.save-Measures</i> , sobrepostas à imagem original das moedas. . . . .                                                                                                                                                                                                                                                                                                                                                  | 480 |
| 8.15 | Simulador: Distância de Hamming entre Dois Descritores Binários . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                            | 488 |
| 8.16 | Simulador: RANSAC — Votação por Inliers entre Modelos Candidatos . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                           | 490 |
| 8.17 | Simulador: Soma Retangular em O(1) — Múltiplas Situações de Borda . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                          | 492 |
| 8.18 | Simulador: IoU e Supressão de Não-Máximos . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                  | 494 |
| 8.19 | Simulador: Rotulação de Componentes Conectados — Conectividade 4 vs. 8 . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                     | 497 |
| 8.20 | Imagem utilizada no EP08_06. À esquerda, a imagem original. À direita, a imagem com as <i>bounding boxes</i> do arquivo de gabarito. . . . .                                                                                                                                                                                                                                                                                                                                                                         | 499 |
| 8.21 | Simulador: Acurácia de Segmentação em Múltiplos Objetos (IoU) . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                              | 500 |
| 9.1  | Visão geral dos principais conceitos abordados neste capítulo. <b>Fonte:</b> elaborado com auxílio do <i>Gemini Notebook</i> (Google, 2025). . . . .                                                                                                                                                                                                                                                                                                                                                                 | 503 |
| 9.2  | Simulador interativo de convolução 2D clássica: escolha entre as três imagens sintéticas de entrada 12×12 (casa, rosto feliz ou triste) e um filtro 3×3 (Sobel V, Sobel H, Nitidez ou Identidade) e avance passo a passo para observar como os produtos internos locais do campo receptivo constroem o mapa de características célula a célula. . . . .                                                                                                                                                              | 506 |
| 9.3  | Simulador interativo do Neurônio Artificial em contexto de CNN: alterne entre um neurônio de camada convolucional (onde $x_i$ são intensidades de pixel em um campo receptivo e $w_i$ são pesos do <i>kernel</i> ) e um neurônio de camada totalmente conectada, ajustando entradas, pesos, viés e função de ativação para visualizar o cálculo de $z$ e da saída $y$ em tempo real. . . . .                                                                                                                         | 507 |
| 9.4  | Simulador interativo da Camada Convolucional: escolha entre três imagens de entrada 12×12 (casa, rosto feliz ou rosto triste) para observar como os mesmos <i>kernels</i> fixos reagem a diferentes bordas e formas. Navegue pelo campo receptivo com os botões ou reprodução automática, ajuste a função de ativação e alterne o zero-padding, acompanhando o mapa de características sendo revelado célula a célula, com o cálculo detalhado termo a termo e a fórmula da dimensão de saída em tempo real. . . . . | 509 |
| 9.5  | Simulador interativo da função de ativação ReLU: arraste o controle para ver como valores negativos são zerados e valores positivos são preservados, tanto na curva quanto em um mapa de características real. . . . .                                                                                                                                                                                                                                                                                               | 510 |
| 9.6  | Simulador interativo de <i>pooling</i> : escolha entre <i>max-pooling</i> e <i>average-pooling</i> e avance passo a passo para observar a redução da resolução espacial do mapa de características. . . . .                                                                                                                                                                                                                                                                                                          | 511 |
| 9.7  | Simulador interativo da Função de Perda ( <i>Cross-Entropy</i> ): selecione a classe real da imagem (Casa, Feliz ou Triste) e ajuste as probabilidades estimadas pela Softmax para visualizar o cálculo da penalização escalar e o gráfico do logaritmo negativo em tempo real. . . . .                                                                                                                                                                                                                              | 512 |



|      |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        |     |
|------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 9.8  | Simulador interativo de <i>Backpropagation</i> : avance os passos da Regra da Cadeia para acompanhar o fluxo do sinal de erro no sentido inverso da rede, observando a computação das derivadas parciais do gradiente em cada camada. . . . .                                                                                                                                                                                                                                                                                                                                                                                                          | 513 |
| 9.9  | Simulador interativo dos Algoritmos de Otimização: compare a trajetória do SGD e do Adam sobre uma superfície de perda não convexa com mapa de calor e curvas de nível. A linha sólida mostra o otimizador selecionado avançando passo a passo; a linha tracejada mostra, para comparação instantânea, o caminho completo que o outro otimizador percorreria a partir do mesmo ponto inicial. Observe como o SGD fica retido no Mínimo Local à direita, enquanto o Adam pode ou não transpor a barreira central dependendo do impulso acumulado e da taxa de aprendizado. Clique em qualquer ponto do mapa para redefinir o ponto inicial dos pesos. . | 514 |
| 9.10 | Simulador interativo da arquitetura de uma CNN: escolha uma das imagens de entrada 12×12 (casa, rosto feliz ou triste), clique em cada bloco do <i>pipeline</i> — Entrada, <i>Conv+ReLU</i> , <i>Pooling</i> , <i>Flatten</i> , <i>FC</i> e <i>Softmax</i> — e execute passos de treinamento reais ( <i>forward pass</i> + retropropagação) para observar a perda e a acurácia evoluindo, os <i>kernels</i> sendo ajustados e o <i>Softmax</i> passando a apontar a classe correta. . . . .                                                                                                                                                            | 516 |
| 9.11 | Curva de treinamento de uma CNN simples na base de dígitos: perda de treinamento e acurácia no conjunto de teste ao longo das épocas. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          | 518 |
| 9.12 | Comparação de acurácia entre os classificadores clássicos do Capítulo 7 (pixels brutos e HOG com k-NN) e a CNN treinada neste capítulo, na mesma base de dígitos. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                              | 519 |
| 9.13 | Comparação de acurácia entre treinar do zero e reaproveitar (transferir) um extrator de características já treinado, ambos com o mesmo pequeno número de exemplos rotulados na tarefa de destino. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                              | 522 |
| 9.14 | Amostras do conjunto de dados sintético de objetos geométricos, com as caixas delimitadoras no formato YOLO sobrepostas. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       | 528 |
| 9.15 | Detecções do YOLO ajustado por transferência de aprendizado em uma imagem de validação não vista durante o treinamento. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        | 533 |
| 9.16 | Amostras do conjunto de dados sintético de nódulos: imagem em tons de cinza (fundo e nódulo com médias de intensidade próximas, sob o mesmo ruído) e máscara binária de referência. . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                | 541 |
| 9.17 | Linha de base clássica de segmentação: borrão gaussiano, limiarização de Otsu e abertura morfológica, aplicados a uma imagem de validação. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     | 542 |
| 9.18 | Curva de treinamento da U-Net compacta: perda de treinamento (entropia cruzada binária combinada à perda Dice) e IoU médio no conjunto de validação ao longo das épocas. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                       | 545 |
| 9.19 | . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                              | 547 |
| 9.20 | . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                              | 551 |
| 9.21 | . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                              | 552 |
| 9.22 | . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                              | 553 |
| 9.23 | Simulador: Convolução 2D Manual (correlação cruzada + viés + ReLU) . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           | 560 |
| 9.24 | Simulador: Pooling Manual (máximo vs. média) . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 | 562 |
| 9.25 | Simulador: Contagem de Parâmetros — Convolução vs. Camada Totalmente Conectada . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   | 564 |
| 9.26 | Simulador: IoU e Supressão de Não-Máximos . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    | 566 |
| 9.27 | Simulador: Pipeline Integrado — NMS + Medição por Referência de Escala . . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       | 568 |

# Lista de Tabelas

|     |                                                                                                                                                                       |     |
|-----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 1   | Diferentes formatos de publicação gerados automaticamente a partir do mesmo código-fonte.                                                                             | 23  |
| 1.1 | Conexão entre PDI, VC e outras áreas da ciência.                                                                                                                      | 31  |
| 1.2 | Principais tipos de imagem digital e seus respectivos conjuntos de valores possíveis para cada pixel.                                                                 | 34  |
| 1.3 | Principais bibliotecas utilizadas ao longo deste livro para manipulação matricial, PDI e visualização de resultados.                                                  | 35  |
| 2.1 | Convenções de escala e ordem de canais nas principais bibliotecas de PDI.                                                                                             | 78  |
| 2.2 | Comparativo entre estratégias de compactação e eficiência de processamento.                                                                                           | 85  |
| 2.3 | Comparativo de métricas de distância aplicadas à malha de pixels.                                                                                                     | 86  |
| 2.4 | Principais formatos de armazenamento de imagens digitais e suas aplicações em PDI.                                                                                    | 86  |
| 2.5 | Métodos de interpolação disponíveis em <code>mm.resize</code> e seus respectivos números de vizinhos utilizados no cálculo.                                           | 92  |
| 3.1 | Algoritmo de equalização de histograma.                                                                                                                               | 130 |
| 3.2 | Interpretação típica dos coeficientes do <i>kernel</i> .                                                                                                              | 140 |
| 3.3 | Etapas do <i>Unsharp Masking</i> .                                                                                                                                    | 153 |
| 3.4 | Média vs. mediana com um pixel corrompido. A mediana ignora o outlier; a média é deslocada ~40 níveis.                                                                | 156 |
| 4.1 | Técnicas de pré-processamento avaliadas para melhorar a separação entre moedas e fundo antes da aplicação do método de Otsu.                                          | 188 |
| 4.2 | Propriedades de abertura e fechamento.                                                                                                                                | 198 |
| 4.3 | Sequências do filtro sequencial alternado <code>mm.asf</code> .                                                                                                       | 200 |
| 4.4 | Comparação entre os operadores <i>clohole</i> e <i>edgeoff</i> .                                                                                                      | 208 |
| 4.5 | Taxonomia simplificada das principais abordagens de segmentação e refinamento estudadas neste capítulo.                                                               | 215 |
| 4.6 | <i>Pipeline</i> completo do <i>watershed</i> baseado em marcadores para imagens reais.                                                                                | 225 |
| 4.7 | <i>Pipeline</i> simplificado utilizado no exemplo didático da Figure 4.25.                                                                                            | 228 |
| 4.8 | Comparação entre as abordagens baseadas em componentes conexos e em contornos.                                                                                        | 230 |
| 5.1 | Correspondência entre as regiões do espectro de magnitude após a aplicação do FFT Shift.                                                                              | 264 |
| 5.2 | Comparação da complexidade da convolução direta, separável e via Transformada Rápida de Fourier (FFT).                                                                | 272 |
| 5.3 | Subbandas produzidas pela Transformada <i>Wavelet</i> Discreta 2D (DWT), indicando os filtros aplicados em cada direção e o conteúdo predominante de cada componente. | 284 |
| 5.4 | Comparação entre famílias de <i>wavelets</i> , destacando o comprimento do suporte, o número de momentos nulos, a simetria e aplicações típicas.                      | 285 |
| 5.5 | Comparação entre a Transformada Discreta de Fourier (DFT) e a Transformada <i>Wavelet</i> Discreta (DWT), destacando suas principais características e aplicações.    | 293 |
| 5.6 | Categorias de redundância em imagens digitais e seus respectivos mecanismos de exploração.                                                                            | 294 |
| 5.7 | Etapas do <i>pipeline</i> de compressão JPEG e seus respectivos fundamentos de projeto.                                                                               | 298 |
| 5.8 | Comparação estrutural entre os principais formatos de imagem rasterizados.                                                                                            | 302 |
| 5.9 | Síntese das etapas do <i>pipeline</i> de compressão JPEG e seus respectivos impactos.                                                                                 | 309 |
| 6.1 | Imagens do <code>skimage.data</code> utilizadas nos experimentos deste capítulo.                                                                                      | 332 |

---

|     |                                                                                                                                    |     |
|-----|------------------------------------------------------------------------------------------------------------------------------------|-----|
| 6.2 | Seleção de imagens públicas representativas disponíveis no módulo <i>skimage.data</i> , organizadas por área de aplicação. . . . . | 332 |
| 7.1 | Conjunto de descritores cromáticos, texturais e geométricos utilizados para representar imagens de frutas. . . . .                 | 408 |
| 7.2 | Exemplo simplificado de classificação de frutas utilizando duas características normalizadas. .                                    | 411 |
| 8.1 | Comparação entre os principais paradigmas de segmentação visual. . . . .                                                           | 472 |
| 8.2 | Arquiteturas representativas de Aprendizado Profundo para detecção e segmentação de imagens.                                       | 481 |
| 9.1 | Comparativo entre as principais tarefas de Visão Computacional segundo a granularidade da informação produzida. . . . .            | 504 |

---

# PDI e VC — Python

---

Bem-vindo ao livro de PDI e Visão Computacional — versão Python / Português.

## Organização

- **Parte I — Fundamentos de PDI** — Representação, histogramas, filtragem, morfologia
  - **Parte II — Visão Computacional** — Segmentação, descritores, detecção, deep learning
-



# Prefácio

Este livro constitui uma **obra em permanente atualização** nas áreas de **Processamento Digital de Imagens (PDI)** e **Visão Computacional (VC)**, concebida como material didático interativo para cursos de graduação e pós-graduação em Computação, Engenharia e áreas afins.

**! Destaque**

A obra fundamenta-se na metodologia descrita em Zampirolli et al. (2025) — extensão de Zampirolli et al. (2024), trabalho premiado na trilha **Recursos e Ambientes Educacionais** da **EduComp 2024**. O conteúdo integra a biblioteca `morph.py`, desenvolvida pelo autor.

Este não é um livro estático. Seu conteúdo evolui continuamente à medida que exemplos são aprimorados, novas seções são incorporadas e as abordagens pedagógicas são refinadas com base na experiência de uso e no retorno de estudantes e docentes. Dessa forma, a obra é tratada como um *projeto em constante evolução*, buscando acompanhar tanto os avanços tecnológicos quanto as melhores práticas de ensino em PDI e VC.

## Como este livro é produzido

O conteúdo deste livro é desenvolvido em **Quarto** e armazenado na pasta `all` do repositório [github.com/fzampirolli/pdi-vc](https://github.com/fzampirolli/pdi-vc). A partir de um único código-fonte, o livro é automaticamente gerado e publicado em diferentes formatos, apresentados na Table 1.

Tabela 1: Diferentes formatos de publicação gerados automaticamente a partir do mesmo código-fonte.

| Formato                   | Descrição                                                                                                                                                                                                                                                                                                                  |
|---------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>HTML</b>               | Versão para <i>web</i> , com simuladores interativos e navegação entre capítulos: <a href="https://fzampirolli.github.io/pdi-vc/">fzampirolli.github.io/pdi-vc/</a>                                                                                                                                                        |
| <b>PDF</b>                | Versão adequada para impressão ou leitura <i>offline</i> : <a href="#">livro.pt.py.pdf</a>                                                                                                                                                                                                                                 |
| <b>Notebooks (.ipynb)</b> | Compatíveis com <b>Jupyter</b> e <b>Google Colab</b> , permitindo executar, modificar e experimentar os exemplos de código e os Exercícios de Programação (EPs). Um filtro personalizado mantém referências cruzadas, numeração de figuras e tabelas, além de formatar automaticamente as citações conforme o padrão ABNT. |

Cada capítulo disponibiliza dois botões **Executar Colab** (Figure 1), que direcionam para ambientes complementares:

1. **Parte Teórica**, localizada na abertura de cada capítulo, contendo os conceitos apresentados e exemplos de código executáveis;
2. **Parte Prática**, na seção **Parte Prática com Exercícios de Programação** (EPs), dedicada aos exercícios e aos seus simuladores interativos.

A geração dos *notebooks* é totalmente automatizada pelo *script* `gerar_notebooks_alunos.py`, que adapta o conteúdo para ambientes interativos, permitindo sua execução sem a necessidade de instalação do Quarto.



Figura 1: Botão clicável **Executar Colab**, disponível no início das partes **Teórica** e **Prática** de cada capítulo, permitindo a execução interativa dos exemplos e exercícios.

## Idiomas e Conversão de Código

O **núcleo de referência** é escrito em **Português** com exemplos em **Python**. Versões em outros idiomas e linguagens de programação são geradas via **APIs de IA**, por meio de um fluxo automatizado que realiza a tradução textual e a conversão de sintaxe do código.

### **i** Nota

As versões traduzidas via IA servem como **ponto de partida** e podem conter imprecisões; recomenda-se revisão antes da aplicação em sala de aula.

## Uso de ferramentas de Inteligência Artificial

A elaboração deste livro contou com o apoio de **ferramentas gratuitas de Inteligência Artificial (IA)** para aprimorar a qualidade do texto, dos exemplos de código e dos materiais de apoio. Ao longo do desenvolvimento, diferentes assistentes de IA, como **ChatGPT**, **Claude**, **DeepSeek** e **Gemini**, foram utilizados de forma iterativa em atividades como:

- aprimoramento da clareza, da precisão e da fluidez das explicações;
- identificação e correção de erros de sintaxe, lógica e digitação em exemplos de código;
- sugestão de melhorias na organização, na estrutura e na apresentação do conteúdo.

Além disso, **algumas ilustrações foram produzidas com o auxílio do Gemini**, com o objetivo de facilitar a visualização de conceitos abstratos e complementar as explicações apresentadas ao longo do livro.

Embora essas ferramentas tenham desempenhado um papel importante no processo de produção, **a seleção, a validação técnica, a adaptação, a organização e a responsabilidade pelo conteúdo final são integralmente do autor.**

Mais do que utilizar IA para gerar textos, códigos ou imagens, o principal desafio consiste em selecionar criticamente, verificar, adaptar e integrar esse material de forma tecnicamente correta e pedagogicamente consistente. Nesse contexto, merece destaque o conjunto de **simuladores interativos**, desenvolvido em JavaScript e incorporado às versões HTML e IPYNB do livro, que permite ao leitor experimentar conceitos em tempo real e reforçar a compreensão dos conteúdos apresentados.

## A biblioteca **morph.py**

A biblioteca **morph.py** (Zampirolli et al., 2025) acompanha toda a obra como uma ferramenta de apoio ao ensino. Seu objetivo não é substituir bibliotecas consolidadas, como **OpenCV**, **scikit-image**, **scikit-learn**, **NumPy** ou **Matplotlib**, nem competir com elas em desempenho ou abrangência. Em vez disso, procura **tornar transparentes os algoritmos fundamentais de Processamento Digital de Imagens e Visão Computacional (PDI-VC)**, permitindo que o estudante compreenda sua implementação, modifique o código e desenvolva novas funcionalidades.

Sempre que possível, a biblioteca oferece duas versões para um mesmo algoritmo: uma **implementação didática**, escrita passo a passo para refletir diretamente as definições matemáticas apresentadas no livro, e outra **implementação otimizada**, baseada em bibliotecas especializadas para aplicações práticas.

### **i** Herança Técnica

A estrutura da `morph.py` tem como base ferramentas de Morfologia Matemática desenvolvidas no Brasil, como **MMachLib** (Lotufo et al., 1997) e **MMach** (Barrera et al., 1998), além da **mmorph**, utilizada na obra de Dougherty; Lotufo (2003). Essas bibliotecas serviram de referência para o ensino da área durante décadas.

Essa filosofia pode ser observada, por exemplo, nos operadores morfológicos de dilatação:

- `mm.dil`: implementação otimizada, indicada para aplicações práticas;
- `mm.dil0`: implementação didática da dilatação para **elementos estruturantes planares**, seguindo diretamente a definição clássica da Morfologia Matemática;
- `mm.dil1`: implementação didática da dilatação para **funções estruturantes (*kernels* não planares)**, seguindo rigorosamente sua formulação matemática.

A biblioteca também oferece funções para leitura, exibição, conversão de cores, filtragem e morfologia matemática por meio de uma interface simples:

```
from morph import mm

img = mm.gray(mm.read("lena.jpg")) # leitura e conversão para níveis de cinza
grad = mm.gradm(img)               # gradiente morfológico
mm.show(grad)                      # exibição
```

Ao longo do livro, novos métodos são introduzidos na biblioteca para simplificar a realização dos Exercícios de Programação (EPs). Entre eles estão `mm.readTrain()` e `mm.readTest()`, que automatizam a leitura das bases de treinamento e teste utilizadas nos capítulos dedicados ao reconhecimento de padrões.

Além disso, todos os projetos do **Gemini Notebook** incluem o arquivo `morph.py`, permitindo consultar e discutir diretamente a implementação dos algoritmos apresentados no livro. Dessa forma, o estudante pode utilizar o próprio Gemini Notebook como um assistente de estudos, fazendo perguntas como:

Explique como foi implementado o algoritmo `mm.knn0` do `morph.py`, mostrando o código e comentando cada etapa de forma didática. Além disso, explique as diferenças entre `mm.knn0()` e `mm.knn()`.

### **!** Implementações didáticas e implementações otimizadas

Em vários capítulos, um mesmo algoritmo é apresentado em duas versões. As funções com sufixo 0, 1, etc. (por exemplo, `mm.knn0()`, `mm.dil0()` e `mm.dil1()`) são implementações didáticas, desenvolvidas para facilitar o entendimento dos algoritmos. Já as funções sem sufixo (como `mm.knn()` e `mm.dil()`) utilizam implementações otimizadas, frequentemente baseadas em bibliotecas especializadas, como OpenCV, scikit-image e scikit-learn, sendo mais adequadas para aplicações práticas.

Nas atividades avaliadas pelo **VPL do Moodle**, bibliotecas como **scikit-learn** e, em alguns casos, **scikit-image**, podem não ser utilizadas devido às limitações de memória do ambiente de execução. Por esse motivo, os Exercícios de Programação (EPs) empregam preferencialmente as implementações didáticas da `morph.py`, que produzem os mesmos resultados, embora com menor desempenho computacional. Essa restrição não existe quando os programas são executados localmente, por exemplo, no **VS Code**, **Jupyter Notebook** ou **Google Colab**.

O código-fonte da biblioteca está disponível em:

<https://github.com/fzampirolli/pdi-vc/tree/master/morph>

## Exercícios de Programação (EPs) e Validação Automática

Cada unidade do livro inclui **Exercícios de Programação (EPs)** práticos e de complexidade crescente, projetados para consolidar os conceitos apresentados ao longo do capítulo. Cada EP é acompanhado por um **simulador interativo**, disponível nas versões HTML e IPYNB, que permite ao estudante manipular parâmetros, visualizar o comportamento dos algoritmos e desenvolver uma compreensão intuitiva do problema antes de iniciar sua implementação. Dessa forma, o processo de aprendizagem combina experimentação, programação e validação automática.

A validação das soluções é feita localmente pela classe `TestSuite` (`testsuite.py`), que compara a saída do programa com os arquivos de casos de teste (`.cases`):

```
TestSuite("EP01_01.py").run()
```

O sistema suporta múltiplas linguagens (Python, Java, C++, C, JavaScript e R) e pode ser integrado diretamente ao Moodle. Para o passo a passo completo de integração com o **VPL do Moodle**, consulte o Guia do Professor: Publicação de EPs no Moodle.

## Código aberto

O projeto é regido por princípios de código aberto. O repositório público reúne o texto, os códigos, as imagens e os *scripts*: [github.com/fzampirolli/pdi-vc](https://github.com/fzampirolli/pdi-vc)

Cada versão do livro é arquivada permanentemente no **Zenodo** com um *DOI citable*. Para citar este material em trabalhos acadêmicos:

ZAMPIROLI, Francisco de Assis. **PDI+VC — Processamento Digital de Imagens e Visão Computacional**. UFABC, 2026. DOI: [10.5281/zenodo.20784606](https://doi.org/10.5281/zenodo.20784606)

## Guia do Professor: Publicação de EPs no Moodle

*Esta seção destina-se a docentes que desejam integrar os Exercícios de Programação (EPs) às atividades VPL (Virtual Programming Lab) do Moodle.*

### Integração com o Moodle (VPL)

Os EPs dos *notebooks* podem ser convertidos em atividades **VPL** no Moodle. O *script* `ep_tools.py` (executado via `make build`) automatiza a exportação dos EPs do final de cada capítulo em duas etapas:

1. **Extração** (`make eps`): gera um HTML interativo independente por EP, com enunciado, exemplos e simulador, em `gen/book/eps/<versao>/`. Veja um exemplo em: [https://fzampirolli.github.io/pdi-vc/eps/py.pt/EP01\\_01.html](https://fzampirolli.github.io/pdi-vc/eps/py.pt/EP01_01.html)
2. **Conversão** (`make moodle`): transforma o HTML em um fragmento autocontido, sem dependência de CSS externo, pronto para ser colado no editor do Moodle, em `gen/book/eps/<versao>_moodle/`. Veja um exemplo em: [https://fzampirolli.github.io/pdi-vc/eps/py.pt/\\_moodle/EP01\\_01.html](https://fzampirolli.github.io/pdi-vc/eps/py.pt/_moodle/EP01_01.html)

Ao publicar com `make publish`, essas **duas versões** de cada EP ficam disponíveis nos *links* indicados. O professor pode combinar as duas estratégias: colar a versão Moodle no editor VPL (com simulador funcional) e incluir no enunciado um *link* para a versão completa, onde as fórmulas são renderizadas corretamente pelo MathJax.

 Revisão obrigatória antes de publicar no Moodle

Embora automatizada, a conversão exige revisão do professor em razão das limitações do editor TinyMCE/HTML Purifier do Moodle:

- **Fórmulas matemáticas** — O TinyMCE descarta barras invertidas (`\`), corrompendo equações LaTeX. Por isso, a versão Moodle converte fórmulas simples para HTML puro (entidades como `&ge;`, `&times;`). Fórmulas complexas (`\begin{cases}`), matrizes, integrais) podem sair incompletas — revise e, se necessário, reescreva-as em texto ou indique a versão completa via *link*.
- **Figuras externas** — Imagens complementares devem ser inseridas manualmente na atividade VPL.
- **Simuladores** — Funcionam perfeitamente desde que utilizem JavaScript padrão com estilos *inline* e manipulação direta do DOM (`getElementById`). **Atenção:** se incluir fórmulas em LaTeX que contenham o caractere `\` no Moodle, os simuladores podem parar de funcionar.

## Como Publicar no Moodle

1. Acesse a versão Moodle do EP desejado:

```
https://fzampirolli.github.io/pdi-vc/eps/py.pt_moodle/EPXX_YY.html
```

2. Copie o código-fonte completo da página (`Ctrl+U` → `Ctrl+A` → `Ctrl+C`).
3. No Moodle, crie a atividade VPL, acesse o editor HTML, cole o conteúdo (`Ctrl+V`) e salve.
4. Importe os arquivos `.cases` da pasta `all/capXX/casos/` nas configurações de testes do VPL.

 Reaproveitamento dos Casos de Teste

Os arquivos `.cases` são compatíveis com o VPL, permitindo usar o mesmo conjunto de testes tanto no desenvolvimento local quanto na correção automatizada no Moodle.

## Antes de começar: *Notebooks* em Python

O conceito de *Literate Programming* (Programação Literária), proposto por Donald Knuth (Knuth, 1984), fundamenta a estrutura deste material. A lógica inverte o paradigma tradicional: o programa é escrito para a leitura humana, assemelhando-se a um ensaio, enquanto o código é extraído separadamente para execução computacional.

O conteúdo é estruturado em *notebooks* — documentos que intercalam **células de texto** (em [Markdown](#)) e **células de código** (em Python).

- **Execução:** células de código são identificadas por `[ ]`. A execução pode ser realizada com `Shift + Enter` ou pelo botão  da interface.
- **Ambientes:** os *notebooks* podem ser executados localmente, por meio do [Jupyter](#) ou do [Visual Studio Code \(VS Code\)](#), bem como em ambientes de nuvem, como o [Google Colab](#).

 Nota sobre o formato

Em ambientes interativos, o código pode ser modificado e executado. Nas versões estáticas (HTML ou PDF), os blocos de código têm finalidade de leitura e referência, sem prejuízo à integridade das explicações.



## Parte I

# Parte I — Fundamentos de PDI

# Capítulo 1

## Fundamentos e Primeiros Passos



Este capítulo inaugura a **Parte 1** do livro, dedicada aos fundamentos do Processamento Digital de Imagens (PDI). São apresentados a representação matemática de imagens digitais e os principais métodos para sua manipulação, utilizando a linguagem Python e a biblioteca `morph.py` (Zampirolli et al., 2025).

### 1.1 Objetivos

Ao final deste capítulo, você será capaz de:

- Compreender a natureza física e matemática da imagem digital  $f(x, y)$ .
- Identificar as faixas do espectro eletromagnético relevantes para PDI.
- Configurar o ambiente de desenvolvimento em Python.
- Realizar operações básicas: leitura, exibição e salvamento de imagens.
- Manipular estruturas de matrizes (NumPy) sem cair em armadilhas de memória.
- Acessar e modificar intensidades de pixels individualmente.
- Aplicar limiarização manual.

### 1.2 Antes de começar: *Notebooks* em Python

Este material foi construído sob o conceito de **Literate Programming** (Programação Literária), idealizado por Donald Knuth na década de 1980 (Knuth, 1984). Knuth — também criador do sistema **TeX** para tipografia digital — propôs que os programas fossem escritos como uma narrativa lógica para seres humanos, intercalando código e documentação.

Para executar uma célula, pressione Shift + Enter ou clique no botão ▷.

#### **i** Nota sobre o formato

Nas versões renderizadas (PDF ou HTML), o código é apresentado em blocos estáticos para fins de leitura e referência. A execução interativa requer o acesso via Google Colab (disponível no topo da página) ou em ambiente local via VSCode ou Jupyter Notebook.

### 1.3 Fundamentos

O estudo de sistemas baseados em imagens compreende um ecossistema de disciplinas integradas que transformam dados visuais brutos em conhecimento estruturado. Enquanto algumas áreas focam na geração de representações, outras dedicam-se ao tratamento e à análise desses dados para dar suporte a aplicações tecnológicas complexas.

O diagrama apresentado no Figure 1.1 estabelece a distinção e complementaridade entre o Processamento Digital de Imagens (PDI) e a Visão Computacional (VC). O PDI, destacado em **verde**, tem como foco

a transformação de imagem para imagem, visando melhoria de qualidade ou pré-processamento, como a remoção de ruídos e realce de contraste.

Em contrapartida, a VC, assinalada em **azul**, foca na interpretação do conteúdo visual para extrair modelos ou informações, como o reconhecimento de objetos e gestos. A região de intersecção ilustra a sinergia entre as áreas, onde o PDI prepara os dados visuais para a interpretação pela VC. O mapa também demonstra as interconexões de ambas as disciplinas com áreas como Robótica, Computação Gráfica, Inteligência Artificial (IA) e Neurociência.




Figura 1.1: Diagrama relacional detalhando as distinções fundamentais, sinergias e interconexões entre PDI e VC no contexto de sistemas baseados em imagens.

### 1.3.1 Visão Computacional

- **Foco:** *Imagem* → *Modelo* (caminho inverso da Computação Gráfica).
- **Objetivo:** Extrair informação de alto nível a partir de imagens ou vídeos.
- **Aplicações típicas:**
  - Robótica - detecção de obstáculos, localização e navegação autônoma.
  - Vigilância e inspeção - reconhecimento de eventos, leitura de placas, controle de qualidade.
  - Sensoriamento remoto - análise de imagens de satélite, mapeamento ambiental.
  - Imagens médicas - detecção de tumores, segmentação de órgãos, auxílio ao diagnóstico.
  - Interação humano-computador - reconhecimento de gestos, expressões faciais, rastreamento ocular.
- **Relação com outras áreas:** utiliza técnicas de Aprendizado de Máquina e IA para classificar e interpretar cenas; serve como “olhos” da Robótica.

### 1.3.2 Processamento Digital de Imagens (PDI)

- **Foco:** *Imagem* → *Imagem* (geralmente - transformação de uma imagem em outra).
- **Objetivo:** Melhorar a qualidade visual ou extrair características de baixo nível.
- **Aplicações comuns:**
  - Eliminação de ruídos (filtros de média, mediana, gaussiano).
  - Melhoria de contraste (equalização de histograma, ajuste gamma).
  - Detecção de bordas (Sobel, Canny, Laplaciano).
  - Segmentação (limiarização, crescimento de regiões, *watershed*).

- Transformações geométricas (redimensionamento, rotação, correção de perspectiva).
- **Relação com outras áreas (ver Table 1.1):**
  - É a **base** para a maioria dos sistemas de VC (pré-processamento).
  - A Computação Gráfica frequentemente aplica PDI para pós-processamento (ex.: suavização, realce).
  - Técnicas de IA podem otimizar parâmetros de processamento (ex.: aprendizado de filtros).

Tabela 1.1: Conexão entre PDI, VC e outras áreas da ciência.

| Área                           | Relação com PDI e VC                                                                                             |
|--------------------------------|------------------------------------------------------------------------------------------------------------------|
| <b>Inteligência Artificial</b> | Fornecer modelos (redes neurais, SVM) que interpretam saídas da VC.                                              |
| <b>Robótica</b>                | Consome dados de VC para tomar decisões (navegação, manipulação).                                                |
| <b>Aprendizado de Máquina</b>  | Usa descritores extraídos pelo PDI/VC para treinar classificadores.                                              |
| <b>Computação Gráfica</b>      | Caminho inverso: <i>modelo</i> $\rightarrow$ <i>imagem</i> ; muitas vezes aplica PDI para renderização realista. |
| <b>Neurociência</b>            | Inspira modelos de PDI (ex.: filtros semelhantes a células ganglionares da retina).                              |

## 1.4 Etapas do PDI

As etapas do PDI são apresentadas na Figure 1.2, que podem ser compreendidas como uma cadeia de transformações que reduz a redundância dos dados em busca de significado:

- **Baixo Nível:** Atua diretamente sobre os pixels da imagem ruidosa para realizar melhorias e filtrações, gerando como saída uma imagem limpa ou realçada.
- **Médio Nível:** Recebe a imagem tratada e realiza a segmentação e descrição, transformando a matriz de pixels em atributos estruturados (forma, tamanho e textura).
- **Alto Nível:** Utiliza a tabela de atributos para alimentar processos de lógica e inteligência artificial, resultando na decisão ou reconhecimento final (como o diagnóstico médico).

A Figure 1.3 detalha a sequência completa do PDI, desde a captura até a interpretação. O fluxo inicia-se na Aquisição da Imagem (1) e prossegue com o Melhoramento (2) e a Restauração (3). Em seguida, o conteúdo é isolado pela Segmentação (4) e refinado pela Morfologia (5). A transição crucial ocorre na Representação e Descrição (6), onde objetos visuais são convertidos em dados matemáticos (área, perímetro etc.), permitindo o Reconhecimento (7). Processos auxiliares incluem o Processamento de Imagem Colorida e a Compressão, que contribuem para a eficiência do armazenamento e da análise.


## 1.5 Formação da Imagem e o Espectro

O processo de formação de uma imagem é fundamentado na interação entre a matéria e a energia radiante. Essencialmente, uma imagem é concebida quando um **sensor registra a radiação** resultante da interação com um objeto físico. No contexto da visão humana e da fotografia convencional, este fenômeno depende de uma fonte de luz que ilumine a cena; as características dos objetos são então codificadas através das **variações de intensidade e cor** da luz que atinge o sensor, conforme ilustrado na Figure 1.4.

A **luz visível** ocupa apenas uma pequena faixa do espectro eletromagnético — entre **380 nm (violeta)** e **750 nm (vermelho)** — conforme ilustrado na Figure 1.5. Sensores digitais convencionais operam nessa mesma janela, mas equipamentos especializados podem captar radiações invisíveis ao olho humano, como o infravermelho e os raios X. Em PDI, a imagem formada depende diretamente da sensibilidade espectral do sensor utilizado.



## PDI: FLUXO SEQUENCIAL DE ETAPAS



As etapas de processamento de imagens podem ser divididas em processamento de baixo, médio e alto nível.

Figura 1.2: Representação do fluxo sequencial de processamento: a saída de cada nível torna-se a entrada do nível subsequente.




Figura 1.3: Fluxo detalhado do PDI: da aquisição sensorial à extração de atributos e reconhecimento automatizado, incluindo em processamento colorido e compressão.






Figura 1.4: Representação do espectro visível e sua posição em relação às demais radiações eletromagnéticas, destacando a variação dos comprimentos de onda de 380 nm a 750 nm.




Figura 1.5: (A) Espectro eletromagnético completo em escala logarítmica, com destaque para a faixa visível. (B) Detalhe da luz visível (380-750 nm) e suas cores. (C) Decomposição da luz branca pelo prisma: menor comprimento de onda sofre maior refração, separando UV, visível e infravermelho.

A partir desse processo físico de aquisição, torna-se possível modelar matematicamente a imagem digital como uma função bidimensional discreta, na qual cada ponto da cena é representado por amostras numéricas de intensidade luminosa, formalizando assim os conceitos de pixel e de imagem digital apresentados na próxima seção.

## 1.6 O que é uma Imagem Digital?

Uma **imagem digital** é formada por uma grade de **pixels** (*Picture Elements*), onde cada pixel é a menor unidade elementar da imagem.

### O que é um Pixel?

Um **pixel** é a menor unidade endereçável que compõe uma imagem digital. Cada pixel ocupa uma posição única na grade e armazena um ou mais valores numéricos que representam sua intensidade ou cor.

### Representação Matemática

Diferente de uma função contínua, o domínio de uma imagem digital é um plano retangular finito  $\mathbb{E} \subset \mathbb{Z}^2$ , que representa a grade de amostragem. Este domínio é indexado por coordenadas inteiras:

$$\mathbb{E} = \{(x, y) \in \mathbb{Z}^2 \mid 0 \leq x < L, 0 \leq y < H\} \tag{1.1}$$

Onde:

- $L$ : representa a largura da imagem (número de colunas).
- $H$ : representa a altura da imagem (número de linhas).

A imagem digital é uma função que associa cada par de coordenadas  $(x, y)$  a um ou mais valores que descrevem a aparência do pixel.

$$f : \mathbb{E} \rightarrow \mathcal{V} \tag{1.2}$$

O conjunto  $\mathcal{V}$  define os valores possíveis para o pixel (codomínio), variando conforme o tipo de imagem, como demonstrado na Table 1.2.

Tabela 1.2: Principais tipos de imagem digital e seus respectivos conjuntos de valores possíveis para cada pixel.

| Tipo de imagem        | $\mathcal{V}$ (valores do pixel)                     | Representação                                                                                                                                                                                                                                                     |
|-----------------------|------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Binária</b>        | $\{0, 1\}$ ou $\{0, 255\}$                           |                                                                                         |
| <b>Tons de cinza</b>  | $\{0, 1, \dots, 255\}$                               | [ ] [=] [#]                                                                                                                                                                  |
| <b>Colorida (RGB)</b> | $\{0, \dots, 255\}^3$ (triplas ordenadas de valores) |    |

**Exemplo prático:** Uma imagem colorida no modelo RGB pode ser representada matematicamente por uma função que associa três valores de intensidade a cada pixel. Computacionalmente, essa representação corresponde a três matrizes sobrepostas — os canais vermelho (*Red*), verde (*Green*) e azul (*Blue*) — nas quais cada elemento armazena a intensidade luminosa do respectivo canal em uma determinada posição da imagem.

Para viabilizar os experimentos práticos de PDI e VC, este livro utiliza o ecossistema científico do Python, integrando bibliotecas voltadas à manipulação matricial, ao processamento de imagens e à visualização de resultados, apresentadas a seguir.

### 1.7 Configuração do Ambiente

Este material fundamenta-se no ecossistema científico do Python, com destaque para o **NumPy** (matemática matricial), **OpenCV** (VC padrão de mercado) e a biblioteca **morph.py** (Zampirolli et al., 2025), desenvolvida especificamente para fins didáticos neste livro, ver Table 1.3.

Atualmente, o projeto disponibiliza a versão em **Python** e **Português**. A arquitetura do sistema, no entanto, foi projetada para expansão futura, permitindo a adaptação automatizada para outras linguagens de programação (como C++ e Java) e idiomas, por meio de APIs de tradução.

Os **Exercícios de Programação (EPs)** do final de cada capítulo integram o módulo `testsuite.py`, já disponível para práticas em Python, C, C++, Java, JavaScript e R, garantindo a validação imediata das soluções propostas nos *notebooks* de estudo.

Tabela 1.3: Principais bibliotecas utilizadas ao longo deste livro para manipulação matricial, PDI e visualização de resultados.

| Biblioteca                 | Função principal                        |
|----------------------------|-----------------------------------------|
| <code>numpy</code>         | Representação matricial de imagens      |
| <code>opencv-python</code> | Leitura, escrita e operações de VC      |
| <code>matplotlib</code>    | Visualização de imagens e gráficos      |
| <code>morph.py</code>      | Abstração didática das operações de PDI |

**i** Versões do `morph.py`

A biblioteca `morph.py` possui duas versões públicas:

- **Versão 1.0** — versão original, publicada junto ao artigo apresentado no EduComp 2024: <https://github.com/fzampirolli/morph>
- **Versão 1.1** — versão compacta, utilizada nas atividades deste livro: <https://github.com/fzampirolli/pdi-vc/blob/master/morph/morph.py>

A versão 1.1 foi necessária para uso nas atividades do **Moodle/VPL** (Laboratório Virtual de Programação). Na versão 1.0, bibliotecas como `matplotlib`, `requests` e `skimage` eram carregadas no momento do `import morph`, causando erro de memória (Jail: out of memory, 128MiB) no ambiente restrito do VPL.

Na versão 1.1, esses *imports* foram convertidos para **carregamento lazy**: cada biblioteca é importada apenas dentro do método que a utiliza, e somente quando esse método é de fato chamado. Assim, um simples `import morph` carrega apenas `numpy` e `cv2`, que são suficientes para a maioria dos EPs.

```
import os, importlib, urllib.request, numpy as np, matplotlib.pyplot as plt

# URLs do repositório
BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph"
for f in ["morph.py"]:
    if not os.path.exists(f):
        urllib.request.urlretrieve(f"{BASE_URL}/{f}", f)

import morph
importlib.reload(morph)
from morph import mm

# Verifica se o atributo existe antes de imprimir
version = getattr(morph, "__version__", "local_file")

print(f" Ambiente pronto. Módulo 'morph' carregado com sucesso (Versão: {version}).")
print(f" Funções disponíveis no mm: \n{dir(mm)[-5:]}...")
```

Ambiente pronto. Módulo 'morph' carregado com sucesso (Versão: 1.1.5).  
 Funções disponíveis no mm:  
 ['verifyBoundingBox\_old', 'watershed', 'watershed0', 'watershedB', 'write']...

## 1.8 Fundamentos de Matrizes - atenção à cópia de referências

Como uma imagem digital é uma matriz, precisamos saber criá-las corretamente. Em Python, existe uma armadilha comum ao usar o operador `*` em listas:

### ⚠ Atenção à cópia de referências

Ao fazer `m = [[0]*2]*3`, você não cria 3 linhas independentes, mas sim 3 referências para a **mesma** linha. Alterar um valor em uma linha alterará todas as outras!

Para visualizar esse comportamento, você pode testar o código no [Python Tutor](#) e comparar com a forma correta de criar matriz com listas: `m = [[0]*2 for _ in range(3)]`.

A forma recomendada e padrão em PDI é usar **NumPy**, que cria matrizes com dados independentes e oferece eficiência computacional. O código a seguir mostra diferentes formas de criação de imagens sintéticas — o resultado é exibido na Figure 1.6.

```
# Criando uma imagem preta (zeros) de 4, 6 pixels
img_preta = np.zeros((4, 6), dtype='uint8')
img_preta[0,0] = 255 # pixel branco no canto superior esquerdo

# Criando uma imagem branca (255) de 4, 6 pixels
img_branca = np.ones((4, 6), dtype='uint8') * 255
img_branca[3,5] = 0 # pixel preto no canto inferior direito

# Criando uma imagem aleatória para testes (ruído)
img_random = mm.randomImage(4, 6, maxValue=255)

print("Matriz aleatória gerada:")
print(mm.drawImg(img_random))

mm.show(
    [img_preta, img_branca, img_random],
    titles=[
        "Predominantemente preta\n(com 1 pixel branco em (0,0))",
        "Predominantemente branca\n(com 1 pixel preto em (3,5))",
        "Imagem aleatória\n(simulação de ruído)"
    ],
    cols=3,
    figsize=(9, 3),
    axis=True
)
```

Matriz aleatória gerada:

|     |     |     |     |     |     |
|-----|-----|-----|-----|-----|-----|
| 39  | 121 | 181 | 42  | 98  | 138 |
| 123 | 145 | 115 | 115 | 177 | 105 |
| 211 | 12  | 186 | 67  | 254 | 64  |
| 243 | 162 | 229 | 133 | 251 | 50  |




Figura 1.6: Exemplos de imagens sintéticas representadas matricialmente.

## 1.9 Lendo e Exibindo Imagens

Em bibliotecas como o [NumPy](#), [OpenCV](#) e [scikit-image](#), imagens digitais são frequentemente representadas computacionalmente como *arrays* do NumPy. Dessa forma, operações matriciais e conceitos de álgebra linear podem ser aplicados diretamente ao PDI.

Uma das operações fundamentais em PDI é a leitura de imagens. Na biblioteca `morph.py`, a função `mm.read()` permite carregar imagens tanto de arquivos locais quanto de URLs, como ilustrado na Figure 2.7.

```
import os
import numpy as np

url = "https://upload.wikimedia.org/wikipedia/commons/8/87/Mandrillus_sphinx_339428057.jpg"
caminho = "imagens/mandrill.png"

if not os.path.exists(caminho):
    os.makedirs("imagens", exist_ok=True)
    img_obj = mm.read(url, pil=True)
    mm.write(img_obj, caminho)
else:
    img_obj = mm.read(caminho, pil=True)

img = np.array(img_obj)

print(f"Dimensões (H, W, Canais): {img.shape}")
print(f"Tipo de dado: {img.dtype}")

mm.show(img, title="Exemplo: Captura RGB")
```

```
Dimensões (H, W, Canais): (1365, 2048, 3)
Tipo de dado: uint8
```



## Exemplo: Captura RGB



Figura 1.7: Mandrill (*Mandrillus sphinx*) em ambiente natural. Crédito: Julien Renoult (CC BY 4.0).

**Alternativa: *Download* da Imagem para Armazenamento Local**

Em ambientes nos quais a leitura direta de URLs esteja indisponível — devido a restrições de rede, políticas de *firewall* ou ausência de conectividade — uma alternativa consiste em realizar previamente o *download* da imagem para o sistema de arquivos local. Após o armazenamento, a imagem pode ser carregada normalmente pela função `mm.read()`. No exemplo a seguir, o arquivo é salvo localmente com o nome `mandrill.png`.

```
!wget -O mandrill.png \
    https://upload.wikimedia.org/wikipedia/commons/8/87/Mandrillus_sphinx_339428057.jpg
```

```
img = mm.read('mandrill.png')
mm.show(img, title="Exemplo: Captura RGB (arquivo local)")
```

**Explicação**

- `wget -O mandrill.png <URL>` realiza o *download* da imagem e a armazena localmente com o nome especificado;
- `mm.read('mandrill.png')` efetua a leitura do arquivo diretamente do sistema de arquivos, sem necessidade de requisições HTTP adicionais;
- essa estratégia reduz a dependência de conectividade durante a execução dos experimentos e evita *downloads* repetidos da mesma imagem.

**Nota**

O prefixo `!` é utilizado em ambientes baseados em *notebooks*, como [Jupyter Notebook](#), [JupyterLab](#) e [Google Colab](#), para executar comandos do sistema operacional diretamente em células de código. Em terminais convencionais, o comando deve ser utilizado sem o prefixo `!`.

Caso o utilitário `wget` não esteja instalado, pode-se utilizar alternativamente:

```
!curl -o mandrill.png \
    https://upload.wikimedia.org/wikipedia/commons/8/87/Mandrillus_sphinx_339428057.jpg
```

## 1.10 Conversão de Tipos e Limiarização

Conforme vimos, uma imagem colorida no espaço RGB é representada pela função:

$$f : \mathbb{E} \rightarrow \{0, 1, \dots, 255\}^3$$

Ou seja, para cada pixel  $(x, y)$ , temos três valores  $(R, G, B)$  que definem sua cor.

### Conversão para Tons de Cinza

Para converter uma imagem RGB em tons de cinza (*grayscale*), é necessário combinar os três canais em um único valor de intensidade  $g$ , que representa o brilho percebido. Como o olho humano não é igualmente sensível ao vermelho, verde e azul, utiliza-se uma **média ponderada**. O padrão [ITU-R BT.601](#) (ITU-R, 2011) define os seguintes pesos:

$$g = 0.299 R + 0.587 G + 0.114 B \quad (1.3)$$

Após o cálculo, o valor  $g$  é arredondado para o inteiro mais próximo e ajustado ao intervalo  $[0, 255]$ . O resultado é uma nova imagem, agora em tons de cinza, representada por:

$$f_{\text{cinza}} : \mathbb{E} \rightarrow \{0, 1, \dots, 255\}$$

### Limiarização (*Thresholding*)

A partir da imagem em tons de cinza  $f_{\text{cinza}}(x, y)$ , uma operação fundamental é a **limiarização**, que produz uma imagem **binária** (apenas preto e branco). Para isso, escolhe-se um valor de corte  $T$  (geralmente no intervalo  $[0, 255]$ ) e define-se:

$$f_{\text{bin}}(x, y) = \begin{cases} 255 & \text{se } f_{\text{cinza}}(x, y) > T \\ 0 & \text{caso contrário} \end{cases} \quad (1.4)$$

**Exemplo:** Com  $T = 128$ , pixels com intensidade acima de 128 tornam-se brancos (255); os demais tornam-se pretos (0).

A limiarização é amplamente usada para **segmentar objetos do fundo**, extrair bordas ou criar máscaras binárias para processamento posterior.

**Nota:** O valor 255 representa o branco máximo em imagens de 8 bits, enquanto 0 representa o preto absoluto.

### Exemplo prático de conversão e limiarização

A Figure 1.8 ilustra os principais passos para transformar uma imagem colorida em tons de cinza e, em seguida, convertê-la em uma imagem binária por limiarização. O código a seguir implementa essas etapas:

```
# 1. Converter para Tons de Cinza
img_gray = mm.gray(img)

# 2. Aplicar limiar (Pixels > 128 tornam-se 255, outros 0)
limiar = 128
img_binaria = mm.threshold(img_gray, limiar)

# Uso da nova função
mm.show(
    [img, img_gray, img_binaria],
```

```
titles=["Original", "Tons de Cinza", f"Binária (T={limiar})"],
cols=3
)
```



Figura 1.8: Processamento básico de imagens: (a) imagem original, (b) imagem em tons de cinza, (c) imagem binarizada por limiar ( $T=128$ ).

### 1.11 Limiarização pelo método de Otsu

Conforme apresentado na Equation 1.4, a limiarização converte uma imagem em tons de cinza para binária usando um valor de corte  $T$ . Até agora fixamos  $T = 128$  manualmente.

```
img_bin_fixo = mm.threshold(img_gray, T=128)
```

Entretanto, a escolha manual de  $T$  nem sempre é trivial. A biblioteca `mm` oferece uma alternativa automática: quando o parâmetro `limiar` **não é fornecido**, a função `mm.threshold(img_gray)` calcula o valor de  $T$  pelo **método de Otsu** (Otsu, 1979). Esse método, que será detalhado em capítulos futuros, maximiza a variância entre classes do histograma (frequência de cada tom de cinza), separando automaticamente os pixels de objeto e fundo.

O código abaixo compara a limiarização manual ( $T = 128$ ) com a automática (Otsu), mostrando também o valor de  $T$  calculado:

```
import cv2
# Limiarização com T fixo (manual)
T_fixo = 128
img_bin_fixo = mm.threshold(img_gray, T_fixo)

# Limiarização pelo método de Otsu (T automático)
T_otsu, img_bin_otsu = cv2.threshold(img_gray, 0, 255,
                                     cv2.THRESH_BINARY + cv2.THRESH_OTSU)

print(f'Limiar calculado por Otsu: T = {T_otsu}')
# ou simplesmente:
# img_bin_otsu = mm.threshold(img_gray)

# Exibição lado a lado
mm.show(
    [img_gray, img_bin_fixo, img_bin_otsu],
    titles=["Tons de Cinza", f"Binária (T={T_fixo})", f"Binária (Otsu, T={T_otsu})"],
    cols=3
)
```

```
Limiar calculado por Otsu: T = 95.0
```



Figura 1.9: Comparação entre limiarização manual ( $T=128$ ) e automática (Otsu) sobre a imagem em tons de cinza.

A Figure 1.9 mostra que o limiar obtido por Otsu se adapta automaticamente à imagem, resultando em uma binarização mais eficiente do que um valor fixo, especialmente quando as intensidades do objeto e do fundo são bem separadas no histograma. Essa técnica é amplamente utilizada em sistemas de VC para binarização de documentos, detecção de objetos e pré-processamento de imagens.

### 💡 Simplicidade da biblioteca `morph.py`

Enquanto o OpenCV exige a chamada completa:

```
T_otsu, img_bin = cv2.threshold(img_gray, 0, 255,
                                cv2.THRESH_BINARY + cv2.THRESH_OTSU)
```

a biblioteca `mm` abstrai toda essa complexidade: basta chamar `mm.threshold(img_gray)`. O limiar de Otsu é calculado automaticamente e a imagem binária é retornada diretamente. Essa abordagem permite concentrar-se no conceito, não nos detalhes de implementação.

## 1.12 Acesso a Pixels

Em Python com NumPy, uma imagem é estruturada como um **array multidimensional**. O acesso a um pixel específico utiliza a convenção matricial **linha** (eixo Y) e **coluna** (eixo X): `img[linha, coluna]`.

O código da Figure 1.10 demonstra como extrair esses valores em imagens coloridas (RGB) e em tons de cinza, além de isolar a vizinhança imediata do ponto de interesse.

```
import matplotlib.pyplot as plt

# 1. Definição das coordenadas do pixel alvo
r, c = 600, 800

# 2. Acesso direto aos valores dos pixels
pixel_cinza = img_gray[r, c]
pixel_rgb = img[r, c]

print(f" VALORES NO PIXEL ALVO ({r}, {c}):")
print(f"   • Tons de cinza (Escalar) : {pixel_cinza}")
print(f"   • Colorido (Vetor RGB)      : R={pixel_rgb[0]}, G={pixel_rgb[1]}, B={pixel_rgb[2]}")
print(f"  "-" * 50)

# 3. Exibição didática da vizinhança 3x3 ao redor do pixel (r, c)
# Recorta da linha r-1 até r+1, e da coluna c-1 até c+1
vizinhanca_gray = img_gray[r-1:r+2, c-1:c+2]

print(f" MATRIZ DE VIZINHANÇA 3x3 EM TONS DE CINZA:")
```



```

print(f"    (0 pixel alvo central está destacado com entre colchetes)\n")

# Impressão formatada para destacar o pixel central
for i, linha in enumerate(vizinhanca_gray):
    linhas_str = []
    for j, valor in enumerate(linha):
        if i == 1 and j == 1:
            linhas_str.append(f"[{valor:3d}]") # Destaca o centro (100, 100)
        else:
            linhas_str.append(f"{valor:3d} ")
    print("    " + " ".join(linhas_str))

# 4. Demonstração visual usando o mm.show (opcional, mas excelente para o livro)
# Mostra a imagem inteira com um ponto demarcando a região
plt.figure(figsize=(5, 5))
plt.imshow(img)
plt.plot(c, r, 'ro', markersize=8, label=f'Pixel ({r},{c})') # Plota (x, y) -> (c, r)
plt.title(f"Localização do Pixel ({r}, {c}) na Imagem")
plt.legend()
plt.axis('on') # Mantém os eixos para o estudante ver as coordenadas 100, 100
plt.show()

```

#### VALORES NO PIXEL ALVO (600, 800):

- Tons de cinza (Escalar) : 81
- Colorido (Vetor RGB) : R=92, G=78, B=67

#### MATRIZ DE VIZINHANÇA 3x3 EM TONS DE CINZA:

(0 pixel alvo central está destacado com entre colchetes)

```

83   96  105
85  [ 81]  96
83   77   84

```




Figura 1.10: Acesso a um pixel específico (r, c) e a representação de sua vizinhança na imagem.

### Explicação linha a linha:

1. `img_gray[r, c]` — Retorna um único valor inteiro (escalar) entre 0 e 255, que representa a intensidade de brilho do cinza.



2. `img[r, c]` — Retorna um vetor com três valores `[R, G, B]`, correspondentes às intensidades dos canais Vermelho, Verde e Azul.
3. `img_gray[r-1:r+2, c-1:c+2]` — Realiza um fatiamento (*slicing*) para extrair a submatriz  $3 \times 3$  ao redor do pixel. Esta operação é a base para a implementação de filtros espaciais e convoluções.
4. O laço `for` subsequente apenas formata essa submatriz no console, exibindo o pixel central entre colchetes `[ ]` para fins didáticos.
5. A função `plt.plot(c, r, 'ro')` plota um ponto vermelho sobre a imagem para correlacionar a coordenada numérica com sua posição visual. Note que o Matplotlib utiliza a ordem padrão de tela `(X, Y)`, invertendo para `(c, r)`.

Como a indexação em Python começa em zero (*zero-based*), o canto superior esquerdo da imagem é a coordenada `(0,0)`. Guarde sempre esta regra: a primeira dimensão da matriz controla a **altura** (linhas/Y) e a segunda controla a **largura** (colunas/X).

## 1.13 Resumo

Neste capítulo, apresentaram-se os fundamentos de representação de imagens digitais: a definição de pixel, a estruturação de imagens em matrizes e o impacto da amostragem e da quantização na qualidade final:

- **Imagem digital** = função  $f(x, y)$  que mapeia coordenadas para intensidades (escalares ou vetoriais).
- **Domínio**: conjunto finito  $\mathbb{E} = \{(x, y) \in \mathbb{Z}^2 \mid 0 \leq x < L, 0 \leq y < H\}$ .
- **Tipos principais**: binária ( $\mathcal{V} = \{0, 255\}$ ), tons de cinza ( $\mathcal{V} = [0, 255]$ ) e RGB ( $\mathcal{V} = [0, 255]^3$ ).
- A biblioteca `morph.py` (ou `mm`) oferece funções didáticas para operações básicas de PDI, como `mm.gray()`, `mm.threshold()`, `mm.show_multiple()`.
- **Armadilha NumPy**: nunca use `[[0]*n]*m` para criar matrizes — use sempre `np.zeros()` ou `np.ones()`.
- **Limiarização** converte tons de cinza em binária; o **método de Otsu** determina o valor de corte automaticamente maximizando a variância entre classes.
- Acesso a pixels via `img[linha, coluna]`, com indexação *zero-based*.

O Capítulo 2 abordará **histogramas e equalização de contraste**.

## 1.14 Uso do Gemini Notebook como Tutor Complementar

Nesta edição, além dos *notebooks* interativos no Google Colab, o **Gemini Notebook** está disponível como ferramenta complementar de estudo. A plataforma utiliza exclusivamente os documentos fornecidos pelo autor como base de conhecimento, garantindo respostas coerentes com o conteúdo do livro.

### Estude com o Tutor Inteligente

Acesse o ambiente do capítulo pelo *link* abaixo e explore especialmente as opções **Guia de Estudo** e **Conversa** para aprofundar sua compreensão.

 [ACESSAR Gemini Notebook: CAPÍTULO 01](#)

### Aviso sobre Conteúdo Gerado por IA

A IA é uma poderosa aliada nos estudos, mas o conteúdo gerado pode conter **erros ou imprecisões**. Consulte sempre **livros, artigos científicos e outras fontes acadêmicas confiáveis** para validar as informações. Sempre que possível, execute os exemplos práticos fornecidos neste capítulo para verificar os resultados.

## Funcionalidades Disponíveis na Plataforma

O **Gemini Notebook** oferece uma suíte avançada de ferramentas baseadas em IA para transformar o conteúdo estático do livro em uma experiência de aprendizado dinâmica e multimídia. Conforme ilustrado

na Figure 1.11, a plataforma utiliza técnicas de **RAG** (*Retrieval-Augmented Generation*), fundamentadas no trabalho de Lewis et al. (2020), para basear as respostas estritamente nos documentos fornecidos e minimizar a ocorrência de alucinações.

As principais funcionalidades incluem:

- **Resumos Multimodais (Áudio e Vídeo):** Geração de conversas naturais entre especialistas no formato de **Resumo em Áudio** (estilo *podcast*) e **Resumo em Vídeo**, discutindo os temas centrais do capítulo, como as diferenças entre PDI e VC, ou a interpretação de transformações como a limiarização e o método de Otsu.
- **Visualização de Estruturas (Mapa Mental e Infográfico):** Criação automática de diagramas que conectam visualmente os conceitos, por exemplo, o fluxo de processamento desde a captura da imagem digital, passando pela conversão para tons de cinza, limiarização e segmentação binária.
- **Ferramentas de Avaliação (Teste e Cartões Didáticos):** Geração de **Testes** de múltipla escolha e **Cartões Didáticos** (*flashcards*) para fixação de conhecimento, baseados no texto autoral (ex.: perguntas sobre a fórmula de conversão RGB→cinza ou sobre o funcionamento do limiar global e de Otsu).
- **Apoio à Apresentação (Slides e Relatórios):** Auxílio na estruturação de **Apresentações de Slides** e na redação de **Relatórios** técnicos, facilitando a comunicação de resultados de experimentos com imagens.
- **Análise de Dados (Tabela de Dados):** Organização de dados extraídos do texto em tabelas estruturadas, auxiliando na compreensão de exemplos práticos, como a comparação entre diferentes valores de limiar.
- **Chat Contextualizado:** Permite o questionamento direto sobre o código e a teoria, como: “*Como implementar a conversão de RGB para tons de cinza usando os pesos do padrão ITU-R BT.601?*” ou “*O que acontece com a imagem binária se eu escolher um limiar  $T=200$  em vez de  $T=128$ ?*”.



Figura 1.11: Estúdio do Gemini Notebook.

## 1.15 Lista de Exercícios

1. (15%) Com suas próprias palavras, defina **imagem digital** e **pixel**. Dê um exemplo concreto de como uma imagem colorida (RGB) é representada matricialmente no computador.
2. (15%) Explique as diferenças entre **imagem binária**, **tons de cinza (8 bits)** e **colorida RGB**, indicando a faixa de valores possíveis para cada pixel em cada tipo.
3. (20%) Considerando a fórmula de conversão RGB → tons de cinza do padrão ITU-R BT.601:

$$g = 0.299 R + 0.587 G + 0.114 B$$

Calcule o valor do pixel em tons de cinza para  $(R, G, B) = (80, 180, 30)$ . Arredonde para o inteiro mais próximo.

4. (20%) O que é **limiarização** (*thresholding*)? Explique a diferença entre escolher um limiar  $T$  fixo (ex.:  $T = 128$ ) e utilizar o **método de Otsu** para determinação automática do limiar. Em poucas palavras, como o método de Otsu escolhe o limiar?
5. (15%) No contexto da biblioteca didática `mm` discutida no capítulo, responda:
  - a) (7,5%) Como se acessa o valor do pixel na posição (linha=50, coluna=60) de uma imagem em tons de cinza `img_gray`?
  - b) (7,5%) Qual é a vantagem de usar `mm.threshold(img_gray)` sem passar o limiar? Compare com a chamada equivalente no OpenCV.
6. (15%) O que a propriedade `img.shape` retorna para uma imagem NumPy no formato RGB? Dê um exemplo concreto com uma imagem de 640×480 pixels.

## Referências do Capítulo

A fundamentação teórica deste capítulo compreende as seguintes obras de PDI e VC:

- Gonzalez; Woods (2018) para os fundamentos de **Processamento Digital de Imagens** (PDI).
- Singh (2019) para a implementação prática de métodos de **processamento e análise de imagens**.
- Szeliski (2022) para o estudo de VC e algoritmos fundamentais.
- Bradski; Kaehler (2008) para a aplicação da biblioteca **OpenCV** em ambiente Python.
- Lewis et al. (2020) para o conceito de **geração aumentada por recuperação (RAG)**, utilizado no suporte ao processamento de informações deste material.



### 1.16 Parte Prática com Exercícios de Programação

#### Objetivo deste Caderno

Os **Exercícios de Programação (EPs)** apresentados a seguir podem ser submetidos também em atividades do Moodle (atividades VPL) que fornecem *feedback* automático.

**Este caderno foi desenvolvido para superar limitações de uso do Moodle.** Com ele, deve-se:

1. **Desenvolver:** Escrever e editar sua solução diretamente no ambiente Colab.
2. **Validar:** Testar seu código localmente utilizando os **mesmos casos de teste** do Moodle.
3. **Organizar:** Salvar seus códigos das atividades VPL de forma segura.
4. **Avaliar:** Quando estiver conectado ao Moodle, basta copiar sua solução e clicar em **Avaliar** no Moodle (se estiver na rede da UFABC) para registrar sua nota oficial.

#### § Instruções Passo a Passo

Em um ambiente de execução (como VSCode, Jupyter ou Colab), siga a ordem abaixo para configurar o ambiente e validar seus exercícios:

##### Preparação do Ambiente

Execute a célula de código abaixo para baixar `morph.py` e `testsuite.py` do repositório da disciplina — apenas se ainda não existirem no diretório local. Com ambos em `./`, o *notebook* e os subprocessos do `TestSuite` encontram o módulo sem configurações extras de caminho.

*Nota:* O script `testsuite.py` buscará automaticamente os casos de teste em `all/{cap}/cases` no [GitHub](#).

## Escrevendo o Código

Salve sua solução em uma célula de código usando o comando mágico `%%writefile`. O nome do arquivo deve seguir o padrão `EPX_Y.*`, onde `X` é o capítulo, `Y` é o exercício e `*` é a extensão da linguagem.

**Exemplo:** `%%writefile EP01_01.py`

### Download

Baixe `morph.py` e `testsuite.py` executando a célula abaixo:

```
import os, sys, importlib, inspect, urllib.request

# URLs do repositório
BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph"
for f in ["morph.py", "testsuite.py"]:
    if not os.path.exists(f):
        urllib.request.urlretrieve(f"{BASE_URL}/{f}", f)

import morph, testsuite
importlib.reload(morph); importlib.reload(testsuite)
from morph import mm
from testsuite import TestSuite

print(f" Ambiente pronto. Morph: {morph.__version__} | TestSuite: {testsuite.__version__}")
```

Ambiente pronto. Morph: 1.1.5 | TestSuite: 1.1.2

## Executando os Testes

Após salvar o arquivo com sua solução, execute o comando abaixo (em uma nova célula) para avaliar os testes automáticos:

```
TestSuite("EP01_01.extensão").run()
```

Substitua a extensão conforme a linguagem usada:

| Linguagem  | Extensão |
|------------|----------|
| Python     | .py      |
| Java       | .java    |
| C          | .c       |
| C++        | .cpp     |
| JavaScript | .js      |
| R          | .r       |

**Como funciona:** O `TestSuite` baixa os casos de teste do GitHub, executa seu programa com cada entrada e compara a saída com a esperada – calculando automaticamente sua nota.

Para testar código Python diretamente, sem salvar arquivo, use `run_code(codigo)` passando o código como *string* numa variável `codigo`:

```
codigo = """
from morph import mm
# ... seu código aqui ...
"""

TestSuite("EP04_01").run_code(codigo)
```

## ⚠ Importante: Regras e Boas Práticas

### ♦ Sobre a Entrada de Dados

O seu programa deve ler a entrada padrão (teclado).

- **Python:** Utilize `input()`.
- **Outras linguagens:** Utilize o comando de leitura padrão equivalente (`cin`, `Scanner`, etc.).

### ♦ Configuração de IA no Colab

Para um melhor aprendizado, recomenda-se desativar o preenchimento automático de código por IA, pois não estará disponível durante as avaliações. Por exemplo no navegador Chrome:

- Vá em: **Ferramentas > Configurações > IA generativa**
- Desmarque: **Habilitar geração de código**

### ♦ Integridade Acadêmica (Plágio)

Este recurso de testes locais aplica-se a EPs **sem variações**. No entanto:

- **Individualidade:** Cada estudante deve desenvolver sua própria solução.
- **Detecção de Similaridade:** O professor utiliza ferramentas que detectam cópias, **mesmo com alteração de nomes de variáveis ou espaços em branco**.

## 1.16.1 EP01\_01 📏 Três métricas de distância em PDI

Nesta atividade, você deve escrever um programa que calcule as três distâncias clássicas em PDI: **Euclidiana (L2)**, **City-Block (L1)** e **Chessboard (L $\infty$ )**.

- Leia **4 números reais** que representam as coordenadas:  $A_x, A_y, B_x, B_y$ .
- Calcule as três distâncias utilizando as fórmulas:

$$d_{\text{Euclidiana}} = \sqrt{(B_x - A_x)^2 + (B_y - A_y)^2}$$

$$d_{\text{City-block}} = |B_x - A_x| + |B_y - A_y|$$

$$d_{\text{Chessboard}} = \max(|B_x - A_x|, |B_y - A_y|)$$

- Imprima os três resultados, cada um em uma linha, formatados com **duas casas decimais**, na ordem: **Euclidiana**, **City-block**, **Chessboard**.

### 📌 Importante:

- Utilize as funções matemáticas padrão da sua linguagem: `math.sqrt`, `abs` (ou `fabs`) e `max`.
- A saída deve conter **apenas os números** (um por linha), sem textos adicionais.
- Ver um simulador interativo para esta questão na **Figure 1.12** (gráfico com arrasto dos pontos e visualização das três métricas).

### 1.16.1.1 🖼 Por que isso importa? – Custo computacional

Em uma imagem **1000×1000 pixels** (1 milhão de pixels), calcular a distância de cada pixel a um ponto de referência exige **1 milhão de operações**. A escolha da métrica afeta o desempenho:



| Métrica                                  | Operações por pixel                                   | Custo relativo (1M pixels)                                                                                          | Quando usar                         |
|------------------------------------------|-------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------|-------------------------------------|
| <b>Euclidiana (L2)</b>                   | 2 subtrações, 2 multiplicações, 1 soma, 1 <b>sqrt</b> |  Mais custosa – <b>sqrt</b> é cara | Distância “real” no espaço contínuo |
| <b>City-block (L1)</b>                   | 2 subtrações, 2 <b>abs</b> , 1 soma                   |  Moderada – sem raiz quadrada      | Grids, robótica, imagens binárias   |
| <b>Chessboard (L<math>\infty</math>)</b> | 2 subtrações, 2 <b>abs</b> , 1 <b>max</b>             |  Mais eficiente                    | Movimentos de peças, morfologia     |

A função **sqrt** é computacionalmente mais cara que operações como adição, subtração, multiplicação e valor absoluto. Em CPUs modernas, a diferença pode ser pequena (cerca de  $1,5\times$  a  $3\times$ ), mas em sistemas embarcados ou em laços de milhões de iterações, qualquer ganho importa. Por isso, **quando o objetivo é apenas comparar distâncias** (ex.: encontrar o ponto mais próximo), use a **distância euclidiana ao quadrado**.

#### 1.16.1.2 Tarefa (especificação para VPL)

##### Entrada:

Uma única linha com quatro números reais:  $A_x$   $A_y$   $B_x$   $B_y$

##### Saída:

Três linhas, cada uma com um número real de duas casas decimais (Euclidiana, City-block, Chessboard).

#### 1.16.1.3 Exemplos

| Entrada | Saída | Observação        |
|---------|-------|-------------------|
| 0       | 5.00  | Triângulo 3-4-5   |
| 0       | 7.00  |                   |
| 3       | 4.00  |                   |
| 4       |       |                   |
| 0       | 1.41  | Diagonal unitária |
| 0       | 2.00  |                   |
| 1       | 1.00  |                   |
| 1       |       |                   |

Exemplo de teste de **sqrt** em Python, com **timeit** isolando cada operação:

```
import math
import timeit

N = 50_000_000

def apenas_soma():
    a, b = 3.0, 4.0
    return a + b

def soma_e_sqrt():
    a, b = 3.0, 4.0
    return math.sqrt(a*a + b*b)
```

```
t_soma = timeit.timeit(apenas_soma, number=N)
t_sqrt = timeit.timeit(soma_e_sqrt, number=N)

print(f"Soma simples      : {t_soma:.3f} s")
print(f"Soma + sqrt       : {t_sqrt:.3f} s")
print(f"Razão (sqrt/soma)   : {t_sqrt/t_soma:.2f}x")
```

```
Soma simples      : 2.836 s
Soma + sqrt       : 5.602 s
Razão (sqrt/soma) : 1.97x
```




Figura 1.12: Simulador: Distâncias Euclidiana, *City-block* e *Chessboard*

#### 1.16.1.4 🐍 Python

Basta criar uma célula de código normal e inserir o código Python. A entrada pode ser simulada usando `input()`, que funciona normalmente.

Exemplo de célula:

```
%%writefile EP01_01.py
# Código Python
x1,y1,x2,y2 = int(input()), int(input()), int(input()), int(input())
# Cálculo das diferenças
dx = abs(x2 - x1)
dy = abs(y2 - y1)

# 1. Distância Euclidiana (L2)
dist_euclidiana = (dx**2 + dy**2)**0.5
```

```
# 2. Distância City-block / Manhattan (L1)
dist_city_block = dx + dy

# 3. Distância Chessboard / Chebyshev (Linf)
dist_chessboard = max(dx, dy)

# Saída formatada conforme os casos de teste
print(f"{dist_euclidiana:.2f}")
print(f"{dist_city_block:.2f}")
print(f"{dist_chessboard:.2f}")
```

Writing EP01\_01.py

```
# Espera que você digite 4 números inteiros ao executar esta célula.
# No Jupyter ou Google Colab, a mágica %run -i permite que o script leia do teclado.
# No terminal comum, você usaria: python3 EP01_01.py (sem o '!' e sem '%run').

# %run -i EP01_01.py
```

```
# Envia 4 inteiros como entrada padrão (stdin) para o script EP01_01.py usando um pipe
!echo -e "0\n0\n4\n4" | python3 EP01_01.py
```

```
5.66
8.00
4.00
```

```
TestSuite("EP01_01.py").run()
```

### 1.16.1.5 Java

Para executar Java no Colab, você precisa usar uma célula com o prefixo `%%writefile` para salvar o código em arquivo, compilar e executar.

```
%%writefile EP01_01.java
import java.util.Scanner;

class EP01_01 {
    public static void main(String[] args) {
        Scanner s = new Scanner(System.in);

        double x1 = s.nextDouble(), y1 = s.nextDouble();
        double x2 = s.nextDouble(), y2 = s.nextDouble();

        double dx = Math.abs(x2 - x1);
        double dy = Math.abs(y2 - y1);

        System.out.printf("%.2f\n", Math.sqrt(dx*dx + dy*dy));
        System.out.printf("%.2f\n", dx + dy);
        System.out.printf("%.2f\n", Math.max(dx, dy));
    }
}
```

Writing EP01\_01.java

```
!javac EP01_01.java
!echo -e "0\n0\n4\n4" | java EP01_01
```

```
5,66
8,00
4,00
```

```
TestSuite("EP01_01.java").run()
```

### 1.16.1.6 C

De forma similar, use `%%writefile` para salvar o código, depois compile e execute. Para C, utilizamos o compilador **GCC**.

```
# Instalar o compilador GCC e ferramentas de build
# O build-essential inclui gcc, g++, make, etc.
import platform, shutil, subprocess

def instalar_gcc():
    if shutil.which("gcc"):
        print(" GCC já disponível."); return
    if platform.system() != "Linux":
        print(" Mac: xcode-select --install | Windows: WSL ou MinGW"); return
    try: import google.colab; cmd = ["apt-get", "install", "-y", "build-essential"]
    except ImportError: cmd = ["sudo", "apt-get", "install", "-y", "build-essential"]
    subprocess.run(cmd, check=True)
    print(" build-essential instalado!")

instalar_gcc()
```

GCC já disponível.

```
%%writefile EP01_01.c
#include <stdio.h>
#include <math.h>

int main() {
    double x1, y1, x2, y2;
    if (scanf("%lf %lf %lf %lf", &x1, &y1, &x2, &y2) != 4) return 0;

    double dx = fabs(x2 - x1);
    double dy = fabs(y2 - y1);

    // Euclidiana, City-block e Chessboard
    printf("%.2f\n", sqrt(dx * dx + dy * dy));
    printf("%.2f\n", dx + dy);
    printf("%.2f\n", fmax(dx, dy));

    return 0;
}
```

Writing EP01\_01.c

```
# Compila o arquivo .c gerando o executável EP01_01
# -lm é usado para linkar a biblioteca matemática (math.h) se necessário

!gcc EP01_01.c -o EP01_01 -lm
!echo -e "0\n0\n4\n4" | ./EP01_01
```

5.66  
8.00  
4.00

```
TestSuite("EP01_01.c").run()
```

### 1.16.1.7 C++

De forma similar ao Java, use `%%writefile` para salvar o código, depois compile e execute. Lembre-se de que, no Colab, também é necessário instalar o seguinte:

```
# Instalar o compilador G++ para C++
# O build-essential inclui o g++, make, etc.
import platform, shutil, subprocess

def instalar_gpp():
    if shutil.which("g++"):
        print(" G++ já disponível."); return
    if platform.system() != "Linux":
        if platform.system() == "Darwin":
            print(" Mac: xcode-select --install")
        else:
            print(" Windows: use WSL ou MinGW (https://www.mingw-w64.org)")
        return
    try: import google.colab; cmd = ["apt-get", "install", "-y", "build-essential"]
    except ImportError: cmd = ["sudo", "apt-get", "install", "-y", "build-essential"]
    subprocess.run(cmd, check=True)
    print(" Compilador C++ pronto.")

instalar_gpp()
```

G++ já disponível.

```
%%writefile EP01_01.cpp
#include <iostream>
#include <iomanip>
#include <cmath>
#include <algorithm>

int main() {
    double x1, y1, x2, y2;
    if (!(std::cin >> x1 >> y1 >> x2 >> y2)) return 0;

    double dx = std::abs(x2 - x1);
    double dy = std::abs(y2 - y1);

    std::cout << std::fixed << std::setprecision(2);

    // Euclidiana, City-block e Chessboard
    std::cout << std::sqrt(dx*dx + dy*dy) << std::endl;
    std::cout << (dx + dy) << std::endl;
    std::cout << std::max(dx, dy) << std::endl;

    return 0;
}
```

Writing EP01\_01.cpp



```
!g++ EP01_01.cpp -o EP01_01
!echo -e "0\n0\n4\n4" | ./EP01_01
```

```
5.66
8.00
4.00
```

```
TestSuite("EP01_01.cpp").run()
```

### 1.16.1.8 JavaScript (Node.js)

Para JavaScript, use `%%writefile` para criar o arquivo e execute com Node:

```
%%writefile EP01_01.js
function escreva(s) { try { document.write(s + "<br>"); } catch(e) { console.log(s); } }

process.stdin.once('data', data => {
  const valores = data.toString().trim().split(/\s+/);
  const x1 = parseFloat(valores[0]);
  const y1 = parseFloat(valores[1]);
  const x2 = parseFloat(valores[2]);
  const y2 = parseFloat(valores[3]);

  const dx = Math.abs(x2 - x1);
  const dy = Math.abs(y2 - y1);

  // Euclidiana, City-block e Chessboard
  escreva(Math.sqrt(dx * dx + dy * dy).toFixed(2));
  escreva((dx + dy).toFixed(2));
  escreva(Math.max(dx, dy).toFixed(2));
});
```

```
Writing EP01_01.js
```

```
TestSuite("EP01_01.js").run()
```

### 1.16.1.9 R

No Colab, pode-se executar código R diretamente utilizando a mágica `%%R`.

O programa deve ler **quatro números** ( $x_1$ ,  $y_1$ ,  $x_2$ ,  $y_2$ ) e exibir a distância euclidiana com **duas casas decimais**.

Exemplo de célula:

```
%%R
dados <- scan(file = "stdin", n = 4, quiet = TRUE)
x1 <- dados[1]; y1 <- dados[2]; x2 <- dados[3]; y2 <- dados[4]
dist <- sqrt((x2 - x1)^2 + (y2 - y1)^2)
cat(sprintf("%.2f", dist))
```

```
# Instalar o R e o Rscript
# O r-base instala o ambiente R completo, incluindo o Rscript
import platform, shutil, subprocess
```

```
def instalar_r():
    if shutil.which("R"):
        print(" R já disponível."); return
    if platform.system() != "Linux":
        if platform.system() == "Darwin":
            print(" Mac: https://cran.r-project.org/bin/macosx/")
        else:
            print(" Windows: https://cran.r-project.org/bin/windows/base/")
        return
    try: import google.colab; cmd = ["apt-get", "install", "-y", "r-base"]
    except ImportError: cmd = ["sudo", "apt-get", "install", "-y", "r-base"]
    subprocess.run(cmd, check=True)
    print(" Ambiente R pronto.")

instalar_r()
```

R já disponível.

Para testar da mesma forma que nos exemplos anteriores, deve-se usar a entrada padrão (stdin) no terminal ou adaptar o código conforme abaixo:

```
%%writefile EP01_01.r
dados <- scan(file = "stdin", n = 4, quiet = TRUE)
dx <- abs(dados[3] - dados[1])
dy <- abs(dados[4] - dados[2])

# Saídas: Euclidiana, City-block e Chessboard
cat(sprintf("%.2f\n%.2f\n%.2f\n",
    sqrt(dx^2 + dy^2),
    dx + dy,
    max(dx, dy)))
```

Writing EP01\_01.r

```
!echo -e "0\n0\n4\n4" | Rscript EP01_01.r
```

5.66  
8.00  
4.00

```
TestSuite("EP01_01.r").run()
```

## 1.16.2 EP01\_02 Desempenho Preditivo — Métricas de ML em VC

Nesta atividade, você entrará no mundo do **Aprendizado de Máquina** (*Machine Learning*). Seu objetivo é avaliar o desempenho de um classificador binário calculando métricas a partir de uma **Matriz de Confusão**.

### 1.16.2.1 Por que a métrica certa importa?

Imagine um detector de **moedas de R\$ 1,00**. O impacto do erro define a métrica prioritária:

| Métrica         | Exemplo Prático          | Importância em PDI/VC                                                                         |
|-----------------|--------------------------|-----------------------------------------------------------------------------------------------|
| <b>Acurácia</b> | <b>Contagem de Grãos</b> | Útil quando as classes são equilibradas (ex: metade dos grãos com defeito, metade saudáveis). |

| Métrica              | Exemplo Prático            | Importância em PDI/VC                                                                                                        |
|----------------------|----------------------------|------------------------------------------------------------------------------------------------------------------------------|
| <b>Precisão</b>      | <b>Segurança/Biometria</b> | Crucial para evitar <b>Falsos Positivos</b> (ex: não permitir que um impostor acesse um sistema por erro de reconhecimento). |
| <b>Sensibilidade</b> | <b>Saúde (Tumores)</b>     | Crucial para evitar <b>Falsos Negativos</b> (ex: não deixar um tumor passar despercebido em um exame de Raio-X).             |
| <b>F1-score</b>      | <b>Cédulas de Dinheiro</b> | Ideal para um <b>equilíbrio</b> entre não rejeitar notas verdadeiras e não aceitar notas falsas.                             |

### 1.16.2.2 A Matriz de Confusão

|               | Predita Positiva                | Predita Negativa                |
|---------------|---------------------------------|---------------------------------|
| Real Positiva | <b>VP</b> (Verdadeiro Positivo) | <b>FN</b> (Falso Negativo)      |
| Real Negativa | <b>FP</b> (Falso Positivo)      | <b>VN</b> (Verdadeiro Negativo) |

#### Tarefa:

1. Leia **4 valores inteiros** na ordem: VP, FN, FP, VN.
2. Calcule as métricas utilizando as fórmulas:

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN}$$

$$\text{Precisão} = \frac{VP}{VP + FP}$$

$$\text{Sensibilidade (Recall)} = \frac{VP}{VP + FN}$$

$$\text{F1-score} = \frac{2 \times \text{Precisão} \times \text{Sensibilidade}}{\text{Precisão} + \text{Sensibilidade}}$$

3. Imprima os resultados formatados com **duas casas decimais**, um por linha.

#### **Importante:**

- Use divisão em ponto flutuante para evitar resultados truncados.
- A ordem de saída deve ser: **Acurácia**, **Precisão**, **Sensibilidade** e **F1-score**.
- Veja a simulação interativa deste EP na Figure 1.13.

### 1.16.2.3 Exemplo de Execução

| Entrada | Saída | Observação    |
|---------|-------|---------------|
| 40      | 0.75  | Acurácia      |
| 10      | 0.73  | Precisão      |
| 15      | 0.80  | Sensibilidade |

| Entrada | Saída | Observação |
|---------|-------|------------|
| 35      | 0.76  | F1-score   |

(Nota:  $VP=40$ ,  $FN=10$ ,  $FP=15$ ,  $VN=35$ . Total de casos = 100)

### Simulador: desempenho de classificadores

Ajuste os valores da matriz de confusão e veja as métricas calculadas em tempo real.




Figura 1.13: Simulador: Desempenho Preditivo — Métricas de ML

```
%%writefile EP01_02.py
# sua solução
```

Writing EP01\_02.py

```
TestSuite("EP01_02.py").run()
```

#### 1.16.3 EP01\_03 ↗ *Mean Average Precision* (mAP) — Curva Precisão-Sensibilidade

Nesta atividade, você avaliará um classificador binário (ex.: detecção de desmatamento em imagens de satélite, ver [dgi.inpe.br](http://dgi.inpe.br)) através da **curva Precisão-Sensibilidade** e da métrica **mAP** (*Mean Average Precision*). O mAP é padrão em competições como **COCO** (*Common Objects in Context*) e **PASCAL VOC** (*Visual Object Classes*) e dos modelos **YOLO** (*You Only Look Once*).

### 1.16.3.1 🧠 Por que o mAP é a métrica-padrão?

Na EP01\_02 você viu que a escolha do limiar altera significativamente a Precisão e a Sensibilidade. O **mAP** (*Mean Average Precision*) resolve isso: avalia o modelo em **vários limiares** (cada limiar deve gerar uma matriz de confusão diferente) e resume o desempenho pela **área sob a curva Precisão-Sensibilidade (P-S)**.

Enquanto o *F1-Score* olha para um único ponto de equilíbrio, o mAP considera a curva inteira. Quanto mais próximo de **1,0**, melhor o detector em todos os limiares e classes (ex.: moedas de 25, 50 e 1 real).

| Métrica         | O que resume                             | Limitação                     |
|-----------------|------------------------------------------|-------------------------------|
| <b>F1-Score</b> | Equilíbrio $P \times S$ num único limiar | Depende do limiar escolhido   |
| <b>AP</b>       | Área sob a curva P-S de uma classe       | Válida apenas para uma classe |
| <b>mAP</b>      | Média das APs sobre todas as classes     | Mais complexo de implementar  |

Referências: [Roboflow — mAP](#) · [Vídeo explicativo](#)

### 1.16.3.2 Como o mAP é calculado — passo a passo

1. **Limiares fixos** (use sempre esta lista):

```
limiares = [0.00, 0.09, 0.21, 0.31, 0.39, 0.52, 0.60, 0.71, 0.81, 0.89, 1.00]
```

2. Para cada limiar ( $t$ ), classifique as amostras: **predito = 1 se confiança  $\geq t$ , senão 0**. Calcule VP, FP, FN, VN e obtenha  $Precis\tilde{a}o(t)$  e  $Sensibilidade(t)$ .
3. Monte a curva P-S: pares ( $Sensibilidade(t)$ ,  $Precis\tilde{a}o(t)$ ), ordenados por Sensibilidade crescente.
4. **Monotonize a Precisão:**

$$P_{mono}[i] = \max_{j \geq i} P[j]$$

5. Calcule a **AP** (área sob a curva monotônica) usando a **regra do trapézio** (aproximação mais precisa que a simples soma de Riemann):

$$AP = \sum_{i=1}^{m-1} \frac{P_{mono}[i-1] + P_{mono}[i]}{2} \cdot (S[i] - S[i-1])$$

6. **mAP** = média das APs de todas as classes. Neste EP há apenas **1 classe**, portanto  $mAP = AP$ .

#### Note

#### Diferença resumida:

A *soma de Riemann* aproxima a área por retângulos, podendo subestimar ou superestimar. A **regra do trapézio** usa trapézios, reduzindo o erro ao considerar a média entre os valores nos extremos do intervalo, sendo geralmente mais precisa para funções suaves por partes, como a curva Precisão-Sensibilidade.

### 1.16.3.3 📋 Tarefa

Leia um inteiro  $n$  (quantidade de amostras). Em seguida leia  $n$  linhas, cada uma com: **verdade** (0 ou 1) e **confiança** (float 0.0–1.0).

Calcule e imprima, para o **limiar 0.85** (índice 9 da lista):

- Matriz de Confusão (VP, FN, FP, VN)
- Acurácia, Precisão, Sensibilidade e F1-Score



Em seguida, para **todos os limiares**, imprima:

- Precisões cruas, Precisões monotônicas e Sensibilidades, separadas por ,
- mAP final

#### 1.16.3.4 Importante

- Limiar fixo para as métricas individuais: **0.85**
- Divisão segura: se denominador for zero, use 0
- Formatação: duas casas decimais
- Monotonize de trás para frente
- A Figure 1.14 apresenta uma simulação desta questão

#### 1.16.3.5 Exemplo de Execução

| Entrada | Saída Esperada                                                                   |
|---------|----------------------------------------------------------------------------------|
| 7       | # MÉTRICAS PARA O LIMIAR 0.85 #                                                  |
| 0 0.94  | Matriz de Confusão:                                                              |
| 1 0.80  | VP = 0, FN = 5                                                                   |
| 1 0.69  | FP = 1, VN = 1                                                                   |
| 0 0.67  |                                                                                  |
| 1 0.30  | Métricas de Avaliação:                                                           |
| 1 0.15  | Acurácia: 0.14                                                                   |
| 1 0.15  | Precisão: 0.00                                                                   |
|         | Sensibilidade: 0.00                                                              |
|         | F1-Score: 0.00                                                                   |
|         | # MÉTRICAS PARA TODOS OS LIMIARES #                                              |
|         | Precisões: 0.00, 0.00, 0.00, 0.50, 0.50, 0.50, 0.50, 0.50, 0.60, 0.71, 0.71      |
|         | Precisões mon.: 0.71, 0.71, 0.71, 0.71, 0.71, 0.71, 0.71, 0.71, 0.71, 0.71, 0.71 |
|         | Sensibilidades: 0.00, 0.00, 0.00, 0.20, 0.40, 0.40, 0.40, 0.40, 0.60, 1.00, 1.00 |
|         | mAP: 0.71                                                                        |

#### 1.16.3.6 Dica para calcular o AP (com regra do trapézio)

```
def calcular_AP(verdades, confiancas, limiares):
    m = len(limiares)
    precisoes = [0.0] * m
    sensibilidades = [0.0] * m
    for i in range(m):
        p, s = calcular_metricas(verdades, confiancas, limiares[i])
        precisoes[m-1-i] = p
        sensibilidades[m-1-i] = s
    prec_mono = precisoes.copy()
    for i in range(m-2, -1, -1):
        if prec_mono[i] < prec_mono[i+1]:
            prec_mono[i] = prec_mono[i+1]
    AP = 0.0
    for i in range(1, m):
        # Regra do trapézio: média das alturas vezes a base
        area_trapezio = (prec_mono[i-1] + prec_mono[i]) / 2.0
        AP += area_trapezio * (sensibilidades[i] - sensibilidades[i-1])
```

```
return precisoes, prec_mono, sensibilidades, AP
```

### Simulador: Curva P-S e mAP

Edite as amostras (verdade e confiança) e veja a curva Precisão-Sensibilidade e o mAP calculados em tempo real.




Figura 1.14: Simulador: *Mean Average Precision* (mAP) - Curva P.S

```
%%writefile EP01_03.py
# sua solução
```

```
Writing EP01_03.py
```

```
TestSuite("EP01_03.py").run()
```

### 1.16.4 EP01\_04 Leitura e Informações de uma Imagem em Matriz

Nesta atividade, você deve escrever um programa que processe uma imagem digital representada como uma matriz de pixels em tons de cinza.

- Leia dois inteiros **L** e **C**, representando o número de linhas e colunas.
- Leia os **L \* C** valores inteiros que compõem a matriz da imagem (cada valor entre 0 e 255).
- Calcule e imprima as seguintes informações:
  1. O número de linhas.
  2. O número de colunas.
  3. O valor do maior pixel (**Máximo**).
  4. O valor do menor pixel (**Mínimo**).
  5. A **Média** aritmética de todos os pixels.

#### Importante:

- A saída deve seguir exatamente o formato rotulado (ex: **Linhas: X**).
- O valor da média deve ser formatado com **duas casas decimais**.
- Ver um simulador interativo para esta questão na **Figure 1.15** (grade interativa para visualização de intensidades e cálculos em tempo real).

#### 1.16.4.1 Por que isso importa? – A Imagem como Dados

Toda imagem digital é, no fundo, uma estrutura de dados. Em tons de cinza de 8 bits, cada pixel é um valor escalar. Extrair estatísticas básicas é o primeiro passo para:

| Operação             | Utilidade Prática                                                      |
|----------------------|------------------------------------------------------------------------|
| <b>Máximo/Mínimo</b> | Identificar se a imagem está “lavada” (baixo contraste) ou saturada.   |
| <b>Média</b>         | Calcular o brilho global da cena para ajustes de exposição.            |
| <b>Normalização</b>  | Redimensionar os valores para intervalos como [0, 1] em redes neurais. |

#### 1.16.4.2 Tarefa (especificação para VPL)

##### Entrada:

A primeira linha contém o inteiro L (linhas).

A segunda linha contém o inteiro C (colunas).

As linhas seguintes contêm os elementos da matriz.

##### Saída:

Cinco linhas formatadas conforme o exemplo:

Linhas: L

Colunas: C

Max: V

Min: V

Media: V.VV

### 1.16.4.3 📌 Exemplos

| Entrada    | Saída         | Observação                       |
|------------|---------------|----------------------------------|
| 2          | Linhas: 2     | Imagem pequena de alto contraste |
| 3          | Colunas: 3    |                                  |
| 0 128 255  | Max: 255      |                                  |
| 50 100 200 | Min: 0        |                                  |
|            | Media: 122.17 |                                  |




Figura 1.15: Simulador: Estatísticas de Pixels

```
%%writefile EP01_04.py
# sua solução
```

Writing EP01\_04.py

```
TestSuite("EP01_04.py").run()
```

### 1.16.5 EP01\_05 ↺ Negativo de uma Imagem em Tons de Cinza

Nesta atividade, deve-se escrever um programa que calcule o negativo de uma imagem digital.

- Leia dois inteiros **L** e **C**, representando o número de linhas e colunas.
- Leia os valores inteiros que compõem a matriz da imagem.
- Para cada pixel, aplique a transformação de inversão:

$$pixel_{negativo} = 255 - pixel_{original}$$

- Imprima a matriz resultante, mantendo o formato original (L linhas e C colunas).

 **Importante:**

- Os valores de cada linha na saída devem ser separados por um **espaço em branco**.
- A saída deve conter **apenas os números** da matriz resultante.
- Ver um simulador interativo para esta questão na **Figure 1.16** (comparação em tempo real entre a matriz original e seu negativo).

**1.16.5.1  Por que isso importa? – Inversão de Intensidade**

O **negativo** é uma transformação linear básica que inverte a escala de brilho. É uma ferramenta essencial para o olho humano identificar detalhes claros que estão “escondidos” em fundos mais escuros, sendo amplamente utilizada em:

| Aplicação              | Utilidade                                                            |
|------------------------|----------------------------------------------------------------------|
| <b>Imagens Médicas</b> | Melhora a visualização de anomalias em tecidos densos (ex: Raios-X). |
| <b>Astronomia</b>      | Destacar galáxias e nebulosas tênues contra o vazio do espaço.       |
| <b>Artes Digitais</b>  | Efeitos estéticos e preparação de máscaras de seleção.               |

**1.16.5.2  Tarefa (especificação para VPL)****Entrada:**

A primeira linha contém o inteiro **L**.

A segunda linha contém o inteiro **C**.

As linhas seguintes contêm os elementos da matriz.

**Saída:**

A matriz invertida com **L** linhas e **C** colunas.

**1.16.5.3  Exemplos**

| Entrada    | Saída      | Observação                           |
|------------|------------|--------------------------------------|
| 2          | 255 127 0  | Onde era 0 (preto) vira 255 (branco) |
| 3          | 205 155 55 |                                      |
| 0 128 255  |            |                                      |
| 50 100 255 |            |                                      |

```
%%writefile EP01_05.py
# sua solução
```

```
Writing EP01_05.py
```

```
TestSuite("EP01_05.py").run()
```




Figura 1.16: Simulador: Transformação de Negativo

### 1.16.6 EP01\_06 🧠 Conversão RGB → Tons de Cinza (ITU-R BT.601)

Nesta atividade, você deve escrever um programa que converta pixels coloridos (RGB) para tons de cinza utilizando a ponderação fisiológica do padrão ITU-R BT.601.

- Leia dois inteiros **L** e **C**, representando o número de linhas e colunas.
- Leia  $L \times C$  triplas de inteiros, onde cada tripla representa os canais **R** (Red), **G** (Green) e **B** (Blue) de um pixel.
- Para cada pixel, calcule o valor de cinza ( $g$ ) usando a fórmula:

$$g = \text{round}(0.299 \times R + 0.587 \times G + 0.114 \times B)$$

- Imprima a matriz resultante (L linhas e C colunas) contendo os valores inteiros convertidos.

#### 📌 Importante:

- Utilize a função `round()` da sua linguagem para garantir o arredondamento correto para o inteiro mais próximo.
- A saída deve conter apenas os valores de cinza, mantendo a estrutura de matriz (separados por espaço na linha).
- Ver um simulador interativo para esta questão na **Figure 1.17** (ajuste os sliders para ver como cada cor contribui para o brilho final).

#### 1.16.6.1 🧠 Por que não usar apenas a média?

O olho humano não percebe todas as cores com a mesma intensidade. Somos muito mais sensíveis ao **Verde** do que ao **Azul** devido à nossa evolução biológica. O padrão ITU-R BT.601 utiliza pesos específicos para criar uma imagem em cinza que pareça naturalmente correta para nossa visão:



| Canal                                       | Peso  | Percepção Humana                               |
|---------------------------------------------|-------|------------------------------------------------|
| <span style="color: green;">●</span> Verde  | 58.7% | Máxima sensibilidade (distinção de folhagens). |
| <span style="color: red;">●</span> Vermelho | 29.9% | Sensibilidade média.                           |
| <span style="color: blue;">●</span> Azul    | 11.4% | Baixa sensibilidade (tons mais escuros).       |

### 1.16.6.2 Tarefa (especificação para VPL)

#### Entrada:

A primeira linha contém o inteiro L.

A segunda linha contém o inteiro C.

As linhas seguintes contêm triplas de inteiros R G B para cada pixel.

#### Saída:

A matriz de cinzas com L linhas e C colunas.

### 1.16.6.3 Exemplos

| Entrada                           | Saída     | Observação                                               |
|-----------------------------------|-----------|----------------------------------------------------------|
| 1<br>3<br>255 0 0 0 255 0 0 0 255 | 76 150 29 | Note como o Verde (150) é mais brilhante que o Azul (29) |

 Simulador: Percepção de Cor
 ITU-R BT.601

Observe o peso de cada canal colorido no brilho final da imagem.

AJUSTE DOS CANAIS

R

80

G

180

B

30

$0.299 \times 80 = 23.9$   
 $0.587 \times 180 = 105.7$   
 $0.114 \times 30 = 3.4$   
 Soma: 133.0 → 133

Original

Cinza

133

Dica: O Verde tem o maior peso (0.587) porque nossos olhos distinguem melhor tons de folhagens!

Figura 1.17: Simulador: Percepção de Cor e Pesos ITU-R

```
%%writefile EP01_06.py
# sua solução
```

```
Writing EP01_06.py
```

```
TestSuite("EP01_06.py").run()
```

### 1.16.7 EP01\_07 ● Limiarização Manual: Imagem Binária

Nesta atividade, você deve escrever um programa que realize a segmentação de uma imagem através da limiarização (*thresholding*).

- Leia dois inteiros **L** e **C**, representando as dimensões da matriz.
- Leia um inteiro **T**, que será o valor do limiar (corte).
- Leia os valores inteiros da matriz.
- Para cada pixel  $p$ , aplique a seguinte regra de binarização:

$$\text{resultado} = \begin{cases} 255 & \text{se } p > T \\ 0 & \text{se } p \leq T \end{cases}$$

- Imprima a matriz resultante contendo apenas os valores 0 ou 255.

#### 📌 Importante:

- Preste atenção ao operador: o pixel só vira branco (255) se for **estritamente maior** que  $T$ .
- A saída deve manter a estrutura de matriz (L linhas e C colunas).
- Ver um simulador interativo para esta questão na **Figure 1.18** (ajuste o slider de  $T$  para observar como os objetos são isolados do fundo).

#### 1.16.7.1 🧠 O que é Segmentação?

A limiarização é o método mais simples de separar objetos de interesse do fundo da imagem. Ao transformar tons de cinza em preto e branco puro, criamos um mapa binário que facilita a contagem de objetos ou a identificação de formas:

| Valor do Pixel ( $p$ ) | Condição        | Resultado Final     |
|------------------------|-----------------|---------------------|
| Escuro ( $p \leq T$ )  | Fundo/Ruído     | <b>0</b> (Preto)    |
| Claro ( $p > T$ )      | Objeto/Destaque | <b>255</b> (Branco) |

#### 1.16.7.2 📋 Tarefa (especificação para VPL)

##### Entrada:

A primeira linha contém o inteiro L.

A segunda linha contém o inteiro C.

A terceira linha contém o inteiro T (limiar).

As linhas seguintes contêm os elementos da matriz.

##### Saída:

A matriz binarizada (0 ou 255) com L linhas e C colunas.

### 1.16.7.3 📌 Exemplos

| Entrada       | Saída       | Observação                                          |
|---------------|-------------|-----------------------------------------------------|
| 2             | 0 0 0 255   | Note que o valor 128 virou 0 (pois $128 \leq 128$ ) |
| 4             | 0 255 255 0 |                                                     |
| 128           |             |                                                     |
| 0 100 128 200 |             |                                                     |
| 50 129 255 64 |             |                                                     |




Figura 1.18: Simulador: Limiarização Interativa

```
%%writefile EP01_07.py
# sua solução
```

Writing EP01\_07.py

```
TestSuite("EP01_07.py").run()
```

### 1.16.8 EP01\_08 🧠 Remapeamento por Faixa de Intensidade

Nesta atividade, você deve escrever um programa que aplique transformações lineares distintas a diferentes regiões de intensidade da imagem.

- Leia dois inteiros **L** e **C**, representando as dimensões da matriz.
- Leia os inteiros **T** (limiar),  $\Delta 1$  e  $\Delta 2$ .
- Leia os valores inteiros da matriz.
- Para cada pixel  $p$ , aplique a regra de remapeamento condicional:

$$\text{resultado} = \begin{cases} p + \delta_1 & \text{se } p < T \\ p + \delta_2 & \text{se } p \geq T \end{cases}$$

- Imprima a matriz resultante com os novos valores de intensidade.

#### Importante:

- $\delta_1$  é o offset aplicado aos pixels escuros (abaixo do limiar).
- $\delta_2$  é o offset aplicado aos pixels claros (maior ou igual ao limiar).
- Os casos de teste garantem que o resultado estará sempre no intervalo válido de **0 a 255**, portanto, não é necessário tratar saturação ou arredondamentos.
- A saída deve manter a estrutura de matriz (**L** linhas e **C** colunas).

#### 1.16.8.1 Transformação Condicional de Pixels

Em Processamento Digital de Imagens (PDI), frequentemente precisamos tratar regiões de forma independente. Esta técnica permite, por exemplo, clarear apenas as sombras de uma fotografia (aumentando os pixels escuros) sem estourar o brilho das áreas já claras, ou vice-versa.

| Faixa de Intensidade | Condição   | Operação       |
|----------------------|------------|----------------|
| Pixels Escuros       | $p < T$    | $p + \delta_1$ |
| Pixels Claros        | $p \geq T$ | $p + \delta_2$ |

#### 1.16.8.2 Tarefa (especificação para VPL)

##### Entrada:

A primeira linha contém os inteiros L e C.

A segunda linha contém os inteiros T,  $\delta_1$  e  $\delta_2$ .

As linhas seguintes contêm os elementos da matriz.

##### Saída:

A matriz transformada com L linhas e C colunas, com valores separados por espaço.

#### 1.16.8.3 Exemplos

| Entrada                                             | Saída                           | Observação                                     |
|-----------------------------------------------------|---------------------------------|------------------------------------------------|
| 2 4<br>128 60 -40<br>0 100 150 255<br>80 128 200 30 | 60 160 110 215<br>140 88 160 90 | Pixels < 128 somam 60. Pixels 128 subtraem 40. |

```
%%writefile EP01_08.py
# sua solução
```

Writing EP01\_08.py




Figura 1.19: Simulador: Ajuste de Brilho e Contraste

```
TestSuite("EP01_08.py").run()
```

### 1.16.9 EP01\_09 Padrão de Tabuleiro: Matriz de Xadrez

Nesta atividade, você deve escrever um programa que gere uma imagem sintética no padrão de um tabuleiro de xadrez.

- Leia dois inteiros **L** (linhas) e **C** (colunas).
- Gere uma matriz onde os valores alternam entre **0** (preto) e **1** (branco).
- A lógica de preenchimento deve seguir a regra da paridade:
- O elemento na posição  $(0, 0)$  é sempre **0**.
- Um pixel na posição  $(i, j)$  será **1** se a soma dos índices  $(i + j)$  for **ímpar**.
- Um pixel na posição  $(i, j)$  será **0** se a soma dos índices  $(i + j)$  for **par**.

#### Importante:

- As cores devem alternar corretamente tanto horizontalmente quanto verticalmente.
- A saída deve ser a matriz impressa linha por linha, com os elementos separados por um espaço.
- Ver um simulador interativo para esta questão na **Figure 1.20** (ajuste as dimensões para visualizar a construção da malha e a saída textual correspondente).

#### 1.16.9.1 Padrões Sintéticos

Criar padrões geométricos é um exercício fundamental para dominar a **lógica de índices** em matrizes. Em Processamento Digital de Imagens, o padrão de xadrez não é apenas estético; ele é amplamente utilizado para:

| Aplicação                    | Utilidade                                                                                |
|------------------------------|------------------------------------------------------------------------------------------|
| <b>Calibração de Câmera</b>  | Estimar parâmetros intrínsecos e extrínsecos da lente.                                   |
| <b>Correção de Distorção</b> | Identificar e corrigir o efeito de “barril” ou “almofada” em lentes grande-angulares.    |
| <b>Mapeamento 3D</b>         | Projetar padrões conhecidos para reconstruir superfícies em sistemas de luz estruturada. |

#### 1.16.9.2 Tarefa (especificação para VPL)

##### Entrada:

Uma linha contendo o inteiro **L** (linhas).

Uma linha contendo o inteiro **C** (colunas).

##### Saída:

A matriz de xadrez com **L** linhas e **C** colunas, impressa com espaços entre os elementos.

#### 1.16.9.3 Exemplos



| Entrada | Saída   | Observação                                           |
|---------|---------|------------------------------------------------------|
| 3       | 0 1 0 1 | Note que cada linha começa com o inverso da anterior |
| 4       | 1 0 1 0 |                                                      |
|         | 0 1 0 1 |                                                      |

Lógica de Paridade

Altere as dimensões para ver como a lógica de índices constrói o tabuleiro.

Linhas (L)

5

×

Colunas (C)

6

|   |   |   |   |   |   |
|---|---|---|---|---|---|
| 0 | 1 | 0 | 1 | 0 | 1 |
| 1 | 0 | 1 | 0 | 1 | 0 |
| 0 | 1 | 0 | 1 | 0 | 1 |
| 1 | 0 | 1 | 0 | 1 | 0 |
| 0 | 1 | 0 | 1 | 0 | 1 |

SAÍDA ESPERADA:

```

0 1 0 1 0 1
1 0 1 0 1 0
0 1 0 1 0 1
1 0 1 0 1 0
0 1 0 1 0 1

```

Figura 1.20: Simulador: Gerador de Xadrez

```
%%writefile EP01_09.py
# sua solução
```

Writing EP01\_09.py

```
TestSuite("EP01_09.py").run()
```

### 1.16.10 EP01\_10 Metadados: Leitura de Arquivo PGM

Nesta atividade, você deve ler um arquivo de imagem no formato **PGM (Portable Gray Map)** e extrair suas dimensões a partir do cabeçalho.

- O formato **PGM (P2)** é um arquivo de texto simples (ASCII) que armazena imagens em tons de cinza.
- O arquivo possui um **cabeçalho** estruturado da seguinte forma:
  - Versão:** O identificador P2.
  - Comentários:** Linhas opcionais que começam com # (devem ser ignoradas).
  - Dimensões:** Dois inteiros representando **Largura** e **Altura**.

4. **Máximo:** Um inteiro representando a intensidade máxima (geralmente 255).

- Após o cabeçalho, seguem-se os dados dos pixels.

#### **Importante:**

- **Leitura de Arquivo:** Você deve abrir o arquivo indicado no exemplo utilizando a função `open()` do Python.
- **Ordem de Saída:** Ao contrário da ordem presente no arquivo, a saída esperada deve estar no formato de tupla: (Altura, Largura, Canais).
- Como arquivos PGM são em tons de cinza, o número de **Canais** é sempre **1**.
- Ver um simulador interativo para esta questão na **Figure 1.21** (ajuste as dimensões para ver como o cabeçalho ASCII é gerado).

#### 1.16.10.1 Entendendo o formato PGM

O formato PGM é um dos mais simples para processamento de imagens. Por ser em texto puro, ele permite visualizar os metadados e até os valores dos pixels abrindo o arquivo em um bloco de notas:

| Componente          | Exemplo      | Significado                                                |
|---------------------|--------------|------------------------------------------------------------|
| <b>Magic Number</b> | P2           | Identifica que é um PGM em formato de texto (ASCII).       |
| <b>Comentário</b>   | # CREATOR... | Linha informativa ignorada pelo processador.               |
| <b>Dimensões</b>    | 397 343      | <b>397</b> colunas (Largura) e <b>343</b> linhas (Altura). |
| <b>Intensidade</b>  | 255          | Define o valor do branco puro (escala de 0 a 255).         |

#### 1.16.10.2 Tarefa (especificação para VPL)

##### **Entrada:**

Nenhuma entrada via teclado. O programa deve ler o arquivo "aula01fig03b.pgm" presente no diretório de execução.

##### **Saída:**

Uma tupla contendo (Altura, Largura, 1).

#### 1.16.10.3 Exemplos

| Nome do Arquivo    | Saída Esperada | Observação                                |
|--------------------|----------------|-------------------------------------------|
| "aula01fig03b.pgm" | (343, 397, 1)  | Note a inversão da ordem: Altura primeiro |

#### Nota

O arquivo necessário para este EP será baixado automaticamente do repositório por meio do seguinte código:



Figura 1.21: Simulador: Estrutura do Arquivo PGM

```
import os, urllib.request

BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/all/cap01/imagens"
file = "aula01fig03b.pgm"

opener = urllib.request.build_opener()
opener.addheaders = [('User-agent', 'Mozilla/5.0')]
urllib.request.install_opener(opener)

for f in [file]:
    if not os.path.exists(f):
        url = f"{BASE_URL}/{f}"
        try:
            urllib.request.urlretrieve(url, f)
            print(f" Arquivo baixado: {f}")
        except urllib.error.HTTPError as e:
            print(f" Erro {e.code}: Não encontrado em {url}")
```

```
%%writefile EP01_10.py
# sua solução
```

Writing EP01\_10.py

```
TestSuite("EP01_10.py").run()
```

### 1.16.11 EP01\_11 ↗ Análise de Vizinhança: Filtro de Máximo 1D

Nesta atividade, você deve implementar um filtro morfológico simples de máximo operando em um sinal unidimensional (vetor).

- Leia um inteiro **n**, representando o tamanho do vetor.
- Leia os **n** elementos inteiros que compõem o vetor original **v1**.
- Crie um novo vetor **v2**, onde cada posição *i* é o resultado da comparação entre o elemento atual e seus vizinhos imediatos:

$$v2[i] = \max(v1[i - 1], v1[i], v1[i + 1])$$

### Importante:

- **Bordas:** Nas extremidades do vetor (índices 0 e  $n - 1$ ), a vizinhança possui apenas dois elementos (o próprio e o único vizinho disponível). No índice 0, compare apenas  $v1[0]$  e  $v1[1]$ . No último índice, compare apenas  $v1[n - 2]$  e  $v1[n - 1]$ .
- **Saída:** Imprima o cabeçalho “v2:” seguido pelos valores do vetor resultante, um por linha.
- Ver um simulador interativo para esta questão na **Figure 1.22** (passe o mouse sobre os resultados para visualizar a janela de vizinhança utilizada no cálculo).

#### 1.16.11.1 Por que analisar vizinhos?

Em processamento de imagens, o valor de um pixel raramente é isolado; ele depende do contexto ao seu redor. O **Filtro de Máximo** é a base da operação de **Dilatação** em morfologia matemática, servindo para:

| Função                  | Efeito Visual                                                     |
|-------------------------|-------------------------------------------------------------------|
| <b>Realce</b>           | Expande estruturas brilhantes e “engorda” objetos claros.         |
| <b>Remoção de Ruído</b> | Elimina pequenos pontos pretos (ruído de “sal e pimenta” escuro). |
| <b>Preenchimento</b>    | Fecha pequenos buracos ou lacunas em formas binárias.             |

#### 1.16.11.2 Tarefa (especificação para VPL)

##### Entrada:

Um inteiro  $n$ .

Nas linhas seguintes, os  $n$  elementos inteiros do vetor.

##### Saída:

A *string* `v2`: na primeira linha.

Nas linhas seguintes, cada elemento de `v2` (um por linha).

#### 1.16.11.3 Exemplos

| Entrada | Saída | Observação                          |
|---------|-------|-------------------------------------|
| 5       | v2:   | No índice 1: $\max(10, 20, 5) = 20$ |
| 10      | 20    |                                     |
| 20      | 20    |                                     |
| 5       | 30    |                                     |
| 30      | 30    |                                     |
| 15      | 30    |                                     |



Figura 1.22: Simulador: Filtro de Máximo Local 1D

```
%%writefile EP01_11.py  
# sua solução
```

```
Writing EP01_11.py
```

```
TestSuite("EP01_11.py").run()
```

## Capítulo 2

# Da Captura ao Pixel - Amostragem, Quantização e Conectividade



Este capítulo aprofunda a compreensão da imagem digital, transitando da natureza física da captura para a sua representação matemática discreta. Investigamos como a luz se torna dado e como a organização espacial dos pixels define as relações de vizinhança e conectividade essenciais para algoritmos avançados de Visão Computacional (VC).

## 2.1 Objetivos

Ao final deste capítulo, você será capaz de:

- Explicar o modelo físico de formação da imagem baseado em iluminação e refletância.
- Diferenciar os mecanismos da visão humana e dos sensores digitais.
- Compreender os processos de **amostragem** (discretização do espaço) e **quantização** (discretização da intensidade).
- Descrever as relações topológicas entre pixels: vizinhança, adjacência, conectividade e distâncias.
- Realizar transformações geométricas básicas (translação, rotação, escala) preservando a qualidade.
- Visualizar na prática os efeitos da variação da resolução espacial e da profundidade de bits.

## 2.2 O Olho e a Câmera - Elementos da Percepção Visual

A formação de uma imagem digital começa com a captura da luz refletida pelos objetos. Como ilustrado na Figure 2.1, tanto o olho humano quanto as câmeras digitais seguem princípios ópticos semelhantes para focar a luz em uma superfície sensível, embora utilizem mecanismos biológicos e eletrônicos distintos para a transdução do sinal.

### 2.2.1 Visão humana

O olho funciona como um sistema óptico complexo: a luz atravessa a córnea, o humor aquoso, a pupila (controlada pela íris) e o cristalino — que ajusta o foco dinamicamente — até atingir a retina. Na retina, encontram-se os fotorreceptores: os **cones** ( 6 milhões), concentrados na fóvea, são responsáveis pela visão de cores e detalhes, enquanto os **bastonetes** ( 120 milhões) garantem a visão em baixa luminosidade (visão escotópica), detectando apenas intensidades de cinza. O ponto cego é a região de onde parte o nervo óptico, carecendo de receptores.

### 2.2.2 Sensores digitais

Nas câmeras, os sensores de imagem desempenham o papel da retina. Os dois tipos mais comuns são o **CCD** (*Charge-Coupled Device* - Dispositivo de Carga Acoplada) e o **CMOS** (*Complementary Metal-Oxide-Semiconductor* - Semicondutor de Óxido Metálico Complementar). O sensor é composto por uma matriz de fotossítios (pixels) que acumulam carga elétrica proporcional à luz incidente.



Para a reconstrução de cores, utiliza-se o **Filtro de Bayer**, uma matriz de filtros coloridos que permite que cada pixel capture apenas uma componente de cor: vermelho, verde ou azul (RGGB - *Red, Green, Green, Blue*). Posteriormente, um **ADC** (*Analog-to-Digital Converter* - Conversor Analógico-Digital) quantiza essa carga em valores numéricos, definidos por uma profundidade de bits (ex.: 8 bits, resultando em 256 níveis de intensidade).

### i Curiosidade

Embora o olho humano tenha milhões de receptores, a resolução de alta definição é restrita à fóvea (visão central), equivalente a aproximadamente  $120 \times 120$  pixels. A percepção de uma cena completa em alta resolução é resultado de intenso pós-processamento realizado pelo cérebro.

## O Olho e a Câmera - Elementos da Percepção Visual




Figura 2.1: Comparativo didático entre o sistema visual biológico e o eletrônico: no topo, a anatomia do olho humano destacando a retina e os fotorreceptores (cones e bastonetes); abaixo, a estrutura de uma câmera digital detalhando o sensor CMOS, a matriz de filtros de Bayer (RGGB) e o processo de quantização digital realizado pelo ADC.

## 2.3 Ilusões de Ótica: Os Desafios da Percepção Visual

Enquanto os sensores digitais capturam a intensidade da luz de forma linear e objetiva, o sistema visual humano interpreta a cena com base em contexto, experiências prévias e mecanismos biológicos de sobrevivência. As ilusões de ótica não são “erros” do olho, mas evidências do intenso **pós-processamento cerebral** realizado no córtex visual.

### 2.3.1 Ambiguidade e Contexto

O cérebro busca constantemente dar sentido a padrões ambíguos. No exemplo do **Vaso de Rubin** (veja a Figure 2.2), a percepção alterna entre a figura (vaso) e o fundo (dois rostos), demonstrando que não conseguimos processar ambas as interpretações simultaneamente. Já a ilusão do **Elefante de Shepard** brinca com a nossa incapacidade de reconciliar linhas de contorno que sugerem volume em posições logicamente impossíveis.

### 2.3.2 Brilho e Contraste Local

Muitas ilusões decorrem da **inibição lateral**, mecanismo pelo qual neurônios vizinhos na retina competem entre si para realçar bordas. Na **Grade de Scintillating**, pontos escuros “fantasmas” parecem surgir nas interseções brancas devido a esse processamento local de contraste.

A ilusão da **Sombra no Tabuleiro de Adelson** é talvez a mais impactante para a VC: o quadrado “A” e o quadrado “B” possuem exatamente o mesmo valor de cinza no sensor (ou arquivo digital), mas o cérebro “corrige” o brilho de “B” por entender que ele está sob uma sombra projetada, percebendo-o como mais claro.

### 2.3.3 Geometria e Perspectiva

A percepção de profundidade pode ser enganada por construções geométricas que desafiam a lógica tridimensional a partir de um ângulo de visão específico. A **Escada de Schröder** utiliza a ambiguidade da perspectiva para criar um objeto que parece subir ou descer dependendo de como é observado, evidenciando como a nossa interpretação de “cima” e “baixo” depende do ponto de fuga.

## Ilusões de Ótica: Os Desafios da Percepção Visual




Figura 2.2: Coletânea de desafios perceptivos: (topo esquerdo) Vaso de Rubin — ambiguidade figura-fundo; (topo central) Elefante de Shepard — incongruência geométrica; (topo direita) Sombra de Adelson — constância de brilho baseada no contexto; (inferior esquerdo) Grade de pontos — inibição lateral; (inferior direito) Escada de Schröder.

## 2.4 O Modelo Matemático da Formação da Imagem

Uma imagem pode ser modelada como o produto de duas funções:

$$f(x, y) = i(x, y) \cdot r(x, y) \quad (2.1)$$

onde:

- $i(x, y)$  é a **iluminação** incidente sobre a cena (energia luminosa por unidade de área), determinada pela fonte de luz;

- $r(x, y)$  é a **refletância** do objeto (fração da luz refletida), determinada pelas propriedades ópticas da superfície, com  $0 < r(x, y) < 1$ .

Na prática, as duas componentes variam em escalas espaciais distintas:  $i(x, y)$  tende a variar lentamente no espaço, enquanto  $r(x, y)$  pode apresentar variações abruptas associadas a texturas, bordas e detalhes finos. Técnicas de PDI frequentemente procuram separar ou compensar essas componentes, como em métodos de correção de iluminação não uniforme.

A Figure 2.3 ilustra como esse modelo se manifesta em imagens digitais coloridas, representadas por múltiplos canais espectrais (RGB) e, opcionalmente, por um canal adicional de transparência (RGBA).

### 2.4.1 Representação Digital e Canais Espectrais

Em imagens digitais coloridas, a função  $f(x, y)$  da Equation 2.1 é representada por múltiplos canais espectrais. No padrão **RGB**, cada pixel armazena três amostras independentes:

$$\mathbf{f}(x, y) = [R(x, y), G(x, y), B(x, y)]$$

correspondentes às intensidades das componentes vermelha (*Red*), verde (*Green*) e azul (*Blue*). Em imagens do tipo **RGBA**, adiciona-se um quarto canal:

$$\mathbf{f}(x, y) = [R(x, y), G(x, y), B(x, y), A(x, y)]$$

onde  $A(x, y)$  representa o canal **alfa** (*Alpha*), responsável por codificar a opacidade do pixel. Por convenção, o valor  $A = 0$  indica um pixel totalmente transparente, enquanto  $A = 255$  (ou 1) representa um pixel totalmente opaco.

Assim, uma imagem digital colorida é estruturada como uma matriz multidimensional de dimensões:

- **RGB:**  $M \times N \times 3$
- **RGBA:**  $M \times N \times 4$

em que cada posição  $(x, y)$  armazena as amostras associadas às propriedades ópticas daquela coordenada espacial.

**Convenção de escala entre bibliotecas:** Diferentes ecossistemas de programação adotam faixas de valores e ordenações distintas para representar os canais digitais, conforme sintetizado na Table 2.1.

Tabela 2.1: Convenções de escala e ordem de canais nas principais bibliotecas de PDI.

| Biblioteca       | Tipo padrão   | Faixa de valores   | Ordem das bandas | Forma do array/tensor |
|------------------|---------------|--------------------|------------------|-----------------------|
| OpenCV           | uint8         | [0, 255]           | <b>BGR</b>       | $H \times W \times C$ |
| Pillow           | uint8         | [0, 255]           | RGB              | $H \times W \times C$ |
| NumPy            | uint8/float32 | [0, 255] ou [0, 1] | —                | $H \times W \times C$ |
| scikit-image     | float64       | [0, 1]             | RGB              | $H \times W \times C$ |
| PyTorch          | float32       | [0, 1]             | RGB              | $C \times H \times W$ |
| TensorFlow/Keras | float32       | [0, 1]             | RGB              | $H \times W \times C$ |

A conversão entre essas faixas de intensidade é direta e dada por:

$$f_{\text{norm}}(x, y) = \frac{f(x, y)}{255}$$



onde  $f(x, y) \in [0, 255]$  e  $f_{\text{norm}}(x, y) \in [0, 1]$ .

Negligenciar essas discrepâncias é uma fonte frequente de erros em fluxos de trabalho de VC — como, por exemplo, injetar uma imagem lida via OpenCV (padrão BGR, tipo `uint8`) diretamente em um modelo profundo do PyTorch que pressupõe o formato RGB normalizado.

### 2.4.2 Preparando o Ambiente Prático

O bloco a seguir carrega o módulo `morph.py` do repositório e demonstra, para um pixel sintético, as diferentes convenções de escala e ordem de canais adotadas pelas principais bibliotecas de PDI.

```
import os, importlib, urllib.request
import numpy as np
import matplotlib.pyplot as plt

BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph"
for f in ["morph.py"]:
    if not os.path.exists(f):
        urllib.request.urlretrieve(f"{BASE_URL}/{f}", f)

import morph
importlib.reload(morph)
from morph import mm

version = getattr(morph, "__version__", "local_file")
print(f" Ambiente pronto. Módulo 'morph' carregado (versão: {version}).")

# Demonstração das convenções de escala
img_exemplo = np.array([[200, 100, 50]], dtype=np.uint8) # 1 pixel RGB

print("\n Convenções de escala por biblioteca ")
print(f" NumPy / Pillow / OpenCV (uint8): {img_exemplo[0,0]} → faixa [0, 255]")
print(f" scikit-image / PyTorch (float): {img_exemplo[0,0] / 255.0} → faixa [0.0, 1.0]")
print(f" OpenCV: atenção - lê em BGR: {img_exemplo[0,0,:-1]} (canais invertidos)")
```

Ambiente pronto. Módulo 'morph' carregado (versão: 1.1.5).

```
Convenções de escala por biblioteca
NumPy / Pillow / OpenCV (uint8): [200 100 50] → faixa [0, 255]
scikit-image / PyTorch (float): [0.78431373 0.39215686 0.19607843] → faixa [0.0, 1.0]
OpenCV: atenção - lê em BGR: [ 50 100 200] (canais invertidos)
```

### 2.4.3 Implementação da Leitura de Imagem em `morph.py`

O trecho a seguir exibe o código-fonte da função `mm.read`, permitindo verificar diretamente como a biblioteca `morph.py` implementa a leitura de imagens.

```
import inspect
print(inspect.getsource(mm.read))
```

```
@staticmethod
def read(file, pil=False, grayscale=False):
    """Lê imagem (local, URL ou Google Drive) → PIL.Image, ndarray 2D ou RGB 3D."""
    import re, requests
    from PIL import Image
    from io import BytesIO
    from urllib.request import urlopen, Request
    np = mm._get_np()

    # - fonte: URL / Google Drive -
```

```

if isinstance(file, str) and file.startswith(("http://", "https://", "id=")):
    m = re.search(r"id=(\[w-\]+\)", file) or re.search(r"/d/(\[w-\]+\)", file)
    url = f"https://drive.google.com/uc?export=view&id={m.group(1)}" \
        if m and ("id=" in file or "drive.google.com" in file) else file
    hdr = {"User-Agent": "Mozilla/5.0 AppleWebKit/537.36 Chrome/124 Safari/537.36"}
    try:
        r = requests.get(url, headers=hdr, timeout=20)
        if r.status_code == 429: raise requests.exceptions.HTTPError()
        r.raise_for_status()
        file = BytesIO(r.content)
    except:
        file = BytesIO(urlopen(Request(url, headers=hdr), timeout=20).read())

img = Image.open(file)
img.load()
if pil:
    return img
if grayscale:
    return np.array(img.convert("L")) # (H,W)
if img.mode == "L":
    return np.array(img) # (H,W)
if img.mode == "RGBA":
    # fundo branco
    bg = Image.new("RGB", img.size, (255, 255, 255))
    bg.paste(img, mask=img.split()[3])
    return np.array(bg)
return np.array(img.convert("RGB")) # (H,W,3)

```

#### 2.4.4 RGB e RGBA: Exemplo Prático com a Imagem Mandrill

O exemplo a seguir carrega a imagem Mandrill em formato RGB, constrói artificialmente um canal alfa com gradiente horizontal e exibe ambas as representações, ilustrando concretamente as estruturas matriciais  $M \times N \times 3$  e  $M \times N \times 4$ .

```

import os
import numpy as np

# https://commons.wikimedia.org/wiki/File:Mandrill-k-means.png
url = "https://upload.wikimedia.org/wikipedia/commons/a/ab/Mandrill-k-means.png"
caminho = "imagens/mandrill.png"

# Leitura RGB
if not os.path.exists(caminho):
    os.makedirs("imagens", exist_ok=True)
    img_pil = mm.read(url, pil=True)
    mm.write(img_pil, caminho)
else:
    img_pil = mm.read(caminho, pil=True)

img_rgb = np.array(img_pil.convert("RGB")) # shape: (M, N, 3), uint8

# Criação do canal alfa (gradiente horizontal)
h, w, _ = img_rgb.shape
alpha = np.tile(np.linspace(0, 255, w, dtype=np.uint8), (h, 1))
img_rgba = np.dstack([img_rgb, alpha]) # shape: (M, N, 4), uint8

# Diagnóstico
print(f"RGB → shape={img_rgb.shape}, dtype={img_rgb.dtype}, "
      f"faixa=[{img_rgb.min()}, {img_rgb.max()}]")
print(f"RGBA → shape={img_rgba.shape}, dtype={img_rgba.dtype}, "
      f"faixa=[{img_rgba.min()}, {img_rgba.max()}]")
print(f"Pixel (0,0): RGB={img_rgb[0,0]} | RGBA={img_rgba[0,0]}")

# Normalização float32 (padrão scikit-image / PyTorch)

```

```
img_rgb_norm = img_rgb.astype(np.float32) / 255.0
print(f"\nNormalizado (float32): faixa=[{img_rgb_norm.min():.2f}, {img_rgb_norm.max():.2f}]")
print(f"Pixel (0,0) normalizado: {img_rgb_norm[0,0]}")

# Visualização
mm.show(
    [img_rgb, img_rgba],
    title=["RGB - $M \\times N \\times 3$", "RGBA - $M \\times N \\times 4$"],
    cols=2, axis=True
)
```

```
RGB → shape=(512, 512, 3), dtype=uint8, faixa=[14, 248]
RGBA → shape=(512, 512, 4), dtype=uint8, faixa=[0, 255]
Pixel (0,0): RGB=[125 110 58] | RGBA=[125 110 58 0]
```

```
Normalizado (float32): faixa=[0.05, 0.97]
Pixel (0,0) normalizado: [0.49019608 0.43137255 0.22745098]
```




Figura 2.3: Imagem RGB (3 canais,  $M \times N \times 3$ ) e versão RGBA (4 canais,  $M \times N \times 4$ ) com transparência alfa gradual da esquerda para a direita. Imagem Mandrill — [USC SIPI Image Database](#) (domínio público).

## 2.5 Digitalização: Amostragem e Quantização

Para transformar uma cena contínua em uma imagem digital, dois processos são necessários: amostragem e quantização.

### 2.5.1 Amostragem - Discretização do espaço

A amostragem consiste em medir o valor da função  $f(x, y)$  em pontos igualmente espaçados, formando uma matriz de  $M$  linhas (altura) e  $N$  colunas (largura). Cada elemento dessa matriz é um **pixel**. A **resolução espacial** é dada por  $M \times N$ . Quanto maior a resolução, mais detalhes espaciais são preservados, mas maior também o custo computacional e de armazenamento.



### 2.5.2 Quantização - Discretização da intensidade

A quantização associa a cada pixel um valor numérico discreto, geralmente representado por um inteiro de  $b$  bits. A **profundidade de bits** define o número de níveis de intensidade:  $2^b$ . Imagens em tons de cinza costumam usar 8 bits (256 níveis). Imagens coloridas usam três canais de 8 bits (24 bits no total).

**Ilustração:** Se usarmos apenas 1 bit por pixel (preto e branco), perdemos todos os tons intermediários. Com 2 bits (4 níveis) já se percebe degradês grosseiros. Com 8 bits, o olho humano dificilmente percebe a discretização (visão contínua).

#### ⚠ Erro de quantização

**Erro de quantização** é a diferença entre o valor analógico real e o valor discreto atribuído. Ele se manifesta como ruído de quantização, visível em regiões com gradiente suave quando se usa poucos bits.

### 2.5.3 Efeitos da amostragem e quantização

Os experimentos a seguir mostram como a redução da resolução espacial (subamostragem) e da profundidade de bits degradam a qualidade visual. Use o código para explorar diferentes fatores e níveis de cinza.

```
# Carregar imagem de exemplo
base = "https://upload.wikimedia.org/wikipedia/commons"

arquivo = (
    "Area_de_Prote%C3%A7%C3%A3o_Ambiental_"
    "Quilombos_do_M%C3%A9dio_Ribeira_-_Thomas-"
    "Fuhrmann_%282023-02%29_Malacoptila_striata.jpg"
)

url = f"{base}/c/c5/{arquivo}"
caminho = "imagens/barbudo-rajado.jpg"

if not os.path.exists(caminho):
    os.makedirs("imagens", exist_ok=True)
    img_pil = mm.read(url, pil=True) # retorna PIL Image com EXIF
    mm.write(img_pil, caminho)       # salva preservando EXIF
else:
    img_pil = mm.read(caminho, pil=True)

img_numpy = np.array(img_pil)

exif = img_pil._getexif() # agora funciona - img_pil é PIL Image

img_color = mm.read(caminho)
img_gray0 = mm.gray(img_color)
print(f"Imagem original: {img_color.shape}")
print(f"Tipo da imagem: {type(img_color)}")
```

```
Imagem original: (3067, 2047, 3)
Tipo da imagem: <class 'numpy.ndarray'>
```

O experimento apresentado na Figure 2.4 ilustra o compromisso entre a **resolução espacial** e o **custo de armazenamento** em memória. O código utiliza a técnica de subamostragem por fatiamento (*slicing*) para reduzir a matriz original de pixels conforme um fator  $f$ , resultando em uma economia de memória — por exemplo, um fator  $f = 8$  reduz o tamanho do dado em 64 vezes ( $8^2$ ). Para fins de comparação visual, as imagens reduzidas são restauradas às dimensões originais ( $512 \times 512$ ) através da interpolação por **vizinho mais próximo** (*nearest*). Este processo não recupera a informação perdida, mas torna evidente o efeito de **aliasing** e a estrutura de blocos (pixelização) gerada pela baixa densidade de dados da matriz amostrada.

```
def subsample_simple(image, f):
    # Subamostragem via fatiamento (slicing)
    reduced = image[:, ::f, ::f]

    # Cálculo de memória em KB
    mem_kb = reduced.nbytes / 1024
    label = f"{reduced.shape[1]}x{reduced.shape[0]}, {int(mem_kb)} KB\n(Fator {f})"

    # Restaura o tamanho para visualização (H, W originais)
    res = mm.resize(reduced, (image.shape[1], image.shape[0]), method='nearest')
    return res, label

factors = [1, 4, 8, 12]
img_gray = img_gray0[820:1850, 890:1550] # Recorte para melhor visualização dos detalhes

# Gera os resultados e separa em listas para o mm.show
results = [subsample_simple(img_gray, f) for f in factors]
imgs_list = [r[0] for r in results]
titles_list = [r[1] for r in results]

mm.show(imgs_list, titles=titles_list, cols=4, figsize=(16, 12))
```




Figura 2.4: Efeito da subamostragem. Os títulos exibem as dimensões (W x H) e o tamanho da matriz em memória (KB).

O experimento na Figure 2.5 foca na **quantização de intensidade**, o processo de discretização da amplitude da função  $f(x, y)$ . Enquanto a subamostragem afeta a grade espacial, a redução da profundidade de bits limita a quantidade de tons de cinza disponíveis para representar o brilho.

Ao reduzir a profundidade de 8 bits (256 níveis) para valores menores, surge o efeito de **posterização**, onde os gradientes suaves de uma cena são substituídos por transições abruptas. No limite de 1 bit, a imagem torna-se estritamente binária, preservando apenas a silhueta e perdendo detalhes de textura e volume.

```
def quantize_simple(image, bits):
    """Reduz a profundidade de bits e calcula metadados de memória."""
    levels = 2 ** bits
    # Normalização e quantização uniforme
    quantized = (np.floor(image / 256 * levels) / levels * 255).astype(np.uint8)

    # Cálculo de memória em KB
```

```

mem_kb = quantized.nbytes / 1024
label = f"{bits} bits ({levels} níveis)\n{int(mem_kb)} KB"

return quantized, label

# Lista de bits para teste (8 é o padrão, 1 é o binário)
bits_test = [8, 4, 2, 1]

# Gera os resultados e separa em listas para o mm.show
results_q = [quantize_simple(img_gray, b) for b in bits_test]
imgs_q = [r[0] for r in results_q]
titles_q = [r[1] for r in results_q]

mm.show(imgs_q, titles=titles_q, cols=4, figsize=(16, 12))

```




Figura 2.5: Efeito da redução da profundidade de bits. Os títulos exibem a quantidade de bits, níveis e o tamanho em memória (KB).

### 2.5.4 Análise Técnica

- **Domínio vs. Codomínio:** Note que a resolução espacial (dimensões da matriz) permanece constante em 512x512; o que se altera é apenas o codomínio da função da imagem.
- **Constância de Memória:** Observe nos títulos que o tamanho em KB não diminui. Isso ocorre porque o NumPy armazena cada pixel quantizado em um contêiner de 8 bits (`uint8`), independentemente de o valor real ser apenas 0 ou 1.
- **Percepção:** A degradação visual torna-se crítica abaixo de 4 bits, onde o olho humano começa a perceber as “fronteiras” artificiais criadas pela falta de tons intermediários.

A limitação de tipos de dados menores que um byte no ecossistema Python/NumPy deve-se à arquitetura de hardware, que endereça a memória em blocos de 8 bits (Bytes). Para que se mantenha a compatibilidade com o OpenCV e se garanta a eficiência, mapeiam-se até mesmo elementos binários para contêineres de 1 byte (`uint8` ou `bool8`).

Embora linguagens como ANSI C permitam a compactação de 8 pixels por byte (*bit-packing*), tal abordagem exige a descompactação constante para cálculos e impõe alta complexidade na manipulação de ponteiros. Conforme a Table 2.2, privilegia-se o uso de `uint8` pela facilidade no acesso a vizinhos e pela versatilidade em transformações geométricas. Além disso, métodos nativos do NumPy e OpenCV executam o processamento internamente em baixo nível (C/C++), o que torna operações vetorizadas mais rápidas do que implementações manuais com laços aninhados em Python.

Tabela 2.2: Comparativo entre estratégias de compactação e eficiência de processamento.

| Característica           | Python (NumPy/OpenCV)   | ANSI C (Bit-packing)                 |
|--------------------------|-------------------------|--------------------------------------|
| <b>Menor Unidade</b>     | 1 Byte (8 bits)         | 1 Bit                                |
| <b>Memória (Binária)</b> | 256 KB (para 512x512)   | 32 KB (para 512x512)                 |
| <b>Velocidade</b>        | Alta (Vetorização em C) | Variável (Lenta se houver bit-shift) |
| <b>Complexidade</b>      | Baixa: Métodos prontos  | Alta: Ponteiros e Máscaras           |

## 2.6 Relações entre Pixels - Topologia da Imagem

Os pixels não são elementos isolados; suas posições relativas definem importantes conceitos para processamento.

### 2.6.1 Vizinhança

Dado um pixel de coordenadas  $(x, y)$ , definem-se dois tipos principais de vizinhança (para imagens em *grid* retangular):

- **Vizinhança-4** (von Neumann): inclui os pixels nas posições  $(x-1, y)$ ,  $(x+1, y)$ ,  $(x, y-1)$ ,  $(x, y+1)$ .
- **Vizinhança-8** (Moore): inclui todos os oito pixels adjacentes (acrescenta os quatro diagonais).

A escolha da vizinhança influencia operações como detecção de bordas, cálculo de gradientes e conectividade.

```
# # Criação de uma matriz 3x3 para exemplo topológico
# viz = np.zeros((3, 3), dtype='uint8')

# # Definindo Vizinhança-4 (N4) com valor diferente para destaque
# viz[0, 1] = viz[2, 1] = viz[1, 0] = viz[1, 2] = viz[1, 1] = 255

# ou simplesmente (teste com números como argumentos):
viz = mm.secross()

# Exibição da matriz para análise de coordenadas
mm.drawImgPlt(viz, scale=40)
```




Figura 2.6: Ilustração de vizinhanças 4 em uma matriz 3x3. No centro (1,1), o pixel de interesse.

```
import morph
importlib.reload(morph)
from morph import mm
```

### 2.6.2 Adjacência, conectividade e caminhos

Dois pixels são **adjacentes** se estão em contato segundo uma vizinhança definida e satisfazem um critério de valor (ex.: mesmo nível de intensidade). Uma **conectividade** define uma relação de equivalência entre pixels que formam uma região conexa. Um **caminho** é uma sequência de pixels adjacentes.

A **conectividade-4** (N4) e **conectividade-8** (N8) podem produzir resultados diferentes na segmentação e no cálculo de componentes conexas (etiquetagem). Por exemplo, um padrão de tabuleiro de xadrez pode ser completamente desconexo em N4, mas totalmente conexo em N8.

2.6.3 Distâncias entre pixels

As métricas de distância são fundamentais para quantificar a proximidade física e a conectividade entre os elementos que compõem a grade digital. Conforme demonstrado na Table 2.3, a escolha da métrica define o custo de deslocamento entre pixels e altera o comportamento de algoritmos de segmentação e análise morfológica.

Para medir a distância entre dois pixels  $p(x_1, y_1)$  e  $q(x_2, y_2)$ , utilizam-se diferentes funções métricas que impõem restrições de movimento distintas sobre o *grid*:

Tabela 2.3: Comparativo de métricas de distância aplicadas à malha de pixels.

| Métrica                                | Definição                              | Interpretação                                   |
|----------------------------------------|----------------------------------------|-------------------------------------------------|
| <b>Euclidiana</b>                      | $\sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$ | Distância <b>exata</b> em linha reta (contínua) |
| <b>Manhattan</b> ( <i>City block</i> ) | $ x_1 - x_2  +  y_1 - y_2 $            | Movimentos horizontais + verticais              |
| <b>Chebyshev</b> ( <i>Tabuleiro</i> )  | $\max( x_1 - x_2 ,  y_1 - y_2 )$       | Maior deslocamento entre os eixos               |

Essas distâncias são aplicadas em diversos contextos de PDI, incluindo algoritmos de interpolação geométrica, transformadas de distância, crescimento de regiões e análise de formas.

*i* Exemplo prático

Considerando dois pixels com deslocamentos relativos  $\Delta x = 3$  e  $\Delta y = 4$ :

- **Euclidiana**:  $\sqrt{3^2 + 4^2} = 5$  (hipotenusa do triângulo retângulo).
- **Manhattan**:  $3 + 4 = 7$  (soma dos catetos).
- **Chebyshev**:  $\max(3, 4) = 4$  (predomínio do maior deslocamento).

2.7 Armazenamento de Imagens

A escolha do formato de arquivo é um passo decisivo no fluxo de processamento, pois determina como os dados de amostragem e quantização serão preservados ou descartados. Conforme se apresenta na Table 2.4, cada extensão equilibra de forma distinta a fidelidade dos dados e a eficiência de armazenamento.

Tabela 2.4: Principais formatos de armazenamento de imagens digitais e suas aplicações em PDI.

| Formato     | Características                                                        | Uso típico                             |
|-------------|------------------------------------------------------------------------|----------------------------------------|
| <b>PGM</b>  | Formato simples de mapa de cinzas (texto ou binário).                  | Pesquisa acadêmica e ferramentas Unix. |
| <b>BMP</b>  | Não comprimido (ou compressão simples).                                | Windows, aplicações legado.            |
| <b>PNG</b>  | Compressão <b>sem perdas</b> ( <i>lossless</i> ).                      | Web, imagens com transparência.        |
| <b>JPEG</b> | Compressão <b>com perdas</b> ( <i>lossy</i> ), ideal para fotografias. | Fotos, câmeras digitais.               |
| <b>TIFF</b> | Suporta múltiplas camadas e compressão variada.                        | Editoração, arquivamento.              |
| <b>RAW</b>  | Dados brutos do sensor, sem processamento.                             | Fotografia profissional.               |



| Formato      | Características                                                                    | Uso típico                                     |
|--------------|------------------------------------------------------------------------------------|------------------------------------------------|
| <b>DICOM</b> | Padrão médico com metadados clínicos embutidos (paciente, equipamento, protocolo). | Radiologia, tomografia, ressonância magnética. |

Os metadados de uma imagem incluem parâmetros como largura, altura, profundidade de bits e codificação de cor. Em formatos científicos, preservam-se também informações de calibração e detalhes da captura. Ao utilizar-se a função `mm.read()`, a biblioteca `morph` preserva automaticamente esses dados para que se respeitem as propriedades originais da imagem.

Em contextos científicos e hospitalares, privilegia-se o padrão **DICOM** (*Digital Imaging and Communications in Medicine*) para garantir que não haja perda de precisão diagnóstica. Repositórios públicos como o [The Cancer Imaging Archive \(TCIA\)](#), o [Alzheimer’s Disease Neuroimaging Initiative \(ADNI\)](#) e o [PhysioNet](#) disponibilizam vastos conjuntos de dados neste formato, incluindo metadados clínicos anonimizados que são essenciais para a investigação científica.

### 2.7.1 Exemplo: Extração de Metadados e Localização GPS

Diferente da matriz de pixels pura obtida pela leitura convencional — como na imagem do pássaro apresentada no início deste capítulo —, o uso do argumento `pil=True` no método `mm.read()` altera a natureza do objeto retornado (ver Figure 2.7). Enquanto o padrão (`pil=False`) retorna um `numpy.ndarray` RGB, a leitura com `pil=True` retorna um objeto especializado da biblioteca Pillow, capaz de interpretar o cabeçalho **EXIF**.

O cabeçalho **EXIF** (*Exchangeable Image File Format*) funciona como um repositório técnico da captura, permitindo que o objeto Pillow interprete uma vasta gama de informações que vão muito além das coordenadas de GPS. Ao utilizar `pil=True`, o sistema ganha acesso ao “DNA” da imagem, incluindo metadados de hardware (marca e modelo da câmera), configurações ópticas (abertura, distância focal e tempo de exposição) e parâmetros de iluminação (uso de flash e balanço de branco).

Essa distinção é importante no PDI, pois transforma a matriz de amostragem em um conjunto de dados contextualizado, onde as características físicas do sensor e da lente podem ser utilizadas para normalizar brilhos ou corrigir distorções geométricas.

```
from PIL.ExifTags import TAGS
import os, numpy as np

base = "https://upload.wikimedia.org/wikipedia/commons"
arquivo = (
    "Area_de_Prote%C3%A7%C3%A3o_Ambiental_"
    "Quilombos_do_M%C3%A9dio_Ribeira_-_Thomas-"
    "Fuhrmann_%282023-02%29_Malacoptila_striata.jpg"
)
url = f"{base}/c/c5/{arquivo}"
caminho = "imagens/barbudo-rajado.jpg"

# 1. Leitura - preserva objeto PIL com EXIF
if not os.path.exists(caminho):
    os.makedirs("imagens", exist_ok=True)
    img_obj = mm.read(url, pil=True)
    mm.write(img_obj, caminho) # salva preservando EXIF
else:
    img_obj = mm.read(caminho, pil=True)

img_numpy = np.array(img_obj) # conversão para NumPy

# 2. Extração e conversão de GPS (Tag 34853)
exif = img_obj._getexif()
```



```

if exif and (gps := exif.get(34853)):
    to_dec = lambda dms, ref: float(-(dms[0]+dms[1]/60+dms[2]/3600) if ref in 'SW'
                                   else (dms[0]+dms[1]/60+dms[2]/3600))
    lat, lon = to_dec(gps[2], gps[1]), to_dec(gps[4], gps[3])
    print(f"GPS Decimal: {lat:.6f}, {lon:.6f}")
    print(f"Maps: https://www.google.com/maps/search/?api=1&query={lat},{lon}")

# 3. Diagnóstico de tipos, dimensões e acesso a pixels
print(f"\nTipo PIL : {type(img_obj)} | Dimensões (x,y): {img_obj.size}")
print(f"Pillow (0,0): {img_obj.getpixel((0, 0))}")
print(f"Tipo NumPy: {type(img_numpy)} | Dimensões [y,x,c]: {img_numpy.shape}")
print(f"NumPy [0,0]: {img_numpy[0, 0]}")

# 4. Exibição
mm.show(img_numpy, scale=30)

```

```

GPS Decimal: -24.587955, -48.629758
Maps: https://www.google.com/maps/search/?api=1&query=-24.587955,-48.629758333333335

Tipo PIL : <class 'PIL.JpegImagePlugin.JpegImageFile'> | Dimensões (x,y): (2047, 3067)
Pillow (0,0): (58, 96, 0)
Tipo NumPy: <class 'numpy.ndarray'> | Dimensões [y,x,c]: (3067, 2047, 3)
NumPy [0,0]: [58 96 0]

```




Figura 2.7: Área de Proteção Ambiental Quilombos do Médio Ribeira - Barbudo-rajado (*Malacoptila striata*). Crédito: Thomas Fuhrmann (CC BY-SA 4.0).

### **i** Nota Pedagógica: A sutil diferença das dimensões

Repare que a representação das dimensões muda conforme a estrutura de dados utilizada:

- **No Pillow (.size):** Retorna (Largura, Altura) — no exemplo: (2047, 3067). É uma visão orientada ao arquivo de imagem.
- **No NumPy (.shape):** Segue a convenção matemática de matrizes: (Linhas/Altura, Colunas/Largura, Canais) — no exemplo: (3067, 2047, 3).

Esta distinção é fundamental para evitar erros de indexação ao implementar filtros manuais. Enquanto o objeto Pillow carrega o “**onde**” e o “**quando**” (contexto), o array NumPy carrega o “**quanto**” de luz (intensidade) existe em cada ponto da imagem.

## 2.7.2 Por que esta separação é importante?

Ao carregar uma imagem via `cv2.imread()`, o resultado é um `<class 'numpy.ndarray'>`, que contém estritamente os valores numéricos resultantes da **quantização** e **amostragem**. No entanto, ao utilizar `pil=True`, o `mm.read()` retorna um objeto da classe `PIL.JpegImagePlugin.JpegImageFile`.

Esta classe mantém o arquivo “aberto” para permitir o acesso ao contexto da captura antes que os dados sejam convertidos em uma matriz bruta. Note que o pixel (0, 0) é idêntico nas duas representações — (58, 96, 0) no Pillow e [58, 96, 0] no NumPy —, confirmando que ambos descrevem os mesmos dados, apenas com interfaces distintas. Essa separação é vital: pixels servem para algoritmos; metadados servem para georreferenciamento, catalogação científica e correções baseadas no hardware de aquisição.

Para inspecionar todos os metadados EXIF de um objeto Pillow:

```
from PIL import ExifTags

exif_raw = img_obj._getexif()
if exif_raw:
    for tag_id, valor in sorted(exif_raw.items()):
        tag_nome = ExifTags.TAGS.get(tag_id, f"TAG_{tag_id}")
        print(f" {tag_nome:40s} : {valor}")
```

## 2.8 Transformações Geométricas Básicas

As transformações geométricas alteram a posição dos pixels, mantendo os valores de intensidade. São fundamentais para alinhamento, correção de distorções e aumento de dados (*data augmentation*) em aprendizado de máquina.

Uma **transformação afim** é qualquer mapeamento que preserve colinearidade (pontos sobre uma reta permanecem sobre uma reta) e razões de distâncias entre pontos colineares. Em 2D, toda transformação afim pode ser expressa em **coordenadas homogêneas** por uma matriz  $3 \times 3$ :

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \underbrace{\begin{bmatrix} a_{11} & a_{12} & t_x \\ a_{21} & a_{22} & t_y \\ 0 & 0 & 1 \end{bmatrix}}_{\mathbf{T}} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (2.2)$$

A sub-matriz  $2 \times 2$  superior esquerda  $\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$  controla rotação, escala e cisalhamento; o vetor  $(t_x, t_y)^\top$  controla a translação. As transformações geométricas mais usadas em PDI — translação, rotação e escala — são casos particulares de  $\mathbf{T}$ , e podem ser **compostas** por multiplicação de matrizes, na ordem  $\mathbf{T} = \mathbf{T}_n \cdots \mathbf{T}_2 \mathbf{T}_1$ .

### i Transformação inversa e interpolação

Na implementação prática (`cv2.warpAffine`), aplica-se a **transformação inversa**: para cada pixel  $(x', y')$  da imagem destino, calcula-se a posição de origem  $(x, y) = \mathbf{T}^{-1}(x', y')$  e interpola-se o valor. Isso evita buracos na imagem resultante causados pelo mapeamento direto de pixels inteiros para posições não inteiras.

## 2.8.1 Translação

A translação é a transformação afim mais simples: desloca todos os pixels por um vetor  $(t_x, t_y)$ . Em coordenadas homogêneas, é expressa pela matriz:

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & t_x \\ 0 & 1 & t_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \Rightarrow \begin{cases} x' = x + t_x \\ y' = y + t_y \end{cases} \quad (2.3)$$

A terceira linha da matriz garante que a operação permaneça no espaço afim, permitindo que translação, rotação e escala sejam combinadas por simples multiplicação de matrizes. Na prática, `cv2.warpAffine` usa apenas as duas primeiras linhas (matriz  $2 \times 3$ ), pois a terceira é sempre  $[0, 0, 1]$ .

Pixels deslocados para além da área original são descartados; áreas descobertas são preenchidas com 0 (preto). Ver um exemplo na Figure 2.8.

```
img_tx1 = mm.translate(img_gray, 50, 50)
img_tx2 = mm.translate(img_gray, 100, 50)
mm.show([img_gray, img_tx1, img_tx2],
        titles=["Original", "Translação (50,50)", "Translação (100,50)"],
        cols=3, figsize=(16, 12))
```



Figura 2.8: Exemplo de translação da imagem do pássaro com deslocamentos (50,50) e (100,50).

## 2.8.2 Rotação

A rotação por ângulo  $\theta$  em torno de um ponto central  $(c_x, c_y)$  é composta por três transformações afins: translação para a origem, rotação pura e translação de volta. A matriz resultante é:

$$\mathbf{T}_{\text{rot}} = \begin{bmatrix} \cos \theta & -\sin \theta & c_x(1 - \cos \theta) + c_y \sin \theta \\ \sin \theta & \cos \theta & c_y(1 - \cos \theta) - c_x \sin \theta \\ 0 & 0 & 1 \end{bmatrix} \quad (2.4)$$

Na implementação, `cv2.getRotationMatrix2D` gera diretamente as duas primeiras linhas de  $\mathbf{T}_{\text{rot}}$  (matriz  $2 \times 3$  para `warpAffine`), aceitando também um fator de escala  $s$  que multiplica  $\cos \theta$  e  $\sin \theta$ . Ver exemplo na Figure 2.9.

Como a rotação desloca pixels para novas posições não-inteiras, `cv2.warpAffine` precisa estimar a cor de cada pixel de destino a partir dos vizinhos — processo chamado **interpolação**. O parâmetro `interp` controla esse comportamento:

- **nearest** (`INTER_NEAREST`): atribui o valor do pixel mais próximo. Rápido, mas produz serrilhado (*aliasing*) em bordas diagonais.
- **bilinear** (`INTER_LINEAR`, padrão): média ponderada dos 4 vizinhos mais próximos. Equilibra qualidade e desempenho — adequado para a maioria dos casos.
- **bicubic** (`INTER_CUBIC`): considera os 16 vizinhos em uma superfície cúbica. Produz bordas mais suaves, ao custo de maior processamento.

```
img_rot30 = mm.rotate(img_gray, 30, interp='bilinear')
img_rot45 = mm.rotate(img_gray, 45, interp='bilinear')

mm.show([img_gray, img_rot30, img_rot45],
        titles=["Original", "Rotação 30°", "Rotação 45°"],
        cols=3, figsize=(16, 12))
```



Figura 2.9: Exemplo de rotação da imagem do pássaro em 30° e 45° usando interpolação bilinear.



### 2.8.3 Escala (Redimensionamento)

O redimensionamento por fatores  $(s_x, s_y)$  é uma transformação afim com matriz:

$$\mathbf{T}_{\text{escala}} = \begin{bmatrix} s_x & 0 & 0 \\ 0 & s_y & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad (2.5)$$

Quando  $s > 1$  (ampliação), pixels da imagem destino mapeiam para posições não inteiras na origem — exigindo interpolação para estimar o valor. Quando  $s < 1$  (redução), múltiplos pixels de origem contribuem para um único pixel destino — exigindo **decimação**. Os mesmos três métodos descritos na rotação estão disponíveis em `mm.resize`, com a diferença de que aqui o impacto visual é mais perceptível: na ampliação, **nearest** produz efeito de blocos (*pixelation*), enquanto **bicubic** preserva melhor a nitidez das bordas, conforme a Table 2.5:

Tabela 2.5: Métodos de interpolação disponíveis em `mm.resize` e seus respectivos números de vizinhos utilizados no cálculo.

| Método     | Vizinhos usados | Característica                                        |
|------------|-----------------|-------------------------------------------------------|
| 'nearest'  | 1               | Rápido; produz efeito de blocos ( <i>pixelation</i> ) |
| 'bilinear' | 4               | Bom compromisso qualidade/custo; bordas suaves        |
| 'bicubic'  | 16              | Maior nitidez; preferido em softwares profissionais   |

O parâmetro `size_or_factor` aceita tanto um escalar (fator uniforme, e.g. 0.5 para reduzir à metade) quanto uma tupla (largura, altura) para dimensões absolutas.

```
# 1. Recorte da região do bico
y, x, offset = 210, 40, 40
crop = img_gray[y-offset:y+offset, x-offset:x+offset]
print(f"Imagem: {img_gray.shape} | Crop: {crop.shape}")

# 2. Ampliar 4× com mm.resize
crop_nearest = mm.resize(crop, size_or_factor=4, method='nearest')
crop_bilinear = mm.resize(crop, size_or_factor=4, method='bilinear')

# 3. Exibição comparativa
mm.show(
    [crop, crop_nearest, crop_bilinear],
    titles=["Original (recorte)", "Vizinho mais próximo (4×)", "Bilinear (4×)"],
    cols=3, figsize=(16, 12), dpi=200
)
```

Imagem: (1030, 660) | Crop: (80, 80)



Figura 2.10: Comparação de interpolação com zoom no detalhe do olho (recorte  $60 \times 60$ , ampliado  $4 \times$ ). Note o efeito de blocos no vizinho mais próximo vs. a suavização na bilinear.

#### 2.8.4 Cisalhamento (*Shear*)

O cisalhamento é uma transformação afim que distorce a imagem ao deslocar cada pixel proporcionalmente à sua posição em um eixo. A matriz geral combina cisalhamento horizontal ( $sh_x$ ) e vertical ( $sh_y$ ):

$$\mathbf{T}_{\text{cisalh}} = \begin{bmatrix} 1 & sh_x & 0 \\ sh_y & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad (2.6)$$

Para  $sh_x \neq 0$  e  $sh_y = 0$ , cada linha é deslocada horizontalmente proporcionalmente à sua posição vertical — produzindo o efeito de “inclinação” característico. Ver exemplo na Figure 2.11.

```
img_shx = mm.shear(img_gray, shx=0.3)
img_shy = mm.shear(img_gray, shy=0.3)
img_shc = mm.shear(img_gray, shx=0.2, shy=0.2)

mm.show(
    [img_gray, img_shx, img_shy, img_shc],
    titles=["Original", "Horiz. (shx=0.3)", "Vert. (shy=0.3)", "Combinado (0.2, 0.2)"],
    cols=4, figsize=(16, 12)
)
```






Figura 2.11: Exemplo de cisalhamento da imagem do pássaro: horizontal ( $shx=0.3$ ), vertical ( $shy=0.3$ ) e combinado ( $shx=0.2$ ,  $shy=0.2$ ).

## 2.9 Resumo

Neste capítulo foram apresentados os fundamentos de digitalização e topologia de imagens:

- **Formação da imagem:**  $f(x, y) = i(x, y) \cdot r(x, y)$ .
- **Amostragem:** discretização do espaço  $\rightarrow$  resolução espacial  $M \times N$ .
- **Quantização:** discretização da intensidade  $\rightarrow$  profundidade de bits  $b$ .
- **Relações topológicas:** vizinhança-4, vizinhança-8, conectividade, distâncias (Euclidiana, Manhattan, Chebyshev).
- **Transformações geométricas:** translação, rotação, escala (com interpolação bilinear ou vizinho mais próximo).
- **Formatos de arquivo:** BMP, PNG, JPEG, TIFF, RAW; cada um com diferentes compromissos entre qualidade e tamanho.

O Capítulo 3 abordará **operações espaciais** como convolução, filtragem e morfologia matemática (erosão, dilatação).

## 2.10 Uso do Gemini Notebook como Tutor Complementar

Nesta edição, incentivamos o uso do **Gemini Notebook** como ferramenta complementar de aprendizagem. Essa ferramenta de IA utiliza exclusivamente os documentos fornecidos pelo autor como base de conhecimento, garantindo respostas coerentes com o conteúdo do livro.

Para cada capítulo, preparamos um projeto específico na plataforma. Para uma experiência de estudo ampliada, utilize o acesso abaixo:

### Estude com o Tutor Inteligente

Para interagir com o conteúdo deste capítulo, acesse o link a seguir. O ambiente contém materiais didáticos em diferentes formatos, gerados a partir do **PDF** do capítulo. Na plataforma, explore especialmente as opções **Guia de Estudo** e **Conversa** para aprofundar sua compreensão.

 [ACESSAR Gemini Notebook: CAPÍTULO 02](#)

### Aviso sobre Conteúdo Gerado por IA

A IA é uma poderosa aliada nos estudos, mas o conteúdo gerado pode conter **erros ou imprecisões**. Consulte sempre **livros, artigos científicos e outras fontes acadêmicas confiáveis** para validar as informações. Sempre que possível, execute os exemplos práticos fornecidos neste capítulo para verificar os resultados.

## 2.11 Lista de Exercícios

1. **(15%)** Explique, com suas próprias palavras, a diferença entre **amostragem** e **quantização**. Dê um exemplo concreto de cada uma no contexto de uma imagem digital.
2. **(15%)** Considere uma imagem com resolução espacial de  $1024 \times 768$  pixels e profundidade de 24 bits (8 bits por canal RGB). Calcule o tamanho total não comprimido da imagem em bytes e em megabytes.
3. **(20%)** Utilizando o código do laboratório, modifique o fator de subamostragem para 3 e para 6. Descreva visualmente o que ocorre com as bordas dos objetos. O que é o efeito de *aliasing*?
4. **(20%)** Para a imagem em tons de cinza, aplique quantização com 3 bits (8 níveis) e 5 bits (32 níveis). Compare os resultados e explique por que 5 bits já pode ser considerado suficiente para muitas aplicações.
5. **(15%)** Dados dois pixels  $A = (10, 20)$  e  $B = (15, 25)$ , calcule as distâncias Euclidiana, Manhattan e Chebyshev entre eles.
6. **(15%)** Usando a função `mm.rotate`, gire a imagem do pássaro em ângulos de  $90^\circ$ ,  $180^\circ$  e  $270^\circ$  com interpolação bilinear. Compare com a rotação usando `method='nearest'`. Em quais situações a interpolação vizinho mais próximo ainda é útil?

## Referências do Capítulo

A fundamentação teórica deste capítulo baseia-se nas seguintes obras:

- Gonzalez; Woods (2018) para os conceitos de amostragem, quantização e relações entre pixels.
- Szeliski (2022) para transformações geométricas e conectividade.
- Bradski; Kaehler (2008) para a implementação prática com OpenCV e `morph.py`.

---

 Executar Colab  Abrir pdi-vc GitHub

## 2.12 Parte Prática com Exercícios de Programação

### Objetivo deste Caderno

O caderno permite desenvolver, validar, organizar e testar soluções de **Exercícios de Programação (EPs)** em ambientes interativos, como o Colab, com os mesmos casos de teste do Moodle, copiando para lá apenas na hora de registrar a nota oficial.

### Download

Baixe `morph.py` e `testsuite.py` executando a célula abaixo:

```
import os, sys, importlib, inspect, urllib.request

# URLs do repositório
BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph"
for f in ["morph.py", "testsuite.py"]:
    if not os.path.exists(f):
        urllib.request.urlretrieve(f"{BASE_URL}/{f}", f)

import morph, testsuite
importlib.reload(morph); importlib.reload(testsuite)
from morph import mm
from testsuite import TestSuite

print(f" Ambiente pronto. Morph: {morph.__version__} | TestSuite: {testsuite.__version__}")
```

Ambiente pronto. Morph: 1.1.2 | TestSuite: 1.1.2

## Executando os Testes

Para avaliar os testes, execute `TestSuite("EP04_01.extensão").run()` numa nova célula, trocando a extensão pela da linguagem usada (.py, .java, .c, .cpp, .js ou .r). O sistema baixa os casos de teste do GitHub, executa o programa e calcula a nota automaticamente.

Para testar código Python diretamente, sem salvar arquivo, use `run_code(codigo)` passando o código como *string* numa variável `codigo`:

```
codigo = """
from morph import mm
# ... seu código aqui ...
"""

TestSuite("EP04_01").run_code(codigo)
```

### 2.12.1 EP02\_01 ☉ Ajuste de Brilho e Contraste

Nesta atividade, o objetivo é implementar um operador de ponto para **transformação linear de intensidade**, aplicando o ajuste dinâmico de brilho e contraste em uma imagem digital.

#### 2.12.1.1 📋 Diretrizes de Implementação

O algoritmo deve seguir o fluxo de execução abaixo:

1. **Dimensões:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas) da matriz.
2. **Parâmetros:** Ler o valor real  $\alpha$  (fator de contraste) e o inteiro  $\beta$  (fator de brilho).
3. **Dados:** Ler os valores inteiros da matriz original.
4. **Mapeamento:** Para cada pixel  $p$ , calcular o novo valor  $p'$  pela equação:

$$p' = \text{clip}(\text{round}(\alpha \cdot p + \beta))$$

5. **Saída:** Exibir a matriz resultante com as dimensões  $L \times C$ .

#### 2.12.1.2 📌 Restrições Computacionais

- **Arredondamento (*Round*):** Aplica-se o arredondamento matemático para o inteiro mais próximo antes da conversão de tipo.
- **Saturação (*Clipping*):** Os valores devem ser confinados ao intervalo  $[0, 255]$  para preservar o padrão de 8 bits:

$$\text{clip}(x) = \max(0, \min(255, x))$$

- **Simulação:** O efeito dos parâmetros  $\alpha$  e  $\beta$  na correção histogramática pode ser observado na Figure 2.12.

### 2.12.1.3 Fundamentação Teórica

As alterações modificam o histograma da imagem para ajustar o perfil de iluminação e a distinção tonal.

| Parâmetro                 | Função    | Impacto Visual                                                                                             |
|---------------------------|-----------|------------------------------------------------------------------------------------------------------------|
| $\alpha$ ( <b>Alpha</b> ) | Escalar   | Modula o <b>Contraste</b> . Se $\alpha > 1$ , expande o histograma; se $0 \leq \alpha < 1$ , comprime.     |
| $\beta$ ( <b>Beta</b> )   | Aditiva   | Modula o <b>Brilho</b> . Se positivo, translada o histograma para a direita; se negativo, para a esquerda. |
| <b>clip</b>               | Limitador | Restringe a faixa dinâmica, impedindo erros de <i>underflow</i> e <i>overflow</i> .                        |

### 2.12.1.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Valores de **alpha** ( $\alpha$ ) e **beta** ( $\beta$ ).
- Linhas seguintes: Elementos numéricos da matriz original.

**Saída:**

- Matriz transformada estruturada em  $L$  linhas e  $C$  colunas.

### 2.12.1.5 Exemplos

A tabela a seguir apresenta um exemplo prático do comportamento esperado do algoritmo, destacando a atuação dos operadores de arredondamento e saturação.

| Entrada                            | Saída         | Observação                                 |
|------------------------------------|---------------|--------------------------------------------|
| 1<br>4<br>1.5 -30<br>0 100 180 255 | 0 120 240 255 | Note o efeito de saturação no último pixel |

### Executando os Testes

Para avaliar os testes, execute `TestSuite("EP02_01.extensão").run()` numa nova célula, trocando a extensão pela da linguagem usada (.py, .java, .c, .cpp, .js ou .r). O sistema baixa os casos de teste do GitHub, executa o programa e calcula a nota automaticamente.




Figura 2.12: Simulador: Ajuste de Brilho e Contraste

```
%%writefile EP02_01.py
# sua solução
```

```
Writing EP02_01.py
```

```
TestSuite("EP02_01.py").run()
```

### 2.12.2 EP02\_02 Subamostragem Espacial

Nesta atividade, você deve implementar a redução da resolução espacial de uma imagem através do processo de subamostragem.

- Leia dois inteiros  $L$  e  $C$ , representando as dimensões da matriz original.
- Leia um valor inteiro  $f$  ( $f \geq 1$ ), que representa o fator de amostragem.
- Leia os valores inteiros da matriz original.
- A nova imagem deve ser construída selecionando o pixel da posição  $(f \cdot i, f \cdot j)$  da imagem original.
- Imprima a matriz resultante com as novas dimensões.
- Ver na Figure 2.13 uma simulação deste EP.

#### Importante:

- **Dimensões Finais:** A imagem amostrada terá dimensões  $\lceil L/f \rceil \times \lceil C/f \rceil$ . No contexto de programação, isso equivale ao tamanho resultante de um fatiamento (slicing) com passo  $f$ .
- **Implementação:** Não utilize funções prontas de bibliotecas de processamento de imagens (como OpenCV ou PIL) para o redimensionamento. Implemente a lógica de seleção de pixels manualmente ou via fatiamento de matrizes.

- **Aliasing:** Note que este processo pode causar o efeito de *aliasing* (serrilhamento), onde detalhes finos são perdidos ou padrões indesejados aparecem.

### 2.12.2.1 🧠 Discretização do Espaço

A subamostragem reduz a resolução espacial de uma imagem, selecionando apenas um pixel a cada  $f$  pixels em cada direção. É o processo inverso da interpolação:

| Parâmetro                   | Função              | Efeito                                                                          |
|-----------------------------|---------------------|---------------------------------------------------------------------------------|
| <b>Fator <math>f</math></b> | Salto de amostragem | Define o intervalo de seleção. Um fator 2 reduz a largura e altura pela metade. |
| <b>Resolução</b>            | Densidade de pixels | Diminui a quantidade total de informação espacial da imagem.                    |
| <b>Aliasing</b>             | Efeito colateral    | Surgimento de padrões em escada ou blocos devido à perda de detalhes finos.     |

### 2.12.2.2 📋 Tarefa (especificação para VPL)

#### Entrada:

A primeira linha contém  $L$ .

A segunda linha contém  $C$ .

A terceira linha contém o fator  $f$ .

As linhas seguintes contêm os elementos da matriz  $L \times C$ .

#### Saída:

A matriz reduzida com as dimensões correspondentes ao fatiamento por  $f$ .

### 2.12.2.3 📌 Exemplos

| Entrada                                   | Saída | Observação                                                                                 |
|-------------------------------------------|-------|--------------------------------------------------------------------------------------------|
| 2<br>4<br>2<br>10 20 30 40<br>50 60 70 80 | 10 30 | O fator 2 seleciona os pixels (0,0) e (0,2) da primeira linha. A segunda linha é ignorada. |

```
%%writefile EP02_02.py
# Código Python
```

```
Writing EP02_02.py
```

```
TestSuite("EP02_02.py").run()
```






Figura 2.13: Simulador: Subamostragem

### 2.12.3 EP02\_03 🧠 Quantização de Níveis de Cinza

Nesta atividade, você deve implementar a quantização uniforme de uma imagem, reduzindo a quantidade de níveis de intensidade de cinza originais para uma nova escala baseada em um número menor de bits.

- Leia dois inteiros **L** e **C**, representando as dimensões da matriz.
- Leia um inteiro  $k$  ( $1 \leq k \leq 8$ ), representando o novo número de bits da imagem.
- Calcule o número de níveis ( $N = 2^k$ ) e o tamanho do intervalo (passo).
- Para cada pixel  $p$ , calcule o novo valor  $p'$  mapeando-o para o índice do nível discretizado correspondente (variando de 0 a  $2^k - 1$ ).
- Imprima a matriz resultante com os mesmos valores de dimensões originais.
- Ver na Figure 2.14 uma simulação deste EP.

#### 📌 Importante:

- **Posterização:** Ao reduzir drasticamente os níveis (ex:  $k = 2$ ), você notará que degradês suaves se transformam em faixas abruptas de cor devido à perda de resolução de amplitude.
- **Cálculo do Passo:** O intervalo entre cada nível é definido por  $\text{passo} = 256/2^k$ .
- **Mapeamento:** O método de quantização uniforme por truncamento que mapeia o pixel para o índice do seu respectivo nível discretizado é dado por:

$$p' = \left\lfloor \frac{p}{\text{passo}} \right\rfloor$$

Em termos de implementação (como em Python), isso equivale à divisão inteira:  $p' = p // \text{passo}$ .

### 2.12.3.1 🧠 Discretização da Amplitude

Enquanto a subamostragem lida com a resolução espacial, a quantização foca na precisão da cor (amplitude). Reduzir os bits significa simplificar a informação cromática:

| Parâmetro                    | Função              | Efeito                                                        |
|------------------------------|---------------------|---------------------------------------------------------------|
| <b>Bits (<math>k</math>)</b> | Profundidade de cor | Define quantos tons diferentes a imagem pode ter ( $2^k$ ).   |
| <b>Passo</b>                 | Intervalo de tom    | Espaçamento entre os níveis de cinza permitidos.              |
| <b>Posterização</b>          | Fenômeno visual     | Transformação de variações contínuas em blocos de cor sólida. |

### 2.12.3.2 📋 Tarefa (especificação para VPL)

#### Entrada:

A primeira linha contém  $L$ .

A segunda linha contém  $C$ .

A terceira linha contém o número de bits  $k$ .

As linhas seguintes contêm os elementos da matriz  $L \times C$ .

#### Saída:

A matriz transformada com os índices dos níveis quantizados, mantendo o tamanho original  $L \times C$ .

### 2.12.3.3 📌 Exemplos

| Entrada                          | Saída     | Observação                                                                                                                                                                                                     |
|----------------------------------|-----------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1<br>4<br>2<br>0 80 170 255      | 0 1 2 3   | Com $k = 2$ , temos $2^2 = 4$ níveis discretos disponíveis (0, 1, 2, 3). O passo é $256/4 = 64$ . Aplicando a divisão inteira por elemento:<br>$0//64 = 0$ , $80//64 = 1$ ,<br>$170//64 = 2$ , $255//64 = 3$ . |
| 1<br>5<br>1<br>10 50 120 200 250 | 0 0 0 1 1 | Com $k = 1$ , temos $2^1 = 2$ níveis (0 e 1). Passo = $256/2 = 128$ . Pixels menores que 128 resultam em 0, e pixels maiores ou iguais a 128 resultam em 1.                                                    |

```
%%writefile EP02_03.py
# Código Python
```

```
Writing EP02_03.py
```

```
TestSuite("EP02_03.py").run()
```




Figura 2.14: Simulador: Quantização

2.12.4 EP02\_04 Transformada de Distância em Imagem Binária

Dada uma imagem binária onde pixels de valor **1** representam o *objeto* e pixels **0** representam o *fundo*, a distância de um pixel de fundo recebe a **menor distância ao pixel de objeto mais próximo**. Pixels de objeto recebem distância **0**. Para simplificar, considere que a imagem tem **apenas um único objeto com um pixel de valor 1**.

**Problema:** Leia uma imagem binária  $L \times C$  e uma métrica, e calcule essa distância simplificada aplicando uma das três fórmulas:

$$d_{\text{Euclidiana}} = \sqrt{(\Delta r)^2 + (\Delta c)^2}$$

$$d_{\text{City-block}} = |\Delta r| + |\Delta c|$$

$$d_{\text{Chessboard}} = \max(|\Delta r|, |\Delta c|)$$

onde  $\Delta r$  é a diferença de linhas e  $\Delta c$  a diferença de colunas entre dois pixels.

2.12.4.1 Por que isso importa? - Aplicações da DT

A Transformada de Distância (DT) aparece em dezenas de pipelines de visão computacional:

| Métrica    | Complexidade     | Aplicação típica                   |
|------------|------------------|------------------------------------|
| Euclidiana | $O(n^2)$ ingênuo | Esqueletização, matching de formas |

| Métrica    | Complexidade          | Aplicação típica             |
|------------|-----------------------|------------------------------|
| City-block | ● $O(n)$ com 2 passes | Morfologia, dilatação/erosão |
| Chessboard | ● $O(n)$ com 2 passes | Morfologia, dilatação/erosão |

#### 2.12.4.2 📌 Requisitos Técnicos

- **Entrada:** \* Primeira linha:  $L$  e  $C$  (inteiros).
  - Segunda linha: nome da métrica (`euclidean`, `cityblock` ou `chessboard`).
  - Em seguida, a matriz binária  $L \times C$  (valores 0 ou 1).
- **Pixels de objeto (1):** distância = 0 (ou 0.00 para euclidiana).
- **Pixels de fundo (0):** distância ao único pixel de objeto na imagem.
- **Arredondamento (euclidiana):** imprimir com **2 casas decimais** (formato `:.2f`). City-block e Chessboard produzem inteiros — imprimir sem decimais.
- **Saída:** valores separados por espaço, uma linha por linha da matriz.
- Ver na Figure 2.15 uma simulação deste EP.

#### 2.12.4.3 📌 Exemplos

| Entrada    | Saída   | Observação                                                                                                                                |
|------------|---------|-------------------------------------------------------------------------------------------------------------------------------------------|
| 4          | 2 2 2 2 | A distância Chessboard é $\max(\ dx\ , \ dy\ )$ . O único pixel objeto é $(2, 2) = 0$ ; os demais armazenam sua distância mínima até ele. |
| 4          | 2 1 1 1 |                                                                                                                                           |
| chessboard | 2 1 0 1 |                                                                                                                                           |
| 0 0 0 0    | 2 1 1 1 |                                                                                                                                           |
| 0 0 0 0    |         |                                                                                                                                           |
| 0 0 1 0    |         |                                                                                                                                           |
| 0 0 0 0    |         |                                                                                                                                           |

#### 2.12.4.4 📌 Observações finais

- Como a imagem tem **apenas um objeto de um pixel**, a distância de cada pixel de fundo é simplesmente a distância desse pixel ao único ponto objeto.
- A implementação pode usar força bruta (percorrer todos os pixels da imagem e calcular a distância diretamente), pois  $L$  e  $C$  são pequenos nos casos de teste.
- Este problema é um aquecimento para a Transformada de Distância geral, que será trabalhada em capítulos posteriores com múltiplos objetos e algoritmos otimizados.

```
%%writefile EP02_04.py
# Código Python
```

```
Writing EP02_04.py
```

```
TestSuite("EP02_04.py").run()
```




Figura 2.15: Simulador: Ajuste de Brilho e Contraste

### 2.12.5 EP02\_05 Translação de Imagem

Nesta atividade, você deve implementar o deslocamento espacial de uma imagem. A translação move cada pixel da imagem original para uma nova posição com base em um vetor de deslocamento.

- Leia dois inteiros  $L$  e  $C$ , representando as dimensões da matriz.
- Leia dois inteiros  $t_x$  (deslocamento horizontal) e  $t_y$  (deslocamento vertical).
- Leia os valores inteiros da matriz original.
- Calcule a nova posição  $(x', y')$  para cada pixel  $(x, y)$  original.
- Imprima a matriz resultante com as mesmas dimensões da original.
- Ver na Figure 2.16 uma simulação deste EP.

#### Importante:

- **Preenchimento:** Pixels que “entram” na imagem devido ao deslocamento e não possuem correspondente na original devem ser preenchidos com 0 (preto).
- **Descarte:** Pixels que, após a translação, ficarem fora dos limites da matriz  $(0 \dots L - 1$  ou  $0 \dots C - 1)$  devem ser ignorados.
- **Coordenadas:** Considere  $x$  como o índice da linha e  $y$  como o índice da coluna.

#### 2.12.5.1 Deslocamento Espacial

Transladar uma imagem significa mover todos os seus pontos por uma distância fixa em direções especificadas. Matematicamente, usando coordenadas homogêneas, a operação é descrita como:

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & t_x \\ 0 & 1 & t_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

Que resulta nas equações simples:

- $x' = x + t_x$
- $y' = y + t_y$

### 2.12.5.2 Tarefa (especificação para VPL)

#### Entrada:

A primeira linha contém  $L$ .

A segunda linha contém  $C$ .

A terceira linha contém os inteiros  $t_x$  e  $t_y$ .

As linhas seguintes contêm os elementos da matriz  $L \times C$ .

#### Saída:

A matriz resultante com as mesmas dimensões  $L \times C$  após o deslocamento.

### 2.12.5.3 Exemplos

| Entrada                                   | Saída                   | Observação                                                                                                                                                                                                                                                     |
|-------------------------------------------|-------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 2<br>2<br>1 1<br>10 20<br>30 40           | 0 0<br>0 10             | <b>Deslocamento</b> ( $t_x = 1, t_y = 1$ ):<br>Cada pixel move uma posição para a direita (horizontal) e uma para baixo (vertical). O pixel $(0, 0) = 10$ vai para o destino $(1, 1)$ (canto inferior direito). As posições vazias são preenchidas com 0.      |
| 3<br>3<br>-1 0<br>1 2 3<br>4 5 6<br>7 8 9 | 2 3 0<br>5 6 0<br>8 9 0 | <b>Deslocamento</b> ( $t_x = -1, t_y = 0$ ): Cada pixel move uma posição para a esquerda (horizontal). A primeira coluna original (1, 4, 7) é descartada, as demais colunas movem-se para a esquerda, e a última coluna resultante é preenchida com zeros (0). |

```
%%writefile EP02_05.py
# Código Python
```

```
Writing EP02_05.py
```

```
TestSuite("EP02_05.py").run()
```

### 2.12.6 EP02\_06 Rotação de Imagem

Nesta atividade, você deve implementar a rotação de uma imagem em torno do seu centro geométrico. Esta operação requer o mapeamento de coordenadas e o uso de técnicas de interpolação para determinar os novos valores dos pixels.






Figura 2.16: Simulador: Translação (tx, ty)

- Leia dois inteiros  $L$  e  $C$ , representando as dimensões da matriz.
- Leia um valor real  $\theta$  (ângulo em graus) e uma *string* representando o **método** de interpolação (**nearest** ou **bilinear**).
- Leia os valores inteiros da matriz original.
- Realize a rotação em torno do centro da imagem  $(L/2, C/2)$ .
- Imprima a matriz resultante com as mesmas dimensões da original.
- Ver na Figure 2.17 uma simulação deste EP.

#### 📌 Importante:

- **Mapeamento Inverso:** Para evitar “buracos” na imagem final, percorra cada pixel  $(x', y')$  da imagem de destino e calcule sua posição correspondente  $(x, y)$  na imagem original usando a matriz de rotação inversa.
- **Interpolação:**
  - **nearest:** Atribui o valor do pixel mais próximo da coordenada calculada.
  - **bilinear:** Calcula uma média ponderada baseada nos 4 vizinhos mais próximos.
- **Bordas:** Pixels cuja origem  $(x, y)$  caia fora dos limites da imagem original devem ser preenchidos com 0.

#### 2.12.6.1 🧠 Transformação por Ângulo

A rotação de um ponto  $(x, y)$  em relação à origem por um ângulo  $\theta$  é dada pela matriz de transformação. Para rotacionar em torno de um centro  $(x_c, y_c)$ , primeiro transladamos o centro para a origem, rotacionamos e transladamos de volta:

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta & x_c \\ \sin \theta & \cos \theta & y_c \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x - x_c \\ y - y_c \\ 1 \end{bmatrix}$$

**Dica:** Use o mapeamento inverso para garantir que todos os pixels da imagem de saída sejam preenchidos corretamente.

### 2.12.6.2 Tarefa (especificação para VPL)

#### Entrada:

A primeira linha contém  $L$ .

A segunda linha contém  $C$ .

A terceira linha contém o ângulo `theta` (em graus) e o método `interp` (`nearest` ou `bilinear`).

As linhas seguintes contêm os elementos da matriz  $L \times C$ .

#### Saída:

A matriz rotacionada com  $L$  linhas e  $C$  colunas.

### 2.12.6.3 Exemplos

| Entrada     | Saída       | Observação                                                                                                                                                                                                               |
|-------------|-------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 2           | 3 1         | Rotação de 90° horário: a coluna 0 vira a linha 0 (de baixo para cima). $(0, 0) = 1 \rightarrow (1, 0)$ ,<br>$(1, 0) = 3 \rightarrow (0, 0)$ ,<br>$(0, 1) = 2 \rightarrow (1, 1)$ ,<br>$(1, 1) = 4 \rightarrow (0, 1)$ . |
| 2           | 4 2         |                                                                                                                                                                                                                          |
| 90 nearest  |             |                                                                                                                                                                                                                          |
| 1 2         |             |                                                                                                                                                                                                                          |
| 3 4         |             | Rotação de 45°: o pixel central permanece 255; os vizinhos diretos recebem valor interpolado $\approx 180$ por bilinear; os cantos permanecem 0.                                                                         |
| 3           | 0 180 0     |                                                                                                                                                                                                                          |
| 3           | 180 255 180 |                                                                                                                                                                                                                          |
| 45 bilinear | 0 180 0     |                                                                                                                                                                                                                          |
| 0 0 0       |             |                                                                                                                                                                                                                          |
| 0 255 0     |             |                                                                                                                                                                                                                          |
| 0 0 0       |             |                                                                                                                                                                                                                          |

```
%%writefile EP02_06.py
# Código Python
```

```
Writing EP02_06.py
```

```
TestSuite("EP02_06.py").run()
```

### 2.12.7 EP02\_07 Redimensionamento (Escala)

Nesta atividade, você deve implementar o redimensionamento de uma imagem utilizando fatores de escala. Diferente da subamostragem simples, aqui utilizaremos técnicas de interpolação para permitir tanto a ampliação quanto a redução da imagem.




Figura 2.17: Simulador: Rotação (ângulo )

- Leia dois inteiros **L** e **C**, representando as dimensões da matriz original.
- Leia dois valores reais  $s_x$  (escala nas linhas) e  $s_y$  (escala nas colunas).
- Leia uma *string* representando o **método** de interpolação (**nearest** ou **bilinear**).
- Leia os valores inteiros da matriz original.
- Calcule as novas dimensões:  $L' = \text{round}(L \times s_x)$  e  $C' = \text{round}(C \times s_y)$ .
- Imprima a matriz resultante com as novas dimensões.
- Ver na Figure 2.18 uma simulação deste EP.

#### **Importante:**

- **Mapeamento Inverso:** Para cada pixel  $(x', y')$  da imagem de destino, encontre a posição correspondente na origem usando  $(x, y) = (x'/s_x, y'/s_y)$ .
- **Interpolação:**
  - **nearest:** Seleciona o valor do pixel mais próximo (arredondamento das coordenadas).
  - **bilinear:** Realiza uma interpolação linear dupla entre os quatro pixels vizinhos mais próximos na imagem original.
  - **Bordas:** Certifique-se de que o mapeamento não tente acessar índices fora do intervalo  $[0, L - 1]$  e  $[0, C - 1]$ .

#### 2.12.7.1 Interpolação para Ampliação/Redução

Redimensionar uma imagem por fatores  $(s_x, s_y)$  exige o preenchimento de vazios (na ampliação) ou a fusão de informações (na redução). O método de interpolação define a qualidade visual do resultado:

| Método          | Funcionamento                                   | Efeito Visual                                 |
|-----------------|-------------------------------------------------|-----------------------------------------------|
| <b>Nearest</b>  | Pega o valor do vizinho mais próximo.           | Rápido, mas gera efeito “pixelado” ou blocos. |
| <b>Bilinear</b> | Média ponderada dos 4 vizinhos $(2 \times 2)$ . | Suaviza a imagem, reduzindo o serrilhamento.  |

#### 2.12.7.2 Tarefa (especificação para VPL)

##### Entrada:

A primeira linha contém **L**.

A segunda linha contém **C**.

A terceira linha contém os fatores **sx** e **sy**.

A quarta linha contém o método **interp** (**nearest** ou **bilinear**).

As linhas seguintes contêm os elementos da matriz  $L \times C$ .

##### Saída:

A matriz redimensionada com dimensões  $L' \times C'$ .

#### 2.12.7.3 Exemplos

| Entrada | Saída   | Observação                                                                                                  |
|---------|---------|-------------------------------------------------------------------------------------------------------------|
| 2       | 1 1 2 2 | Ampliação 2×: cada pixel original é replicado em um bloco 2×2. A imagem 2 × 2 vira 4 × 4.                   |
| 2       | 1 1 2 2 |                                                                                                             |
| 2.0 2.0 | 3 3 4 4 |                                                                                                             |
| nearest | 3 3 4 4 |                                                                                                             |
| 1 2     | 10      | Redução 0.5×: a imagem 2 × 2 vira 1 × 1. Com nearest, o único pixel de saída amostra a posição (0, 0) = 10. |
| 3 4     |         |                                                                                                             |
| 2       |         |                                                                                                             |
| 2       |         |                                                                                                             |
| 0.5 0.5 |         |                                                                                                             |
| nearest |         |                                                                                                             |
| 10 20   |         |                                                                                                             |
| 30 40   |         |                                                                                                             |




Figura 2.18: Simulador: Redimensionamento (Nearest vs Bilinear)

```
%%writefile EP02_07.py
# Código Python
import numpy as np
from morph import mm

# 1. Leitura das dimensões, fatores e método
l = int(input())
c = int(input())
sx, sy = map(float, input().split())
interp = input().strip()

# 2. Leitura da imagem original
img = mm.readImg(l, c)

# 3. Novas dimensões
```

```

l_new = round(l * sx)
c_new = round(c * sy)

# 4. Redimensionamento usando mm.resize
# cv2.resize usa (largura, altura) = (colunas, linhas)
resultado = mm.resize(img, (c_new, l_new), method=interp)

# 5. Exibição
print(mm.drawImg(resultado))

```

Writing EP02\_07.py

TestSuite("EP02\_07.py").run()

### 2.12.8 EP02\_08 ✂ Cisalhamento (Shear)

Nesta atividade, você deve implementar a transformação de cisalhamento em uma imagem. O cisalhamento é uma transformação afim que desloca cada ponto em uma direção fixada, por um valor proporcional à sua distância de uma reta paralela a essa direção, resultando em um efeito de inclinação.

- Leia dois inteiros **L** e **C**, representando as dimensões da matriz.
- Leia dois valores reais  $sh_x$  (cisalhamento horizontal) e  $sh_y$  (cisalhamento vertical).
- Leia uma *string* representando o **método** de interpolação (**nearest** ou **bilinear**).
- Leia os valores inteiros da matriz original.
- Aplique a transformação mantendo o tamanho original da imagem (cortando o que ultrapassar os limites).
- Imprima a matriz resultante com as dimensões  $L \times C$ .
- Ver na Figure 2.19 uma simulação deste EP.

#### 📌 Importante:

- **Mapeamento Inverso:** Para cada pixel  $(x', y')$  da imagem de destino, calcule a posição correspondente na origem  $(x, y)$  utilizando a matriz de cisalhamento inversa.
- **Preenchimento:** Coordenadas que resultarem em posições fora da matriz original devem ser preenchidas com 0.
- **Coordenadas:** Para fins desta implementação, considere  $x$  como o índice da linha e  $y$  como o índice da coluna.

#### 2.12.8.1 🧠 Distorção Afim

O cisalhamento altera a geometria da imagem inclinando seus eixos. A relação entre as coordenadas originais  $(x, y)$  e as transformadas  $(x', y')$  é dada por:

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & sh_x & 0 \\ sh_y & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

Isso resulta nas equações:

- $x' = x + sh_x \cdot y$
- $y' = y + sh_y \cdot x$



### 2.12.8.2 Tarefa (especificação para VPL)

#### Entrada:

A primeira linha contém  $L$ .

A segunda linha contém  $C$ .

A terceira linha contém os fatores `shx` e `shy`.

A quarta linha contém o método `interp` (`nearest` ou `bilinear`).

As linhas seguintes contêm os elementos da matriz  $L \times C$ .

#### Saída:

A matriz transformada com as mesmas dimensões  $L \times C$ .

### 2.12.8.3 Exemplos

| Entrada  | Saída    | Observação                                                                                                                                                                                                                                                                       |
|----------|----------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 3        | 10 20 30 | Cisalhamento horizontal: linha $i$ desloca $\lfloor i \cdot 0.5 \rfloor$ pixels. Linha $0 \rightarrow 0\text{px}$ , linha $1 \rightarrow 0\text{px}$ , linha $2 \rightarrow 1\text{px}$ . Os pixels deslocados para fora são descartados e as posições vazias preenchidas com 0. |
| 3        | 0 40 50  |                                                                                                                                                                                                                                                                                  |
| 0.5 0.0  | 0 0 70   |                                                                                                                                                                                                                                                                                  |
| nearest  |          |                                                                                                                                                                                                                                                                                  |
| 10 20 30 |          |                                                                                                                                                                                                                                                                                  |
| 40 50 60 |          | Cisalhamento vertical: coluna $j$ desloca $\lfloor j \cdot 1.0 \rfloor$ pixels para baixo. Coluna $0 \rightarrow 0\text{px}$ (inalterada), coluna $1 \rightarrow 1\text{px}$ : 20 desce para $(1, 1)$ e $(0, 1)$ fica 0.                                                         |
| 70 80 90 |          |                                                                                                                                                                                                                                                                                  |
| 2        | 10 0     |                                                                                                                                                                                                                                                                                  |
| 2        | 30 20    |                                                                                                                                                                                                                                                                                  |
| 0.0 1.0  |          |                                                                                                                                                                                                                                                                                  |
| nearest  |          |                                                                                                                                                                                                                                                                                  |
| 10 20    |          |                                                                                                                                                                                                                                                                                  |
| 30 40    |          |                                                                                                                                                                                                                                                                                  |

```
%%writefile EP02_08.py
# Código Python
```

```
Writing EP02_08.py
```

```
TestSuite("EP02_08.py").run()
```

### 2.12.9 EP02\_09 Transformação Afim Genérica

Nesta atividade, você deve implementar uma transformação afim arbitrária em uma imagem. Esta operação é a generalização de todas as transformações lineares (escala, rotação, cisalhamento) combinadas com a translação, permitindo manipulações geométricas complexas através de uma única matriz.

- Leia dois inteiros  $L$  e  $C$ , representando as dimensões da matriz.
- Leia **seis valores reais** ( $a, b, t_x, c, d, t_y$ ) que compõem a matriz de transformação afim  $2 \times 3$ .
- Leia uma *string* representando o **método** de interpolação (`nearest` ou `bilinear`).
- Leia os valores inteiros da matriz original.
- Aplique a transformação mantendo o tamanho original  $L \times C$ .




Figura 2.19: Simulador: Cisalhamento (shx, shy)

- Imprima a matriz resultante.
- Ver na Figure 2.20 uma simulação deste EP.

#### 📌 Importante:

- **Mapeamento Inverso:** Para calcular o valor de cada pixel na imagem de destino, você deve utilizar a **inversa** da matriz de transformação afim fornecida para encontrar a coordenada correspondente na imagem original.
- **Preenchimento:** Coordenadas calculadas que caiam fora dos limites  $[0, L - 1]$  e  $[0, C - 1]$  da imagem original devem resultar em um pixel de valor **0**.
- **Flexibilidade:** Esta implementação deve ser capaz de realizar qualquer uma das tarefas anteriores (translação, rotação, etc.) bastando alterar os parâmetros da matriz.

#### Dica:

```
flags = cv2.INTER_NEAREST if interp == 'nearest' else \
        cv2.INTER_CUBIC   if interp == 'bicubic'   else \
        cv2.INTER_LANCZOS4 if interp == 'lanczos'  else \
        cv2.INTER_LINEAR

r = cv2.warpAffine(img, M, (C, L), flags=flags)
```

#### 2.12.9.1 🧠 Combinação de Operações

A transformação afim preserva pontos, retas e planos. No processamento de imagens, ela mapeia a posição  $(x, y)$  para  $(x', y')$  seguindo o sistema:

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} + \begin{bmatrix} t_x \\ t_y \end{bmatrix}$$

Ou, de forma compacta em coordenadas homogêneas:

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} a & b & t_x \\ c & d & t_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

### 2.12.9.2 Tarefa (especificação para VPL)

#### Entrada:

A primeira linha contém  $L$ .

A segunda linha contém  $C$ .

A terceira linha contém seis floats:  $a$   $b$   $t_x$   $c$   $d$   $t_y$ .

A quarta linha contém o método `interp` (`nearest` ou `bilinear`).

As linhas seguintes contêm os elementos da matriz  $L \times C$ .

#### Saída:

A matriz transformada com as dimensões originais  $L \times C$ .

### 2.12.9.3 Exemplos

| Entrada                 | Saída | Observação                                                                                                                                                                                                                                                                              |
|-------------------------|-------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 2                       | 15 20 | Translação fracionária<br>( $t_x = 0.5, t_y = 0.5$ ): cada pixel de saída $(i, j)$ amostra a posição $(i + 0.5, j + 0.5)$ da entrada via bilinear. Ex: $(0, 0)$ interpola os quatro vizinhos $\rightarrow 15$ .                                                                         |
| 2                       | 25 30 |                                                                                                                                                                                                                                                                                         |
| 1.0 0.0 0.5 0.0 1.0 0.5 |       |                                                                                                                                                                                                                                                                                         |
| bilinear                |       |                                                                                                                                                                                                                                                                                         |
| 10 20                   |       | Escala $2\times$ via matriz afim<br>( $a = 2, d = 2$ ): cada pixel de saída $(i, j)$ amostra a posição $(2i, 2j)$ da entrada com nearest. Ex:<br>$(0, 2) \rightarrow (0, 4)$ fora da imagem $\rightarrow$ nearest clipa para $(0, 2) = 3...$<br>aguarda confirmação da lógica de borda. |
| 30 40                   |       |                                                                                                                                                                                                                                                                                         |
| 3                       | 1 1 2 |                                                                                                                                                                                                                                                                                         |
| 3                       | 1 1 2 |                                                                                                                                                                                                                                                                                         |
| 2.0 0.0 0.0 0.0 2.0 0.0 | 4 4 5 |                                                                                                                                                                                                                                                                                         |
| nearest                 |       |                                                                                                                                                                                                                                                                                         |
| 1 2 3                   |       |                                                                                                                                                                                                                                                                                         |
| 4 5 6                   |       |                                                                                                                                                                                                                                                                                         |
| 7 8 9                   |       |                                                                                                                                                                                                                                                                                         |

```
%%writefile EP02_09.py
# Código Python
```

```
Writing EP02_09.py
```

```
TestSuite("EP02_09.py").run()
```




Figura 2.20: Simulador: Transformação Afim (matriz 2x3)

### 2.12.10 EP02\_10 🎯 Correção de Perspectiva (Homografia)

Nesta atividade, você deve implementar a transformação de perspectiva, também conhecida como homografia. Diferente das transformações afins, a perspectiva não preserva o paralelismo, permitindo “retificar” objetos inclinados, como documentos ou placas capturados em ângulos oblíquos.

- Leia dois inteiros **L** e **C**, representando as dimensões da matriz original.
- Leia **quatro pares de coordenadas**  $(x, y)$  representando os cantos do quadrilátero de origem (objeto distorcido).
- Leia **quatro pares de coordenadas**  $(x, y)$  representando os cantos do quadrilátero de destino (onde o objeto deve ser mapeado).
- Leia os valores da matriz original.
- Calcule a matriz de homografia  $3 \times 3$  e aplique a transformação.
- Imprima a matriz resultante com as dimensões de saída especificadas.
- Ver na Figure 2.21 uma simulação deste EP.

#### 📌 Importante:

- **Graus de Liberdade:** A homografia possui 8 graus de liberdade (o nono elemento da matriz  $3 \times 3$  é uma constante de normalização, geralmente 1), exigindo no mínimo 4 pontos correspondentes para ser calculada.
- **Projeção:** Após multiplicar as coordenadas pela matriz, é necessário dividir os resultados  $x'$  e  $y'$  pela componente homogênea  $w$  para retornar ao plano 2D.
- **Uso de Bibliotecas:** Para esta tarefa, você pode utilizar as funções `cv2.getPerspectiveTransform` para obter a matriz e `cv2.warpPerspective` para aplicar a transformação, ou implementar o sistema linear e o mapeamento inverso manualmente para um desafio extra.

```
# Dimensões de saída: bounding box dos pontos destino + 1
w = int(max(pts2[:, 0])) + 1; h = int(max(pts2[:, 1])) + 1
# M = cv2.getPerspectiveTransform(pts1, pts2)
# dst = cv2.warpPerspective(img, M, (w, h))
# ou
dst = mm.perspective_transform(img, pts1, pts2, size=(w, h))
```

#### 2.12.10.1 🧠 Deformação não-afim

Enquanto transformações afins mapeiam paralelogramos em paralelogramos, a homografia mapeia qualquer quadrilátero em outro quadrilátero. Isso é essencial para visão computacional:

| Operação             | Característica         | Aplicação Típica                                |
|----------------------|------------------------|-------------------------------------------------|
| <b>Homografia</b>    | Projeção em plano      | Correção de documentos, escaneamento de placas. |
| <b>Ponto de Fuga</b> | Convergência de linhas | Reconstrução 3D a partir de imagens 2D.         |
| <b>Warping</b>       | Deformação de malha    | Estabilização de vídeo e panoramas (stitching). |

#### 2.12.10.2 📌 Exemplos

| Entrada         | Saída           | Observação                                                                                                                                                                                    |
|-----------------|-----------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 4 4             | 10 20 30 40     | As 4 primeiras linhas após as dimensões são os pontos de origem; as 4 seguintes são os destinos. Com pontos idênticos, a transformação de perspectiva é a identidade e a imagem é preservada. |
| 0 0             | 50 60 70 80     |                                                                                                                                                                                               |
| 3 0             | 90 100 110 120  |                                                                                                                                                                                               |
| 0 3             | 130 140 150 160 |                                                                                                                                                                                               |
| 3 3             |                 |                                                                                                                                                                                               |
| 0 0             |                 |                                                                                                                                                                                               |
| 3 0             |                 |                                                                                                                                                                                               |
| 0 3             |                 |                                                                                                                                                                                               |
| 3 3             |                 |                                                                                                                                                                                               |
| 10 20 30 40     |                 |                                                                                                                                                                                               |
| 50 60 70 80     |                 |                                                                                                                                                                                               |
| 90 100 110 120  |                 |                                                                                                                                                                                               |
| 130 140 150 160 |                 |                                                                                                                                                                                               |
|                 |                 |                                                                                                                                                                                               |
|                 |                 |                                                                                                                                                                                               |
|                 |                 |                                                                                                                                                                                               |




Figura 2.21: Simulador: Correção de Perspectiva (Homografia)

```
%%writefile EP02_10.py
# Código Python

Writing EP02_10.py

TestSuite("EP02_10.py").run()
```



### 2.12.11 EP02\_11 🏆 Correção de Perspectiva (Homografia) em Imagem Real

Nesta atividade, o objetivo é aplicar a transformação de perspectiva (homografia) para “retificar” um objeto inclinado em uma fotografia real. Você lidará com a imagem de um jornal, onde a grade de um jogo de Sudoku está distorcida devido ao ângulo em que a foto foi capturada.

Seu programa deve ler os parâmetros de entrada do terminal, carregar a imagem, calcular a matriz de homografia  $3 \times 3$ , aplicar a transformação geométrica e exibir um indicador global de validação.

- Leia dois inteiros **L** e **C**, representando as dimensões de linhas e colunas (altura e largura) que a imagem retificada de saída deve ter.
- Leia **quatro pares de coordenadas**  $(x, y)$  via terminal, representando os quatro cantos do quadrilátero de origem (o Sudoku distorcido na imagem original).
- Calcule automaticamente os **quatro pares de coordenadas de destino** utilizando as dimensões  $L$  e  $C$  fornecidas, mapeando os cantos para as extremidades da nova imagem:  $(0, 0)$ ,  $(C - 1, 0)$ ,  $(0, L - 1)$  e  $(C - 1, L - 1)$ .
- Carregue a imagem local **sudoku.png** e converta-a para tons de cinza (grayscale).
- Calcule a matriz de homografia e aplique a transformação espacial na imagem.
- **Saída:** Calcule e imprima a **soma de todos os pixels** da imagem resultante.

#### 📌 Importante:

- **Arquivo de entrada:** A imagem **sudoku.png** deve estar na mesma pasta do script. O programa deve lê-la diretamente do disco (ex: usando `mm.read("sudoku.png")` ou `cv2.imread`).
- **Ordem dos Pontos:** Garanta que a leitura dos 4 pontos de origem e a geração dos 4 pontos de destino sigam rigorosamente a mesma ordem dos cantos: Superior-Esquerdo (TL), Superior-Direito (TR), Inferior-Esquerdo (BL) e Inferior-Direito (BR).
- **Dimensões no OpenCV:** Lembre-se que funções como `cv2.warpPerspective` esperam o tamanho da imagem de saída no formato `(largura, altura)`, o que equivale a `(C, L)`.
- **Interpolação:** Para garantir a consistência matemática da soma dos pixels com o corretor automático, utilize a interpolação bilinear padrão (`flags=cv2.INTER_LINEAR`).
- **Créditos:** A imagem utilizada é “Sudoku en periódico” de Héctor Rodríguez, sob licença **CC BY 2.0**.

#### 2.12.11.1 🧠 Contexto do Problema

A homografia possui 8 graus de liberdade, exigindo no mínimo 4 correspondências de pontos para ser calculada. Ao contrário de transformações afins, ela mapeia qualquer quadrilátero em outro quadrilátero, permitindo que linhas que convergem para pontos de fuga voltem a ser paralelas:

| Operação                  | Característica                     | Aplicação Típica                                                              |
|---------------------------|------------------------------------|-------------------------------------------------------------------------------|
| <b>Homografia</b>         | Projeção entre planos              | Retificação de documentos, escaneamento de placas e QR Codes.                 |
| <b>Mapeamento Inverso</b> | Varredura do destino para a origem | Evita “buracos” ou pixels vazios na imagem final retificada.                  |
| <b>Warping</b>            | Reamostragem espacial              | Correção de distorção de lentes e montagem de panoramas ( <i>stitching</i> ). |

### 2.12.11.2 📌 Exemplos

| Entrada                                              | Saída    | Observação                                                                                                                                                                                                                   |
|------------------------------------------------------|----------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 500<br>500<br>100 120<br>420 95<br>80 440<br>450 460 | 32982820 | As duas primeiras entradas são as dimensões de saída ( $L$ e $C$ ). As 4 linhas seguintes são as coordenadas $(x, y)$ dos cantos do Sudoku na imagem original + PAD. A saída é a soma total dos pixels da imagem retificada. |
| 200 200<br>100 120<br>420 95<br>80 440<br>450 460    | 5277150  |                                                                                                                                                                                                                              |
|                                                      |          |                                                                                                                                                                                                                              |
|                                                      |          |                                                                                                                                                                                                                              |
|                                                      |          |                                                                                                                                                                                                                              |
|                                                      |          |                                                                                                                                                                                                                              |

### 2.12.11.3 Aquisição da imagem do sudoku e conversão para níveis de cinza

A Figure 2.22 mostra a leitura da imagem original seguida da conversão para tons de cinza e redimensionamento para uma matriz de  $500 \times 500$  pixels, preparando os dados para a etapa seguinte. A correção de perspectiva, aplicada na Figure 2.23 via matriz de homografia, elimina as deformações causadas pelo ângulo da câmera e produz uma visão frontal e regular da grade do Sudoku.



Figura 2.22: Aquisição da imagem de um Sudoku à esquerda. À direita, conversão para tons de cinza e redimensionamento. Crédito: Héctor Rodríguez de Guardamar, Espanha (CC BY 2.0).

```
import cv2
import numpy as np

# --- 1. Carrega a imagem salva (sudoku.png) ---
img = mm.read("sudoku.png")          # BGR, 500x500

# --- 2. Padding para não cortar vértices ---
```

```

PAD = 60
img_pad = cv2.copyMakeBorder(
    img, PAD, PAD, PAD, PAD,
    cv2.BORDER_CONSTANT, value=[255, 255, 255]
)

# --- 3. Pontos de origem (cantos da grade na imagem expandida) ---
pts1 = np.float32([
    [100, 160], # TL
    [390, 45],  # TR
    [200, 580], # BL
    [570, 420], # BR
])
#      W      H

# --- 4. Pontos de destino (vista frontal 500x500) ---
SIZE = 500
pts2 = np.float32([
    [0, 0],
    [SIZE, 0],
    [0, SIZE],
    [SIZE, SIZE],
])

# --- 5. Homografia e retificação ---
img_rect = mm.perspective_transform(img_pad, pts1, pts2, size=(SIZE, SIZE))

# --- 6. Exibição ---
mm.show(
    [img_pad, img_rect],
    titles=["Original (com padding)", "Vista frontal retificada"],
    cols=2, figsize=(10, 6), axis=True
)

```




Figura 2.23: Correção de perspectiva: original e vista frontal retificada.




Figura 2.24: Simulador: correção de perspectiva do Sudoku.

```
%%writefile EP02_11.py  
# Código Python
```

```
Writing EP02_11.py
```

```
TestSuite("EP02_11.py").run()
```



## Capítulo 3

# Operações Espaciais: Intensidade, Histograma e Filtragem



Este capítulo aprofunda o processamento de imagens no domínio espacial, partindo da manipulação direta de pixels e histogramas para o realce de contraste, até a aplicação de filtros locais por convolução para suavização, redução de ruído e detecção de bordas. O objetivo é desenvolver a intuição matemática e computacional que sustenta grande parte dos algoritmos modernos de Visão Computacional.

### 3.1 Objetivos

Ao final deste capítulo, você será capaz de:

- **Manipular intensidade e pixels:** Executar operações aritméticas saturadas (`mm.addm`, `mm.subm`) e lógicas bit a bit (`mm.band`, `mm.bor`, `mm.bnot`) para combinação e seleção de regiões de interesse (ROI), e aplicar *alpha blending* (`mm.blend`) para fusão ponderada de imagens;
- **Processar histogramas:** Interpretar o histograma como diagnóstico tonal, aplicar equalização global (`mm.equalize`) e adaptativa (CLAHE), e realizar especificação de histograma para transferência de perfil tonal entre imagens;
- **Compreender fundamentos espaciais:** Entender vizinhança, *padding* de borda, e a diferença entre correlação cruzada (`mm.conv`) e convolução — incluindo por que kernels assimétricos como Sobel produzem resultados distintos nas duas operações;
- **Aplicar filtragem de suavização:** Utilizar o filtro de média (`mm.conv` com kernel uniforme) e o filtro Gaussiano (`cv2.GaussianBlur`) para redução de ruído, compreendendo a vantagem da ponderação radial e da separabilidade Gaussiana;
- **Aplicar filtragem de realce:** Usar o Laplaciano ( $w_4$  e  $w_8$ ) para realce isotrópico de bordas, o operador de Sobel para gradiente direcional ( $G_x$ ,  $G_y$ , magnitude e direção), e o *Unsharp Masking* para amplificação controlada de alta frequência pelo parâmetro  $k$ ;
- **Utilizar filtros de ordem:** Aplicar o filtro da mediana (`cv2.medianBlur`) para remoção eficaz de ruído sal e pimenta, compreendendo por que sua natureza não linear e robustez a outliers o tornam superior aos filtros lineares nesse cenário;
- **Resolver problemas práticos:** Encadear técnicas em pipelines de pré-processamento (ex.: CLAHE  $\rightarrow$  Gaussiano  $\rightarrow$  Canny) e utilizar as funções da biblioteca `morph.py` (`mm.conv`, `mm.histImg`, `mm.equalize`, `mm.drawImageKernel`) para análise e visualização didática de cada etapa.

### 3.2 Operações em Nível de Intensidade

O nível mais elementar de processamento de imagens atua diretamente sobre os valores dos pixels, sem considerar vizinhança. Essas operações — chamadas de **transformações de ponto** (*point operations*) — são as mais rápidas computacionalmente e formam a base para técnicas mais complexas.

Formalmente, uma transformação de ponto pode ser descrita como:



$$g(x, y) = T[f(x, y)] \quad (3.1)$$

onde  $f(x, y)$  é a imagem de entrada,  $g(x, y)$  é a saída e  $T$  é uma função aplicada a cada pixel individualmente.

### 3.2.1 Preparando o Ambiente Prático

O bloco a seguir carrega o módulo `morph.py` do repositório.

```
import os, importlib, urllib.request
import numpy as np
import matplotlib.pyplot as plt

BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph"
for f in ["morph.py"]:
    if not os.path.exists(f):
        urllib.request.urlretrieve(f"{BASE_URL}/{f}", f)

import morph
importlib.reload(morph)
from morph import mm

version = getattr(morph, "__version__", "local_file")
print(f" Ambiente pronto. Módulo 'morph' carregado (versão:{version}).")
```

Ambiente pronto. Módulo 'morph' carregado (versão: 1.1.5).

Como objeto de estudo ao longo deste capítulo, utilizaremos as imagens de vida selvagem apresentadas nas Figure 3.1 e Figure 3.3. A partir delas, exploraremos operações espaciais sobre intensidade, histogramas e filtragem, analisando seus efeitos no realce, na suavização, na redução de ruído e na detecção de bordas, de modo a compreender os fundamentos matemáticos e computacionais do PDI.

```
import os

# Fonte : https://commons.wikimedia.org/wiki/File:Carlos_Guilherme_Rodrigues_(76515283).jpeg
# Mapa : https://www.google.com/maps?q=-26.204734,28.226624

base = "https://upload.wikimedia.org/wikipedia/commons"
arquivo = "Carlos_Guilherme_Rodrigues_%2876515283%29.jpeg"
url = f"{base}/9/9b/{arquivo}"
caminho = "imagens/mandrill-exif.jpg"

# 1. Leitura com cache local
if not os.path.exists(caminho):
    os.makedirs("imagens", exist_ok=True)
    img_obj = mm.read(url, pil=True)
    mm.write(img_obj, caminho)
else:
    img_obj = mm.read(caminho, pil=True)

img_color = np.array(img_obj)
img_gray = mm.gray(img_color)

# 2. Diagnóstico de tipos, dimensões e acesso a pixels
print(f"\nTipo PIL : {type(img_obj)} | Dimensões (x,y): {img_obj.size}")
print(f"Tipo NumPy: {type(img_color)} | Dimensões [y,x,c]: {img_color.shape}")

# 3. Exibição
mm.show(img_color, scale=90)
```

Tipo PIL : <class 'PIL.JpegImagePlugin.JpegImageFile'> | Dimensões (x,y): (960, 540)  
 Tipo NumPy: <class 'numpy.ndarray'> | Dimensões [y,x,c]: (540, 960, 3)



Figura 3.1: *Mandrill* (*Mandrillus sphinx*) fotografado em ambiente natural na África do Sul. A imagem possui resolução de 500 px e contém metadados EXIF com coordenadas GPS aproximadas (-26.20473, 28.22662). Crédito: Carlos Guilherme Rodrigues (CC BY-SA 3.0).

### 3.2.2 Operações Aritméticas

Operações aritméticas entre imagens são amplamente usadas em PDI para combinar, comparar ou realçar informações. A **subtração de imagens** é especialmente poderosa para detectar diferenças entre dois quadros — por exemplo, na remoção de fundo estático em câmeras de vigilância:

$$g(x, y) = f_1(x, y) - f_2(x, y) \quad (3.2)$$

A **adição saturada** limita o resultado ao intervalo  $[0, 255]$ : valores acima de 255 são fixados em 255, evitando o *overflow* silencioso do tipo `uint8` (ex.:  $200 + 100 = 44$  em vez de 300). A **subtração saturada** aplica o mesmo princípio pelo lado inferior: valores negativos são fixados em 0.

#### ⚠ Saturação e *overflow*

Operações aritméticas em `uint8` sofrem *overflow* silencioso:  $200 + 100 = 44$  (não 300). As funções `mm.addm` e `mm.subm` usam `cv2.add` e `cv2.subtract`, que realizam saturação automática. Para o *blending*, converta para `float32` antes de operar e aplique `np.clip(..., 0, 255).astype(np.uint8)` ao final, pois a operação envolve pesos fracionários.

A Figure 3.2 demonstra adição de uma constante (clareamento) e subtração de uma constante (escurecimento com saturação em 0).

```
fundo = 60

img_add = mm.addm(img_gray, fundo)
img_sub = mm.subm(img_gray, fundo)

mm.show(
    [img_gray, img_add, img_sub],
    titles=["Original", "addm (+60)", "subm (-60)"],
    cols=3
)
```



Figura 3.2: Operações aritméticas saturadas: adição de constante (clareamento) e subtração de constante (escurecimento com saturação em 0).

### 3.2.3 Mistura Ponderada (*Alpha Blending*)

A **mistura ponderada** (*alpha blending*) combina duas imagens utilizando pesos complementares  $\alpha$  e  $(1 - \alpha)$ :

$$g(x, y) = \alpha f_1(x, y) + (1 - \alpha) f_2(x, y), \quad \alpha \in [0, 1] \quad (3.3)$$

Quando  $\alpha = 1$ , obtém-se apenas a imagem  $f_1$ ; quando  $\alpha = 0$ , apenas  $f_2$ . Valores intermediários produzem uma transição suave entre ambas, sendo amplamente utilizados em composição de imagens, sobreposição de camadas, marcas d'água e efeitos de fusão visual.

Para que a combinação produza um resultado coerente, é necessário alinhar previamente as regiões de interesse das imagens. Na Figure 3.4, utiliza-se um recorte do rosto do leopardo:

```
leo = img_gray_leo[250:-300, 100:-200]
```

e um recorte central da região facial do mandril:

```
mandrill = img_gray[100:400, 380:530]
```

As duas regiões são escolhidas de forma que olhos e estrutura facial permaneçam aproximadamente alinhados. Em seguida, o recorte do leopardo é redimensionado para coincidir com as dimensões do mandril antes da aplicação da mistura ponderada.

A operação é realizada em `float32` para evitar problemas de *overflow* durante as operações aritméticas, seguida de *clipping* e conversão final para `uint8`.

```
import os
from PIL.ExifTags import TAGS

base = "https://upload.wikimedia.org/wikipedia/commons"
arquivo = "Leopard_%28Panthera_pardus%29_portrait.jpg"
url = f"{base}/9/92/{arquivo}"
caminho = "imagens/leopardo.jpg"

# 1. Leitura com cache local
if not os.path.exists(caminho):
    os.makedirs("imagens", exist_ok=True)
    img_obj = mm.read(url, pil=True)
    mm.write(img_obj, caminho)
else:
    img_obj = mm.read(caminho, pil=True)

img_numpy = np.array(img_obj)
img_gray_leo = mm.gray(img_numpy)

# 2. Extração e conversão de GPS (Tag 34853)
```

```

exif = img_obj._getexif()
if exif and (gps := exif.get(34853)):
    to_dec = lambda dms, ref: float(
        -(dms[0]+dms[1]/60+dms[2]/3600) if ref in 'SW'
        else (dms[0]+dms[1]/60+dms[2]/3600)
    )
    lat, lon = to_dec(gps[2], gps[1]), to_dec(gps[4], gps[3])
    print(f"GPS Decimal: {lat:.6f}, {lon:.6f}")
    print(f"Maps: https://www.google.com/maps/search/?api=1&query={lat},{lon}")

# 3. Diagnóstico de tipos, dimensões e acesso a pixels
print(f"\nTipo PIL : {type(img_obj)} | Dimensões (x,y): {img_obj.size}")
print(f"Pillow (0,0): {img_obj.getpixel((0, 0))}")
print(f"Tipo NumPy: {type(img_numpy)} | Dimensões [y,x,c]: {img_numpy.shape}")
print(f"NumPy [0,0]: {img_numpy[0, 0]}")

# 4. Exibição
mm.show(img_numpy)

```

```

GPS Decimal: -19.140200, 23.814872
Maps: https://www.google.com/maps/search/?api=1&query=-19.1402,23.814872222222224

Tipo PIL : <class 'PIL.JpegImagePlugin.JpegImageFile'> | Dimensões (x,y): (1242, 1324)
Pillow (0,0): (192, 134, 86)
Tipo NumPy: <class 'numpy.ndarray'> | Dimensões [y,x,c]: (1324, 1242, 3)
NumPy [0,0]: [192 134 86]

```



Figura 3.3: Retrato de um leopardo (*Panthera pardus*) em ambiente natural. Crédito: C. Brück (CC BY-SA 4.0).

```

leo = img_gray_leo[250:-300, 100:-200]
mandrill = img_gray[100:400, 380:530]
img_leopardo = mm.resize(leo, (mandrill.shape[1], mandrill.shape[0]), method='bilinear')

alphas = [1.0, 0.8, 0.6, 0.4, 0.2, 0.0]
imgs_blend = []

```

```
titles_blend = []

for a in alphas:
    imgs_blend.append(mm.blend(mandrill, img_leopardo, alpha=a))
    titles_blend.append(f"={a:.1f}")

mm.show(imgs_blend, titles=titles_blend, cols=6, figsize=(18, 16))
```




Figura 3.4: *Alpha blending* entre recortes alinhados de mandrill e do leopardo (Figure 3.3) para diferentes valores de  $\alpha$ . Em  $\alpha=1$  vê-se apenas mandrill; em  $\alpha=0$ , apenas o leopardo; valores intermediários fundem os olhares das duas imagens proporcionalmente.

### 3.2.4 Operações Lógicas e Máscaras Bit a Bit

As operações lógicas bit a bit (AND, OR e NOT) atuam diretamente sobre os bits de cada pixel e são a base para criação e aplicação de **máscaras** (*masks*) — imagens binárias com apenas 0 (preto) e 255 (branco) usadas para isolar **Regiões de Interesse (ROI)**.

O comportamento de cada operação decorre da representação binária do 255 (11111111) e do 0 (00000000):

- **AND** com a máscara: onde  $m = 255$ , os bits originais são preservados; onde  $m = 0$ , o pixel é zerado. Resultado: recorte da ROI.
- **OR** com a máscara: onde  $m = 255$ , o pixel é forçado a branco; onde  $m = 0$ , o valor original é mantido. Resultado: iluminação da ROI.
- **NOT** (sem máscara): inverte todos os bits ( $g = 255 - f$ ), produzindo o negativo fotográfico da imagem.

A Figure 3.5 ilustra as três operações aplicadas à imagem do mandrill com uma máscara circular.

```
import cv2
h, w = img_gray.shape

# Máscara circular centrada na imagem
mask_circ = np.zeros((h, w), dtype=np.uint8)
cv2.circle(mask_circ, (w//2, h//2), min(h, w)//3 - 10, 255, -1)

# Operações via morph
img_not = mm.bnot(img_gray) # NOT: negativo fotográfico
img_and = mm.band(img_gray, mask_circ) # img_gray & mask_circ: preserva apenas a ROI circular
img_or = mm.bor(img_gray, mask_circ) # img_gray | mask_circ: ilumina a região da máscara

mm.show(
    [img_gray, img_and, img_or, img_not],
```



```
titles=["Original", "AND (ROI circular)", "OR (ilumina ROI)", "NOT (negativo)"],
cols=4
)
```




Figura 3.5: Operações lógicas bit a bit com máscara circular: AND (isolamento da ROI), OR (iluminação da ROI) e NOT (negativo).

### 3.3 Histograma de Imagens

O **histograma** de uma imagem em tons de cinza é uma função discreta que descreve a distribuição de frequências das intensidades:

$$h(r_k) = n_k, \quad k = 0, 1, \dots, L - 1 \quad (3.5)$$

onde  $r_k$  é o  $k$ -ésimo nível de intensidade,  $n_k$  é o número de pixels com essa intensidade e  $L$  é o total de níveis (tipicamente 256 para 8 bits). O histograma normalizado estima a probabilidade de cada nível:

$$p(r_k) = \frac{n_k}{MN} \quad (3.6)$$

onde  $MN$  é o total de pixels. Por ser uma **estatística global**, o histograma não carrega informação posicional, mas revela características essenciais como brilho médio, contraste e distribuição tonal. Na prática, `mm.hist(img)` retorna o vetor de contagens  $h(r_k)$ , que serve tanto para visualização (via `mm.histImg`) quanto para cálculos como **função de distribuição acumulada (CDF)** e equalização.

#### i Interpretação do Histograma

- **Estreito à esquerda:** imagem subexposta (escura).
- **Estreito à direita:** imagem superexposta (clara).
- **Concentrado no centro:** baixo contraste.
- **Distribuído por toda a faixa:** alto contraste, boa utilização dos tons disponíveis.

A Figure 3.6 apresenta o histograma da imagem do mandrill, bem como versões escurecida (`mm.subm`) e clareada (`mm.addm`). Observa-se o deslocamento da distribuição de intensidades para a esquerda e para a direita, respectivamente. Note que o intervalo representado no eixo  $x$  não corresponde necessariamente a toda a faixa de 0 a 255.

```
img_dark = mm.subm(img_gray, 80)
img_high = mm.addm(img_gray, 80)

images = [img_gray, img_dark, img_high]
titles = ["Original", "Escurecida (-80)", "Clareada (+80)"]

def hist_title(img, t):
    H = mm.hist(img)
    n0 = int(H[0])
    n255 = int(H[255]) if len(H) > 255 else 0
    return f"Histograma - {t}\n0:{n0:},px 255:{n255:},px"
```



```
mm.show(
    images + [mm.histImg(img) for img in images],
    titles=titles + [hist_title(img, t) for img, t in zip(images, titles)],
    rows=2, cols=3,
    figsize=(14, 8)
)
```




Figura 3.6: Histogramas da imagem original, de uma versão escurecida e de uma versão clareada. Os valores na segunda linha indicam a quantidade de pixels saturados em 0 (preto) e 255 (branco).

### 3.3.1 Equalização de Histograma

A **equalização de histograma** redistribui as intensidades para que o histograma resultante seja o mais uniforme possível. O mapeamento é dado pela **função de distribuição acumulada (CDF)**:

$$s_k = T(r_k) = (L - 1) \sum_{j=0}^k p(r_j) = \frac{L - 1}{MN} \sum_{j=0}^k n_j \quad (3.7)$$

A transformação é monotônica: níveis frequentes recebem intervalos maiores no domínio de saída (maior separação → mais contraste), enquanto níveis raros são comprimidos.

O algoritmo completo, em cinco etapas, é apresentado na Table 3.1.

Tabela 3.1: Algoritmo de equalização de histograma.

| Etapa | Operação                          | Fórmula                                                                      |
|-------|-----------------------------------|------------------------------------------------------------------------------|
| 1     | <b>Histograma</b>                 | $h[k] \leftarrow$ número de pixels com intensidade $k$ , $k = 0 \dots L - 1$ |
| 2     | <b>Probabilidade</b>              | $p[k] \leftarrow h[k]/MN$                                                    |
| 3     | <b>CDF</b>                        | $\text{cdf}[k] \leftarrow \sum_{j=0}^k p[j]$ (soma acumulada)                |
| 4     | <b>Look-Up Table (mapeamento)</b> | $\text{lut}[k] \leftarrow \text{round}(\text{cdf}[k] \times (L - 1))$        |

| Etapa | Operação         | Fórmula                                                    |
|-------|------------------|------------------------------------------------------------|
| 5     | <b>Aplicação</b> | $g[i, j] \leftarrow \text{lut}[f[i, j]]$ (para todo pixel) |

Note na Figure 3.7 que a equalização **redistribui** os tons existentes para posições mais espaçadas na faixa  $[0, L - 1]$ , mas não cria novos tons — a imagem equalizada continua com exatamente 3 tons distintos, agora em  $\{1, 5, 7\}$  em vez de  $\{2, 3, 4\}$ .

```
img5 = np.array([[3, 4, 2, 3, 4],
                 [4, 3, 3, 4, 3],
                 [2, 3, 4, 3, 2],
                 [3, 4, 3, 2, 3],
                 [4, 3, 2, 3, 4]], dtype=np.uint8)
L = 8 # 3 bits: níveis 0..7

# 1. Histograma com tamanho garantido até L
h = mm.hist(img5, 3) # B=3 → 2³=8 níveis, tamanho garantido

p = h / h.sum() # 2. Probabilidade de cada nível p[k] = h[k] / MN

cdf = np.cumsum(p) # 3. CDF normalizada ou
# cdf = np.zeros(len(p))
# cdf[0] = p[0]
# for k in range(1, len(p)):
#     cdf[k] = cdf[k-1] + p[k] # cdf[k] = Σ p[j], j=0..k

lut = np.round(cdf * (L - 1)).astype(np.uint8) # 4. LUT: mapeamento para [0, L-1]

img5_eq = lut[img5] # 5. Aplica LUT pixel a pixel ou, equivalente a:
# l, c = img5.shape
# img5_eq = np.zeros((l, c), dtype=np.uint8)
# for i in range(l):
#     for j in range(c):
#         img5_eq[i, j] = lut[img5[i, j]] # g[i,j] = lut[f[i,j]]

print("Imagem original (5×5, 3 bits):")
print(img5)
print()
header = f"{'k':>3} {'h[k]':>6} {'p[k]':>7} {'CDF[k]':>8} {'lut[k]':>7}"
print(header)
print("-" * len(header))
for k in range(L):
    print(f"{k:>3} {h[k]:>6} {p[k]:>7.4f} {cdf[k]:>8.4f} {lut[k]:>7}")
print()
print("Imagem equalizada (5×5):")
print(img5_eq)

# Conta tons distintos
tons_orig = len(np.unique(img5))
tons_eq = len(np.unique(img5_eq))

mm.show(
    [img5, img5_eq, mm.histImg(img5, L-1), mm.histImg(img5_eq, L-1)],
    titles=[f"Original ({tons_orig} tons: {sorted(np.unique(img5).tolist())})",
           f"Equalizada ({tons_eq} tons: {sorted(np.unique(img5_eq).tolist())})",
           "Histograma - Original",
           "Histograma - Equalizada"],
    rows=2, cols=2, figsize=(5, 4), dpi=100
```

Imagem original (5×5, 3 bits):



```
[[3 4 2 3 4]
 [4 3 3 4 3]
 [2 3 4 3 2]
 [3 4 3 2 3]
 [4 3 2 3 4]]
```

| k | h[k] | p[k]   | CDF[k] | lut[k] |
|---|------|--------|--------|--------|
| 0 | 0    | 0.0000 | 0.0000 | 0      |
| 1 | 0    | 0.0000 | 0.0000 | 0      |
| 2 | 5    | 0.2000 | 0.2000 | 1      |
| 3 | 12   | 0.4800 | 0.6800 | 5      |
| 4 | 8    | 0.3200 | 1.0000 | 7      |
| 5 | 0    | 0.0000 | 1.0000 | 7      |
| 6 | 0    | 0.0000 | 1.0000 | 7      |
| 7 | 0    | 0.0000 | 1.0000 | 7      |


Imagem equalizada (5×5):

```
[[5 7 1 5 7]
 [7 5 5 7 5]
 [1 5 7 5 1]
 [5 7 5 1 5]
 [7 5 1 5 7]]
```

Original (3 tons: [2, 3, 4])    Equalizada (3 tons: [1, 5, 7])



Histograma — Original



Histograma — Equalizada




Figura 3.7: Equalização de histograma em imagem 5×5 com 3 bits ( $L=8$ ): imagem original com tons concentrados em  $\{2,3,4\}$ , imagem equalizada com tons redistribuídos para  $\{1,5,7\}$ , e os respectivos histogramas evidenciando o espalhamento das frequências.

**Limitação:** a equalização global pode super-realçar ruídos e produzir contraste excessivo em regiões homogêneas. O **CLAHE** (*Contrast Limited Adaptive Histogram Equalization*) reduz esse problema ao aplicar a equalização em blocos locais (*tiles*) e limitar a altura dos picos do histograma antes da equalização.

A Figure 3.8 compara a imagem original, a equalização global via `mm.equalize` e o CLAHE do OpenCV, exibindo também os histogramas resultantes. Diferentemente da equalização global, que utiliza uma única transformação baseada na CDF de toda a imagem, o CLAHE adapta o contraste a cada região, sendo particularmente útil em imagens com iluminação não uniforme.

No exemplo, foi utilizado `clipLimit=2.0` e `tileGridSize=(32,32)`. O parâmetro `clipLimit` define o quanto os picos do histograma local podem crescer antes de serem cortados (*clipped*). No OpenCV, esse valor é um fator relativo: o limite real é aproximadamente calculado como `clipLimit × (número de pixels do bloco / número de níveis de cinza)`. Por exemplo, em um bloco com 4096 pixels e uma imagem de 8 bits (256 níveis de cinza), a frequência média por nível é  $4096/256 = 16$ . Assim, `clipLimit=2.0` permite picos de aproximadamente  $2 \times 16 = 32$  ocorrências antes do corte. As ocorrências excedentes não são descartadas: elas são redistribuídas entre os demais níveis de cinza do histograma, reduzindo a concentração excessiva em poucos níveis e evitando uma amplificação exagerada do contraste local. Valores menores limitam mais o contraste e reduzem a amplificação de ruído, enquanto valores maiores permitem um realce mais intenso, mas podem introduzir artefatos.

- `clipLimit=1.0`: realce suave e conservador;
- `clipLimit=2.0`: bom equilíbrio entre contraste e naturalidade;
- `clipLimit=4.0`: maior destaque para detalhes locais;
- `clipLimit=8.0`: contraste agressivo, com possível amplificação de ruído.

Assim, o CLAHE costuma produzir resultados mais naturais do que a equalização global, especialmente em imagens com sombras, reflexos ou iluminação desigual.

```
img_eq    = mm.equalize(img_gray)
clahe     = cv2.createCLAHE(clipLimit=2.0, tileGridSize=(32, 32))
img_clahe = clahe.apply(img_gray)

images = [img_gray, img_eq, img_clahe]
titles = ["Original", "mm.equalize (CDF)", "CLAHE"]

mm.show(
    images + [mm.histImg(img) for img in images],
    titles=titles + [f"Histograma - {t}" for t in titles],
    rows=2, cols=3,
    figsize=(14, 8)
)
```




Figura 3.8: Equalização de histograma: mm.equalize (global via CDF) vs. CLAHE (adaptativa com limitação de contraste). Os histogramas revelam o espalhamento progressivo das intensidades.

### 3.3.2 Especificação de Histograma

Enquanto a equalização impõe uma distribuição uniforme, a **especificação de histograma** (*histogram matching*) permite que o histograma da imagem de saída siga uma distribuição **arbitrária** — por exemplo, o histograma de outra imagem de referência.

O procedimento envolve três etapas:

1. Calcular a CDF da imagem de entrada:  $P_r(r_k)$ .
2. Calcular a CDF da imagem de referência:  $P_z(z_k)$ .
3. Para cada nível  $r_k$ , encontrar o nível  $z$  que minimiza  $|P_z(z) - P_r(r_k)|$ .

$$T(r_k) = \arg \min_z |P_z(z) - P_r(r_k)| \quad (3.8)$$

Na Figure 3.9, transferimos o perfil tonal do leopardo (Figure 3.3) para a imagem do mandrill — uma aplicação direta do conceito visto no *blending*: em vez de fundir pixels, aqui fundimos distribuições tonais.

```
img_leop_gray = mm.gray(img_numpy)

def hist_specify(src, ref):
    """Mapeia src para o perfil tonal de ref via CDF."""
    cdf_src = np.cumsum(mm.hist(src) / src.size)
    cdf_ref = np.cumsum(mm.hist(ref) / ref.size)
    lut = np.array([np.argmin(np.abs(cdf_ref - v)) for v in cdf_src], dtype=np.uint8)
    return lut[src]

img_spec = hist_specify(img_gray, img_leop_gray)

images = [img_gray, img_leop_gray, img_spec]
titles = ["Mandrill (original)", "Leopardo (referência)", "Mandrill → perfil do leopardo"]

mm.show(
    images + [mm.histImg(img) for img in images],
```

```

titles=titles + [f"Histograma - {t}" for t in titles],
rows=2, cols=3,
figsize=(12, 9)
)

```




Figura 3.9: Especificação de histograma: mandril mapeada para o perfil tonal do leopardo. A CDF da saída aproxima a CDF de referência.

### 3.4 Fundamentos Espaciais: Vizinhança, Convolução e *Kernels*

As operações de filtragem espacial não atuam em um único pixel isolado, mas em uma **vizinhança** ao seu redor. Para isso, utiliza-se uma pequena matriz de coeficientes denominada **kernel** (ou máscara), que percorre toda a imagem por meio de uma **janela deslizante** (*sliding window*).

As janelas mais comuns são  $3 \times 3$ ,  $5 \times 5$  e  $7 \times 7$ . Em uma janela  $3 \times 3$ , por exemplo, o pixel central é processado juntamente com seus oito vizinhos imediatos. Em cada posição da janela, os valores dos pixels são combinados com os coeficientes do *kernel*, produzindo um novo valor para o pixel central.

#### 3.4.1 Vizinhança

Considere uma janela  $3 \times 3$  centrada no pixel  $(x, y)$ :

$$\begin{bmatrix} (x-1, y-1) & (x, y-1) & (x+1, y-1) \\ (x-1, y) & (x, y) & (x+1, y) \\ (x-1, y+1) & (x, y+1) & (x+1, y+1) \end{bmatrix} \quad (3.9)$$

De forma geral, uma janela de tamanho  $(2a+1) \times (2b+1)$  abrange todos os pixels situados até  $a$  posições na horizontal e até  $b$  posições na vertical em relação ao pixel central. Assim, uma janela  $3 \times 3$  corresponde a



$a = b = 1$ , uma janela  $5 \times 5$  a  $a = b = 2$ , e assim por diante.

Matematicamente, a vizinhança é definida por

$$\mathcal{V}(x, y) = \{(x + s, y + t) : -a \leq s \leq a, -b \leq t \leq b\} \quad (3.10)$$

### 3.4.2 Tratamento de Bordas

Pixels próximos às bordas possuem parte de sua vizinhança fora da imagem. Para aplicar filtros nessas regiões, é necessário definir como os valores externos serão obtidos. As estratégias mais comuns são:

- **Zero-padding** (BORDER\_CONSTANT): completa a região externa com zeros.
- **Replicação** (BORDER\_REPLICATE): repete os valores da borda.
- **Reflexão** (BORDER\_REFLECT\_101): espelha os pixels vizinhos à borda.

O OpenCV utiliza, por padrão, BORDER\_REFLECT\_101, pois essa estratégia preserva melhor a continuidade dos níveis de cinza e reduz artefatos introduzidos pelo tratamento das bordas.

O exemplo a seguir compara os três métodos usando uma matriz  $3 \times 3$ . Observe como cada estratégia preenche os pixels externos necessários para que filtros  $3 \times 3$  possam ser aplicados também nos cantos da imagem.

```
import cv2
import numpy as np

img = np.array([
    [1, 2, 3],
    [4, 5, 6],
    [7, 8, 9]
], dtype=np.uint8)

bordas = {
    "CONSTANT (zero-padding)": cv2.BORDER_CONSTANT,
    "REPLICATE": cv2.BORDER_REPLICATE,
    "REFLECT_101": cv2.BORDER_REFLECT_101
}

print("Imagem original:")
print(mm.drawImg(img))

for k in [3, 5]:
    b = k // 2

    print(f"=== Kernel {k}x{k} ===")

    for nome, tipo in bordas.items():
        pad = cv2.copyMakeBorder(
            img, b, b, b, b,
            tipo,
            value=0
        )

        print(f"{nome}")
        print(mm.drawImg(pad))
```

```
Imagem original:
1 2 3
4 5 6
7 8 9

=== Kernel 3x3 ===
```

## CONSTANT (zero-padding)

```
0 0 0 0 0
0 1 2 3 0
0 4 5 6 0
0 7 8 9 0
0 0 0 0 0
```

## REPLICATE

```
1 1 2 3 3
1 1 2 3 3
4 4 5 6 6
7 7 8 9 9
7 7 8 9 9
```

## REFLECT\_101

```
5 4 5 6 5
2 1 2 3 2
5 4 5 6 5
8 7 8 9 8
5 4 5 6 5
```

## === Kernel 5x5 ===

## CONSTANT (zero-padding)

```
0 0 0 0 0 0 0
0 0 0 0 0 0 0
0 0 1 2 3 0 0
0 0 4 5 6 0 0
0 0 7 8 9 0 0
0 0 0 0 0 0 0
0 0 0 0 0 0 0
```

## REPLICATE

```
1 1 1 2 3 3 3
1 1 1 2 3 3 3
1 1 1 2 3 3 3
4 4 4 5 6 6 6
7 7 7 8 9 9 9
7 7 7 8 9 9 9
7 7 7 8 9 9 9
```

## REFLECT\_101

```
9 8 7 8 9 8 7
6 5 4 5 6 5 4
3 2 1 2 3 2 1
6 5 4 5 6 5 4
9 8 7 8 9 8 7
6 5 4 5 6 5 4
3 2 1 2 3 2 1
```

Observe que o resultado de um filtro pode variar significativamente conforme o tratamento adotado para as bordas da imagem.

Na biblioteca didática `morph.py`, os algoritmos implementados diretamente em Python (sem utilizar OpenCV ou *scikit-image*) não utilizam *padding*. Para cada pixel, em geral, os elementos da vizinhança são examinados individualmente, e apenas os vizinhos cujas coordenadas pertencem ao domínio da imagem participam do cálculo. Assim, nas regiões próximas às bordas, a vizinhança efetiva pode conter menos pixels do que a janela especificada.

### 3.4.3 Correlação e Convolução

Existem dois mecanismos matematicamente relacionados:

**Correlação cruzada** (*cross-correlation*) — o *kernel* é aplicado diretamente:

$$g(x, y) = \sum_{s=-a}^a \sum_{t=-b}^b w(s, t) f(x + s, y + t) \quad (3.11)$$

**Convolução bidimensional** — o *kernel* é rotacionado 180° antes da aplicação:

$$g(x, y) = \sum_{s=-a}^a \sum_{t=-b}^b w(s, t) f(x - s, y - t) \quad (3.12)$$

Para *kernels* simétricos (Gaussiano, Laplaciano, média) as duas operações produzem resultados idênticos. Para *kernels* assimétricos (Sobel, Prewitt) a diferença é significativa.

### 3.4.4 Correlação vs. Convolução no OpenCV

`cv2.filter2D` implementa **correlação**. Para convolução verdadeira com *kernel* assimétrico, rotacione o *kernel* 180° (`np.rot90(w, 2)`) antes de passar para `filter2D`.

#### 3.4.4.1 Correlação (*OpenCV*: `cv2.filter2D`)

```
import cv2
import numpy as np

# imagem 4x4
img = np.array([
    [ 1,  2,  3,  4],
    [ 5,  6,  7,  8],
    [ 9, 10, 11, 12],
    [13, 14, 15, 16]
], dtype=np.float32)

# kernel assimétrico
w = np.array([
    [0, 1, 2],
    [0, 0, 0],
    [0, 0, 0]
], dtype=np.float32)

corr = cv2.filter2D(
    img, -1, w, # -1 indica que o tipo da saída é o mesmo da entrada
    borderType=cv2.BORDER_CONSTANT
)

print("Imagem original:")
print(mm.drawImg(img))

print("Kernel:")
print(mm.drawImg(w))

print("Resultado da correlação:")
print(mm.drawImg(corr))
```

Imagem original:

|   |   |   |   |
|---|---|---|---|
| 1 | 2 | 3 | 4 |
|---|---|---|---|

|    |    |    |    |
|----|----|----|----|
| 5  | 6  | 7  | 8  |
| 9  | 10 | 11 | 12 |
| 13 | 14 | 15 | 16 |

Kernel:

|   |   |   |
|---|---|---|
| 0 | 1 | 2 |
| 0 | 0 | 0 |
| 0 | 0 | 0 |

Resultado da correlação:

|    |    |    |    |
|----|----|----|----|
| 0  | 0  | 0  | 0  |
| 5  | 8  | 11 | 4  |
| 17 | 20 | 23 | 8  |
| 29 | 32 | 35 | 12 |

O método `cv2.filter2D` realiza correlação, isto é, aplica o *kernel* exatamente na orientação fornecida.

#### 3.4.4.2 Convolução

```
import cv2
import numpy as np

# mesmo kernel
w_conv = np.rot90(w, 2)

conv = cv2.filter2D(
    img, -1, w_conv,
    borderType=cv2.BORDER_CONSTANT
)

print("Imagem original:")
print(mm.drawImg(img))

print("Kernel original:")
print(mm.drawImg(w))

print("Kernel rotacionado 180°:")
print(mm.drawImg(w_conv))

print("Resultado da convolução:")
print(mm.drawImg(conv))
```

Imagem original:

|    |    |    |    |
|----|----|----|----|
| 1  | 2  | 3  | 4  |
| 5  | 6  | 7  | 8  |
| 9  | 10 | 11 | 12 |
| 13 | 14 | 15 | 16 |

Kernel original:

|   |   |   |
|---|---|---|
| 0 | 1 | 2 |
| 0 | 0 | 0 |
| 0 | 0 | 0 |

Kernel rotacionado 180°:

|   |   |   |
|---|---|---|
| 0 | 0 | 0 |
| 0 | 0 | 0 |
| 2 | 1 | 0 |

Resultado da convolução:

|   |    |    |    |
|---|----|----|----|
| 5 | 16 | 19 | 22 |
|---|----|----|----|

|    |    |    |    |
|----|----|----|----|
| 9  | 28 | 31 | 34 |
| 13 | 40 | 43 | 46 |
| 0  | 0  | 0  | 0  |

A convolução utiliza o *kernel* rotacionado em 180°. Por isso, para reproduzir a definição matemática de convolução usando `cv2.filter2D`, é necessário aplicar previamente `np.rot90(w, 2)`.

Quando o *kernel* é simétrico (por exemplo, filtros de média ou Gaussianos), correlação e convolução produzem o mesmo resultado. A diferença aparece apenas para *kernels* assimétricos, como o exemplo apresentado.

### 3.4.5 O Papel do *Kernel*

Os coeficientes do *kernel* determinam completamente o efeito produzido pelo filtro, conforme resumido na Table 3.2.

Tabela 3.2: Interpretação típica dos coeficientes do *kernel*.

| Característica                                              | Efeito típico                           |
|-------------------------------------------------------------|-----------------------------------------|
| Coeficientes positivos com soma 1                           | Suavização ( <i>passa-baixa</i> )       |
| Soma igual a 0, com valores positivos e negativos           | Deteção de bordas ( <i>passa-alta</i> ) |
| Coeficiente central positivo dominante e vizinhos negativos | Realce de nitidez                       |
| Coeficientes assimétricos                                   | Gradiente direcional                    |

#### Exemplos:

Suavização:

$$\frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

Deteção de bordas:

$$\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$$

Realce de nitidez:

$$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$

Gradiente direcional (Sobel):

$$\begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

A Figure 3.10 demonstra o mecanismo passo a passo: para cada posição da janela, multiplica-se cada coeficiente do *kernel* pelo pixel correspondente da vizinhança e somam-se os produtos obtidos. O resultado é exatamente o valor definido pela Equation 3.11 para aquela posição da imagem. Embora as imagens produzidas por `mm.conv0` e `cv2.filter2D` (ou `mm.conv`) sejam visualmente muito semelhantes, a implementação baseada em OpenCV é milhares de vezes mais rápida, como mostrado a seguir.

### ⚠ Desempenho: laços Python vs. operações vetorizadas

A função `mm.conv0` implementa a correlação diretamente em Python por meio de laços aninhados. Embora essa abordagem seja adequada para fins didáticos, ela executa um grande número de operações e torna-se lenta para imagens maiores.

Já `mm.conv` utiliza `cv2.filter2D`, implementado em C++ e otimizado para operações matriciais. No exemplo apresentado, a versão vetorizada foi mais de **3000 vezes mais rápida** que a implementação didática, produzindo um resultado visualmente equivalente.

As diferenças numéricas observadas concentram-se principalmente nas bordas da imagem. Em `mm.conv0`, os pixels da borda permanecem inalterados, enquanto `mm.conv` utiliza uma estratégia de reflexão das bordas (`cv2.BORDER_REFLECT_101`, padrão do `cv2.filter2D`).

Por isso, `mm.conv0` deve ser utilizado para compreender o algoritmo, enquanto `mm.conv` é a opção recomendada para aplicações práticas.

```
import time

w_mean = np.ones((3,3), dtype=np.float32) / 9.0
img_gray = img_leop_gray
# Demonstração numérica em patch 5x5
patch = img_gray[250:255, 250:255].astype(np.float32)
roi = patch[0:3, 0:3]
print("Patch 5x5 (intensidades):")
print(patch.astype(np.int32))
print(f"\nKernel 3x3 de média:\n{w_mean}")
print(f"\nCorrelação no pixel central [1,1]: \
      {(w_mean * roi).sum():.1f} (original: {patch[1,1]:.0f})")

# Comparação de tempo na imagem completa
t0 = time.perf_counter()
img_conv0 = mm.conv0(img_gray, w_mean)
t_conv0 = time.perf_counter() - t0

t0 = time.perf_counter()
img_conv = mm.conv(img_gray, w_mean)
t_conv = time.perf_counter() - t0

diff = np.abs(img_conv0.astype(int) - img_conv.astype(int)).max()
print(f"\nTempos na imagem {img_gray.shape[0]}x{img_gray.shape[1]}:")
print(f"  mm.conv0 (laços Python): {t_conv0:.3f} s")
print(f"  mm.conv (cv2.filter2D): {t_conv:.5f} s")
print(f"  Aceleração: {t_conv0/t_conv:.0f}x mais rápido")
print(f"  Diferença máxima: {diff} (bordas com padding diferente)")

mm.show(
    [img_gray, img_conv0, img_conv],
    titles=["Original", f"conv0 ({t_conv0:.2f}s)", f"conv ({t_conv:.4f}s)"],
    cols=3
)
```

Patch 5x5 (intensidades):

```
[[ 91  95 108 116 114]
 [106 107 108 111 114]
 [102 103 107 112 116]
 [ 83  90 111 125 123]
 [ 79  88 110 126 124]]
```

Kernel 3x3 de média:

```
[[0.11111111 0.11111111 0.11111111]]
```



```
[0.11111111 0.11111111 0.11111111]
[0.11111111 0.11111111 0.11111111]]
```

Correlação no pixel central [1,1]: 103.0 (original: 107)

Tempos na imagem 1324x1242:

mm.conv0 (laços Python): 6.950 s

mm.conv (cv2.filter2D): 0.00114 s

Aceleração: 6085× mais rápido

Diferença máxima: 39 (bordas com padding diferente)



Figura 3.10: Correlação com *kernel* de média 3×3: versão didática (mm.conv0) vs. vetorizada (mm.conv via cv2.filter2D). A diferença máxima de 39 ocorre nas bordas.

### 3.4.6 Exemplo Numérico: Correlação Passo a Passo

Para tornar concreto o mecanismo da Equation 3.11, considere o *kernel* de média 3×3 ( $a = b = 1$ , todos os coeficientes =  $1/9 \approx 0,111$ ) aplicado ao *patch* 5×5 extraído da imagem do leopardo. A Figure 3.11 exhibe o *patch* com grade e destaca em amarelo a janela 3×3 centrada no pixel [1,1]:

```
patch = img_gray[250:255, 250:255]
B      = np.ones((3,3), dtype=np.uint8)

print("Patch 5x5 (intensidades):")
print(mm.drawImg(patch))

mm.drawImgKernel(patch, B, x=1, y=1, scale=40.0)
```

```
Patch 5x5 (intensidades):
 91  95 108 116 114
106 107 108 111 114
102 103 107 112 116
 83  90 111 125 123
 79  88 110 126 124
```




Figura 3.11: *Patch* 5×5 extraído da imagem do leopardo (posição [250:255, 250:255]). A janela amarela destaca a vizinhança 3×3 centrada no pixel [1,1] onde a correlação será calculada.

Para ilustrar o cálculo da correlação, considere o pixel na posição [1, 1] do *patch* 5×5 mostrado na Figure 3.11. Essa posição foi escolhida apenas por conveniência didática, pois possui uma vizinhança 3×3 completa ao seu redor.

Os valores dessa vizinhança correspondem à submatriz superior esquerda do *patch*:

$$\text{vizinhança} = \begin{bmatrix} 91 & 95 & 108 \\ 106 & 107 & 108 \\ 102 & 103 & 107 \end{bmatrix}$$

Aplicando a Equation 3.11 com o kernel de média:

$$g[1, 1] = \frac{91 + 95 + 108 + 106 + 107 + 108 + 102 + 103 + 107}{9} = \frac{927}{9} = 103$$

O resultado (103) é ligeiramente menor que o valor original do pixel central (107), pois a média incorpora vizinhos de menor intensidade, produzindo o efeito de suavização. Na prática, o algoritmo inicia o processamento em [0, 0] e repete esse mesmo cálculo para cada posição da imagem, deslocando a janela até cobrir todo o domínio.

## 3.5 Filtragem Espacial de Suavização

Os filtros de suavização (*smoothing filters*) atenuam variações bruscas de intensidade, reduzindo ruído e detalhes de alta frequência. São filtros **passa-baixa** — preservam as componentes de baixa frequência (estruturas grandes) e atenuam as de alta frequência (ruído, bordas).

### 3.5.1 Filtro de Média (*Box Filter*)

O filtro de média utiliza um *kernel* uniforme de tamanho  $n \times n$ , onde todos os coeficientes valem  $1/n^2$ :

$$w_{\text{média}} = \frac{1}{n^2} \begin{bmatrix} 1 & \cdots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \cdots & 1 \end{bmatrix}_{n \times n} \quad (3.13)$$

Cada pixel de saída é a média aritmética dos  $n^2$  pixels de sua vizinhança. Note que a soma dos coeficientes é sempre 1 — o brilho médio da imagem é preservado. *Kernels* maiores produzem suavização mais agressiva, mas borram progressivamente as bordas.

A Figure 3.12 mostra o efeito do filtro de média com *kernels*  $3 \times 3$ ,  $7 \times 7$  e  $15 \times 15$  sobre um detalhe da imagem do leopardo. Os resultados foram obtidos com `mm.blur`, que implementa o filtro de média por meio da função `cv2.blur`, equivalente à convolução da imagem com um *kernel* uniforme cujos coeficientes são  $h(x, y) = 1/N^2$ ; de forma equivalente, o mesmo resultado pode ser obtido com `mm.conv`, calculando ( $g = f * h$ ). À medida que o *kernel* aumenta, mais pixels contribuem para cada valor de saída, intensificando a suavização, reduzindo o ruído e tornando detalhes finos e bordas progressivamente mais borrados.

```
# Detalhe da região do olho
y0, y1, x0, x1 = 580, 740, 680, 900
crop = lambda img: img[y0:y1, x0:x1]

img_gray_crop = crop(img_gray)

sizes = [3, 7, 15]
imgs = [img_gray_crop] + \
    [mm.blur(img_gray_crop, k) for k in sizes] # ou
    #[mm.conv(img_gray_crop, np.ones((k,k), dtype=np.float32)/(k*k)) for k in sizes]
titles = ["Original"] + [f"Média {k}x{k}" for k in sizes]

mm.show(imgs, titles=titles, cols=4)
```




Figura 3.12: Filtro de média com *kernels* de tamanho crescente ( $3 \times 3$ ,  $7 \times 7$ ,  $15 \times 15$ ). O borramento das bordas aumenta com o tamanho do *kernel*.

### 3.5.2 Filtro Gaussiano

O filtro Gaussiano pesa os pixels da vizinhança de acordo com uma função Gaussiana bidimensional:

$$G(s, t) = \frac{1}{2\pi\sigma^2} e^{-\frac{s^2+t^2}{2\sigma^2}} \quad (3.14)$$

onde  $\sigma$  é o desvio padrão e controla o raio de influência. Pixels mais próximos do centro têm peso maior; pixels distantes são progressivamente ignorados.

A Figure 3.13 apresenta o *kernel* Gaussiano  $5 \times 5$  gerado para  $\sigma = 1$ . O *kernel* foi construído a partir do produto externo de dois vetores Gaussianos unidimensionais e posteriormente normalizado para que a soma de seus coeficientes seja igual a 1. Observa-se que os maiores pesos concentram-se no centro da matriz, decrescendo radialmente em direção às bordas. Essa distribuição faz com que os pixels centrais tenham maior influência no resultado da filtragem, contribuindo para uma suavização mais natural e com melhor preservação de bordas do que o filtro de média.

```
# Gera kernel Gaussiano 5x5 via cv2
k_gauss = cv2.getGaussianKernel(5, 1)
w_gauss = k_gauss @ k_gauss.T          # @ => multiplicação matricial: G(s,t) = G(s)·G(t)
w_gauss = w_gauss / w_gauss.sum()      # garante soma = 1

print("Kernel Gaussiano 5x5 (=1), normalizado:")
for row in w_gauss:
```

```
print(" " + " ".join(f"{v:.4f}" for v in row))
print(f"\nSoma dos coeficientes: {w_gauss.sum():.6f}")
print(f"Peso central vs. canto: {w_gauss[2,2]:.4f} vs. {w_gauss[0,0]:.4f} "
      f"({w_gauss[2,2]/w_gauss[0,0]:.1f}× maior)")

mm.drawImgPlt((w_gauss * 1000).astype(np.uint8), scale=40)
```

Kernel Gaussiano 5×5 (=1), normalizado:

```
0.0030  0.0133  0.0219  0.0133  0.0030
0.0133  0.0596  0.0983  0.0596  0.0133
0.0219  0.0983  0.1621  0.0983  0.0219
0.0133  0.0596  0.0983  0.0596  0.0133
0.0030  0.0133  0.0219  0.0133  0.0030
```

Soma dos coeficientes: 1.000000

Peso central vs. canto: 0.1621 vs. 0.0030 (54.6× maior)




Figura 3.13: *Kernel* Gaussiano 5×5 (=1): pesos normalizados, maiores no centro e decrescentes radialmente. A grade facilita a leitura de cada coeficiente.

### **i** Vantagem computacional da separabilidade

Considere um *kernel* quadrado de tamanho  $n \times n$ . Se esse filtro for separável (como o Gaussiano), a convolução 2D pode ser decomposta em duas convoluções 1D: uma horizontal e outra vertical. Nesse caso, o custo por pixel passa de aproximadamente  $O(n^2)$  operações (convolução 2D direta) para  $O(2n)$  operações (duas convoluções 1D). Assim, a complexidade é reduzida de forma significativa, tornando o processamento mais eficiente

Comparado ao filtro de média, o Gaussiano:

- **Preserva melhor as bordas** — a ponderação radial suaviza sem criar transições abruptas;
- **Não introduz anéis** (*ringing*) no domínio da frequência, pois a Gaussiana é sua própria transformada de Fourier (Capítulo 5);
- **É controlado por  $\sigma$**  — aumentar  $\sigma$  equivale a aumentar o raio de suavização de forma contínua e previsível.

A Figure 3.14 compara os filtros de média e Gaussiano aplicados à imagem do leopardo usando uma janela  $9 \times 9$ . O filtro de média foi implementado por convolução com um *kernel* uniforme, em que todos os 81 pixels da vizinhança possuem o mesmo peso ( $1/81$ ), enquanto o filtro Gaussiano foi obtido com `cv2.GaussianBlur`, utilizando pesos definidos por uma distribuição Gaussiana. Ambos reduzem ruído e suavizam a imagem, porém o filtro Gaussiano preserva melhor as bordas e os detalhes locais, como pode ser observado na região ampliada do olho.

A Figure 3.14 compara os filtros de média e Gaussiano aplicados a um detalhe da imagem do leopardo

com *kernels*  $9 \times 9$ . O filtro de média foi obtido com `mm.blur`, equivalente à convolução com um *kernel* uniforme cujos coeficientes valem  $1/81$ , enquanto o filtro Gaussiano foi obtido com `mm.gaussian`, equivalente à convolução com um *kernel* gerado a partir de uma distribuição Gaussiana. Ambos promovem suavização e redução de ruído, porém o filtro Gaussiano atribui maior peso aos pixels centrais da vizinhança, preservando melhor as bordas e os detalhes locais, como pode ser observado na região ampliada do olho.

```
# w_media9 = np.ones((9,9), dtype=np.float32) / 81.0
# img_media9 = mm.conv(img_gray, w_media9) # ou
img_media9 = mm.blur(img_gray, 9)
# img_gauss9 = cv2.GaussianBlur(img_gray, (9,9), 0) # ou
img_gauss9 = mm.gaussian(img_gray, 9, 0)

# Detalhe da região do olho
y0, y1, x0, x1 = 580, 740, 680, 900
crop = lambda img: img[y0:y1, x0:x1]

img_gray_crop = crop(img_gray)

mm.show(
    [crop(img_gray), crop(img_media9), crop(img_gauss9)],
    titles=["Detalhe: Original", "Média 9x9", "Gaussiano 9x9"],
    cols=3, figsize=(12, 8)
)
```



Figura 3.14: Comparação entre filtro de média e Gaussiano (*kernel*  $9 \times 9$ ,  $=0$ ). O Gaussiano preserva melhor as bordas, visível no detalhe do rosto.

### 3.6 Filtragem Espacial de Realce

Os filtros de realce (*sharpening filters*) enfatizam transições abruptas de intensidade, aumentando a nitidez e a visibilidade de bordas. São filtros **passa-alta** — amplificam as componentes de alta frequência (bordas, textura) e suprimem as de baixa frequência (regiões uniformes).

A intuição é simples: se subtrairmos de uma imagem sua versão suavizada (que contém apenas as baixas frequências), o que resta são as altas frequências — bordas e detalhes. Somando esse resíduo de volta à imagem original, o contraste local aumenta:

$$g = f + k(f - f_{\text{suave}}), \quad k > 0 \quad (3.15)$$

O Figure 3.15 ilustra esse processo em um sinal 1D sintético com três estruturas distintas: um degrau largo, um pico fino e uma rampa suave. No painel , o sinal original  $f(x)$ ; no , a versão suavizada  $f_{\text{suave}}(x)$  obtida por média móvel — note como o pico fino é atenuado. O painel exibe o resíduo  $f - f_{\text{suave}}$ , que retém apenas as transições abruptas. Por fim, o painel mostra  $g(x)$ : o pico, antes atenuado, é restaurado e amplificado

em relação ao original. Ajuste  $k$  e o tamanho da janela para observar o *trade-off* entre nitidez e amplificação de ruído.

Os filtros de realce formalizam essa ideia diretamente no *kernel*, sem precisar de duas etapas separadas.



Figura 3.15: Simulador: Filtragem Espacial de Realce 1D.

### 3.6.1 Laplaciano

O Laplaciano é um operador de **segunda derivada** isotrópico, ou seja, responde igualmente a variações em todas as direções, ao contrário de operadores de primeira derivada, como Sobel e Prewitt, que são direcionais:

$$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} \quad (3.16)$$

Uma propriedade importante da segunda derivada é que seu valor é **próximo de zero em regiões uniformes** e elevado nas transições de intensidade. Assim, ao subtrair o Laplaciano da imagem original, reforçam-se bordas e detalhes, aumentando o contraste local:

$$g(x, y) = f(x, y) - \nabla^2 f(x, y) \quad (3.17)$$

Na forma discreta, a segunda derivada em  $x$  é aproximada por  $f(x+1, y) - 2f(x, y) + f(x-1, y)$ , e analogamente em  $y$ . Somando as duas direções, obtém-se o *kernel*  $w_4$  (4-vizinhos) ou  $w_8$  (8-vizinhos, incluindo diagonais):



$$w_4 = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}, \quad w_8 = \begin{bmatrix} 1 & 1 & 1 \\ 1 & -8 & 1 \\ 1 & 1 & 1 \end{bmatrix} \quad (3.18)$$

### **i** Soma zero e centro negativo

Ambos os *kernels* têm **soma dos coeficientes igual a zero**: em regiões uniformes, a saída é 0 — o Laplaciano não altera o brilho médio, apenas detecta variações. O **centro negativo** indica que o pixel é comparado com seus vizinhos: quanto mais ele se destacar (para cima ou para baixo), maior o valor absoluto do Laplaciano naquele ponto.

No exemplo a seguir, o pixel central  $[1, 1] = 107$  possui vizinhos  $\{95, 106, 108, 103\}$ . Como esses valores são próximos entre si, a região é quase uniforme e o Laplaciano retorna um valor baixo, produzindo pouco realce. Em regiões de borda, onde há diferenças maiores entre o pixel central e seus vizinhos, o Laplaciano assume valores mais elevados (positivos ou negativos), e a operação de Equation 3.17 intensifica essas transições.

A Figure 3.16 ilustra o cálculo do Laplaciano com o *kernel*  $w_4$  em uma vizinhança  $3 \times 3$  destacada dentro de um *patch*  $5 \times 5$ . O exemplo mostra o valor obtido pelo operador e o correspondente pixel realçado na imagem de saída, que passa de 107 para 123.

```
patch = img_gray[250:255, 250:255]
w4 = np.array([[0, 1, 0],
               [1,-4, 1],
               [0, 1, 0]], dtype=np.float32)
B = np.ones((3,3), dtype=np.uint8)

p = patch.astype(np.float32)
lap_11 = int(p[0,1] + p[1,0] - 4*p[1,1] + p[1,2] + p[2,1])
real_11 = int(np.clip(p[1,1] - lap_11, 0, 255))

print("Patch original:")
print(mm.drawImg(patch))
print(f"Laplac. w4 em [1,1]: ", end="")
print(f"{p[0,1]:.0f} + {p[1,0]:.0f} - 4*{p[1,1]:.0f} + {p[1,2]:.0f} + {p[2,1]:.0f} = {lap_11}")
print(f"Pixel realçado [1,1]: {p[1,1]:.0f} - ({lap_11}) = {real_11}")

mm.drawImgKernel(patch, B, x=1, y=1, scale=40.0)
```

```
Patch original:
 91  95 108 116 114
106 107 108 111 114
102 103 107 112 116
 83  90 111 125 123
 79  88 110 126 124
```

```
Laplac. w4 em [1,1]: 95 + 106 - 4*107 + 108 + 103 = -16
Pixel realçado [1,1]: 107 - (-16) = 123
```




Figura 3.16: *Kernel* Laplaciano  $w_4$  aplicado ao *patch*  $5 \times 5$ : a janela amarela destaca a vizinhança  $3 \times 3$  onde o operador de segunda derivada é calculado.

A Figure 3.17 compara a aplicação dos *kernels* Laplacianos  $w_4$  e  $w_8$  em um recorte maior da imagem do leopardo. Para cada caso, são mostradas a resposta bruta do operador, que evidencia as bordas e transições de intensidade, e a imagem obtida após o realce por subtração do Laplaciano. Observa-se que o *kernel*  $w_8$ , por considerar também os vizinhos diagonais, produz uma resposta mais intensa e detecta variações em mais direções, resultando em um realce ligeiramente mais acentuado.

```
w4 = np.array([[0, 1, 0],
               [1,-4, 1],
               [0, 1, 0]], dtype=np.float32)
w8 = np.array([[1, 1, 1],
               [1,-8, 1],
               [1, 1, 1]], dtype=np.float32)

mm.show(
    [img_gray_crop, mm.laplacian_viz(img_gray_crop, w4), mm.laplacian(img_gray_crop, w4),
      img_gray_crop, mm.laplacian_viz(img_gray_crop, w8), mm.laplacian(img_gray_crop, w8)],
    titles=["Original", "Laplaciano w4", "Realce w4",
            "Original", "Laplaciano w8", "Realce w8"],
    rows=2, cols=3, figsize=(14, 8)
)
```



Figura 3.17: Laplaciano aplicado à imagem do leopardo: resposta bruta (bordas detectadas) com w4 e w8, e imagens realçadas pela subtração do Laplaciano. w8 é mais sensível às diagonais.

### 3.6.2 Operador de Sobel

O operador de Sobel estima as **derivadas parciais de primeira ordem** nas direções horizontal e vertical. Diferente do Laplaciano (segunda derivada), o Sobel é direcional e mais robusto ao ruído, pois cada *kernel* combina uma derivada com uma suavização Gaussiana perpendicular:

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} * f, \quad G_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} * f \quad (3.19)$$

$G_x$  detecta bordas **verticais** (variação na direção  $x$ );  $G_y$  detecta bordas **horizontais** (variação na direção  $y$ ). Os pesos  $\{1, 2, 1\}$  na direção perpendicular correspondem à suavização Gaussiana 1D, que reduz a sensibilidade ao ruído.

**i** Sobel é correlação, não convolução

Os *kernels* de Sobel são **assimétricos** — a rotação de  $180^\circ$  altera o resultado. `cv2.Sobel` implementa correlação cruzada (como `cv2.filter2D`). Para obter a derivada direcional correta, os sinais já estão definidos para correlação:  $G_x$  retorna valores positivos onde a intensidade cresce da esquerda para a direita.

A magnitude do **gradiente** combina os dois componentes, representando a força da borda independente de direção:

$$|\nabla f| = \sqrt{G_x^2 + G_y^2} \quad (3.20)$$

E a **direção** do gradiente (perpendicular à borda) é:

$$\theta = \arctan \left( \frac{G_y}{G_x} \right) \quad (3.21)$$

Para ilustrar numericamente, calcula-se  $G_x$  e  $G_y$  manualmente no pixel central  $[1, 1]$  do *patch* 5×5:

```
patch = img_gray[250:255, 250:255]
p = patch.astype(np.float32)

# Gx no pixel [1,1]: coluna direita - coluna esquerda (ponderada)
gx = (p[0,2] + 2*p[1,2] + p[2,2]) - (p[0,0] + 2*p[1,0] + p[2,0])

# Gy no pixel [1,1]: linha inferior - linha superior (ponderada)
gy = (p[2,0] + 2*p[2,1] + p[2,2]) - (p[0,0] + 2*p[0,1] + p[0,2])

mag = np.sqrt(gx**2 + gy**2)
theta = np.degrees(np.arctan2(gy, gx))

print("Patch 5x5:")
print(mm.drawImg(patch))
print(f"Gx em [1,1]: ({p[0,2]:.0f} + 2*{p[1,2]:.0f} + {p[2,2]:.0f}) \
      - ({p[0,0]:.0f} + 2*{p[1,0]:.0f} + {p[2,0]:.0f}) = {gx:.1f}")
print(f"Gy em [1,1]: ({p[2,0]:.0f} + 2*{p[2,1]:.0f} + {p[2,2]:.0f}) \
      - ({p[0,0]:.0f} + 2*{p[0,1]:.0f} + {p[0,2]:.0f}) = {gy:.1f}")

# Substituído o | pelo prefixo mag para não quebrar o interpretador de tabelas do Quarto
print(f"mag(Grad f) = sqrt({gx:.1f}^2 + {gy:.1f}^2) = {mag:.1f}")
print(f"Theta = arctan({gy:.1f}/{gx:.1f}) = {theta:.1f} graus")
```

Patch 5x5:

```
91 95 108 116 114
106 107 108 111 114
102 103 107 112 116
83 90 111 125 123
79 88 110 126 124
```

```
Gx em [1,1]: (108 + 2*108 + 107) - (91 + 2*106 + 102) = 26.0
Gy em [1,1]: (102 + 2*103 + 107) - (91 + 2*95 + 108) = 26.0
mag(Grad f) = sqrt(26.0^2 + 26.0^2) = 36.8
Theta = arctan(26.0/26.0) = 45.0 graus
```

O valor reduzido de  $|\nabla f|$  nesse *patch* confirma que a região é quase uniforme, pois o gradiente assume valores elevados apenas onde há mudanças significativas de intensidade. A Figure 3.18 aplica o operador de Sobel a um recorte maior da imagem do leopardo. São apresentadas as respostas horizontal ( $G_x$ ) e vertical ( $G_y$ ), obtidas por convolução com os respectivos *kernels* de Sobel, além da magnitude  $|\nabla f|$ , calculada a partir da combinação de ambas. Enquanto  $G_x$  destaca bordas verticais e  $G_y$  bordas horizontais, a magnitude evidencia bordas em qualquer direção.

```
def norm255(img):
    mn, mx = img.min(), img.max() #+1e-9 para evitar divisão por zero
    return ((img - mn) / (mx - mn + 1e-9) * 255).astype(np.uint8)

sobelx = cv2.Sobel(img_gray_crop, cv2.CV_64F, 1, 0, ksize=3)
sobely = cv2.Sobel(img_gray_crop, cv2.CV_64F, 0, 1, ksize=3)
magnitudo = np.sqrt(sobelx**2 + sobely**2)
direcao = np.degrees(np.arctan2(sobely, sobelx))

# magnitudo = mm.sobel(img_gray_crop) # ou, mas com clip em vez de norm255

mm.show()
```

```
[img_gray_crop, norm255(np.abs(sobelx)), norm255(np.abs(sobely)),
 norm255(magnitude), norm255(direcao % 180)],
titles=["Original", "Gx (bordas vert.)", "Gy (bordas horiz.)",
        "Magnitude |f|", "Direção (mod 180°)"],
cols=5
)
```



Figura 3.18: Operador de Sobel na imagem do leopardo: Gx detecta bordas verticais, Gy detecta bordas horizontais, e a magnitude  $|f|$  combina ambos, revelando todas as bordas independente de direção.

### 3.6.3 Operador de Prewitt

O operador de Prewitt é estruturalmente idêntico ao Sobel, mas substitui a ponderação Gaussiana  $\{1, 2, 1\}$  por pesos uniformes  $\{1, 1, 1\}$ :

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} * f, \quad G_y = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix} * f \quad (3.22)$$

A magnitude e a direção do gradiente seguem as mesmas equações do Sobel (Equation 3.20 e Equation 3.21). A diferença prática é que o Prewitt é ligeiramente mais sensível ao ruído — a suavização perpendicular uniforme pondera menos o pixel central da linha — mas computacionalmente mais simples. Em imagens com baixo ruído os resultados são equivalentes.

```
Kx = np.array([[-1,0,1],[-1,0,1],[-1,0,1]], dtype=np.float32)
Ky = np.array([[-1,-1,-1],[0,0,0],[1,1,1]], dtype=np.float32)
f = img_gray_crop.astype(np.float32)

mm.show(
    [img_gray_crop,
     norm255(np.abs(cv2.filter2D(f, -1, Kx))),
     norm255(np.abs(cv2.filter2D(f, -1, Ky))),
     mm.prewitt(img_gray_crop)],
    titles=["Original", "Gx", "Gy", "Magnitude |f|"],
    cols=4
)
```




Figura 3.19: Operador de Prewitt: Gx, Gy e magnitude — comparável ao Sobel, mas sem ponderação Gaussiana perpendicular.

### 3.6.4 Unsharp Masking (USM)

O *Unsharp Masking* é uma técnica clássica de realce de nitidez originária da fotografia analógica, hoje amplamente usada em software de edição de imagens. A ideia central é extrair as **componentes de alta frequência** da imagem (bordas e detalhes) e somá-las de volta à original com um peso  $k$ :

Tabela 3.3: Etapas do *Unsharp Masking*.

| Etapas | Operação                   | Descrição                                        |
|--------|----------------------------|--------------------------------------------------|
| 1      | $\bar{f} = f * G_{\sigma}$ | Suaviza com Gaussiana — retém baixas frequências |
| 2      | $m = f - \bar{f}$          | Máscara: diferença = altas frequências (bordas)  |
| 3      | $g = f + k \cdot m$        | Soma ponderada da máscara à original             |

Substituindo a etapa 2 na etapa 3, obtém-se a expressão compacta:

$$g = f + k(f - f * G_{\sigma}) = (1 + k)f - k(f * G_{\sigma}) \quad (3.23)$$

O parâmetro  $k$  controla a intensidade do realce:

- $k = 0$ : sem realce ( $g = f$ );
- $k = 1$ : USM clássico — duplica a contribuição das altas frequências;
- $k > 1$ : *High Boost Filtering* — amplificação além do dobro, útil para imagens muito borradas.

#### ⚠ Amplificação de ruído

O USM não distingue bordas de ruído — ambos são componentes de alta frequência. Para  $k$  elevado, o ruído presente na imagem é amplificado junto com as bordas. Por isso, é recomendável aplicar uma leve suavização antes do USM em imagens ruidosas, ou usar  $\sigma$  pequeno na Gaussiana.

Para ilustrar as etapas do USM, a Figure 3.20 aplica o método a um *patch*  $30 \times 30$  da imagem do leopardo, utilizando  $\sigma = 1$  e  $k = 1$ . Inicialmente, a imagem é suavizada por um filtro Gaussiano. Em seguida, a máscara de alta frequência é obtida pela diferença entre a imagem original e a suavizada. Por fim, essa máscara é somada à imagem original, reforçando bordas e detalhes. A figura apresenta as três etapas do processo e o resultado final do realce.

```
patch = img_gray_crop[35:65, 45:75]
k = 1.0

p = patch.astype(np.float32)
sigma = 1.0

# Etapa 1: suavização Gaussiana
ksize = int(6 * sigma + 1) | 1 # operador binário garante tamanho ímpar
p_suave = cv2.GaussianBlur(p, (ksize, ksize), sigma)

# Etapa 2: máscara de alta frequência
mascara = p - p_suave

# Etapa 3: realce
p_usm = np.clip(p + k * mascara, 0, 255).astype(np.uint8)

# p_usb = mm.usm(p, k) # ou

print(f"Pixel central [1,1]: original={int(p[1,1])} suave={p_suave[1,1]:.1f}")
```



```
f" mascara={mascara[1,1]:.1f} realcado={p_usm[1,1]}")

mm.show(
    [patch,
     p_suave.astype(np.uint8),
     np.clip(mascara + 128, 0, 255).astype(np.uint8), # tornar os valores negativos visíveis na figura
     p_usm],
    titles=["Patch original",
           f"Suavizado (={sigma})",
           "Máscara (alta freq., +128)",
           f"Realçado USM (k={k})"],
    cols=4, figsize=(12, 4)
)
```

Pixel central [1,1]: original=16 suave=20.2 mascara=-4.2 realcado=11




Figura 3.20: Realce de nitidez por *Unsharp Masking* na imagem do leopardo: a imagem suavizada é subtraída da original para gerar a máscara de alta frequência, que é então reintroduzida para realçar bordas e detalhes.

A Figure 3.21 aplica o método USM a um recorte maior da imagem do leopardo utilizando  $\sigma = 1$  e diferentes valores do fator de ganho  $k$ . Em todos os casos, a máscara de alta frequência é obtida pela diferença entre a imagem original e sua versão suavizada por filtro Gaussiano. O parâmetro  $k$  controla a intensidade do realce: valores menores produzem um aumento sutil de nitidez, enquanto valores maiores reforçam progressivamente bordas e detalhes. Observa-se que, para valores elevados de  $k$ , surgem halos ao redor das bordas e o ruído presente na imagem passa a ser amplificado.

```
ks = [0.5, 1.0, 3.0, 5.0, 8.0]

imgs = [img_gray_crop] + [mm.usm(img_gray_crop, k) for k in ks]
titles = ["Original"] + [f"USM k={k}" for k in ks]

mm.show(imgs, titles=titles, cols=3, rows=2, figsize=(14, 8))
```




Figura 3.21: *Unsharp Masking* na imagem do leopardo com  $\alpha=1$  e  $k$  variando de 0.5 a 8.0. Para  $k>2$  surgem artefatos nas bordas (halos) e o ruído de fundo começa a ser visível.

### 3.6.5 Detector de Canny

O Canny combina quatro etapas em sequência — suavização Gaussiana, gradiente de Sobel, supressão de não-máximos e histerese por duplo limiar — para produzir bordas **finas, binárias e conectadas**. Diferente de Sobel e Prewitt, o resultado não é um mapa de gradiente contínuo, mas uma máscara onde cada pixel é borda ou não.

O parâmetro central é o par de limiares ( $T_{low}, T_{high}$ ). Pixels com gradiente acima de  $T_{high}$  são bordas certas; abaixo de  $T_{low}$ , descartados. Os pixels ambíguos — entre os dois limiares — são decididos por **histerese**: tornam-se borda se estiverem conectados a uma borda certa, e descartados caso contrário. Isso evita tanto a perda de trechos fracos de bordas reais quanto a inclusão de ruído isolado. Uma heurística comum é  $T_{high} = 3 \times T_{low}$ .

```
mm.show(
    [img_gray_crop,
     mm.canny(img_gray_crop, 30, 90),
     mm.canny(img_gray_crop, 60, 180),
     mm.canny(img_gray_crop, 120, 240)],
    titles=["Original", "Canny (30/90)", "Canny (60/180)", "Canny (120/240)"],
    cols=4
)
```




Figura 3.22: Detector de Canny com diferentes pares de limiar: limiares baixos capturam mais bordas (inclusive ruído); limiares altos retêm apenas as bordas mais fortes.

### **i** Escolha dos limiares

Uma heurística comum é  $T_{high} = 3 \times T_{low}$ . Valores típicos dependem do intervalo de gradiente da imagem — `cv2.Canny` aceita valores absolutos em  $[0, 255]$ . Para imagens com contraste variável, calcular os limiares a partir de percentis da magnitude de Sobel é mais robusto do que valores fixos.

## 3.7 Filtros de Ordem: Filtro da Mediana

Os filtros de ordem (*order-statistic filters*) substituem o pixel central pelo valor de um **percentil** da distribuição de intensidades da vizinhança — ao contrário dos filtros lineares, que calculam combinações ponderadas. O mais importante é o **filtro da mediana**.

### 3.7.1 Ruído Impulsivo: Sal e Pimenta

O ruído **sal e pimenta** (*salt-and-pepper noise*) substitui pixels aleatórios por valores extremos: 0 (pimenta, preto) ou 255 (sal, branco). É comum em transmissão de imagens com erros de bit e em câmeras com sensores defeituosos.

Para entender por que os filtros lineares falham, considere uma vizinhança  $3 \times 3$  onde um único pixel foi corrompido para 255:

$$\text{vizinhança} = \begin{bmatrix} 102 & 98 & 105 \\ 100 & \mathbf{255} & 97 \\ 103 & 99 & 101 \end{bmatrix}$$

Tabela 3.4: Média vs. mediana com um pixel corrompido. A mediana ignora o outlier; a média é deslocada ~40 níveis.

| Método  | Cálculo                                                 | Resultado |
|---------|---------------------------------------------------------|-----------|
| Média   | $(102+98+\dots+255+\dots+101)/9$                        | 140       |
| Mediana | $\{97, 98, 99, 100, \mathbf{101}, 102, 103, 105, 255\}$ | 101       |

### **⚠** Por que filtros de média falham com ruído impulsivo?

A média é sensível a **outliers** — um único pixel com valor 255 em uma vizinhança de valor 100 eleva a saída para 140, espalhando o ruído pela imagem. A mediana, por ser um **estimador robusto**, seleciona o valor central da distribuição ordenada, descartando naturalmente os extremos sem nenhum ajuste especial.

O exemplo a seguir ilustra o comportamento da média e da mediana na presença de um pixel corrompido por ruído impulsivo. Observa-se que a média é fortemente influenciada pelo valor extremo (255), produzindo uma estimativa distante dos valores predominantes da vizinhança. Já a mediana permanece próxima do valor original da região, evidenciando sua maior robustez a *outliers* e justificando seu uso na remoção de ruído sal e pimenta.

```
# Exemplo numérico: média vs. mediana com pixel corrompido
vizinhanca = np.array([102, 98, 105, 100, 255, 97, 103, 99, 101])
print(f"Vizinhança: {sorted([int(x) for x in vizinhanca])}")
print(f"Média:      {vizinhanca.mean():.1f}  (deslocada pelo outlier 255)")
print(f"Mediana:    {int(np.median(vizinhanca))}  (ignora o outlier)")
print(f"Valor original: ~100")
```

```
Vizinhança: [97, 98, 99, 100, 101, 102, 103, 105, 255]
Média:      117.8  (deslocada pelo outlier 255)
Mediana:    101   (ignora o outlier)
Valor original: ~100
```

A Figure 3.23 apresenta o efeito do ruído sal e pimenta em diferentes densidades. O ruído foi gerado substituindo aleatoriamente uma fração dos pixels por valores mínimos (0, pimenta) e máximos (255, sal). À medida que a densidade aumenta de 2% para 10%, cresce a quantidade de pixels corrompidos, tornando a degradação visual mais evidente e dificultando a percepção de detalhes da imagem.

```
def add_salt_pepper(img, prob=0.05, seed=42):
    """Adiciona ruído sal e pimenta com probabilidade total prob."""
    noisy = img.copy()
    rnd = np.random.default_rng(seed).random(img.shape)
    noisy[rnd < prob / 2] = 0 # pimenta
    noisy[rnd > 1 - prob / 2] = 255 # sal
    n_corrompidos = int((rnd < prob/2).sum() + (rnd > 1-prob/2).sum())
    return noisy, n_corrompidos

probs = [0.02, 0.05, 0.10]
imgs_noise, titles_noise = [img_gray_crop], ["Original"]

for p in probs:
    noisy, n = add_salt_pepper(img_gray_crop, p)
    imgs_noise.append(noisy)
    titles_noise.append(f"Ruído {int(p*100)}%\n({n:,} pixels)")

mm.show(imgs_noise, titles=titles_noise, cols=4)
```




Figura 3.23: Ruído sal e pimenta com densidades crescentes (2%, 5%, 10%). O parâmetro *prob* indica a fração total de pixels corrompidos, metade sal (255) e metade pimenta (0).

### 3.7.2 Filtro da Mediana

O filtro da mediana substitui cada pixel pelo **valor mediano** dos pixels da sua vizinhança  $n \times n$ :

$$g(x, y) = \text{med}_{(s,t) \in \mathcal{V}_n} \{f(x + s, y + t)\} \quad (3.24)$$

O valor mediano é aquele que ocupa a posição central quando os  $n^2$  valores da vizinhança são ordenados. Para uma janela  $3 \times 3$  ( $n^2 = 9$  pixels), a mediana é o 5º valor da sequência ordenada.

Para ilustrar, considere o mesmo *patch*  $5 \times 5$  com um pixel corrompido artificialmente em  $[1, 1]$ :

```
patch = img_gray[250:255, 250:255].copy()
corrompido = patch.copy()
corrompido[1, 1] = 255 # injeta pixel sal no centro

# Vizinhança 3x3 centrada em [1,1]
viz_orig = sorted(patch[0:3, 0:3].ravel().tolist())
viz_corr = sorted(corrompido[0:3, 0:3].ravel().tolist())

print("Patch original:")
print(mm.drawImg(patch))
print("\nPatch com pixel corrompido [1,1]=255:")
print(mm.drawImg(corrompido))
print(f"\nVizinhança 3x3 original (ordenada): {viz_orig}")
print(f"Mediana original: {viz_orig[4]}")
print(f"\nVizinhança 3x3 corrompida (ordenada): {viz_corr}")
print(f"Mediana corrompida: {viz_corr[4]} ← ignora o 255")
print(f"Média corrompida: {np.mean(viz_corr):.1f} ← distorcida pelo 255")
```

```
Patch original:
 91  95 108 116 114
106 107 108 111 114
102 103 107 112 116
 83  90 111 125 123
 79  88 110 126 124
```

```
Patch com pixel corrompido [1,1]=255:
```

```
 91  95 108 116 114
106 255 108 111 114
102 103 107 112 116
 83  90 111 125 123
 79  88 110 126 124
```

```
Vizinhança 3x3 original (ordenada): [91, 95, 102, 103, 106, 107, 107, 108, 108]
Mediana original: 106
```

```
Vizinhança 3x3 corrompida (ordenada): [91, 95, 102, 103, 106, 107, 108, 108, 255]
Mediana corrompida: 106 ← ignora o 255
Média corrompida: 119.4 ← distorcida pelo 255
```

O exemplo confirma: mesmo com o pixel corrompido a 255, a mediana retorna o valor central correto — o *outlier* ocupa a última posição na ordenação e é descartado naturalmente.

Por ser baseada em ordenação e não em soma, a mediana possui três propriedades fundamentais que a diferenciam dos filtros lineares:

- **Robusta** ao ruído impulsivo — outliers vão para as extremidades da sequência ordenada e não afetam o valor central;
- **Preservadora de bordas** — transições abruptas de intensidade são mantidas, pois a mediana seleciona um valor que já existe na vizinhança, sem criar novos níveis intermediários;



- **Não linear** — não pode ser expressa como convolução, portanto `mm.conv` não se aplica; usa-se `cv2.medianBlur`.

A Figure 3.24 compara diferentes técnicas de remoção de ruído sal e pimenta aplicadas a uma imagem com 10% de pixels corrompidos. Foram avaliados os filtros Gaussiano, Média, Mediana, Bilateral e Morfológico (próximo capítulo), permitindo observar o compromisso entre remoção de ruído e preservação de detalhes. Em geral, os filtros de média e Gaussiano reduzem o ruído, mas tendem a borrar as bordas, enquanto a mediana apresenta melhor desempenho para ruído impulsivo. O filtro bilateral preserva melhor as bordas, e o filtro morfológico remove boa parte dos pixels corrompidos sem degradar excessivamente a estrutura da imagem.

```
# 10% de ruído para evidenciar diferenças entre filtros
noisy_5, _ = add_salt_pepper(img_gray_crop, prob=0.1)

# Filtros
f_gauss = cv2.GaussianBlur(noisy_5, (5, 5), 1.0)
f_media = mm.conv(noisy_5, np.ones((5, 5), dtype=np.float32) / 20.0)
f_median3 = cv2.medianBlur(noisy_5, 3)
f_median5 = cv2.medianBlur(noisy_5, 5)
f_bilat = cv2.bilateralFilter(noisy_5, d=9, sigmaColor=75, sigmaSpace=75)

# filtros morfológicos no próximo capítulo, mas já adiantados aqui para comparação
# B = cv2.getStructuringElement(cv2.MORPH_ELLIPSE, (3, 3))
# f_morf = cv2.morphologyEx( # apresentado no próximo capítulo
#     cv2.morphologyEx(noisy_5, cv2.MORPH_OPEN, B),
#     cv2.MORPH_CLOSE, B)
B = mm.secross() # elemento estruturante de caixa 3x3
f_morf = mm.asf(noisy_5, 'OC', B) # equivalente via morph

# MSE
def mse(a, b):
    return float(np.mean((a.astype(np.float32) - b.astype(np.float32))**2))

print(f"{'Filtro':<22} {'MSE':>8}")
print("-" * 32)
pares = [("Gaussiano 5x5", f_gauss),
         ("Média 5x5", f_media),
         ("Mediana 3x3", f_median3),
         ("Mediana 5x5", f_median5),
         ("Bilateral", f_bilat),
         ("Morf. open+close", f_morf)]
for nome, img in pares:
    print(f"{nome:<22} {mse(img_gray_crop, img):>8.2f}")

imgs = [img_gray_crop, noisy_5, f_gauss, f_media,
        f_median3, f_median5, f_bilat, f_morf]
titles = ["Original", "Ruído 10%", "Gaussiano 5x5", "Média 5x5",
         "Mediana 3x3", "Mediana 5x5", "Bilateral", "Morf. open+close"]

mm.show(
    imgs,
    titles=[f"Crop: {t}" for t in titles],
    cols=4, rows=2, figsize=(14, 8)
)
```

| Filtro        | MSE    |
|---------------|--------|
| Gaussiano 5x5 | 260.84 |
| Média 5x5     | 872.57 |
| Mediana 3x3   | 31.26  |



|                  |         |
|------------------|---------|
| Mediana 5×5      | 65.86   |
| Bilateral        | 1001.22 |
| Morf. open+close | 65.16   |




Figura 3.24: Comparação de filtros para remoção de ruído sal e pimenta (10%): Gaussiano, Média, Mediana, Bilateral e Morfológico. Linha superior: imagens completas; linha inferior: crop da região de interesse.

### 3.8 Aplicação Prática: Pré-processamento para Segmentação

Na prática, as técnicas deste capítulo raramente são usadas isoladamente. Um *pipeline* de **pré-processamento** típico combina várias etapas em sequência, adaptando-se ao tipo de imagem e à aplicação. A Figure 3.25 ilustra um *pipeline* completo:

1. **Equalização de histograma (CLAHE)**: normaliza o contraste independente das condições de iluminação;
2. **Filtro Gaussiano**: suaviza ruído de aquisição sem destruir bordas;
3. **Deteção de bordas (Sobel/Canny)**: extrai estruturas relevantes para segmentação.

#### **i** Ordem importa

A ordem das operações afeta o resultado final. Em geral: **(1) normalização de intensidade → (2) redução de ruído → (3) realce/segmentação**. Inverter a ordem pode amplificar ruído ou perder bordas antes de detectá-las.

```
# Etapa 1: CLAHE
clahe = cv2.createCLAHE(clipLimit=2.0, tileGridSize=(8, 8))
img_clahe = clahe.apply(img_gray_crop)

# Etapa 2: Gaussiano
img_gauss = cv2.GaussianBlur(img_clahe, (5, 5), 0)

# Etapa 3: Canny
edges = cv2.Canny(img_gauss, 50, 150)

# Comparação: pipeline vs. Canny direto
edges_direct = cv2.Canny(img_gray_crop, 50, 150)
```

```
mm.show(
    [img_gray_crop, img_clahe, img_gauss, edges, edges_direct],
    titles=["Original", "1. CLAHE", "2. Gaussiano", "3. Canny (pipeline)", "Canny (direto)"],
    cols=5
)
```



Figura 3.25: *Pipeline* de pré-processamento: CLAHE → Gaussiano → Canny. Cada etapa prepara a imagem para a seguinte, resultando em bordas limpas e bem definidas.

### 3.9 Resumo

Neste capítulo foram apresentadas as principais técnicas de processamento no domínio espacial, da manipulação direta de pixels até a filtragem por vizinhança:

- **Operações de ponto:** aritméticas saturadas (`mm.addm`, `mm.subm`) e lógicas bit a bit (`mm.band`, `mm.bor`, `mm.bnot`) para recorte de ROI e combinação de imagens; *alpha blending* (`mm.blend`) para fusão ponderada com peso  $\alpha \in [0, 1]$ .
- **Histograma:** função discreta de distribuição de intensidades; visualizado com `mm.histImg` e calculado com `mm.hist`; base para diagnóstico tonal e para as técnicas de equalização e especificação.
- **Equalização:** redistribuição automática das intensidades pela CDF (`mm.equalize`), com variante adaptativa CLAHE para controle local do contraste.
- **Especificação de histograma:** transferência do perfil tonal de uma imagem de referência via mapeamento inverso da CDF — generalização da equalização para distribuições arbitrárias.
- **Correlação e convolução:** mecanismo de janela deslizante implementado em `mm.conv` (`cv2.filter2D`); diferenciados pela rotação de  $180^\circ$  do *kernel* — relevante apenas para kernels assimétricos.
- **Filtros de suavização:** média (*kernel* uniforme, borra bordas proporcionalmente ao tamanho) e Gaussiano (ponderação radial, separável, sem *ringing*, preserva melhor as bordas).
- **Filtros de realce:** Laplaciano ( $w_4/w_8$ , segunda derivada isotrópica), Sobel (gradiente direcional de primeira ordem, com magnitude  $|\nabla f|$  e direção  $\theta$ ) e *Unsharp Masking* (amplificação das altas frequências com parâmetro  $k$ ).
- **Filtro da mediana:** não linear, robusto a outliers, preserva bordas — superior aos filtros lineares para ruído sal e pimenta.
- **Pipeline prático:** encadeamento CLAHE → Gaussiano → Canny como estratégia de pré-processamento; `mm.drawImgKernel` para visualização didática da janela deslizante.

O Capítulo 4 abordará a **morfologia matemática** (erosão, dilatação, abertura e fechamento), explorando em profundidade as funções `mm.ero` e `mm.dil` da biblioteca `morph.py`. Em seguida, o Capítulo 5 apresentará o **processamento no domínio da frequência**, com foco na Transformada de Fourier e em técnicas de filtragem espectral.

### 3.10 Uso do Gemini Notebook como Tutor Complementar

Nesta edição, incentivamos o uso do **Gemini Notebook** como ferramenta complementar de aprendizagem. Essa ferramenta de IA utiliza exclusivamente os documentos fornecidos pelo autor como base de conhecimento, garantindo respostas coerentes com o conteúdo do livro — incluindo as funções da biblioteca `morph.py` e os experimentos realizados neste capítulo.

Para cada capítulo, preparamos um projeto específico na plataforma com o PDF do capítulo, os *notebooks* e materiais auxiliares. Sugerimos explorar especialmente:

- **Guia de Estudo:** resumo estruturado dos conceitos, ideal para revisão antes de provas;
- **Conversa:** tire dúvidas sobre equalização, convolução, filtros e pipelines diretamente com o tutor;
- **Perguntas frequentes:** questões típicas sobre a diferença entre média e mediana, USM, Laplaciano vs. Sobel.

#### Estude com o Tutor Inteligente

Para interagir com o conteúdo deste capítulo, acesse o *link* a seguir. O ambiente contém materiais didáticos em diferentes formatos, gerados a partir do **PDF** do capítulo. Na plataforma, explore especialmente as opções **Guia de Estudo** e **Conversa** para aprofundar sua compreensão.

 **ACESSAR Gemini Notebook: CAPÍTULO 03**

#### Aviso sobre Conteúdo Gerado por IA

A IA é uma poderosa aliada nos estudos, mas o conteúdo gerado pode conter **erros ou imprecisões**. Consulte sempre **livros, artigos científicos e outras fontes acadêmicas confiáveis** para validar as informações. Sempre que possível, execute os exemplos práticos fornecidos neste capítulo para verificar os resultados.

## 3.11 Lista de Exercícios

1. (10%) Explique a diferença entre **convolução** e **correlação cruzada**. Para quais tipos de *kernel* os resultados são idênticos? Dê um exemplo de *kernel* assimétrico (como Sobel  $G_x$ ) e mostre numericamente que os resultados diferem aplicando-o ao patch  $5 \times 5$  do capítulo das duas formas.
2. (15%) Considere uma imagem  $5 \times 5$  com intensidades concentradas entre os níveis 3 e 5 (baixo contraste, 3 bits). Aplique manualmente o algoritmo de equalização da Table 3.1, preenchendo todas as colunas da tabela ( $k$ ,  $h[k]$ ,  $p[k]$ ,  $\text{cdf}[k]$ ,  $\text{lut}[k]$ ). Verifique o resultado com `mm.equalize`.
3. (15%) Usando `mm.conv`, aplique o filtro de média com kernels de tamanho  $3 \times 3$ ,  $9 \times 9$  e  $21 \times 21$  à imagem do mandrill. Para cada versão, calcule o **PSNR** (*Peak Signal-to-Noise Ratio*) em relação à original:

$$\text{PSNR} = 10 \log_{10} \left( \frac{255^2}{\text{MSE}} \right), \quad \text{MSE} = \frac{1}{MN} \sum_{i,j} (f - g)^2$$

Plote o PSNR em função do tamanho do kernel e explique o que a queda progressiva indica sobre a relação entre suavização e perda de informação.

4. (15%) Usando `add_salt_pepper` com densidade de 5%, aplique e compare: (a) `mm.conv` com média  $3 \times 3$ , (b) `cv2.GaussianBlur` com  $\sigma = 1$ , (c) `cv2.medianBlur` com janela  $3 \times 3$  e (d) `cv2.medianBlur` com janela  $5 \times 5$ . Exiba as imagens com `mm.show` em grade  $2 \times 4$  (linha 1: imagens, linha 2: histogramas via `mm.histImg`). Explique por que a mediana supera os filtros lineares usando o argumento da Table 3.4.
5. (15%) Implemente `mm.conv0` usando apenas operações NumPy vetorizadas — sem laços Python e sem `cv2.filter2D` — com o operador de *stride tricks* (`np.lib.stride_tricks.sliding_window_view`). Compare o resultado e o tempo de execução com `mm.conv0` (laços) e `mm.conv` (cv2) para kernels  $3 \times 3$  e  $15 \times 15$  na imagem do mandrill.
6. (15%) Aplique o *Unsharp Masking* com  $\sigma = 1$  e  $k \in \{0.5, 1.0, 2.0, 4.0\}$  usando a função `usm` do capítulo. Para cada valor de  $k$ : (a) calcule a diferença absoluta  $|g - f|$ , (b) exiba as imagens e as diferenças com `mm.show`, e (c) plote o histograma das diferenças com `mm.histImg`. Identifique a partir de qual  $k$  os artefatos (halos e amplificação de ruído) tornam-se visualmente inaceitáveis.

7. (15%) Escolha uma imagem de raio-X ou tomografia disponível publicamente (ex.: via `mm.read` de URL) e projete um pipeline de pré-processamento com pelo menos 4 etapas sequenciais, justificando cada escolha com base nos conceitos do capítulo. Exiba com `mm.show` em grade: imagem original, cada etapa intermediária e o resultado final com seus histogramas (`mm.histImg`).

## Referências do Capítulo

A fundamentação teórica deste capítulo baseia-se nas seguintes obras:

- Gonzalez; Woods (2018) para os conceitos de operações de intensidade, histograma, convolução e filtragem espacial.
- Szeliski (2022) para a visão computacional e aplicações práticas de filtragem.
- Bradski; Kaehler (2008) para a implementação prática com OpenCV e `morph.py`.



### 3.12 Parte Prática com Exercícios de Programação

#### Objetivo deste Caderno

O caderno permite desenvolver, validar, organizar e testar soluções de **Exercícios de Programação (EPs)** em ambientes interativos, como o Colab, com os mesmos casos de teste do Moodle, copiando para lá apenas na hora de registrar a nota oficial.

#### Download

Baixe `morph.py` e `testsuite.py` executando a célula abaixo:

```
import os, sys, importlib, inspect, urllib.request

BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph"
for f in ["morph.py", "testsuite.py"]:
    if not os.path.exists(f):
        urllib.request.urlretrieve(f"{BASE_URL}/{f}", f)

import morph, testsuite
importlib.reload(morph); importlib.reload(testsuite)
from morph import mm
from testsuite import TestSuite

print(f"\u2705 Ambiente pronto. Morph: {morph.__version__} | TestSuite: {testsuite.__version__}")
```

Ambiente pronto. Morph: 1.1.2 | TestSuite: 1.1.2

#### Executando os Testes

Para avaliar os testes, execute `TestSuite("EP03_01.extensão").run()` numa nova célula, trocando a extensão pela da linguagem usada (`.py`, `.java`, `.c`, `.cpp`, `.js` ou `.r`). O sistema baixa os casos de teste do GitHub, executa o programa e calcula a nota automaticamente.

Para testar código Python diretamente, sem salvar arquivo, use `run_code(codigo)` passando o código como *string* numa variável `codigo`:

```

codigo = """
from morph import mm
# ... seu código aqui ...
"""
TestSuite("EP03_01").run_code(codigo)

```

### 3.12.1 EP03\_01 + Adição Saturada de Constante

Em sistemas de vigilância por vídeo, câmeras em ambientes com iluminação variável produzem imagens subexpostas. O ajuste de brilho por **adição saturada de uma constante** é a operação mais simples para correção imediata, sendo aplicada em tempo real nos *chips* de câmeras embarcadas e em *pipelines* de pré-processamento de robôs móveis.

Ver na Figure 3.26 uma simulação deste EP.

#### 3.12.1.1 📋 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas).
2. **Constante:** Ler o inteiro  $k$  (valor a ser somado).
3. **Dados:** Ler os valores inteiros da matriz original linha a linha.
4. **Mapeamento:** Para cada pixel  $p$ , calcular o novo valor pela equação:

$$p' = \text{clip}(p + k)$$

5. **Saída:** Exibir a matriz resultante com dimensões  $L \times C$ .

#### 3.12.1.2 📌 Restrições Computacionais

- **Saturação (*Clipping*):** Os valores devem ser confinados ao intervalo  $[0, 255]$ :

$$\text{clip}(x) = \max(0, \min(255, x))$$

- **Tipo:** O resultado final deve ser inteiro (sem casas decimais).
- **$k$  pode ser negativo:** valores negativos escurecem a imagem; positivos clareiam.

#### 3.12.1.3 🧠 Fundamentação Teórica

| Parâmetro | Tipo    | Impacto Visual                                             |
|-----------|---------|------------------------------------------------------------|
| $k > 0$   | Inteiro | Clareia a imagem; pixels próximos de 255 saturam em branco |
| $k < 0$   | Inteiro | Escurece a imagem; pixels próximos de 0 saturam em preto   |
| $k = 0$   | Inteiro | Imagem inalterada                                          |

#### 3.12.1.4 📦 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .

- Linha 2: Inteiro  $C$ .
- Linha 3: Inteiro  $k$ .
- Linhas seguintes: Elementos inteiros da matriz original.

Saída:

- Matriz transformada em  $L$  linhas e  $C$  colunas, valores inteiros separados por espaço.

3.12.1.5 📌 Exemplos

| Entrada      | Saída       | Observação                        |
|--------------|-------------|-----------------------------------|
| 2            | 50 150 250  | Saturação em 255 nos pixels altos |
| 3            | 255 255 255 |                                   |
| 50           |             |                                   |
| 0 100 200    |             |                                   |
| 210 240 255  |             |                                   |
| 1            | 0 0 170 225 | Saturação em 0 nos pixels baixos  |
| 4            |             |                                   |
| -30          |             |                                   |
| 0 20 200 255 |             |                                   |




Figura 3.26: Simulador: Adição Saturada de Constante

```
%%writefile EP03_01.py
# Código Python

Writing EP03_01.py

TestSuite("EP03_01.py").run()
```



### 3.12.2 EP03\_02 Alpha *Blending* de Duas Imagens

Em medicina nuclear, imagens de diferentes modalidades (tomografia computadorizada e ressonância magnética) são fundidas para auxiliar no diagnóstico. A **mistura ponderada** (*alpha blending*) é a operação fundamental desse processo, permitindo ao radiologista controlar interativamente o peso de cada modalidade na imagem exibida.

Ver na Figure 3.27 uma simulação deste EP.

#### 3.12.2.1 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas).
2. **Parâmetro:** Ler o valor real  $\alpha \in [0, 1]$ .
3. **Dados:** Ler os valores inteiros da matriz  $f_1$  (imagem 1) e em seguida da matriz  $f_2$  (imagem 2).
4. **Mapeamento:** Para cada posição  $(i, j)$ , calcular:

$$g(i, j) = \text{clip}(\text{round}(\alpha \cdot f_1(i, j) + (1 - \alpha) \cdot f_2(i, j)))$$

5. **Saída:** Exibir a matriz resultante  $L \times C$ .

#### 3.12.2.2 Restrições Computacionais

- **Arredondamento:** Aplicar **round** antes da conversão para inteiro.
- **Saturação:** Confinar ao intervalo  $[0, 255]$  com  $\text{clip}(x) = \max(0, \min(255, x))$ .
- **Operação em float:** Realize a operação em ponto flutuante antes de arredondar.

#### 3.12.2.3 Fundamentação Teórica

| Valor de $\alpha$ | Resultado                         |
|-------------------|-----------------------------------|
| $\alpha = 1.0$    | Apenas $f_1$                      |
| $\alpha = 0.5$    | Média aritmética de $f_1$ e $f_2$ |
| $\alpha = 0.0$    | Apenas $f_2$                      |

#### 3.12.2.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Real  $\alpha$ .
- Linhas seguintes: Elementos de  $f_1$  ( $L$  linhas com  $C$  valores cada).
- Linhas seguintes: Elementos de  $f_2$  ( $L$  linhas com  $C$  valores cada).

**Saída:**

- Matriz resultante  $L \times C$ .

3.12.2.5 📌 Exemplos

| Entrada                                  | Saída      | Observação                  |
|------------------------------------------|------------|-----------------------------|
| 1<br>3<br>0.5<br>0 100 200<br>100 200 50 | 50 150 125 | Média entre as duas imagens |
| 1<br>3<br>1.0<br>10 20 30<br>90 80 70    | 10 20 30   | Apenas $f_1$ (alpha=1)      |




Figura 3.27: Simulador: Alpha *Blending* de Duas Imagens

```
%%writefile EP03_02.py
# Código Python

Writing EP03_02.py

TestSuite("EP03_02.py").run()
```

3.12.3 EP03\_03 🧩 Inversão de Imagem (Negativo Fotográfico)

Em radiologia, as imagens de raio-X são tradicionalmente visualizadas em negativo: ossos aparecem em preto sobre fundo branco. A operação de **negativo fotográfico** é aplicada rotineiramente em PACS (*Picture Archiving and Communication Systems*) para facilitar a detecção de fraturas e densidades ósseas.

Ver na Figure 3.28 uma simulação deste EP.

### 3.12.3.1 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas).
2. **Dados:** Ler os valores inteiros da matriz original.
3. **Mapeamento:** Para cada pixel  $p$ , calcular o negativo:

$$p' = 255 - p$$

4. **Saída:** Exibir a matriz resultante  $L \times C$ .

### 3.12.3.2 Restrições Computacionais

- **Sem *clipping* necessário:** O resultado de  $255 - p$  com  $p \in [0, 255]$  é sempre  $\in [0, 255]$ .
- **Tipo inteiro:** Saída deve ser valores inteiros.
- **Equivalência lógica:** A operação é idêntica ao NOT bit a bit (`mm.bnot`) em imagens de 8 bits.

### 3.12.3.3 Fundamentação Teórica

| Pixel Original $p$ | Pixel Negativo $p'$ | Observação     |
|--------------------|---------------------|----------------|
| 0 (preto)          | 255 (branco)        | Inversão total |
| 128 (cinza médio)  | 127 (cinza médio)   | Valor central  |
| 255 (branco)       | 0 (preto)           | Inversão total |

### 3.12.3.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linhas seguintes: Elementos inteiros da matriz original.

**Saída:**

- Matriz negativa em  $L$  linhas e  $C$  colunas.

### 3.12.3.5 Exemplos

| Entrada         | Saída           | Observação             |
|-----------------|-----------------|------------------------|
| 140 128 200 255 | 255 127 55 0    | Inversão de cada pixel |
| 2 2 10 20 30 40 | 245 235 225 215 | Matriz 2x2 invertida   |

```
%%writefile EP03_03.py
# Código Python
```

```
Writing EP03_03.py
```

```
TestSuite("EP03_03.py").run()
```




Figura 3.28: Simulador: Inversão de Imagem (Negativo Fotográfico)

### 3.12.4 EP03\_04 Equalização de Histograma (L bits)

Em imagens de satélite de sensoriamento remoto, a variação de iluminação ao longo do dia produz imagens de baixo contraste. A **equalização de histograma** é aplicada automaticamente em satélites como o Landsat para redistribuir os tons, revelando detalhes de vegetação, relevo e zonas urbanas invisíveis na imagem original.

Ver na Figure 3.29 uma simulação deste EP.

#### 3.12.4.1 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (linhas),  $C$  (colunas) e  $B$  (número de bits, com  $L_{\max} = 2^B$ ).
2. **Dados:** Ler a matriz de pixels  $f$  com valores em  $[0, 2^B - 1]$ .
3. **Histograma:** Calcular  $h[k]$  = número de pixels com intensidade  $k$ , para  $k = 0 \dots 2^B - 1$ .
4. **Probabilidade:**  $p[k] = h[k]/(L \cdot C)$ .
5. **CDF:**  $\text{cdf}[k] = \sum_{j=0}^k p[j]$ ; função de distribuição acumulada.
6. **LUT:**  $\text{lut}[k] = \text{round}(\text{cdf}[k] \cdot (2^B - 1))$ ; *Look-Up Table* (tabela de consulta).
7. **Aplicação:**  $g[i, j] = \text{lut}[f[i, j]]$ .
8. **Saída:** Exibir a matriz equalizada  $L \times C$ .

#### 3.12.4.2 Restrições Computacionais

- **Arredondamento:** Usar arredondamento matemático (**round**) na LUT.
- **Bits:** O número de níveis é  $2^B$  (ex.:  $B = 3 \Rightarrow 8$  níveis,  $B = 8 \Rightarrow 256$  níveis).
- **CDF acumulada:**  $\text{cdf}[k] = \sum_{j=0}^k p[j]$ , com  $\text{cdf}[2^B - 1] = 1.0$ .

#### 3.12.4.3 Fundamentação Teórica

| Etapa | Operação   | Fórmula                                                            |
|-------|------------|--------------------------------------------------------------------|
| 1     | Histograma | $h[k] \leftarrow \text{n}^\circ \text{ pixels com intensidade } k$ |

| Etapa | Operação      | Fórmula                                                                                                            |
|-------|---------------|--------------------------------------------------------------------------------------------------------------------|
| 2     | Probabilidade | $p[k] = h[k]/(L \cdot C)$                                                                                          |
| 3     | CDF           | $\text{cdf}[k] = \sum_{j=0}^k p[j]$                                                                                |
| 4     | LUT           | $\text{lut}[\text{Look} - \text{UpTable}(\text{tabeladeconsulta})k] = \text{round}(\text{cdf}[k] \cdot (2^B - 1))$ |
| 5     | Aplicação     | $g[i, j] = \text{lut}[f[i, j]]$                                                                                    |

#### 3.12.4.4 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Inteiro  $B$  (número de bits).
- Linhas seguintes: Elementos inteiros da matriz.

##### Saída:

- Matriz equalizada em  $L$  linhas e  $C$  colunas.

#### 3.12.4.5 Exemplos

| Entrada   | Saída     | Observação                 |
|-----------|-----------|----------------------------|
| 5         | 5 7 1 5 7 | Exemplo 3 bits do capítulo |
| 5         | 7 5 5 7 5 |                            |
| 3         | 1 5 7 5 1 |                            |
| 3 4 2 3 4 | 5 7 5 1 5 |                            |
| 4 3 3 4 3 | 7 5 1 5 7 |                            |
| 2 3 4 3 2 |           |                            |
| 3 4 3 2 3 |           | Histograma bimodal extremo |
| 4 3 2 3 4 |           |                            |
| 1         | 0 0 7 7   |                            |
| 4         |           |                            |
| 3         |           |                            |
| 0 0 7 7   |           |                            |

```
%%writefile EP03_04.py
# Código Python
```

```
Writing EP03_04.py
```

```
TestSuite("EP03_04.py").run()
```

#### 3.12.5 EP03\_05 Aplicação de Máscara AND Binária

Em sistemas de inspeção industrial por visão computacional, é necessário isolar regiões de interesse (ROI) em imagens de peças para verificar defeitos de fabricação. A operação **AND bit a bit com uma máscara**

Simulador: Equalização de Histograma

Escolha o número de bits e gere uma imagem para ver a equalização em tempo real.




Figura 3.29: Simulador: Equalização de Histograma (L bits)



**binária** é o mecanismo fundamental para recortar exatamente a área de inspeção, zerando todos os pixels fora dela.

Ver na Figure 3.30 uma simulação deste EP.

#### 3.12.5.1 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas).
2. **Dados:** Ler a matriz de pixels  $f$  (valores  $\in [0, 255]$ ).
3. **Máscara:** Ler a matriz binária  $m$  (valores: apenas 0 ou 255).
4. **Mapeamento:** Para cada pixel  $(i, j)$ , aplicar o AND bit a bit:

$$g(i, j) = f(i, j) \text{ AND } m(i, j)$$

onde  $255 = 11111111$  e  $0 = 00000000$  em binário.

5. **Saída:** Exibir a matriz resultante  $L \times C$ .

#### 3.12.5.2 Restrições Computacionais

- **AND com 255:**  $p \text{ AND } 255 = p$  (todos os bits preservados).
- **AND com 0:**  $p \text{ AND } 0 = 0$  (todos os bits zerados).
- **Máscara:** Os únicos valores possíveis na máscara são 0 e 255.
- **Implementação:** Em Python, o AND bit a bit entre inteiros usa o operador `&`.

#### 3.12.5.3 Fundamentação Teórica

| Pixel $f$    | Máscara $m$    | Resultado $f \text{ AND } m$ |
|--------------|----------------|------------------------------|
| qualquer $v$ | 255 (11111111) | $v$ (preservado)             |
| qualquer $v$ | 0 (00000000)   | 0 (zerado)                   |

#### 3.12.5.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linhas seguintes: Elementos de  $f$  ( $L$  linhas).
- Linhas seguintes: Elementos de  $m$  ( $L$  linhas com valores 0 ou 255).

**Saída:**

- Matriz resultante  $L \times C$ .

#### 3.12.5.5 Exemplos

| Entrada     | Saída     | Observação                  |
|-------------|-----------|-----------------------------|
| 2           | 100 150 0 | Máscara seleciona região    |
| 3           | 0 80 120  |                             |
| 100 150 200 |           |                             |
| 50 80 120   |           |                             |
| 255 255 0   |           |                             |
| 0 255 255   |           | Alternado preservado/zerado |
| 1           | 10 0 30 0 |                             |
| 4           |           |                             |
| 10 20 30 40 |           |                             |
| 255 0 255 0 |           |                             |

Simulador de máscara AND binária: aplica operação AND pixel a pixel entre imagem e máscara interativa.




Figura 3.30: Simulador: Aplicação de Máscara AND Binária

```
%%writefile EP03_05.py
# Código Python

Writing EP03_05.py

TestSuite("EP03_05.py").run()
```

3.12.6 EP03\_06 Filtro de Média com *Kernel* N×N

Em câmeras de veículos autônomos, imagens capturadas sob chuva ou névoa apresentam ruído gaussiano. O **filtro de média** é amplamente utilizado para sua redução em tempo real, sendo implementado diretamente

no **ISP** (*Image Signal Processor*) de sensores **CMOS** (*Complementary Metal-Oxide-Semiconductor*).

Os sensores CMOS são os sensores de imagem usados na maioria das câmeras modernas (*smartphones*, *webcams*, câmeras automotivas etc.). Eles convertem a luz em sinais elétricos, e o ISP processa esses sinais em tempo real — aplicando operações como redução de ruído, balanço de branco e outros ajustes de imagem.

Ver na Figure 3.31 uma simulação deste EP.

#### 3.12.6.1 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (linhas),  $C$  (colunas) e  $N$  (tamanho do *kernel*, sempre ímpar).
2. **Dados:** Ler a matriz de pixels  $f$ .
3. **Filtro de Média:** Para cada pixel  $(i, j)$  **interno** (sem bordas), calcular:

$$g(i, j) = \text{round} \left( \frac{1}{N^2} \sum_{s=-(r)}^r \sum_{t=-(r)}^r f(i+s, j+t) \right), \quad r = \lfloor N/2 \rfloor$$

4. **Tratamento de Borda:** Pixels na borda (onde a janela  $N \times N$  ultrapassa os limites) devem ser **copiados diretamente** do original sem modificação.
5. **Saída:** Exibir a matriz resultante  $L \times C$ .

#### 3.12.6.2 Restrições Computacionais

- **Raio:**  $r = \lfloor N/2 \rfloor$  (metade do *kernel*, inteiro).
- **Pixels internos:**  $(i, j)$  com  $r \leq i < L - r$  e  $r \leq j < C - r$ .
- **Arredondamento:** Usar arredondamento matemático antes de converter para inteiro.
- **Sem *clipping*:** A média de valores  $\in [0, 255]$  permanece em  $[0, 255]$ .

#### 3.12.6.3 Fundamentação Teórica

| Tamanho $N$ | Coefficiente         | Pixels na janela | Efeito |
|-------------|----------------------|------------------|--------|
| 3           | $1/9 \approx 0.111$  | 9                | Suave  |
| 5           | $1/25 = 0.04$        | 25               | Médio  |
| 7           | $1/49 \approx 0.020$ | 49               | Forte  |

#### 3.12.6.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Inteiro  $N$  (ímpar,  $N \geq 3$ ).
- Linhas seguintes: Elementos da matriz original.


**Saída:**

- Matriz filtrada  $L \times C$ .

#### 3.12.6.5 Exemplos

| Entrada     | Saída        | Observação                                                                                           |
|-------------|--------------|------------------------------------------------------------------------------------------------------|
| 3           | 10 20 30     | Apenas borda (3×3 = borda total)                                                                     |
| 3           | 40 50 60     |                                                                                                      |
| 3           | 70 80 90     |                                                                                                      |
| 10 20 30    |              |                                                                                                      |
| 40 50 60    |              |                                                                                                      |
| 70 80 90    |              |                                                                                                      |
| 5           | 0 0 0 0 0    | Pixel isolado: todos os 9 pixels internos cuja janela 3×3 inclui o valor 100 recebem round(100/9)=11 |
| 5           | 0 11 11 11 0 |                                                                                                      |
| 3           | 0 11 11 11 0 |                                                                                                      |
| 0 0 0 0 0   | 0 11 11 11 0 |                                                                                                      |
| 0 0 0 0 0   | 0 0 0 0 0    |                                                                                                      |
| 0 0 100 0 0 |              |                                                                                                      |
| 0 0 0 0 0   |              |                                                                                                      |
| 0 0 0 0 0   |              |                                                                                                      |

Simulador de filtro de média com kernel 3×3 ou 5×5: passe o mouse nas células do resultado para visualizar a janela de vizinhança.



Passe o mouse sobre um pixel interno do resultado para ver o cálculo.

Figura 3.31: Simulador: Filtro de Média com *Kernel* N×N

```
%%writefile EP03_06.py
# Código Python
```

Writing EP03\_06.py

```
TestSuite("EP03_06.py").run()
```

### 3.12.7 EP03\_07 🔍 Operador Laplaciano (w4) para Realce de Bordas

Em tomografias de alta resolução, a nitidez das bordas entre tecidos é crítica para diagnóstico. O **operador Laplaciano** é amplamente utilizado em *pipelines* de pré-processamento de imagens médicas para realçar automaticamente os contornos anatômicos antes da segmentação, evitando intervenção manual do radiologista.

Ver na Figure 3.32 uma simulação deste EP.

#### 3.12.7.1 📋 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas).
2. **Dados:** Ler a matriz de pixels  $f$ .
3. **Laplaciano (w4):** Para cada pixel **interno**  $(i, j)$  com  $1 \leq i < L - 1$ ,  $1 \leq j < C - 1$ , calcular:

$$\nabla^2 f(i, j) = f(i - 1, j) + f(i + 1, j) + f(i, j - 1) + f(i, j + 1) - 4 \cdot f(i, j)$$

4. **Realce:** Calcular a imagem realçada:

$$g(i, j) = \text{clip}(f(i, j) - \nabla^2 f(i, j))$$

5. **Borda:** Pixels na borda são copiados diretamente:  $g(i, j) = f(i, j)$ .
6. **Saída:** Exibir a matriz realçada  $L \times C$ .

#### 3.12.7.2 📌 Restrições Computacionais

- **Kernel w4:**  $\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$  — apenas 4-vizinhos.
- **Saturação:**  $\text{clip}(x) = \max(0, \min(255, x))$  aplicado ao resultado do realce.
- **Sem arredondamento:** O Laplaciano usa apenas somas/subtrações de inteiros.

#### 3.12.7.3 🧠 Fundamentação Teórica

| Região            | $\nabla^2 f$ | Efeito do Realce |
|-------------------|--------------|------------------|
| Uniforme          | $\approx 0$  | Sem alteração    |
| Borda crescente   | $< 0$        | Pixel clareado   |
| Borda decrescente | $> 0$        | Pixel escurecido |

#### 3.12.7.4 📦 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linhas seguintes: Elementos da matriz original.

**Saída:**

- Matriz realçada  $L \times C$ .

**3.12.7.5 Exemplos**

| Entrada                                    | Saída                            | Observação                                                                          |
|--------------------------------------------|----------------------------------|-------------------------------------------------------------------------------------|
| 3<br>3<br>0 0 0<br>0 100 0<br>0 0 0        | 0 0 0<br>0 255 0<br>0 0 0        | Pico isolado: $\text{lap}=-400$ ,<br>$g=100-(-400)=500 \rightarrow \text{clip}=255$ |
| 3<br>3<br>50 50 50<br>50 50 50<br>50 50 50 | 50 50 50<br>50 50 50<br>50 50 50 | Região uniforme: Laplaciano=0, sem<br>alteração                                     |

```
%%writefile EP03_07.py
# Código Python
```

Writing EP03\_07.py

```
TestSuite("EP03_07.py").run()
```

**3.12.8 EP03\_08 Gradiente de Sobel: Gx e Gy**

Em robôs exploradores de Marte (como o Perseverance), a detecção de obstáculos é realizada em tempo real por câmeras estereoscópicas. O **operador de Sobel** calcula o gradiente direcional da cena e é utilizado no algoritmo de detecção de bordas para identificar rochas, fissuras e desníveis do terreno que possam comprometer a navegação.

Ver na Figure 3.33 uma simulação deste EP.

**3.12.8.1 Diretrizes de Implementação**

1. **Dimensões:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas).
2. **Dados:** Ler a matriz  $f$ .
3. **Gx e Gy:** Para cada pixel **interno**  $(i, j)$  com  $1 \leq i < L - 1$ ,  $1 \leq j < C - 1$ :

$$G_x(i, j) = [f(i - 1, j + 1) + 2f(i, j + 1) + f(i + 1, j + 1)] - [f(i - 1, j - 1) + 2f(i, j - 1) + f(i + 1, j - 1)]$$

$$G_y(i, j) = [f(i + 1, j - 1) + 2f(i + 1, j) + f(i + 1, j + 1)] - [f(i - 1, j - 1) + 2f(i - 1, j) + f(i - 1, j + 1)]$$

4. **Magnitude:**  $|\nabla f(i, j)| = \text{clip}(\text{round}(\sqrt{G_x^2 + G_y^2}))$ .
5. **Borda:** Pixels de borda recebem magnitude 0.
6. **Saída:** Exibir a magnitude  $L \times C$ .



Simulador do operador Laplaciano para realce de bordas: imagem original, laplaciano e resultado.




Figura 3.32: Simulador: Operador Laplaciano (w4) para Realce de Bordas

### 3.12.8.2 📌 Restrições Computacionais

- **Arredondamento:** Aplicar round antes de converter para inteiro.
- **Saturação:**  $\text{clip}(x) = \max(0, \min(255, x))$ .
- **Raiz quadrada:** Usar  $\sqrt{G_x^2 + G_y^2}$  (não a aproximação  $|G_x| + |G_y|$ ).

### 3.12.8.3 🧠 Fundamentação Teórica

| Operador     | Detecta            | Coeficientes diagonais |
|--------------|--------------------|------------------------|
| $G_x$        | Bordas verticais   | $\pm 1$                |
| $G_y$        | Bordas horizontais | $\pm 1$                |
| $ \nabla f $ | Todas as bordas    | Combinado              |

### 3.12.8.4 📦 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linhas seguintes: Elementos da matriz.

**Saída:**

- Magnitude do gradiente, matriz  $L \times C$ .

### 3.12.8.5 📌 Exemplos

| Entrada | Saída   | Observação                      |
|---------|---------|---------------------------------|
| 3       | 0 0 0   | Imagem nula: gradiente zero     |
| 3       | 0 0 0   |                                 |
| 0 0 0   | 0 0 0   |                                 |
| 0 0 0   | 0 0 0   |                                 |
| 3       | 0 0 0   | Borda vertical central: Gx alto |
| 3       | 0 255 0 |                                 |
| 0 0 255 | 0 0 0   |                                 |
| 0 0 255 |         |                                 |
| 0 0 255 |         |                                 |

```
%%writefile EP03_08.py
# Código Python
```

```
Writing EP03_08.py
```

```
TestSuite("EP03_08.py").run()
```

## Simulador do gradiente de Sobel: imagem original, Gx, Gy e magnitude do gradiente.




Figura 3.33: Simulador: Gradiente de Sobel: Gx e Gy

### 3.12.9 EP03\_09 Filtro da Mediana 3×3

Imagens de radar de abertura sintética (SAR) usadas em monitoramento ambiental e militar sofrem de um tipo específico de ruído chamado *speckle*, que possui características similares ao ruído sal e pimenta. O **filtro da mediana** é o método padrão de remoção desse ruído porque preserva as bordas das estruturas enquanto elimina os pontos espúrios.

Ver na Figure 3.34 uma simulação deste EP.

#### 3.12.9.1 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas).
2. **Dados:** Ler a matriz de pixels  $f$ .
3. **Filtro da Mediana 3×3:** Para cada pixel **interno**  $(i, j)$  com  $1 \leq i < L - 1$ ,  $1 \leq j < C - 1$ :
  - Coletar os 9 pixels da vizinhança  $3 \times 3$ :  $\{f(i + s, j + t) : s, t \in \{-1, 0, 1\}\}$ .
  - Ordenar os 9 valores em ordem crescente.
  - Atribuir  $g(i, j)$  ao valor central (posição índice 4, considerando índice 0).

$$g(i, j) = \text{mediana}\{f(i + s, j + t) : s, t \in \{-1, 0, 1\}\}$$

4. **Borda:** Copiar diretamente:  $g(i, j) = f(i, j)$ .
5. **Saída:** Exibir a matriz filtrada  $L \times C$ .

#### 3.12.9.2 Restrições Computacionais

- **Janela:** Sempre  $3 \times 3 = 9$  elementos.
- **Mediana:** O elemento central da sequência ordenada (índice 4 de 0 a 8).
- **Sem clipping:** A mediana de valores em  $[0, 255]$  permanece em  $[0, 255]$ .
- **Não linear:** O filtro mediana não pode ser expresso como convolução linear.

#### 3.12.9.3 Fundamentação Teórica

| Ruído                    | Filtro de Média   | Filtro de Mediana           |
|--------------------------|-------------------|-----------------------------|
| Sal e pimenta (0 ou 255) | Espalha o ruído   | Remove sem distorcer bordas |
| Gaussiano                | Reduz eficazmente | Reduz parcialmente          |

#### 3.12.9.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linhas seguintes: Elementos da matriz.

**Saída:**

- Matriz filtrada  $L \times C$ .

#### 3.12.9.5 Exemplos

| Entrada     | Saída       | Observação                                                    |
|-------------|-------------|---------------------------------------------------------------|
| 3           | 100 100 100 | Ponto preto eliminado: mediana de $8\times100+1\times0 = 100$ |
| 3           | 100 100 100 |                                                               |
| 100 100 100 | 100 100 100 |                                                               |
| 100 0 100   |             |                                                               |
| 100 100 100 |             |                                                               |
| 3           | 50 50 50    | Ponto branco (sal) eliminado                                  |
| 3           | 50 50 50    |                                                               |
| 50 50 50    | 50 50 50    |                                                               |
| 50 255 50   |             |                                                               |
| 50 50 50    |             |                                                               |




Figura 3.34: Simulador: Filtro da Mediana 3×3

```
%%writefile EP03_09.py
# Código Python

Writing EP03_09.py

TestSuite("EP03_09.py").run()
```

3.12.10 EP03\_10 ✨ *Unsharp Masking* (USM)

Em sistemas de digitalização de documentos históricos e obras de arte, a nitidez das imagens é fundamental para leitura de textos manuscritos e detalhes ornamentais. O *Unsharp Masking* (USM) é o algoritmo de

realce de nitidez padrão utilizado em *scanners* profissionais e softwares como Adobe Photoshop, controlado pelo parâmetro  $k$  que determina a intensidade do realce.

Ver na Figure 3.35 uma simulação deste EP.

### 3.12.10.1 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas).
2. **Parâmetro:** Ler o valor real  $k$  (intensidade do realce,  $k \geq 0$ ).
3. **Dados:** Ler a matriz de pixels  $f$ .
4. **Suavização:** Calcular  $\bar{f}$  com filtro de média  $3 \times 3$  (apenas pixels internos; bordas mantidas):

$$\bar{f}(i, j) = \frac{1}{9} \sum_{s=-1}^1 \sum_{t=-1}^1 f(i+s, j+t)$$

5. **Máscara de alta frequência:**  $m(i, j) = f(i, j) - \bar{f}(i, j)$ .
6. **Realce USM:** Para cada pixel interno:

$$g(i, j) = \text{clip}(\text{round}(f(i, j) + k \cdot m(i, j)))$$

7. **Borda:**  $g(i, j) = f(i, j)$  (cópia direta).
8. **Saída:** Exibir a matriz realçada  $L \times C$ .

### 3.12.10.2 Restrições Computacionais

- **Arredondamento:** Aplicar `round` antes do clipping.
- **Saturação:**  $\text{clip}(x) = \max(0, \min(255, x))$ .
- **Operações em float:** Calcular  $\bar{f}$  e  $m$  em ponto flutuante antes de arredondar o resultado final.
- $k = 0$ : Sem realce — a saída é idêntica à entrada (exceto pelas bordas).

### 3.12.10.3 Fundamentação Teórica

| Etapas | Operação                                            | Descrição                       |
|--------|-----------------------------------------------------|---------------------------------|
| 1      | $\bar{f} = f * \frac{1}{9} \mathbf{1}_{3 \times 3}$ | Suavização (baixas frequências) |
| 2      | $m = f - \bar{f}$                                   | Máscara (altas frequências)     |
| 3      | $g = \text{clip}(\text{round}(f + k \cdot m))$      | Realce ponderado                |

### 3.12.10.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Real  $k$ .
- Linhas seguintes: Elementos da matriz original.

**Saída:**

- Matriz realçada  $L \times C$ .



3.12.10.5 Exemplos

| Entrada     | Saída       | Observação                             |
|-------------|-------------|----------------------------------------|
| 3           | 100 100 100 | k=0: sem realce                        |
| 3           | 100 100 100 |                                        |
| 0.0         | 100 100 100 |                                        |
| 100 100 100 |             |                                        |
| 100 100 100 |             | k=1: pixel central realçado e saturado |
| 100 100 100 |             |                                        |
| 3           | 50 50 50    |                                        |
| 3           | 50 255 50   |                                        |
| 1.0         | 50 50 50    |                                        |
| 50 50 50    |             |                                        |
| 50 200 50   |             |                                        |
| 50 50 50    |             |                                        |

Simulador de Unsharp Masking (USM): visualização do pipeline com imagem original, versão desfocada, máscara de alta frequência e resultado realçado.




Figura 3.35: Simulador: *Unsharp Masking* (USM)

```
%%writefile EP03_10.py
# Código Python

Writing EP03_10.py

TestSuite("EP03_10.py").run()
```

## Capítulo 4

# Morfologia Matemática e Segmentação de Imagens



Este capítulo apresenta dois temas fundamentais do Processamento Digital de Imagens (PDI): a **morfologia matemática** e a **segmentação de imagens**. A morfologia matemática fornece um arcabouço teórico baseado na teoria dos conjuntos para analisar, refinar e quantificar a forma de objetos em imagens binárias e em tons de cinza, por meio de operadores fundamentais como **erosão** e **dilatação**. A segmentação, por sua vez, tem como objetivo particionar a imagem em regiões de interesse, separando objetos do fundo e produzindo representações adequadas para análise e interpretação.

O capítulo inicia com a **limiarização**, uma das técnicas mais importantes de segmentação, introduzindo o método automático de **Otsu** e revisitando a análise de histogramas por meio da variância interclasses, apresentada no Capítulo 1. Em seguida, são estudados os principais operadores da morfologia matemática, incluindo erosão, dilatação, abertura, fechamento e reconstrução morfológica, que permitem refinar máscaras binárias e preservar estruturas relevantes dos objetos. Por fim, são apresentadas técnicas de segmentação baseada em regiões, como a **rotulação de componentes conexos**, a **transformada de distância** e o algoritmo **watershed** baseado em marcadores, culminando na extração de descritores geométricos e na geração de *bounding boxes* compatíveis com sistemas modernos de detecção de objetos.

## 4.1 Objetivos

Ao final deste capítulo, você será capaz de:

- **Aplicar limiarização:** Compreender o critério automático de Otsu por maximização da variância interclasses ( $\sigma_B^2$ ) e selecionar estratégias adequadas de pré-processamento para facilitar a segmentação;
- **Dominar morfologia binária:** Compreender e aplicar erosão ( $A \ominus B$ ) e dilatação ( $A \oplus B$ ) como operadores fundamentais, derivando abertura ( $A \circ B$ ), fechamento ( $A \bullet B$ ) e operações baseadas em reconstrução morfológica, como `mm.clohole` e `mm.edgeoff`;
- **Aplicar morfologia em tons de cinza:** Utilizar gradiente morfológico e filtros *top-hat* para realce e análise de estruturas locais;
- **Rotular componentes conexos:** Identificar e separar regiões conectadas em imagens binárias por meio de algoritmos de rotulação;
- **Aplicar transformada de distância:** Interpretar e calcular distâncias ao fundo utilizando abordagens morfológicas e métricas geométricas;
- **Segmentar por regiões:** Construir *pipelines* de segmentação baseados em marcadores utilizando Transformada de Distância e o algoritmo **watershed**;
- **Extraír descritores geométricos:** Calcular propriedades como área, perímetro, centróide, circularidade e *bounding boxes* por meio de `cv2.connectedComponentsWithStats` e `cv2.findContours`;
- **Relacionar PDI e visão computacional:** Compreender como descritores extraídos por segmentação podem ser convertidos para formatos utilizados por detectores modernos, como YOLO.

```
import os, importlib, urllib.request
import numpy as np
import matplotlib.pyplot as plt

BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph"
for f in ["morph.py"]:
    if not os.path.exists(f):
        urllib.request.urlretrieve(f"{BASE_URL}/{f}", f)

import morph
importlib.reload(morph)
from morph import mm

version = getattr(morph, "__version__", "local_file")
print(f" Ambiente pronto. Módulo 'morph' carregado (versão: {version}).")
```

Ambiente pronto. Módulo 'morph' carregado (versão: 1.1.5).

## 4.2 Limiarização

A **limiarização** (*thresholding*) é uma das formas mais simples e eficientes de segmentação de imagens. Seu objetivo é classificar cada pixel em duas classes de intensidade, normalmente associadas a *objeto* e *fundo*:

$$g(x, y) = \begin{cases} 255, & \text{se } f(x, y) > T \\ 0, & \text{caso contrário} \end{cases} \quad (4.1)$$

em que  $f(x, y)$  representa a intensidade do pixel na imagem original e  $g(x, y)$  a imagem binária resultante.

A escolha do limiar  $T$  é importante para a qualidade da segmentação. O método de **Otsu** determina automaticamente o limiar ótimo ao maximizar a **variância interclasses**  $\sigma_B^2$  e definida por:

$$\sigma_B^2(T) = w_0(T) w_1(T) [\mu_0(T) - \mu_1(T)]^2 \quad (4.2)$$

em que:

- $w_0(T)$  e  $w_1(T)$  são as probabilidades acumuladas das classes fundo e objeto;
- $\mu_0(T)$  e  $\mu_1(T)$  são as médias de intensidade dessas classes;
- $\sigma_B^2(T)$  representa a variância interclasses para um dado limiar  $T$ .

O método funciona melhor quando o histograma apresenta dois grupos de intensidades relativamente separados. Para isso, o algoritmo avalia todos os limiares possíveis da imagem — tipicamente no intervalo  $[0, 255]$  para imagens de 8 bits — e seleciona o valor que maximiza a variância entre classes, denotada por  $\sigma_B^2$ :

$$T^* = \arg \max_{T \in [0, 255]} \sigma_B^2(T)$$

### **i** Otsu assume histogramas bimodais

O método de Otsu produz melhores resultados quando o histograma apresenta dois picos bem definidos (*bimodalidade*), correspondentes ao fundo e ao objeto. Quanto maior a separação entre esses picos e mais pronunciado o máximo de  $\sigma_B^2$ , mais confiável tende a ser o limiar obtido.

Em imagens com iluminação não uniforme ou múltiplas regiões de intensidade, técnicas de **limiarização adaptativa** — nas quais o limiar é calculado localmente — costumam produzir segmentações mais robustas.

O índice  $B$  em  $\sigma_B^2$  significa *between classes* (entre classes). Assim,  $\sigma_B^2$  representa a **variância entre as classes** (between-class variance).

#### 4.2.1 Imagem de Moedas

A imagem utilizada para praticar a segmentação é uma fotografia de coleção de moedas de diferentes países e épocas (Figure 4.1). Crédito: GAZI.MD.AHAD (CC BY-SA 4.0). Ela apresenta objetos circulares com bordas bem definidas, sendo ideal para demonstrar limiarização, operadores morfológicos, transformada de distância, *watershed* e descritores de forma.

```
import os

url      = "https://upload.wikimedia.org/wikipedia/commons/2/25/GAZI.MD.AHAD_11.jpg"
caminho = "imagens/coins.jpg"

if not os.path.exists(caminho):
    os.makedirs("imagens", exist_ok=True)
    img_obj = mm.read(url, pil=True)
    mm.write(img_obj, caminho)
else:
    img_obj = mm.read(caminho, pil=True)

img_coins_color = np.array(img_obj)
img_coins_gray  = mm.gray(img_coins_color)

print(f"Dimensões [y,x,c]: {img_coins_color.shape}")
mm.show(img_coins_color, scale=30)
```

Dimensões [y,x,c]: (2560, 1920, 3)



Figura 4.1: Imagem com moedas de vários tipos. Crédito: GAZI.MD.AHAD (CC BY-SA 4.0).

### 4.2.2 Escolha do Pré-processamento para o Otsu

A qualidade do método de Otsu depende diretamente de quão **bimodal** é o histograma da imagem de entrada. A imagem original das moedas apresenta iluminação não uniforme e moedas escuras (cobre oxidado) com intensidades próximas às do fundo escuro, tornando o histograma pouco bimodal.

Para minimizar essas limitações, serão avaliadas duas técnicas clássicas de pré-processamento, apresentadas no capítulo anterior, aplicadas antes da etapa de limiarização. A Table 4.1 resume as características de cada abordagem. Essas técnicas buscam aumentar a separação entre objeto e fundo, tornando o histograma mais próximo de uma distribuição bimodal.

Tabela 4.1: Técnicas de pré-processamento avaliadas para melhorar a separação entre moedas e fundo antes da aplicação do método de Otsu.

| Técnica          | O que faz                                  | Quando usar                                 |
|------------------|--------------------------------------------|---------------------------------------------|
| <b>CLAHE</b>     | Equalização de histograma adaptativa local | Baixo contraste global ou regional          |
| <b>Gaussiano</b> | Suavização por convolução com gaussiana    | Ruído de alta frequência (textura do fundo) |

A função `cv2.createCLAHE(clipLimit, tileGridSize)` divide a imagem em blocos e aplica equalização de histograma em cada um deles, limitando a amplificação de ruído por meio do parâmetro `clipLimit`. Já o filtro Gaussiano (`cv2.GaussianBlur`) suaviza texturas finas que poderiam criar falsos picos no histograma.

Para comparar objetivamente qual pré-processamento produz a melhor entrada para o método de Otsu, serão apresentados, para cada versão da imagem, a própria imagem, o histograma com o limiar ótimo  $T^*$  destacado, a curva  $\sigma_B^2(T)$  e o resultado da binarização.

#### i Critério de comparação

A versão que apresentar o maior valor de  $\sigma_B^2$  em seu pico fornece a melhor separação entre as classes de fundo e objeto e, conseqüentemente, a melhor entrada para o método de Otsu (Figure 4.2).

```
import cv2, io

def otsu_criterio(img):
    h=mm.hist(img); p=h/h.sum(); # histograma e probabilidades
    sigma2=np.zeros(len(p))
    for T in range(1,len(p)): # percorre limiares
        w0,w1=p[:T].sum(),p[T:].sum() # probabilidades das classes
        if w0*w1==0: continue # evita divisão por zero
        mu0=(np.arange(T)*p[:T]).sum()/w0 # média fundo
        mu1=(np.arange(T,len(p))*p[T:]).sum()/w1 # média objeto
        sigma2[T]=w0*w1*(mu0-mu1)**2 #  $\sigma_B^2(T)$ 
    return sigma2,np.argmax(sigma2) # curva e T ótimo

def fig2img(fig):
    b=io.BytesIO(); fig.savefig(b,format='png',dpi=100) # figura → buffer
    plt.close(fig); b.seek(0)
    return np.array(plt.imread(b)) # buffer → array

def plot_curve(y,T,title,ylabel,color):
    fig,ax=plt.subplots(figsize=(4,3))
    ax.plot(y,color=color) if ylabel==" $\sigma_B^2$ " else ax.bar(range(len(y)),y,color=color,width=1)
    ax.axvline(T,color='red',lw=2,label=f"T*={T}") # limiar ótimo
    ax.set(xlabel="T" if ylabel==" $\sigma_B^2$ " else "Intensidade",ylabel=ylabel)
    ax.legend(fontsize=8); plt.tight_layout()
```

```

return fig2img(fig)

# Pré-processamentos
clahe=cv2.createCLAHE(clipLimit=2.0,tileGridSize=(8,8))
img_clahe = clahe.apply(img_coins_gray)
img_gauss = cv2.GaussianBlur(img_clahe,(5,5),0)
imgs0=[("Original",img_coins_gray),
        ("CLAHE",img_clahe),
        ("CLAHE+Gauss",img_gauss)]

# Tabela comparativa
print(f"{'Versão':<18}{'T*':>6}{'2B pico':>14}")
print("-"*40)

imgs,titles=[],[]
for nome,img in imgs0:
    sigma2,T=otsu_criterio(img) # calcula 2B(T)
    print(f"{'nome':<18}{'T':>6}{'sigma2[T]:>14.4e}")
    imgs += [
        img, # imagem
        plot_curve(mm.hist(img),T,f"Hist T*={T}", "Freq.", "steelblue"),
        plot_curve(sigma2,T,"2B(T)", "2B", "darkorange"),
        mm.threshold(img) # Otsu final
    ]
    titles += [nome,f"Hist T*={T}", "2B(T)", f"Otsu T*={T}"]

# Exibição final
mm.show(imgs,titles=titles,cols=4,figsize=(12,12),dpi=200)

```

| Versão      | T*  | <sup>2</sup> B pico |
|-------------|-----|---------------------|
| Original    | 105 | 1.9437e+03          |
| CLAHE       | 122 | 2.4695e+03          |
| CLAHE+Gauss | 123 | 2.4283e+03          |






Figura 4.2: Comparação dos pré-processamentos: imagem | histograma+ $T^*$  |  $\sigma^2_B(T)$  | Otsu. A melhor separação bimodal indica o limiar mais confiável.

#### 4.2.3 Resultado: CLAHE como Melhor Pré-processamento

A análise da Figure 4.2 indica que o **CLAHE** obteve o maior valor da variância inter-classes ( $\sigma_B^2 \approx 2,47 \times 10^3$ ), com limiar ótimo  $T^* = 122$ . Embora a combinação **CLAHE+Gaussiano** tenha produzido resultado muito semelhante ( $\sigma_B^2 \approx 2,43 \times 10^3$ ,  $T^* = 123$ ), o critério quantitativo do método de Otsu favorece ligeiramente o uso do CLAHE isoladamente.

Em termos visuais, as imagens binarizadas obtidas com CLAHE e CLAHE+Gaussiano são praticamente equivalentes. A diferença entre as duas abordagens torna-se mais evidente na análise dos histogramas e dos valores de  $\sigma_B^2(T)$  do que na inspeção direta das segmentações resultantes. Assim, a escolha do CLAHE baseia-se principalmente na maximização da separação estatística entre as classes de fundo e objeto.

### 💡 Interpretação dos resultados

Observe que os pré-processamentos com CLAHE e CLAHE+Gaussiano produzem histogramas e limiares ótimos muito próximos ( $T^* = 122$  e  $T^* = 123$ ). Consequentemente, as imagens binarizadas resultantes também são bastante semelhantes. Nesse caso, a decisão não é baseada em diferenças visuais marcantes, mas no critério objetivo do método de Otsu: o maior valor de  $\sigma_B^2$  indica a melhor separação entre as classes.

## 4.3 Morfologia Matemática

A **morfologia matemática** é uma teoria baseada em conjuntos utilizada para analisar a forma e a estrutura de objetos em imagens. Diferentemente dos filtros lineares apresentados no Capítulo 3, os operadores morfológicos são **não lineares**, pois se baseiam em operações de mínimo, máximo e inclusão espacial, em vez de combinações lineares de intensidades. Esses operadores atuam sobre a vizinhança de cada pixel por meio de um **elemento estruturante**  $\mathbb{B}$ , responsável por definir a forma e o tamanho da região analisada.

Em imagens binárias e em tons de cinza com elementos planos, o elemento estruturante transladado para a posição  $x$  é definido espacialmente como:

$$\mathbb{B}_x = \{x + b \mid b \in \mathbb{B}\}$$

Nas regiões de borda da imagem, parte do conjunto  $\mathbb{B}_x$  pode extrapolar o domínio físico da cena ( $\mathbb{E}$ ). Para garantir a consistência matemática dos operadores primitivos nessas fronteiras, assume-se teoricamente que o espaço exterior ao domínio da imagem é preenchido com o **elemento neutro** da operação correspondente (infinito positivo para a erosão e infinito negativo para a dilatação), impedindo que o ambiente externo corrompa as estruturas internas do objeto.

Quando o elemento estruturante associa pesos a seus elementos — isto é,  $b : \mathbb{B} \rightarrow \mathbb{Z}$  — ele é denominado **função estruturante** ou **elemento estruturante não plano**.

Desenvolvida por Matheron e Serra na década de 1960 para imagens binárias e posteriormente estendida a tons de cinza, a morfologia matemática fundamenta operadores como gradiente morfológico, *top-hat*, *watershed* e transformada de distância, todos derivados de dois primitivos: **erosão** e **dilatação** (Matheron, 1975; Serra, 1982).

### 4.3.1 Erosão e Dilatação

Os dois operadores primitivos são definidos de forma unificada para imagens em tons de cinza ( $f : \mathbb{E} \rightarrow \mathbb{Z}$ ) e, por restrição ao domínio  $\{0, 1\}$ , também para imagens binárias.

#### 4.3.1.1 Erosão

A **Erosão** de uma imagem  $f$  por uma função estruturante  $b : \mathbb{B} \rightarrow \mathbb{Z}$  é definida formalmente por:

$$\varepsilon_b(f)(x) = (f \ominus b)(x) = \min_{z \in \mathbb{B}} \{ f(x + z) - b(z) \}, \quad \forall x \in \mathbb{E} \quad (4.3)$$

Na prática, a erosão substitui a intensidade do pixel  $x$  pelo mínimo valor resultante da diferença entre a imagem e o elemento estruturante na vizinhança definida pelo domínio  $\mathbb{B}$ . Valores positivos nos pesos de  $b(z)$  forçam o resultado local para baixo, “cavando” o relevo da imagem mais profundamente e intensificando a erosão.

No caso **plano** (onde os pesos são nulos dentro do domínio, ou seja,  $b \equiv 0$ ), a expressão simplifica-se para o mínimo local puro:

$$\varepsilon_B(f)(x) = \min\{f(y) : y \in \mathbb{B}_x\}$$

Em imagens binárias, essa operação equivale a exigir que o conjunto  $\mathbb{B}$ , transladado para a coordenada  $x$ , esteja **completamente contido** no objeto  $A$ :

$$A \ominus \mathbb{B} = \{z \in \mathbb{E} \mid \mathbb{B}_z \subseteq A\}$$

**Efeito Visual:** *Encolhe* objetos e estruturas claras, eliminando protuberâncias, picos brilhantes ou ruídos que sejam geometricamente menores que o domínio  $\mathbb{B}$ .

#### 4.3.1.2 Implementação da erosão

A versão didática `mm.ero0` implementa o caso particular de erosão com **elemento estruturante plano**. Para cada pixel  $(y, x)$ , a função percorre os vizinhos espaciais permitidos por  $B$  e armazena o menor valor encontrado na imagem de entrada  $f$ , reproduzindo diretamente a operação de mínimo local descrita na Equation 4.3 para  $b \equiv 0$ .

Observe que os valores dos vizinhos são sempre lidos de forma estática da imagem original  $f$ ; a matriz de saída  $g$  é utilizada exclusivamente para registrar o mínimo acumulado da vizinhança corrente. Dessa forma, o resultado final é invariante em relação à ordem de varredura dos pixels (seja por linhas ou colunas).

A função auxiliar `_viz` calcula as coordenadas dos vizinhos válidos dentro dos limites físicos da imagem. Nas bordas, a inicialização do acumulador em 255 emula com exatidão o preenchimento por elemento neutro exigido pela teoria. Já a função de interface `mm.ero` recorre à implementação nativa e otimizada do OpenCV (`cv2.erode`) quando o elemento estruturante é plano, chaveando para a rotina geral `mm.ero1` caso o elemento possua pesos topográficos.

O exemplo computacional a seguir ilustra a aplicação de um elemento estruturante em cruz (`mm.secross()`) em destaque na Figure 4.3, comparando a execução da variante didática em laço (`mm.ero0`) com o motor computacional do OpenCV (`mm.ero`).

```
B_cruz = mm.secross()
mm.drawImgPlt(B_cruz, scale=20)
```




Figura 4.3: Elemento estruturante em formato de cruz ( $B_{\text{cruz}}$ ) utilizado para conectividade-4.

```
def _viz(f, B, y, x):
    """Gera (vy, vx, b_val) para cada vizinho válido de (y,x)."""
    H, W = f.shape
    Bh, Bw = B.shape
    oh, ow = -Bh/2 + 0.5, -Bw/2 + 0.5 # offsets fixos
    for by, bx in np.ndindex(Bh, Bw):
        vy, vx = int(y + by + oh), int(x + bx + ow)
        if 0 <= vy < H and 0 <= vx < W:
            yield vy, vx, B[by, bx]

def ero(f, Bc=np.zeros((3,3),dtype='uint8')):
    """Erosão (OpenCV ou com pesos)."""
    try:
        return cv2.erode(f, Bc)
```

```

except: return mm.ero1(f, Bc)

def ero0(f, Bc=np.ones((3,3),dtype='uint8')):
    """Erosão clássica sem pesos."""
    g = np.empty_like(f)
    for y in range(f.shape[0]):
        for x in range(f.shape[1]):
            g[y,x] = 255
            for vy,vx,bv in mm._viz(f,Bc,y,x):
                if bv and g[y,x] > f[vy,vx]: g[y,x] = f[vy,vx]
    return g

# Script de Teste e Validação
B = mm.seccross()
print("Elemento estruturante B:")
print(mm.drawImage(B))

f = mm.randomImage(5,5)
print("Imagem original f:")
print(mm.drawImage(f))

print("Erosão Plana Didática (ero0):")
print(mm.drawImage(ero0(f, B)))

print("Erosão Otimizada OpenCV (ero):")
print(mm.drawImage(ero(f, B)))

```

```

Elemento estruturante B:
0 1 0
1 1 1
0 1 0

Imagem original f:
8 0 3 5 3
1 9 9 8 1
8 2 2 5 4
9 9 7 2 9
6 9 7 1 9

Erosão Plana Didática (ero0):
0 0 0 3 1
1 0 2 1 1
1 2 2 2 1
6 2 2 1 2
6 6 1 1 1

Erosão Otimizada OpenCV (ero):
0 0 0 3 1
1 0 2 1 1
1 2 2 2 1
6 2 2 1 2
6 6 1 1 1

```

A função `_viz` utiliza `yield` para gerar cada vizinho sob demanda, sem armazenar todos os resultados em memória em uma lista. No experimento abaixo, uma janela de  $3000 \times 3000$  produz 9 milhões de vizinhos. A implementação baseada em lista consumiu mais de 1 GB de RAM e levou aproximadamente 46 s, enquanto a versão com `yield` consumiu memória desprezível e executou em 38 s. Em processamento de imagens, geradores são especialmente úteis para percorrer grandes vizinhanças de forma eficiente.

```
import tracemalloc

def lista(n): return [(i, i) for i in range(n)]
def gera(n):
    for i in range(n): yield i, i

for nome, f in [("LISTA", lista), ("YIELD", gera)]:
    tracemalloc.start()
    sum(x+y for x,y in f(9_000_000))
    _, pico = tracemalloc.get_traced_memory()
    tracemalloc.stop()
    print(f"{nome}: {pico/1024/1024:.1f} MB")
```

```
LISTA: 830.8 MB
YIELD: 0.0 MB
```

#### 4.3.1.3 Dilatação

A **Dilatação** de uma imagem  $f$  por uma função estruturante  $b : \mathbb{B} \rightarrow \mathbb{Z}$  é definida formalmente por:

$$\delta_b(f)(x) = (f \oplus b)(x) = \max_{z \in \mathbb{B}} \{ f(x - z) + b(z) \}, \quad \forall x \in \mathbb{E} \quad (4.4)$$

Na prática, a dilatação substitui a intensidade do pixel  $x$  pelo maior valor resultante da soma entre a imagem e o elemento estruturante na vizinhança definida. O argumento de inversão espacial ( $x - z$ ) indica que a dilatação avalia implicitamente o elemento transposto (refletido)  $\hat{b}$ , propriedade fundamental para assegurar a dualidade matemática em relação à erosão.

No caso **plano** (onde os pesos são nulos dentro do domínio, ou seja,  $b \equiv 0$ ), a expressão reduz-se ao máximo local puro:

$$\delta_B(f)(x) = \max \{ f(y) : y \in \mathbb{B}_x \}$$

Em imagens binárias, essa operação equivale a exigir que o conjunto refletido  $\hat{\mathbb{B}}$ , transladado para a coordenada  $x$ , possua **interseção não vazia** com o objeto  $A$ :

$$A \oplus \mathbb{B} = \{ z \in \mathbb{E} \mid \hat{\mathbb{B}}_z \cap A \neq \emptyset \}$$

**Efeito Visual:** *Expand*e as estruturas claras da imagem, aumentando o preenchimento de objetos, conectando componentes próximos e eliminando canais, fossas escuras ou vales que sejam geometricamente menores que o domínio  $\mathbb{B}$ .

#### 4.3.1.4 Implementação da dilatação

A versão didática `mm.dil0` implementa o caso particular de dilatação com **elemento estruturante plano**. Para cada pixel  $(y, x)$ , a função percorre os vizinhos espaciais permitidos por  $B$  e armazena o maior valor encontrado na imagem de entrada  $f$ , reproduzindo diretamente a operação de máximo local para  $b \equiv 0$ .

Antes de iniciar a varredura espacial, o elemento estruturante sofre uma reflexão geométrica por meio da instrução `np.flip(Bc)` para construir explicitamente a matriz transposta  $\hat{B}$  exigida pela teoria. Em máscaras perfeitamente simétricas (como cruzeiros, quadrados e discos centrados na origem), essa reflexão não altera o arranjo dos pixels; contudo, para elementos assimétricos, tal etapa é estritamente necessária para garantir a equivalência com as definições formais e salvaguardar as leis de dualidade.

Assim como verificado no operador de erosão, os valores dos vizinhos são sempre lidos de forma estática a partir da matriz original  $f$ , enquanto a matriz de saída  $g$  atua puramente como o registrador do máximo acumulado da vizinhança. Nas fronteiras da imagem, a inicialização do acumulador em 0 emula com exatidão

o preenchimento externo por elemento neutro ( $-\infty$ , ou zero em representações de 8 bits), garantindo que as bordas físicas da cena sejam dilatadas em perfeita conformidade com o padrão adotado pelo OpenCV.

O exemplo computacional abaixo ilustra a aplicação prática de um elemento em cruz (`mm.secross()`), validando a consistência entre a lógica em laços (`mm.dil0`) e o método nativo industrial (`mm.dil`).

```
def dil(f, Bc=np.zeros((3,3),dtype='uint8')):
    """Dilatação (OpenCV ou com pesos)."""
    try:    return cv2.dilate(f, Bc)
    except: return mm.dil1(f, Bc)

def dil0(f, Bc=np.zeros((3,3),dtype='uint8')):
    """Dilatação plana seguindo rigorosamente a teoria."""
    g = np.empty_like(f)
    Bc = np.flip(Bc)      # reflexão explícita: B
    for y in range(f.shape[0]):
        for x in range(f.shape[1]):
            g[y,x] = 0 # Inicializa com o valor mínimo para buscar o máximo
            for vy,vx,bv in mm._viz(f,Bc,y,x):
                if bv and g[y,x] < f[vy,vx]:
                    g[y,x] = f[vy,vx]

    return g

# Script de Teste e Validação
B = mm.secross()
print("Elemento estruturante B:")
print(mm.drawImage(B))

f = mm.randomImage(5,5)
print("Imagem original f:")
print(mm.drawImage(f))

print("Dilatação Plana Didática (dil0):")
print(mm.drawImage(dil0(f, B)))

print("Dilatação Otimizada OpenCV (dil):")
print(mm.drawImage(dil(f, B)))
```

```
Elemento estruturante B:
0 1 0
1 1 1
0 1 0

Imagem original f:
9 2 0 8 4
9 3 8 6 1
1 4 1 1 3
2 9 4 9 6
6 8 6 8 7

Dilatação Plana Didática (dil0):
9 9 8 8 8
9 9 8 8 6
9 9 8 9 6
9 9 9 9 9
8 9 8 9 8

Dilatação Otimizada OpenCV (dil):
9 9 8 8 8
9 9 8 8 6
```



```

9 9 8 9 6
9 9 9 9 9
8 9 8 9 8

```

### **i** Nota: O Confronto dos Sinais ( $f(x+z)$ vs $f(x-z)$ )

Compare as definições formais da erosão (Equation 4.3) e da dilatação (Equation 4.4). Considere um elemento estruturante assimétrico à direita  $\mathbb{B} = \{0, 1\}$  (origem e um pixel à direita) aplicado na posição  $x = 10$ .

#### 1. Na Erosão (Equation 4.3):

$$\min\{f(x+z) - b(z)\}$$

- $z = 0 \Rightarrow f(10+0) = \mathbf{f(10)}$
- $z = 1 \Rightarrow f(10+1) = \mathbf{f(11)}$

O operador consulta o pixel atual (10) e o pixel à direita (11), preservando a orientação original de  $\mathbb{B}$ .

#### 2. Na Dilatação (Equation 4.4):

$$\max\{f(x-z) + b(z)\}$$

- $z = 0 \Rightarrow f(10-0) = \mathbf{f(10)}$
- $z = 1 \Rightarrow f(10-1) = \mathbf{f(9)}$

Devido ao sinal negativo ( $-z$ ), avançar no elemento estruturante corresponde a recuar na imagem, fazendo com que a dilatação consulte o pixel à esquerda (9).

A função `_viz`, utilizada em `morph.py`, gera vizinhos por deslocamentos aditivos da forma  $x+z$ . Por esse motivo, a implementação de `mm.dil0` reflete previamente o elemento estruturante por meio de `np.flip(B)`. Após a reflexão, a varredura baseada em  $x+z$  passa a acessar exatamente os mesmos pontos definidos pela expressão teórica  $f(x-z)$  da dilatação em Equation 4.4.

Para elementos estruturantes simétricos (como discos, quadrados e cruzes centradas), a reflexão não altera a máscara. Já para elementos assimétricos, essa etapa é indispensável para que a implementação reproduza corretamente a definição matemática da dilatação e preserve a dualidade erosão–dilatação.

### **i** Dualidade erosão–dilatação

Erosão e dilatação são **duais pelo complemento**. Isso significa que um operador pode ser completamente obtido a partir do outro, desde que se atue sobre o complemento da imagem utilizando o elemento estruturante refletido  $\hat{B}$ :

$$(A \ominus B)^c = A^c \oplus \hat{B} \quad \Longleftrightarrow \quad A \ominus B = (A^c \oplus \hat{B})^c$$

De forma análoga, a **dilatação também pode ser obtida a partir da erosão**:

$$(A \oplus B)^c = A^c \ominus \hat{B} \quad \Longleftrightarrow \quad A \oplus B = (A^c \ominus \hat{B})^c$$

Em termos práticos, a erosão de um objeto pode ser obtida pela dilatação de seu complemento, seguida da complementação do resultado (e vice-versa). Na implementação do pacote `morph.py`, as versões didáticas `mm.ero0` e `mm.dil0` tornam explícita essa estrutura por meio de laços (*loops*), enquanto `mm.ero` e `mm.dil` delegam as operações ao OpenCV visando maior eficiência computacional.

### **i** Condições de contorno e imagens finitas

Na morfologia matemática clássica, definida sobre um domínio infinito (tipicamente  $\mathbb{Z}^2$ ), essa dualidade é exata. Em imagens digitais, entretanto, trabalha-se com matrizes finitas, e o resultado passa a depender da forma como são tratados os pixels localizados fora da imagem.

Para que as identidades de dualidade permaneçam válidas, o complemento deve ser definido em relação ao mesmo universo e as condições de contorno adotadas para a erosão e para a dilatação devem ser complementares entre si. Por exemplo, se a erosão assume que os pixels externos pertencem ao objeto (255), então a dilatação aplicada ao complemento deve assumir que esses mesmos pixels externos pertencem ao fundo (0).

Quando diferentes estratégias de preenchimento são utilizadas (replicação, reflexão, valor constante etc.), a dualidade teórica pode deixar de ser satisfeita exatamente nas regiões próximas às bordas da imagem.

Para ilustrar numericamente os operadores morfológicos e a dualidade erosão–dilatação, a Figure 4.4 apresenta uma imagem binária 10×10 processada com um elemento estruturante em formato de “L”. Na implementação de `morph.py`, a origem de  $B$  é fixada no centro geométrico da máscara — posição (1,1) para um *kernel* 3×3 — e deve corresponder a um elemento ativo para que a erosão se comporte corretamente (conforme discutido anteriormente). O elemento estruturante  $B_L$  definido a seguir satisfaz essa condição. A Figure 4.5 complementa a análise com um simulador interativo da erosão, permitindo visualizar o deslocamento do elemento estruturante sobre a imagem e identificar as posições em que ele permanece completamente contido no objeto.

```
A = np.array([
    [0,0,0,0,0,0,0,0,0,0],
    [0,0,0,1,1,1,0,0,0,0],
    [0,0,1,1,1,1,1,0,0,0],
    [0,1,1,1,1,1,1,1,0,0],
    [0,1,1,1,1,1,1,1,0,0],
    [0,1,1,1,1,1,1,1,0,0],
    [0,1,1,1,1,1,1,1,0,0],
    [0,0,1,1,1,1,1,1,0,0],
    [0,0,0,1,1,1,1,1,0,0],
    [0,0,0,0,1,0,0,0,0,0],
    [0,0,0,0,0,0,0,0,0,0]], dtype=np.uint8) * 255

B_L = np.array([[1,0,0],
                [1,1,0],
                [1,1,0]], dtype=np.uint8) # origem no centro (1,1), elemento ativo

# Elemento estruturante refletido B
B_hat = np.flip(B_L)
print("Elemento estruturante B_L:")
print(mm.drawImg(B_L))
print("Elemento estruturante refletido B:")
print(mm.drawImg(B_hat))

# Erosão de A por B_L
img_ero0 = mm.ero0(A, B_L)

# Validação da dualidade: (A ∖ B)c = Ac ∖ B
A_c = 255 - A # complemento de A
ero_c = 255 - img_ero0 # complemento da erosão - lado esquerdo
dil_Ac = mm.dil0(A_c, B_hat) # lado direito

dualidade_ok = np.array_equal(ero_c, dil_Ac)
print(f"Dualidade (A ∖ B)c == Ac ∖ B : {dualidade_ok}")
# Transposto (reflexão em ambos os eixos): B usado na dilatação da dualidade
B_hat = np.flip(B_L)
mm.show(
    [A, A_c, img_ero0, ero_c, dil_Ac],
    titles=["A", "A ", "A ∖ B", "(A ∖ B) ", "A ∖ B"],
    cols=5,
```

```
figsize=(15, 3)
)
```

Elemento estruturante B\_L:

```
1 0 0
1 1 0
1 1 0
```

Elemento estruturante refletido B:

```
0 1 1
0 1 1
0 0 1
```

Dualidade  $(A \ominus B)^c == A^c \oplus B$  : True




Figura 4.4: Erosão e dilatação em imagem binária 10×10 com elemento estruturante ‘L’ assimétrico 3×3. Validação da dualidade erosão–dilatação.

### 4.3.2 Abertura e Fechamento

Combinando erosão e dilatação obtêm-se dois operadores de grande utilidade prática: a **abertura** e o **fechamento**, definidos pelas Equações Equation 4.5 e Equation 4.6. Seus principais efeitos são resumidos na Table 4.2.

**Abertura** (*opening*) — erosão seguida de dilatação pelo mesmo  $B$ :

$$A \circ B = (A \ominus B) \oplus B \quad (4.5)$$

**Fechamento** (*closing*) — dilatação seguida de erosão pelo mesmo  $B$ :

$$A \bullet B = (A \oplus B) \ominus B \quad (4.6)$$

Na prática, o OpenCV aplica o mesmo elemento estruturante nas duas etapas. Para elementos estruturantes simétricos (os mais comuns), essa implementação coincide com a definição matemática apresentada acima.

Tabela 4.2: Propriedades de abertura e fechamento.

| Operador                 | Sequência          | Efeito principal                                                                          |
|--------------------------|--------------------|-------------------------------------------------------------------------------------------|
| Abertura $A \circ B$     | erosão → dilatação | Remove estruturas incapazes de conter o elemento estruturante; suaviza contornos externos |
| Fechamento $A \bullet B$ | dilatação → erosão | Preenche buracos menores que $B$ ; suaviza contornos internos                             |

**Propriedade importante:** ambos são **idempotentes**. Por exemplo,




Figura 4.5: Simulador interativo de erosão morfológica: visualização do critério de inclusão do elemento estruturante assimétrico  $B_L$  sobre a imagem binária  $A$ .

$$(A \circ B) \circ B = A \circ B,$$

ou seja, após a primeira aplicação, novas aplicações do mesmo operador não alteram mais o resultado.

#### 4.3.2.1 Implementação da abertura e do fechamento

Diferentemente da erosão e da dilatação, abertura e fechamento não introduzem novos mecanismos computacionais. Ambos são obtidos pela composição sequencial dos operadores primitivos já apresentados:

```
def open0(f, B):
    return mm.dil0(mm.ero0(f, B), B)

def close0(f, B):
    return mm.ero0(mm.dil0(f, B), B)
```

A função `mm.open` delega a operação para `cv2.morphologyEx(..., MORPH_OPEN, B)`, enquanto `mm.close` utiliza `cv2.morphologyEx(..., MORPH_CLOSE, B)`, produzindo o mesmo resultado de forma mais eficiente.

A abertura herda da erosão a capacidade de remover estruturas menores que o elemento estruturante e da dilatação a restauração parcial das regiões preservadas. O fechamento realiza o processo inverso: primeiro expande os objetos e depois restaura suas dimensões originais, preenchendo lacunas e buracos menores que o elemento estruturante.

#### 4.3.2.2 Filtro Sequencial Alternado

Na prática, abertura e fechamento são frequentemente aplicados em sequência para remover simultaneamente ruído externo e preencher buracos internos. A função `mm.asf` (*Alternating Sequential Filter*) generaliza essa estratégia ao aplicar aberturas e fechamentos alternadamente com elementos estruturantes progressivamente maiores. As sequências disponíveis são apresentadas na Table 4.3.

Tabela 4.3: Sequências do filtro sequencial alternado `mm.asf`.

| Sequência | Ordem                              | Uso típico                                               |
|-----------|------------------------------------|----------------------------------------------------------|
| 'OC'      | abertura → fechamento              | remove ruído externo antes de preencher pequenos buracos |
| 'CO'      | fechamento → abertura              | preenche pequenos buracos antes de remover ruído externo |
| 'OCO'     | abertura → fechamento → abertura   | ênfatisa a remoção de ruído externo                      |
| 'COC'     | fechamento → abertura → fechamento | ênfatisa o preenchimento de buracos e lacunas            |

O parâmetro `n` controla o número de escalas utilizadas pelo filtro. Em cada iteração  $i$ , o elemento estruturante é ampliado por soma de Minkowski (`mm.sesum(b, i)`), produzindo uma sequência de filtros morfológicos cada vez mais abrangentes. Diferentemente de uma única abertura ou fechamento com um elemento estruturante grande, o ASF realiza uma suavização progressiva em múltiplas escalas, preservando melhor a geometria dos objetos relevantes enquanto elimina estruturas menores. A Figure 4.6 apresenta um exemplo de aplicação da abertura, do fechamento e do ASF na imagem das moedas.

```
img_bin    = mm.threshold(img_clahe)
B_disk     = mm.sedisk(19)

img_open   = mm.open(img_bin, B_disk)           # erosão → dilatação
img_close  = mm.close(img_bin, B_disk)          # dilatação → erosão
img_oc     = mm.close(img_open, B_disk)         # abertura seguida de fechamento
img_asf    = mm.asf(img_bin, 'OC', mm.sedisk(3), n=7)
# ASF: disco base 3×3, cresce a cada iteração
```

```
mm.show(
    [img_bin, img_open, img_close, img_oc, img_asf],
    titles=["Binarização Otsu (CLAHE)", "Abertura (A∘B)", "Fechamento (A⋄B)",
           "Abertura→Fechamento", "ASF-OC (n=7)"],
    cols=5, figsize=(15, 12)
)
```




Figura 4.6: Abertura, fechamento, composição e filtro sequencial alternado aplicados à binarização Otsu das moedas com CLAHE. Elemento estruturante: disco  $13 \times 13$ .

### 4.3.3 Operadores Geodésicos

Os operadores geodésicos introduzem uma restrição adicional aos operadores morfológicos clássicos por meio de uma imagem de controle denominada **máscara**  $g$ . Em vez de permitir que a erosão ou a dilatação se propaguem livremente pela imagem, o resultado de cada iteração é limitado ponto a ponto pelos valores da máscara, restringindo a evolução da operação às regiões permitidas.

#### 4.3.3.1 Dilatação Geodésica

A **dilatação geodésica** de uma imagem marcador  $f$  sob uma imagem máscara  $g$ , utilizando um elemento estruturante plano  $b$ , é definida por:

$$f \oplus_g b = (f \oplus b) \wedge g, \quad (4.7)$$

onde  $\wedge$  representa o mínimo ponto a ponto.

Em outras palavras, realiza-se inicialmente uma dilatação convencional sobre o marcador e, em seguida, o resultado é restringido pela máscara  $g$ . Dessa forma, a propagação nunca pode ultrapassar as regiões permitidas pela máscara.

A formulação clássica da dilatação geodésica pressupõe que o marcador esteja contido na máscara, isto é,  $f \leq g$ , garantindo que a evolução da operação permaneça sempre limitada pela máscara.

#### 4.3.3.2 Implementação da dilatação geodésica

A função `mm.cdil` implementa diretamente esse operador e permite executar múltiplas iterações consecutivas:

```
def cdil(f, g, b=np.zeros((3,3),dtype='uint8'), n=1):
    """Dilatação geodésica do marcador f sob a máscara g."""
    y = f.copy()
    for _ in range(n):
        y = np.minimum(cv2.dilate(y, b), g)
    return y
```



A instrução `np.minimum(cv2.dilate(y, b), g)` implementa exatamente a definição matemática da dilatação geodésica, isto é,  $(y \oplus b) \wedge g$ .

Quando  $n = 1$ , a função executa uma única dilatação geodésica. Para  $n > 1$ , o resultado de cada etapa torna-se o marcador da etapa seguinte, produzindo uma propagação progressiva controlada pela máscara.

O simulador interativo Figure 4.7 permite acompanhar, passo a passo, a propagação do marcador  $f$  ao longo dos corredores do labirinto. A cada iteração de `mm.cdil`, a frente de dilatação avança para as células vizinhas livres — aquelas em que  $g = 1$  —, enquanto as paredes ( $g = 0$ ) permanecem intransponíveis. O número de passos necessários para que o marcador alcance a saída corresponde exatamente ao comprimento geodésico do caminho mais curto dentro da máscara, evidenciando a conexão direta entre a dilatação geodésica iterada e a noção de distância em grafos.



Figura 4.7: Simulador interativo de dilatação geodésica: o marcador  $f$  (verde) propaga-se passo a passo pelos caminhos livres da máscara  $g$ , sem atravessar paredes — ilustrando como  $\delta_g^{(n)}(f)$  encontra a saída do labirinto.

#### 4.3.3.3 Erosão Geodésica

De forma dual, a **erosão geodésica** de uma imagem marcador  $f$  sob uma imagem máscara  $g$  é definida por:

$$f \ominus_g b = (f \ominus b) \vee g, \quad (4.8)$$

onde  $\vee$  representa o operador de máximo ponto a ponto.

Nesse caso, a erosão convencional do marcador é seguida por uma restrição inferior imposta pela máscara. Assim, nenhum pixel do resultado pode assumir valor inferior ao correspondente pixel da máscara.

A formulação clássica da erosão geodésica pressupõe a condição dual

$$f \geq g,$$

de modo que a máscara atue como limite inferior durante todo o processo.

#### 4.3.3.4 Implementação da erosão geodésica

A função estática `mm.cero` materializa esse operador:

```
@staticmethod
def cero(f, g, b=np.zeros((3,3),dtype='uint8'), n=1):
    """Erosão geodésica do marcador f sob a máscara g."""
    y = f.copy()
    for _ in range(n):
        y = np.maximum(cv2.erode(y, b), g)
    return y
```

A instrução `np.maximum(cv2.erode(y, b), g)` implementa diretamente a expressão  $(y \ominus b) \vee g$ .

Assim como na dilatação geodésica, o parâmetro  $n$  define quantas erosões geodésicas sucessivas serão computadas antes de retornar a imagem final.

#### i Relação com a reconstrução morfológica

A reconstrução morfológica apresentada na próxima seção é obtida pela aplicação iterativa da dilatação geodésica (`mm.cdil`) até que um ponto fixo seja alcançado, isto é, até que nenhuma célula mude de valor entre duas iterações consecutivas. Em outras palavras, a reconstrução consiste em uma sequência de dilatações geodésicas sucessivas que se propagam dentro da máscara até não haver mais alterações. De forma dual, também é possível definir reconstruções baseadas em erosão geodésica por meio de aplicações sucessivas de `mm.cero`.

#### 4.3.3.5 Exemplo: propagação em um labirinto via dualidade

A Figure 4.8 ilustra a resolução do problema de conectividade de um labirinto utilizando a dualidade morfológica por meio das funções `mm.cero` e `mm.suprec`.

Em vez de propagar um marcador pelos corredores livres através de dilatações geodésicas, o problema é formulado no domínio complementar. Inicialmente, a máscara original é invertida,

$$g = 1 - g_{orig},$$

fazendo com que as paredes passem a assumir valor 1 e os corredores valor 0. De forma análoga, o marcador é construído nesse mesmo domínio complementar, contendo um único valor 0 na posição de entrada do labirinto e valor 1 nos demais pixels.

Utilizando o elemento estruturante em cruz (`mm.secross()`), a erosão geodésica atua sobre o marcador complementado. A cada iteração de `mm.cero`, a região conectada ao marcador inicial sofre erosões sucessivas, enquanto a máscara impõe um limite inferior que impede a propagação através das paredes do labirinto.

As imagens intermediárias mostram estados da evolução após diferentes números de iterações ( $n=5$ ,  $n=12$  e  $n=22$ ). O resultado final é obtido pela reconstrução geodésica por erosão (`mm.suprec`), que aplica erosões geodésicas sucessivas até atingir um ponto fixo, isto é, uma situação em que nenhuma alteração adicional ocorre entre duas iterações consecutivas.

No domínio complementar, a região reconstruída corresponde exatamente ao conjunto de corredores conectados à entrada do labirinto. Assim, a conectividade entre entrada e saída pode ser determinada diretamente a partir da imagem reconstruída.

```
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.colors as mcolors

# 1. Máscara original g (0 = Parede, 1 = Corredor)
g_orig = np.array([
    [0, 1, 0, 0, 0, 0, 0, 0, 0, 0],
    [0, 1, 1, 1, 1, 1, 0, 1, 1, 1],
    [0, 0, 0, 0, 0, 1, 0, 1, 0, 1],
    [0, 1, 1, 1, 0, 1, 1, 1, 0, 1],
    [0, 1, 0, 1, 0, 0, 0, 0, 0, 1],
    [0, 1, 0, 1, 1, 1, 1, 1, 1, 1],
    [0, 1, 0, 0, 0, 0, 0, 0, 1, 0],
    [0, 1, 1, 1, 1, 1, 1, 0, 1, 0],
    [0, 0, 0, 0, 0, 0, 1, 1, 1, 0],
    [0, 0, 0, 0, 0, 0, 0, 0, 1, 0]], dtype=np.uint8)

# Inversão global no início (Dualidade Morfológica)
g = 1 - g_orig # Agora: 1 = Parede, 0 = Corredor
f = np.ones((10, 10), dtype=np.uint8)
f[0, 1] = 0 # Semente injetada como 0 no corredor

# Elemento estruturante em cruz
B_cruz = mm.secross()

# Processamento direto usando mm.cero e mm.suprec no domínio invertido
passo_5 = mm.cero(f, g, B_cruz, n=5)
passo_12 = mm.cero(f, g, B_cruz, n=12)
passo_22 = mm.cero(f, g, B_cruz, n=22)
ponto_fixo = mm.suprec(f, g, B_cruz)

# --- CONFIGURAÇÃO DA EXIBIÇÃO GRÁFICA ---

titles = [
    "Máscara (~g)", "Marcador (~f)",
    "Avanço (n=5)", "Avanço (n=12)",
    "Avanço (n=22)", "~mm.suprec"
]

images = [g, f, passo_5, passo_12, passo_22, ponto_fixo]

fig, axes = plt.subplots(1, 6, figsize=(16, 4), facecolor='#fcfcfc')

# Mapa de cores adaptado para o domínio complementar:
# No domínio invertido: 1 = Parede (Azul Escuro)
# Onde g == 0 e imagem == 1 = Corredor Livre (Cinza Claro)
# Onde g == 0 e imagem == 0 = Onda Geodésica Ativa (Ouro)
cmap_pipeline = mcolors.ListedColormap(['#ffc13b', '#e0e0e0', '#1e3d59'])

for i, ax in enumerate(axes):
    if i == 0 or i == 1:
        # Para as condições iniciais (~g e ~f)
        cmap_init = mcolors.ListedColormap(['#e0e0e0', '#1e3d59'])
        ax.imshow(images[i], cmap=cmap_init, vmin=0, vmax=1)
    else:
        # Renderização baseada nos estados complementares
        render_step = np.zeros_like(g, dtype=np.uint8)
```

```

render_step[g == 1] = 2      # Parede (1 original do mapa de cores)
render_step[g == 0] = 1      # Corredor padrão
render_step[images[i] == 0] = 0 # Onda ativa (0 original do mapa de cores)
ax.imshow(render_step, cmap=cmap_pipeline, vmin=0, vmax=2)

ax.set_title(titles[i], fontsize=10, fontweight='bold', color='#1e3d59', pad=12)
ax.set_xticks(np.arange(-0.5, 10, 1), minor=True)
ax.set_yticks(np.arange(-0.5, 10, 1), minor=True)
ax.grid(which='minor', color='ffffff', linestyle='--', linewidth=1)
ax.tick_params(which='both', bottom=False, left=False, labelbottom=False, labelleft=False)

# Indicadores gráficos de Entrada e Saída
ax.plot(1, 0, marker='v', color='#2ecc71', markersize=7, markeredgewidth=1.5)
ax.plot(8, 9, marker='o', color='#e74c3c', markersize=6, fillstyle='none', markeredgewidth=2)

plt.tight_layout()
plt.show()

```




Figura 4.8: Resolução de labirinto via Operações Complementares: Invertendo a máscara e o marcador no início do *pipeline*, o fluxo é resolvido diretamente no domínio complementar através de *mm.cero* e *mm.suprec*, eliminando re-inversões redundantes.

#### 4.3.4 Reconstrução Morfológica

A **reconstrução morfológica** propaga uma imagem **marcador**  $f$  dentro de uma imagem **máscara**  $g$ , garantindo que o resultado nunca ultrapasse os valores de intensidade impostos pela máscara. O operador fundamental que viabiliza essa propagação contida é a **dilatação geodésica**, definida pela Equation 4.7.

A reconstrução é obtida pela aplicação iterativa dessa dilatação condicionada. Inicialmente, o marcador é limitado pela máscara para estabelecer o estado inicial:

$$X^{(0)} = f \wedge g,$$

e as iterações subsequentes são definidas de forma recursiva por:

$$X^{(k)} = (X^{(k-1)} \oplus b) \wedge g.$$

A sequência cresce monotonicamente até atingir um ponto fixo, produzindo a **reconstrução morfológica por dilatação** (também conhecida na literatura como *inf-reconstrução*):

$$R_g^\delta(f) = \lim_{k \rightarrow \infty} X^{(k)} = X^{(k)} \quad \text{quando} \quad X^{(k)} = X^{(k-1)}. \quad (4.9)$$

A subida iterativa é interrompida assim que a estabilidade é alcançada, isto é, quando duas iterações consecutivas produzem matrizes com valores absolutamente idênticos.

#### 4.3.4.1 Implementação da reconstrução morfológica

A rotina didática `mm.infrec` implementa diretamente o algoritmo iterativo de ponto fixo. Inicialmente, o marcador efetivo inicial  $X^{(0)}$  é determinado pela operação `np.minimum(f, g)`. Para garantir que o laço de verificação execute a primeira passada sem disparar falsas convergências prematuras, a variável de controle da iteração anterior (`y1`) é inicializada preenchida com um valor sentinela fora do domínio de dados (ou simplesmente com uma matriz que force a primeira execução).

```
def infrec(f, g, b=np.zeros((3,3), dtype='uint8')):
    """Inf-reconstrução: dilata o marcador (f, g) até convergir sob a máscara g."""
    y = np.minimum(f, g)
    # Inicializa y1 com valores impossíveis para forçar a entrada no laço
    y1 = np.full_like(f, 256, dtype=np.int16)
    while not np.array_equal(y, y1):
        y1 = y.copy()
        # Aplica a dilatação geodésica: (y, b) g
        y = np.minimum(cv2.dilate(y, b), g)
    return y.astype('uint8')
```

No interior do laço `while`, a variável `y` armazena a estimativa corrente da reconstrução  $X^{(k)}$ , enquanto `y1` preserva a imagem do estágio imediatamente anterior  $X^{(k-1)}$ . A instrução de controle condicional `np.minimum(cv2.dilate(y, b), g)` traduz fielmente a dilatação geodésica teórica, onde a expansão morfológica convencional comandada pelo OpenCV é imediatamente “podada” e limitada pelas barreiras de intensidade da máscara `g`. O laço cessa quando nenhuma modificação de pixel é registrada entre os passos.

#### 4.3.4.2 Vantagens da reconstrução morfológica

A reconstrução morfológica é significativamente mais robusta que a abertura convencional porque é capaz de remover estruturas indesejadas sem distorcer ou alterar a morfologia dos objetos que devem ser preservados.

Enquanto a abertura clássica suaviza cantos, elimina pontas e deforma contornos devido à imposição geométrica rígida do elemento estruturante, a reconstrução geodésica utiliza a máscara para recuperar com exatidão os limites e formatos originais dos objetos que possuem conectividade com o marcador original.

Em termos intuitivos, o marcador atua como uma semente de contágio que se expande progressivamente, mas apenas trafegando pelas regiões permitidas pela máscara. Componentes que não possuem nenhuma intersecção com o marcador jamais serão reconstruídas (sendo eliminadas), enquanto as componentes tocadas pela semente expandem-se até restaurar integralmente a sua geometria original.

Esse comportamento discriminatório e conservativo é ilustrado na Figure 4.9, utilizando o elemento estruturante em cruz apresentado na Figure 4.3.

```
# 1. Definição da Máscara (g): Imagem 10x10 com dois objetos isolados
g = np.array([
    [0,0,0,0,0,0,0,0,0,0],
    [0,1,1,1,0,0,0,1,1,0],
    [0,1,1,1,1,0,0,1,1,0],
    [0,1,1,1,1,0,0,0,0,0],
    [0,1,1,1,1,0,0,0,0,0],
    [0,1,1,1,0,0,0,0,0,0],
    [0,0,1,1,1,0,0,1,0,0],
    [0,0,1,1,1,0,0,1,1,0],
    [0,0,0,1,0,0,0,0,0,0],
    [0,0,0,0,0,0,0,0,0,0]], dtype=np.uint8) * 255

B_cruz = mm.secross()

# 2. Geração do Marcador (f)
f = mm.ero(g, mm.sebox())
```

```
# 3. Iterações da Dilatação Condicionada automatizadas em laço
iteracoes = []
titulos_iteracoes = []
img_atual = f.copy()

for i in range(1, 6):
    img_add = img_atual*80
    img_atual = mm.cdil(img_atual, g, B_cruz)
    iteracoes.append(img_add+img_atual)
    titulos_iteracoes.append(f"Dilatação Cond. (n={i})")

# Reconstrução Geodésica Final via biblioteca (ponto de controle)
img_reconstruida = mm.infrec(f, g, B_cruz)

# Verificação de convergência (o passo 5 deve ser idêntico à reconstrução final)
convergencia_ok = np.array_equal(img_reconstruida, iteracoes[-1])
print(f" Reconstrução alcançou estabilidade na iteração 5: {convergencia_ok}")

# 4. Exibição do pipeline evolutivo (Montagem dinâmica das listas)
mm.show(
    [g, f] + iteracoes + [img_reconstruida],
    titles=["Máscara (g)", "Marcador (f)"] + titulos_iteracoes + ["Reconstrução Final R_g(f)"],
    cols=8,
    figsize=(18, 3)
)
```

Reconstrução alcançou estabilidade na iteração 5: False




Figura 4.9: *Pipeline* de Reconstrução Morfológica por Dilatação Condicionada: a máscara contém dois objetos, o marcador isola apenas o núcleo do objeto principal, e as iterações subsequentes em laço reconstróem sua forma exata até a convergência.

#### 4.3.5 Preenchimento de Buracos e Remoção de Bordas

Dois operadores baseados em reconstrução morfológica completam o *pipeline* de limpeza binária. Suas características principais são resumidas na Table 4.4.

**Preenchimento de buracos** (`mm.clohole`) remove cavidades completamente cercadas pelo objeto, independentemente do tamanho, sem alterar os contornos externos. O procedimento atua no complemento da imagem, utilizando como marcador uma restrição da moldura (*frame*) ao fundo:

$$\text{clohole}(f) = (R_{f^c}^\delta(\text{frame}(f) \wedge f^c))^c \quad (4.10)$$

Em termos operacionais, primeiro reconstrói-se o fundo externo e, em seguida, aplica-se a complementação para recuperar os objetos com buracos preenchidos.

**Remoção de objetos de borda** (`mm.edgeoff`) elimina todos os objetos que tocam a borda da imagem, preservando apenas os componentes totalmente internos. O marcador é obtido pela interseção entre a moldura (*frame*) e os objetos da imagem:



$$\text{edgeoff}(f) = f \setminus R_f^\delta(\text{frame}(f) \wedge f) \quad (4.11)$$

Tabela 4.4: Comparação entre os operadores *clohole* e *edgeoff*.

| Operador                | Marcador                                    | Máscara | Efeito                            |
|-------------------------|---------------------------------------------|---------|-----------------------------------|
| <code>mm.clohole</code> | <i>frame</i> restrito ao fundo<br>( $f^c$ ) | $f^c$   | Preenche buracos internos         |
| <code>mm.edgeoff</code> | <i>frame</i> restrito ao objeto ( $f$ )     | $f$     | Remove objetos conectados à borda |

A evolução passo a passo dessas transformações geodésicas pode ser acompanhada nas figuras a seguir. A Figure 4.10 ilustra o mecanismo de inundação controlada do operador `mm.clohole`, no qual a reconstrução ocorre a partir do fundo externo e impede a propagação para regiões internas não conectadas ao exterior, resultando no preenchimento consistente das cavidades internas. Em contrapartida, a Figure 4.11 detalha a dinâmica do operador `mm.edgeoff`, em que apenas os componentes conectados à borda são reconstruídos e posteriormente removidos, preservando exclusivamente os objetos totalmente contidos no interior da imagem.

A conectividade da propagação geodésica é controlada pelo elemento estruturante: `mm.sebox()` (vizinhança de 8) inclui conexões diagonais, enquanto `mm.secross()` (vizinhança de 4) as exclui. Consequentemente, a escolha do elemento estruturante afeta quais componentes são alcançados pela reconstrução e, portanto, quais serão preservados ou removidos.

#### 4.3.5.1 Conformidade com a implementação

As definições acima estão diretamente alinhadas com a implementação em `morph.py`, reproduzida a seguir:

```
@staticmethod
def clohole(f, b=np.ones((3,3),dtype='uint8')):
    # marcador restrito ao fundo da imagem
    marcador = mm.frame(f, border=1) & mm.neg(f)
    return mm.neg(mm.infrec(marcador, mm.neg(f), b))

@staticmethod
def edgeoff(f, b=np.ones((3,3),dtype='uint8')):
    # marcador restrito aos objetos da imagem
    marcador = mm.frame(f, border=1) & f
    return mm.subm(f, mm.infrec(marcador, f, b))
```

Essas implementações deixam explícito que ambos os operadores são instâncias diretas de reconstrução morfológica por dilatação geodésica com `mm.infrec`, diferindo apenas na escolha do marcador e da máscara: `clohole` atua no complemento da imagem, enquanto `edgeoff` atua diretamente no domínio dos objetos.

```
# Função auxiliar unificada para gerar o pipeline iterativo com realce visual
def gerar_pipeline_reconstrucao(marcador, mascara, kernel, passos=4, fator=80):
    iteracoes, titulos = [], []
    img_atual = marcador.copy()
    for i in range(1, passos + 1):
        img_visual = img_atual * fator
        img_atual = mm.cdil(img_atual, mascara, kernel)
        iteracoes.append(img_visual + img_atual)
        titulos.append(f"Iter. (n={i})")
    return iteracoes, titulos

# Imagem binária 10x10 com 3 cenários: objeto com buraco, objeto isolado e objeto na borda
f = np.array([
    [0,0,0,0,0,0,0,0,0,0],
```

```

[0,1,1,1,1,0,0,0,1],
[0,1,0,0,1,0,0,1,0,1],
[0,1,0,0,1,0,0,1,0,1],
[0,1,1,1,1,0,0,1,0,0],
[0,0,0,0,0,0,0,0,0,0],
[0,0,1,1,1,0,1,1,1,0],
[0,0,1,1,1,0,1,0,1,0],
[0,0,1,1,1,0,1,1,1,0],
[0,0,0,0,0,0,0,0,0,1]], dtype=np.uint8) * 255

B_cruz = mm.secross()
f_c = mm.neg(f)          # Utiliza o operador de negação nativo da mm

# PIPELINE CLOHOLE
# 0 marcador do clohole teórico é a borda externa
marcador_ch = mm.frame(f, border=1)
iters_ch, tits_ch = gerar_pipeline_reconstrucao(marcador_ch, f_c, B_cruz, passos=5)

# Resultado final calculado por extenso e validado com a função nativa mm.clohole
img_clohole = mm.neg(mm.infrec(marcador_ch, f_c, B_cruz))
print(f" Validação clohole: {np.array_equal(img_clohole, mm.clohole(f))}")

mm.show(
    [f, marcador_ch] + iters_ch + [img_clohole],
    titles=["f original", "Marcador (Borda)"] + tits_ch + ["clohole(f)"],
    cols=8, figsize=(18, 3), axis=True
)

```

Validação clohole: True




Figura 4.10: *Pipeline* de preenchimento de buracos (*clohole*): o marcador é obtido a partir da borda da imagem e restringido ao complemento  $f^c$ . As iterações de dilatação geodésica reconstruem o fundo externo; após a complementação final, os buracos internos ficam preenchidos.

```

# PIPELINE EDGEOFF
B_box = mm.sebox()
marcador_eo = marcador_ch & f
iters_eo, tits_eo = gerar_pipeline_reconstrucao(marcador_eo, f, B_box, passos=5)

# Resultado final por definição e validação nativa
img_edgoff = mm.edgoff(f, B_box)
print(f" Validação edgoff: {np.array_equal(img_edgoff, mm.edgoff(f))}")

mm.show(
    [f, marcador_eo] + iters_eo + [img_edgoff],
    titles=["f original", "Marcador (Borda)"] + tits_eo + ["edgoff(f)"],
    cols=8, figsize=(18, 3)
)

```

Validação edgoff: True





Figura 4.11: *Pipeline* de eliminação de estruturas de borda (*edgeoff*): o marcador captura as raízes conectadas às extremidades da matriz, a reconstrução delimita a extensão desses elementos e a subtração booleana preserva unicamente os objetos totalmente internos.

#### 4.3.6 Pipeline de Limpeza Binária com CLAHE

Com base na análise anterior — na qual o CLAHE produziu o maior valor da variância interclasses ( $\sigma_B^2 \approx 2,47 \times 10^3$ ), ver Figure 4.2, e o operador `mm.clohole` mostrou-se eficaz no preenchimento das cavidades internas —, o *pipeline* final de segmentação, ilustrado na Figure 4.12, é estruturado pelo seguinte fluxo computacional:



Após a etapa de `mm.clohole`, aplica-se uma segunda abertura morfológica com um elemento estruturante maior (`mm.sedisk(33)`, disco de diâmetro 33). Essa operação remove pequenas regiões residuais e artefatos que possam ter permanecido após a segmentação. Em particular, o preenchimento geodésico pode transformar pequenas cavidades isoladas em componentes conectados ao objeto, tornando conveniente uma etapa adicional de filtragem baseada em tamanho. O diâmetro foi escolhido de modo que as moedas permaneçam capazes de conter o elemento estruturante, enquanto componentes significativamente menores sejam eliminados.

Nesta imagem, nenhuma moeda está conectada à borda da matriz. Consequentemente, a aplicação de `mm.edgeoff` não altera o resultado obtido após a segunda abertura. Ainda assim, essa etapa é mantida no *pipeline* por robustez, pois em outras imagens podem existir objetos parcialmente visíveis ou conectados às bordas, que devem ser removidos antes da etapa de análise.

#### 💡 Por que a abertura após o clohole?

O operador `mm.clohole` preenche todas as cavidades fechadas presentes nos objetos segmentados. Em algumas situações, pequenas regiões indesejadas podem permanecer após essa etapa ou tornar-se conectadas aos objetos principais. A abertura morfológica subsequente remove componentes menores que o elemento estruturante, preservando as moedas devido ao seu tamanho significativamente maior.

```
# Pré-processamento: apenas CLAHE
img_clahe0 = cv2.createCLAHE(clipLimit=2.0, tileGridSize=(8, 8)).apply(img_coins_gray)

# Etapa 1: Binarização Otsu
img_bin = mm.threshold(img_clahe0)

# Etapa 2: Abertura - remove ruídos brancos de fundo
img_open = mm.open(img_bin, mm.sedisk(9))

# Etapa 3: clohole - fecha todos os buracos internos
img_hole = mm.clohole(img_open)

# Etapa 4: Abertura (kernel grande) - remove artefatos do clohole
img_limpo = mm.open(img_hole, mm.sedisk(33))

# Etapa 5: edgeoff - remove objetos que tocam a borda
img_final = mm.edgeoff(img_limpo, border=1)
```

```

mm.show(
    [img_clahe0, img_bin,          img_open,
     img_hole,  img_limpo,        img_final],
    titles=["CLAHE",              "Otsu",          "Abertura (r=9)",
           "clohole",            "Abertura (r=33)", "Final (edgeoff)",
    cols=6, figsize=(18, 6)
)

```




Figura 4.12: *Pipeline* completo de segmentação com CLAHE: Otsu  $\rightarrow$  abertura ( $r=9$ )  $\rightarrow$  clohole  $\rightarrow$  abertura ( $r=33$ )  $\rightarrow$  edgeoff.

#### 4.3.7 Morfologia em Tons de Cinza

Os operadores morfológicos estendem-se naturalmente para imagens em tons de cinza. Nessa formulação, a erosão e a dilatação passam a atuar diretamente sobre os níveis de intensidade da imagem. Para elementos estruturantes planos ( $b \equiv 0$ ), a erosão corresponde ao **mínimo local** e a dilatação ao **máximo local** dentro da vizinhança definida pelo elemento estruturante.

A interpretação intuitiva é simples: a erosão **escorece** regiões ao substituir cada pixel pelo menor valor presente em sua vizinhança, enquanto a dilatação **clareia** regiões ao utilizar o maior valor disponível. A combinação desses operadores permite construir transformações capazes de realçar bordas, remover tendências de iluminação e destacar estruturas locais.

Três operadores derivados são especialmente úteis:

**Gradiente morfológico** — destaca bordas como a diferença entre dilatação e erosão:

$$\text{grad}_B(f) = (f \oplus B) - (f \ominus B) \quad (4.12)$$

**Top-hat** — destaca estruturas brilhantes menores que o elemento estruturante (diferença entre a imagem original e sua abertura):

$$\text{top-hat}_B(f) = f - (f \circ B) \quad (4.13)$$

**Black-hat** — destaca estruturas escuras menores que o elemento estruturante (diferença entre o fechamento e a imagem original):

$$\text{black-hat}_B(f) = (f \bullet B) - f \quad (4.14)$$

O *Top-hat* extrai detalhes brilhantes que não sobrevivem à abertura, enquanto o *Black-hat* evidencia detalhes escuros removidos pelo fechamento. Já o gradiente morfológico realça transições abruptas de intensidade, produzindo uma representação semelhante à de um detector de bordas.

Para compreender o mecanismo desses operadores em nível local, a Figure 4.13 apresenta um simulador interativo de morfologia em tons de cinza. O simulador permite editar livremente o elemento estruturante,

visualizar seu deslocamento sobre a imagem e acompanhar simultaneamente o perfil unidimensional das intensidades. Dessa forma, torna-se possível observar diretamente como a erosão seleciona mínimos locais, como a dilatação seleciona máximos locais e como o gradiente morfológico emerge da diferença entre esses dois operadores.

O botão localizado no canto superior direito permite alternar entre a visualização original em tons de cinza e uma representação pseudocolorida (*colormap*) apenas nos três tipos gradientes. A versão colorida facilita a percepção visual das variações de intensidade, tornando mais evidente a ação dos operadores morfológicos sobre máximos, mínimos e transições locais da imagem.

Os operadores apresentados estão disponíveis em `morph.py` por meio das funções `mm.gradm`, `mm.tophat` e `mm.blackhat`.




Figura 4.13: Simulador interativo avançado de morfologia com elemento estruturante editável e perfil 1D.

A Figure 4.14 ilustra os efeitos desses operadores sobre a imagem das moedas e seus respectivos histogramas. Observe que a erosão desloca a distribuição para intensidades mais baixas, enquanto a dilatação a desloca para intensidades mais altas. O gradiente concentra valores nas regiões de contorno, e os operadores *Top-hat* e *Black-hat* produzem histogramas fortemente concentrados em baixos níveis de intensidade, pois apenas pequenas estruturas locais são realçadas.

```

import io
import matplotlib.pyplot as plt
import numpy as np

def fig2img(fig):
    b = io.BytesIO(); fig.savefig(b, format='png', dpi=100); plt.close(fig); b.seek(0)
    return (plt.imread(b)[: , : , :3] * 255).astype(np.uint8)

def plot_hist(img, title):
    fig, ax = plt.subplots(figsize=(4, 3))
    h = mm.hist(img)
    # CORREÇÃO: range usa len(h) dinamicamente para casar com o retorno da biblioteca
    ax.bar(range(len(h)), h, color='steelblue', width=1, edgecolor='steelblue')
    ax.set(xlim=(0, 255)); plt.tight_layout()
    return fig2img(fig)

# 1. Processamento morfológico base
B = mm.sedisk(19)
operadores = [
    ("Original", img_coins_gray),
    ("Erosão", mm.ero(img_coins_gray, B)),
    ("Dilatação", mm.dil(img_coins_gray, B)),
    ("Gradiente Morf.", mm.gradm(img_coins_gray, B)),
    ("Top-hat", mm.tophat(img_coins_gray, B)),
    ("Black-hat", mm.blackhat(img_coins_gray, B))
]

# 2. Montagem dinâmica do par: [Imagem, Histograma]
imgs, titles = [], []
for nome, img in operadores:
    imgs += [img, plot_hist(img, f"Hist. {nome}")]
    titles += [nome, f"Hist. {nome}"]

# 3. Exibição final em grade de duas colunas (Imagem | Histograma)
mm.show(imgs, titles=titles, cols=4, figsize=(10, 8))

```






Figura 4.14: Morfologia em tons de cinza e seus respectivos histogramas. A erosão reduz intensidades locais, a dilatação as amplia, o gradiente destaca bordas, e os operadores Top-hat e Black-hat evidenciam detalhes locais brilhantes e escuros. Elemento estruturante: disco de diâmetro 19.

Os operadores morfológicos apresentados anteriormente serão agora utilizados como ferramentas de refinamento e geração de marcadores para métodos de segmentação mais avançados, apresentados a seguir.

## 4.4 Segmentação de Imagens: Fundamentação e Taxonomia

A **segmentação de imagens** consiste em dividir a imagem em regiões associadas a objetos ou estruturas de interesse. Em PDI, ela representa a transição entre o processamento de baixo nível — como filtragem e realce — e etapas de análise mais avançadas, como extração de características, reconhecimento e interpretação da cena.

Formalmente, o objetivo da segmentação consiste em decompor o domínio espacial completo de uma imagem, denotado por  $\Omega$ , em uma partição de subconjuntos  $\{R_1, R_2, \dots, R_n\}$  que satisfaça simultaneamente os critérios de **completeza** e **disjunção**:

$$\bigcup_{i=1}^n R_i = \Omega, \quad R_i \cap R_j = \emptyset \quad \forall i \neq j \quad (4.15)$$

Além das propriedades de completeza e disjunção expressas na Equation 4.15, cada sub-região  $R_i$  deve constituir um domínio **homogêneo** segundo um predicado de similaridade definido sobre propriedades locais — intensidade, cor ou textura — e, simultaneamente, ser **distinta** das regiões adjacentes.

As técnicas de segmentação podem ser organizadas em diferentes famílias. Neste capítulo serão enfatizadas as abordagens resumidas na Table 4.5, fundamentadas principalmente em critérios de intensidade, conectividade e proximidade espacial.

Tabela 4.5: Taxonomia simplificada das principais abordagens de segmentação e refinamento estudadas neste capítulo.

| Abordagem                    | Critério de Segmentação                                          | Operadores de Referência                                                       |
|------------------------------|------------------------------------------------------------------|--------------------------------------------------------------------------------|
| <b>Limiarização</b>          | Particionamento do espaço de intensidades                        | Critério de Otsu, limiarização global e local                                  |
| <b>Morfologia Matemática</b> | Relações espaciais definidas por elementos/funções estruturantes | Erosão, dilatação, abertura, fechamento e reconstrução                         |
| <b>Baseada em Regiões</b>    | Homogeneidade local e conectividade espacial                     | Rotulação de componentes conexos, Transformada de Distância e <i>Watershed</i> |

Até este ponto, o desenvolvimento prático concentrou-se na **limiarização**, por meio da combinação entre equalização adaptativa CLAHE e o método global de Otsu. Essa etapa foi complementada por operadores de **reconstrução morfológica** baseados em dilatações geodésicas, implementados pelas funções `mm.infrec`, `mm.clohole` e `mm.edgeoff`, produzindo uma máscara binária limpa e adequada para análise.

Contudo, em cenários onde objetos distintos aparecem conectados na máscara binária — seja por contato físico, sobreposição parcial ou por pontes estreitas de pixels produzidas pela segmentação —, a limiarização deixa de ser suficiente para individualizar cada objeto. Nesses casos, múltiplos objetos passam a compor um único componente conexo, dificultando etapas posteriores de medição e interpretação.

Para superar essa limitação, as próximas seções introduzem três ferramentas complementares: a **Rotulação de Componentes Conexos**, a **Transformada de Distância** e o algoritmo de segmentação por **Watershed** baseado em marcadores. Em conjunto, essas técnicas permitem separar objetos adjacentes, identificar regiões individualmente e extrair descritores geométricos consistentes para análise quantitativa.

#### 4.4.1 Rotulação

A **rotulação de componentes conexas** (*connected component labeling*) é o operador que atribui um identificador inteiro único a cada conjunto de pixels pertencentes à mesma componente conexa em uma imagem binária.

##### **i** Definição formal

Dada uma imagem binária  $f$  e uma relação de conectividade definida por um elemento estruturante  $B$  (tipicamente conectividade-4 ou conectividade-8), o algoritmo de rotulação da Figure 4.15 produz uma imagem  $g$  na qual todos os pixels pertencentes à mesma componente conexa recebem o mesmo rótulo inteiro positivo, enquanto pixels pertencentes a componentes distintas recebem rótulos diferentes.

A conectividade define quais pixels são considerados vizinhos diretos de um pixel  $(x, y)$ . As definições mais utilizadas são:

- **Conectividade-4:** considera apenas os quatro vizinhos ortogonais (norte, sul, leste e oeste).
- **Conectividade-8:** considera os quatro vizinhos ortogonais e os quatro diagonais, totalizando oito vizinhos.

A escolha da conectividade influencia diretamente a formação das componentes conexas e, consequentemente, o resultado da rotulação, como ilustrado na Figure 4.17. Um exemplo adicional pode ser explorado interativamente no simulador apresentado na Figure 4.16.

A implementação em `morph.py` disponibiliza duas versões desse operador. A função `mm.label0` reproduz explicitamente o algoritmo de *flood-fill* utilizando uma pilha e permite controlar a conectividade por meio do elemento estruturante adotado. Já `mm.label` delega a operação à implementação otimizada do OpenCV (`cv2.connectedComponents`). Em ambos os casos, o resultado é uma imagem rotulada na qual cada componente conexa recebe um identificador inteiro distinto.




Figura 4.15: Algoritmo de rotulação por *flood-fill* com pilha: passo a passo, cards, linha do tempo, código Python e fluxograma.

O auxiliar `_viz` itera sobre a janela estruturante `b` centrada em  $(i, j)$ , gerando somente os vizinhos válidos dentro dos limites da imagem — a conectividade desejada é inteiramente determinada pela forma de `b` passada ao algoritmo.

**Exemplo didático — efeito da conectividade:**




Figura 4.16: Simulador interativo de rotulação de componentes conexas (*connected component labeling*): visualização da expansão flood-fill, conectividade-4 e conectividade-8.

```
# Imagem binária 10x10 com componentes diagonalmente adjacentes
f = np.array([
    [0,0,0,0,0,0,0,0,0,0],
    [0,1,0,0,0,0,0,0,0,0],
    [0,0,1,0,0,0,0,0,0,0], # diagonal com linha anterior
    [0,0,0,1,0,0,1,1,0,0],
    [0,0,0,0,0,0,1,1,0,0],
    [0,0,0,0,0,0,0,0,0,0],
    [0,1,1,1,0,0,0,0,0,0],
    [0,1,0,1,0,0,0,1,0,0],
    [0,1,1,1,0,0,0,0,1,0], # diagonal com linha anterior
    [0,0,0,0,0,0,0,0,0,0]], dtype=np.uint8) * 255

# Elemento estruturante cruz (conectividade-4) e quadrado (conectividade-8)
B4 = mm.secross() # conectividade-4
B8 = mm.sebox() # conectividade-8

# Rotulação com label0 (didático) e label (cv2)
lbl4_didatico = mm.label0(f, B4)
lbl8_didatico = mm.label0(f, B8)

_, lbl4_cv2 = cv2.connectedComponents(f, connectivity=4)
_, lbl8_cv2 = cv2.connectedComponents(f, connectivity=8)

# Validação cruzada
print(f" label0 (C4) == cv2 (C4): {np.array_equal(lbl4_didatico, lbl4_cv2)}")
print(f" label0 (C8) == cv2 (C8): {np.array_equal(lbl8_didatico, lbl8_cv2)}")
print(f" Componentes C4: {lbl4_cv2.max()} | Componentes C8: {lbl8_cv2.max()}")
```

```
# Normalização para visualização
def norm_label(lbl):
    out = np.zeros_like(lbl, dtype=np.uint8)
    for i, v in enumerate(np.unique(lbl)[1:], 1):
        out[lbl == v] = int(i * 255 / lbl.max())
    return out

mm.show(
    [f, norm_label(lbl4_cv2), norm_label(lbl8_cv2)],
    titles=[
        "f original",
        f"Rotulação C4\n({lbl4_cv2.max()} componentes)",
        f"Rotulação C8\n({lbl8_cv2.max()} componentes)"
    ],
    cols=3, figsize=(12, 4), axis=True
)
```

```
label0 (C4) == cv2 (C4): True
label0 (C8) == cv2 (C8): True
Componentes C4: 7 | Componentes C8: 4
```




Figura 4.17: Efeito da conectividade na rotulação: a imagem binária  $10 \times 10$  contém pixels diagonalmente adjacentes. Com conectividade-4, esses pixels formam componentes distintas; com conectividade-8, fundem-se em uma única componente.

#### 4.4.2 Transformada de Distância

A **Transformada de Distância** (TD) é um operador que, aplicado a uma imagem binária  $f$ , produz uma imagem em níveis de cinza  $D$  na qual cada pixel pertencente ao objeto ( $f(x, y) \neq 0$ ) recebe como valor a distância geométrica até o pixel de fundo ( $f(x', y') = 0$ ) mais próximo:

$$D(x, y) = \min_{(x', y') : f(x', y') = 0} d((x, y), (x', y'))$$

onde  $d(\cdot, \cdot)$  é uma métrica de distância — tipicamente a distância Euclidiana ( $L_2$ ). O resultado é uma representação topográfica dos objetos: pixels localizados no interior assumem valores elevados, enquanto pixels próximos às bordas apresentam baixos valores de distância. Os **máximos locais** de  $D$  correspondem aos pontos mais afastados da borda do objeto, frequentemente próximos aos seus centros geométricos ou centros de máxima inscrição — propriedade particularmente útil para a geração automática de marcadores no algoritmo *watershed*.

### **i** Definição formal usando erosões

A TD admite ainda uma interpretação morfológica iterativa, conforme algoritmo da Figure 4.18. Considere uma função estruturante  $b$  cujo valor central é nulo e cujos vizinhos possuem custos negativos associados ao deslocamento. Ao aplicar erosões sucessivas com essa função estruturante particular, os valores dos pixels dos objetos (que devem assumir a distância máxima possível da imagem) são progressivamente reduzidos segundo os custos definidos por  $b$ . O valor acumulado dessa propagação passa então a representar a distância ao fundo segundo a métrica induzida pela função estruturante.

Essa interpretação é implementada em `mm.dist1()`, que acumula erosões sucessivas utilizando a operação `mm.ero1()`. Já `mm.dist()` delega o cálculo da distância Euclidiana ao operador otimizado do OpenCV `cv2.distanceTransform(f, cv2.DIST_L2, 5)`, onde  $f$  é a imagem binária de entrada, `cv2.DIST_L2` especifica a métrica Euclidiana ( $L_2$ ) e 5 indica o uso de uma máscara  $5 \times 5$  para aproximar a distância com elevada precisão.

A função `dist1` produz uma transformada de distância discreta cuja métrica é determinada pela geometria e pelos pesos da função estruturante utilizada. Por exemplo, utilizando uma função estruturante em cruz com custo unitário para os quatro vizinhos ortogonais, obtém-se a distância de *Manhattan* ( $L_1$ ). Outras escolhas de vizinhança e pesos induzem métricas diferentes. Já `mm.dist()` calcula uma aproximação eficiente da distância Euclidiana ( $L_2$ ).

Por exigir sucessivas erosões sobre toda a imagem, a abordagem `dist1` possui custo computacional significativamente maior que `mm.dist()`, sendo empregada neste livro principalmente para fins didáticos e para evidenciar a relação entre morfologia matemática e transformadas de distância.

A Figure 4.19 apresenta um simulador interativo da TD: é possível posicionar o cursor sobre diferentes pixels do objeto e observar, em tempo real, o valor da distância associado àquela posição, isto é, a distância até o pixel de fundo mais próximo. A Figure 4.20 apresenta um exemplo prático dessa execução em ambiente Python.

```
import numpy as np

# Imagem binária 10×10 com um único pixel de fundo (0,0) e o resto como objeto (255)
f = np.ones((10,10), dtype=np.uint8) * 255
f[0,0] = 0

B_cruz = np.array([
    [-np.inf, -1, -np.inf],
    [-1,      0, -1],
    [-np.inf, -1, -np.inf]
], dtype=float)


d_iter = mm.dist1(f, B_cruz)
d_l2 = mm.dist(f)

print(f"Máx. dist1 (erosões) : {d_iter.max()} px")
print(f"Máx. dist (L2)       : {d_l2.max():.2f} px")
print(f"Posição do máximo dist1 : {np.where(d_iter == d_iter.max())}")
print(f"Posição do máximo dist  : {np.where(d_l2 == d_l2.max())}")

mm.show(
    [f, d_iter, d_l2],
    titles=["f original", "mm.dist1\n(erosões com cruz)", "mm.dist\n(L2 Euclidiana)"],
    cols=3, figsize=(12, 4), axis=True
)
```

```
Máx. dist1 (erosões) : 18 px
Máx. dist (L2)       : 12.00 px
```





*Ponto Fixo Numérico: A distância emerge da propagação matemática do valor zero.*

Figura 4.18: Algoritmo da Transformada de Distância: passo a passo, cards, linha do tempo, código Python e fluxograma.




Figura 4.19: Simulador interativo da Transformada de Distância (TD) iterativa via erosão em tons de cinza. Pixels fora da imagem agora assumem o valor máximo (144), propagando os custos apenas a partir do fundo interno.

```

Posição do máximo dist1 : (array([9]), array([9]))
Posição do máximo dist  : (array([9]), array([9]))

```




Figura 4.20: Transformada de Distância em imagem binária 10×10. Esquerda: imagem original (*foreground* = 255). Centro: mm.dist1 iterativa (erosões com elemento cruz). Direita: mm.dist (L2 Euclidiana).

A anotação dos valores numéricos diretamente sobre os pixels permite verificar como `dist1` propaga as distâncias segundo a métrica induzida pela função estruturante utilizada. No caso do elemento cruz com custo unitário, os valores obtidos correspondem à distância de *Manhattan* ( $L_1$ ). Embora `dist1` e `mm.dist` produzam valores numéricos distintos por adotarem métricas diferentes, ambas as transformadas preservam a estrutura topográfica dos objetos, fazendo com que seus máximos ocorram em regiões centrais semelhantes. Essa propriedade justifica o uso de `mm.dist` em aplicações práticas, devido à sua elevada eficiência computacional.

#### 4.4.3 Transformada de Distância Euclidiana em quatro passos

O simulador da Figure 4.21 implementa o algoritmo da TDE de Lotufo; Zampirolli (2001) em duas etapas. Na primeira etapa, a função `edt1` realiza uma transformação unidimensional vertical de forma sequencial (*in-place*), percorrendo cada coluna em *raster* ( $\downarrow$ ) e *anti-raster* ( $\uparrow$ ) para calcular as distâncias na direção vertical (dois passos: Sul e Norte). Na segunda etapa, a função `edt2` utiliza esse resultado como entrada e realiza uma propagação horizontal por filas: para cada linha da matriz, duas filas de prioridade, `Eq` e `Wq`, são inicializadas percorrendo os índices de coluna em sentidos opostos (`Eq` de `W-1` até 1, `Wq` de 2 até `W`), de modo que cada pixel atualizado enfileira imediatamente seus vizinhos para reprocessamento dentro da mesma rodada (mais dois passos: Leste e Oeste). Esse mecanismo de fila permite aplicar erosões sucessivas com pesos ímpares crescentes ( $b = 1, 3, 5, \dots$ , incrementado a cada iteração do laço externo) sem que a propagação fique presa em valores desatualizados, já que cada rodada resolve a cadeia de dependências horizontal por completo antes do próximo incremento de  $b$ . A convergência dessa propagação produz a Transformada de Distância Euclidiana em toda a matriz, combinando a informação vertical obtida em `edt1` com a propagação horizontal em fila realizada em `edt2`.

##### 4.4.3.1 Transformada de Distância Geodésica

A transformada de distância geodésica associa a cada pixel a menor distância até um marcador, sob a restrição imposta por uma máscara. Dessa forma, a propagação ocorre exclusivamente pelos pixels permitidos, preservando a conectividade do domínio.

A Figure 4.22 ilustra esse processo em um labirinto: (a) a máscara `g`; (b) a distância geodésica `D1` calculada a partir da entrada; (c) a distância `D2` calculada a partir da saída; e (d) o caminho mínimo obtido a partir dessas duas transformadas.

O caminho ótimo é determinado pela soma das distâncias ( $D1 + D2$ ). Os pixels pertencentes à trajetória mínima são aqueles para os quais essa soma assume seu menor valor, definindo uma conexão entre entrada e

EDT<sup>2</sup> 2D Corrigido · Matriz 4x4

Passo 1: edt1 Vertical In-place · Passo 2: edt2 Horizontal In-place (mesma estrutura raster/anti-raster do edt1)



Figura 4.21: Simulador interativo 2D (4x4) com sincronizao estrita de filas de propagaco horizontal (b) para obter a convergncia exata descrita no artigo.

sada com comprimento geodsico mnimo.

Esse princpio permite resolver labirintos sem a necessidade de explorar explicitamente todas as possibilidades de percurso. A soluo emerge diretamente da propagaco de distncias em um domnio restrito. Essa abordagem  particularmente relevante em labirintos de elevada complexidade, como os construdos a partir de estruturas quasicristalinas e ciclos hamiltonianos descritos por Singh; Lloyd; Flicker (2024). Em Zampirolli et al. (2025), esse mesmo formalismo  empregado para resolver um labirinto complexo; a seguir, o mtodo  ilustrado em uma verso simplificada do problema.

```
import numpy as np

# 1 = corredor, 0 = parede
g = np.array([
    [0,1,0,0,0,0,0,0,0],
    [0,1,1,1,1,1,0,1,1],
    [0,1,1,1,1,1,0,1,1],
    [0,0,0,0,0,1,0,1,0],
    [0,1,1,1,0,1,1,1,0],
    [0,1,0,1,0,0,0,0,1],
    [0,1,0,1,1,1,1,1,1],
    [0,1,0,0,0,0,0,0,1],
    [0,1,1,1,1,1,1,0,1],
    [0,0,0,0,0,1,1,1,0],
    [0,0,0,0,0,0,0,1,0]
], dtype=np.uint8)

# marcador da entrada
entrada = np.zeros_like(g, dtype=np.uint8)
entrada[0,1] = 1

# marcador da sada
saida = np.zeros_like(g, dtype=np.uint8)
saida[9,8] = 1
```

```

# distâncias geodésicas
D1 = mm.gdist(g, entrada)
D2 = mm.gdist(g, saída)

# soma das distâncias
S = D1 + D2

# menor valor válido da soma
dmin = np.min(S[S > 0])

# pixels pertencentes a um caminho ótimo
caminho = (S == dmin)

print("Distância geodésica mínima:", dmin)

mm.show(
    [g, D1, D2, caminho],
    titles=[
        "Labirinto",
        "Distância da Entrada",
        "Distância da Saída",
        f"Menor Caminho\n(d={dmin})"
    ],
    cols=4,
    figsize=(14,4),
    axis=True
)

```

Distância geodésica mínima: 15




Figura 4.22: Menor caminho geodésico em um labirinto. As distâncias geodésicas são calculadas a partir da entrada e da saída usando `mm.gdist`. Os pixels cujo somatório das duas distâncias é igual à distância mínima entre os marcadores pertencem a um caminho ótimo.

#### 4.4.4 Segmentação por *Watershed*

O algoritmo ***Watershed*** interpreta uma imagem em níveis de cinza como uma superfície topográfica, na qual valores elevados correspondem a montanhas e valores baixos correspondem a vales ou bacias de drenagem (*catchment basins*). No contexto da segmentação baseada em marcadores, os máximos da Transformada de Distância são frequentemente utilizados para identificar regiões internas aos objetos, fornecendo sementes confiáveis para o processo de inundação.

A segmentação é então realizada por uma simulação conceitual de inundação progressiva a partir desses marcadores. À medida que as bacias associadas a diferentes sementes se expandem, regiões vizinhas eventualmente entram em contato. Nesse instante são construídas barreiras virtuais, denominadas *watershed*

*lines*, que passam a delimitar os objetos da cena. Esse mecanismo permite separar objetos adjacentes ou parcialmente sobrepostos, mesmo quando eles formam uma única componente conexa após a limiarização.

A implementação didática apresentada neste capítulo explora inicialmente o conceito de crescimento de regiões (*region growing*) confinado por uma máscara binária, conforme detalhado no algoritmo iterativo da Figure 4.23.

#### **i** Versão didática versus implementação clássica

A função `mm.watershed0` não implementa o algoritmo *watershed* clássico. Seu objetivo é ilustrar, de forma simplificada, a propagação de marcadores por crescimento de regiões (*region growing*), permitindo visualizar como diferentes sementes competem pela ocupação do espaço disponível. O crescimento é delimitado por uma máscara binária de suporte e monitorado por um controle de estagnação, gerando um resultado semelhante a uma partição de Voronoi restrita à geometria dos objetos de entrada. Já a função `mm.watershed` utiliza a implementação otimizada do OpenCV (`cv2.watershed`), que realiza a inundação sobre uma superfície topográfica definida pela imagem de entrada. Nesse caso, a propagação dos marcadores é influenciada pelos valores dos pixels, fazendo com que as linhas de separação se formem naturalmente sobre as cristas do relevo.

A Figure 4.24 apresenta um simulador iterativo que ilustra a propagação dos marcadores pela região de interesse. Cada marcador atua como uma fonte de inundação que expande sua área de influência até encontrar regiões provenientes de outras sementes. No algoritmo do OpenCV, os pixels pertencentes às linhas divisoras são identificados pelo valor `-1`, representando as fronteiras entre bacias adjacentes.

### **Pipeline Morfológico do Watershed**

O *watershed* baseado em marcadores normalmente integra um fluxo mais amplo de segmentação. Em imagens reais, etapas de pré-processamento são frequentemente necessárias para melhorar o contraste, reduzir ruídos e gerar marcadores confiáveis. Esse fluxo completo está resumido na Table 4.6.

Tabela 4.6: *Pipeline* completo do *watershed* baseado em marcadores para imagens reais.

| Etapa | Operação                           | Finalidade                                               |
|-------|------------------------------------|----------------------------------------------------------|
| 1     | CLAHE + Suavização                 | Realce de contraste e redução de ruído                   |
| 2     | Limiarização                       | Separação inicial entre objeto e fundo                   |
| 3     | Abertura/Fechamento                | Remoção de ruídos e pequenas imperfeições                |
| 4     | Dilatação da Máscara               | Identificação do Fundo Certo ( <i>Sure Background</i> )  |
| 5     | Transformada de Distância + Limiar | Identificação do Objeto Certo ( <i>Sure Foreground</i> ) |
| 6     | Região Incerta                     | Diferença entre Fundo Certo e Objeto Certo               |
| 7     | <code>cv2.watershed</code>         | Propagação dos marcadores pela região incerta            |

Para enfatizar exclusivamente os conceitos de Transformada de Distância, marcadores e inundação topográfica, o exemplo da Figure 4.25 utiliza uma imagem binária sintética e adota um fluxo simplificado, resumido na Table 4.7.






Figura 4.23: Algoritmo Didático de *Watershed* por Crescimento de Regiões Limitado por Máscara: passo a passo, cards, linha do tempo, código Python e fluxograma.

**Simulador: Segmentação por Watershed**

**Propagação com Elemento Estruturante (b)**

ÁREA (MÁSCARA)  
**83**

MARCADORES  
**2**

PREENCHIMENTO  
**100%**

ITERAÇÃO (K)  
**Finalizado**

arraste para desenhar/apagar a máscara ou as sementes

**Ferramentas**

☐ Máscara
☐ Apagar

☒ Sem. 1
☒ Sem. 2

☐ Sem. 3

**Elem. Estruturante (b)**

|   |   |   |
|---|---|---|
| 0 | 1 | 0 |
| 1 | 1 | 1 |
| 0 | 1 | 0 |

Cruz (C-4)
Quadr. (C-8)

**Visualização**

Final
Animado

**Exemplos Iniciais**

Limpar Tudo

Figura 4.24: Simulador interativo do Algoritmo *Watershed* por propagação morfológica. Desenhe a máscara, posicione os marcadores e ajuste o Elemento Estruturante para observar a inundação. Quando as bacias se encontram simultaneamente, o empate é resolvido assumindo uma das regiões de forma aleatória.

Tabela 4.7: *Pipeline* simplificado utilizado no exemplo didático da Figure 4.25.

| Etapa | Operação                   | Finalidade                                             |
|-------|----------------------------|--------------------------------------------------------|
| 1     | Transformada de Distância  | Construção da superfície topográfica                   |
| 2     | Limiar da TD               | Extração dos marcadores ( <i>Sure Foreground</i> )     |
| 3     | Dilatação                  | Determinação do Fundo Certo ( <i>Sure Background</i> ) |
| 4     | Região Incerta             | Diferença entre fundo e marcadores                     |
| 5     | <code>cv2.watershed</code> | Propagação dos marcadores e geração das fronteiras     |

```
import cv2

# 1. Imagem sintética e Transformada de Distância
f_sint = np.zeros((20, 20), dtype=np.uint8)
cv2.circle(f_sint, (6, 10), 5, 255, -1)
cv2.circle(f_sint, (14, 10), 5, 255, -1)
dist = mm.dist(f_sint)


# 2. Marcadores (picos da distância)
m = (dist > 0.8 * dist.max()).astype(np.uint8) * 255

# 3. Execução do Watershed0 condicional (m=marcadores primeiro, mask=f_sint)
w_reg = mm.watershed0(m, mask=f_sint, op='region')
w_line = mm.watershed0(m, mask=f_sint, op='line')

#w_reg = mm.watershedB(m, mask=f_sint, op='region')
#w_line = mm.watershedB(m, mask=f_sint, op='line')

w_reg = mm.watershed(m, mask=f_sint, op='region')
w_line = mm.watershed(m, mask=f_sint, op='line')

# 4. Exibição dos resultados
mm.show([f_sint, dist, m, w_reg, w_line], cols=5, figsize=(16, 4),
        titles=["Original", "Distância", "Marcadores", "Regiões", "Linhas"])
```

Figura 4.25: *Pipeline watershed* delimitado por máscara em imagem binária 20×20.

### Aplicação em moedas sobrepostas:

```
img_base = img_coins_gray

# 1. Simular moedas sobrepostas/conectadas (usando a máscara binária base)
```

```

img_sobrepostas = mm.dil(img_final, mm.sebox(40))

# 2. Abertura morfológica para limpar ruídos
opening = mm.open(img_sobrepostas, mm.sebox(2))

# 3. Transformada de Distância
dist = mm.dist(opening)
dist_vis=(255*(dist/dist.max())).astype(np.uint8) if dist.max() > 0 else dist.astype(np.uint8)

# 4. Picos seguros (Marcadores das moedas)
picos = (dist > 0.5 * dist.max()).astype(np.uint8) * 255

# 5. Execução do Watershed (Ajustado para usar a nova assinatura)
# Passamos 'opening' direto em mask, pois ela delimita o escopo de expansão das moedas
ws_region = mm.watershed(picos, mask=opening, op='region')
ws_line = mm.watershed(picos, mask=opening, op='line')

# 6. Contagem de objetos (Ignora fundo 0)
labels = np.unique(ws_region)
labels = labels[labels > 0]
print(f"Objetos detectados: {len(labels)}")

# 7. Anotação Final
img_annotated = cv2.cvtColor(img_base, cv2.COLOR_GRAY2BGR)

for idx, label_id in enumerate(labels):
    mask_reg = (ws_region == label_id).astype(np.uint8)
    if mask_reg.sum() < 500: continue

    cy, cx = np.mean(np.where(mask_reg), axis=1).astype(int)
    cv2.putText(img_annotated, str(idx + 1), (cx - 25, cy + 20),
                cv2.FONT_HERSHEY_SIMPLEX, 3.2, (0, 255, 0), 8, cv2.LINE_AA)

# Desenha as linhas de separação em vermelho
mask_ann = mm.dil(ws_line, np.ones((11, 11), np.uint8))
img_annotated[mask_ann > 0] = [255, 0, 0]

# Exibição
mm.show(
    [img_base, img_sobrepostas, dist_vis, picos, ws_region, img_annotated],
    titles=["Original", "Sobrepostas", "Distância", "Marcadores", "Watershed", "Anotado"],
    cols=3, rows=2, figsize=(12, 8)
)

```

Objetos detectados: 12




Figura 4.26: *Pipeline Watershed* para separação de moedas sobrepostas: da máscara binária dilatada até os contornos finais anotados sobre a imagem original.

### 4.5 Extração de Componentes e Descritores de Forma

Após a segmentação e o refinamento morfológico, o próximo passo consiste em identificar individualmente cada objeto presente na imagem e extrair suas propriedades geométricas. Essa etapa é fundamental para tarefas de medição, classificação e reconhecimento de padrões.

Um **componente conexo** é um conjunto maximal de pixels pertencentes ao objeto que permanecem mutuamente conectados segundo uma relação de conectividade previamente definida (4- ou 8-conectividade). Após a rotulação, cada componente recebe um identificador único, permitindo que suas características sejam analisadas individualmente.

O OpenCV oferece duas abordagens complementares para essa análise, resumidas na Table 4.8.

Tabela 4.8: Comparação entre as abordagens baseadas em componentes conexos e em contornos.

|                            | <code>connectedComponentsWithStats</code>      | <code>findContours</code>                  |
|----------------------------|------------------------------------------------|--------------------------------------------|
| <b>Retorna</b>             | rótulo por pixel e estatísticas por componente | sequência de pontos que descreve a borda   |
| <b>Descritores diretos</b> | área, <i>bounding box</i> e centróide          | perímetro, forma e hierarquia              |
| <b>Objetos em contato</b>  | tende a fundir regiões conectadas              | tende a produzir um único contorno externo |

|                   | <code>connectedComponentsWithStats</code> | <code>findContours</code>                 |
|-------------------|-------------------------------------------|-------------------------------------------|
| <b>Uso típico</b> | contagem, filtragem e rotulação           | análise geométrica e descritores de forma |

### 4.5.1 Rotulação e Estatísticas de Componentes

A função `cv2.connectedComponentsWithStats` realiza simultaneamente a rotulação dos componentes conexos e a extração de descritores básicos de cada região. O operador retorna:

- uma imagem de rótulos (`labels`);
- estatísticas geométricas (`stats`);
- coordenadas dos centróides (`centroids`).

As estatísticas incluem área, largura, altura e posição da *bounding box* mínima alinhada aos eixos da imagem.

A Figure 4.27 ilustra a aplicação desse operador após o *pipeline* de segmentação das moedas. Cada componente conexo recebe uma cor distinta e sua área é anotada diretamente sobre a imagem.

```
# 1. Rotulagem e estatísticas
n, labels, stats, centroids = cv2.connectedComponentsWithStats(
    img_final, connectivity=8
)

# 2. Coloração dos componentes
np.random.seed(4)
colors = np.random.randint(50, 255, (n, 3), dtype=np.uint8)
colors[0] = [0, 0, 0] # fundo preto
img_colored = colors[labels]
img_annotated = img_colored.copy()

# 3. Tabela de descritores
print(f"Componentes detectados (excluindo fundo): {n - 1}")
print(f"\n{'ID':>4} {'Área':>8} {'cx':>6} {'cy':>6} {'w':>6} {'h':>6}")
print("-" * 42)
for i in range(1, n):
    area = stats[i, cv2.CC_STAT_AREA]
    cx, cy = int(centroids[i, 0]), int(centroids[i, 1])
    w, h = stats[i, cv2.CC_STAT_WIDTH], stats[i, cv2.CC_STAT_HEIGHT]
    print(f"{i:>4} {area:>8} {cx:>6} {cy:>6} {w:>6} {h:>6}")
    for cor, esp in [(0,0,0), 10), ((255,0,0), 5)]:
        cv2.putText(img_annotated, f"{i}: {area}",
                    (cx - 150, cy + 18),
                    cv2.FONT_HERSHEY_SIMPLEX, 2.0, cor, esp, cv2.LINE_AA)

mm.show(
    [img_coins_gray, img_final, img_colored, img_annotated],
    titles=["Original", "Segmentação Final", "Componentes Conexos", "Áreas Anotadas"],
    cols=4, figsize=(18, 6)
)
```

Componentes detectados (excluindo fundo): 12

| ID    | Área   | cx   | cy  | w   | h   |
|-------|--------|------|-----|-----|-----|
| ----- |        |      |     |     |     |
| 1     | 231969 | 1484 | 280 | 553 | 542 |
| 2     | 158967 | 917  | 250 | 453 | 468 |
| 3     | 139229 | 250  | 312 | 433 | 419 |
| 4     | 175550 | 857  | 821 | 474 | 465 |
| 5     | 222882 | 1442 | 889 | 539 | 531 |



|    |        |      |      |     |     |
|----|--------|------|------|-----|-----|
| 6  | 210043 | 316  | 977  | 527 | 516 |
| 7  | 343376 | 934  | 1559 | 667 | 665 |
| 8  | 213641 | 1555 | 1574 | 530 | 515 |
| 9  | 147880 | 328  | 1543 | 432 | 438 |
| 10 | 187280 | 363  | 2111 | 487 | 492 |
| 11 | 150110 | 1487 | 2215 | 433 | 444 |
| 12 | 215387 | 932  | 2292 | 528 | 522 |




Figura 4.27: Componentes conexos extraídos após o *pipeline* CLAHE → Otsu → limpeza morfológica. Cada objeto é colorido com cor distinta e anotado com sua área em pixels.

#### 4.5.2 Descritores de Forma

Enquanto `connectedComponentsWithStats` opera sobre regiões, `cv2.findContours` atua diretamente sobre suas fronteiras. O operador retorna, para cada objeto, uma sequência ordenada de pontos que descreve seu contorno.

A partir dessa representação é possível calcular descritores geométricos que não são fornecidos diretamente pela rotulação de componentes:

- **Área** (`cv2.contourArea`);
- **Perímetro** (`cv2.arcLength`);
- **Circularidade** ( $C = \frac{4\pi A}{P^2}$ , onde  $A$  é a área e  $P$  o perímetro);
- **Aproximação poligonal** (`cv2.approxPolyDP`);
- **Fecho convexo** (*convex hull*);
- **Hierarquia de contornos**, permitindo representar relações pai-filho entre regiões e seus buracos internos.

A circularidade assume valor máximo igual a 1 para um círculo perfeito e diminui à medida que o objeto se torna mais alongado ou apresenta irregularidades em sua borda.

A Figure 4.28 apresenta os contornos extraídos das moedas segmentadas, juntamente com os valores de circularidade calculados para cada objeto.

```
contornos, hierarquia = cv2.findContours(
    img_final, cv2.RETR_EXTERNAL, cv2.CHAIN_APPROX_SIMPLE
)

img_contornos = cv2.cvtColor(img_coins_gray, cv2.COLOR_GRAY2BGR)
img_circulares = img_contornos.copy()
```

```

print(f"Contornos detectados: {len(contornos)}")
print(f"\n{'ID':>4} {'Área':>8} {'Perímetro':>10} {'Circularidade':>14}")
print("-" * 42)

for i, cnt in enumerate(contornos, start=1):
    area = cv2.contourArea(cnt)
    perim = cv2.arcLength(cnt, closed=True)
    circ = (4 * np.pi * area / perim**2) if perim > 0 else 0
    M = cv2.moments(cnt)
    cx = int(M["m10"] / M["m00"]) if M["m00"] > 0 else 0
    cy = int(M["m01"] / M["m00"]) if M["m00"] > 0 else 0

    print(f"{'i':>4} {'area':>8.0f} {'perim':>10.1f} {'circ':>14.3f}")

    cv2.drawContours(img_contornos, [cnt], -1, (0, 255, 0), 3)
    cv2.drawContours(img_circulares, [cnt], -1, (0, 255, 0), 3)
    for cor, esp in [((0,0,0), 8), ((255,0,0), 3)]:
        cv2.putText(img_circulares, f"{circ:.2f}",
                    (cx - 80, cy + 15),
                    cv2.FONT_HERSHEY_SIMPLEX, 3.6, cor, esp, cv2.LINE_AA)

mm.show(
    [img_final, img_contornos, img_circulares],
    titles=["Segmentação Final", "Contornos", "Circularidade"],
    cols=3, figsize=(18, 6)
)

```

Contornos detectados: 12

| ID    | Área   | Perímetro | Circularidade |
|-------|--------|-----------|---------------|
| ----- |        |           |               |
| 1     | 214626 | 1769.6    | 0.861         |
| 2     | 149480 | 1465.1    | 0.875         |
| 3     | 186570 | 1654.9    | 0.856         |
| 4     | 147252 | 1458.6    | 0.870         |
| 5     | 212886 | 1756.3    | 0.867         |
| 6     | 342424 | 2232.5    | 0.863         |
| 7     | 209282 | 1767.7    | 0.842         |
| 8     | 222108 | 1809.7    | 0.852         |
| 9     | 174854 | 1616.4    | 0.841         |
| 10    | 138602 | 1471.5    | 0.804         |
| 11    | 158306 | 1538.7    | 0.840         |
| 12    | 231181 | 1847.4    | 0.851         |



Figura 4.28: Contornos extraídos com *findContours*. Cada moeda é anotada com sua circularidade — valores próximos de 1 confirmam forma circular.

### 4.5.3 Conexão com Detecção de Objetos Moderna

Os descritores extraídos nas seções anteriores — especialmente *bounding boxes*, centróides, áreas e medidas de forma — estabelecem uma ponte natural entre a segmentação morfológica clássica e os sistemas modernos de detecção de objetos. Embora as técnicas estudadas neste capítulo utilizem operações sobre pixels e regiões segmentadas, muitas das representações produzidas são diretamente compatíveis com os formatos empregados em modelos contemporâneos de visão computacional.

Detectores baseados em aprendizado profundo, como a família YOLO (*You Only Look Once*) (Redmon et al., 2016), operam diretamente sobre imagens coloridas e produzem, para cada objeto detectado, uma *bounding box* descrita pelo centro ( $cx, cy$ ) e pelas dimensões ( $w, h$ ), além de uma classe e uma pontuação de confiança. Essa representação compartilha a mesma estrutura geométrica básica obtida por `connectedComponentsWithStats`, embora seja produzida por um modelo aprendido e não por segmentação explícita.

A Figure 4.29 ilustra como as *bounding boxes* obtidas por morfologia podem ser exportadas no formato YOLO para compor conjuntos de dados utilizados no treinamento ou na avaliação de detectores.

```
H_img, W_img = img_coins_gray.shape
img_bbox = cv2.cvtColor(img_coins_gray, cv2.COLOR_GRAY2BGR)

CLASSE = 0 # 0 = moeda (única categoria neste exemplo)

print(f"{'cls':>4} {'cx_n':>8} {'cy_n':>8} {'w_n':>8} {'h_n':>8} ← formato YOLO")
print("-" * 54)

yolo_linhas = []
for i in range(1, n):
    x0 = stats[i, cv2.CC_STAT_LEFT]
    y0 = stats[i, cv2.CC_STAT_TOP]
    w = stats[i, cv2.CC_STAT_WIDTH]
    h = stats[i, cv2.CC_STAT_HEIGHT]

    cx_n = (x0 + w / 2) / W_img
    cy_n = (y0 + h / 2) / H_img
    w_n = w / W_img
    h_n = h / H_img

    yolo_linhas.append(f"{CLASSE} {cx_n:.4f} {cy_n:.4f} {w_n:.4f} {h_n:.4f}")
print(f"{CLASSE:>4} {cx_n:>8.4f} {cy_n:>8.4f} {w_n:>8.4f} {h_n:>8.4f}")
```

```

cv2.rectangle(img_bbox, (x0, y0), (x0 + w, y0 + h), (0, 255, 0), 4)
cv2.putText(img_bbox, f"moeda", (x0 + 8, y0 + 60),
            cv2.FONT_HERSHEY_SIMPLEX, 3.8, (255, 0, 0), 5, cv2.LINE_AA)

# Exportar arquivo de anotação no formato YOLO
with open("moedas.txt", "w") as f:
    f.write("\n".join(yolo_linhas))
print("\nAnotação salva em moedas.txt")

mm.show(
    [img_coins_gray, img_final, img_bbox],
    titles=["Original", "Segmentação Final", "Bounding Boxes (formato YOLO)"],
    cols=3, figsize=(18, 6)
)

```

| cls | cx_n   | cy_n   | w_n    | h_n    | ← formato YOLO |
|-----|--------|--------|--------|--------|----------------|
| 0   | 0.7753 | 0.1102 | 0.2880 | 0.2117 |                |
| 0   | 0.4784 | 0.0984 | 0.2359 | 0.1828 |                |
| 0   | 0.1331 | 0.1225 | 0.2255 | 0.1637 |                |
| 0   | 0.4464 | 0.3217 | 0.2469 | 0.1816 |                |
| 0   | 0.7523 | 0.3471 | 0.2807 | 0.2074 |                |
| 0   | 0.1664 | 0.3812 | 0.2745 | 0.2016 |                |
| 0   | 0.4862 | 0.6104 | 0.3474 | 0.2598 |                |
| 0   | 0.8115 | 0.6154 | 0.2760 | 0.2012 |                |
| 0   | 0.1724 | 0.6023 | 0.2250 | 0.1711 |                |
| 0   | 0.1893 | 0.8258 | 0.2536 | 0.1922 |                |
| 0   | 0.7763 | 0.8652 | 0.2255 | 0.1734 |                |
| 0   | 0.4854 | 0.8953 | 0.2750 | 0.2039 |                |

Anotação salva em moedas.txt




Figura 4.29: *Bounding boxes* derivadas dos componentes conexos sobrepostas à imagem original. As anotações são exportadas no formato YOLO (*classe cx cy w h*), com coordenadas normalizadas para o intervalo  $[0,1]$ .

O formato YOLO armazena cada objeto em uma linha contendo cinco campos:

classe cx cy w h

onde  $(cx, cy)$  representa o centro da *bounding box* e  $(w, h)$  suas dimensões. Todos os valores geométricos são normalizados para o intervalo  $[0,1]$  em relação à largura e à altura da imagem. A **classe** é um identificador

inteiro associado a uma categoria definida pelo conjunto de dados (por exemplo,  $0 \rightarrow \text{moeda}$ ). Quando há múltiplas categorias — como moeda de ouro (0), moeda de prata (1) e disco plástico (2) — basta atribuir o identificador correspondente a cada objeto antes da exportação, mantendo exatamente o mesmo formato de anotação. No exemplo anterior, essas informações foram armazenadas no arquivo `moedas.txt`.

O fluxo apresentado neste capítulo — segmentação  $\rightarrow$  rotulação  $\rightarrow$  extração de *bounding boxes* — corresponde conceitualmente à etapa de **anotação** (*labeling*) empregada na construção de conjuntos de treinamento para detectores modernos. Ferramentas especializadas, como Label Studio e Roboflow, automatizam esse processo em imagens complexas, mas a lógica fundamental permanece a mesma: associar a cada objeto uma região de interesse e uma classe. Em cenários controlados, com fundo uniforme e objetos bem separados, técnicas morfológicas podem inclusive gerar anotações automaticamente ou servir como ponto de partida para a rotulação manual, reduzindo significativamente o esforço de construção do conjunto de dados. Em aplicações reais mais complexas, entretanto, a validação humana continua sendo necessária para garantir a qualidade das anotações.

### Avaliação: IoU (*Intersection over Union*)

Uma forma simples de avaliar a qualidade de uma segmentação consiste em compará-la com uma máscara de referência (*ground truth*). A métrica mais utilizada para essa finalidade é a **IoU** (*Intersection over Union*):

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} \quad (4.16)$$

onde  $A$  representa a segmentação produzida pelo algoritmo e  $B$  a segmentação de referência.

O valor da IoU varia entre 0 e 1. Quanto maior o valor, maior a sobreposição entre as máscaras. Uma IoU igual a 1 indica correspondência perfeita entre a segmentação obtida e a referência.

A mesma métrica também é amplamente utilizada em detecção de objetos, sendo aplicada às *bounding boxes* previstas e anotadas. Nessa área, valores de IoU superiores a 0,5 são frequentemente adotados como critério mínimo para considerar uma detecção correta.

### Além da Morfologia

As técnicas estudadas neste capítulo segmentam objetos explorando conectividade espacial, operações morfológicas e relevo topográfico. Existem, entretanto, abordagens alternativas baseadas em agrupamento de características, como o algoritmo *k-means*, modelos de mistura Gaussiana (GMM) e métodos mais recentes baseados em aprendizado profundo. Essas técnicas serão retomadas na Parte II do livro, dedicada à Visão Computacional.

## 4.6 Resumo

Neste capítulo foram apresentadas as principais técnicas de segmentação e morfologia matemática, concluindo o estudo do PDI no domínio espacial.

- **Pré-processamento e limiarização:** A combinação entre equalização adaptativa CLAHE e o método de Otsu mostrou-se eficaz para induzir separação bimodal no histograma e simplificar a binarização de imagens com iluminação não uniforme.
- **Erosão e dilatação:** Operadores morfológicos fundamentais baseados na busca por mínimos e máximos locais em uma vizinhança definida pelo elemento estruturante  $B$ . São operadores duais pelo complemento e foram implementados por meio das funções `mm.ero` e `mm.dil`.
- **Abertura e fechamento:** Composições de erosão e dilatação que permitem remover ruídos, suavizar contornos e preencher pequenas lacunas, preservando a estrutura global dos objetos.
- **Reconstrução morfológica:** Processo geodésico iterativo que propaga um marcador dentro dos limites impostos por uma máscara, constituindo a base de operadores como `mm.clohole` e `mm.edgeoff`.



- **Pipeline de limpeza binária:** Fluxo consolidado composto por CLAHE → Otsu → abertura → `mm.clohole` → abertura restrita → `mm.edgeoff`, produzindo máscaras adequadas para análise quantitativa.
- **Morfologia em tons de cinza:** Extensão algébrica baseada em mínimos e máximos ponderados, viabilizando operadores como gradiente morfológico e filtros *top-hat* para realce de estruturas locais.
- **Transformada de Distância e Watershed:** A Transformada de Distância permitiu gerar marcadores automáticos para o algoritmo *watershed*, possibilitando a separação de objetos adjacentes ou parcialmente sobrepostos.
- **Componentes conexos e descritores:** A rotulação de regiões (`cv2.connectedComponentsWithStats`) e a extração de contornos (`cv2.findContours`) permitiram calcular descritores geométricos como área, centróide, perímetro, circularidade e *bounding boxes*.
- **Conexão com Visão Computacional Moderna:** As *bounding boxes* extraídas por morfologia foram exportadas no formato YOLO, evidenciando a ligação entre técnicas clássicas de segmentação e sistemas modernos de detecção de objetos.

O Capítulo 5 introduzirá técnicas de processamento no **domínio da frequência**, abordando a **Transformada de Fourier**, filtragem espectral e os fundamentos da **compressão de imagens**, incluindo DCT, JPEG e *wavelets*.

## 4.7 Uso do Gemini Notebook como Tutor Complementar

Nesta edição, o uso do **Gemini Notebook** é incentivado como ferramenta complementar de aprendizagem. Baseado em inteligência artificial, o sistema utiliza exclusivamente os documentos fornecidos pelo autor como fonte de conhecimento, produzindo respostas alinhadas ao conteúdo e à abordagem adotada ao longo deste capítulo.

 Estude com o Tutor Inteligente

 [ACESSAR Gemini Notebook: CAPÍTULO 04](#)

### Aviso sobre Conteúdo Gerado por IA

Embora seja uma ferramenta valiosa de apoio aos estudos, o Gemini Notebook pode eventualmente produzir respostas incompletas, imprecisas ou incorretas. Recomenda-se validar as informações consultando o material do capítulo, livros, artigos científicos e outras fontes acadêmicas confiáveis. Sempre que possível, execute e experimente os exemplos práticos apresentados ao longo do texto para consolidar a compreensão dos conceitos.

## 4.8 Lista de Exercícios

1. (10%) Implemente manualmente o critério de Otsu sem utilizar `cv2.threshold`. Calcule a variância interclasses  $\sigma_B^2(T)$  para todos os limiares  $T \in [0, 255]$  usando `mm.hist`, identifique o limiar ótimo  $T^*$  e compare o resultado com o valor obtido pelo OpenCV. Plote  $\sigma_B^2$  em função de  $T$  e destaque o ponto de máximo.
2. (15%) Aplique limiarização adaptativa com blocos de tamanho 11, 31 e 51 a uma imagem contendo iluminação não uniforme. Compare os resultados com a limiarização global de Otsu e discuta as vantagens e limitações de cada abordagem.
3. (15%) Execute o *pipeline watershed* da imagem de moedas variando o limiar aplicado à Transformada de Distância (0.3, 0.5 e 0.7 vezes o valor máximo). Explique como esse parâmetro influencia a geração dos marcadores, a separação de objetos adjacentes e a ocorrência de sobre-segmentação.
4. (15%) Utilizando `mm.drawImage`, construa uma demonstração visual passo a passo da erosão de uma imagem binária  $7 \times 7$  com elemento estruturante quadrado  $3 \times 3$ . Para cada posição analisada, indique



se o elemento estruturante está completamente contido no objeto e justifique o valor atribuído ao pixel de saída.

5. (15%) Demonstre experimentalmente a dualidade entre erosão e dilatação verificando a identidade  $(A \ominus B)^c = A^c \oplus \hat{B}$  utilizando `mm.ero`, `mm.dil` e `mm.bnot`. Calcule a diferença pixel a pixel entre os dois lados da equação e apresente o resultado utilizando `mm.histImg` ou visualização equivalente.
6. (15%) Implemente manualmente o gradiente morfológico utilizando apenas `mm.ero` e `mm.dil`, comparando o resultado com `cv2.morphologyEx(img, cv2.MORPH_GRADIENT, B)`. Avalie o efeito de diferentes elementos estruturantes (quadrado  $3 \times 3$ , disco  $5 \times 5$  e linha  $1 \times 9$ ) sobre a detecção de bordas.
7. (15%) Construa um *pipeline* completo para contagem e classificação de moedas por tamanho (pequena, média e grande) utilizando área e circularidade como descritores. Gere uma máscara de referência (*ground truth*) manualmente e calcule a métrica IoU (*Intersection over Union*) para avaliar a qualidade da segmentação. Apresente os resultados em tabela e por meio de visualizações produzidas com `mm.show`.

## Referências do Capítulo

A fundamentação teórica deste capítulo baseia-se nas seguintes obras:

- Gonzalez; Woods (2018) para os conceitos de segmentação, limiarização de Otsu, Transformada de Distância, *watershed*, morfologia matemática e descritores de forma.
- Matheron (1975) e Serra (1982) para a fundamentação teórica original, formulação algébrica e desenvolvimento da Morfologia Matemática.
- Szeliski (2022) para segmentação baseada em regiões, rotulação de componentes conexos, *watershed* baseado em marcadores e avaliação de segmentação por meio da métrica IoU.
- Bradski; Kaehler (2008) para a utilização prática da biblioteca OpenCV, incluindo funções como `cv2.distanceTransform`, `cv2.watershed`, `cv2.connectedComponentsWithStats` e `cv2.findContours`.
- Redmon et al. (2016) para a introdução aos detectores modernos da família YOLO e sua relação com descritores geométricos como *bounding boxes* extraídas por segmentação.
- Singh; Lloyd; Flicker (2024) para a construção de labirintos complexos baseados em ciclos hamiltonianos sobre mosaicos quasicristalinos, utilizados como exemplo de aplicação da Transformada de Distância Geodésica e de algoritmos de busca de caminhos.
- Zampirolli et al. (2025) para a implementação dos operadores morfológicos, transformadas geodésicas e resolução de labirintos por propagação de distâncias em domínios restritos.



## 4.9 Parte Prática com Exercícios de Programação

Esta lista transforma os conceitos do Capítulo 4 em uma trilha prática de segmentação e morfologia matemática. Os EPs começam com limiarização e avançam até rotulação e descritores de componentes, sempre com matrizes pequenas para que cada pixel possa ser conferido à mão.

### ! Regra comum dos EPs morfológicos

Nas operações com vizinhança, **não faça padding**. Para cada pixel, avalie apenas as posições do elemento estruturante que caem dentro do domínio da imagem. Essa é a mesma ideia das implementações didáticas em `morph.py`, como `mm.dil0`, `mm.ero0`, `mm.dil1` e `mm.label0`: a vizinhança é recortada pelo domínio válido da imagem.

## 🎯 Objetivo deste Caderno

O caderno permite desenvolver, validar, organizar e testar soluções de **Exercícios de Programação (EPs)** em ambientes interativos, como o Colab, com os mesmos casos de teste do Moodle, copiando para lá apenas na hora de registrar a nota oficial.

## Download

Baixe `morph.py` e `testsuite.py` executando a célula abaixo:

```
import os, sys, importlib, inspect, urllib.request

# URLs do repositório
BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph"
for f in ["morph.py", "testsuite.py"]:
    if not os.path.exists(f):
        urllib.request.urlretrieve(f"{BASE_URL}/{f}", f)

import morph, testsuite
importlib.reload(morph); importlib.reload(testsuite)
from morph import mm
from testsuite import TestSuite

print(f" Ambiente pronto. Morph: {morph.__version__} | TestSuite: {testsuite.__version__}")
```

Ambiente pronto. Morph: 1.1.2 | TestSuite: 1.1.2

## Executando os Testes

Para avaliar os testes, execute `TestSuite("EP04_01.extensão").run()` numa nova célula, trocando a extensão pela da linguagem usada (`.py`, `.java`, `.c`, `.cpp`, `.js` ou `.r`). O sistema baixa os casos de teste do GitHub, executa o programa e calcula a nota automaticamente.

Para testar código Python diretamente, sem salvar arquivo, use `run_code(codigo)` passando o código como *string* numa variável `codigo`:

```
codigo = """
from morph import mm
# ... seu código aqui ...
"""

TestSuite("EP04_01").run_code(codigo)
```

### 4.9.1 EP04\_01 Limiarização Global por Limiar Fixo

Em **scanners de documentos** e em **sistemas de leitura de código de barras**, a primeira etapa do processamento é sempre separar o que é “objeto” (tinta, texto, barras) do que é “fundo” (papel, embalagem). A **limiarização global** faz exatamente isso: compara cada pixel a um único limiar  $T$  e decide, em tempo real, se ele pertence à classe clara ou à classe escura. É o operador de segmentação mais simples — e mesmo assim, está por trás de boa parte dos *pipelines* industriais de inspeção visual. Ver na Figure 4.30 uma simulação deste EP.

#### 4.9.1.1 📋 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas).
2. **Limiar:** Ler o inteiro  $T$  (limiar de decisão).
3. **Dados:** Ler os valores inteiros da matriz original linha a linha.
4. **Mapeamento:** Para cada pixel  $p$ , calcular o novo valor pela equação:

$$p' = \begin{cases} 255, & \text{se } p > T \\ 0, & \text{se } p \leq T \end{cases}$$

5. **Saída:** Exibir a matriz binarizada com dimensões  $L \times C$ .

#### 4.9.1.2 Restrições Computacionais

- **Binarização:** A saída contém **apenas** os valores 0 ou 255.
- **Comparação estrita:** O critério usa  $> T$  (pixels iguais a  $T$  tornam-se fundo).
- **Tipo:** O resultado final deve ser inteiro.
- **Observação:** Este EP segue a convenção da OpenCV (`cv2.THRESH_BINARY`): apenas pixels com valor **maior que**  $T$  tornam-se brancos (255); pixels com valor **igual a**  $T$  permanecem pretos (0).

#### 4.9.1.3 Fundamentação Teórica

| Parâmetro                | Tipo    | Impacto Visual                       |
|--------------------------|---------|--------------------------------------|
| $T$ <b>pequeno</b>       | Inteiro | A maioria dos pixels torna-se branca |
| $T$ <b>grande</b>        | Inteiro | A maioria dos pixels torna-se preta  |
| $T$ <b>bem escolhido</b> | Inteiro | Separa nitidamente objeto e fundo    |

#### 4.9.1.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Inteiro  $T$ .
- Linhas seguintes: Elementos inteiros da matriz original.

**Saída:**

- Matriz binarizada em  $L$  linhas e  $C$  colunas, valores 0 ou 255 separados por espaço.

#### 4.9.1.5 Exemplos

| Entrada                                        | Saída                    | Observação                                                                                                |
|------------------------------------------------|--------------------------|-----------------------------------------------------------------------------------------------------------|
| 2<br>4<br>100<br>0 99 100 180<br>255 30 120 80 | 0 0 0 255<br>255 0 255 0 | $T = 100$ : apenas pixels com valor maior que 100 tornam-se brancos; por isso, 99 e 100 tornam-se pretos. |
| 1<br>3<br>0<br>0 50 255                        | 0 255 255                |                                                                                                           |
|                                                |                          | $T = 0$ : apenas pixels com valor estritamente maior que 0 tornam-se brancos.                             |

```
%%writefile EP04_01.py
# Código Python
```

```
Writing EP04_01.py
```

```
TestSuite("EP04_01.py").run()
```




Figura 4.30: Simulador: Limiarização Global por Limiar Fixo

#### 4.9.2 EP04\_02 Limiarização Automática de Otsu

Escolher manualmente o limiar  $T$  funciona quando a iluminação é estável, mas em **microscopia digital** e em **inspeção de lâminas de sangue**, cada amostra tem um contraste diferente — um limiar fixo falharia de imagem para imagem. O **método de Otsu** resolve isso encontrando, sozinho, o limiar que **maximiza a separação estatística** entre as duas classes de pixels, tornando a segmentação automática e adaptativa. Ver na Figure 4.31 uma simulação deste EP.

##### 4.9.2.1 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas).
2. **Dados:** Ler os valores inteiros da matriz original linha a linha.
3. **Histograma:** Construir o histograma  $h[i]$ ,  $i = 0, \dots, 255$ , contando quantos pixels têm valor  $i$ .
4. **Busca do limiar:** Para cada candidato  $T$  de 1 a 255, calcular a **variância entre classes**:

$$\sigma_B^2(T) = \frac{n_0 \cdot n_1}{N^2} (m_0 - m_1)^2$$

onde  $n_0, n_1$  são as quantidades de pixels com valor  $< T$  e  $\geq T$ ,  $m_0, m_1$  são suas médias, e  $N = L \times C$ .

5. **Escolha:** O limiar ótimo  $T^*$  é o que maximiza  $\sigma_B^2(T)$  (em caso de empate, manter o **primeiro** encontrado).
6. **Aplicação:** Binarizar a imagem usando  $T^*$ , aplicando:

$$p' = \begin{cases} 255, & \text{se } p > T^* \\ 0, & \text{se } p \leq T^* \end{cases}$$

#### 4.9.2.2 📌 Restrições Computacionais

- **Candidatos válidos:** Ignorar  $T$  que deixe  $n_0 = 0$  ou  $n_1 = 0$  (classe vazia).
- **Empate:** Sempre manter o **primeiro**  $T$  que atingiu o valor máximo de  $\sigma_B^2$ .
- **Tipo:**  $T^*$  e a matriz de saída devem ser inteiros.
- **Convenção OpenCV:** A binarização segue `cv2.THRESH_BINARY`; pixels com valor exatamente igual a  $T^*$  tornam-se pretos.

#### 4.9.2.3 🧠 Fundamentação Teórica

| Conceito             | Significado                  | Impacto                                                                   |
|----------------------|------------------------------|---------------------------------------------------------------------------|
| $\sigma_B^2(T)$ alta | Classes bem separadas em $T$ | $T$ é um bom candidato a limiar                                           |
| Histograma bimodal   | Dois “morros” distintos      | Otsu encontra o vale entre eles                                           |
| Histograma unimodal  | Um único “morro”             | Otsu ainda escolhe <i>algum</i> $T$ , mas a segmentação é pouco confiável |

#### 4.9.2.4 📦 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linhas seguintes: Elementos inteiros da matriz original.

##### Saída:

- Matriz binarizada em  $L$  linhas e  $C$  colunas, valores 0 ou 255.

#### 4.9.2.5 📌 Exemplos

| Entrada         | Saída           | Observação                               |
|-----------------|-----------------|------------------------------------------|
| 4               | 0 0 0 255       | Histograma bimodal claro: 12 e 200       |
| 4               | 0 0 255 255     |                                          |
| 12 12 12 200    | 0 255 255 255   |                                          |
| 12 12 200 200   | 255 255 255 255 |                                          |
| 12 200 200 200  |                 | Apenas dois valores: $T^*$ fica no maior |
| 200 200 200 200 |                 |                                          |
| 1               | 0 250           |                                          |
| 2               |                 |                                          |
| 10 250          |                 |                                          |

```
%%writefile EP04_02.py
# Código Python
```

```
Writing EP04_02.py
```

```
TestSuite("EP04_02.py").run()
```




Figura 4.31: Simulador: Limiarização Automática de Otsu



### 4.9.3 EP04\_03 🌱 Dilatação Binária Plana (mm.dil0)

Em **microscopia de partículas** e em **OCR de placas de carro desgastadas**, traços finos ou descontínuos precisam ser “engrossados” para que o reconhecimento funcione. A **dilatação morfológica** faz exatamente isso: expande regiões claras usando um elemento estruturante  $B$  — a mesma operação implementada em `morph.py` como `mm.dil0(f, B)`, usada quando  $B$  é **plano** (sem pesos, só 0/1). Ver na Figure 4.32 uma simulação deste EP.

#### 4.9.3.1 📋 Diretrizes de Implementação

1. **Dimensões da imagem:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas) de  $f$ .
2. **Dimensões de  $B$ :** Ler os inteiros  $L_B$  (linhas) e  $C_B$  (colunas) do elemento estruturante.
3. **Elemento estruturante:** Ler a matriz  $B$  com valores 0 ou 1, linha a linha.
4. **Dados:** Ler a matriz  $f$  (a imagem original), linha a linha.
5. **Reflexão:** Construir  $B_{ref}$ , a versão de  $B$  refletida em  $180^\circ$  (linhas e colunas invertidas) — exatamente como faz `mm.dil0` internamente.
6. **Vizinhança sem padding:** Para cada pixel  $(y, x)$ , percorrer as posições  $(by, bx)$  de  $B_{ref}$  centradas em  $(y, x)$ , usando o deslocamento

$$v_y = y + by + o_y, \quad v_x = x + bx + o_x, \quad o_y = -\frac{L_B}{2} + 0,5, \quad o_x = -\frac{C_B}{2} + 0,5$$

**Descartar** todo  $(v_y, v_x)$  fora de  $[0, L) \times [0, C)$  — **não preencher com zeros**.

7. **Mapeamento:** Calcular cada pixel de saída como o **máximo** entre  $f(y, x)$  e todos os  $f(v_y, v_x)$  válidos cuja posição correspondente em  $B_{ref}$  vale 1:

$$g(y, x) = \max \left( f(y, x), \max_{\substack{(v_y, v_x) \text{ válido} \\ B_{ref}(by, bx)=1}} f(v_y, v_x) \right)$$

8. **Saída:** Exibir a matriz  $g$  com dimensões  $L \times C$ .

#### 4.9.3.2 🚫 Restrições Computacionais

- **Sem padding:** Jamais inventar vizinhos fora da imagem; usar apenas os que existem de fato.
- **Reflexão obrigatória:**  $B$  deve ser refletido antes de aplicado (é o que diferencia `mm.dil0` de uma simples busca por máximo).
- **Robustez de borda:** Se nenhuma posição válida de  $B_{ref} = 1$  cair dentro do domínio para um dado pixel, ele **mantém seu valor original**.

#### 4.9.3.3 🧠 Fundamentação Teórica

| Conceito                          | Significado                   | Impacto Visual                                       |
|-----------------------------------|-------------------------------|------------------------------------------------------|
| <b>Dilatação</b>                  | $g \geq f$ sempre (extensiva) | Regiões claras crescem, buracos escuros encolhem     |
| <b><math>B</math> maior</b>       | Vizinhança mais ampla         | Crescimento mais agressivo                           |
| <b>Reflexão de <math>B</math></b> | $B_{ref}(y, x) = B(-y, -x)$   | Garante a definição formal de Minkowski da dilatação |

#### 4.9.3.4 📦 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Inteiro  $L_B$ .
- Linha 4: Inteiro  $C_B$ .

- Próximas  $L_B$  linhas: elementos inteiros (0 ou 1) da matriz  $B$ .
- Próximas  $L$  linhas: elementos inteiros da matriz  $f$ .

**Saída:**

- Matriz  $g$  em  $L$  linhas e  $C$  colunas, valores inteiros separados por espaço.

**4.9.3.5 Exemplos**

| Entrada     | Saída          | Observação                                                       |
|-------------|----------------|------------------------------------------------------------------|
| 3           | 0 9 0          | $B$ em cruz simétrico: ponto isolado se expande em cruz          |
| 3           | 9 9 9          |                                                                  |
| 3           | 0 9 0          |                                                                  |
| 3           |                |                                                                  |
| 0 1 0       |                | $B$ horizontal: cada pixel “puxa” o máximo dos vizinhos da linha |
| 1 1 1       |                |                                                                  |
| 0 1 0       |                |                                                                  |
| 0 0 0       |                |                                                                  |
| 0 9 0       |                |                                                                  |
| 0 0 0       |                |                                                                  |
| 1           | 200 200 200 80 |                                                                  |
| 4           |                |                                                                  |
| 1           |                |                                                                  |
| 3           |                |                                                                  |
| 1 1 1       |                |                                                                  |
| 10 200 5 80 |                |                                                                  |

```
%%writefile EP04_03.py
# Código Python
```

```
Writing EP04_03.py
```

```
TestSuite("EP04_03.py").run()
```

**4.9.4 EP04\_04 Erosão Binária Plana (mm.ero0)**

Se a dilatação engrossa, a **erosão** afina. Em **sistemas de contagem de células**, ela é usada para **separar células que se tocam**: ao “comer” as bordas de cada região, conexões finas entre objetos desaparecem antes mesmo de qualquer contagem ser feita. Em **morph.py**, essa é a operação **mm.ero0(f, B)** — a **dual** exata da dilatação, e a única das duas que **não** reflete o elemento estruturante. Ver na Figure 4.33 uma simulação deste EP.

**4.9.4.1 Diretrizes de Implementação**

1. **Dimensões da imagem:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas) de  $f$ .
2. **Dimensões de  $B$ :** Ler os inteiros  $L_B$  (linhas) e  $C_B$  (colunas) do elemento estruturante.
3. **Elemento estruturante:** Ler a matriz  $B$  com valores 0 ou 1, linha a linha.
4. **Dados:** Ler a matriz  $f$  (a imagem original), linha a linha.
5. **Vizinhança sem padding (sem reflexão!):** Para cada pixel  $(y, x)$ , percorrer as posições  $(by, bx)$  de  $B$  na ordem original (sem refletir), usando o mesmo deslocamento do EP04\_03:

$$v_y = y + by + o_y, \quad v_x = x + bx + o_x, \quad o_y = -\frac{L_B}{2} + 0,5, \quad o_x = -\frac{C_B}{2} + 0,5$$




Figura 4.32: Simulador: Dilatação Binária Plana (mm.dil0)

**Descartar** todo  $(v_y, v_x)$  fora de  $[0, L) \times [0, C)$ . 6. **Mapeamento:** Calcular cada pixel de saída como o **mínimo** entre  $f(y, x)$  e todos os  $f(v_y, v_x)$  válidos cuja posição correspondente em  $B$  vale 1:

$$g(y, x) = \min \left( f(y, x), \min_{\substack{(v_y, v_x) \text{ válido} \\ B(by, bx)=1}} f(v_y, v_x) \right)$$

7. **Saída:** Exibir a matriz  $g$  com dimensões  $L \times C$ .

#### 4.9.4.2 Restrições Computacionais

- **Sem reflexão:** Diferente da dilatação,  $B$  é usado **exatamente como lido** — refletir aqui seria um erro conceitual grave.
- **Sem padding:** Vizinhos fora da imagem são simplesmente ignorados, nunca tratados como 0.
- **Robustez de borda:** Se nenhuma posição válida de  $B = 1$  cair dentro do domínio, o pixel mantém seu valor original.

#### 4.9.4.3 Fundamentação Teórica

| Conceito                    | Significado                                          | Impacto Visual                                    |
|-----------------------------|------------------------------------------------------|---------------------------------------------------|
| <b>Erosão</b>               | $g \leq f$ sempre (anti-extensiva)                   | Regiões claras encolhem, ruído pontual desaparece |
| <b>Dualidade</b>            | $\text{ero}(f, B) = -\text{dil}(-f, B_{\text{ref}})$ | Erosão e dilatação são “espelhos” matemáticos     |
| <b><math>B</math> maior</b> | Erosão mais agressiva                                | Objetos finos somem completamente                 |

#### 4.9.4.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Inteiro  $L_B$ .
- Linha 4: Inteiro  $C_B$ .
- Próximas  $L_B$  linhas: elementos inteiros (0 ou 1) da matriz  $B$ .
- Próximas  $L$  linhas: elementos inteiros da matriz  $f$ .

**Saída:**

- Matriz  $g$  em  $L$  linhas e  $C$  colunas, valores inteiros separados por espaço.

#### 4.9.4.5 Exemplos

| Entrada | Saída | Observação                                |
|---------|-------|-------------------------------------------|
| 3       | 9 0 9 | O “buraco” central (0) se propaga em cruz |
| 3       | 0 0 0 |                                           |
| 3       | 9 0 9 |                                           |
| 3       |       |                                           |
| 0 1 0   |       |                                           |
| 1 1 1   |       |                                           |
| 0 1 0   |       |                                           |
| 9 9 9   |       |                                           |
| 9 0 9   |       |                                           |
| 9 9 9   |       |                                           |

| Entrada     | Saída     | Observação                                                       |
|-------------|-----------|------------------------------------------------------------------|
| 1           | 10 5 5 80 | $B$ horizontal: cada pixel “puxa” o mínimo dos vizinhos da linha |
| 4           |           |                                                                  |
| 1           |           |                                                                  |
| 3           |           |                                                                  |
| 1 1 1       |           |                                                                  |
| 10 200 5 80 |           |                                                                  |




Figura 4.33: Simulador: Erosão Binária Plana (mm.ero0)

```
%%writefile EP04_04.py
# Código Python

Writing EP04_04.py

TestSuite("EP04_04.py").run()
```

### 4.9.5 EP04\_05 Abertura Morfológica (Remoção de Ruído)

Imagens capturadas por **sensores de baixo custo**, como os de drones agrícolas, costumam vir salpicadas de pequenos pontos de ruído — pixels isolados que não representam nada real. Aplicar erosão seguida de dilatação com o **mesmo** elemento estruturante produz a **abertura**: ela “limpa” pontos e protuberâncias finas, mas devolve ao objeto principal praticamente seu tamanho original. É a combinação clássica usada em **pré-processamento de imagens de satélite** antes de qualquer contagem de área plantada. Ver na Figure 4.34 uma simulação deste EP.

#### 4.9.5.1 Diretrizes de Implementação

1. **Dimensões da imagem:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas) de  $f$ .
2. **Dimensões de  $B$ :** Ler os inteiros  $L_B$  (linhas) e  $C_B$  (colunas) do elemento estruturante.
3. **Elemento estruturante:** Ler a matriz  $B$  com valores 0 ou 1, linha a linha.
4. **Dados:** Ler a matriz binária  $f$  (valores 0 ou 1), linha a linha.
5. **Erosão:** Calcular  $e = f \ominus B$ , usando exatamente o algoritmo do EP04\_04 (sem refletir  $B$ , sem padding).
6. **Dilatação:** Calcular  $g = e \oplus B$ , usando exatamente o algoritmo do EP04\_03 (refletindo  $B$ , sem padding) — mas agora aplicado sobre  $e$ , não sobre  $f$ .
7. **Saída:** Exibir a matriz resultante  $g$  (a **abertura** de  $f$  por  $B$ ) com dimensões  $L \times C$ .

#### 4.9.5.2 Restrições Computacionais

- **Ordem fixa:** É **sempre** erosão primeiro, depois dilatação — a ordem inversa define outro operador (fechamento, do próximo EP).
- **Mesmo  $B$ :** O elemento estruturante usado na erosão e na dilatação deve ser idêntico.
- **Sem padding em nenhuma das duas etapas.**

#### 4.9.5.3 Fundamentação Teórica

| Conceito                  | Significado                                                | Impacto Visual                                  |
|---------------------------|------------------------------------------------------------|-------------------------------------------------|
| <b>Anti-extensividade</b> | $g \subseteq f$ sempre                                     | A abertura nunca cria pixel novo, só remove     |
| <b>Idempotência</b>       | $\text{abertura}(\text{abertura}(f)) = \text{abertura}(f)$ | Aplicar de novo não muda mais nada              |
| <b>Pontos isolados</b>    | Menores que $B$                                            | São completamente eliminados                    |
| <b>Núcleo do objeto</b>   | Maior que $B$                                              | É recuperado quase intacto pela dilatação final |

#### 4.9.5.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Inteiro  $L_B$ .
- Linha 4: Inteiro  $C_B$ .
- Próximas  $L_B$  linhas: elementos inteiros (0 ou 1) da matriz  $B$ .
- Próximas  $L$  linhas: elementos inteiros (0 ou 1) da matriz  $f$ .

**Saída:**

- Matriz resultante em  $L$  linhas e  $C$  colunas, valores 0 ou 1.

#### 4.9.5.5 Exemplos



| Entrada       | Saída         | Observação                                                                       |
|---------------|---------------|----------------------------------------------------------------------------------|
| 7             | 0 0 0 0 0 0   | Pontos isolados e a protuberância fina desaparecem; o quadrado central sobrevive |
| 7             | 0 0 0 0 0 0   |                                                                                  |
| 3             | 0 0 1 1 1 0 0 |                                                                                  |
| 3             | 0 0 1 1 1 0 0 |                                                                                  |
| 1 1 1         | 0 0 1 1 1 0 0 |                                                                                  |
| 1 1 1         | 0 0 0 0 0 0 0 |                                                                                  |
| 1 1 1         | 0 0 0 0 0 0 0 |                                                                                  |
| 0 0 0 0 0 0 0 |               |                                                                                  |
| 0 1 0 0 0 1 0 |               |                                                                                  |
| 0 0 1 1 1 0 0 |               |                                                                                  |
| 0 0 1 1 1 0 0 |               |                                                                                  |
| 0 0 1 1 1 1 0 |               |                                                                                  |
| 0 0 0 0 0 0 0 |               |                                                                                  |
| 0 1 0 0 0 0 1 |               |                                                                                  |




Figura 4.34: Simulador: Abertura Morfológica (erosão + dilatação)

```
%%writefile EP04_05.py
# Código Python

Writing EP04_05.py

TestSuite("EP04_05.py").run()
```

### 4.9.6 EP04\_06 Fechamento Morfológico (Preenchimento de Falhas)

Em **digitalização de impressões digitais**, sulcos da pele às vezes ficam interrompidos por sujeira ou ressecamento, criando pequenas falhas na curva contínua que deveria existir. O **fechamento** — dilatação seguida de erosão com o mesmo elemento estruturante — é o operador dual da abertura: ele **preenche buracos pequenos e reentrâncias estreitas**, sem alterar significativamente o contorno externo do objeto. É a etapa padrão antes de extrair o esqueleto de uma impressão digital. Ver na Figure 4.35 uma simulação deste EP.

#### 4.9.6.1 Diretrizes de Implementação

1. **Dimensões da imagem:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas) de  $f$ .
2. **Dimensões de  $B$ :** Ler os inteiros  $L_B$  (linhas) e  $C_B$  (colunas) do elemento estruturante.
3. **Elemento estruturante:** Ler a matriz  $B$  com valores 0 ou 1, linha a linha.
4. **Dados:** Ler a matriz binária  $f$  (valores 0 ou 1), linha a linha.
5. **Dilatação:** Calcular  $d = f \oplus B$ , usando exatamente o algoritmo do EP04\_03 (refletindo  $B$ , sem padding).
6. **Erosão:** Calcular  $g = d \ominus B$ , usando exatamente o algoritmo do EP04\_04 (sem refletir  $B$ , sem padding) — agora aplicado sobre  $d$ , não sobre  $f$ .
7. **Saída:** Exibir a matriz resultante  $g$  (o **fechamento** de  $f$  por  $B$ ) com dimensões  $L \times C$ .

#### 4.9.6.2 Restrições Computacionais

- **Ordem fixa:** É sempre dilatação primeiro, depois erosão — a ordem inversa é a abertura do EP04\_05.
- **Mesmo  $B$ :** O elemento estruturante usado na dilatação e na erosão deve ser idêntico.
- **Sem padding em nenhuma das duas etapas.**

#### 4.9.6.3 Fundamentação Teórica

| Conceito                | Significado                                              | Impacto Visual                                |
|-------------------------|----------------------------------------------------------|-----------------------------------------------|
| <b>Extensividade</b>    | $g \supseteq f$ sempre                                   | O fechamento nunca remove pixel, só adiciona  |
| <b>Idempotência</b>     | $\text{fecha}(\text{fecha}(f)) = \text{fecha}(f)$        | Aplicar de novo não muda mais nada            |
| <b>Buracos pequenos</b> | Menores que $\overline{B}$                               | São completamente preenchidos                 |
| <b>Dualidade</b>        | $\text{fecha}(f) = \overline{\text{abre}(\overline{f})}$ | É a abertura aplicada ao “negativo” da imagem |

#### 4.9.6.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Inteiro  $L_B$ .
- Linha 4: Inteiro  $C_B$ .
- Próximas  $L_B$  linhas: elementos inteiros (0 ou 1) da matriz  $B$ .
- Próximas  $L$  linhas: elementos inteiros (0 ou 1) da matriz  $f$ .

**Saída:**

- Matriz resultante em  $L$  linhas e  $C$  colunas, valores 0 ou 1.

#### 4.9.6.5 Exemplos

| Entrada         | Saída           | Observação                                                         |
|-----------------|-----------------|--------------------------------------------------------------------|
| 8               | 0 0 1 1 1 1 0 0 | Os dois buracos internos não-adjacentes são totalmente preenchidos |
| 8               | 0 0 1 1 1 1 0 0 |                                                                    |
| 3               | 0 0 1 1 1 1 0 0 |                                                                    |
| 3               | 0 0 1 1 1 1 0 0 |                                                                    |
| 1 1 1           | 0 0 1 1 1 1 0 0 |                                                                    |
| 1 1 1           | 0 0 1 1 1 1 0 0 |                                                                    |
| 1 1 1           | 0 0 1 1 1 1 0 0 |                                                                    |
| 0 0 0 0 0 0 0 0 | 0 0 1 1 1 1 0 0 |                                                                    |
| 0 0 1 1 1 1 0 0 |                 |                                                                    |
| 0 0 1 1 1 1 0 0 |                 |                                                                    |
| 0 0 1 0 1 1 0 0 |                 |                                                                    |
| 0 0 1 1 0 1 0 0 |                 |                                                                    |
| 0 0 1 1 1 1 0 0 |                 |                                                                    |
| 0 0 1 1 1 1 0 0 |                 |                                                                    |
| 0 0 0 0 0 0 0 0 |                 |                                                                    |




Figura 4.35: Simulador: Fechamento Morfológico (dilatação + erosão)

```
%%writefile EP04_06.py
# Código Python
```

```
Writing EP04_06.py
```

```
TestSuite("EP04_06.py").run()
```

### 4.9.7 EP04\_07 Dilatação e Erosão com Pesos (mm.dil1 / mm.ero1)

Até agora, o elemento estruturante só dizia “este vizinho conta” ou “não conta” — mas em **modelos digitais de elevação** (usados em SIG e em planejamento de drenagem urbana), cada vizinho deveria ter um **peso diferente** dependendo da distância ou da direção do relevo. As versões **ponderadas** da dilatação e da erosão, implementadas em `morph.py` como `mm.dil1(f, b)` e `mm.ero1(f, b)`, somam (ou subtraem) o peso de cada vizinho antes de tomar o máximo (ou mínimo) — generalizando tudo o que foi feito nos EPs anteriores. Ver na Figure 4.36 uma simulação deste EP.

#### 4.9.7.1 Diretrizes de Implementação

1. **Dimensões da imagem:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas) de  $f$ .
2. **Dimensões de  $b$ :** Ler os inteiros  $L_B$  (linhas) e  $C_B$  (colunas) do elemento estruturante ponderado.
3. **Pesos:** Ler a matriz  $b$  de pesos **inteiros** (podem ser negativos, zero ou positivos), linha a linha.
4. **Dados:** Ler a matriz  $f$  (a imagem original), linha a linha.
5. **Vizinhança sem padding:** Para cada pixel  $(y, x)$ , percorrer **todas** as posições  $(by, bx)$  de  $b$  (não apenas onde valeria 1 — aqui **todo** peso participa), usando o mesmo deslocamento dos EPs anteriores:

$$v_y = y + by + o_y, \quad v_x = x + bx + o_x, \quad o_y = -\frac{L_B}{2} + 0,5, \quad o_x = -\frac{C_B}{2} + 0,5$$

**Descartar** todo  $(v_y, v_x)$  fora de  $[0, L) \times [0, C)$ .

6. **Dilatação ponderada:** Calcular

$$g_{dil}(y, x) = \max \left( f(y, x), \max_{(v_y, v_x) \text{ válido}} (f(v_y, v_x) + b(by, bx)) \right)$$

7. **Erosão ponderada:** Calcular, **usando o mesmo  $b$  e sem refletir:**

$$g_{ero}(y, x) = \min \left( f(y, x), \min_{(v_y, v_x) \text{ válido}} (f(v_y, v_x) - b(by, bx)) \right)$$

8. **Saída:** Exibir **primeiro** a matriz  $g_{dil}$  completa, e **depois** a matriz  $g_{ero}$  completa.

#### 4.9.7.2 Restrições Computacionais

- **Nenhuma das duas reflete  $b$**  — a versão ponderada não usa reflexão, mesmo na dilatação (diferente de `mm.dil0`).
- **Todos os pesos participam:** Não existe aqui o filtro “ $B = 1$ ”; mesmo peso 0 entra na conta.
- **Sem padding:** vizinhos fora da imagem são ignorados, nunca virtualmente preenchidos.
- **Tipo:** A saída pode conter valores negativos ou maiores que 255 — **não** há *clipping* neste EP.
- **Dica:** Para remover mensagens de overflow ao ultrapassar limites do tipo `uint8`, incluir no início do código:

```
import warnings
warnings.filterwarnings("ignore")
```

#### 4.9.7.3 Fundamentação Teórica

| Conceito                   | Significado                                      | Impacto Visual                                               |
|----------------------------|--------------------------------------------------|--------------------------------------------------------------|
| <b>Peso positivo</b>       | “Puxa” o valor do vizinho para cima na dilatação | Simula relevo que sobe naquela direção                       |
| <b>Peso negativo</b>       | Reduz a contribuição do vizinho                  | Simula distância ou atenuação direcional                     |
| <b>Dualidade ponderada</b> | $ero1(f, b) = -dil1(-f, b)$                      | A simetria entre as duas operações se mantém mesmo com pesos |

4.9.7.4  Especificação de Entrada e Saída (VPL)

Entrada:

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Inteiro  $L_B$ .
- Linha 4: Inteiro  $C_B$ .
- Próximas  $L_B$  linhas: elementos inteiros (podem ser negativos) da matriz  $b$ .
- Próximas  $L$  linhas: elementos inteiros da matriz  $f$ .

Saída:

- Primeiro a matriz  $g_{dil}$  em  $L$  linhas e  $C$  colunas.
- Em seguida a matriz  $g_{ero}$  em  $L$  linhas e  $C$  colunas.

4.9.7.5  Exemplos

| Entrada  | Saída    | Observação                                                                   |
|----------|----------|------------------------------------------------------------------------------|
| 3        | 50 60 61 | Peso central 2 acelera o crescimento na dilatação e o encolhimento na erosão |
| 3        | 80 90 91 |                                                                              |
| 3        | 81 91 92 |                                                                              |
| 3        | 8 9 19   |                                                                              |
| 0 1 0    | 9 10 20  |                                                                              |
| 1 2 1    | 39 40 50 |                                                                              |
| 0 1 0    |          |                                                                              |
| 10 20 30 |          |                                                                              |
| 40 50 60 |          |                                                                              |
| 70 80 90 |          |                                                                              |




Figura 4.36: Simulador: Dilatação e Erosão com Pesos (mm.dil1 / mm.ero1)

```
import morph, testsuite
importlib.reload(morph); importlib.reload(testsuite)
from morph import mm
from testsuite import TestSuite
```

```
%%writefile EP04_07.py
# Código Python
```

```
Writing EP04_07.py
```

```
TestSuite("EP04_07.py").run()
```

#### 4.9.8 EP04\_08 Gradiente Morfológico, Top-hat e Black-hat

Em **inspeção automática de placas de circuito**, três perguntas aparecem o tempo todo: onde estão as **bordas** dos componentes? Quais **detalhes claros e pequenos** (como pontos de solda) se destacam do fundo? Quais **reentrâncias escuras** (como fissuras) o fundo esconde? Um único par erosão/dilatação responde às três: o **gradiente morfológico** evidencia contornos, o **top-hat** revela picos estreitos, e o **black-hat** revela vales estreitos — três ferramentas, uma só vizinhança. Ver na Figure 4.37 uma simulação deste EP.

##### 4.9.8.1 Diretrizes de Implementação

1. **Dimensões da imagem:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas) de  $f$ .
2. **Dimensões de  $B$ :** Ler os inteiros  $L_B$  (linhas) e  $C_B$  (colunas) do elemento estruturante.
3. **Elemento estruturante:** Ler a matriz  $B$  com valores 0 ou 1, linha a linha.
4. **Dados:** Ler a matriz  $f$  (a imagem original, em tons de cinza), linha a linha.
5. **Operadores de base:** Calcular, exatamente como nos EPs 04\_03 a 04\_06:
  - $d = f \oplus B$  (dilatação),
  - $e = f \ominus B$  (erosão),
  - abertura =  $e \oplus B$ ,
  - fechamento =  $d \ominus B$ .
6. **Gradiente morfológico:**  $\text{grad}(y, x) = d(y, x) - e(y, x)$ .
7. **Top-hat:**  $\text{tophat}(y, x) = f(y, x) - \text{abertura}(y, x)$ .
8. **Black-hat:**  $\text{blackhat}(y, x) = \text{fechamento}(y, x) - f(y, x)$ .
9. **Saída:** Exibir, **nesta ordem**, as três matrizes completas: gradiente, top-hat, black-hat.

##### 4.9.8.2 Restrições Computacionais

- **Sem padding em nenhuma etapa intermediária** — dilatação, erosão, abertura e fechamento seguem as mesmas regras de vizinhança dos EPs anteriores.
- **Não há clipping:** as três saídas podem conter qualquer valor inteiro (o gradiente é sempre  $\geq 0$ , mas top-hat e black-hat também).
- **Reaproveitamento:**  $d$  e  $e$  devem ser calculados **uma única vez** e reaproveitados para montar abertura, fechamento e gradiente.

##### 4.9.8.3 Fundamentação Teórica

| Operador         | Fórmula                    | O que revela                                        |
|------------------|----------------------------|-----------------------------------------------------|
| <b>Gradiente</b> | $d - e$                    | Bordas: zero em regiões planas, alto nas transições |
| <b>Top-hat</b>   | $f - \text{abertura}(f)$   | Elementos <b>claros e finos</b> , menores que $B$   |
| <b>Black-hat</b> | $\text{fechamento}(f) - f$ | Elementos <b>escuros e finos</b> , menores que $B$  |

4.9.8.4  Especificação de Entrada e Saída (VPL)

Entrada:

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Inteiro  $L_B$ .
- Linha 4: Inteiro  $C_B$ .
- Próximas  $L_B$  linhas: elementos inteiros (0 ou 1) da matriz  $B$ .
- Próximas  $L$  linhas: elementos inteiros da matriz  $f$ .

Saída:

- Matriz gradiente em  $L$  linhas e  $C$  colunas.
- Matriz top-hat em  $L$  linhas e  $C$  colunas.
- Matriz black-hat em  $L$  linhas e  $C$  colunas.

4.9.8.5  Exemplos

| Entrada                    | Saída                             | Observação                                                                          |
|----------------------------|-----------------------------------|-------------------------------------------------------------------------------------|
| 9                          | (gradiente: halo                  | Pico isolado vira top-hat; vale isolado vira black-hat; ambos aparecem no gradiente |
| 9                          | $3 \times 3 = 70$ em torno de     |                                                                                     |
| 3                          | (2, 2) e halo $3 \times 3 = 8$ em |                                                                                     |
| 3                          | torno de (6, 6), resto 0)         |                                                                                     |
| 1 1 1                      | (top-hat: único 70 em             |                                                                                     |
| 1 1 1                      | (2, 2), resto 0)                  |                                                                                     |
| 1 1 1                      | (black-hat: único 8 em            |                                                                                     |
| 10 10 10 10 10 10 10 10 10 | (6, 6), resto 0)                  |                                                                                     |
| 10 10 10 10 10 10 10 10 10 |                                   |                                                                                     |
| 10 10 80 10 10 10 10 10 10 |                                   |                                                                                     |
| 10 10 10 10 10 10 10 10 10 |                                   |                                                                                     |
| 10 10 10 10 10 10 10 10 10 |                                   |                                                                                     |
| 10 10 10 10 10 10 10 10 10 |                                   |                                                                                     |
| 10 10 10 10 10 10 2 10 10  |                                   |                                                                                     |
| 10 10 10 10 10 10 10 10 10 |                                   |                                                                                     |
| 10 10 10 10 10 10 10 10 10 |                                   |                                                                                     |




Figura 4.37: Simulador: Gradiente Morfológico, Top-hat e Black-hat



```
%%writefile EP04_08.py
# Código Python
```

```
Writing EP04_08.py
```

```
TestSuite("EP04_08.py").run()
```

#### 4.9.9 EP04\_09 Transformada de Distância e o “Miolo” do Objeto

Em **robótica móvel**, ao planejar uma rota dentro de um corredor, o robô quer saber não apenas *onde* existe espaço livre, mas também **quão longe** cada ponto livre está da parede mais próxima. Os caminhos mais seguros tendem a passar pelo “miolo” do corredor, longe dos obstáculos.

A **transformada de distância morfológica** atribui a cada pixel um valor que representa sua distância até a borda mais próxima, segundo a métrica definida pelo elemento estruturante. Pixels próximos à borda recebem valores baixos, enquanto pixels mais internos recebem valores maiores. O pixel de valor máximo corresponde à região mais protegida do objeto, frequentemente associada ao seu centro morfológico.

Ver na Figure 4.38 uma simulação deste EP.

##### 4.9.9.1 Diretrizes de Implementação

1. **Dimensões da imagem:** ler os inteiros  $L$  (linhas) e  $C$  (colunas) da imagem  $f$ .
2. **Dimensões de  $B$ :** ler os inteiros  $L_B$  (linhas) e  $C_B$  (colunas) do elemento estruturante.
3. **Elemento estruturante:** ler a matriz  $b$ , contendo valor 0 no centro e valores negativos nas demais posições.
4. **Imagem:** ler a matriz binária  $f$  (valores 0 ou 1), linha a linha.
5. **Preparação:** multiplicar a imagem por  $L \times C$ , garantindo que os pixels internos tenham valor inicial suficientemente alto para a propagação das distâncias.
6. **Transformada de distância:** calcular a matriz de distâncias utilizando o método `mm.dist1(f,b)`.
7. **Saída:** exibir a matriz resultante da transformada de distância.

##### 4.9.9.2 Restrições Computacionais

- Utilizar a implementação de erosão ponderada fornecida pela biblioteca.
- O elemento estruturante pode conter valores negativos arbitrários.
- A transformada deve ser obtida pela aplicação iterativa de erosões ponderadas até atingir um ponto fixo.

 **Nota Crucial sobre Leitura de Matrizes:** Como o elemento estruturante pode conter valores inteiros negativos (por exemplo,  $-1$  e  $-99$ ), **não utilize a função `mm.readImg` para ler a matriz  $b$** . Essa função converte os dados para o tipo `uint8`, provocando *underflow* e corrompendo os valores negativos. Leia as  $L_B$  linhas de  $b$  manualmente utilizando o tipo padrão `int`. A imagem  $f$  pode continuar sendo lida normalmente por `mm.readImg`.

##### 4.9.9.3 Fundamentação Teórica

| Conceito                               | Significado                                                                       | Impacto Visual                               |
|----------------------------------------|-----------------------------------------------------------------------------------|----------------------------------------------|
| $\text{dist}(y, x)$                    | Distância morfológica até a borda mais próxima segundo a métrica definida por $b$ | Pixels mais internos recebem valores maiores |
| <b>Valor máximo</b>                    | Pixel mais distante da borda                                                      | Aproxima o centro morfológico do objeto      |
| <b>Elemento estruturante ponderado</b> | Define os custos de deslocamento entre pixels vizinhos                            | Determina a métrica de distância utilizada   |

| Conceito             | Significado                 | Impacto Visual                       |
|----------------------|-----------------------------|--------------------------------------|
| <b>Objetos finos</b> | Regiões estreitas do objeto | Produzem valores baixos de distância |

#### 4.9.9.4 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: inteiro  $L$ .
- Linha 2: inteiro  $C$ .
- Linha 3: inteiro  $L_B$ .
- Linha 4: inteiro  $C_B$ .
- Próximas  $L_B$  linhas: elementos inteiros da matriz  $b$ .
- Próximas  $L$  linhas: elementos binários (0 ou 1) da matriz  $f$ .

 **Nota de implementação:** Os elementos da matriz  $f$  (0 ou 1) devem ser multiplicados por **255** para gerar uma imagem binária adequada (0 e 255) antes de aplicar a Transformada de Distância (TD).

##### Saída:

- Matriz da transformada de distância em  $L$  linhas e  $C$  colunas.

#### 4.9.9.5 Exemplo

| Entrada         | Saída           | Observação                              |
|-----------------|-----------------|-----------------------------------------|
| 5               | 0 0 0 0 0 0 0 0 | Resultado da transformada de distância. |
| 9               | 0 1 1 1 1 1 1 0 |                                         |
| 3               | 0 1 2 2 2 2 2 0 |                                         |
| 3               | 0 1 1 1 1 1 1 0 |                                         |
| -99 -1 -99      | 0 0 0 0 0 0 0 0 |                                         |
| -1 0 -1         |                 |                                         |
| -99 -1 -99      |                 |                                         |
| 0 0 0 0 0 0 0 0 |                 |                                         |
| 0 1 1 1 1 1 1 0 |                 |                                         |
| 0 1 1 1 1 1 1 0 |                 |                                         |
| 0 1 1 1 1 1 1 0 |                 |                                         |
| 0 0 0 0 0 0 0 0 |                 |                                         |

**Nota:** o valor  $-99$  atua como uma aproximação prática de  $-\infty$ , impedindo a propagação pelas diagonais. Dessa forma, apenas os vizinhos horizontal e vertical contribuem para a distância, produzindo a distância de Manhattan.

```
%%writefile EP04_09.py
# Código Python
```

```
Writing EP04_09.py
```

```
TestSuite("EP04_09.py").run()
```

#### 4.9.10 EP04\_10 Separação de *Blobs*, Rotulação e Descritores

Em uma **linha de produção de moedas**, é comum que peças encostem umas nas outras na esteira, formando uma única mancha conectada na imagem — uma contagem ingênua erraria o total. A solução




Figura 4.38: Simulador: Transformada de Distância

clássica combina operações morfológicas e análise de conectividade: primeiro uma **erosão** reduz ou rompe conexões frágeis entre objetos, e depois a **rotulação de componentes conectados** separa cada objeto em uma região distinta. Por fim, **descritores geométricos** (área e caixa delimitadora) resumem cada componente encontrado.

Ver na Figure 4.39 uma simulação deste EP.

#### 4.9.10.1 Diretrizes de Implementação

1. **Dimensões da imagem:** ler os inteiros  $L$  (linhas) e  $C$  (colunas) de  $f$ .
2. **Dimensões de  $B$ :** ler os inteiros  $L_B$  (linhas) e  $C_B$  (colunas) do elemento estruturante.
3. **Elemento estruturante:** ler a matriz  $B$ , contendo valores 0 ou 1, linha a linha.
4. **Dados:** ler a matriz binária  $f$  (valores 0 ou 1), linha a linha.
5. **Separação:** calcular

$$f_{ero} = f \ominus B$$

usando erosão binária plana (como no EP04\_04), eliminando conexões frágeis entre objetos.

6. **Rotulação:** sobre  $f_{ero}$ , identificar componentes conectados usando conectividade definida pela vizinhança  $B$ . A rotulação deve seguir varredura *raster*: ao encontrar um pixel 1 ainda não rotulado, atribuir um novo rótulo inteiro crescente a partir de 1 e propagar esse rótulo a toda a região conectada.
7. **Descritores:** para cada rótulo  $k$ , calcular:
  - **Área:** número de pixels pertencentes ao rótulo;
  - **Caixa delimitadora:**

$$(y_{min}, x_{min}, y_{max}, x_{max})$$

8. **Saída:** exibir o número total de rótulos e, em seguida, uma linha por rótulo no formato:

$$k, \text{ área}, y_{\min}, x_{\min}, y_{\max}, x_{\max}$$

#### 4.9.10.2 Restrições Computacionais

- A erosão deve ser aplicada antes da rotulação.
- A conectividade é fixa e definida pela vizinhança acima.
- O elemento estruturante  $B$  não interfere na conectividade da rotulação.
- Sem padding em qualquer etapa.
- A ordem dos rótulos segue a primeira descoberta em varredura *raster*.

#### 4.9.10.3 Fundamentação Teórica

| Conceito           | Significado                                | Impacto                                              |
|--------------------|--------------------------------------------|------------------------------------------------------|
| Ponte fina         | Conexão estreita entre objetos             | Pode ser removida pela erosão morfológica            |
| Conectividade      | Definida pelo conjunto $\mathcal{N}(y, x)$ | Determina quais pixels pertencem ao mesmo componente |
| Área               | Número de pixels por componente            | Estimativa direta do tamanho do objeto               |
| Caixa delimitadora | Extensão espacial do rótulo                | Resumo geométrico do componente                      |

#### 4.9.10.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: inteiro  $L$
- Linha 2: inteiro  $C$
- Linha 3: inteiro  $L_B$
- Linha 4: inteiro  $C_B$
- Próximas  $L_B$  linhas: matriz  $B$
- Próximas  $L$  linhas: matriz  $f$

**Saída:**

- Linha 1: número total de rótulos encontrados
- Linhas seguintes:

$$k, \text{ área}, y_{\min}, x_{\min}, y_{\max}, x_{\max}$$

```
%%writefile EP04_10.py
# Código Python
```

```
Writing EP04_10.py
```

```
TestSuite("EP04_10.py").run()
```



Figura 4.39: Simulador: Separação de Blobs, Rotulação e Descritores

## Capítulo 5

# Transformadas e Compressão



### Em construção!

Nos capítulos anteriores, todas as operações foram realizadas **no domínio espacial**, em que os algoritmos atuam diretamente sobre os valores de intensidade dos pixels.

Neste capítulo será apresentada uma abordagem complementar: o **domínio da frequência**, no qual a imagem é representada pelas variações espaciais de intensidade, e não apenas pelos valores individuais dos pixels.

O conceito de **frequência espacial** descreve a rapidez com que a intensidade varia ao longo da imagem. Variações lentas correspondem a **baixas frequências**, enquanto bordas, detalhes finos e ruídos correspondem a **altas frequências**.

Essa representação baseia-se no fato de que qualquer imagem digital discreta pode ser decomposta em uma combinação de **funções ortogonais**. A **Transformada de Fourier** utiliza uma **base de exponenciais complexas bidimensionais** (equivalentes a senoides com orientação e frequência específicas). Outras transformadas, como a **Transformada de Cossenos (DCT)** e a **Transformada Wavelet (DWT)**, utilizam diferentes famílias de funções de base — cossenos bidimensionais no caso da DCT, e funções com suporte compacto no caso das *wavelets*.

Entre as principais aplicações dessa representação destacam-se:

1. **Filtragem no domínio da frequência**, para atenuar ou realçar determinadas faixas de frequência;
2. **Análise multirresolução por meio de transformadas wavelet**, que representa estruturas em diferentes escalas;
3. **Compressão de imagens**, pela redução do número de coeficientes necessários para representar a imagem.

## 5.1 Objetivos

Ao concluir este capítulo, você será capaz de:

- **Interpretar o espectro de Fourier** de uma imagem, distinguindo magnitude, fase e componentes de frequência;
- **Aplicar o Teorema da Convolução** para realizar filtragem no domínio da frequência utilizando a Transformada Rápida de Fourier (FFT);
- **Projetar e analisar filtros no domínio da frequência**, compreendendo o funcionamento de filtros passa-baixa, passa-alta e *notch*;
- **Compreender a análise multirresolução por transformadas wavelet** e sua aplicação na representação hierárquica de imagens;
- **Descrever o processo de compressão de imagens**, incluindo a Transformada Discreta do Cosseno (DCT) e a quantização dos coeficientes;
- **Selecionar formatos de armazenamento de imagens**, como JPEG, PNG e WebP, de acordo com os requisitos da aplicação.

## 5.2 Configuração do Ambiente

```
import os, importlib, urllib.request
import numpy as np
import matplotlib.pyplot as plt
import cv2

BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph"
for f in ["morph.py"]:
    if not os.path.exists(f):
        urllib.request.urlretrieve(f"{BASE_URL}/{f}", f)

import morph
importlib.reload(morph)
from morph import mm

version = getattr(morph, "__version__", "local_file")
print(f" Ambiente pronto. Módulo 'morph' carregado (versão: {version}).")
```

Ambiente pronto. Módulo 'morph' carregado (versão: 1.1.5).

## 5.3 Transformada de Fourier Discreta 2D

A análise de Fourier baseia-se no princípio de que qualquer sinal periódico pode ser representado como uma soma de funções senoidais com diferentes frequências, amplitudes e fases. Esse conceito também se aplica às imagens digitais, permitindo representá-las no **domínio da frequência** em vez do domínio espacial.

A Figure 5.1 ilustra essa decomposição para um sinal unidimensional. No caso de uma imagem, a Transformada Discreta de Fourier (DFT) converte a matriz de intensidades  $f(x, y)$  em um conjunto de coeficientes que descreve a contribuição das diferentes frequências espaciais presentes na imagem.




Figura 5.1: Decomposição de Fourier 1D: uma onda quadrada (linha tracejada) é aproximada pela soma das primeiras senóides (linhas coloridas). Quanto mais termos, melhor a aproximação.

### 5.3.1 Simulador: Reconstruindo Sinais com Senóides

Antes de estudar imagens bidimensionais, o simulador da Figure 5.2 ilustra o princípio da análise de Fourier para sinais unidimensionais: **uma forma de onda pode ser aproximada pela soma de senóides com diferentes frequências e amplitudes.**



À medida que novos termos são adicionados, a soma das senoides (curva preta) aproxima-se da forma de onda de referência (tracejada). O gráfico inferior apresenta o espectro de amplitudes, indicando a contribuição de cada frequência para a reconstrução do sinal.

#### 💡 Atividade

Explore o simulador e responda:

1. Quantos termos são necessários para obter uma boa aproximação da onda quadrada?
2. Qual das três formas de onda converge mais rapidamente? Justifique sua resposta.
3. Como o espectro de amplitudes se altera ao trocar a onda quadrada pela triangular?

#### i Respostas

##### 1. Quantos termos são necessários para uma boa aproximação da onda quadrada?

Com aproximadamente 15 a 20 termos, a forma da onda já se aproxima bem da referência. Entretanto, próximo às descontinuidades permanece uma pequena oscilação, conhecida como **fenômeno de Gibbs**, que não desaparece mesmo com a adição de mais termos.

##### 2. Qual forma converge mais rapidamente? Por quê?

A **onda triangular** converge mais rapidamente, pois as amplitudes de seus harmônicos decaem mais rápido que as da onda quadrada e da onda dente-de-serra. Como consequência, poucos termos já produzem uma boa aproximação.

##### 3. Como o espectro muda entre a onda quadrada e a triangular?

Ambas possuem apenas **harmônicos ímpares**, mas, na onda triangular, as amplitudes diminuem muito mais rapidamente. Assim, poucos harmônicos são suficientes para reconstruir o sinal com boa precisão.

### 5.3.2 Interpretação do espectro de frequência

Ao aplicar a Transformada Discreta de Fourier (DFT) a uma imagem e visualizar o módulo de seus coeficientes (ver Figure 5.5), obtém-se o **espectro de magnitude**, que mostra a distribuição das frequências espaciais presentes na imagem.

O coeficiente localizado na origem da DFT, denominado **componente DC** (*Direct Current*), corresponde à frequência nula e representa a intensidade média da imagem. Por convenção, esse coeficiente é armazenado no canto superior esquerdo do espectro. Para facilitar sua interpretação, aplica-se a operação **FFT Shift**, que desloca a componente DC para o centro da imagem. Após esse deslocamento, as baixas frequências concentram-se na região central, enquanto as altas frequências ficam próximas às bordas, como resume a Table 5.1.

Tabela 5.1: Correspondência entre as regiões do espectro de magnitude após a aplicação do FFT Shift.

| Região do espectro                               | Componentes predominantes         | Exemplos na imagem                              |
|--------------------------------------------------|-----------------------------------|-------------------------------------------------|
| <b>Centro</b> (baixas frequências)               | Variações espaciais lentas        | Iluminação, regiões homogêneas e formas globais |
| <b>Região intermediária</b> (médias frequências) | Variações de escala intermediária | Texturas e padrões repetitivos                  |
| <b>Bordas</b> (altas frequências)                | Variações espaciais rápidas       | Contornos, detalhes finos e ruído               |

Essa organização facilita a interpretação do espectro e o projeto de filtros. A atenuação das baixas frequências reduz as variações globais de intensidade, enquanto a atenuação das altas frequências suaviza a imagem ao reduzir detalhes finos e parte do ruído.




Figura 5.2: Simulador interativo da decomposição de Fourier 1D: visualização da soma de senoides com diferentes frequências, amplitudes e fases. Adicione termos e observe a convergência para formas de onda arbitrárias.

### 5.3.3 O Experimento da Grade: Construindo uma Imagem a partir de um Único Coeficiente

Antes de apresentar a formulação matemática da Transformada Discreta de Fourier (DFT), é útil analisar sua inversa, denominada Transformada Discreta Inversa de Fourier (IDFT). Considere um espectro em que todos os coeficientes sejam nulos, exceto um. Um exemplo dessa construção é apresentado no código da Figure 5.3 e pode ser explorado interativamente no simulador da Figure 5.4.

A imagem reconstruída é uma senoide bidimensional. A posição do coeficiente no espectro determina sua **orientação** e sua **frequência espacial**, enquanto sua magnitude e sua fase definem, respectivamente, sua amplitude e seu deslocamento espacial. Assim, cada coeficiente da DFT representa uma componente senoidal, e a imagem original pode ser reconstruída pela soma de todas essas componentes.

```
N_grid = 100
espectro_vazio = np.zeros((N_grid, N_grid), dtype=complex)

# Acendendo um único ponto (frequência) fora do centro
u0, v0 = 10, 5
espectro_vazio[N_grid//2 - v0, N_grid//2 - u0] = 1000

# Retornando para o domínio espacial (IDFT)
onda_2d = np.real(np.fft.ifft2(np.fft.ifftshift(espectro_vazio)))

onda_vis = cv2.normalize(onda_2d, None, 0, 255, cv2.NORM_MINMAX).astype(np.uint8)
espectro_vis = cv2.normalize(
    np.abs(espectro_vazio), None, 0, 255, cv2.NORM_MINMAX).astype(np.uint8)

# Destaque visual do ponto
espectro_color = cv2.cvtColor(espectro_vis, cv2.COLOR_GRAY2BGR)
cv2.circle(espectro_color, (N_grid//2 - u0, N_grid//2 - v0), 2, (0, 0, 255), -1)

mm.show([espectro_color, onda_vis],
        titles=["Espectro (1 ponto ativo)", "Onda 2D Resultante (IDFT)"],
        cols=2, figsize=(10, 4))
```




Figura 5.3: Toda frequência no espectro (ponto isolado) corresponde a uma onda senoidal 2D rotacionada no domínio espacial.




Figura 5.4: Simulador interativo da síntese de Fourier 2D. Altere a posição horizontal ( $u$ ) e vertical ( $v$ ) do coeficiente no espectro de frequências centrado e observe como a distância em relação ao centro dita a frequência espacial (espessura) e o ângulo dita a orientação da onda senoidal gerada.

### 5.3.4 Definição Matemática

Considere uma imagem  $f(x, y)$  com dimensões  $M \times N$ . Sua **Transformada Discreta de Fourier 2D** (DFT) é definida por:

$$F(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) e^{-j2\pi(\frac{ux}{M} + \frac{vy}{N})} \quad (5.1)$$

em que  $u = 0, 1, \dots, M-1$  e  $v = 0, 1, \dots, N-1$  representam as frequências discretas nas direções horizontal e vertical, respectivamente. O termo exponencial corresponde a uma senoide bidimensional, cuja frequência e orientação são determinadas pelos índices  $(u, v)$ .

A **Transformada Discreta Inversa de Fourier 2D** (IDFT) reconstrói a imagem original a partir de seus coeficientes:

$$f(x, y) = \frac{1}{MN} \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} F(u, v) e^{j2\pi(\frac{ux}{M} + \frac{vy}{N})} \quad (5.2)$$

As Equações Equation 5.1 e Equation 5.2 mostram que a DFT e a IDFT formam um par de transformações: a primeira converte a imagem para o domínio da frequência, enquanto a segunda reconstrói exatamente a imagem original a partir de seus coeficientes.

### **i** Sobre o símbolo $j$

O termo  $j$  denota a **unidade imaginária**, definida por  $j^2 = -1$ . Em engenharia e processamento de sinais, adota-se  $j$  em vez de  $i$  para evitar conflito com a notação de corrente elétrica. Sua utilização na exponencial complexa, regida pela fórmula de Euler ( $e^{j\theta} = \cos \theta + j \sin \theta$ ), permite representar de forma compacta a amplitude e a fase de cada frequência espacial presente na imagem.

### **i** O que é o componente DC?

O coeficiente  $F(0,0)$ , denominado **componente DC** (*Direct Current*), é igual à soma das intensidades de todos os pixels da imagem (ver Figure 5.5):

$$F(0,0) = MN \bar{f},$$

em que  $\bar{f}$  é a intensidade média da imagem. Por isso, o componente DC representa o nível médio de intensidade e, na maioria das imagens naturais, possui a maior magnitude do espectro.

Os demais coeficientes representam variações em torno dessa média. Após a aplicação do **FFT Shift**, o componente DC é deslocado para o centro do espectro, concentrando as baixas frequências na região central e as altas frequências nas bordas.



Figura 5.5: Diagrama conceitual do espectro de Fourier 2D centrado.

### 5.3.5 Magnitude e Fase

Cada coeficiente da Transformada Discreta de Fourier (DFT) é um número complexo e pode ser escrito como

$$F(u,v) = R(u,v) + jI(u,v),$$

em que  $R(u,v)$  e  $I(u,v)$  correspondem, respectivamente, às partes **real** e **imaginária** do coeficiente. Da Equação Equation 5.1, obtêm-se

$$R(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) \cos\left(2\pi \left(\frac{ux}{M} + \frac{vy}{N}\right)\right),$$

e

$$I(u, v) = - \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) \sin\left(2\pi \left(\frac{ux}{M} + \frac{vy}{N}\right)\right).$$

A partir dessa representação, definem-se duas grandezas fundamentais:

- **Magnitude**, que indica a intensidade da componente de frequência,

$$|F(u, v)| = \sqrt{R(u, v)^2 + I(u, v)^2};$$

- **Fase**, que determina o alinhamento (ou deslocamento) espacial da componente,

$$\phi(u, v) = \text{atan2}(I(u, v), R(u, v)).$$

Assim, cada coeficiente também pode ser escrito em sua forma polar,

$$F(u, v) = |F(u, v)| e^{j\phi(u, v)}.$$

O espectro de Fourier pode, portanto, ser visualizado por meio de duas imagens distintas: o **espectro de magnitude**, normalmente utilizado para analisar a distribuição das frequências, e o **espectro de fase**, que descreve a organização espacial das componentes senoidais.

Embora o espectro de magnitude seja o mais utilizado para inspeção visual, a fase contém grande parte das informações estruturais da imagem. A combinação de magnitude e fase permite reconstruir exatamente a imagem original por meio da IDFT.

### 5.3.6 O que a Magnitude e a Fase carregam?

Uma demonstração clássica consiste em combinar a magnitude de uma imagem com a fase de outra e reconstruir o resultado. Esse experimento evidencia que:

- **A fase** preserva a estrutura espacial da imagem, incluindo a posição dos objetos, seus contornos e sua geometria. Pequenas alterações na fase podem provocar grandes mudanças visuais.
- **A magnitude** controla como a energia é distribuída entre as frequências espaciais, influenciando principalmente o contraste e a textura.

Quando uma imagem é reconstruída com a magnitude de A e a fase de B, o resultado tende a **assemelhar-se mais a B do que a A**, evidenciando que a fase é o principal componente responsável pela organização espacial da cena. Entretanto, a magnitude continua sendo importante, pois modula o contraste das estruturas reconstruídas. Assim, uma reconstrução fiel depende da combinação consistente entre magnitude e fase.

Um exemplo desse comportamento é apresentado na Figure 5.6.

#### **i** Analogia com Áudio: Limitações e Cuidados

A fase de um sinal desempenha papéis distintos em áudio e imagens:

- **Áudio estéreo ou multicanal:** a fase relativa entre os canais é fundamental para a percepção da posição das fontes sonoras, por meio das diferenças interaurais de tempo (ITD, *Interaural Time Differences*).
- **Áudio monaural:** a fase absoluta exerce pouca influência perceptual direta.

- **Imagens (DFT):** a fase é o principal fator responsável pela organização espacial da cena, enquanto a magnitude modula o contraste e a distribuição da energia entre as frequências.

Em ambos os domínios, a **magnitude** está relacionada à intensidade das componentes de frequência: em áudio, influencia o timbre e a intensidade percebida; em imagens, influencia o contraste e a textura.

```
# Experimento: A Importância da Fase
# Carregamento da imagem
url      = "https://upload.wikimedia.org/wikipedia/commons/2/25/GAZI.MD.AHAD_11.jpg"
caminho  = "imagens/coins.jpg"

if not os.path.exists(caminho):
    os.makedirs("imagens", exist_ok=True)
    img_obj = mm.read(url, pil=True)
    mm.write(img_obj, caminho)
else:
    img_obj = mm.read(caminho, pil=True)

img_color = np.array(img_obj)
img_gray  = mm.gray(img_color)

img_a = cv2.resize(img_gray, (400, 400))

# Criar uma imagem B sintética (padrão geométrico)
img_b = np.zeros((400, 400), dtype=np.uint8)
cv2.rectangle(img_b, (100, 100), (300, 300), 255, -1)
cv2.circle(img_b, (200, 200), 150, 128, 10)

FA = np.fft.fft2(img_a)
FB = np.fft.fft2(img_b)

# Troca de Fase
rec_A_mag_B_fase = np.real(np.fft.ifft2(np.abs(FA) * np.exp(1j * np.angle(FB))))
rec_B_mag_A_fase = np.real(np.fft.ifft2(np.abs(FB) * np.exp(1j * np.angle(FA))))

mm.show(
    [img_a, img_b, rec_A_mag_B_fase, rec_B_mag_A_fase],
    titles=["Imagem A", "Imagem B", "Mag(A) + Fase(B)", "Mag(B) + Fase(A)"],
    cols=4, figsize=(16, 4)
)

print(" A fase preserva bordas e contornos; a magnitude controla contraste e")
print("textura. Em áudio estéreo, a fase afeta a localização espacial; em")
print("imagens, determina a organização da cena.")
```






Figura 5.6: Experimento de troca de fase: Imagem A (moedas) e Imagem B (padrão geométrico) reconstruídas com magnitudes e fases trocadas. O resultado mostra que a estrutura visual é **muito mais sensível à fase** do que à magnitude: quando a fase de B é mantida, a imagem resultante preserva a organização espacial de B, mesmo com a magnitude de A. A magnitude, por sua vez, influencia principalmente o contraste e a textura. Observe que a qualidade da reconstrução não é perfeita — há artefatos visíveis —, evidenciando a interdependência entre fase e magnitude para uma representação fiel da imagem.

A fase preserva bordas e contornos; a magnitude controla contraste e textura. Em áudio estéreo, a fase afeta a localização espacial; em imagens, determina a organização da cena.

## 5.4 Teorema da Convolução e Estratégias de Filtragem

O **Teorema da Convolução** estabelece uma relação fundamental entre os domínios espacial e da frequência:

$$f(x, y) \otimes h(x, y) \xleftrightarrow{\mathcal{F}} F(u, v) H(u, v) \quad (5.3)$$

em que  $\otimes$  representa a **convolução circular discreta**. Assim, a convolução entre uma imagem  $f(x, y)$  e um filtro  $h(x, y)$  pode ser substituída pela multiplicação de seus espectros.

Na prática, para obter o mesmo resultado da convolução linear realizada no domínio espacial, aplica-se **zero-padding** antes da Transformada Rápida de Fourier (FFT), evitando artefatos nas bordas da imagem.

Entretanto, nem sempre a filtragem no domínio da frequência é a alternativa mais eficiente. Para filtros como o Gaussiano e o filtro da média (*Box Filter*), a propriedade de **separabilidade** permite reduzir significativamente o custo computacional da convolução no domínio espacial.

### 5.4.1 Kernel Separável vs. Não Separável

Um **kernel separável** pode ser escrito como o produto externo de dois vetores unidimensionais,

$$H = v h^T,$$

permitindo que a convolução bidimensional seja substituída por duas convoluções unidimensionais consecutivas: uma na direção horizontal e outra na vertical.

Já um **kernel não separável** não admite essa decomposição e, portanto, sua convolução deve ser realizada diretamente sobre a vizinhança bidimensional.

Na prática, para um *kernel* de dimensão  $K \times K$ , a convolução direta exige  $K^2$  multiplicações por pixel, enquanto um *kernel* separável requer apenas  $2K$  multiplicações, reduzindo significativamente o custo computacional.

### 5.4.2 Análise de Eficiência Computacional

Considere uma imagem de dimensões  $M \times N$  e um filtro quadrado de tamanho  $K \times K$ . A Table 5.2 compara a complexidade das principais estratégias de filtragem.

Tabela 5.2: Comparação da complexidade da convolução direta, separável e via Transformada Rápida de Fourier (FFT).

| Método de Filtragem           | Complexidade Assintótica   | Dependência de $K$  | Aplicação típica                         |
|-------------------------------|----------------------------|---------------------|------------------------------------------|
| <b>Espacial não separável</b> | $\mathcal{O}(MNK^2)$       | Quadrática          | <i>Kernels</i> pequenos e não separáveis |
| <b>Espacial separável</b>     | $\mathcal{O}(MNK)$         | Linear              | Filtros Gaussiano e da média             |
| <b>Via FFT</b>                | $\mathcal{O}(MN \log(MN))$ | Independente de $K$ | <i>Kernels</i> grandes                   |

Para *kernels* pequenos, a convolução espacial, especialmente quando o filtro é separável, costuma ser mais eficiente devido ao baixo custo das operações. À medida que o tamanho do *kernel* aumenta, a filtragem via FFT torna-se mais vantajosa, pois seu custo praticamente independe da dimensão do filtro.

### 5.4.3 Discussão dos resultados experimentais

O gráfico obtido no ensaio com a imagem das moedas ( $2560 \times 1920$ ), apresentado na Figure 5.7, confirma o comportamento previsto pela análise de complexidade computacional.

#### 1. Convolução não separável ( $\mathcal{O}(MNK^2)$ )

A convolução direta apresenta crescimento quadrático com o tamanho do *kernel*. Para valores pequenos de  $K$ , o custo é baixo, mas aumenta rapidamente à medida que o *kernel* cresce, tornando-se inviável para aplicações em tempo real.

#### 2. Filtragem via FFT ( $\mathcal{O}(MN \log(MN))$ )

O custo da FFT depende apenas do tamanho da imagem, sendo independente de  $K$ . Por isso, seu desempenho permanece aproximadamente constante ao variar o *kernel*, tornando-a vantajosa para filtros grandes ou não separáveis.

#### 3. Convolução separável ( $\mathcal{O}(MNK)$ )

A decomposição do *kernel* em dois filtros unidimensionais reduz significativamente o custo computacional. Na prática, essa abordagem tende a ser a mais eficiente para filtros separáveis, especialmente em implementações otimizadas.

Em geral, a escolha do método depende do tamanho e da estrutura do *kernel*. Filtros separáveis são mais eficientes no domínio espacial, enquanto a FFT se torna mais vantajosa para *kernels* grandes ou múltiplas convoluções no domínio da frequência.

$$g = \mathcal{F}^{-1}[\mathcal{F}(f) \cdot \mathcal{F}(h)] \quad (\text{FFT}) \quad g = f \circledast h \quad (\text{convolução direta}) \quad g = (f \circledast v) \circledast h^T \quad (\text{separável}) \quad (5.4)$$

onde:

- $f(x, y)$  representa a imagem de entrada;
- $h(x, y)$  é o *kernel* bidimensional do filtro;
- $v$  e  $h^T$  são, respectivamente, os vetores vertical e horizontal que compõem o *kernel* separável.




Figura 5.7: Comparação de eficiência: Convolução Não Separável (Espacial 2D), Separável (Espacial 1D) e via FFT.

### ! O problema da convolução circular (*wrap-around*)

A Transformada Discreta de Fourier (DFT) assume que a imagem é **periodicamente estendida no espaço**, isto é, que suas bordas se repetem indefinidamente.

Nessa condição, a multiplicação no domínio da frequência corresponde a uma **convolução circular** no domínio espacial. Como consequência, regiões opostas da imagem (topo e base, esquerda e direita) passam a interagir artificialmente, conforme ilustrado na Figure 5.8.

A aplicação de *zero-padding* antes da FFT reduz esse efeito ao estender a imagem com valores nulos nas bordas, aproximando o resultado da convolução linear. Esse comportamento pode ser interpretado à luz do Teorema da Convolução, apresentado na Figure 5.9.

```
# Definir M e N
M, N = img_gray.shape # linha adicionada

# Simulação de um filtro de deslocamento brutal
H_shift = np.zeros_like(img_gray, dtype=complex)
for u in range(M):
    for v in range(N):
        H_shift[u, v] = np.exp(-1j * 2 * np.pi * (u*120/M + v*120/N))

# Filtragem SEM padding (causa o wrap-around)
F_img = np.fft.fft2(img_gray)
img_vazada = np.real(np.fft.ifft2(F_img * H_shift))

img_vazada_vis = cv2.normalize(img_vazada, None, 0, 255, cv2.NORM_MINMAX).astype(np.uint8)
mm.show([img_gray, img_vazada_vis],
        titles=["Original", "Filtragem s/ Padding (Vazamento)"], cols=2, figsize=(10, 4))
```



Figura 5.8: Sem *padding*, um deslocamento severo faz a imagem vazar para o lado oposto (convolução circular).

```
# Kernel Gaussiano 11x11
sigma = 3.0
K = 11
ks = np.arange(K) - K // 2
gauss1d = np.exp(-ks**2 / (2 * sigma**2))
gauss1d /= gauss1d.sum()
kernel = np.outer(gauss1d, gauss1d) # kernel 2D separável

# Método 1: Convolução espacial direta
f_float = img_gray.astype(np.float64)
conv_esp = cv2.filter2D(f_float, -1, kernel, borderType=cv2.BORDER_CONSTANT)

# Método 2: Multiplicação em frequência (via FFT)
M, N = f_float.shape
# Padding para convolução linear (evita aliasing circular)
Mpad = 2 ** int(np.ceil(np.log2(M + K - 1)))
Npad = 2 ** int(np.ceil(np.log2(N + K - 1)))

# Posiciona o kernel com a origem no (0,0) e padding com zeros
kernel_pad = np.zeros((Mpad, Npad))
kh, kw = kernel.shape
kernel_pad[kh:kh+kw, :kw] = kernel

F_img = np.fft.fft2(f_float, (Mpad, Npad))
F_kern = np.fft.fft2(kernel_pad)
conv_freq = np.real(np.fft.ifft2(F_img * F_kern))

# Recorte para compensar o deslocamento introduído pelo posicionamento do kernel
offset = K // 2
conv_freq_crop = conv_freq[offset:offset+M, offset:offset+N]

# Verificação numérica
```

```

diff = np.abs(conv_esp - conv_freq_crop)
print(f"Diferença máxima (|conv_esp - conv_freq|): {diff.max():.2e}")
print(f"Diferença média (|conv_esp - conv_freq|): {diff.mean():.2e}")
print(f"→ Teorema da Convolução verificado numericamente.")

conv_esp_vis = cv2.normalize(conv_esp, None, 0, 255, cv2.NORM_MINMAX).astype(np.uint8)
conv_freq_vis = cv2.normalize(conv_freq_crop, None, 0, 255, cv2.NORM_MINMAX).astype(np.uint8)
diff_vis = cv2.normalize(diff, None, 0, 255, cv2.NORM_MINMAX).astype(np.uint8)

mm.show(
    [img_gray, conv_esp_vis, conv_freq_vis, diff_vis],
    titles=[
        "Original",
        "Convolução espacial",
        "Multiplicação em frequência",
        f"Diferença (máx={diff.max():.1e})"
    ],
    cols=4, figsize=(16, 5)
)

```

Diferença máxima (|conv\_esp - conv\_freq|): 2.56e-13  
 Diferença média (|conv\_esp - conv\_freq|): 2.76e-14  
 → Teorema da Convolução verificado numericamente.



Figura 5.9: Verificação do Teorema da Convolução: a diferença pixel a pixel entre a convolução espacial (`cv2.filter2D`) e a multiplicação em frequência (FFT) é numericamente nula — confirmando a equivalência teórica.

### **i** Sobre a diferença numérica

A diferença residual da ordem de  $10^{-13}$  não viola o Teorema da Convolução, mas reflete **limitações computacionais** inerentes à aritmética de ponto flutuante (precisão dupla,  $\sim 10^{-16}$ ) e à **ordem de operações** entre os dois métodos:

- **Convolução espacial:** soma ponderada de vizinhos com arredondamentos sucessivos.
- **Convolução em frequência:** envolve três transformadas FFT e uma multiplicação complexa, sujeita a erros de truncamento e quantização.

Portanto, a igualdade teórica é exata, mas a implementação numérica produz uma diferença praticamente nula (erro relativo  $< 10^{-12}$ ), confirmando o teorema dentro da precisão da máquina.



## 5.5 Filtros no Domínio da Frequência

Um filtro no domínio da frequência pode ser interpretado como uma **função de transferência aplicada ao espectro da imagem**. Nessa representação, cada coeficiente de frequência é multiplicado por um valor entre 0 e 1, que determina sua atenuação ou preservação. A forma dessa função define o efeito visual do filtro.

**Corte abrupto e *ringing*.** Filtros ideais com transição instantânea em uma frequência de corte  $D_0$  produzem discontinuidades no domínio da frequência. Essa discontinuidade se reflete no domínio espacial como oscilações próximas a bordas, conhecidas como *ringing*. Esse efeito está associado à convolução com funções de suporte infinito no espaço, como a função *sinc*, conforme ilustrado na Figure 5.10.

**Filtros com transição suave.** Alternativas como os filtros Gaussiano e Butterworth suavizam a transição entre regiões de passagem e rejeição, reduzindo o *ringing*. Em contrapartida, essa suavização implica uma fronteira de separação menos definida entre frequências preservadas e atenuadas.

```
# Simulando o Filtro Ideal na Frequência (Cilindro) e sua representação Espacial (Sinc)
N_grid = 2**7
u = np.arange(-N_grid//2, N_grid//2)
U, V = np.meshgrid(u, u)
D = np.sqrt(U**2 + V**2)


# Frequência: Cilindro Ideal (1 no centro, 0 fora do raio 20)
H_freq = np.zeros((N_grid, N_grid))
H_freq[D <= 20] = 1

# Espaço: A inversa resulta na famigerada Sinc 2D
h_space = np.fft.fftshift(np.real(np.fft.ifft2(np.fft.ifftshift(H_freq))))

fig, ax = plt.subplots(1, 2, subplot_kw={'projection': '3d'}, figsize=(12, 4))
ax[0].plot_surface(U, V, H_freq, cmap='viridis', edgecolor='none')
ax[0].set_title("Frequência: Filtro Ideal (Cilindro)")
ax[0].set_zlim(0, 1.2)

ax[1].plot_surface(U, V, h_space, cmap='plasma', edgecolor='none')
ax[1].set_title("Espaço Real: Ondulações da Sinc (Causa do Ringing)")
plt.tight_layout(); plt.show()
```

Frequência: Filtro Ideal (Cilindro)



Espaço Real: Ondulações da Sinc (Causa do Ringing)




Figura 5.10: A Dualidade Perigosa: O corte abrupto na Frequência (Cilindro) transforma-se obrigatoriamente numa Sinc espacial. Suas ondulações causam o *ringing* fantasma nas bordas da imagem.

### 5.5.1 Filtros Passa-Baixa

Filtros passa-baixa atenuam componentes de alta frequência, resultando em suavização da imagem e redução de ruído. Após a centralização do espectro (FFT Shift), a distância de cada ponto ao centro é dada por:

$$D(u, v) = \sqrt{\left(u - \frac{M}{2}\right)^2 + \left(v - \frac{N}{2}\right)^2} \quad (5.5)$$

**Filtro Ideal (LPFI):**

$$H_{\text{ideal}}(u, v) = \begin{cases} 1, & D(u, v) \leq D_0 \\ 0, & D(u, v) > D_0 \end{cases} \quad (5.6)$$

O corte abrupto em  $D_0$  introduz descontinuidades no domínio da frequência, resultando em oscilações no domínio espacial conhecidas como *ringing*. Esse efeito está associado à convolução com funções de suporte infinito.

**Filtro Gaussiano (LPFG):**

$$H_{\text{gauss}}(u, v) = e^{-D^2(u, v)/(2\sigma^2)} \quad (5.7)$$

A suavidade da função Gaussiana no domínio da frequência evita descontinuidades, o que elimina o *ringing* e produz uma transição gradual entre frequências preservadas e atenuadas.

**Filtro Butterworth (LPFB) de ordem  $n$ :**

$$H_{\text{BW}}(u, v) = \frac{1}{1 + [D(u, v)/D_0]^{2n}} \quad (5.8)$$

O parâmetro  $n$  controla a suavidade da transição entre passagem e rejeição de frequências. Valores pequenos produzem transições suaves, enquanto valores grandes aproximam o comportamento do filtro ideal, com maior risco de *ringing*. Um exemplo comparativo é apresentado na Figure 5.11.




Figura 5.11: Filtros passa-baixa.

### 5.5.2 Filtros Passa-Alta e Passa-Banda

**Filtros passa-alta** podem ser obtidos a partir de um filtro passa-baixa complementar, definido como:

$$H_{\text{HP}}(u, v) = 1 - H_{\text{LP}}(u, v)$$

Esse tipo de filtro preserva componentes de alta frequência, realçando bordas e detalhes, enquanto atenua regiões de variação suave.



**Filtros passa-banda** preservam apenas uma faixa intermediária de frequências, limitada por dois raios  $D_L$  e  $D_H$ :

$$H_{BP}(u, v) = H_{LP}^{(D_H)}(u, v) \cdot [1 - H_{LP}^{(D_L)}(u, v)]$$

Esse tipo de filtragem é útil quando se deseja remover simultaneamente componentes de baixa e alta frequência, preservando apenas estruturas de escala intermediária.

Uma aplicação importante é a remoção de **ruído periódico**, no qual padrões regulares aparecem como picos localizados no espectro de magnitude. Esses picos podem ser atenuados por meio de filtros *notch* (rejeita-banda), posicionados especificamente nas frequências indesejadas.

Exemplos de filtros no domínio da frequência são apresentados no simulador da Figure 5.12, Figure 5.13 e Figure 5.14.



Figura 5.12: Simulador interativo de filtros no domínio da frequência.

```
import io

def distancia_centro(M, N):
    """Matriz de distâncias ao centro do espectro."""
    u = np.arange(M) - M // 2
    v = np.arange(N) - N // 2
    V, U = np.meshgrid(v, u)
    return np.sqrt(U**2 + V**2)
```

```

def aplicar_filtro_freq(img, H):
    """Aplica filtro H (centrado) a imagem via FFT."""
    F = np.fft.fftshift(np.fft.fft2(img.astype(np.float64)))
    Fg = F * H
    g = np.real(np.fft.ifft2(np.fft.ifftshift(Fg)))
    return cv2.normalize(g, None, 0, 255, cv2.NORM_MINMAX).astype(np.uint8)

M, N = img_gray.shape
D = distancia_centro(M, N)
D0 = 30 # frequência de corte
n_bw = 2 # ordem do Butterworth

# Funções de transferência
H_ideal = (D <= D0).astype(np.float64)
H_gauss = np.exp(-D**2 / (2 * D0**2))
H_bw = 1.0 / (1.0 + (D / D0)**(2 * n_bw))

# Imagens filtradas
img_ideal = aplicar_filtro_freq(img_gray, H_ideal)
img_gauss = aplicar_filtro_freq(img_gray, H_gauss)
img_bw = aplicar_filtro_freq(img_gray, H_bw)

# Perfis de H(u,v)
def fig2img(fig):
    b = io.BytesIO(); fig.savefig(b, format='png', dpi=100); plt.close(fig); b.seek(0)
    return (plt.imread(b)[:,:,:3]*255).astype(np.uint8)

fig, ax = plt.subplots(figsize=(6, 3))
linha = M // 2
ax.plot(H_ideal[linha, :], label="Ideal", color="#D85A30", lw=1.5, ls="--")
ax.plot(H_gauss[linha, :], label="Gaussiano", color="#1D9E75", lw=1.5)
ax.plot(H_bw[linha, :], label="Butterworth", color="#534AB7", lw=1.5)
ax.axvline(N//2-D0, color="#aaa", lw=0.8, ls=":")
ax.axvline(N//2+D0, color="#aaa", lw=0.8, ls=":")
ax.set(title="Perfis H(u,v) - linha central", xlabel="v", ylabel="H(u,v)")
ax.legend(fontsize=8); plt.tight_layout()
perfil_img = fig2img(fig)

# Filtros H visualizados
def H_vis(H):
    return cv2.normalize((H*255).astype(np.uint8), None, 0, 255, cv2.NORM_MINMAX)

mm.show(
    [img_gray, img_ideal, img_gauss, img_bw,
     H_vis(H_ideal), H_vis(H_gauss), H_vis(H_bw), perfil_img],
    titles=[
        "Original", "LPF Ideal", "LPF Gaussiano", "LPF Butterworth (n=2)",
        "H Ideal", "H Gaussiano", "H Butterworth", "Perfis H(u,v)"
    ],
    cols=4, figsize=(16, 9)
)

```




Figura 5.13: Comparação entre filtros passa-baixa: Ideal ( $D = 30$ ), Gaussiano ( $D = 30$ ) e Butterworth ( $D = 30$ ,  $n=2$ ). Perfis de  $H(u,v)$  ao longo de uma linha central e imagens filtradas correspondentes.

```
# Filtro passa-alta: complemento do passa-baixa Gaussiano
# Reutiliza aplicar_filtro_freq() definida na célula anterior
H_alta = 1 - H_gauss
img_alta = aplicar_filtro_freq(img_gray, H_alta)

mm.show(
    [img_gray, img_alta],
    titles=["Original", "Passa-alta Gaussiano ( $D_0=30$ )"],
    cols=2
)
```




Figura 5.14: Filtro passa-alta Gaussiano. (a) Original; (b) Filtro passa-alta ( $D = 30$ ) - as bordas das moedas e fundo texturizado são realçados.

### 5.5.3 Remoção de Ruído Periódico

Ruído periódico — associado a interferências elétricas, padrões regulares de sensores ou artefatos de digitalização — aparece no espectro de Fourier como **picos pontuais simétricos em torno do centro**.

O filtro **rejeita-banda** (*notch*) atenua seletivamente essas frequências, preservando as demais componentes da imagem. Um exemplo de aplicação é apresentado na Figure 5.15.

```
# Imagem com ruído periódico sintético
h_img, w_img = img_gray.shape
x = np.arange(w_img)
y = np.arange(h_img)
X, Y = np.meshgrid(x, y)

# Usar frequências inteiras e consistentes (importante para restauração perfeita)
u0, v0 = 20, 20 # frequências exatas do ruído

ruído = 40 * np.sin(2 * np.pi * (u0 * X / w_img + v0 * Y / h_img))
img_ruidosa = np.clip(img_gray.astype(np.float64) + ruído, 0, 255).astype(np.uint8)

# Espectro da imagem ruidosa
F_r = np.fft.fftshift(np.fft.fft2(img_ruidosa.astype(np.float64)))
mag_r = np.log1p(np.abs(F_r))
mag_vis = cv2.normalize(mag_r, None, 0, 255, cv2.NORM_MINMAX).astype(np.uint8)

# Máscara notch
mascara = np.ones((h_img, w_img), dtype=np.float64)
r_notch = 8 # raio do notch (ajuste fino se necessário)

def suprimir_pico(mask, cy, cx, r):
```

```

"""Zera um disco de raio r centrado em (cy, cx)"""
yy, xx = np.ogrid[:mask.shape[0], :mask.shape[1]]
dist = np.sqrt((yy - cy)**2 + (xx - cx)**2)
mask[dist <= r] = 0
return mask

# Coordenadas centrais
cy, cx = h_img // 2, w_img // 2

# Suprimir os 4 picos simétricos (importante!)
for dy, dx in [(v0, u0), (-v0, -u0), (v0, -u0), (-v0, u0)]:
    mascara = suprimir_pico(mascara, cy + dy, cx + dx, r_notch)

mascara_vis = (mascara * 255).astype(np.uint8)

# Filtragem e reconstrução
F_filtrada = F_r * mascara
img_rest = np.real(np.fft.ifft2(np.fft.ifftshift(F_filtrada)))
img_rest_vis = cv2.normalize(img_rest, None, 0, 255, cv2.NORM_MINMAX).astype(np.uint8)

# Avaliação
psnr = cv2.PSNR(img_gray, img_rest_vis)
ssim = cv2.SSIM(img_gray, img_rest_vis) if hasattr(cv2, 'SSIM') else "N/A"
#ssim = ssim_sk(img_gray, img_rest_vis, data_range=255)

print(f"PSNR (original vs restaurada): {psnr:.2f} dB")

# Visualização
mm.show(
    [img_ruidosa, mag_vis, mascara_vis, img_rest_vis],
    titles=[
        "Com ruído periódico",
        "Espectro (log)",
        "Máscara notch",
        f"Restaurada (PSNR={psnr:.1f} dB)"
    ],
    cols=4,
    figsize=(16, 4)
)

```

PSNR (original vs restaurada): 32.93 dB




Figura 5.15: Remoção de ruído periódico via filtro *notch* no domínio da frequência: (a) imagem com ruído senoidal, (b) espectro mostrando os picos do ruído, (c) máscara *notch* centrada nos picos, (d) imagem restaurada.

## Síntese — Filtros Espectrais

| Filtro                  | Efeito visual                   | Artefato                      | Uso                                         |
|-------------------------|---------------------------------|-------------------------------|---------------------------------------------|
| Passa-baixa ideal       | Suavização intensa              | <i>Ringing</i>                | Ilustrativo                                 |
| Passa-baixa Gaussiano   | Suavização suave                | Não apresenta <i>ringing</i>  | Suavização geral                            |
| Passa-baixa Butterworth | Suavização controlada           | <i>Ringing</i> (ordens altas) | Compromisso entre suavização e seletividade |
| Passa-alta              | Realce de bordas                | Amplificação de ruído         | Deteção de contornos                        |
| <i>Notch</i>            | Remoção seletiva de frequências | Possíveis distorções locais   | Remoção de ruído periódico                  |

O projeto de filtros no domínio da frequência consiste na definição de máscaras espectrais. Entretanto, efeitos no domínio espacial, como *ringing* e borramento, emergem diretamente dessas escolhas no espectro.

## 5.6 Wavelets e Multirresolução

A Transformada de Fourier decompõe o sinal em frequências **globais**: cada coeficiente  $F(u, v)$  recebe contribuições de toda a imagem, sem informação explícita sobre a localização espacial dessas frequências. Assim, estruturas localizadas, como bordas, são representadas de forma distribuída no espectro.

As **wavelets (ondaletas)** superam essa limitação ao utilizar funções base **localizadas no espaço**, que podem ser deslocadas e escaladas. Essas funções possuem **suporte compacto**, isto é, são diferentes de zero apenas em uma região finita do domínio, permitindo uma representação simultânea em termos de **frequência e localização espacial**.

### 5.6.1 O Limite da Transformada de Fourier: localização espacial

A Transformada de Fourier descreve com precisão **quais frequências estão presentes** em um sinal, mas não representa explicitamente **onde essas frequências ocorrem no espaço**.

No experimento apresentado na Figure 5.16, duas imagens com estruturas localizadas em posições diferentes produzem espectros de magnitude praticamente idênticos. Isso ocorre porque a representação de Fourier é global: cada coeficiente recebe contribuição de toda a imagem.

Como consequência, o espectro de magnitude não representa explicitamente a localização de bordas ou outras estruturas, apenas a distribuição das frequências presentes. Essa limitação motivou o desenvolvimento de representações multirresolução, como a Transformada *Wavelet* Discreta (DWT), capazes de descrever simultaneamente a frequência e a localização espacial das estruturas da imagem.

```
img_sinal1 = np.zeros((128, 128)); img_sinal1[:, 20:25] = 1; img_sinal1[100:105, :] = 1
img_sinal2 = np.zeros((128, 128)); img_sinal2[:, 90:95] = 1; img_sinal2[30:35, :] = 1

mag1 = np.log1p(np.abs(np.fft.fftshift(np.fft.fft2(img_sinal1))))
mag2 = np.log1p(np.abs(np.fft.fftshift(np.fft.fft2(img_sinal2))))

mm.show([img_sinal1, mag1, img_sinal2, mag2],
         titles=["Sinal A", "Espectro A", "Sinal B (Deslocado)", "Espectro B"],
         cols=4, figsize=(14, 4))
```






Figura 5.16: Fourier global é cego para a posição. Os espectros não dizem onde as bordas estão.

### 5.6.2 Transformada *Wavelet* Discreta 2D

A Transformada *Wavelet* Discreta (DWT) aplica, separadamente nas direções horizontal e vertical, dois filtros complementares: um **passa-baixa**  $h$  (aproximação) e um **passa-alta**  $g$  (detalhes), seguidos de subamostragem por um fator de 2 em cada dimensão. Esse processo produz quatro subbandas, cujos nomes indicam a combinação dos filtros aplicados em cada direção (L = *Low-pass*, passa-baixa; H = *High-pass*, passa-alta). As características de cada subbanda são resumidas na Table 5.3.

$$\text{DWT}(f) = \left\{ \underbrace{\text{LL}}_{\text{aprox.}}, \underbrace{\text{LH}}_{\text{detalhes horizontais}}, \underbrace{\text{HL}}_{\text{detalhes verticais}}, \underbrace{\text{HH}}_{\text{detalhes diagonais}} \right\}.$$

Tabela 5.3: Subbandas produzidas pela Transformada *Wavelet* Discreta 2D (DWT), indicando os filtros aplicados em cada direção e o conteúdo predominante de cada componente.

| Subbanda  | Filtros aplicados    | Conteúdo visual                                     |
|-----------|----------------------|-----------------------------------------------------|
| <b>LL</b> | baixa $\times$ baixa | Aproximação da imagem (versão suavizada e reduzida) |
| <b>LH</b> | baixa $\times$ alta  | Bordas horizontais e variações verticais            |
| <b>HL</b> | alta $\times$ baixa  | Bordas verticais e variações horizontais            |
| <b>HH</b> | alta $\times$ alta   | Detalhes diagonais e texturas                       |

A decomposição pode ser aplicada recursivamente sobre a subbanda LL, gerando uma representação multirresolução. Após  $J$  níveis, obtém-se uma estrutura com  $3J + 1$  subbandas, em que cada novo nível reduz a resolução da componente de aproximação.

#### **i** Conexão com CNNs

A decomposição multirresolução das *wavelets* possui uma relação conceitual com as representações hierárquicas utilizadas em redes neurais convolucionais (CNNs). Em ambos os casos, sucessivas etapas de filtragem e redução de resolução produzem descrições cada vez mais abstratas da imagem. Entretanto, as *wavelets* utilizam filtros matematicamente definidos e reconstruíveis, enquanto as CNNs aprendem seus filtros durante o treinamento.

### 5.6.3 Famílias de *Wavelets*

Diferentes famílias de *wavelets* apresentam compromissos distintos entre **suporte espacial**, suavidade e capacidade de compressão. O **suporte** corresponde à extensão da função *wavelet* no domínio espacial: quanto



menor o suporte, mais localizada é a função; quanto maior, mais suave tende a ser sua representação, porém com maior custo computacional. A Table 5.4 compara algumas das famílias mais utilizadas.

Tabela 5.4: Comparação entre famílias de *wavelets*, destacando o comprimento do suporte, o número de momentos nulos, a simetria e aplicações típicas.

| <i>Wavelet</i>  | Comprimento do suporte | Momentos nulos | Simetria        | Uso típico                  |
|-----------------|------------------------|----------------|-----------------|-----------------------------|
| Haar            | 2                      | 1              | Assimétrica     | Introdução e análise básica |
| Daubechies db4  | 8                      | 4              | Assimétrica     | Compressão e análise geral  |
| Symlet sym4     | 8                      | 4              | Quase simétrica | Reconstrução de sinais      |
| Biortogonal 5/3 | 5/3                    | 2/2            | Simétrica       | JPEG 2000 sem perda         |
| Biortogonal 9/7 | 9/7                    | 4/4            | Simétrica       | JPEG 2000 com perda         |

Os **momentos nulos** medem a capacidade da *wavelet* de representar regiões suaves da imagem com poucos coeficientes diferentes de zero. Uma *wavelet* com  $p$  momentos nulos anula exatamente polinômios de grau até  $p - 1$ . Em consequência, quanto maior o número de momentos nulos, maior tende a ser a eficiência de compressão em regiões homogêneas, embora isso geralmente implique funções com suporte mais longo.

A Figure 5.17 apresenta as funções de base (*wavelets*)  $\psi(t)$  no domínio espacial. Essas funções possuem **suporte compacto**, isto é, são diferentes de zero apenas em uma região finita do domínio, ao contrário das senoides da Transformada de Fourier, que se estendem por todo o domínio.

```
# Import pywt
try:
    import pywt
except ImportError:
    import subprocess
    subprocess.run(["pip", "install", "PyWavelets", "-q"])
    import pywt

wavelet_haar = pywt.Wavelet('haar')
wavelet_db4 = pywt.Wavelet('db4')

phi_h, psi_h, x_h = wavelet_haar.wavefun(level=4)
phi_d, psi_d, x_d = wavelet_db4.wavefun(level=4)

fig, ax = plt.subplots(1, 2, figsize=(10, 3))
ax[0].plot(x_h, psi_h, 'b', lw=2); ax[0].set_title("Ondaleta Haar ( )")
ax[1].plot(x_d, psi_d, 'g', lw=2); ax[1].set_title("Ondaleta Daubechies 4 ( )")
plt.tight_layout(); plt.show()
```




Figura 5.17: Funções da *Wavelet* ( $\psi$ ). Note como elas rapidamente decaem para zero (suporte compacto), ao contrário das senoides infinitas de Fourier.

O diagrama da Figure 5.18 ilustra a análise multirresolução realizada pela DWT, na qual a subbanda de aproximação (LL) é sucessivamente decomposta, formando uma representação hierárquica com dois níveis.




Figura 5.18: Diagrama da decomposição *wavelet* 2D em dois níveis.

O simulador da Figure 5.19 permite explorar interativamente a Transformada *Wavelet* Discreta 2D (DWT) utilizando a *wavelet* de Haar. A decomposição em subbandas evidencia a separação entre a componente de aproximação e as componentes de detalhe da imagem.

Os diferentes padrões de entrada permitem observar o comportamento direcional dos filtros. Em imagens com bordas horizontais e verticais, as subbandas LH e HL destacam, respectivamente, as variações verticais e horizontais da intensidade. Em regiões de variação suave, a maior parte da energia concentra-se na subbanda de aproximação LL, enquanto as subbandas de detalhe apresentam coeficientes próximos de zero.

A análise multirresolução também pode ser observada ao aumentar o número de níveis de decomposição. Nesse caso, apenas a subbanda  $LL_1$  é novamente decomposta, originando as subbandas  $LL_2$ ,  $LH_2$ ,  $HL_2$  e  $HH_2$ , que formam o segundo nível da representação hierárquica.

Em padrões formados por regiões homogêneas de grande extensão, como um degradê suave ou um tabuleiro composto por blocos grandes, a energia permanece predominantemente concentrada na subbanda LL. No degradê, isso ocorre porque as diferenças entre pixels vizinhos são pequenas. No tabuleiro, por sua vez, os pixels possuem praticamente a mesma intensidade no interior de cada bloco, de modo que apenas as

fronteiras entre blocos produzem coeficientes não nulos nas subbandas de detalhe. Como essas fronteiras ocupam apenas uma pequena fração da imagem, sua contribuição para a energia total permanece reduzida.

Para viabilizar a análise visual dessas variações sutis, o simulador incorpora um controle de ganho de contraste dos detalhes (variando de 1 a 8). Esse parâmetro funciona como um fator de amplificação linear aplicado exclusivamente aos coeficientes das subbandas de detalhe (LH, HL e HH) antes de sua renderização em tela. Em cenários de transição suave (como o gradiente) ou de uniformidade local (como o interior dos blocos do tabuleiro), as diferenças numéricas calculadas pelo filtro passa-altas de Haar resultam em coeficientes muito próximos de zero, o que tornaria os quadrantes correspondentes escuros e imperceptíveis a olho nu. Ao multiplicar esses valores pelo ganho, o simulador resgata visualmente as estruturas de alta frequência ocultas e realça a orientação das bordas remanescentes.

O gráfico de energia por subbanda quantifica essa distribuição entre a componente de aproximação e as componentes de detalhe, demonstrando que o ganho visual não altera a métrica original da energia. Em imagens naturais, a maior parte da energia concentra-se na subbanda LL, enquanto as subbandas LH, HL e HH representam principalmente bordas, texturas e outras variações locais da intensidade.




Figura 5.19: Simulação da decomposição *wavelet* 2D.

### 5.6.4 Análise Multirresolução com a DWT 2D

A Transformada *Wavelet* Discreta 2D (DWT) decompõe uma imagem em componentes de aproximação e detalhe, organizadas de forma hierárquica em diferentes escalas e orientações. Como as subbandas de detalhe em imagens naturais frequentemente apresentam coeficientes de baixo contraste, os exemplos práticos a seguir utilizam um padrão geométrico sintético gerado em Python. Essa abordagem replica o comportamento do simulador da Figure 5.19, tornando visualmente explícitos os efeitos da filtragem espacial e da decomposição multirresolução.

#### 5.6.4.1 Decomposição em Mosaico de Múltiplos Níveis

A Figure 5.20 ilustra a estrutura hierárquica da DWT em dois níveis utilizando a *wavelet* de Haar. O processo baseia-se na aplicação combinada de filtros passa-baixa e passa-alta nas direções horizontal e vertical, seguidos por subamostragem por um fator de 2.

No primeiro nível, a imagem original origina a subbanda de aproximação ( $LL_1$ ) e as componentes de detalhe horizontal ( $LH_1$ ), vertical ( $HL_1$ ) e diagonal ( $HH_1$ ). Na análise multirresolução, a subbanda  $LL_1$  é novamente filtrada e subamostrada, gerando o segundo nível de decomposição ( $LL_2$ ,  $LH_2$ ,  $HL_2$  e  $HH_2$ ).

Para viabilizar a interpretação visual das componentes de detalhe, o código extrai o valor absoluto de seus coeficientes e aplica uma normalização linear (*min-max*) para ocupar toda a faixa dinâmica de tons de cinza [0, 255]. Essa operação transforma regiões homogêneas (coeficientes nulos) em preto e destaca em branco as bordas e texturas extraídas em cada escala e orientação.

```
try:
    import pywt
    HAS_PYWT = True
except ImportError:
    import subprocess
    subprocess.run(["pip", "install", "PyWavelets", "-q"])
    import pywt
    HAS_PYWT = True

import numpy as np
import cv2

# Geração da Imagem Sintética (Mesmo padrão 'combined' do simulador)
def gerar_imagem_sintetica(N=256):
    img = np.zeros((N, N), dtype=np.float64)
    for y in range(N):
        for x in range(N):
            v = 55 + 35 * (x / N) + 15 * np.sin(y / 24)
            # Quadrado
            if 24 < x < 100 and 24 < y < 100:
                v = 225
            # Círculo
            cx, cy, r = 190, 76, 34
            if (x - cx)**2 + (y - cy)**2 < r**2:
                v = 205
            # Textura periódica (inferior)
            if y > 164 and y < 244:
                p = 12
                v = 185 if ((x // p + y // p) % 2 == 0) else 65
            # Linha diagonal
            if abs(x - y) < 4:
                v = 240
            img[y, x] = np.clip(v, 0, 255)
    return img.astype(np.uint8)
```

```
# Substitui a imagem escura de moedas pelo padrão sintético claro
img_gray = gerar_imagem_sintetica(256)

# Decomposição wavelet 2 níveis
wavelet = "haar"
img_float = img_gray.astype(np.float64)

# Nível 1
coefs1 = pywt.dwt2(img_float, wavelet)
LL1, (LH1, HL1, HH1) = coefs1

# Nível 2 (aplicado sobre LL1)
coefs2 = pywt.dwt2(LL1, wavelet)
LL2, (LH2, HL2, HH2) = coefs2

def sb_vis(sb):
    """Normaliza subbanda para visualização [0,255]."""
    return cv2.normalize(np.abs(sb), None, 0, 255, cv2.NORM_MINMAX).astype(np.uint8)

print(f"Forma original      : {img_gray.shape}")
print(f"LL1 (nível 1)       : {LL1.shape} | LH1/HL1/HH1: {LH1.shape}")
print(f"LL2 (nível 2)       : {LL2.shape} | LH2/HL2/HH2: {LH2.shape}")

imgs_dwt = [img_gray, sb_vis(LL1), sb_vis(LH1), sb_vis(HL1), sb_vis(HH1),
              sb_vis(LL2), sb_vis(LH2), sb_vis(HL2), sb_vis(HH2)]
titles_dwt = ["Original",
              "LL (aprox.)", "LH (horiz.)", "HL (vert.)", "HH (diag.)",
              "LL (aprox.)", "LH (horiz.)", "HL (vert.)", "HH (diag.)"]

mm.show(imgs_dwt, titles=titles_dwt, cols=5, figsize=(16, 7))
```

```
Forma original      : (256, 256)
LL1 (nível 1)       : (128, 128) | LH1/HL1/HH1: (128, 128)
LL2 (nível 2)       : (64, 64)  | LH2/HL2/HH2: (64, 64)
```




Figura 5.20: Decomposição *wavelet* 2D de 2 níveis com *wavelet* Haar: subbandas LL, LH, HL, HH em cada nível. As subbandas de detalhe revelam estruturas orientadas em diferentes escalas utilizando um padrão sintético.

### 5.6.4.2 O Compromisso entre Localização e Suavidade

A escolha da função de base (*wavelet*) influencia diretamente a forma como as feições da imagem são distribuídas e codificadas pelos coeficientes da DWT. A Figure 5.21 compara os resultados práticos obtidos ao aplicar quatro famílias distintas sobre o padrão geométrico sintético: *haar*, *db4*, *sym4* e *bior2.2*.

Por possuir suporte curto e formato de função degrau, a *wavelet* de Haar produz coeficientes altamente localizados nas descontinuidades espaciais, gerando bordas finas e nítidas nas subbandas de detalhe. Em contrapartida, famílias como Daubechies (*db4*) e Symlets (*sym4*), que apresentam maior suporte (filtros mais longos) e maior número de momentos nulos, geram respostas mais suaves e distribuídas ao redor das transições, o que pode introduzir leves oscilações ou borramentos nas fronteiras abruptas.

Esse comportamento evidencia o clássico compromisso (*trade-off*) da análise de multirresolução: suportes menores favorecem a localização espacial exata das bordas, enquanto suportes maiores e maior número de momentos nulos tendem a produzir representações mais esparsas e suaves. Essa suavidade e capacidade de atenuação de altas frequências garantem maior eficiência na compactação da energia, características fundamentais para aplicações de compressão de dados e remoção de ruído (*denoising*).

```
import numpy as np
import cv2
import pywt

# Garante que img_gray e img_float utilizem o mesmo padrão sintético claro
if 'gerar_imagem_sintetica' in globals():
    img_gray = gerar_imagem_sintetica(256)
else:
    # Fallback caso o bloco anterior não tenha sido executado na mesma sessão
    def gerar_imagem_sintetica(N=256):
        img = np.zeros((N, N), dtype=np.float64)
        for y in range(N):
            for x in range(N):
                v = 55 + 35 * (x / N) + 15 * np.sin(y / 24)
                if 24 < x < 100 and 24 < y < 100: v = 225
                cx, cy, r = 190, 76, 34
                if (x - cx)**2 + (y - cy)**2 < r**2: v = 205
                if y > 164 and y < 244:
                    p = 12
                    v = 185 if ((x // p + y // p) % 2 == 0) else 65
                if abs(x - y) < 4: v = 240
                img[y, x] = np.clip(v, 0, 255)
            return img.astype(np.uint8)
        img_gray = gerar_imagem_sintetica(256)

img_float = img_gray.astype(np.float64)

wavelets_comp = ["haar", "db4", "sym4", "bior2.2"]
imgs_comp, titles_comp = [], []

for wname in wavelets_comp:
    LL, (LH, HL, HH) = pywt.dwt2(img_float, wname)
    imgs_comp += [sb_vis(LL), sb_vis(HH)]
    titles_comp += [f"{wname} - LL ", f"{wname} - HH "]

mm.show(imgs_comp, titles=titles_comp, cols=4, figsize=(14, 8))
```




Figura 5.21: Comparação entre famílias de *wavelets*: Haar, db4, sym4 e bior2.2. Subbanda LL (aproximação) e HH (diagonal) para cada escolha, ilustrando o compromisso entre compactação e suavidade com base no padrão sintético.

#### 5.6.4.3 Limiarização de Coeficientes e Compressão

Uma das principais aplicações da Transformada *Wavelet* Discreta (DWT) é a compressão de dados, impulsionada pela capacidade de representação **esparças** dos coeficientes. A Figure 5.22 ilustra o efeito da limiarização abrupta (*hard thresholding*), técnica na qual coeficientes de detalhe com magnitude inferior a um limiar  $T$  são integralmente anulados antes do processo de síntese realizado pela Transformada *Wavelet* Discreta Inversa (IDWT).

À medida que o limiar  $T$  é elevado, um volume crescente de coeficientes de alta frequência é zerado. Por concentrarem menor energia, a remoção dessas componentes reduz consideravelmente a quantidade de informação necessária para representar a imagem, mantendo a componente de aproximação global (a subbanda  $LL$  mais profunda) intacta para preservar a estrutura macro. Visualmente, esse descarte de coeficientes manifesta-se através do desaparecimento progressivo de texturas finas e da suavização de transições abruptas de intensidade.

A fidelidade da imagem reconstruída frente à original é quantificada pela métrica de **Pico da Relação Sinal-Ruído (PSNR, *Peak Signal-to-Noise Ratio*)**, expressa em decibéis (dB). Valores mais altos de PSNR indicam menor distorção e maior proximidade matemática com o sinal original. O experimento prático evidencia o decaimento gradual do PSNR conforme a agressividade da limiarização aumenta, permitindo avaliar numericamente o limiar ótimo para o balanço entre compressão e degradação visual.

```
import numpy as np
import cv2
import pywt

# Garante que img_gray utilize o mesmo padrão sintético claro
if 'gerar_imagem_sintetica' in globals():
    img_gray = gerar_imagem_sintetica(256)
else:
    # Fallback caso o bloco anterior não tenha sido executado na mesma sessão
```



```

def gerar_imagem_sintetica(N=256):
    img = np.zeros((N, N), dtype=np.float64)
    for y in range(N):
        for x in range(N):
            v = 55 + 35 * (x / N) + 15 * np.sin(y / 24)
            if 24 < x < 100 and 24 < y < 100: v = 225
            cx, cy, r = 190, 76, 34
            if (x - cx)**2 + (y - cy)**2 < r**2: v = 205
            if y > 164 and y < 244:
                p = 12
                v = 185 if ((x // p + y // p) % 2 == 0) else 65
            if abs(x - y) < 4: v = 240
            img[y, x] = np.clip(v, 0, 255)
    return img.astype(np.uint8)
img_gray = gerar_imagem_sintetica(256)

def dwt_threshold_reconstruct(img, wavelet='db4', nivel=2, threshold=0.0):
    """Decompõe, aplica limiar e reconstrói via IDWT."""
    coefs = pywt.wavedec2(img.astype(np.float64), wavelet, level=nivel)
    # Copia e aplica hard thresholding em todos os detalhes
    coefs_t = [coefs[0]] # LL final não é limiarizado
    for detalhe in coefs[1:]:
        coefs_t.append(tuple(pywt.threshold(sb, threshold, mode='hard') for sb in detalhe))
    rec = pywt.waverec2(coefs_t, wavelet)
    # Recorte para dimensão original
    rec = rec[:img.shape[0], :img.shape[1]]
    return np.clip(rec, 0, 255).astype(np.uint8)

thresholds = [0, 10, 30, 60, 100]
imgs_thr = [img_gray]
titles_thr = ["Original"]

for t in thresholds:
    rec = dwt_threshold_reconstruct(img_gray, threshold=t)
    psnr = cv2.PSNR(img_gray, rec)
    imgs_thr.append(rec)
    titles_thr.append(f"T={t} PSNR={psnr:.1f} dB")

mm.show(imgs_thr, titles=titles_thr, cols=3, figsize=(14, 10))

```




Figura 5.22: Reconstrução *wavelet* com limiarização de coeficientes (*hard thresholding*): à medida que o limiar aumenta, mais detalhes são zerados, produzindo imagens progressivamente mais suaves. Métrica PSNR quantifica a perda de qualidade sobre o padrão sintético.

Síntese — **Fourier vs. Wavelets:** quando utilizar cada abordagem?

A Table 5.5 sintetiza as principais diferenças estruturais e operacionais entre a Transformada Discreta de Fourier (DFT) e a Transformada *Wavelet* Discreta (DWT).

Tabela 5.5: Comparação entre a Transformada Discreta de Fourier (DFT) e a Transformada *Wavelet* Discreta (DWT), destacando suas principais características e aplicações.

| Critério                          | Fourier (DFT)                               | <i>Wavelet</i> (DWT)           |
|-----------------------------------|---------------------------------------------|--------------------------------|
| <b>Funções de base</b>            | Senoides de suporte infinito                | Funções de suporte compacto    |
| <b>Localização espacial</b>       | Não explícita (global)                      | Explícita (local)              |
| <b>Filtragem espectral</b>        | Excelente para controle fino de frequências | Baseada em subbandas (escalas) |
| <b>Compressão de imagens</b>      | Base da DCT (JPEG tradicional)              | Base da DWT (JPEG 2000)        |
| <b>Análise multiescala</b>        | Não                                         | Sim                            |
| <b>Remoção de ruído periódico</b> | Altamente eficiente                         | Pouco indicada                 |
| <b>Sinais não estacionários</b>   | Limitada                                    | Altamente eficiente            |

Em termos práticos, a DFT consolida-se como a ferramenta ideal para análise espectral pura, projeto de filtros seletivos no domínio da frequência e atenuação de ruídos periódicos e harmônicos. Por outro lado, a DWT sobressai-se em cenários que exigem a preservação rigorosa da localização espacial das feições associada ao seu conteúdo frequencial, destacando-se em compressão de dados, análise multirresolução e processamento

de transições abruptas. Desse modo, ambas as transformadas devem ser compreendidas como técnicas perfeitamente complementares, mapeando caminhos distintos e específicos para a resolução de problemas em PDI-VC.

**i** Analogias com Áudio: Limitações e Cuidados

Ao fazer analogias entre processamento de imagens e áudio, é importante considerar as diferenças fundamentais:

- Em sistemas de áudio estéreo/multicanais, a fase entre canais é crucial para a percepção de localização espacial (diferenças interaurais de fase e tempo).
- Em sistemas monaurais, a fase tem influência perceptual limitada — o ouvido humano é relativamente insensível à fase absoluta de componentes senoidais isolados.
- Em imagens, a fase da DFT é sempre fundamental para a localização espacial de estruturas, independentemente de ser uma imagem monocromática ou colorida.

A analogia entre fase em áudio e fase em imagens deve ser usada com cautela, destacando que, embora ambas carreguem informações sobre a organização espacial/temporal do sinal, os mecanismos perceptuais são fundamentalmente diferentes.

5.7 Compressão de Imagens

Enquanto as *wavelets* estabelecem a fundação teórica do padrão JPEG 2000, o padrão JPEG tradicional baseia-se na **Transformada Discreta de Cossenos (DCT, *Discrete Cosine Transform*)**. Apesar das diferenças estruturais, ambas as abordagens compartilham o mesmo princípio fundamental: compactar a energia da imagem em um número reduzido de coeficientes e descartar as componentes de menor relevância com impacto visual mínimo.

O objetivo central da compressão é reduzir o volume de dados necessário para o armazenamento ou transmissão de uma imagem. Esse processo é viabilizado pela identificação e eliminação de **redundâncias** estruturais e perceptuais.

5.7.1 Taxonomia das Redundâncias

O desenvolvimento de algoritmos de compressão fundamenta-se na identificação e eliminação de três categorias principais de redundância, sintetizadas na Table 5.6.

Tabela 5.6: Categorias de redundância em imagens digitais e seus respectivos mecanismos de exploração.

| Tipo                   | Definição                                                                                        | Abordagem de Exploração                                    |
|------------------------|--------------------------------------------------------------------------------------------------|------------------------------------------------------------|
| Espacial (interpixel)  | Alta correlação e dependência estatística entre pixels vizinhos.                                 | DCT, DWT e codificação preditiva.                          |
| Espectral (intercanal) | Correlação estatística entre os canais de cor de uma mesma imagem.                               | Transformações de espaço de cor (ex: RGB para $YC_bC_r$ ). |
| Psicovisual            | Insensibilidade do sistema visual humano (SVH) a variações de alta frequência e baixo contraste. | Processos de quantização seletiva de coeficientes.         |

A depender da preservação da informação original após o processo de decodificação, os métodos de compressão dividem-se em duas classes fundamentais:

- **Sem perda (*lossless*):** Garante uma reconstrução bit a bit idêntica à imagem original. É empregada em cenários onde a integridade dos dados é estritamente crítica, como em imagens médicas, diagnósticos por imagem e armazenamento de documentos textuais.

- **Com perda (*lossy*):** Admite a introdução de uma distorção controlada no sinal em troca de taxas de compressão substancialmente mais elevadas. É a abordagem padrão para fotografias de consumo e *streaming* de vídeo, ecossistemas nos quais o SVH tolera pequenas atenuações de alta frequência sem percepção de degradação da qualidade visual.

### 5.7.2 Transformada de Cossenos Discreta (DCT-II 2D)

A **Transformada de Cossenos Discreta** (DCT) constitui a operação central do padrão JPEG. Diferentemente da DFT, que utiliza uma base complexa, a DCT baseia-se em funções trigonométricas puramente reais. Para um bloco de imagem  $f(x, y)$  de dimensões  $N \times N$ , a **DCT-II 2D** mapeia o sinal espacial para o domínio das frequências espaciais, gerando a matriz de coeficientes  $C(u, v)$  por meio de:

$$C(u, v) = \alpha(u) \alpha(v) \sum_{x=0}^{N-1} \sum_{y=0}^{N-1} f(x, y) \cos \left[ \frac{\pi(2x+1)u}{2N} \right] \cos \left[ \frac{\pi(2y+1)v}{2N} \right] \quad (5.9)$$

onde os fatores de normalização ortogonal são dados por  $\alpha(0) = \sqrt{1/N}$  e  $\alpha(k) = \sqrt{2/N}$  para  $k > 0$ .

Cada coeficiente  $C(u, v)$  quantifica a contribuição — ou “peso” — de uma frequência espacial específica dentro daquele bloco. O termo  $C(0, 0)$  é denominado **componente DC** e representa a intensidade média do bloco (frequência nula). Os demais coeficientes, chamados de **componentes AC** (*Alternating Current*), correspondem às frequências espaciais progressivamente maiores.

### 5.7.3 As Funções de Base da DCT

Sob uma perspectiva geométrica, a Equation 5.9 realiza a projeção do bloco de pixels sobre um conjunto de funções ortogonais. Para o caso padrão do JPEG ( $N = 8$ ), o bloco espacial é decomposto em uma combinação linear de **64 funções de base** bidimensionais, denotadas por  $B_{u,v}(x, y)$  e geradas pelo produto de funções cossenoidais:

$$B_{u,v}(x, y) = \cos \left[ \frac{\pi(2x+1)u}{16} \right] \cos \left[ \frac{\pi(2y+1)v}{16} \right]$$

Dessa forma, a operação inversa pode ser interpretada como a reconstrução exata do bloco original por meio da soma ponderada dessas 64 matrizes de base, onde cada coeficiente  $C(u, v)$  atua como o peso analítico de sua respectiva componente harmônica.

A **frequência espacial** indicada pelos índices  $(u, v)$  determina o número de ciclos de oscilação ao longo das dimensões horizontais e verticais do bloco. Como ilustrado na Figure 5.23 — cujo código isola cada base aplicando a transformação inversa sobre impulsos unitários —, essas 64 funções são organizadas em uma matriz  $8 \times 8$ . O canto superior esquerdo ( $u = 0, v = 0$ ) exhibe o padrão uniforme de frequência nula (DC), enquanto o avanço para a direita (eixo  $u$ ) ou para baixo (eixo  $v$ ) mapeia variações harmônicas progressivamente maiores, representando transições rápidas, bordas e texturas nas orientações horizontais, verticais e diagonais.

#### **i** DCT vs DFT: Vantagem da Compactação de Energia

Tanto a DCT quanto a DFT mapeiam um bloco  $N \times N$  espacial em uma matriz de coeficientes de mesma dimensão. Contudo, para imagens naturais, a DCT apresenta maior eficiência na **compactação de energia** nas baixas frequências. Isso ocorre porque a DCT assume implicitamente uma simetria par do sinal nas fronteiras do bloco, o que equivale a uma extensão periódica contínua, minimizando o efeito de espalhamento espectral (*ringing*). Como consequência, a maioria dos coeficientes AC decai rapidamente para valores próximos de zero, otimizando o *pipeline* de compressão sem introduzir degradação visual perceptível.

```

from scipy.fft import dct, idct # linha adicionada

fig, axes = plt.subplots(8, 8, figsize=(6, 6))
fig.subplots_adjust(hspace=0.05, wspace=0.05)
for i in range(8):
    for j in range(8):
        coef = np.zeros((8, 8)); coef[i, j] = 1
        b = idct(idct(coef.T, norm='ortho').T, norm='ortho')
        axes[i, j].imshow(b, cmap='gray')
        axes[i, j].axis('off')
plt.suptitle("As 64 Bases da DCT 8x8", y=0.92, fontsize=12, fontweight='bold')
plt.show()

```




Figura 5.23: O Alfabeto Visual do JPEG: As 64 funções de base da DCT-II. O coeficiente DC fica no topo esquerdo (suave). Ao descer e avançar à direita, a oscilação espacial aumenta drasticamente.

#### 5.7.4 Concentração de Energia e Reconstrução Progressiva

Antes da aplicação da DCT, os pixels do bloco de intensidade são rotineiramente transladados (subtraindo-se 128 para imagens de 8 bits) a fim de centralizar o sinal em torno de zero, eliminando componentes contínuas desnecessárias. Ao computar a DCT sobre o bloco resultante, a propriedade de **compactação de energia** torna-se evidente: a quase totalidade da variância e da informação da imagem original concentra-se no coeficiente DC ( $C(0,0)$ ) e nos primeiros harmônicos AC de baixa frequência.

A Figure 5.24 demonstra esse fenômeno por meio de uma reconstrução progressiva por truncamento abrupto. Em vez de utilizar todos os 64 coeficientes, o algoritmo preserva apenas os  $k$  primeiros componentes — selecionados com base em uma varredura que prioriza as baixas frequências espaciais — e anula os demais.

A síntese inversa (**IDCT**) realizada com apenas uma fração dos coeficientes (como 15% ou 30%) já é capaz de recuperar as estruturas e a iluminação macro do bloco original de pixels. À medida que harmônicos de frequências mais altas são progressivamente reincorporados, os detalhes finos e as transições rápidas são restaurados. Esse comportamento valida o princípio da compressão perceptual: as altas frequências descartadas possuem pouca energia e sua ausência, em condições normais, gera um impacto visual secundário na percepção do observador.

```
from scipy.fft import dct, idct

def dct2(bloco):
    """DCT-II 2D ortogonal (separável)."""
    return dct(dct(bloco.T, norm='ortho').T, norm='ortho')

def idct2(coefs):
    """IDCT-II 2D ortogonal."""
    return idct(idct(coefs.T, norm='ortho').T, norm='ortho')

# Bloco 8x8 centralizado da imagem
cy, cx = img_gray.shape[0]//2, img_gray.shape[1]//2
bloco = img_gray[cy:cy+8, cx:cx+8].astype(np.float64) - 128.0

C = dct2(bloco)

print("Coeficientes DCT do bloco 8x8:")
print(np.round(C).astype(int))
print(f"\nEnergia DC      : {C[0,0]**2:.1f}")
print(f"Energia total    : {(C**2).sum():.1f}")
print(f"Fração no DC      : {C[0,0]**2 / (C**2).sum():.1%} ← concentração de energia")

# Reconstrução progressiva
imgs_rec = [cv2.normalize((bloco+128).astype(np.uint8), None, 0, 255, cv2.NORM_MINMAX)]
titles_rec = ["Bloco original\n(8x8 pixels)"]

for keep in [1, 4, 10, 20, 40, 64]:
    C_trunc = np.zeros_like(C)
    indices = sorted([(u,v) for u in range(8) for v in range(8)], key=lambda p: p[0]+p[1])
    for u, v in indices[:keep]:
        C_trunc[u, v] = C[u, v]
    rec = np.clip(idct2(C_trunc) + 128, 0, 255).astype(np.uint8)
    imgs_rec.append(rec)
    titles_rec.append(f"{keep} coef.\n({keep}/64:.0%} do total)")

mm.show(imgs_rec, titles=titles_rec, cols=4, figsize=(12, 7))
```

Coeficientes DCT do bloco 8x8:

```
[[ 450   2 -199   -1    0    0  -14    0]
 [  -2  506    0 -58    0   24    0 -24]
 [-199    2   89   -1   82    1    0    0]
 [  -1 -58    0 -158    0   59    0 -24]
 [   0    0   83    0 -89    0 -34    0]
 [   0   24    0   58    0   84    0 -58]
 [-14    0    0    0 -34    0   89   -1]
 [   0 -24    0 -24    0 -58    0 -76]]
```

```
Energia DC      : 202725.1
Energia total   : 639868.0
Fração no DC    : 31.7% ← concentração de energia
```





Figura 5.24: DCT 2D em bloco 8×8: coeficientes e reconstrução progressiva.

5.7.5 O *Pipeline* de Compressão JPEG

O padrão JPEG opera dividindo a imagem em blocos disjuntos de 8 × 8 pixels, processados por meio de uma sequência de transformações espaciais, perceptuais e estatísticas. O *pipeline* completo de codificação é estruturado em seis etapas principais:



A Table 5.7 detalha a função analítica e o fundamento perceptual que justifica cada uma dessas etapas.

Tabela 5.7: Etapas do *pipeline* de compressão JPEG e seus respectivos fundamentos de projeto.

| Etapa | Operação                                   | Fundamento Perceptual e Estatístico                                                                                                                           |
|-------|--------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1     | Conversão $RGB \rightarrow YC_bC_r$        | Separa a luminância ( $Y$ ) da cromaticidade ( $C_b, C_r$ ). O sistema visual humano (SVH) apresenta maior sensibilidade a variações de brilho do que de cor. |
| 2     | Subamostragem de cromaticidade (ex: 4:2:0) | Reduz a resolução espacial dos canais de cor pela metade, descartando dados redundantes com impacto visual desprezível.                                       |



| Etapa | Operação                                      | Fundamento Perceptual e Estatístico                                                                                                                                         |
|-------|-----------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 3–4   | Centralização e aplicação da DCT $8 \times 8$ | Translada os pixels para o intervalo $[-128, 127]$ e compacta a energia espectral do bloco nos coeficientes de baixa frequência.                                            |
| 5     | Quantização linear seletiva                   | Divide cada coeficiente $C(u, v)$ pelo elemento correspondente da matriz $Q(u, v)$ , aplicando arredondamento inteiro. Constitui a principal fonte de compressão com perda. |
| 6     | Varredura em ziguezague e codificação         | Ordena os coeficientes quantizados para maximizar sequências nulas consecutivas, otimizando a codificação por comprimento de corrida (RLE) e a codificação de Huffman.      |

A **matriz de quantização**  $Q(u, v)$  é o mecanismo central de controle do compromisso entre taxa de compressão e qualidade visual. No algoritmo prático da Figure 5.25, o fator de qualidade estipulado pelo usuário (escala de 1 a 100) é convertido em um escalar que parametriza a severidade da matriz  $Q$ . Valores reduzidos de qualidade expandem os divisores de  $Q(u, v)$ , forçando o truncamento em massa dos coeficientes AC para zero. Quando essa eliminação é excessiva, a descontinuidade nas fronteiras dos blocos adjacentes não é atenuada na reconstrução, gerando os denominados **artefatos de bloco** (*blocking artifacts*).

### A Lógica da Varredura em Ziguezague

A eficiência do codificador entrópico subsequente à quantização depende diretamente da ordenação dos dados. Como a DCT concentra a energia vital no vértice superior esquerdo da matriz (baixas frequências) e empurra os coeficientes nulos para as extremidades opostas, a leitura linear por linhas ou colunas fragmentaria as sequências de zeros.

A ordenação em ziguezague soluciona essa limitação ao percorrer a matriz diagonalmente em ordem crescente de frequência espacial. Esse mapeamento agrupa os coeficientes significativos no início do vetor e concentra os coeficientes nulos em uma única sequência contínua ao final do arranjo, permitindo que o algoritmo RLE codifique grandes blocos de dados de forma compacta e eficiente.

#### **i** O que é RLE?

**RLE** (*Run-Length Encoding*) é uma técnica de compressão sem perdas que codifica sequências consecutivas de valores idênticos — especialmente **zeros** — como um par (contagem, valor). No JPEG, após a varredura em ziguezague, os coeficientes quantizados são organizados de modo que os zeros se concentrem ao final do vetor. O RLE então comprime essa longa corrida de zeros com extrema eficiência, otimizando o armazenamento e a transmissão da imagem comprimida.

```
import numpy as np
import cv2
from scipy.fft import dct, idct

# Carregamento Seguro da Imagem da Câmera (skimage)
try:
    from skimage import data
```

```

    img_gray = data.camera()
except ImportError:
    import subprocess
    subprocess.run(["pip", "install", "scikit-image", "-q"])
    from skimage import data
    img_gray = data.camera()

# Redimensiona levemente para 256x256 para manter o padrão e velocidade dos testes anteriores
img_gray = cv2.resize(img_gray, (256, 256))

# Tabela de quantização luminância (padrão JPEG)
Q_luma = np.array([
    [16,11,10,16,24,40,51,61],
    [12,12,14,19,26,58,60,55],
    [14,13,16,24,40,57,69,56],
    [14,17,22,29,51,87,80,62],
    [18,22,37,56,68,109,103,77],
    [24,35,55,64,81,104,113,92],
    [49,64,78,87,103,121,120,101],
    [72,92,95,98,112,100,103,99]
], dtype=np.float64)

def dct2(bloco):
    """DCT-II 2D ortogonal (separável)."""
    return dct(dct(bloco.T, norm='ortho').T, norm='ortho')

def idct2(coefs):
    """IDCT-II 2D ortogonal."""
    return idct(idct(coefs.T, norm='ortho').T, norm='ortho')

def jpeg_compress_block(bloco, Q_table):
    """DCT → quantização → dequantização → IDCT em bloco 8×8."""
    C = dct2(bloco.astype(np.float64) - 128)
    Cq = np.round(C / Q_table) * Q_table # quantiza e dequantiza
    return np.clip(idct2(Cq) + 128, 0, 255)

def jpeg_quality_compress(img, qualidade=50):
    """JPEG simplificado: comprime imagem inteira por blocos 8×8."""
    if qualidade < 50:
        escala = 5000 / qualidade
    else:
        escala = 200 - 2 * qualidade
    # Corrigido de 'scala' para 'escala'
    Q = np.clip(np.round(Q_luma * escala / 100), 1, 255)

    h, w = img.shape
    result = np.zeros_like(img, dtype=np.float64)
    for r in range(0, h-7, 8):
        for c in range(0, w-7, 8):
            result[r:r+8, c:c+8] = jpeg_compress_block(img[r:r+8, c:c+8], Q)
    return result.astype(np.uint8)

# Comparação de fatores de qualidade
qualidades = [10, 25, 50, 75, 90]
imgs_jpeg = [img_gray]
titles_jpeg = ["Original\n(Cameraman)"]

for q in qualidades:
    rec = jpeg_quality_compress(img_gray, qualidade=q)
    psnr = cv2.PSNR(img_gray, rec)

```

```

imgs_jpeg.append(rec)
titles_jpeg.append(f"Q={q}\nPSNR={psnr:.1f}dB")

mm.show(imgs_jpeg, titles=titles_jpeg, cols=3, figsize=(14, 10))

```



Figura 5.25: *Pipeline JPEG* simplificado aplicado à imagem clássica do *Cameraman*: DCT em blocos  $8 \times 8$ , quantização com diferentes fatores de qualidade e reconstrução via IDCT. Os artefatos de bloco (*blocking artifacts*) tornam-se visualmente evidentes em fatores de qualidade reduzidos ( $Q = 10$  e  $Q = 25$ ).

### 5.7.6 Simulador Interativo: Quantização DCT

O simulador da Figure 5.26 permite explorar o impacto do processo de quantização sobre um bloco  $8 \times 8$  extraído de uma imagem real, sintetizando em tempo real as seguintes componentes:

- **Bloco original e reconstruído:** Representação direta dos pixels no domínio espacial em escala de cinza  $[0, 255]$ .
- **Coefficientes DCT:** Distribuição da energia mapeada de forma logarítmica em um gradiente cromático, evidenciando a concentração de intensidade no vértice superior esquerdo (baixas frequências).
- **Coefficientes quantizados:** Exibição dos valores inteiros resultantes da divisão pela matriz  $Q(u, v)$ , tornando visualmente explícito o surgimento em massa de coeficientes nulos (em tons escuros) conforme o fator de qualidade é reduzido.
- **Métricas de compressão:** Painel de monitoramento que quantifica o Erro Quadrático Médio (MSE), o número de coeficientes preservados e o volume de zeros gerados para a codificação entrópica.



Figura 5.26: Simulador interativo de compressão DCT-JPEG: ajuste o fator de qualidade e visualize em tempo real os coeficientes zerados, o bloco reconstruído e o erro de quantização.

5.8 Comparação de Formatos de Imagem

A escolha de um formato de armazenamento digital impacta diretamente o compromisso entre qualidade visual, tamanho de arquivo e custo computacional de decodificação. Os três formatos de maior relevância para arquiteturas *web* e sistemas de computação visual são o JPEG, o PNG e o WebP.

5.8.1 Características dos Formatos

A Table 5.8 sintetiza as propriedades estruturais dos principais formatos de imagem rasterizados.

Tabela 5.8: Comparação estrutural entre os principais formatos de imagem rasterizados.

| Característica            | JPEG                   | PNG                            | WebP                           |
|---------------------------|------------------------|--------------------------------|--------------------------------|
| <b>Compressão</b>         | Com perda              | Sem perda                      | Com e sem perda.               |
| <b>Transparência</b>      | Não                    | Sim                            | Sim.                           |
| <b>Suporte a animação</b> | Não                    | Limitado (APNG)                | Sim.                           |
| <b>Algoritmo base</b>     | DCT + Huffman          | DEFLATE (LZ77 + Huffman)       | VP8 / VP8L.                    |
| <b>Melhor para</b>        | Fotografia             | Gráficos, texto e ícones       | Uso universal em ambiente Web. |
| <b>Pior para</b>          | Texto e bordas nítidas | Imagens fotográficas complexas | Compatibilidade legada.        |

5.8.2 Métricas de Avaliação de Qualidade

Duas métricas objetivas são amplamente adotadas para quantificar a distorção introduzida por processos de compressão:

**Pico da Relação Sinal-Ruído (PSNR, *Peak Signal-to-Noise Ratio*):**

$$\text{PSNR} = 10 \log_{10} \left( \frac{L^2}{\text{MSE}} \right) \quad [\text{dB}] \quad (5.10)$$

onde  $L = 255$  para imagens quantizadas em 8 bits e MSE representa o **Erro Quadrático Médio** (*Mean Squared Error*). Valores de PSNR acima de 40 dB indicam excelente fidelidade; entre 30 dB e 40 dB representam boa qualidade; e valores inferiores a 30 dB correspondem a degradações visuais facilmente perceptíveis.

**Índice de Similaridade Estrutural (SSIM, *Structural Similarity Index*):**

$$\text{SSIM}(f, g) = \frac{(2\mu_f\mu_g + c_1)(2\sigma_{fg} + c_2)}{(\mu_f^2 + \mu_g^2 + c_1)(\sigma_f^2 + \sigma_g^2 + c_2)} \quad (5.11)$$

O SSIM avalia janelas locais da imagem com base em três componentes complementares: **luminância** ( $\mu_f, \mu_g$ ), **contraste** ( $\sigma_f, \sigma_g$ ) e **estrutura** ( $\sigma_{fg}$ ), ponderados por constantes de estabilidade  $c_1$  e  $c_2$ . O índice varia no intervalo  $[-1, 1]$ , onde a unidade representa a identidade perfeita. Ao contrário do PSNR, o SSIM considera a organização espacial dos erros, alinhando-se à percepção do sistema visual humano (SVH).

**i PSNR vs SSIM: Aplicação de Métricas Perceptuais**

O PSNR possui formulação matemática simples e baixo custo computacional, contudo, tende a superestimar a qualidade em imagens com distorções localizadas ou subestimá-la em variações globais de brilho toleradas pelo observador. O SSIM modela com maior fidelidade a percepção biológica, mas exige maior esforço de processamento. Para análises rigorosas de codificadores, recomenda-se reportar ambas as métricas estatísticas em caráter complementar.

**5.8.3 Inspeção Visual: Natureza dos Artefatos de Compressão**

A natureza matemática do codificador dita o tipo de degradação introduzida em taxas de bits reduzidas. Conforme ilustrado na Figure 5.27, a compressão agressiva via DCT no padrão JPEG segmenta a imagem em malhas rígidas, gerando os **artefatos de bloco** (*blocking artifacts*). Em contrapartida, algoritmos baseados em codificação preditiva ou representações submetidas a transformadas espaciais avançadas (como o WebP e o JPEG 2000) eliminam as descontinuidades de bloco, mas introduzem perda de textura fina e borramentos característicos ao redor de bordas de alto contraste.

```
import os
import cv2

# Garante a existência do diretório e grava os arquivos comprimidos
os.makedirs("imagens/comp_test", exist_ok=True)
cv2.imwrite("imagens/comp_test/camera_q10.jpg", img_gray, [cv2.IMWRITE_JPEG_QUALITY, 10])
cv2.imwrite("imagens/comp_test/camera_q10.webp", img_gray, [cv2.IMWRITE_WEBP_QUALITY, 10])

# Extração de região de interesse para visualização de artefatos (Zoom de 4x)
zoom_original = cv2.resize(img_gray[120:200, 150:230], (320, 320),
                           interpolation=cv2.INTER_NEAREST)

rec_jpeg = cv2.imread("imagens/comp_test/camera_q10.jpg", cv2.IMREAD_GRAYSCALE)
zoom_jpeg = cv2.resize(rec_jpeg[120:200, 150:230], (320, 320),
                      interpolation=cv2.INTER_NEAREST)

rec_webp = cv2.imread("imagens/comp_test/camera_q10.webp", cv2.IMREAD_GRAYSCALE)
zoom_webp = cv2.resize(rec_webp[120:200, 150:230], (320, 320),
                      interpolation=cv2.INTER_NEAREST)
```

```
mm.show([zoom_original, zoom_jpeg, zoom_webp],
        titles=["Zoom Original", "JPEG Q=10 (Artefato de Bloco)", "WebP Q=10 (Suavização)"],
        cols=3, figsize=(14, 5))
```



Figura 5.27: Análise comparativa de artefatos de compressão sob fator de qualidade reduzido ( $Q = 10$ ). À esquerda, observa-se o artefato de bloco característico da discretização por DCT no JPEG. À direita, evidencia-se o efeito de atenuação e suavização de bordas intrínseco ao padrão WebP.

#### 5.8.4 Avaliação Quantitativa e Espacial da Compressão

A validação dos algoritmos de compressão com perda exige uma análise que correlacione o custo de armazenamento à fidelidade do sinal reconstruído. Essa avaliação é realizada de forma complementar através de curvas de desempenho global e pelo mapeamento local das distorções induzidas pelos codificadores.

##### 5.8.4.1 Curvas de Taxa-Distorção

A Figure 5.28 apresenta a avaliação empírica do *pipeline* JPEG e WebP por meio de **curvas de taxa-distorção**, que monitoram o ganho de compressão (tamanho do arquivo em KB) em função do PSNR. O formato PNG atua como linha de base ideal ( $\text{PSNR} = \infty$ ), pois sua natureza *lossless* impede qualquer degradação, embora demande um volume de dados substancialmente maior.

A análise das curvas demonstra a superioridade e a eficiência do padrão WebP sobre o JPEG tradicional: para atingir um mesmo patamar de fidelidade matemática (como a faixa de excelente qualidade, onde  $\text{PSNR} > 40$  dB), o codificador WebP gera arquivos significativamente menores. Esse comportamento traduz o impacto prático da evolução dos algoritmos na otimização de sistemas de transmissão e armazenamento digital.

```
import os
import cv2
import matplotlib.pyplot as plt

# Garante a existência do diretório de testes
os.makedirs("imagens/comp_test", exist_ok=True)
resultados = []

# JPEG
for q in [10, 20, 30, 40, 50, 60, 70, 80, 90, 95]:
    path = f"imagens/comp_test/camera_q{q}.jpg"
    cv2.imwrite(path, img_gray, [cv2.IMWRITE_JPEG_QUALITY, q])
    rec = cv2.imread(path, cv2.IMREAD_GRAYSCALE)
    resultados.append({"formato": "JPEG", "qualidade": q,
                      "PSNR": cv2.PSNR(img_gray, rec),
```



```

        "KB": os.path.getsize(path)/1024})

# PNG
path_png = "imagens/comp_test/camera.png"
cv2.imwrite(path_png, img_gray, [cv2.IMWRITE_PNG_COMPRESSION, 9])
resultados.append({"formato": "PNG", "qualidade": "lossless",
                    "PSNR": float('inf'), "KB": os.path.getsize(path_png)/1024})

# WebP
for q in [50, 75, 90]:
    path_w = f"imagens/comp_test/camera_q{q}.webp"
    cv2.imwrite(path_w, img_gray, [cv2.IMWRITE_WEBP_QUALITY, q])
    rec_w = cv2.imread(path_w, cv2.IMREAD_GRAYSCALE)
    resultados.append(
        {"formato": "WebP", "qualidade": q,
         "PSNR": cv2.PSUB_VAL if 'cv2.PSNR' in globals() else cv2.PSNR(img_gray, rec_w),
         "KB": os.path.getsize(path_w)/1024})

# Geração da Curva Taxa-Distorção
jpeg_r = [r for r in resultados if r["formato"]=="JPEG"]
webp_r = [r for r in resultados if r["formato"]=="WebP"]
png_r = [r for r in resultados if r["formato"]=="PNG"]

fig, ax = plt.subplots(figsize=(8, 4.5))
ax.plot([r["KB"] for r in jpeg_r], [r["PSNR"] for r in jpeg_r],
        "o-", label="JPEG", color="#D85A30", lw=2, ms=5)
ax.plot([r["KB"] for r in webp_r], [r["PSNR"] for r in webp_r],
        "s-", label="WebP", color="#534AB7", lw=2, ms=5)
ax.axhline(50, color="#1D9E75", lw=2, ls="--",
           label=f"PNG sem perda ({png_r[0]['KB']:.1f} KB)")
ax.axhspan(40, 60, alpha=0.05, color="#1D9E75", label="Qualidade excelente (PSNR>40)")
ax.set(xlabel="Tamanho do arquivo (KB)", ylabel="PSNR (dB)",
       title="Curva Taxa-Distorção: JPEG × WebP × PNG")
ax.legend(fontsize=9)
ax.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()

print(f"\nTamanho bruto (sem compressão): {img_gray.nbytes/1024:.0f} KB")
print(f"\n{'Formato':>8} {'Qual.':>6} {'KB':>7} {'PSNR (dB)':>11}")
print("-"*38)
for r in resultados:
    psnr_s = f"{r['PSNR']:>11.2f}" if r['PSNR']!=float('inf') else f"∞ (lossless)':>11}"
    print(f"{r['formato']:>8} {str(r['qualidade']):>6} {r['KB']:>7.1f} {psnr_s}")

```






Figura 5.28: Curva taxa-distorção: PSNR vs tamanho de arquivo para JPEG, WebP e PNG aplicada à imagem do *Cameraman*.

Tamanho bruto (sem compressão): 64 KB

| Formato      | Qual. | KB   | PSNR (dB)       |
|--------------|-------|------|-----------------|
| <hr/>        |       |      |                 |
| JPEG         | 10    | 2.3  | 28.00           |
| JPEG         | 20    | 3.5  | 30.09           |
| JPEG         | 30    | 4.5  | 31.23           |
| JPEG         | 40    | 5.4  | 32.10           |
| JPEG         | 50    | 6.2  | 32.81           |
| JPEG         | 60    | 7.0  | 33.49           |
| JPEG         | 70    | 8.5  | 34.48           |
| JPEG         | 80    | 10.7 | 36.19           |
| JPEG         | 90    | 15.7 | 40.02           |
| JPEG         | 95    | 22.3 | 44.77           |
| PNG lossless |       | 36.2 | 49.9 (lossless) |
| WebP         | 50    | 4.7  | 34.29           |
| WebP         | 75    | 6.7  | 36.69           |
| WebP         | 90    | 12.5 | 43.14           |

### **i** Tamanho original da imagem

A imagem *Cameraman* ( $256 \times 256$  pixels em escala de cinza) ocupa **64 KB** em formato bruto (sem compressão). Como referência, o PNG *lossless* comprime esse volume para **36,2 KB** — evidenciando que a compressão sem perdas já reduz significativamente o armazenamento para imagens com regiões homogêneas. Em contrapartida, os formatos com perda (JPEG e WebP) atingem tamanhos ainda menores: o JPEG com qualidade 95 ocupa 22,3 KB (PSNR 45 dB), enquanto o WebP com qualidade 90 atinge 12,5 KB com PSNR equivalente, demonstrando sua superioridade em eficiência de compressão.

### 5.8.4.2 Mapeamento Espacial de Erros e Correlação Perceptual

Embora o PSNR ofereça um indicativo numérico rápido, métricas globais falham em discriminar como a perda de informação se distribui geometricamente sobre a imagem. A Figure 5.29 soluciona essa limitação ao associar as reconstruções em diferentes qualidades aos seus respectivos mapas de erro absoluto e ao SSIM.

Os mapas residuais — obtidos pela diferença absoluta normalizada entre a imagem original e a comprimida — revelam a assinatura espacial intrínseca de cada arquitetura de codificação:

- **Em altas qualidades ( $Q = 95$  a  $Q = 75$ ):** As distorções concentram-se predominantemente ao redor de transições abruptas de intensidade (bordas), fruto do espelhamento espectral decorrente do descarte de altas frequências. O índice SSIM permanece próximo à unidade, atestando a integridade das estruturas originais.
- **Em qualidades agressivas ( $Q = 50$  a  $Q = 25$ ):** O erro assume uma estrutura de malha ortogonal regularizada. Esse padrão geométrico evidencia o surgimento dos **artefatos de bloco** (*blocking artifacts*), indicando que a quantização severa corrompeu a correlação espacial entre blocos adjacentes de  $8 \times 8$  pixels.

O SSIM captura essa degradação morfológica de forma muito mais sensível que o PSNR, penalizando o escore final à medida que a organização estrutural e as texturas finas — às quais o sistema visual humano é altamente responsivo — são eliminadas pelo codificador.

```
import os
import numpy as np
import cv2

try:
    from skimage.metrics import structural_similarity as ssim
except ImportError:
    import subprocess
    subprocess.run(["pip", "install", "scikit-image", "-q"])
    from skimage.metrics import structural_similarity as ssim

# Garante a existência do diretório de testes
os.makedirs("imagens/comp_test", exist_ok=True)

qualidades_ssim = [25, 50, 75, 95]
imgs_ssim = [img_gray]
titles_ssim = ["Original"]

for q in qualidades_ssim:
    path = f"imagens/comp_test/camera_ssim_q{q}.jpg"

    # GRAVAÇÃO FORÇADA: Gera e grava o JPEG com a qualidade atual no caminho correto
    img_compactada = jpeg_quality_compress(img_gray, qualidade=q)
    cv2.imwrite(path, img_compactada)

    # Leitura segura do arquivo recém-gravado
    rec = cv2.imread(path, cv2.IMREAD_GRAYSCALE)

    if rec is None:
        continue

    if rec.shape != img_gray.shape:
        rec = cv2.resize(rec, (img_gray.shape[1], img_gray.shape[0]))

    psnr_v = cv2.PSNR(img_gray, rec)
    ssim_v, _ = ssim(img_gray, rec, full=True)

    # Diferença absoluta normalizada para evidenciar a estrutura espacial do erro
```

```

diff_vis = cv2.normalize(np.abs(img_gray.astype(float) - rec.astype(float)),
                        None, 0, 255, cv2.NORM_MINMAX).astype(np.uint8)

imgs_ssim += [rec, diff_vis]
titles_ssim += [f"Q={q}\nPSNR={psnr_v:.1f}dB | SSIM={ssim_v:.3f}",
               f"Mapa de erro (Q={q})\n(Bordas e blocagem)"]

mm.show(imgs_ssim, titles=titles_ssim, cols=3, figsize=(14, 14))

```




Figura 5.29: Análise espacial de degradação: imagens reconstruídas e respectivos mapas de erro absoluto normalizados para diferentes fatores de qualidade JPEG.

### **i** Interpretando os mapas de erro

Os mapas de erro apresentados foram **normalizados individualmente** (`cv2.NORM_MINMAX`) para maximizar o contraste visual e revelar a estrutura espacial das distorções. Isso significa que:

- Em **Q=95**, o erro absoluto é da ordem de **0.5–1.5 níveis de cinza** (imperceptível visualmente), mas a normalização o amplifica para preto-branco para evidenciar sua localização em bordas e transições.
- Em **Q=25**, o erro absoluto é **10–20 vezes maior** (5–15 níveis de cinza), mas a normalização também o leva ao mesmo intervalo [0, 255].

Portanto, **a intensidade do branco nos mapas NÃO é comparável entre diferentes qualidades** — os mapas servem apenas para revelar a **assinatura espacial** do erro (bordas vs blocos), não sua magnitude. A magnitude correta é dada pelos valores de PSNR e SSIM, que mostram claramente que Q=95 tem erro muito menor que Q=25.

## Síntese — Compressão JPEG

O processo de compressão no padrão JPEG baseia-se na aplicação combinada de transformações espaciais, perceptuais e estatísticas para reduzir as redundâncias de uma imagem. A Table 5.9 resume o papel de cada etapa no *pipeline* e seu respectivo impacto na redução de dados.

Tabela 5.9: Síntese das etapas do *pipeline* de compressão JPEG e seus respectivos impactos.

| Etapa                                 | Operação Analítica                                                        | Mecanismo de Ganho / Compressão                                                          |
|---------------------------------------|---------------------------------------------------------------------------|------------------------------------------------------------------------------------------|
| <b>Conversão <math>YC_bC_r</math></b> | Isolamento dos canais de luminância e crominância.                        | Modela a percepção do SVH, permitindo tratar cor e brilho de forma independente.         |
| <b>Subamostragem 4:2:0</b>            | Redução da resolução espacial dos canais de cor ( $C_b$ e $C_r$ ).        | Elimina aproximadamente 50% dos dados brutos com impacto visual mínimo.                  |
| <b>DCT <math>8 \times 8</math></b>    | Mapeamento do domínio espacial para o domínio de frequências espaciais.   | Compactação de energia, concentrando a informação vital nos primeiros coeficientes.      |
| <b>Quantização Linear</b>             | Divisão inteira dos coeficientes por uma matriz de ponderação $Q(u, v)$ . | Principal fonte de compressão com perda; elimina altas frequências imperceptíveis.       |
| <b>Codificação Entrópica</b>          | Aplicação de algoritmos RLE e codificação de Huffman.                     | Compressão estatística sem perda, otimizada pelas longas corridas de coeficientes nulos. |

## Artefatos de Degradação Característicos

A aplicação de taxas de compressão excessivamente agressivas (fatores de qualidade reduzidos) introduz distorções previsíveis na imagem reconstruída, decorrentes das limitações matemáticas do modelo:

- **Artefatos de bloco (*blocking artifacts*):** Descontinuidades geométricas visíveis nas fronteiras dos blocos de  $8 \times 8$  pixels, causadas pela perda de correlação espacial após a quantização severa das componentes AC.
- **Efeito de espalhamento (*ringing*):** Oscilações fantasmas ou distorções de “fumaça” ao redor de bordas nítidas e de alto contraste, provocadas pela eliminação abrupta de harmônicos de alta frequência necessários para reconstruir funções degrau.
- **Perda de textura fina:** Atenuação de detalhes de alta frequência e baixo contraste (como gramados, tecidos ou porosidade), fazendo com que regiões originalmente texturizadas assumam um aspecto excessivamente liso ou homogeneizado.

## 5.9 Aplicação Prática: Remoção de Ruído por Filtragem Híbrida

Reunindo as técnicas consolidadas ao longo deste capítulo, apresenta-se um *pipeline* completo de **restauração de imagens** que combina a análise espectral no domínio da frequência com a filtragem adaptativa no domínio espacial. O objetivo é atenuar um ruído misto (composto por degradação Gaussiana e interferência periódica) preservando ao máximo os detalhes estruturais da imagem original.

Imagem Ruidosa  $\xrightarrow{\text{FFT2}}$   $\xrightarrow{\text{Filtro Notch Gaussiano}}$   $\xrightarrow{\text{IFFT2}}$   $\xrightarrow{\text{Filtro Bilateral}}$  Imagem Restaurada

### i Avaliação Complementar: PSNR vs. SSIM

O par de métricas estatísticas PSNR e SSIM fornece uma avaliação qualitativa e morfológica complementar do processo de restauração:

- **PSNR:** Penaliza uniformemente o desvio quadrático médio pixel a pixel.
- **SSIM:** Avalia a preservação de estruturas locais perceptualmente relevantes (luminância, contraste e contornos).

Na prática, existe um compromisso analítico (*trade-off*) entre **redução de ruído** e **preservação de detalhes**: filtros espaciais excessivamente agressivos atenuam bem o ruído de alta frequência, mas degradam texturas finas e suavizam bordas nítidas — o que **reduz simultaneamente** tanto o PSNR quanto o SSIM em relação à imagem original. O desafio do projeto de filtros é encontrar o ponto de equilíbrio que maximize ambas as métricas, garantindo uma restauração fiel e visualmente agradável.

### 5.9.1 Análise de Desempenho e Conclusão do Capítulo

Os resultados numéricos e visuais gerados pela Figure 5.30 demonstram a relevância prática de associar diferentes domínios de processamento. A inserção simultânea de ruído periódico e estocástico corrompe as propriedades morfológicas do sinal, reduzindo severamente os índices de similaridade e a relação sinal-ruído da imagem de referência.

O isolamento e a supressão dos picos harmônicos no domínio da frequência por meio da máscara *notch* removem as franjas de interferência senoidais espalhadas sobre o espaço bi-dimensional. Como evidenciado nos dados impressos da Figure 5.30, essa filtragem cirúrgica promove um salto imediato e substancial na métrica PSNR. Contudo, o ruído Gaussiano de alta frequência permanece ativo de forma homogênea no espectro, exigindo uma abordagem complementar.

A restauração final é consolidada no domínio espacial com a introdução do filtro bilateral. Diferentemente de operadores passa-baixas convencionais (como o Gaussiano ou de média), que suavizariam indiscriminadamente o ruído e os contornos estruturais, a filtragem bilateral calcula pesos ponderados pela proximidade geométrica e pela diferença de intensidade radiométrica. Esse comportamento adaptativo atenua as flutuações estocásticas remanescentes nas regiões de transição suave e preserva a nitidez das bordas espaciais.

A convergência de ambas as abordagens resulta em uma **melhoria substancial e simultânea** do PSNR e do SSIM em relação à imagem ruidosa — embora os valores finais permaneçam inferiores aos da imagem original (PSNR =  $\infty$ , SSIM = 1,0), devido à perda inevitável de informações espectrais e texturais durante os processos de filtragem. A atenuação suave (gaussiana) dos picos no espectro evita artefatos de *ringing*, enquanto o filtro bilateral elimina o ruído estocástico residual sem comprometer a nitidez das bordas. Os resultados comprovam a eficácia e a complementaridade prática das ferramentas de análise de frequência apresentadas neste capítulo, demonstrando que a filtragem híbrida (frequência + espacial) é superior a qualquer abordagem isolada para a restauração de imagens degradadas por ruído misto.

```
import numpy as np
import cv2

try:
    from skimage.metrics import structural_similarity as ssim_sk
```



```

except ImportError:
    import subprocess
    subprocess.run(["pip", "install", "scikit-image", "-q"])
    from skimage.metrics import structural_similarity as ssim_sk

def suprimir_pico_gaussiano(mask, cy, cx, sigma=3.0):
    yy, xx = np.ogrid[:mask.shape[0], :mask.shape[1]]
    dist = np.sqrt((yy - cy)**2 + (xx - cx)**2)
    notch = np.exp(-dist**2 / (2 * sigma**2))
    mask *= (1 - notch)
    return mask

# 1. Construção do ruído misto
np.random.seed(42)
h_img, w_img = img_gray.shape
X2, Y2 = np.meshgrid(np.arange(w_img), np.arange(h_img))

u0, v0 = 15, 10
ruído_gauss = np.random.normal(0, 15, img_gray.shape)
ruído_period = 30 * np.sin(2 * np.pi * (u0 * X2 / w_img + v0 * Y2 / h_img))
img_noisy = np.clip(img_gray.astype(float) +
                    ruído_gauss + ruído_period, 0, 255).astype(np.uint8)

# 2. Espectro e identificação dos picos
F_n = np.fft.fftshift(np.fft.fft2(img_noisy.astype(np.float64)))
mag_n = cv2.normalize(np.log1p(np.abs(F_n)), None, 0, 255, cv2.NORM_MINMAX).astype(np.uint8)

# 3. Notch gaussiano nos picos periódicos
cy0, cx0 = h_img // 2, w_img // 2
mascara_notch = np.ones((h_img, w_img), dtype=np.float64)
for dy, dx in [(+v0, +u0), (-v0, -u0), (+v0, -u0), (-v0, +u0)]:
    mascara_notch = suprimir_pico_gaussiano(mascara_notch, cy0 + dy, cx0 + dx, sigma=3.0)

img_notch = np.real(np.fft.ifft2(np.fft.ifftshift(F_n * mascara_notch)))
img_notch = np.clip(img_notch, 0, 255).astype(np.uint8)

# 4. Filtro Bilateral: remoção do ruído gaussiano residual
img_den = cv2.bilateralFilter(img_notch, d=7, sigmaColor=25, sigmaSpace=7)

# Cálculo das Métricas de Validação
psnr_n, ssim_n = cv2.PSNR(img_gray, img_noisy), ssim_sk(img_gray, img_noisy)
psnr_no, ssim_no = cv2.PSNR(img_gray, img_notch), ssim_sk(img_gray, img_notch)
psnr_d, ssim_d = cv2.PSNR(img_gray, img_den), ssim_sk(img_gray, img_den)

print(f"{'Etapa':>20} | {'PSNR (dB)':>9} | {'SSIM':>6}")
print("-" * 42)
print(f"{'Ruidosa (gauss+per)':>20} | {psnr_n:>9.2f} | {ssim_n:>6.4f}")
print(f"{'Após notch':>20} | {psnr_no:>9.2f} | {ssim_no:>6.4f}")
print(f"{'Notch + bilateral':>20} | {psnr_d:>9.2f} | {ssim_d:>6.4f}")

mascara_vis = (mascara_notch * 255).astype(np.uint8)
mm.show(
    [img_gray, img_noisy, mag_n, mascara_vis, img_notch, img_den],
    titles=[
        "Original",
        f"Ruidosa\nPSNR={psnr_n:.1f} dB",
        "Espectro\n(picos visíveis)",
        "Máscara notch\n(gaussiana suave)",
        f"Após notch\nPSNR={psnr_no:.1f} dB",
        f"Notch + bilateral\nPSNR={psnr_d:.1f} dB SSIM={ssim_d:.3f}"
    ]
)

```

```
],
cols=6, figsize=(20, 4)
)
```

| Etapa               | PSNR (dB) | SSIM   |
|---------------------|-----------|--------|
| Ruidosa (gauss+per) | 20.19     | 0.3486 |
| Após notch          | 24.47     | 0.4715 |
| Notch + bilateral   | 28.93     | 0.7426 |




Figura 5.30: *Pipeline* completo de remoção de ruído misto: (1) adição de ruído gaussiano e periódico; (2) identificação de picos de interferência no espectro de frequências; (3) aplicação de máscara *notch* com atenuação gaussiana suave; (4) pós-processamento via filtro bilateral para eliminação do ruído estocástico residual.

## 5.10 Resumo do Capítulo

A transição do **domínio espacial** para o **domínio da frequência** revela a distribuição espectral de energia da imagem, estabelecendo a base analítica para a filtragem avançada, restauração e compressão de dados. A articulação estrutural desses conceitos é sintetizada no mapa conceitual da Figure 5.31.

### Fundamentos Essenciais

- **DFT e Percepção Visual:** O espectro decompõe a imagem em componentes harmônicas. A **fase** retém a inteligibilidade geométrica da cena e a localização de contornos, enquanto a **magnitude** dita a distribuição de contraste e amplitudes globais.
- **Eficiência Algorítmica:** O Teorema da Convolução viabiliza o processamento de máscaras de grande escala no domínio da frequência via FFT, reduzindo a complexidade computacional assintótica de  $O(N^2K^2)$  no espaço para  $O(N^2 \log N)$ .
- **Fenômeno de Ringing:** Cortes abruptos no espectro (Filtros Ideais) geram oscilações espaciais indesejadas (fenômeno de Gibbs). A atenuação suave por filtros de **Butterworth** ou **Gaussianos** elimina essas discontinuidades.
- **Análise Multirresolução via Wavelets:** Superando o caráter puramente global de Fourier, a DWT captura a frequência e a localização espacial simultaneamente, fundamentando o padrão JPEG 2000 e subsidiando representações hierárquicas análogas às extrações de feições em Redes Neurais Convolucionais (CNNs).
- **Compressão Perceptual (DCT):** O *pipeline* JPEG explora as limitações de contraste do sistema visual humano em altas frequências espaciais. A DCT isola a energia de blocos  $8 \times 8$ , permitindo que a quantização descarte coeficientes AC de detalhes finos sem prejuízo perceptual severo.

**Próximos Passos:** O Capítulo 6 inaugura a Parte II da obra, aplicando as ferramentas de processamento de imagens na resolução de problemas reais de inspeção industrial. Serão exploradas técnicas de **segmentação e análise de formas** para a detecção automática de falhas em linhas de produção — desde a identificação de defeitos superficiais em peças até a leitura *QRCode* em provas, consolidando a ponte entre a teoria apresentada na Parte I e as demandas práticas da visão computacional.






Figura 5.31: Mapa conceitual das transformações e propriedades no domínio da frequência.

## 5.11 Uso do Gemini Notebook como Tutor Complementar

Nesta edição, incentiva-se o uso da plataforma **Gemini Notebook** como ferramenta complementar de aprendizagem — **não como substituta** da leitura atenta, da resolução de exercícios ou da experimentação prática. Baseado em arquiteturas de inteligência artificial, o sistema utiliza exclusivamente o material didático e os documentos fornecidos pelo autor como base de conhecimento, assegurando que as respostas geradas estejam conceitualmente alinhadas ao conteúdo programático e à abordagem pedagógica adotada ao longo desta obra.

Acesso ao Tutor Inteligente

 [ACESSAR Gemini Notebook: CAPÍTULO 05](#)

### Diretrizes sobre o Conteúdo Gerado por Inteligência Artificial

Embora as ferramentas de inteligência artificial constituam aliados eficientes no processo de aprendizagem e revisão, o conteúdo gerado está sujeito a inconsistências ou imprecisões técnicas. Desse modo, é indispensável a consulta sistemática a livros-texto, artigos científicos e fontes acadêmicas indexadas para a validação rigorosa das informações. Recomenda-se veementemente a execução e a modificação dos exemplos práticos em Python fornecidos neste capítulo como método primário de verificação experimental dos resultados.

## 5.12 Lista de Exercícios

1. **(10%) Implementação Direta da DFT 2D:** Implemente analiticamente a Transformada Discreta de Fourier 2D (DFT) sem o auxílio de funções nativas de bibliotecas (como `np.fft.fft2`), utilizando estritamente a formulação matemática definida na Equation 5.1 para uma matriz de dimensões  $16 \times 16$ . Realize a validação numérica comparando os coeficientes gerados com os resultados da função `np.fft.fft2`, certificando-se de que o desvio absoluto máximo seja inferior a  $10^{-8}$ . Mensure os tempos de execução de ambos os métodos e apresente uma justificativa teórica para a disparidade observada em termos de complexidade assintótica.
2. **(15%) Supressão de Ruído Periódico:** Adicione interferências senoidais com frequências espaciais  $(u_0, v_0) \in \{(5, 10), (20, 5), (30, 30)\}$  à imagem de teste do *Camerman*. Para cada cenário de degradação, projete uma máscara de filtragem *notch* específica no domínio da frequência para isolar e atenuar os picos harmônicos indesejados. Avalie quantitativamente a eficácia do processo de restauração por meio do cálculo das métricas de PSNR e SSIM. Discuta analiticamente o compromisso (*trade-off*) entre a atenuação do ruído senoidal e a indesejada atenuação de feições estruturais legítimas da imagem.
3. **(15%) Análise Comparativa de Operadores Passa-Baixa:** Realize um estudo comparativo entre os filtros passa-baixa Ideal, Gaussiano e Butterworth (com ordens harmônicas  $n = 1, 2, 4$ ), parametrizados com frequências de corte  $D_0 = 20, 40, 60$  pixels. Para cada combinação estrutural, calcule os índices PSNR e SSIM da imagem resultante frente ao sinal original de referência. Organize os dados quantitativos em uma tabela estruturada e plote os gráficos unidimensionais das funções de transferência correspondentes ao longo do perfil horizontal  $H(u, 0)$ .
4. **(15%) Banco de Filtros Multirresolução de Haar:** Desenvolva um script para executar manualmente a decomposição *wavelet* discreta 2D de primeiro nível utilizando a família Haar. O algoritmo deve calcular os coeficientes dos filtros correspondentes passa-baixa ( $h$ ) e passa-alta ( $g$ ), aplicando-os de forma separável sobre as linhas e colunas da matriz, seguidos pela operação de decimação (subamostragem espacial por um fator de 2). Valide numericamente a exatidão da sua implementação confrontando as subbandas obtidas com a saída da função `pywt.dwt2(img, 'haar')`.
5. **(15%) Compressão Esparsa por Limiarização Wavelet:** Aplique a técnica de filtragem por limiarização abrupta (*hard thresholding*) sobre os coeficientes de detalhe da decomposição *wavelet*,

adotando os limiares numéricos  $T \in \{5, 10, 20, 40, 80\}$  para as famílias Haar, Daubechies (db4) e Symlets (sym4). Após realizar o processo de síntese por meio da transformada inversa (`pywt.waverec2`), compute os valores de PSNR e SSIM de cada imagem reconstruída. Identifique e justifique qual combinação de família *wavelet* e limiar  $T$  maximiza a similaridade estrutural.

6. **(15%) Construção de Codificador JPEG Simplificado:** Implemente o pipeline completo de compressão de dados simulando o padrão JPEG. O fluxo deve englobar: conversão espacial  $RGB \rightarrow YC_bC_r$ , subamostragem cromática na proporção 4:2:0, segmentação da luminância em blocos disjuntos de  $8 \times 8$  pixels, aplicação da DCT-II 2D ortogonal, e quantização linear baseada na matriz normalizada de luminância escalada por fatores de qualidade desejados. Realize a decodificação inversa e compare quantitativamente as reconstruções com os arquivos gerados pela função `cv2.imencode` para os fatores de qualidade de 20, 50 e 80.
7. **(15%) Análise Perceptual em Conteúdos Heterogêneos:** Desenvolva uma imagem sintética composta por três regiões distintas e de características espectrais contrastantes: uma textura fotográfica complexa (representando altas frequências estocásticas), uma área de texto vetorizado com bordas nítidas (representando transições de grau puras) e um gradiente linear contínuo (representando baixas frequências homogêneas). Submeta essa imagem mista aos processos de compressão sob os formatos JPEG, PNG e WebP. Avalie e interprete os resultados correlacionando o tamanho final do arquivo em disco às métricas PSNR e SSIM obtidas, justificando qual formato exibe o melhor desempenho para sinais de natureza heterogênea e por que essa vantagem ocorre em termos de compactação de energia e preservação perceptual.

## Referências do Capítulo

A fundamentação teórica e o desenvolvimento analítico dos conceitos abordados neste capítulo fundamentam-se nas seguintes obras de referência:

- **Gonzalez; Woods (2018)** — Formulações clássicas de Transformadas Discretas de Fourier 2D (DFT), projeto de filtros analíticos no domínio da frequência, Transformada Discreta de Cossenos (DCT) e princípios fundamentais de sistemas de compressão de imagens.
- **Oppenheim; Schaffer (2010)** — Teoria formal de sinais e sistemas aplicados no domínio discreto, cobrindo as propriedades matemáticas da DFT e a modelagem analítica do Teorema da Convolução.
- **Mallat (1999)** — Fundamentação matemática da teoria de *wavelets*, formalização da análise multirresolução (MRA) e arquitetura de bancos de filtros diádicos.
- **Wallace (1991)** — Especificação original e aspectos de engenharia do padrão de compressão ISO/IEC JPEG, com ênfase nos critérios psicovisuais para o projeto de matrizes de quantização DCT.
- **Szeliski (2022)** — Modelagem computacional e caracterização de métricas modernas de fidelidade e qualidade perceptual (PSNR e SSIM), bem como a análise comparativa de formatos de imagem rasterizados de alto desempenho.



### 5.13 Parte Prática com Exercícios de Programação

#### Em construção!

A presente lista de exercícios de programação (EP) consolida as formulações teóricas apresentadas ao longo do Capítulo 5 — Transformadas e Compressão — por meio de uma trilha prática aplicada. Os exercícios são estruturados a partir de matrizes de dimensões reduzidas, viabilizando a validação analítica e a inspeção manual de cada coeficiente, mantendo a consistência metodológica adotada nos capítulos anteriores.

O encadeamento dos exercícios reproduz rigorosamente o fluxo conceitual do capítulo: inicia-se com a implementação explícita da Transformada Discreta de Fourier (DFT) a partir de sua definição matemática

fundamental; avança-se para o projeto de filtros passa-baixa e máscaras *notch* no domínio da frequência; aplica-se a quantização de coeficientes (núcleo da compressão com perda); e conclui-se com a integração dessas etapas na construção de um *pipeline* de compressão JPEG simplificado e na análise perceptual de formatos de imagem.

### ! Diretrizes para a Resolução dos Exercícios de Programação

Em todos os exercícios deste capítulo, as coordenadas do **centro do espectro** (origem das frequências espaciais pós-aplicação do deslocamento `fftshift`) devem ser determinadas via divisão inteira. Para uma matriz com  $L$  linhas e  $C$  colunas, a componente de frequência nula localiza-se na posição:

$$(c_y, c_x) = \left( \left\lfloor \frac{L}{2} \right\rfloor, \left\lfloor \frac{C}{2} \right\rfloor \right)$$

Esta convenção é rigorosamente idêntica à adotada pela função `np.fft.fftshift`. Ademais, em todas as etapas que exijam discretização ou arredondamento numérico (seja na quantização de coeficientes AC ou na reconstrução final de pixels), deve-se empregar o arredondamento padrão para o inteiro mais próximo (*round half away from zero*), mitigando ambiguidades em valores com fração exatamente igual a 0.5.

## 🎯 Objetivo deste Caderno

O caderno permite desenvolver, validar, organizar e testar soluções de **Exercícios de Programação (EPs)** em ambientes interativos, como o Colab, com os mesmos casos de teste do Moodle, copiando para lá apenas na hora de registrar a nota oficial.

### Download

Baixe `morph.py` e `testsuite.py` executando a célula abaixo:

```
import os, sys, importlib, inspect, urllib.request

# URLs do repositório
BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph"
for f in ["morph.py", "testsuite.py"]:
    if not os.path.exists(f):
        urllib.request.urlretrieve(f"{BASE_URL}/{f}", f)

import morph, testsuite
importlib.reload(morph); importlib.reload(testsuite)
from morph import mm
from testsuite import TestSuite

print(f" Ambiente pronto. Morph: {morph.__version__} | TestSuite: {testsuite.__version__}")
```

Ambiente pronto. Morph: 1.1.2 | TestSuite: 1.1.2

### Executando os Testes

Para avaliar os testes, execute `TestSuite("EP05_01.extensão").run()` numa nova célula, trocando a extensão pela da linguagem usada (`.py`, `.java`, `.c`, `.cpp`, `.js` ou `.r`). O sistema baixa os casos de teste do GitHub, executa o programa e calcula a nota automaticamente.

Para testar código Python diretamente, sem salvar arquivo, use `run_code(codigo)` passando o código como *string* numa variável `codigo`:

```

codigo = """
from morph import mm
# ... seu código aqui ...
"""
TestSuite("EP05_01").run_code(codigo)

```

### 5.13.1 EP05\_01 Filtro Passa-Baixa Ideal por Distância no Espectro

Em um *scanner de documentos antigo*, o sensor capta papel amassado e textura de fibra junto com o texto — ruído de alta frequência que “polui” o espectro nas bordas. O técnico de manutenção não tem acesso à imagem original, apenas ao **espectro de magnitude já calculado** pelo software do *scanner*. Seu trabalho é simples e cirúrgico: manter apenas o **círculo central** de baixas frequências (a estrutura global do documento) e apagar tudo que estiver fora do raio  $D_0$ , eliminando a textura fina sem nem precisar tocar na imagem espacial.

Este é o **Filtro Passa-Baixa Ideal (LPFI)**: a operação espectral mais direta do capítulo, mas também a que melhor revela a anatomia de um espectro centrado.

#### 5.13.1.1 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas) do espectro de magnitude — já fornecido **centrado** (equivalente à saída de `np.fft.fftshift`).
2. **Frequência de corte:** Ler o inteiro  $D_0$ .
3. **Dados:** Ler os valores inteiros da matriz de magnitude, linha a linha.
4. **Centro do espectro:** Calcular  $(c_y, c_x) = (L // 2, C // 2)$ .
5. **Distância:** Para cada posição  $(u, v)$ , calcular

$$D(u, v) = \sqrt{(u - c_y)^2 + (v - c_x)^2}$$

6. **Máscara ideal:** Aplicar

$$H(u, v) = \begin{cases} 1, & D(u, v) \leq D_0 \\ 0, & D(u, v) > D_0 \end{cases}$$

7. **Filtragem:** O valor de saída é  $\text{mag}'(u, v) = \text{mag}(u, v) \cdot H(u, v)$ .
8. **Saída:** Exibir a matriz filtrada com dimensões  $L \times C$ .

#### 5.13.1.2 Restrições Computacionais

- **Comparação não estrita:** o critério usa  $D(u, v) \leq D_0$  (a fronteira pertence ao filtro, ou seja, é mantida).
- **Tipo:** todos os valores de entrada e saída são inteiros; a distância é calculada em ponto flutuante apenas internamente.
- **Sem arredondamento de magnitude:** como a entrada já é inteira e a máscara é binária (0 ou 1), a saída nunca precisa de arredondamento.

#### 5.13.1.3 Fundamentação Teórica

| Região                         | Distância ao centro | Efeito do filtro                          |
|--------------------------------|---------------------|-------------------------------------------|
| <b>Centro</b> ( $D \leq D_0$ ) | Baixas frequências  | Preservadas — estrutura global mantida    |
| <b>Bordas</b> ( $D > D_0$ )    | Altas frequências   | Zeradas — textura e ruído removidos       |
| $D_0$ pequeno                  | —                   | Imagem reconstruída ficaria muito borrada |

| Região       | Distância ao centro | Efeito do filtro                               |
|--------------|---------------------|------------------------------------------------|
| $D_0$ grande | —                   | Pouca filtragem; quase toda energia preservada |

#### 5.13.1.4 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Inteiro  $D_0$ .
- Linhas seguintes: Elementos inteiros da matriz de magnitude (centrada).

##### Saída:

- Matriz filtrada em  $L$  linhas e  $C$  colunas, separados por espaço.

#### 5.13.1.5 Exemplos

| Entrada  | Saída    | Observação                                                                                                                              |
|----------|----------|-----------------------------------------------------------------------------------------------------------------------------------------|
| 3        | 0 20 0   | Centro $(1, 1)$ . Cantos têm $D = \sqrt{2} \approx 1.41 > 1$ , logo são zerados; vizinhos ortogonais têm $D = 1 \leq 1$ e são mantidos. |
| 3        | 40 50 60 |                                                                                                                                         |
| 1        | 0 80 0   |                                                                                                                                         |
| 10 20 30 |          |                                                                                                                                         |
| 40 50 60 |          |                                                                                                                                         |
| 70 80 90 |          |                                                                                                                                         |
| 1        | 0 9 0    | $L = 1, C = 3$ : centro em $(0, 1)$ . Apenas a própria posição central ( $D = 0$ ) sobrevive a $D_0 = 0$ .                              |
| 3        |          |                                                                                                                                         |
| 0        |          |                                                                                                                                         |
| 5 9 7    |          |                                                                                                                                         |

```
%%writefile EP05_01.py
# Código Python
```

```
Writing EP05_01.py
```

```
TestSuite("EP05_01.py").run()
```

#### 5.13.2 EP05\_02 Filtro *Notch*: Removendo Picos Periódicos

Uma câmera de **inspeção industrial** captura imagens de placas de circuito, mas a fonte de alimentação da linha de produção introduz uma **interferência elétrica periódica** — um padrão de listras quase imperceptível a olho nu, mas que aparece no espectro de Fourier como **pares de picos brilhantes** simetricamente posicionados em torno do centro. A equipe de visão computacional não pode reprocessar a captura: precisa **localizar e apagar cirurgicamente** esses pares de picos no espectro, preservando todo o resto da informação útil da imagem.

Esse é o papel do **filtro rejeita-banda *notch***: diferente do passa-baixa (que afeta uma região contínua), ele ataca **pontos específicos e seus simétricos**, deixando o restante do espectro intocado.






Figura 5.32: Simulador: Filtro Passa-Baixa Ideal no Espectro

### 5.13.2.1 📋 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas) do espectro de magnitude centrado.
2. **Dados:** Ler os valores inteiros da matriz de magnitude, linha a linha.
3. **Picos:** Ler o inteiro  $K$  (quantidade de pares de picos a remover).
4. **Para cada um dos  $K$  picos:** ler três inteiros  $\Delta v$ ,  $\Delta u$ ,  $r$  — deslocamento vertical, deslocamento horizontal e raio do *notch*.
5. **Centro do espectro:**  $(c_y, c_x) = (L // 2, C // 2)$ .
6. **Supressão simétrica:** para cada pico, zerar **todas** as posições  $(u, v)$  tais que a distância ao ponto  $(c_y + \Delta v, c_x + \Delta u)$  for  $\leq r$ , e **também** todas as posições com distância  $\leq r$  ao ponto simétrico  $(c_y - \Delta v, c_x - \Delta u)$ .
7. **Saída:** Exibir a matriz resultante com dimensões  $L \times C$ .

### 5.13.2.2 📌 Restrições Computacionais

- **Simetria obrigatória:** cada pico informado gera **dois** discos zerados (o ponto e seu simétrico em relação ao centro) — esquecer o simétrico é o erro mais comum.
- **Sobreposição:** se dois discos se sobrepõem, a posição permanece zerada (não há “soma” ou restauração).
- **Comparação não estrita:** uma posição é zerada se distância  $\leq r$ .
- **Ordem de leitura:** os  $K$  picos devem ser processados na ordem em que aparecem na entrada, mas o resultado final independe da ordem (operações de zerar são comutativas).

### 5.13.2.3 🧠 Fundamentação Teórica

| Conceito                                        | Papel no filtro <i>notch</i>                                                                                   |
|-------------------------------------------------|----------------------------------------------------------------------------------------------------------------|
| <b>Pico em</b> $(\Delta v, \Delta u)$           | Frequência da interferência periódica detectada visualmente no espectro                                        |
| <b>Ponto simétrico</b> $(-\Delta v, -\Delta u)$ | Toda DFT de sinal real é hermitiana: picos sempre aparecem em pares simétricos ao centro                       |
| <b>Raio</b> $r$                                 | Controla a “largura” da rejeição — $r$ grande remove mais energia ao redor do pico, mas também informação útil |

#### 5.13.2.4 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linhas seguintes: Elementos inteiros da matriz de magnitude (centrada),  $L$  linhas.
- Próxima linha: Inteiro  $K$ .
- $K$  linhas seguintes: três inteiros  $\Delta v$ ,  $\Delta u$ ,  $r$  (separados por espaço).

##### Saída:

- Matriz resultante em  $L$  linhas e  $C$  colunas, separados por espaço.

#### 5.13.2.5 Exemplos

| Entrada        | Saída          | Observação                                                                                                                                                                                              |
|----------------|----------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 5              | 1 2 3 4 5      | Centro $(c_y, c_x) = (2, 2)$ . Pico informado $(\Delta v, \Delta u) = (1, 1)$ gera o ponto $(3, 3)$ (valor 19) e seu simétrico $(1, 1)$ (valor 7), ambos zerados com $r = 0$ (apenas os pontos exatos). |
| 5              | 6 0 8 9 10     |                                                                                                                                                                                                         |
| 1 2 3 4 5      | 11 12 13 14 15 |                                                                                                                                                                                                         |
| 6 7 8 9 10     | 16 17 18 0 20  |                                                                                                                                                                                                         |
| 11 12 13 14 15 | 21 22 23 24 25 |                                                                                                                                                                                                         |
| 16 17 18 19 20 |                |                                                                                                                                                                                                         |
| 21 22 23 24 25 |                |                                                                                                                                                                                                         |
| 1              |                |                                                                                                                                                                                                         |
| 1 1 0          |                |                                                                                                                                                                                                         |

```

%writefile EP05_02.py
# Código Python

```

```
Writing EP05_02.py
```

```
TestSuite("EP05_02.py").run()
```

#### 5.13.3 EP05\_03 Quantização DCT: a Verdadeira Fonte de Compressão

Um aplicativo de **galeria de fotos** precisa reduzir o tamanho de milhares de imagens antes de fazer *upload* para a nuvem, sem recodificar tudo do zero. O engenheiro responsável já tem os **coeficientes DCT** de cada bloco  $4 \times 4$  calculados (a etapa cara computacionalmente já foi feita) — falta apenas aplicar a **tabela de quantização**, a etapa que realmente descarta informação e gera compressão. Coeficientes de alta frequência, menos perceptíveis ao olho humano, recebem divisores grandes e tendem a virar **zero**; coeficientes de baixa frequência, mais perceptíveis, recebem divisores pequenos e sobrevivem quase intactos.




Figura 5.33: Simulador: Filtro Notch

Você vai implementar exatamente essa etapa: **quantizar e desquantizar** (dividir, arredondar, multiplicar de volta) — o coração da compressão *lossy* do JPEG.

#### 5.13.3.1 Diretrizes de Implementação

1. **Dimensão do bloco:** Ler o inteiro  $N$  (bloco  $N \times N$ ).
2. **Coefficientes:** Ler a matriz  $C$  de coeficientes DCT,  $N$  linhas com  $N$  inteiros cada (podem ser negativos).
3. **Tabela de quantização:** Ler a matriz  $Q$ ,  $N$  linhas com  $N$  inteiros positivos cada.
4. **Quantização:** Para cada posição  $(u, v)$ , calcular o índice quantizado

$$\tilde{C}(u, v) = \text{round}\left(\frac{C(u, v)}{Q(u, v)}\right)$$

usando arredondamento padrão para o inteiro mais próximo (valores intermediários .5 nunca ocorrem nos casos de teste).

5. **Desquantização (reconstrução):** Calcular

$$C'(u, v) = \tilde{C}(u, v) \times Q(u, v)$$

6. **Saída:** Exibir a matriz reconstruída  $C'$ ,  $N \times N$ , inteiros.

#### 5.13.3.2 Restrições Computacionais

- **Round-trip completo:** a saída é o coeficiente **reconstruído** ( $\tilde{C} \times Q$ ), não o índice quantizado isolado.
- **Divisão em ponto flutuante:** a divisão  $C(u, v)/Q(u, v)$  deve ser feita em ponto flutuante antes do arredondamento — divisão inteira truncada produzirá resultado incorreto.
- **Sinal preservado:** coeficientes negativos mantêm o sinal após quantização e reconstrução.
- $Q(u, v) > 0$  **sempre:** não há necessidade de tratar divisão por zero.

### 5.13.3.3 🧠 Fundamentação Teórica

| Coeficiente          | Frequência          | Valor típico de $Q$ | Efeito da quantização                             |
|----------------------|---------------------|---------------------|---------------------------------------------------|
| $C(0,0)$             | DC (média do bloco) | Pequeno             | Quase sempre sobrevive<br>— domina a energia      |
| $C(u,v)$ baixo $u+v$ | Baixa frequência    | Pequeno/médio       | Parcialmente preservado                           |
| $C(u,v)$ alto $u+v$  | Alta frequência     | Grande              | Frequentemente vira zero<br>— fonte da compressão |

### 5.13.3.4 📦 Especificação de Entrada e Saída (VPL)

#### Entrada:

- Linha 1: Inteiro  $N$ .
- $N$  linhas seguintes: matriz  $C$  (coeficientes DCT, inteiros, podem ser negativos).
- $N$  linhas seguintes: matriz  $Q$  (tabela de quantização, inteiros positivos).

#### Saída:

- Matriz reconstruída  $C'$ ,  $N \times N$ , inteiros separados por espaço.

### 5.13.3.5 📌 Exemplos

| Entrada    | Saída      | Observação                                               |
|------------|------------|----------------------------------------------------------|
| 4          | 50 10 -7 0 | $C(0,0) = 50/2 = 25 \rightarrow 25 \times 2 = 50$        |
| 50 10 -5 0 | 8 0 0 0    | (preservado). $C(0,2) = -5/7 \approx$                    |
| 8 -3 2 1   | 0 0 0 0    | $-0.71 \rightarrow -1 \rightarrow -1 \times 7 = -7$ . Já |
| 0 1 0 0    | 0 0 0 0    | $C(1,1) = -3/7 \approx -0.43 \rightarrow 0$ :            |
| 2 0 0 -1   |            | zerado pela quantização — a                              |
| 2 5 7 8    |            | maior parte do bloco vira zero,                          |
| 4 7 8 11   |            | ilustrando a compactação de                              |
| 6 8 11 12  |            | energia no canto superior                                |
| 9 11 12 14 |            | esquerdo.                                                |

```
%%writefile EP05_03.py
# Código Python
```

```
Writing EP05_03.py
```

```
TestSuite("EP05_03.py").run()
```

### 5.13.4 EP05\_04 📌 Implementando a DFT 2D a Partir da Definição

Um laboratório de pesquisa em **astronomia computacional** recebeu, de uma missão antiga, um pequeno sensor experimental cujos dados brutos não podem ser processados por bibliotecas modernas de FFT — o ambiente de validação é isolado e só permite operações aritméticas básicas. A equipe precisa **reimplementar a Transformada de Fourier Discreta 2D a partir da própria definição matemática**, célula por célula, para depois comparar bit a bit com `np.fft.fft2` em outro ambiente.

Este é o exercício mais conceitual da lista: não há atalhos. Você vai implementar o duplo somatório da Equation 5.1 diretamente, evidenciando *por que* a FFT existe — e o custo computacional que ela evita.



Figura 5.34: Simulador: Quantização DCT (round-trip)

#### 5.13.4.1 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $M$  (linhas) e  $N$  (colunas) da imagem  $f(x, y)$ .
2. **Dados:** Ler os valores inteiros de  $f(x, y)$ , linha a linha.
3. **DFT 2D:** Para cada par de frequências  $(u, v)$  com  $u = 0, \dots, M-1$  e  $v = 0, \dots, N-1$ , calcular

$$F(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) e^{-j2\pi(\frac{ux}{M} + \frac{vy}{N})}$$

usando a identidade de Euler  $e^{-j\theta} = \cos(\theta) - j\sin(\theta)$  para separar parte real e imaginária — **não utilize nenhuma função de FFT pronta.**

4. **Magnitude:** Calcular  $|F(u, v)| = \sqrt{\text{Re}(F)^2 + \text{Im}(F)^2}$  e arredondar para o inteiro mais próximo.
5. **Saída:** Exibir a matriz de magnitudes arredondadas,  $M \times N$ , na mesma ordem (sem `fftshift` — o DC permanece em  $(0, 0)$ ).

#### 5.13.4.2 Restrições Computacionais

- **Proibido usar bibliotecas de FFT:** a implementação deve calcular os somatórios duplos explicitamente (laços aninhados), mesmo que mais lenta.
- **Sem `fftshift`:** a saída mantém a convenção crua da DFT, com o componente DC em  $F(0, 0)$  (canto superior esquerdo).
- **Arredondamento:** a magnitude final deve ser arredondada para o inteiro mais próximo; nos casos de teste não há ambiguidade .5.
- **Precisão:** pequenos erros de ponto flutuante (ordem de  $10^{-6}$ ) antes do arredondamento são esperados e não afetam o resultado inteiro final.

#### 5.13.4.3 Fundamentação Teórica

| Elemento                         | Significado                                                                                                  |
|----------------------------------|--------------------------------------------------------------------------------------------------------------|
| $F(0,0)$                         | Componente DC — soma de todos os pixels,<br>$F(0,0) = \sum f(x,y)$                                           |
| Parte real $\text{Re}(F)$        | Projeção do sinal sobre cossenos                                                                             |
| Parte imaginária $\text{Im}(F)$  | Projeção do sinal sobre senos                                                                                |
| Complexidade desta implementação | $\mathcal{O}((MN)^2)$ — por isso a FFT, com<br>$\mathcal{O}(MN \log(MN))$ , é indispensável em imagens reais |

5.13.4.4 📦 Especificação de Entrada e Saída (VPL)

Entrada:

- Linha 1: Inteiro  $M$ .
- Linha 2: Inteiro  $N$ .
- Linhas seguintes: Elementos inteiros de  $f(x,y)$ ,  $M$  linhas.

Saída:

- Matriz de magnitudes  $|F(u,v)|$  arredondadas,  $M \times N$ , separadas por espaço.

5.13.4.5 📌 Exemplos

| Entrada | Saída | Observação                                                  |
|---------|-------|-------------------------------------------------------------|
| 2       | 10 2  | $F(0,0) = 1 + 2 + 3 + 4 = 10$ (DC = soma total). $F(0,1) =$ |
| 2       | 4 0   | $(1 - 2) + (3 - 4) = -2 \rightarrow  F  = 2$ .              |
| 1 2     |       | $F(1,0) = (1 + 2) - (3 + 4) =$                              |
| 3 4     |       | $-4 \rightarrow  F  = 4$ .                                  |
|         |       | $F(1,1) = (1 - 2) - (3 - 4) = 0$ .                          |



Figura 5.35: Simulador: DFT 2D manual

```
%%writefile EP05_04.py
# Código Python
```



```
Writing EP05_04.py
```

```
TestSuite("EP05_04.py").run()
```

### 5.13.5 EP05\_05 🏆 *Pipeline* JPEG Completo: DCT, Quantização e Reconstrução

Você foi contratado para criar, do zero, um **codec JPEG didático** em ambiente embarcado, sem qualquer biblioteca de imagem disponível — apenas operações matemáticas básicas. O cliente quer entender exatamente onde a qualidade é perdida e onde ela é recuperada, bloco por bloco. Este é o desafio final do capítulo: integrar **tudo** o que foi estudado — a DCT-II ortonormal, a quantização perceptual e a reconstrução via IDCT — em um único *pipeline* de ponta a ponta, processando um bloco  $N \times N$  do início ao fim, exatamente como o padrão JPEG faz internamente,  $8 \times 8$  pixels de cada vez.

#### 5.13.5.1 📋 Diretrizes de Implementação

1. **Dimensão do bloco:** Ler o inteiro  $N$ .
2. **Bloco original:** Ler a matriz de pixels  $f(x, y)$ ,  $N$  linhas com  $N$  inteiros em  $[0, 255]$ .
3. **Tabela de quantização:** Ler a matriz  $Q$ ,  $N \times N$  inteiros positivos.
4. **Centralização:** Subtrair 128 de cada pixel:  $g(x, y) = f(x, y) - 128$ .
5. **DCT-II 2D ortonormal:** Calcular

$$C(u, v) = \alpha(u) \alpha(v) \sum_{x=0}^{N-1} \sum_{y=0}^{N-1} g(x, y) \cos \left[ \frac{\pi(2x+1)u}{2N} \right] \cos \left[ \frac{\pi(2y+1)v}{2N} \right]$$

com  $\alpha(0) = \sqrt{1/N}$  e  $\alpha(k) = \sqrt{2/N}$  para  $k > 0$ .

6. **Quantização:**  $\tilde{C}(u, v) = \text{round}(C(u, v)/Q(u, v))$ .
7. **Desquantização:**  $C'(u, v) = \tilde{C}(u, v) \times Q(u, v)$ .
8. **IDCT-II 2D (inversa ortonormal):** Calcular  $g'(x, y)$  a partir de  $C'(u, v)$  usando a transformada inversa correspondente (mesma base, somatório sobre  $u, v$ ).
9. **Reversão da centralização e arredondamento:**  $f'(x, y) = \text{round}(g'(x, y) + 128)$ , restrito ao intervalo  $[0, 255]$  (*clipping*).
10. **Saída:** Exibir o bloco reconstruído  $f'$ ,  $N \times N$ , inteiros.

#### 5.13.5.2 📌 Restrições Computacionais

- **Pipeline completo obrigatório:** todas as seis etapas (centralizar, DCT, quantizar, desquantizar, IDCT, reverter) devem ser implementadas — pular a quantização não passa nos testes, pois o resultado seria idêntico ao original.
- **Clipping:** valores reconstruídos fora de  $[0, 255]$  devem ser truncados (0 se negativo, 255 se maior que 255).
- **Arredondamento:** tanto na quantização quanto na reconstrução final dos pixels, use arredondamento padrão; os casos de teste evitam ambiguidade .5.
- **Base ortonormal:** a normalização  $\alpha(u)$  e  $\alpha(v)$  deve ser aplicada exatamente como especificado — sem ela, a IDCT não reconstrói corretamente.

#### 5.13.5.3 🧠 Fundamentação Teórica

| Etapas        | Análoga no padrão JPEG real               | Onde a qualidade é perdida                       |
|---------------|-------------------------------------------|--------------------------------------------------|
| Centralização | Mesma — DCT assume sinal centrado em zero | Nenhuma perda                                    |
| DCT-II        | Etapas 3–4 do <i>pipeline</i> (Table 5.7) | Nenhuma perda (transformação exata e reversível) |

| Etapa       | Análoga no padrão JPEG real     | Onde a qualidade é perdida                                                   |
|-------------|---------------------------------|------------------------------------------------------------------------------|
| Quantização | Etapa 5 — divisão por $Q(u, v)$ | <b>Principal fonte de perda</b> — coeficientes de alta frequência viram zero |
| IDCT        | Reconstrução final              | Reconstrói exatamente os coeficientes <i>quantizados</i> , não os originais  |

#### 5.13.5.4 📦 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: Inteiro  $N$ .
- $N$  linhas seguintes: bloco original  $f(x, y)$ , inteiros em  $[0, 255]$ .
- $N$  linhas seguintes: tabela de quantização  $Q$ , inteiros positivos.

##### Saída:

- Bloco reconstruído  $f'(x, y)$ ,  $N \times N$ , inteiros em  $[0, 255]$ , separados por espaço.

#### 5.13.5.5 📌 Exemplos

| Entrada         | Saída           | Observação                                                                                                                                                                                                                                       |
|-----------------|-----------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 4               | 118 126 119 131 | Após DCT, quantização agressiva nas altas frequências (valores grandes de $Q$ no canto inferior direito) e reconstrução via IDCT, o bloco fica <b>próximo</b> do original, mas não idêntico — a diferença é o custo da compressão <i>lossy</i> . |
| 120 130 125 128 | 114 143 140 119 |                                                                                                                                                                                                                                                  |
| 115 140 135 122 | 117 149 159 130 |                                                                                                                                                                                                                                                  |
| 118 150 160 130 | 107 121 146 139 |                                                                                                                                                                                                                                                  |
| 110 120 145 138 |                 |                                                                                                                                                                                                                                                  |
| 4 6 8 10        |                 |                                                                                                                                                                                                                                                  |
| 6 8 10 12       |                 |                                                                                                                                                                                                                                                  |
| 8 10 12 16      |                 |                                                                                                                                                                                                                                                  |
| 10 12 16 20     |                 |                                                                                                                                                                                                                                                  |

#### 5.13.5.6 💡 Dica de Depuração

Se o resultado não bater, verifique nesta ordem: (1) os coeficientes DCT brutos (antes da quantização) — eles devem reconstruir o original **exatamente** via IDCT se você pular a etapa 6–7; (2) a tabela  $\alpha(u)$  — erro comum é aplicar  $\sqrt{2/N}$  também para  $u = 0$ ; (3) o arredondamento da quantização, que deve ocorrer **antes** de multiplicar de volta por  $Q$ .

```
%%writefile EP05_05.py
# Código Python
```

```
Writing EP05_05.py
```

```
TestSuite("EP05_05.py").run()
```




Figura 5.36: Simulador: *Pipeline* JPEG completo em bloco

## Parte II

# Parte II — Visão Computacional

## Capítulo 6

# Análise de Documentos e Inspeção Industrial



Na **Parte I — Processamento Digital de Imagens (PDI)**, foram estudadas técnicas para transformação e aprimoramento de imagens, como operações morfológicas, filtragem espacial, convoluções, limiarização, segmentação e processamento no domínio da frequência.

A **Parte II — Visão Computacional (VC)** amplia esse escopo ao tratar da interpretação automática do conteúdo visual, envolvendo a extração de informações, o reconhecimento de padrões e a tomada de decisões a partir de imagens.

Este capítulo apresenta essa transição por meio de duas aplicações representativas:

1. **Análise Automatizada de Documentos**, aplicada ao processamento de formulários, avaliações e outros documentos estruturados por meio de sistemas de reconhecimento óptico de marcas (*Optical Mark Recognition* – OMR);
2. **Inspeção Industrial Automatizada**, voltada ao controle de qualidade e à detecção de defeitos em linhas de produção.

Essas aplicações integram técnicas de detecção de estruturas geométricas, extração de descritores invariantes, reconhecimento de padrões e classificação de objetos, constituindo a base de diversos sistemas modernos de inspeção visual e automação.

## 6.1 Objetivos do Capítulo

Ao final deste capítulo, o estudante deverá ser capaz de:

- **Avaliar a influência do pré-processamento** na qualidade do reconhecimento automático de informações em documentos;
- **Realizar reconhecimento óptico de caracteres (OCR)** para converter documentos digitalizados em texto codificado;
- **Aplicar técnicas de processamento de linguagem natural**, incluindo tradução automática, ao texto obtido por OCR;
- Aplicar técnicas de **alinhamento e retificação geométrica de documentos** utilizando a Transformada de Hough e transformações projetivas;
- **Implementar sistemas de reconhecimento óptico de marcas (OMR)** para leitura automatizada de avaliações e formulários;
- **Detectar e segmentar regiões de interesse** com base em operações morfológicas, contornos e propriedades geométricas;
- **Decodificar marcadores bidimensionais e códigos de barras**, integrando bibliotecas de Visão Computacional a *pipelines* de processamento documental;
- **Desenvolver *pipelines* de Visão Computacional** para análise automatizada de documentos.

Este capítulo marca a transição do **Processamento Digital de Imagens**, voltado à transformação de imagens, para a **Visão Computacional**, cujo objetivo é interpretar o conteúdo visual, extrair informações e apoiar processos automatizados de análise e tomada de decisão.

## 6.2 Configuração do Ambiente

Os exemplos deste capítulo utilizam bibliotecas amplamente empregadas em PDI-VC. O bloco abaixo instala os pacotes necessários; em ambientes que já os possuam, a execução pode ser ignorada.

```
import sys, subprocess, importlib, shutil

# 1. Dependências de Sistema
if 'google.colab' in sys.modules:
    print("[AMBIENTE] Google Colab. Configurando dependências do sistema...")
    subprocess.run(
        "apt-get update && apt-get install -y poppler-utils "
        "libzbar0 tesseract-ocr tesseract-ocr-por",
        shell=True, stdout=subprocess.DEVNULL, stderr=subprocess.DEVNULL
    )
elif shutil.which("tesseract") is None:
    # Ambiente local sem tesseract: tenta instalar via apt-get (requer sudo/root)
    if shutil.which("apt-get"):
        print("[AMBIENTE] Local. Instalando tesseract-ocr via apt-get (pode pedir senha)...")
        resultado = subprocess.run(
            "sudo apt-get update && sudo apt-get install -y tesseract-ocr tesseract-ocr-por",
            shell=True
        )
        if resultado.returncode != 0 or shutil.which("tesseract") is None:
            print(
                "[AVISO] Não foi possível instalar automaticamente. "
                "Instale manualmente: sudo apt install tesseract-ocr tesseract-ocr-por"
            )
    else:
        print(
            "[AVISO] tesseract não encontrado e apt-get indisponível. "
            "Instale manualmente antes de executar as células de OCR."
        )

# 2. Dependências do Python (Instala apenas as ausentes)
pkgs = {
    "cv2": "opencv-python", "skimage": "scikit-image", "numpy": "numpy",
    "pdf2image": "pdf2image", "pandas": "pandas", "tabulate": "tabulate",
    "PyPDF2": "PyPDF2", "bcrypt": "bcrypt", "pyarrow": "pyarrow",
    "pyzbar": "pyzbar", "pytesseract": "pytesseract", "deep_translator": "deep-translator"
}
for mod, pkg in pkgs.items():
    if importlib.util.find_spec(mod) is None:
        subprocess.run([sys.executable, "-m", "pip", "install", "-q", pkg])

# 3. Imports Globais do Pipeline
import cv2, numpy as np, matplotlib.pyplot as plt
from skimage import io, data, color
```

Além dessas bibliotecas, será utilizado o módulo didático `morph.py`, desenvolvido para simplificar operações de leitura, visualização e processamento de imagens ao longo deste livro. O código a seguir verifica sua disponibilidade, realiza o *download* quando necessário e confirma a versão carregada.

```
import os
import urllib.request

if not os.path.exists("morph.py"):
    urllib.request.urlretrieve(
        "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph/morph.py",
        "morph.py",
    )

import morph
from morph import mm

print(f" Ambiente pronto. morph {getattr(morph, '__version__', 'local_file')}")
```

Ambiente pronto. morph 1.1.5

## 6.3 Bases de Imagens para Experimentação

Os exemplos apresentados nesta parte do livro utilizam, sempre que possível, documentos digitalizados, folhas de respostas, códigos de barras, *QR Codes* e outras imagens provenientes de aplicações reais. Para tornar os experimentos integralmente reproduzíveis — inclusive em ambientes sem acesso à internet ou aos arquivos originais do MCTest —, também são empregadas imagens públicas amplamente utilizadas no ensino e na pesquisa em Processamento Digital de Imagens e Visão Computacional (PDI-VC).

### 💡 Por que utilizar um banco de imagens de *benchmark*?

Imagens como `camera()` e `coins()` são empregadas há décadas em livros-texto, artigos científicos e materiais didáticos de PDI-VC. Sua utilização oferece importantes vantagens:

- **Reprodutibilidade:** qualquer leitor obtém exatamente as mesmas imagens, independentemente do computador ou sistema operacional utilizado, sem necessidade de *downloads* externos ou de arquivos específicos deste livro;
- **Comparabilidade:** os resultados produzidos podem ser comparados diretamente com aqueles reportados na literatura, uma vez que os mesmos conjuntos de imagens são amplamente adotados como referência;
- **Foco nos algoritmos:** por serem imagens compactas, bem documentadas e distribuídas sem restrições de uso para fins educacionais e científicos, permitem concentrar a atenção nas técnicas de processamento, reduzindo interferências relacionadas à aquisição ou ao gerenciamento dos dados.

### 6.3.1 Imagens Públicas com `skimage.data`

O módulo `skimage.data` disponibiliza uma coleção de imagens de referência amplamente utilizada em atividades de ensino, pesquisa e validação de algoritmos em PDI-VC. A inspeção do atributo `data.__all__` mostra que a versão atual reúne **42 itens**, incluindo fotografias naturais, documentos digitalizados, imagens médicas, microscopia, texturas, padrões sintéticos, modelos tridimensionais e sequências temporais. Convém observar que alguns desses itens correspondem a funções utilitárias, como `data_dir()` e `download_all()`, e não a imagens propriamente ditas.

Como o objetivo deste capítulo é apresentar aplicações de análise documental e inspeção visual, a Table 6.2 reúne uma **seleção representativa** das imagens mais relevantes, organizada de acordo com suas principais aplicações em Visão Computacional. A Figure 6.1 apresenta uma amostra dessas imagens, agrupadas conforme a mesma classificação adotada na tabela.



### Imagens utilizadas neste capítulo

Embora o `skimage.data` disponibilize dezenas de imagens de referência, apenas quatro são empregadas diretamente nos experimentos deste capítulo. Elas foram selecionadas por reproduzirem, de forma controlada, características frequentemente encontradas em documentos digitalizados e em sistemas de inspeção visual industrial. A Tabela 6.1 resume o papel de cada uma delas ao longo deste capítulo.

Tabela 6.1: Imagens do `skimage.data` utilizadas nos experimentos deste capítulo.

| Imagem                     | Aplicação no capítulo                                                                                                                    |
|----------------------------|------------------------------------------------------------------------------------------------------------------------------------------|
| <code>data.page()</code>   | Página digitalizada utilizada nos experimentos de correção de iluminação, realce local (CLAHE) e limiarização automática por Otsu.       |
| <code>data.text()</code>   | Documento contendo texto impresso, empregado para ilustrar segmentação, extração de contornos e etapas típicas de OCR e OMR.             |
| <code>data.coffee()</code> | Fotografia colorida com variações naturais de iluminação, utilizada para exemplificar técnicas aplicáveis a cenas reais não documentais. |
| <code>data.brick()</code>  | Textura de referência empregada em exemplos de inspeção superficial e detecção de defeitos por análise de variância local.               |

Tabela 6.2: Seleção de imagens públicas representativas disponíveis no módulo `skimage.data`, organizadas por área de aplicação.

| Categoria                                                                                                               | Função                                                | Descrição                                                                      |
|-------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------|--------------------------------------------------------------------------------|
|  Documentos & OCR/OMR                | <code>data.page()</code>                              | Página digitalizada de documento — normalização de fundo, CLAHE e Otsu.        |
|  Documentos & OCR/OMR                | <code>data.text()</code>                              | Texto impresso — segmentação e extração de contornos em cenários de OCR/OMR.   |
|  Segmentação, Morfologia & Contornos | <code>data.coins()</code>                             | Conjunto de moedas — referência clássica para segmentação e <i>watershed</i> . |
|  Segmentação, Morfologia & Contornos | <code>data.clock()</code>                             | Relógio analógico — detecção de formas e contornos.                            |
|  Segmentação, Morfologia & Contornos | <code>data.binary_blobs()</code>                      | Blobs binários sintéticos — conectividade e morfologia matemática.             |
|  Segmentação, Morfologia & Contornos | <code>data.moon()</code>                              | Superfície lunar — segmentação de crateras por relevo de intensidade.          |
| Textura & Inspeção Industrial                                                                                           | <code>data.brick()</code>                             | Textura uniforme de tijolos — detecção de defeitos por variância local.        |
| Textura & Inspeção Industrial                                                                                           | <code>data.checkerboard()</code>                      | Padrão xadrez — calibração de câmera e transformações geométricas.             |
|  Fotografias Clássicas de PDI/VC     | <code>data.camera()</code>                            | Fotógrafo com tripé — imagem de referência mais citada na literatura de PDI.   |
|  Fotografias Clássicas de PDI/VC     | <code>data.astronaut()</code>                         | Retrato colorido de astronauta — filtragem e realce em cor.                    |
|  Fotografias Clássicas de PDI/VC     | <code>data.coffee()</code>                            | Xícara de café — cena real com variação de iluminação e cor.                   |
|  Fotografias Clássicas de PDI/VC     | <code>data.cat()</code> / <code>data.chelsea()</code> | Fotografias coloridas de gatos — detecção de bordas e realce.                  |

| Categoria                                                                                                         | Função                    | Descrição                                                     |
|-------------------------------------------------------------------------------------------------------------------|---------------------------|---------------------------------------------------------------|
|  Fotografias Clássicas de PDI/VC | <code>data.horse()</code> | Silhueta binária de cavalo — descritores de forma e contorno. |

```
import matplotlib.pyplot as plt
from skimage import data

# Imagens ordenadas por categoria; a cor do título reproduz a cor da categoria na tab. anterior
imgs = [
    ("page",      data.page(),      "#2563eb"),    # Documentos & OCR/OMR
    ("text",      data.text(),      "#2563eb"),
    ("coins",     data.coins(),     "#16a34a"),    # Segmentação & morfologia
    ("binary_blobs", data.binary_blobs(), "#16a34a"),
    ("brick",     data.brick(),     "#ea580c"),    # Textura & inspeção industrial
    ("checkerboard", data.checkerboard(), "#ea580c"),
    ("camera",    data.camera(),    "#7c3aed"),    # Fotografias clássicas de PDI/VC
    ("coffee",    data.coffee(),    "#7c3aed"),
]

fig, ax = plt.subplots(2, 4, figsize=(11, 5.5))
for a, (nome, img, cor) in zip(ax.ravel(), imgs):
    a.imshow(img, cmap="gray")
    a.set_title(nome, color=cor, fontweight="bold")
    a.axis("off")
plt.tight_layout()
```




Figura 6.1: Amostra de imagens públicas do *skimage.data*, agrupadas por área de aplicação.

## 6.4 Normalização de Fundo e Equalização Local de Contraste

A qualidade da segmentação depende diretamente das características da imagem de entrada. Em documentos digitalizados, variações de iluminação, sombras, regiões superexpostas e diferenças de tonalidade do papel reduzem o contraste entre o primeiro plano e o fundo, dificultando a aplicação de métodos de limiarização global, como o algoritmo de Otsu.

Para minimizar esses efeitos, são empregadas duas técnicas complementares de pré-processamento:

- **Normalização de fundo:** estima a componente de baixa frequência da imagem por meio de uma forte suavização e, em seguida, normaliza a imagem original em relação a esse fundo estimado. Esse procedimento reduz gradientes de iluminação e compensa variações lentas de intensidade, preservando as estruturas de interesse.
- **CLAHE** (*Contrast Limited Adaptive Histogram Equalization*), apresentado no **Capítulo 4**: divide a imagem em pequenas regiões (*tiles*) e realiza a equalização do histograma de cada região de forma independente. O contraste é limitado para evitar a amplificação excessiva do ruído, tornando a técnica especialmente adequada para imagens com variações locais de iluminação.

A [Figure 6.2](#) compara essas estratégias utilizando a imagem `page()` da biblioteca `skimage.data`. São apresentados seis resultados: (a) a imagem original; (b) a binarização direta pelo método de Otsu, utilizada como referência; (c) o fundo estimado por filtragem Gaussiana; (d) a imagem após a normalização de fundo; (e) a binarização obtida após a aplicação do CLAHE seguida do método de Otsu; e (f) a binarização obtida após a normalização de fundo seguida da aplicação do método de Otsu.

A comparação permite observar o efeito produzido por cada etapa do pré-processamento e sua influência na qualidade da segmentação. Em particular, a normalização de fundo reduz as variações globais de iluminação, enquanto o CLAHE aumenta o contraste local entre caracteres e fundo. Dependendo das características da imagem, uma ou outra estratégia pode produzir resultados superiores, não existindo uma técnica universalmente mais adequada.

```
import cv2
from skimage import data
from morph import mm

img = data.page() # ou: img = mm.gray(img_final) - com imagem da folha de prova

# Método 1: Normalização de fundo + Otsu
# Estima o fundo com um filtro Gaussiano de sigma grande (variações lentas de luz)
# e divide pixel a pixel para cancelar o gradiente de iluminação
bg = cv2.GaussianBlur(img, (0, 0), sigmaX=25)
img_norm = cv2.divide(img, bg, scale=255)
img_norm_otsu = mm.threshold(img_norm)

# Método 2: CLAHE + Otsu
# tileGridSize define o tamanho de cada região local (tile)
# clipLimit controla o teto de amplificação - valores altos aumentam contraste
# mas também amplificam ruído
clahe = cv2.createCLAHE(clipLimit=2.0, tileGridSize=(8, 8))
img_clahe = clahe.apply(img)
img_clahe_otsu = mm.threshold(img_clahe)

# Método 0: Otsu direto (sem pré-processamento) - referência
img_otsu = mm.threshold(img)

mm.show(
    [img, img_otsu, bg, img_norm, img_clahe_otsu, img_norm_otsu],
    titles=["(a) Original", "(b) Otsu direto", "(c) Gaussiano", \
           "(d) Fundo normalizado (img/bg)", "(e) CLAHE + Otsu", \
           "(f) Normaliz. fundo + Otsu"],
    cols=3,
    figsize=(14, 8)
)
```




Figura 6.2: Comparação entre estratégias de pré-processamento para binarização da imagem de texto: (a) imagem original; (b) limiarização direta pelo método de Otsu; (c) fundo estimado por filtragem Gaussiana; (d) imagem após normalização de fundo (divisão pela imagem suavizada); (e) CLAHE seguido de limiarização por Otsu; e (f) normalização de fundo seguida de limiarização por Otsu. As imagens ilustram o efeito de cada técnica na compensação de variações de iluminação e na qualidade da segmentação.

### Por que funciona? — Normalização de fundo vs. CLAHE

**Normalização de fundo:** ao dividir a imagem por uma versão fortemente suavizada de si mesma, eliminam-se as variações lentas de luminosidade (gradiente de luz, sombra de borda) sem afetar os detalhes finos — texto, linhas, bolhas. O resultado é uma imagem com iluminação aproximadamente uniforme, onde o limiar global de Otsu passa a funcionar bem em toda a página.

**CLAHE:** um histograma global equalizado “estica” os tons de toda a imagem de uma vez — útil quando a iluminação é uniforme, mas problemático quando não é. O CLAHE divide a imagem em pequenos blocos (*tiles*) e equaliza cada um separadamente, com um limite máximo de amplificação (`clipLimit`) para não explodir o ruído. É especialmente eficaz para realçar regiões subexpostas localmente, mas não elimina gradientes globais — por isso, aplicá-lo após a normalização de fundo tende a produzir resultados mais consistentes.

## 6.5 Reconhecimento Óptico de Caracteres (OCR)

Após a binarização, a etapa seguinte do processamento documental consiste na conversão da representação visual dos caracteres em texto codificado digitalmente, processo denominado **Reconhecimento Óptico de Caracteres** (*Optical Character Recognition* — **OCR**).

De forma geral, um sistema de OCR compreende três etapas:

1. **Segmentação:** identifica linhas, palavras e caracteres na imagem, utilizando projeções horizontais e verticais ou detecção de componentes conexos.
2. **Extração de características:** representa cada caractere por atributos visuais, como bordas, curvaturas e padrões de traço.
3. **Reconhecimento:** associa os atributos extraídos ao caractere mais provável. Sistemas atuais utilizam predominantemente redes neurais recorrentes (LSTM) ou arquiteturas baseadas em *transformers*.

Neste livro, utiliza-se o **Tesseract OCR**, acessado por meio da biblioteca `pytesseract` (instalação: `pip install pytesseract`). Desenvolvido originalmente pela Hewlett-Packard entre 1985 e 1995 e atualmente

mantido pelo Google, o Tesseract é descrito em Smith (2007) e Smith (2013). Nas versões recentes, o reconhecimento textual é realizado por redes neurais LSTM.

O desempenho do OCR depende da qualidade da imagem de entrada. Ruído, baixo contraste, distorções geométricas e iluminação irregular reduzem a taxa de reconhecimento. Por esse motivo, etapas como retificação, normalização de fundo e equalização adaptativa (CLAHE) integram o pré-processamento da imagem.

### O Tesseract precisa de uma imagem binarizada?

O Tesseract incorpora internamente uma etapa de binarização adaptativa antes do reconhecimento dos caracteres. Por esse motivo, fornecer ao OCR uma imagem previamente binarizada nem sempre produz os melhores resultados.

Como a limiarização é uma operação irreversível, ela pode eliminar variações sutis de intensidade nas bordas dos caracteres, como o *antialiasing*, que podem auxiliar o mecanismo de reconhecimento. Em muitos casos, uma imagem em tons de cinza, com boa iluminação e contraste, produz uma transcrição mais fiel do que sua versão binarizada.

Para investigar esse efeito, compara-se o texto extraído pelo Tesseract a partir de quatro versões da mesma imagem, apresentadas na Figure 6.3: (a) imagem original; (b) imagem submetida à equalização adaptativa (CLAHE) seguida da limiarização pelo método de Otsu; (c) imagem submetida à normalização de fundo seguida da limiarização pelo método de Otsu; e (d) imagem submetida apenas à normalização de fundo, preservando os tons de cinza.

A comparação entre as versões (c) e (d) mostra que, em trechos contendo caracteres visualmente semelhantes, a versão em tons de cinza (d) produziu uma transcrição mais fiel ao texto original do que a versão binarizada (c). Esse resultado indica que a limiarização aplicada no pré-processamento pode eliminar informações úteis ao reconhecimento. Assim, embora a binarização seja essencial para diversas operações de processamento de imagens, ela não constitui necessariamente a melhor entrada para o OCR. A escolha da técnica de pré-processamento deve considerar a etapa subsequente do *pipeline* documental.

```
import pytesseract
from skimage import data
import cv2
from morph import mm

img = data.page()

# Reaproveitando os resultados da seção anterior
img_otsu = mm.threshold(img)

bg = cv2.GaussianBlur(img, (0, 0), sigmaX=25)
img_norm = cv2.divide(img, bg, scale=255)      # tons de cinza, sem Otsu
img_norm_otsu = mm.threshold(img_norm)        # binarizada

clahe = cv2.createCLAHE(clipLimit=2.0, tileGridSize=(8, 8))
img_clahe = clahe.apply(img)
img_clahe_otsu = mm.threshold(img_clahe)

# Configuração do Tesseract
# --psm 6: assume um único bloco uniforme de texto (adequado à imagem `page`)
config = "--psm 6"

texto_original = pytesseract.image_to_string(img, config=config)
texto_clahe_otsu = pytesseract.image_to_string(img_clahe_otsu, config=config)
texto_norm_otsu = pytesseract.image_to_string(img_norm_otsu, config=config)
texto_norm_gray = pytesseract.image_to_string(img_norm, config=config)
```



```

for nome, texto in zip(
    ["(a) Original", "(b) CLAHE + Otsu", "(c) Normaliz. fundo + Otsu",
     "(d) Normaliz. fundo (tons de cinza)"],
    [texto_original, texto_clahe_otsu, texto_norm_otsu, texto_norm_gray]
):
    print(f"--- {nome} ---")
    print(texto.strip(), "\n")

mm.show(
    [img, img_clahe_otsu, img_norm_otsu, img_norm],
    titles=["(a) Original", "(b) CLAHE + Otsu", "(c) Normaliz. fundo + Otsu",
           "(d) Normaliz. fundo (cinza)"],
    cols=4,
    figsize=(16, 4)
)

```

```

--- (a) Original ---
ion-based segmentation
Fst determine markers of the coins and the
These markers are pixels that we can label
ly a5 either object or background. Here,
are found at the two extreme parts of the
eS
Be iatetcoins)

--- (b) CLAHE + Otsu ---
Rédion-based segmentation
Menus fist determine markers of the coins and the
yee ground. These markers are pixels that we can label
Sere Epbloueusly. aS either object or background. Here,
Reverkers are fourid at the two extreme parts of the
Bsesern.of Grey Values:
eessere i neo zdtoa lixstcoins)

--- (c) Normaliz. fundo + Otsu ---
Region-based segmentation

Let us first determine markers of the coins and the
background. These markers are pixels that we can label
unambiguously as either object or background. Here,
the markers are found at the two extreme parts of the
histogram of grey values:

sa" Mathers © np.ceros_Like(coins)

--- (d) Normaliz. fundo (tons de cinza) ---
Region-based segmentation

Let us first determine markers of the coins and the
background. These markers are pixels that we can label
unambiguously as either object or background. Here,
the markers are found at the two extreme parts of the
histogram of grey values:

4 2? Barkers = np. zeros_like(coins)

```




Figura 6.3: Comparação do texto extraído pelo Tesseract a partir de quatro versões da mesma imagem: (a) imagem original; (b) CLAHE seguido de limiarização por Otsu; (c) normalização de fundo seguida de limiarização por Otsu; e (d) normalização de fundo em tons de cinza, sem limiarização. A comparação evidencia que a binarização externa nem sempre favorece o reconhecimento, uma vez que o Tesseract já realiza sua própria binarização adaptativa internamente.

### Por que o pré-processamento melhora o OCR?

O desempenho do OCR depende diretamente da qualidade da imagem de entrada. Baixo contraste, iluminação não uniforme, ruído e distorções geométricas dificultam a separação entre texto e fundo e aumentam a probabilidade de erros de reconhecimento.

Técnicas como a normalização de fundo e a equalização adaptativa (CLAHE) corrigem gradientes de iluminação e realçam o contraste local entre os caracteres e o fundo, produzindo imagens mais adequadas ao reconhecimento automático. A limiarização, por sua vez, deve ser aplicada com cautela: por tratar-se de uma operação irreversível, pode eliminar variações sutis de intensidade nas bordas dos caracteres — como o *antialiasing* — que o próprio motor de OCR utiliza internamente para resolver ambiguidades entre símbolos visualmente semelhantes. Por esse motivo, imagens em tons de cinza, corrigidas apenas quanto à iluminação, frequentemente produzem transcrições mais fiéis do que suas versões binarizadas. Em documentos capturados por câmeras de dispositivos móveis, o pré-processamento tende a proporcionar maior ganho de desempenho do que em documentos digitalizados por *scanner*, nos quais a iluminação costuma ser mais uniforme.

## 6.6 Tradução Automática do Texto Reconhecido

Após o reconhecimento óptico de caracteres, o texto obtido pode ser submetido a técnicas de processamento de linguagem natural, como correção ortográfica, indexação, sumarização e tradução automática.

A tradução automática constitui uma etapa independente do OCR. Enquanto o OCR converte os caracteres presentes na imagem em texto codificado, a tradução opera sobre esse texto no idioma original do documento. Dessa forma, erros de reconhecimento podem ser propagados para a tradução, comprometendo a qualidade do resultado. Sistemas atuais de tradução automática utilizam predominantemente arquiteturas neurais baseadas em mecanismos de atenção e *transformers* (Bahdanau; Cho; Bengio, 2015; Vaswani et al., 2017).

Neste exemplo, utiliza-se o texto obtido a partir da imagem submetida apenas à normalização de fundo, sem limiarização (item **d** da Figure 6.3), por apresentar a transcrição mais fiel entre as estratégias avaliadas na seção anterior.

A tradução é realizada por meio da biblioteca `deep-translator` (instalação: `pip install deep-translator`), que fornece uma interface para diferentes serviços de tradução automática, incluindo o Google Translate.

```
from deep_translator import GoogleTranslator

# Texto obtido pelo OCR a partir da imagem com normalização de fundo (tons de cinza)
texto_en = texto_norm_gray

texto_pt = GoogleTranslator(source="en", target="pt").translate(texto_en)
```



```
print("--- Texto original gerado pela imagem normalizada em tons de cinza (OCR, EN) ---")
print(texto_en)

print("\n--- Texto traduzido (PT-BR) ---")
print(texto_pt)

mm.show(
    [img_norm],
    titles=["Imagem com normalização de fundo (tons de cinza)"],
    cols=1,
    figsize=(6, 4)
)
```

```
--- Texto original gerado pela imagem normalizada em tons de cinza (OCR, EN) ---
Region-based segmentation
```

Let us first determine markers of the coins and the background. These markers are pixels that we can label unambiguously as either object or background. Here, the markers are found at the two extreme parts of the histogram of grey values:

```
4 2? Barkers = np. zeros_like(coins)
```

```
--- Texto traduzido (PT-BR) ---
Segmentação baseada em região
```

Vamos primeiro determinar os marcadores das moedas e o fundo. Esses marcadores são pixels que podemos rotular inequivocamente como objeto ou plano de fundo. Aqui, os marcadores são encontrados nas duas partes extremas do histograma de valores de cinza:

```
4 2? Ladradores = np. zeros_like(moedas)
```

Imagem com normalização de fundo (tons de cinza)

## Region-based segmentation

Let us first determine markers of the coins and the background. These markers are pixels that we can label unambiguously as either object or background. Here, the markers are found at the two extreme parts of the histogram of grey values:

```
>>> markers = np.zeros_like(coins)
```

Figura 6.4: Fluxo de reconhecimento e tradução automática. A imagem pré-processada por normalização de fundo, sem limiarização, é utilizada como entrada para o Tesseract OCR, e o texto reconhecido é traduzido do inglês para o português por meio da biblioteca *deep-translator*.

### Por que a qualidade do OCR influencia a tradução?

A tradução automática utiliza como entrada o texto produzido pelo OCR. Erros de reconhecimento, como caracteres incorretos, palavras incompletas ou fragmentadas, são propagados para a etapa de tradução e podem alterar o significado do texto.

Consequentemente, a qualidade da tradução depende diretamente da fidelidade da transcrição obtida pelo OCR. Como discutido anteriormente, essa fidelidade nem sempre é maximizada por uma binarização externa: imagens em tons de cinza, corrigidas apenas quanto à iluminação, podem preservar informações relevantes para a distinção entre caracteres visualmente semelhantes. Assim, o pré-processamento da imagem — e a escolha adequada de suas etapas em função da tarefa subsequente — contribui para melhorar não apenas o reconhecimento dos caracteres, mas também o desempenho de etapas posteriores de processamento de linguagem natural, como tradução, indexação e sumarização.

## 6.7 Fundamentos de OMR e Inspeção Industrial

O **Reconhecimento Óptico de Marcas** (*Optical Mark Recognition* — OMR) é uma técnica de Visão Computacional destinada à identificação automática de marcações em posições previamente definidas de um formulário. Suas aplicações incluem folhas de respostas, questionários, formulários administrativos e outros documentos estruturados.

Diferentemente do OCR (*Optical Character Recognition*), que reconhece caracteres e palavras, o OMR determina a presença, a ausência ou a intensidade de marcas em regiões previamente conhecidas. Em vez de interpretar texto, explora propriedades geométricas e estatísticas associadas ao preenchimento dessas regiões.

Os sistemas modernos de OMR processam imagens obtidas por *scanners*, câmeras ou dispositivos móveis, automatizando tarefas que anteriormente dependiam de equipamentos especializados.

De forma geral, um sistema de OMR compreende as seguintes etapas:

1. **Aquisição:** conversão do documento físico em formato digital;
2. **Pré-processamento:** correção geométrica, redução de ruídos e binarização;
3. **Localização das regiões de interesse:** identificação das áreas destinadas às marcações;
4. **Análise das marcações:** avaliação do preenchimento das regiões candidatas;
5. **Interpretação:** conversão das marcações em respostas ou dados estruturados.

Esses princípios se estendem naturalmente à **Inspeção Industrial Automatizada**. Em linhas de produção, o mesmo encadeamento — aquisição, pré-processamento, segmentação, extração de características e decisão — é empregado para detectar defeitos superficiais, verificar a integridade de componentes e medir dimensões com precisão subpixel. A diferença reside no domínio de aplicação: enquanto o OMR opera sobre documentos com estrutura predefinida, a inspeção industrial lida com objetos cujas variações geométricas e radiométricas devem ser modeladas de forma mais flexível.

Nas seções seguintes, ambas as aplicações são desenvolvidas por meio de projetos práticos que reproduzem etapas típicas de sistemas reais.

## 6.8 Projetos Práticos: Construção de um *Pipeline* de Análise Documental

Os conceitos deste capítulo serão desenvolvidos por meio de projetos que reproduzem etapas típicas de sistemas reais de análise documental, introduzindo técnicas reutilizáveis em aplicações de OCR, OMR, inspeção visual e processamento de formulários.

### 6.8.1 Alinhamento Automático de Documentos (*OCR/OMR Pre-processing*)

A correção de inclinação (*deskew*) é uma etapa fundamental no processamento de documentos. Rotações introduzidas durante a digitalização ou captura comprometem a localização de regiões de interesse e reduzem a precisão das etapas subsequentes.

Neste projeto será desenvolvido um sistema para estimar automaticamente a orientação predominante do documento e corrigir sua inclinação. Para isso, serão empregadas técnicas clássicas de detecção de bordas com o operador de Canny e detecção de retas pela Transformada de Hough. A partir das linhas identificadas, será estimado o ângulo de rotação e aplicada uma transformação afim para produzir uma versão alinhada do documento.

Como formulários e folhas de resposta são frequentemente distribuídos em formato PDF, o *pipeline* inicia-se com a rasterização de cada página, convertendo-a em uma imagem matricial. Neste capítulo, essa etapa será realizada com a biblioteca `pdf2image`, gerando imagens PNG com resolução de 300 DPI (*dots per inch*). A partir delas, poderão ser aplicadas as técnicas de detecção de bordas, Transformada de Hough, segmentação, extração de contornos e reconhecimento automático de padrões estudadas ao longo do capítulo.

```
import os
import urllib.request
from pdf2image import convert_from_path
from skimage import data
import cv2

# Diretório dos microdados e folhas de respostas do exame institucional
file_path = "dados/provas_qrcode_EP.pdf"
url_github = (
    "https://raw.githubusercontent.com/fzampirolli/"
    "pdi-vc/master/all/cap06/dados/provas_qrcode_EP.pdf"
)

# Se o arquivo não existir localmente, baixa automaticamente do GitHub
if not os.path.exists(file_path):
    print(f"[DOWNLOAD] Baixando PDF do GitHub: {url_github}")
    try:
        # Garante que a pasta 'dados' existe antes de salvar
        os.makedirs(os.path.dirname(file_path), exist_ok=True)
        urllib.request.urlretrieve(url_github, file_path)
        print("[DOWNLOAD] PDF baixado com sucesso!")
    except Exception as e:
        print(f"[DOWNLOAD] Falha ao baixar o arquivo: {e}")

print(f"PDF de folhas de prova digitalizadas: {file_path}")

if os.path.exists(file_path):
    # Rasterização das páginas com resolução otimizada de 300 DPI
    pages = convert_from_path(file_path, dpi=300)
    for i, page in enumerate(pages):
        saida = f"test{i+1:02d}.png"
        page.save(saida)
        print(f"[INGESTÃO] Página PDF convertida com sucesso: {saida}")
else:
    print("[AVISO] Arquivo PDF não localizado no path. Ativando fallback via skimage.data.")
    # Injeta matriz de texto pública para garantir a execução contínua do pipeline
    img_fallback = data.text()
    cv2.imwrite("test02.png", img_fallback)
    print("[INGESTÃO] Imagem de fallback estruturada: test02.png")

# Carrega e exibe a imagem rasterizada inicial utilizando o ecossistema morph
if os.path.exists('test02.png'):
```

```

img_original = mm.read('test02.png')
else:
    # Fallback definitivo caso até o skimage falhe
    img_original = np.ones((400, 400), dtype=np.uint8) * 255

mm.show(img_original, figsize=(4, 3))

```

PDF de folhas de prova digitalizadas: dados/provas\_qrcode\_EP.pdf  
 [INGESTÃO] Página PDF convertida com sucesso: test01.png  
 [INGESTÃO] Página PDF convertida com sucesso: test02.png  
 [INGESTÃO] Página PDF convertida com sucesso: test03.png




Figura 6.5: *Pipeline* de ingestão de documentos: rasterização adaptativa de páginas PDF para matrizes discretas em formato PNG, exibindo a página dois.

### 6.8.2 Algoritmo de Retificação de Inclinação (*Deskew*)

A etapa de *deskew* tem como objetivo estimar e corrigir a inclinação global de um documento digitalizado, alinhando seu conteúdo aos eixos da imagem. A Figure 6.7 apresenta o fluxo completo de processamento, desde a imagem original até o resultado após a correção geométrica. Complementarmente, o simulador da Figure 6.6 permite visualizar o funcionamento da Transformada de Hough e compreender como a orientação predominante é estimada.

O procedimento é composto por três etapas principais:

1. detecção de bordas pelo operador de Canny;
2. estimação da orientação predominante por meio da Transformada de Hough Linear;
3. correção da inclinação utilizando uma transformação afim de rotação.

Após a retificação, o documento passa a apresentar orientação aproximadamente horizontal, favorecendo as etapas subsequentes de segmentação, rotulagem de componentes conexos e reconhecimento de caracteres e marcas.

### 6.8.3 Modelagem Matemática

As subseções seguintes formalizam, em termos matemáticos, as etapas descritas anteriormente, relacionando o gradiente da imagem, a parametrização de retas no espaço de Hough e a matriz de rotação empregada na correção geométrica.

#### 6.8.3.1 Detecção de Bordas

Inicialmente, a imagem é suavizada por um filtro Gaussiano, reduzindo o efeito de ruídos de alta frequência que podem gerar bordas espúrias. Os conceitos de filtragem espacial e convolução foram apresentados no

### Capítulo 3.

Em seguida, o operador de Canny estima o gradiente da imagem. Seja  $f(x, y)$  a intensidade da imagem e  $\alpha$  o ângulo de rotação.

A magnitude do gradiente é dada por

$$|\nabla f(x, y)| = \sqrt{\left(\frac{\partial f}{\partial x}\right)^2 + \left(\frac{\partial f}{\partial y}\right)^2}.$$

em que:

- $f(x, y)$  representa a intensidade da imagem na posição  $(x, y)$ ;
- $\frac{\partial f}{\partial x}$  e  $\frac{\partial f}{\partial y}$  são as derivadas parciais nas direções horizontal e vertical;
- $|\nabla f(x, y)|$  é a magnitude do gradiente.

Após o cálculo do gradiente, o algoritmo aplica a supressão de não máximos (*non-maximum suppression*) e a limiarização por histerese, produzindo uma imagem binária contendo as principais bordas do documento.

#### 6.8.3.2 Transformada de Hough

A imagem binária de bordas é processada pela Transformada de Hough Linear, cujo objetivo é detectar estruturas aproximadamente retilíneas. Em vez da representação cartesiana da reta,  $y = ax + b$ , utiliza-se a representação na forma normal,

$$\rho = x \cos \theta + y \sin \theta,$$

em que:

- $x$  e  $y$  são as coordenadas de um ponto pertencente à reta;
- $\rho$  é a distância perpendicular entre a reta e a origem do sistema de coordenadas da imagem;
- $\theta$  é o ângulo formado entre a normal à reta e o eixo horizontal da imagem.

Nessa representação, cada ponto de borda  $(x, y)$  gera uma curva no espaço de parâmetros  $(\rho, \theta)$ . A interseção das curvas produzidas por pontos pertencentes à mesma reta origina máximos em uma matriz bidimensional denominada **acumulador**. Assim, os picos do acumulador correspondem às retas predominantes da imagem, como bordas do documento, linhas de formulários ou linhas de texto.

Para estimar a inclinação global do documento, consideram-se apenas as retas cujos ângulos satisfazem

$$-45^\circ \leq \theta \leq 45^\circ.$$

Essa restrição elimina orientações incompatíveis com a disposição esperada do documento e reduz a influência de retas verticais ou de estruturas irrelevantes. Seja  $\theta_1, \theta_2, \dots, \theta_n$  o conjunto dos ângulos das retas selecionadas. A estimativa da inclinação global é obtida pela mediana,

$$\hat{\theta} = \text{med}(\theta_1, \theta_2, \dots, \theta_n),$$

em que:

- $\theta_i$  é o ângulo da  $i$ -ésima reta detectada pela Transformada de Hough;
- $n$  é o número de retas consideradas após a filtragem angular;
- $\hat{\theta}$  é a estimativa da inclinação global do documento.

A mediana é adotada por ser menos sensível à presença de detecções isoladas (*outliers*) do que a média aritmética, produzindo uma estimativa mais estável da orientação predominante.

### 6.8.3.3 Rotação Afim

Seja  $\hat{\theta}$  a inclinação estimada na etapa anterior. A correção geométrica consiste em aplicar uma transformação afim de rotação em torno do centro da imagem, de modo que a orientação predominante passe a coincidir com o eixo horizontal. As transformações afins foram estudadas no **Capítulo 2**, juntamente com as operações de translação, escala, cisalhamento e rotação.

Seja  $(x, y)$  a posição de um pixel em relação ao centro da imagem e  $(x', y')$  sua posição após a rotação. A transformação é descrita por

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = R(\alpha) \begin{bmatrix} x \\ y \end{bmatrix},$$

em que

$$R(\alpha) = \begin{bmatrix} \cos \alpha & -\sin \alpha \\ \sin \alpha & \cos \alpha \end{bmatrix},$$

sendo:

- $(x, y)$  as coordenadas originais do pixel em relação ao centro da imagem;
- $(x', y')$  as coordenadas do pixel após a rotação;
- $\alpha$  o ângulo de rotação aplicado para compensar a inclinação estimada do documento;
- $R(\alpha)$  a matriz de rotação.

Na prática, o ângulo aplicado corresponde ao oposto da inclinação estimada,

$$\alpha = -\hat{\theta},$$

em que  $\hat{\theta}$  representa a orientação predominante obtida pela Transformada de Hough.

Como as coordenadas transformadas nem sempre coincidem com posições inteiras da malha de pixels, é necessário reamostrar a imagem para determinar os novos valores de intensidade. Na implementação apresentada neste capítulo, a função `mm.rotate` realiza essa operação utilizando interpolação bicúbica, reduzindo os artefatos de reamostramento e preservando a continuidade visual de bordas e caracteres.

```
def retificar_inclinacao_documento(img):

    gray = mm.gray(img) if img.ndim == 3 else img
    edges = cv2.Canny(cv2.GaussianBlur(gray, (5,5), 0), 50, 150)
    lines = cv2.HoughLines(edges, 1, np.pi/180, 200)

    if lines is None:
        return edges, img

    angulos = []
    for line in lines:
        angulo = np.rad2deg(line[0][1]) - 90
        if -45 < angulo < 45:
            angulos.append(angulo)

    if not angulos:
        return edges, img

    return edges, mm.rotate(img, np.median(angulos), interp="bicubic")

# Execução do pipeline de deskew
img_edges, img_final = retificar_inclinacao_documento(img_original)

# Exibição múltipla padronizada com o formato nativo do livro
```

 **Simulador: Correção de Inclinação (Deskew)**

Canny → Hough → Rotação

ÂNGULO REAL  
**+0.0°**

ESTIMADO (HOUGH)  
**+0.0°**

ERRO  
**0.0°**


↺ Resetar

Inclinação aplicada: +0.0°  


 Original inclinado

 Bordas Canny

 Corrigido (deskewed)



 **Pipeline de processamento**

- 1 Canny:** detecta bordas dos segmentos de texto — pixels de alto gradiente que formam os contornos das linhas.
- 2 Hough:** cada pixel de borda vota em todas as retas que passam por ele. A *mediana* dos ângulos das retas com mais votos estima a inclinação global.
- 3 Rotação inversa:** aplica `cv2.warpAffine` com ângulo negativo, alinhando o documento ao eixo horizontal.

 **Documento alinhado — nenhuma correção necessária.**

Figura 6.6: Simulador interativo de correção de inclinação (*deskew*): mova o *slider* para inclinar o documento e observe as três etapas do *pipeline* — imagem inclinada, bordas Canny e resultado corrigido.



```
mm.show(
    [img_original, img_edges, img_final],
    titles=["Imagem Original", "Bordas de Canny", "Documento Retificado"],
    cols=3,
    figsize=(12, 4)
)
```




Figura 6.7: *Pipeline* de retificação axial: exibição comparativa entre a entrada rotacionada original, o mapa de gradientes estruturais de Canny e o resultado final alinhado com fundo normalizado em branco.

### **i** 🧠 Por que funciona? — Transformada de Hough

Na Transformada de Hough, cada pixel de borda contribui com votos para todas as retas que podem passar por sua posição. Em vez de selecionar apenas a reta com maior número de votos, o algoritmo considera todas as retas cuja quantidade de votos excede um limiar mínimo e calcula seus respectivos ângulos. A inclinação global do documento é então estimada pela mediana desses ângulos, uma medida robusta a valores discrepantes. Assim, retas espúrias produzidas por sombras, ruídos ou outros elementos da imagem exercem pouca influência sobre a estimativa final, desde que a maioria das retas detectadas corresponda às bordas do documento.

## 6.8.4 Limitações Práticas

Embora apresente bom desempenho em condições usuais de digitalização, o método depende da existência de estruturas lineares suficientemente definidas para serem detectadas pela Transformada de Hough, como bordas da página, linhas de formulários ou linhas de texto. Sua precisão pode ser reduzida em imagens com baixa resolução, ruído excessivo, sombras intensas ou grandes inclinações. Em geral, documentos digitalizados com resolução próxima de 300 DPI e iluminação homogênea fornecem resultados adequados para aplicações de OCR e OMR.

A implementação apresentada neste capítulo possui finalidade didática, ilustrando os princípios da correção automática de inclinação por meio da detecção de bordas, da Transformada de Hough e da rotação afim. Por utilizar apenas a orientação das estruturas lineares predominantes, o método pode ser aplicado a diferentes tipos de documentos, sem depender de marcadores específicos.

Em sistemas reais de análise documental, entretanto, o alinhamento normalmente utiliza marcadores geométricos previamente conhecidos. No modelo de folha de respostas empregado pelo ecossistema MCTest, por exemplo, são utilizados quatro discos pretos de referência, além das regiões correspondentes ao cabeçalho, ao *QRCode* e aos quadros de respostas. A localização desses elementos permite estimar simultaneamente a rotação, a escala e a translação da folha, tornando o registro menos sensível à quantidade de texto, à ausência

de linhas estruturais e às variações de impressão ou digitalização.

Por esse motivo, a abordagem baseada na Transformada de Hough é utilizada neste capítulo para introduzir os fundamentos do problema, enquanto as etapas posteriores adotam o alinhamento por marcadores geométricos, estratégia predominante em sistemas de OMR e análise documental.

### 6.8.5 Detecção de Bordas e Contornos

A localização precisa das regiões de interesse é uma etapa essencial em sistemas de OMR. No modelo de folha de respostas utilizado neste capítulo, o cabeçalho e o quadro de respostas estão contidos em um retângulo virtual delimitado por quatro discos pretos posicionados nos cantos. A identificação desses marcadores permite localizar a região de interesse e corrigir distorções geométricas introduzidas durante a aquisição da imagem.

O procedimento é composto por cinco etapas. Inicialmente, aplica-se um **fechamento morfológico** (dilatação seguida de erosão), operação estudada no **Capítulo 4**, utilizando um elemento estruturante em disco (`mm.sedisk(33)`). Essa operação reduz pequenas descontinuidades e preserva os discos de referência, tornando-os mais homogêneos. Em seguida, a imagem é invertida (`mm.neg`), de modo que os discos passem a constituir componentes claros sobre fundo escuro.

Na etapa seguinte, aplica-se a operação `mm.edgeoff` (**Capítulo 4**), que remove componentes conectados às bordas da imagem, eliminando artefatos como sombras de digitalização, marcas de corte e outros objetos espúrios nas margens. Os componentes remanescentes são então analisados a partir de seus contornos e filtrados por propriedades geométricas, como área e circularidade, para identificar os discos candidatos. A implementação do MCTest torna esse processo mais robusto ao selecionar, entre todos os candidatos, os quatro cujos centros formam um retângulo com largura compatível com a da imagem, reduzindo a ocorrência de falsos positivos.

Por fim, os centros dos quatro discos são ordenados espacialmente (superior esquerdo, superior direito, inferior esquerdo e inferior direito) e utilizados como pontos de controle em uma transformação de perspectiva (*perspective warp*). Essa transformação retifica a imagem, produzindo uma representação alinhada e com dimensões conhecidas, adequada às etapas subsequentes de segmentação e reconhecimento.

As principais etapas desse *pipeline*, desde o processamento morfológico até a imagem retificada, são ilustradas a seguir.

```
import cv2
import numpy as np
from morph import mm

# img: imagem em escala de cinza da folha de prova
if img_final.ndim == 2:
    img = img_final
else:
    img = mm.gray(img_final)

# 1. Fechamento morfológico: preserva os discos escuros, removendo tudo menor que o disco
img_close = mm.close(img, mm.sedisk(41))

# 2. Inversão: discos escuros tornam-se componentes claros sobre fundo escuro
img_neg = mm.neg(img_close)

# 3. Remove componentes conectados que tocam a borda da imagem
img_edgeoff = mm.edgeoff(img_neg)

# 4. Extração dos contornos externos
contornos, _ = cv2.findContours(img_edgeoff, cv2.RETR_EXTERNAL, cv2.CHAIN_APPROX_SIMPLE)

# 5. Filtragem por área e circularidade, mantendo apenas os 4 discos
```

```

centros = []
for c in contornos:
    area = cv2.contourArea(c)
    perimetro = cv2.arcLength(c, True)
    if area < 50 or perimetro == 0:
        continue
    circularidade = 4 * np.pi * area / (perimetro ** 2)
    if circularidade > 0.8:
        M = cv2.moments(c)
        cx, cy = M["m10"] / M["m00"], M["m01"] / M["m00"]
        centros.append((cx, cy))

# Verificação robusta: interrompe o pipeline com mensagem clara em vez de AssertionError
if len(centros) != 4:
    print(f"[AVISO] Esperado 4 discos marcadores, encontrado {len(centros)}.")
    print("  Verifique se a imagem é uma folha de respostas MCTest válida")
    print("  ou ajuste os parâmetros de circularidade e área mínima.")
    img_retificada = img # fallback: preserva a imagem sem retificação
else:
    # 6. Ordenação dos centros: superior-esquerdo, superior-direito,
    # inferior-esquerdo, inferior-direito
    pts = np.array(centros, dtype=np.float32)
    soma = pts.sum(axis=1)
    diff = pts[:, 0] - pts[:, 1]
    tl = pts[np.argmin(soma)]
    br = pts[np.argmax(soma)]
    tr = pts[np.argmax(diff)]
    bl = pts[np.argmin(diff)]
    pts_ordenados = np.array([tl, tr, bl, br], dtype=np.float32)

    # 7. Retificação por transformação de perspectiva (warp)
    largura, altura = 800, 800
    destino = np.array(
        [[0, 0], [largura, 0], [0, altura], [largura, altura]], dtype=np.float32
    )
    M_persp = cv2.getPerspectiveTransform(pts_ordenados, destino)
    img_retificada = cv2.warpPerspective(img, M_persp, (largura, altura))

    mm.show(
        [img_close, img_edgeoff, img_retificada],
        titles=["Fechamento (sedisk 41)", "edgeoff", "Retificada (warp)"],
        cols=3,
        figsize=(12, 4)
    )

mm.write(img_retificada, "img_beetween_disks.png")

```




Figura 6.8: Detecção dos discos marcadores, extração de contornos e retificação por transformação de perspectiva.

### Por que funciona? — Do fechamento morfológico à retificação

**Fechamento morfológico:** a dilatação seguida de erosão preenche pequenas descontinuidades e suaviza os contornos dos objetos sem alterar significativamente sua forma global. Ao utilizar um elemento estruturante grande (`sedisk(41)`), detalhes finos, como textos, linhas do formulário e pequenos ruídos, tendem a ser incorporados ao fundo durante o processamento, enquanto objetos de maior escala, como os discos de referência, permanecem preservados e tornam-se mais homogêneos.

**Circularidade:** após o isolamento dos componentes candidatos, a métrica  $C = \frac{4\pi A}{P^2}$  quantifica o quanto sua forma se aproxima de um círculo. Seu valor é igual a 1 para um círculo perfeito e diminui à medida que o contorno se torna mais irregular. Assim, um limiar como  $C > 0,8$  permite descartar a maior parte dos falsos positivos sem recorrer a modelos de aprendizado. Um simulador dessa métrica é apresentado na Figure 6.9.

**Transformação de perspectiva (*perspective warp*):** uma vez identificados os quatro discos de referência, seus centros são utilizados como pontos de controle para estimar a transformação projetiva que mapeia a imagem capturada para o plano do documento. Essa transformação corrige as distorções introduzidas pela perspectiva durante a aquisição da imagem, produzindo uma representação frontal com dimensões conhecidas e adequada às etapas subsequentes de segmentação e reconhecimento.

#### 6.8.6 Isolamento, Segmentação e Decodificação do *QRCode*

Após a retificação geométrica da folha de respostas, realiza-se a detecção e a decodificação do *QRCode* presente no formulário. Esse marcador armazena informações utilizadas pelo sistema de OMR (*Optical Mark Recognition*), como a identificação do estudante, o código da prova e sua variação, possibilitando a recuperação do gabarito correspondente no banco de dados. Por segurança, essas informações são criptografadas antes da geração do *QRCode*. Assim, a sequência decodificada corresponde a uma *string* hexadecimal, cuja interpretação é realizada exclusivamente pelo sistema MCTest. O procedimento é composto por três etapas: pré-processamento morfológico, isolamento da região do *QRCode* e decodificação de seu conteúdo.

Inicialmente, a imagem retificada em escala de cinza é binarizada por meio da operação `mm.threshold`. Em seguida, aplica-se uma **abertura morfológica** (erosão seguida de dilatação), estudada no **Capítulo 4**, utilizando um elemento estruturante quadrado (`mm.sebox(2)`). Essa operação remove pequenos ruídos e suaviza imperfeições sem comprometer a estrutura do marcador. Por fim, a imagem é invertida (`mm.neg`), de modo que o *QRCode* passe a constituir um componente claro sobre fundo escuro, facilitando a extração de seus contornos.

A localização do *QRCode* é realizada pela análise dos contornos externos da imagem binarizada. Entre os componentes detectados, seleciona-se aquele com maior área e geometria aproximadamente quadrada,




Figura 6.9: Simulador interativo de filtragem por circularidade: mova o *slider* para ajustar o limiar  $C$  e observe quais componentes são aceitos (verde) ou rejeitados (vermelho).

descartando os demais elementos impressos da folha. Em seguida, a região correspondente é expandida por uma pequena margem de segurança, garantindo a preservação integral do marcador.

O *QRCode* é então extraído diretamente da imagem retificada em escala de cinza, preservando sua qualidade radiométrica. Como essa região geralmente apresenta dimensões reduzidas, aplica-se um redimensionamento com interpolação cúbica, aumentando a resolução espacial e favorecendo a identificação de seus módulos. A leitura é realizada pelo detector de *QRCode* do OpenCV (`cv2.QRCodeDetector`), que recupera a sequência de caracteres originalmente codificada.

O fluxo completo desse processamento, desde o pré-processamento morfológico até a decodificação do *QRCode*, é ilustrado na Figure 6.10. O trecho exibido na saída corresponde apenas ao início da *string* hexadecimal criptografada; sua interpretação completa é realizada internamente pelo MCTest após a decodificação.

```
import cv2
import numpy as np
from morph import mm

# f: imagem retificada convertida para o tipo correto de 8 bits (0-255)
f = img_retificada.astype('uint8')

# 1. Limiarização: conversão da imagem em tons de cinza para binária
f_thresh = mm.threshold(f)

# 2. Abertura morfológica: elimina pequenos ruídos e suaviza o contorno dos blocos
f_open = mm.open(f_thresh, mm.sebox(2))

# 3. Inversão morfológica: módulos escuros tornam-se componentes claros sobre fundo escuro
f_inv = mm.neg(f_open)

# 4. Conversão segura para uint8 com escala 0-255
img_uint8 = (f_inv.astype(np.uint8) * 255) if f_inv.max() == 1 else f_inv.astype(np.uint8)

# 5. Detecção de contornos externos
contornos, _ = cv2.findContours(img_uint8, cv2.RETR_EXTERNAL, cv2.CHAIN_APPROX_SIMPLE)

if not contornos:
    raise ValueError("Nenhum contorno encontrado. Verifique o limiar ou a imagem de entrada.")

# 6. Filtragem pelo maior contorno com proporção aproximadamente quadrada
# (aspect ratio entre 0.7 e 1.3 descarta retângulos alongados da folha)
def is_square_like(contorno, tol=0.3):
    x, y, w, h = cv2.boundingRect(contorno)
    ratio = w / h if h > 0 else 0
    return (1 - tol) <= ratio <= (1 + tol)

candidatos = [c for c in contornos if is_square_like(c)]

if not candidatos:
    raise ValueError(
        "Nenhum contorno quadrado encontrado. "
        "Verifique se o QRCode está presente na imagem ou ajuste a tolerância."
    )

# Seleciona o maior candidato quadrado por área de bounding box
maior_contorno = max(candidatos, key=lambda c: cv2.boundingRect(c)[2] * cv2.boundingRect(c)[3])
x, y, w, h = cv2.boundingRect(maior_contorno)

# 7. Expansão da bounding box com margem de segurança (evita truncamento do QRCode)
margem = 5
h_img, w_img = img_uint8.shape[:2]
```



```

x1 = max(x - margem, 0)
y1 = max(y - margem, 0)
x2 = min(x + w + margem, w_img)
y2 = min(y + h + margem, h_img)

# 8. Recorte da região de interesse a partir da imagem original (nítida, em cinza)
img_qrcode_final = img_retificada[y1:y2, x1:x2]

# 9. Ampliação para resolução mínima de decodificação (400 px no lado maior)
# cv2.QRCodeDetector requer módulos com ao menos 3-4 px de largura para decodificar
# com segurança; imagens menores que ~400 px tendem a falhar.
lado = max(img_qrcode_final.shape[:2])
escala = max(400 / lado, 1.0)
img_para_leitura = cv2.resize(
    img_qrcode_final, None,
    fx=escala, fy=escala,
    interpolation=cv2.INTER_CUBIC
)

# 10. Inicialização do detector nativo de QRCode do OpenCV
detector = cv2.QRCodeDetector()

# 11. Detecção geométrica e decodificação dos dados textuais
dados, pontos, qrcode_reto = detector.detectAndDecode(img_para_leitura)

# Visualização intermediária: progressão da binarização ao isolamento do QRCode
mm.show(
    [f_thresh, f_open, f_inv, img_qrcode_final],
    titles=["1. Limiarização", "2. Abertura morfológica", "3. Inversão", "Imagem final"],
    cols=3, figsize=(12, 4)
)

# Validação e saída dos metadados extraídos
if dados:
    print(f"QRCode decodificado com sucesso: \n{dados[:50]}...")
else:
    raise ValueError(
        "Falha na decodificação do QRCode. "
        "Verifique o limiar, as margens da região ou a qualidade da imagem."
    )

```




Figura 6.10: *Pipeline* de processamento do *QRCode*: limiarização, abertura morfológica, inversão e recorte final para decodificação.



QRCode decodificado com sucesso:

325a356b71367266556955646b7233454149624a694f417730...

Simulador: Pipeline de Isolamento do QRCode

Threshold → Fechamento → Contorno Quadrado → Recorte

Selecione a etapa:

0 · Original


1 · Limiarização

2 · Fechamento

3 · Contorno

4 · Recorte

Imagem original em escala de cinza: documento com QRCode no canto superior direito e bolhas de respostas.



Etapas do pipeline (replica fiel do algoritmo OpenCV de referência)

- 1 **Limiarização** (`mm.threshold`): Segmenta os módulos escuros do QRCode isolando-os do fundo claro.
- 2 **Fechamento morfológica** (`mm.close + mm.sebox(k)`): dilatação seguida de erosão remove ruídos e preenche discontinuidades. `sebox(0)` = kernel 3×3, `sebox(1)` = 5×5, e assim por diante. Note que aqui se usa *fechamento* (≠ abertura usada na célula de código acima), o que estimula a comparação entre os dois operadores.
- 4 **Deteção de contornos** (`cv2.findContours, RETR_EXTERNAL`): Busca o maior contorno externo com proporção aproximadamente quadrada (razão largura/altura entre 0.7 e 1.3), descartando retângulos alongados da folha.
- 5 **Recorte + margem de segurança**: Extrai a *bounding box* do contorno selecionado, com margem de 5px, a partir da imagem original em escala de cinza.

Figura 6.11: Simulador interativo do *pipeline* de isolamento do QRCode: navegue pelas etapas de filtragem, ajuste o elemento estruturante do fechamento morfológica e veja a detecção do contorno quadrado sobre a imagem original do gabarito.

Por que funciona? — Isolamento e decodificação do QRCode

**Abertura morfológica:** diferentemente do fechamento, a abertura (erosão seguida de dilatação) remove pequenos ruídos e protuberâncias sem alterar significativamente a geometria dos objetos maiores. Assim, preserva a estrutura do QRCode enquanto elimina componentes espúrios que poderiam dificultar sua localização.

**Seleção por geometria:** o QRCode possui formato aproximadamente quadrado ( $w/h \approx 1$ ). A combinação desse critério com a seleção do componente de maior área descarta linhas do formulário, textos e outros elementos impressos, permitindo isolar o marcador sem o uso de modelos de aprendizado.

**Redimensionamento antes da decodificação:** quando o QRCode ocupa poucos pixels na imagem, seus módulos tornam-se difíceis de distinguir. O redimensionamento com interpolação cúbica aumenta a resolução espacial da região de interesse, facilitando a identificação dos padrões do código pelo `cv2.QRCodeDetector` e tornando a decodificação mais robusta.

### 6.8.7 Decodificação de Códigos de Barras

Na seção anterior, a decodificação de *QR Codes* foi realizada utilizando o detector nativo do OpenCV (`cv2.QRCodeDetector`), que integra em uma única interface a detecção geométrica do símbolo, sua retificação e a extração da informação codificada.

Para códigos de barras lineares (1D), como EAN-13, Code 39 e Code 128, uma alternativa amplamente utilizada é a biblioteca `pyzbar`. Diferentemente do `QRCodeDetector`, ela suporta diversas simbologias de códigos de barras e também pode ser empregada na leitura de *QR Codes*.

O procedimento consiste em localizar automaticamente cada símbolo presente na imagem e interpretar a sequência de barras e espaços correspondente, produzindo a cadeia de caracteres codificada. Além dos dados decodificados, a biblioteca fornece informações como a simbologia identificada e a posição do código na imagem, permitindo sua posterior validação ou processamento.

A Figure 6.12 apresenta um exemplo de código de barras e o resultado de sua decodificação utilizando a biblioteca `pyzbar`.

```
import os
import urllib.request
import numpy as np
from pyzbar.pyzbar import decode
from morph import mm

barcode_path = 'dados/barcode.png'
url_github = (
    "https://raw.githubusercontent.com/fzampirolli/"
    "pdi-vc/master/all/cap06/dados/barcode.png"
)

# Se o arquivo não existir localmente, baixa automaticamente do GitHub
if not os.path.exists(barcode_path):
    print(f"[DOWNLOAD] Baixando código de barras do GitHub: {url_github}")
    try:
        os.makedirs(os.path.dirname(barcode_path), exist_ok=True)
        urllib.request.urlretrieve(url_github, barcode_path)
        print("[DOWNLOAD] Imagem baixada com sucesso!")
    except Exception as e:
        print(f"[DOWNLOAD] Falha ao baixar o arquivo: {e}")

if os.path.exists(barcode_path):
    image = mm.read(barcode_path)
else:
    # Fallback sintético: gera um padrão de barras verticais que simula um Code-128
    print("[AVISO] Arquivo 'dados/barcode.png' não encontrado.")
    print("Usando imagem sintética para demonstração do pipeline.")
    h, w = 100, 400
    img_synth = np.ones((h, w), dtype=np.uint8) * 255
    # Barras escuras em posições regulares (padrão simplificado)
    for x in range(20, w - 20, 8):
        if (x // 8) % 3 != 0:
            img_synth[:, x:x+4] = 0
    image = img_synth

mm.show(image)

# Executa o decode do pyzbar
try:
    barcodes = decode(image)
except ImportError:
```

```
print("[ERRO] zbar do sistema não encontrada. Rode: !apt-get install -y libzbar0")
barcodes = []

if barcodes:
    dados_bc = barcodes[0].data.decode("utf-8")
    tipo = barcodes[0].type
    print(f"Código de barras decodificado com sucesso [{tipo}]:\n{dados_bc}")
else:
    print("[INFO] Nenhum código de barras detectado na imagem.")
    print(
        "Em imagem sintética isso é esperado - "
        "substitua pelo arquivo real para decodificar."
    )
```



Figura 6.12: Decodificação de código de barras linear com *pyzbar*: imagem de entrada e dados extraídos.

```
Código de barras decodificado com sucesso [EAN13]:
00000000000055
```

## 6.9 O MCTest como Estudo de Caso: do Protótipo ao Sistema em Produção

Até este ponto, as principais etapas do *pipeline* de processamento foram apresentadas e analisadas individualmente, incluindo a correção da inclinação (*des skew*), a detecção de marcadores, a retificação por perspectiva e a leitura de *QR Codes*. Embora essa abordagem facilite a compreensão de cada técnica, aplicações reais exigem a integração dessas etapas em um fluxo de processamento único e consistente.

O **MCTest** constitui um exemplo dessa integração. Desenvolvido na UFABC e disponibilizado como software de código aberto, o sistema é utilizado desde 2012 na correção automatizada de avaliações, oferecendo suporte a diferentes modelos de folhas de resposta, gabaritos individualizados e geração automática de relatórios de desempenho (Zampirolli, 2023).

A partir deste ponto, o foco deixa de ser a implementação isolada de algoritmos e passa a ser a organização desses algoritmos em uma aplicação completa. Além da qualidade dos métodos de processamento de imagens, um sistema dessa natureza deve atender a requisitos como robustez diante de diferentes condições de aquisição, facilidade de manutenção e capacidade de evolução para novas funcionalidades.

Nas próximas seções, será analisado o módulo de Visão Computacional do **MCTest**, implementado no arquivo `CVMCTest.py`. O objetivo é mostrar como os conceitos apresentados ao longo deste capítulo são combinados em um *pipeline* de processamento empregado em uma aplicação real.

### 6.9.1 Obtenção e Preparação do Módulo

O arquivo `CVMCTest.py` integra o sistema **MCTest** e, em sua versão original, depende de modelos, configurações e outros componentes do *framework* Django. Como essas dependências não estão disponíveis no ambiente utilizado neste capítulo, o módulo precisa ser adaptado para execução de forma independente.

Para isso, o arquivo é obtido diretamente do repositório do projeto por meio da biblioteca **requests**. Em seguida, comandos `sed` são empregados para remover as importações e dependências específicas do ambiente Web, produzindo uma versão autocontida do módulo. Essa adaptação preserva a implementação dos algoritmos de Visão Computacional, permitindo sua execução e análise sem a necessidade de instalar ou configurar toda a infraestrutura do sistema **MCTest**.

```
import requests
CVMCTest = requests.get(
    "https://raw.githubusercontent.com/fzampirolli/mctest/master/exam/CVMCTest.py"
)
with open('CVMCTest.py', 'w') as writefile:
    writefile.write(CVMCTest.text)
```

Cada comando `sed` remove importações específicas do ambiente Django, tornando o arquivo `CVMCTest.py` utilizável de forma independente neste capítulo.

```
# remove linhas with "from django.", ...
!sed --in-place '/from django./d' CVMCTest.py
!sed --in-place '/from exam./d' CVMCTest.py
!sed --in-place '/from mctest./d' CVMCTest.py
!sed --in-place '/from student./d' CVMCTest.py
!sed --in-place '/from topic./d' CVMCTest.py
!sed --in-place '/from .models import VariationExam/d' CVMCTest.py
```

**i** 🧠 Por que remover as dependências do Django?

Na implementação original, o arquivo `CVMCTest.py` faz parte de uma aplicação desenvolvida com o *framework* Django e, por isso, importa modelos, configurações e outros componentes específicos desse ambiente. Como esses elementos não estão disponíveis neste capítulo, o módulo não pode ser importado diretamente.

Os comandos `sed` removem apenas essas dependências, sem alterar as rotinas de Visão Computacional implementadas no arquivo. Dessa forma, o módulo pode ser executado de maneira independente, preservando o comportamento dos algoritmos apresentados.

Esse procedimento ilustra um princípio importante de engenharia de software: separar a lógica da aplicação da infraestrutura em que ela está inserida, facilitando a reutilização, os testes e o estudo de componentes específicos.

### 6.9.2 Extração da Área de Respostas

Após a leitura da folha, a função `getAnswerArea` executa automaticamente as etapas de detecção dos marcadores de referência e retificação por perspectiva apresentadas nas seções anteriores. Como resultado, é obtida uma imagem contendo apenas a região destinada às respostas, alinhada e com dimensões padronizadas.

Essa padronização simplifica as etapas subsequentes de processamento, pois a localização dos campos de marcação passa a ser conhecida e independente da posição original da folha durante a digitalização.

A Figure 6.13 apresenta a folha de respostas original em escala de cinza, enquanto a Figure 6.14 mostra a região de respostas obtida após a aplicação da função `getAnswerArea`.

```
import os
from pdf2image import convert_from_path
from skimage import data as skdata
import cv2
from morph import mm

file = "dados/provas_qrcode_EP.pdf"
MYFILES = 'extra02.qrcode'

if os.path.exists(file):
    pages = convert_from_path(file, 200) # dpi 100=min 500=max
    numPAGES = 0
    for page in pages:
        myfile0 = MYFILES + '_p' + str(numPAGES) + '.png'
        page.save(myfile0)
```

```

    numPAGES += 1
    print(f"[INGESTÃO] Página convertida: {myfile0}")
    pages.clear()
    img_color = mm.read(myfile0)
    img_inicial = mm.gray(img_color)
else:
    print("[AVISO] Arquivo 'dados/provas_qrcode.pdf' não encontrado.")
    print("        Usando imagem pública skimage.data.page() como substituto.")
    img_inicial = skdata.page()

mm.show(img_inicial)

```

```

[INGESTÃO] Página convertida: extra02.qrcode_p0.png
[INGESTÃO] Página convertida: extra02.qrcode_p1.png
[INGESTÃO] Página convertida: extra02.qrcode_p2.png

```




Figura 6.13: Imagem da folha de respostas em escala de cinza carregada a partir do PDF rasterizado.

```

import CVMCTest
countPage = 0
img_getAnswerArea = CVMCTest.cvMCTest.getAnswerArea(img_inicial, countPage)

```

```
mm.show(img_getAnswerArea)
```




Figura 6.14: Área de respostas extraída por *getAnswerArea*: região retificada contendo os quadros de marcação.

**Nota de compatibilidade:** versões recentes do NumPy ( 2.0) removeram o alias `np.int0`. Caso `CVMCTest.py` utilize esse tipo, o comando abaixo aplica a correção diretamente no arquivo antes de recarregá-lo:

```
!sed -i 's/box = np.int0(cv2.boxPoints(rect))/box = cv2.boxPoints(rect).astype(np.intp)/' \
./CVMCTest.py
```

```
import importlib
import CVMCTest

importlib.reload(CVMCTest)
```

```
<module 'CVMCTest' from '/home/fz/fz/VSCoDe/pdi-vc/all/cap06/CVMCTest.py'>
```

### 6.9.3 Segmentação do *QRCode*

Após a extração da área de respostas, o `MCTest` realiza duas etapas preparatórias para a leitura das marcações: a segmentação do *QRCode* e a localização dos quadros que contêm as questões.

A função `segmentQRcode` isola a região da imagem correspondente ao *QRCode*, apresentada na Figure 6.15. Em seguida, essa região é processada pela função `getQRCode`, responsável por sua decodificação e pela extração dos metadados da prova.

Caso o *QRCode* não possa ser decodificado, o processamento da folha continua normalmente. As respostas do estudante ainda são lidas e registradas no arquivo CSV de saída; apenas as informações obtidas a partir do *QRCode*, como a identificação da prova ou do estudante, permanecem indisponíveis.

```
import CVMCTest
imgQRcode = CVMCTest.cvMCTest.segmentQRcode(img_getAnswerArea, countPage)
mm.show(imgQRcode)
```





Figura 6.15: Região do *QRCode* isolada por *segmentQRcode* dentro da área de respostas retificada.

A função `CVMCTest.cvMCTest.getQRcode(img, countPage)` integra as etapas de segmentação e decodificação do *QRCode*. Internamente, ela utiliza `CVMCTest.cvMCTest.decodeQRcode(imgQRcode)` para interpretar a *string* hexadecimal codificada no símbolo e construir o dicionário `qr`, além de retornar o indicador lógico `myFlagArea`, que informa se a leitura foi realizada com sucesso.

O dicionário `qr` reúne os metadados da prova utilizados nas etapas subsequentes de processamento. Seus principais campos são:

- **date:** identificador temporal da prova, composto pela data de geração e por um *timestamp* interno do MCTest.
- **idClassroom, idExam e idStudent:** identificadores da turma, da prova e do estudante.
- **term:** período letivo.
- **stylesheet:** folha de estilo utilizada na geração do formulário.
- **var1 a var5:** quantidade de questões em cada nível de dificuldade.
- **text:** número de questões dissertativas.
- **answer:** número de alternativas por questão.
- **numquest:** número total de questões.
- **correct e dbtext:** campos preenchidos durante a correção, contendo o gabarito e informações adicionais.
- **variations e variant:** informações sobre as versões da prova.

Esses metadados identificam a prova e o estudante, permitindo selecionar o gabarito correspondente e parametrizar as etapas seguintes de leitura e correção das respostas.

```
myFlagArea, qr = CVMCTest.cvMCTest.getQRcode(img_inicial, countPage)
myFlagArea, qr
```

```
(True,
{'date': '260208-1770403541363',
 'idClassroom': '955',
 'idExam': '810',
 'idStudent': '448898',
 'term': '0',
 'stylesheet': '1',
 'var1': '50',
 'var2': '0',
 'var3': '0',
 'var4': '0',
 'var5': '0',
 'text': '0',
 'answer': '5',
```



```
'numquest': 50,
'correct': '',
'dbtext': '',
'variations': '0',
'variant': '0'})
```

Esses metadados permitem identificar a prova, recuperar o gabarito correspondente e parametrizar as etapas subsequentes de processamento.

Após a decodificação do *QRCode*, o processamento retorna à área de respostas para localizar os quadros que contêm as marcações do estudante.

#### 6.9.4 Localização dos Quadros de Respostas

A imagem produzida por `getAnswerArea` contém toda a região útil da folha, incluindo o cabeçalho, onde se encontra o *QRCode*, e os quadros destinados às respostas. Como a leitura das marcações utiliza apenas esses quadros, a região correspondente ao cabeçalho é descartada por meio do recorte `img_getAnswerArea[300:, :]`.

A Figura 6.16 apresenta essa região de interesse. Embora esse recorte seja posteriormente utilizado pela função `findSquares` para localizar os quadros de respostas, o `MCTest` realiza inicialmente a leitura do *QRCode*, pois ele contém os metadados necessários para identificar a prova e configurar as etapas subsequentes do processamento.

```
img_getAnswerArea_aux = img_getAnswerArea[300:, :]
mm.show(img_getAnswerArea_aux)
```




Figura 6.16: Recorte inferior da área de respostas, concentrando os quadros de bolhas a serem segmentados.

A função `findSquares` recebe a imagem da área de respostas e os metadados armazenados em `qr`, retornando as coordenadas dos quadros que delimitam os grupos de questões.

Cada elemento de `rectSquares` contém as coordenadas dos vértices superior esquerdo e inferior direito de um quadro de respostas, que serão utilizadas na etapa de segmentação das bolhas.

```
rectSquares = CVMCTest.cvMCTest.findSquares(qr, img_getAnswerArea, countPage)
rectSquares
```

```
[[[np.int64(395), np.int64(350)], [np.int64(950), np.int64(516)]],
 [[np.int64(394), np.int64(602)], [np.int64(951), np.int64(767)]]]
```

#### 6.9.5 Leitura Automática das Respostas

Conhecidos os metadados da prova (`qr`) e as coordenadas dos quadros de respostas (`rectSquares`), o `MCTest` identifica automaticamente as alternativas marcadas pelo estudante.

O código a seguir integra as etapas apresentadas anteriormente. Para cada quadro delimitado em `rectSquares`, as funções `setColumns` e `setLines` estimam, respectivamente, o número de alternativas por questão e o número de questões a partir da distribuição espacial das bolhas. Em seguida, `segmentAnswers` determina a alternativa assinalada em cada questão e `setAnswersOneLine` reúne os resultados de todos os quadros no campo `qr['answers']`.

No modo de operação adotado neste capítulo, em que o `MCTest` é executado de forma independente de seu banco de dados, o conteúdo de `qr['answers']` é comparado ao gabarito armazenado na primeira página do arquivo PDF, correspondente ao modelo de prova sem enunciados utilizado nos exemplos.

A Figure 6.17 apresenta os quadros de respostas processados pelo algoritmo, enquanto a saída do programa exibe o conteúdo final de `qr['answers']`.

```
testAnswers = []
if myFlagArea:

    imgQ_all = []

    for countSquare in range(len(rectSquares)):
        p1, p2 = rectSquares[countSquare]

        if True:
            imgQi = CVMCTest.cvMCTest.imgAnswers[p1[0]:p2[0], p1[1]:p2[1]]
            [NUM_COLUMNS, img] = CVMCTest.cvMCTest.setColumns(imgQi, countPage, countSquare)
            [NUM_LINES, img] = CVMCTest.cvMCTest.setLines(imgQi, countPage, countSquare)
            NUM_RESPOSTAS = NUM_COLUMNS
            NUM_QUESTOES = NUM_LINES

            imgQiNC = CVMCTest.cvMCTest.imgAnswers[p1[0]:p2[0], p1[1]:p2[1]]
            testAnswers.append(CVMCTest.cvMCTest.segmentAnswers(
                [imgQi, imgQiNC], countPage, countSquare, NUM_QUESTOES, qr

            ))

            imgQ_all.append(imgQiNC)

    qr = CVMCTest.cvMCTest.setAnswersOneLine(testAnswers, qr)
    # deixa as respostas de cada quadro em uma linha

mm.show(imgQ_all)
print(f"Respostas lidas das {len(qr['answers'].split(","))} questões: \
      \n{qr['answers'][:-19]}...")
```




Figura 6.17: Respostas lidas automaticamente pelo MCTest após segmentação e classificação de todas as bolhas.

Respostas lidas das 50 questões:

C,A,A,C,E,D,E,C,A,E,B,B,A,D,A,B,C,B,E,D,B,D,A,C,E,B,A,A,B,B,C,A,C,A,C,A,B,C,C,C,...

#### 💡 Conectando os Pontos

O campo `qr['answers']` representa o resultado final do *pipeline* de Visão Computacional apresentado neste capítulo. Sua obtenção integra todas as etapas estudadas, desde a rasterização do documento e a retificação geométrica até a extração da área de respostas, a decodificação do *QRCode*, a localização dos quadros e a identificação das alternativas marcadas.

Esse *pipeline* ilustra a transição de um protótipo para um sistema em produção. No MCTest, os algoritmos de Visão Computacional permanecem essencialmente os mesmos; as principais diferenças concentram-se em aspectos de engenharia de software, como tratamento de exceções, suporte a diferentes modelos de formulários, integração com banco de dados, interface Web e mecanismos de auditoria e manutenção.

Nos experimentos deste capítulo, a primeira página do arquivo PDF contém o gabarito da prova, enquanto as páginas subsequentes correspondem às folhas de respostas dos estudantes. Após a obtenção de `qr['answers']`, o MCTest compara automaticamente as respostas lidas com o gabarito para calcular a pontuação de cada estudante.

Na utilização completa do sistema, os resultados da correção são consolidados em um arquivo CSV e enviados ao professor juntamente com um arquivo compactado contendo informações auxiliares para auditoria. Entre esses arquivos estão os recortes das questões em que foram detectadas múltiplas marcações ou outras situações que exigem revisão manual. O professor pode, então, inspecionar essas imagens, decidir a interpretação mais adequada e, se necessário, atualizar o arquivo CSV antes da importação definitiva das notas.

## 6.10 Inspeção Industrial Automatizada

A inspeção visual automatizada é uma aplicação da Visão Computacional em que imagens de peças ou produtos são analisadas para verificar o atendimento a critérios de qualidade previamente definidos. Em uma linha de produção, as imagens podem ser obtidas por câmeras ou outros dispositivos de aquisição e processadas automaticamente para identificar defeitos, medir dimensões ou verificar a presença de componentes.

A estratégia de inspeção depende das características do produto, do tipo de defeito de interesse e da disponibilidade de uma imagem de referência. Neste capítulo são apresentadas duas abordagens clássicas:

- **Subtração de imagens:** compara a imagem da peça inspecionada com uma imagem de referência

considerada livre de defeitos. Regiões em que a diferença de intensidade excede um limiar são classificadas como possíveis defeitos. Essa abordagem pressupõe que as imagens estejam geometricamente alinhadas e tenham sido adquiridas sob condições semelhantes de iluminação.

- **Análise de textura:** utiliza características da textura da superfície para identificar regiões cuja aparência difere do padrão esperado, sem a necessidade de uma imagem de referência. Essa abordagem é adequada para materiais que apresentam textura aproximadamente homogênea, como tecidos, papéis e superfícies metálicas.

Nas próximas seções, essas duas estratégias são ilustradas por meio de exemplos construídos a partir de imagens da biblioteca `skimage.data`. O objetivo é apresentar os princípios de funcionamento de cada abordagem em experimentos que possam ser reproduzidos integralmente pelo leitor.

### 6.10.1 Referências e *Datasets* Públicos

Em aplicações de inspeção industrial, o desempenho de algoritmos de detecção de defeitos é frequentemente avaliado em *datasets* públicos, que fornecem imagens representativas e, em muitos casos, anotações de referência (*ground truth*). Neste capítulo, entretanto, os exemplos utilizam imagens sintéticas derivadas de `skimage.data` (ver Figure 6.18), permitindo reproduzir todos os experimentos sem dependência de bases de dados externas.

Para estudos mais abrangentes e comparação entre algoritmos, destacam-se os seguintes *datasets* públicos:

- **MVTec *Anomaly Detection Dataset* (MVTec AD):** conjunto de imagens de objetos e texturas, contendo amostras sem defeitos e com defeitos, acompanhadas de máscaras de segmentação em nível de pixel para as imagens anômalas (Bergmann et al., 2019). Disponível em: <https://www.mvtec.com/company/research/datasets/mvtec-ad>.
- **Kolektor *Surface-Defect Dataset* (KolektorSDD):** conjunto de imagens de componentes industriais com defeitos superficiais anotados, utilizado em estudos de detecção e segmentação de defeitos (Tabernik et al., 2020). Disponível em: <https://www.vicos.si/resources/kolektorsdd/>.
- **NEU *Surface Defect Database*:** conjunto de imagens de superfícies de aço laminado, organizado em seis categorias de defeitos superficiais, frequentemente empregado na avaliação de métodos de classificação e detecção (Song; Yan, 2013). Disponível em: [http://faculty.neu.edu.cn/songkechen/zh\\_CN/zdylm/263270/list/index.htm](http://faculty.neu.edu.cn/songkechen/zh_CN/zdylm/263270/list/index.htm).

```
import numpy as np
from skimage import data, color
from morph import mm

# Imagem de referência (produto sem defeito)
product_color = data.coffee()
product_gray = color.rgb2gray(product_color)

# Inserção de defeito simulado: arranhão escuro de 10×100 px
defect_image = np.copy(product_gray)
defect_image[100:110, 200:300] = 0.1

# Detecção por subtração e limiarização
difference = np.abs(product_gray - defect_image)
defect_threshold = 0.15 # ajustável conforme a aplicação
detected_defect = (difference > defect_threshold).astype(np.uint8) * 255

mm.show(
    [product_gray, defect_image, detected_defect],
    titles=["Referência", "Com defeito", "Defeito detectado"],
    cols=3,
    figsize=(12, 4)
```

)

```
status = "Defeito detectado." if detected_defect.any() else "Produto conforme."  
print(status)
```



Figura 6.18: Detecção de defeito por subtração de imagem: produto de referência, imagem com defeito simulado e máscara de anomalia detectada.

Defeito detectado.

### i Subtração de Imagens: Registro Geométrico e Princípio de Funcionamento

A subtração de imagens pressupõe que a imagem de inspeção esteja geometricamente alinhada à imagem de referência. Diferenças de posicionamento, rotação, escala ou perspectiva produzem regiões de diferença que podem ser confundidas com defeitos.

Em aplicações com aquisição controlada, esse alinhamento é obtido durante a captura por meio de gabaritos mecânicos, esteiras e câmeras fixas, permitindo comparar diretamente imagens sucessivas. Um exemplo é a inspeção de uma caixa de ferramentas sempre posicionada na mesma orientação para verificar a ausência de algum item.

Quando esse controle não é possível, emprega-se o **registro de imagens**, que estima uma transformação geométrica para compensar diferenças de translação, rotação, escala e, quando necessário, perspectiva. Após o registro, realiza-se a comparação pixel a pixel entre as duas imagens. Em regiões sem alterações, as diferenças de intensidade tendem a ser próximas de zero; onde existe um defeito, surgem diferenças locais que podem ser destacadas por limiarização. A utilização da diferença absoluta permite detectar tanto defeitos mais claros quanto mais escuros que a referência.

O desempenho do método depende principalmente da qualidade do alinhamento geométrico e da escolha do limiar utilizado para separar pequenas variações de aquisição das diferenças associadas aos defeitos. A Figure 6.19 ilustra o efeito do desalinhamento entre as imagens e a importância do registro geométrico antes da aplicação da subtração.

## 6.10.2 Detecção de Defeitos por Análise de Textura

Em aplicações nas quais não existe uma imagem de referência, a detecção de defeitos pode ser baseada nas características da textura da superfície. Nesse caso, busca-se identificar regiões cuja aparência difere do padrão predominante do material.

Neste exemplo, utiliza-se a **variância local** como medida de heterogeneidade. Para cada posição da imagem, calcula-se a variância dos níveis de intensidade em uma vizinhança de dimensões fixas. Regiões com baixa variância tendem a apresentar textura mais uniforme, enquanto alterações locais, como riscos, manchas ou imperfeições, podem produzir valores mais elevados dessa medida.

A Figure 6.20 ilustra esse procedimento utilizando a imagem `skimage.data.brick()`. Inicialmente, calcula-se o mapa de variância local por meio de uma janela deslizante. Em seguida, aplica-se uma limiarização para destacar as regiões cuja variância excede o valor especificado, identificando possíveis áreas de interesse para inspeção.

⚙️ Simulador: Subtração de Imagens e Registro Geométrico

Referência – Inspeção > Limiar

📷 Desalinhamento da Captura (Esteira)

Translação horizontal ( $\Delta x$ ): 0 px

Translação vertical ( $\Delta y$ ): 0 px

Rotação ( $\theta$ ): 0.0°

Subtração direta

Subtração com registro

⚙️ Parametrização do Inspetor

Limiar de tolerância (T): 35

🔄 Resetar simulação

Anomalia localizada! Defeito superficial detectado na estrutura interna (103 px afetados).

1. Referência estável

2. Inspeção (captura real)

3. Máscara de anomalia (subtração direta)

🧠 Desafio Pedagógico

Com o modo **Subtração direta** ativo, utilize os controles de translação e rotação para simular pequenos desalinhamentos entre a imagem de referência e a imagem de inspeção. Observe que diferenças de poucos pixels ou de alguns graus já podem produzir regiões de diferença ao longo das bordas da peça, mesmo na ausência de novos defeitos. Para reduzir essas respostas indesejadas, seria necessário aumentar o **limiar de tolerância**, o que também pode diminuir a sensibilidade à detecção de defeitos de baixo contraste, como o arranhão escuro presente no lado esquerdo da peça. Em seguida, alterne para **Subtração com registro**. Após o alinhamento geométrico das imagens, as diferenças decorrentes do posicionamento são reduzidas, permitindo que a subtração evidencie predominantemente o defeito introduzido.

Figura 6.19: Simulador interativo de inspeção industrial por subtração de imagens: controle as distorções geométricas de desalinhamento (registro) e o limiar de detecção para observar o impacto nos falsos positivos.

## Modelagem Matemática

Considere uma imagem em níveis de cinza representada por

$$f : \Omega \subset \mathbb{Z}^2 \rightarrow \mathbb{R},$$

em que  $\Omega$  é o domínio da imagem e  $f(x, y)$  representa a intensidade do pixel nas coordenadas  $(x, y)$ . Em imagens de 8 bits, essas intensidades pertencem ao intervalo  $[0, 255]$ . Neste exemplo, entretanto, elas foram normalizadas para o intervalo  $[0, 1]$ , sem alterar o funcionamento do algoritmo.

Para cada posição da imagem, considera-se uma vizinhança quadrada  $W_{x,y}$  de dimensão  $15 \times 15$  pixels.

A média local é dada por

$$\mu(x, y) = \frac{1}{|W_{x,y}|} \sum_{(u,v) \in W_{x,y}} f(u, v),$$

e a variância local é calculada por

$$\sigma^2(x, y) = \frac{1}{|W_{x,y}|} \sum_{(u,v) \in W_{x,y}} f(u, v)^2 - \mu(x, y)^2.$$

Na implementação a seguir, essas duas médias são obtidas pela função `cv2.blur`,

```
mean = cv2.blur(img, (15,15))
mean2 = cv2.blur(img**2, (15,15))
var = mean2 - mean**2
```

Em seguida, calcula-se a diferença entre os mapas de variância da imagem de referência e da imagem inspecionada,

$$D(x, y) = |\sigma_d^2(x, y) - \sigma_r^2(x, y)|,$$

em que  $\sigma_r^2(x, y)$  e  $\sigma_d^2(x, y)$  são, respectivamente, as variâncias locais da imagem de referência e da imagem contendo o defeito. Após a normalização do mapa  $D(x, y)$ , aplica-se uma limiarização para obter a máscara das possíveis anomalias.

```
import numpy as np
import cv2
from skimage import data as skdata
from morph import mm

# Imagem de textura uniforme (tijolo)
texture = skdata.brick().astype(np.float32) / 255.0

# Inserção de defeito sintético: mancha clara 20x80 px
texture_defect = np.copy(texture)
texture_defect[60:80, 80:160] = 0.95

# Mapa de variância local (janela 15x15)
def variancia_local(img, ksize=15):
    img_f = img.astype(np.float32)
    mean = cv2.blur(img_f, (ksize, ksize))
    mean2 = cv2.blur(img_f ** 2, (ksize, ksize))
    return np.clip(mean2 - mean ** 2, 0, None)

var_ref = variancia_local(texture)
```



```

var_defect = variancia_local(texture_defect)
diff_var   = np.abs(var_defect - var_ref)

# Normaliza e limiariza
diff_norm = (diff_var / diff_var.max() * 255).astype(np.uint8)
_, mask   = cv2.threshold(diff_norm, 30, 255, cv2.THRESH_BINARY)

mm.show(
    [texture, texture_defect, diff_norm, mask],
    titles=["Textura original", "Com defeito", "Δ variância local", "Anomalia detectada"],
    cols=4,
    figsize=(16, 4)
)

status = "Defeito de textura detectado." if mask.any() else "Superfície conforme."
print(status)

```




Figura 6.20: Detecção de heterogeneidade de textura: mapa de variância local e máscara de anomalia.

Defeito de textura detectado.

### Por que funciona? — Análise de Textura

A variância local mede a dispersão das intensidades em uma vizinhança da imagem. Em regiões cuja textura permanece uniforme, essa medida tende a variar pouco. Quando um defeito modifica o padrão da superfície, a distribuição das intensidades também se altera, produzindo diferenças na variância local.

Neste capítulo, a detecção é realizada comparando os mapas de variância da imagem de referência e da imagem com defeito. Após a normalização, aplica-se uma limiarização para destacar as regiões em que essa diferença excede um valor especificado.

Os principais parâmetros do método são o tamanho da janela utilizada no cálculo da variância e o limiar empregado na segmentação. Janelas menores são mais sensíveis a detalhes finos, enquanto janelas maiores produzem mapas mais suaves e podem reduzir a resposta a defeitos de pequenas dimensões.

## 6.11 Resumo

Neste capítulo foram apresentados métodos de Visão Computacional aplicados à análise de documentos e à inspeção visual automatizada. As principais técnicas estudadas foram:

- **Pré-processamento de documentos:** aplicação de normalização de fundo, equalização adaptativa (CLAHE) e limiarização por Otsu para reduzir os efeitos de iluminação não uniforme e melhorar a segmentação do texto.
- **Reconhecimento óptico de caracteres (OCR):** conversão de imagens de documentos em texto codificado por meio do Tesseract OCR, evidenciando a influência do pré-processamento na qualidade

do reconhecimento.

- **Tradução automática:** aplicação de técnicas de processamento de linguagem natural para traduzir o texto obtido pelo OCR.
- **Retificação geométrica de documentos:** utilização do detector de bordas de Canny, da Transformada de Hough e de transformações projetivas para corrigir a perspectiva de documentos digitalizados.
- **Localização e retificação de formulários:** emprego de operações morfológicas, análise de contornos e transformação de perspectiva para identificar marcadores de referência e extrair automaticamente regiões de interesse.
- **Leitura de códigos bidimensionais e unidimensionais:** detecção e decodificação de *QR Codes* e códigos de barras para identificação automática de documentos e metadados.
- **Reconhecimento óptico de marcas (OMR):** leitura automatizada de formulários e folhas de respostas, ilustrada por um estudo de caso do sistema MCTest.
- **Inspeção industrial:** detecção de defeitos por comparação com uma imagem de referência e por análise da variância local.

Ao longo do capítulo, os algoritmos foram implementados e avaliados com imagens da biblioteca `skimage.data` e com documentos reais, permitindo reproduzir os experimentos apresentados.

## Próximos Passos

Os métodos apresentados neste capítulo mostram como técnicas de Processamento Digital de Imagens, Visão Computacional e Processamento de Linguagem Natural podem ser integradas em *pipelines* para análise automatizada de documentos.

No próximo capítulo serão estudadas técnicas de **extração de características** e **reconhecimento de padrões**, com ênfase em descritores capazes de representar imagens por atributos numéricos para comparação, classificação e reconhecimento automático. Esses conceitos constituem a base para os capítulos dedicados ao aprendizado de máquina e ao aprendizado profundo aplicados à Visão Computacional.

## 6.12 Uso do Gemini Notebook como Tutor Complementar

Como apoio ao estudo deste capítulo, recomenda-se a utilização do **Gemini Notebook** como tutor complementar. A ferramenta emprega modelos de inteligência artificial para responder perguntas, elaborar resumos e explicar conceitos com base nos documentos fornecidos como fonte de consulta, permitindo ao estudante revisar o conteúdo de forma interativa.

 Estude com o Tutor Inteligente

 [ACESSAR Gemini Notebook: CAPÍTULO 06](#)

### Uso Crítico das Respostas

As respostas geradas pelo Gemini Notebook são produzidas automaticamente por um modelo de inteligência artificial e podem conter omissões ou imprecisões. Por esse motivo, elas devem ser utilizadas como material de apoio, e não como substitutas do estudo do capítulo.

Sempre que houver dúvidas, consulte o texto deste livro, execute os exemplos apresentados e, quando necessário, complemente a consulta com livros, artigos científicos e outras fontes acadêmicas confiáveis.

## 6.13 Lista de Exercícios

Os exercícios a seguir consolidam os conceitos apresentados neste capítulo por meio de adaptações, experimentos e extensões dos algoritmos desenvolvidos ao longo do texto.

1. (10%) Investigue a influência do ângulo de inclinação na etapa de *deskew*. Gere versões rotacionadas da imagem `skimage.data.page()` para ângulos entre  $-10^\circ$  e  $10^\circ$ , aplique o algoritmo apresentado no capítulo e compare o ângulo estimado com o ângulo utilizado na rotação. Apresente os resultados em uma tabela e discuta a precisão do método.
2. (15%) Aplique normalização de fundo e CLAHE (utilizando pelo menos três combinações de `clipLimit` e `tileGridSize`) à imagem `skimage.data.page()` degradada artificialmente com gradiente de iluminação e sombra lateral. Segmente cada versão por meio do método de Otsu e compare os resultados utilizando o número de componentes conexos espúrios e a métrica IoU em relação a uma máscara de referência construída manualmente.
3. (15%) Investigue a sensibilidade da filtragem por circularidade,  $C = \frac{4\pi A}{P^2}$ , na detecção dos marcadores circulares. Utilizando o simulador da Figure 6.9, gere discos sintéticos com ruído geométrico crescente e avalie os limiares  $C \in \{0,5, 0,6, 0,7, 0,8\}$ . Apresente uma tabela relacionando o limiar ao número de falsos positivos e falsos negativos e discuta o compromisso entre sensibilidade e especificidade.
4. (15%) A partir dos quatro marcadores detectados, implemente a retificação por perspectiva utilizando `cv2.getPerspectiveTransform` e `cv2.warpPerspective`. Em seguida, perturbe artificialmente as coordenadas dos pontos de controle com ruído gaussiano de desvio-padrão  $\sigma \in \{1, 3, 5\}$  pixels e avalie o erro de reprojeção obtido após a homografia inversa.
5. (15%) Adapte o *pipeline* de aquisição e retificação desenvolvido neste capítulo para processar documentos contendo códigos de barras lineares em substituição aos *QR Codes*. Rasterize o PDF com `pdf2image` a 300 DPI, aplique o *deskew*, decodifique o símbolo com `pyzbar` e apresente a imagem retificada juntamente com a sequência de caracteres obtida.
6. (15%) Estenda a leitura de bolhas do MCTest para identificar três situações: **OK**, **BRANCO** (nenhuma alternativa marcada) e **DUPLA MARCAÇÃO** (duas ou mais alternativas acima de um limiar de preenchimento). Avalie pelo menos três valores desse limiar, apresente os resultados em um `pandas.DataFrame` e discuta sua influência na classificação das respostas.
7. (15%) Construa um *pipeline* de inspeção industrial combinando subtração de imagens e análise de variância local da textura sobre um conjunto de imagens sintéticas contendo defeitos simulados. Para cada imagem, gere uma máscara de referência (*ground truth*), calcule a métrica IoU (*Intersection over Union*) das duas abordagens para diferentes limiares de decisão e apresente os resultados em tabelas e visualizações produzidas com `mm.show`.
8. (Bônus – 10%) Implemente manualmente a estimação do ângulo de inclinação sem utilizar `cv2.HoughLines` ou `cv2.HoughLinesP`. A partir do mapa de bordas obtido pelo detector de Canny, construa o acumulador da Transformada de Hough,  $\rho = x \cos \theta + y \sin \theta$ , para  $\theta \in [-45^\circ, 45^\circ]$ , identifique os máximos do acumulador e estime a inclinação pela mediana das retas detectadas. Compare os resultados com a implementação do OpenCV e discuta a influência de retas espúrias na estimativa final.

## Referências do Capítulo

A fundamentação teórica e os estudos de caso apresentados neste capítulo apoiam-se nas seguintes referências:

- Gonzalez; Woods (2018), para os fundamentos de detecção de bordas, limiarização, segmentação, operações morfológicas, reconhecimento óptico de caracteres e transformações geométricas aplicadas à análise de documentos.
- Szeliski (2022), para a Transformada de Hough, o registro e alinhamento de imagens, as transformações projetivas (homografias) e os fundamentos da inspeção visual automatizada.

- Bradski; Kaehler (2008), para a utilização da biblioteca OpenCV nas etapas de detecção de bordas, Transformada de Hough, transformações geométricas, análise de contornos e decodificação de *QR Codes*.
- Smith (2007) e Smith (2013), para a arquitetura, o funcionamento e a evolução do mecanismo de reconhecimento óptico de caracteres **Tesseract OCR**, empregado nos exemplos de OCR apresentados neste capítulo.
- Bahdanau; Cho; Bengio (2015) e Vaswani et al. (2017), para os fundamentos da tradução automática baseada em redes neurais, incluindo mecanismos de atenção e arquiteturas *transformer*.
- Zampiroli (2023), para a descrição do sistema MCTest, utilizado como estudo de caso de um *pipeline* completo para leitura e correção automatizada de folhas de respostas.
- Bergmann et al. (2019), Tabernik et al. (2020) e Song; Yan (2013), para os *datasets* públicos de inspeção industrial **MVTec AD**, **KolektorSDD** e **NEU Surface Defect Database**, utilizados como referência para avaliação e comparação de algoritmos de detecção de defeitos.



## 6.14 Parte Prática com Exercícios de Programação

Os exercícios de programação (EP) desta seção complementam os conceitos apresentados ao longo do Capítulo 6 por meio da implementação de algoritmos relacionados à inspeção industrial e à análise de documentos. O objetivo é consolidar os fundamentos estudados, reproduzindo, em escala reduzida, etapas de um *pipeline* típico de Visão Computacional.

Diferentemente dos capítulos anteriores, cujos exercícios enfatizavam operações mais diretamente relacionadas aos dados de imagem, os EPs deste capítulo concentram-se nas **grandezas intermediárias** produzidas durante o processamento, como áreas, perímetros, circularidade, ângulos de retas, graus de preenchimento de bolhas, mapas de variância e mapas de diferença. Essa abordagem permite compreender e validar cada etapa do *pipeline* de forma independente, sem depender de bibliotecas especializadas para aquisição de imagens, detecção de marcadores ou decodificação de códigos — com exceção do exercício de encerramento do capítulo (EP06\_08), que propositalmente introduz o uso do OpenCV para a segmentação e a decodificação real de um *QR Code*, fechando o ciclo entre os conceitos teóricos e as ferramentas empregadas na prática.

Os exercícios seguem a mesma sequência conceitual do capítulo, em ordem crescente de complexidade. Inicialmente, são abordadas métricas de avaliação de segmentação, utilizadas para quantificar a qualidade de máscaras binárias. Em seguida, estudam-se critérios geométricos para seleção de marcadores, classificação de marcações em formulários e estimação da inclinação de documentos por meio da Transformada de Hough. Na parte final, os exercícios exploram a normalização de iluminação, a detecção de defeitos por análise de textura e a integração entre registro geométrico e subtração de imagens em um *pipeline* simplificado de inspeção industrial.

Cada exercício representa uma etapa isolada de um sistema real de Visão Computacional, permitindo validar individualmente conceitos que, em aplicações industriais, são combinados em um único *pipeline* de inspeção.

### Legenda de Dificuldade

| Nível                                                                               | Significado                                                                            | EPs              |
|-------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------|------------------|
|  | Muito fácil / fácil —<br>implementação de um único<br>conceito ou algoritmo<br>simples | EP06_01, EP06_02 |

| Nível                                                                             | Significado                                                                                                                  | EPs              |
|-----------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------|------------------|
|  | Fácil–médio — tratamento de múltiplos casos ou utilização de critérios estatísticos simples                                  | EP06_03, EP06_04 |
|  | Médio — processamento matricial ponto a ponto                                                                                | EP06_05          |
|  | Difícil — processamento matricial com operações em vizinhança (janela deslizante)                                            | EP06_06          |
|  | Muito difícil — integração de múltiplas etapas de um <i>pipeline</i> de Visão Computacional                                  | EP06_07          |
|  | Especial — uso de biblioteca especializada (cv2) para segmentação geométrica e decodificação real de código de barras/QRCode | EP06_08          |

### ! Diretrizes para a Resolução dos Exercícios de Programação

Salvo indicação em contrário, todos os exercícios utilizam a convenção de coordenadas matriciais [linha] [coluna], com origem em (0, 0) no canto superior esquerdo da imagem. Quando houver necessidade de arredondamento numérico, deve-se utilizar o arredondamento padrão para o inteiro mais próximo (*round half away from zero*, com `np.floor(img + 0.5)`). Comparações com limiares (por exemplo, circularidade, variância, diferença de intensidade ou grau de preenchimento) devem ser consideradas **estritas** ( $>$ ), exceto quando o enunciado especificar explicitamente outro critério. Cada exercício foi elaborado para enfatizar um conceito específico apresentado no capítulo. Recomenda-se implementar inicialmente a solução de forma direta e, somente após sua validação, buscar alternativas mais eficientes ou mais gerais.

### 🎯 Objetivo deste Caderno

Este caderno foi elaborado para apoiar o desenvolvimento, a validação e os testes das soluções dos **Exercícios de Programação (EPs)** em um ambiente interativo, como o Google Colab ou o Jupyter Notebook. Após verificar o funcionamento da implementação com os casos de teste apresentados, o código pode ser submetido ao Moodle para a avaliação oficial.

### Download

Execute a célula a seguir para obter os arquivos `morph.py` e `testsuite.py`, utilizados pelos exercícios deste capítulo.

```
import os, sys, importlib, inspect, urllib.request

# URLs do repositório
BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph"
for f in ["morph.py", "testsuite.py"]:
    if not os.path.exists(f):
        urllib.request.urlretrieve(f"{BASE_URL}/{f}", f)
```

```
import morph, testsuite
importlib.reload(morph); importlib.reload(testsuite)
from morph import mm
from testsuite import TestSuite

print(f" Ambiente pronto. Morph: {morph.__version__} | TestSuite: {testsuite.__version__}")
```

Ambiente pronto. Morph: 1.1.2 | TestSuite: 1.1.2

## Executando os Testes

Após implementar a solução, execute `TestSuite("EP06_01.extensão").run()` em uma nova célula, substituindo `extensão` pela linguagem utilizada (`.py`, `.java`, `.c`, `.cpp`, `.js` ou `.r`). O sistema obtém automaticamente os casos de teste do repositório do curso, executa o programa e apresenta o resultado da avaliação.

Em Python, também é possível testar a solução diretamente a partir de uma *string*, sem a necessidade de salvar o código em um arquivo. Para isso, armazene o programa em uma variável e utilize o método `run_code`:

```
codigo = """
# ... seu código aqui ...
"""

TestSuite("EP06_01").run_code(codigo)
```

### 6.14.1 EP06\_01 Avaliação de Segmentação por IoU (*Intersection over Union*)

Ao longo deste capítulo, diversas etapas do *pipeline* produzem **máscaras binárias**, como na segmentação de documentos, na localização de *QR Codes* e na detecção de defeitos. Para avaliar objetivamente a qualidade dessas segmentações, é necessário compará-las com uma máscara de referência (*ground truth*).

Uma das métricas mais utilizadas para esse fim é a **IoU** (*Intersection over Union*, ou Interseção sobre União), definida como a razão entre a área de interseção e a área de união de duas máscaras binárias. Quanto maior o valor da IoU, maior a concordância entre a segmentação produzida pelo algoritmo e a referência.

#### 6.14.1.1 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (número de linhas) e  $C$  (número de colunas).
2. **Máscara de referência:** Ler os  $L \times C$  elementos binários (0 ou 1) da matriz `ref`.
3. **Máscara predita:** Ler os  $L \times C$  elementos binários (0 ou 1) da matriz `pred`.
4. **Interseção:** Contar o número de posições  $(i, j)$  para as quais `ref[i][j] = 1` e `pred[i][j] = 1`.
5. **União:** Contar o número de posições  $(i, j)$  para as quais `ref[i][j] = 1` ou `pred[i][j] = 1`.
6. **Caso degenerado:** Se a união for igual a 0, definir  $\text{IoU} = 1,0$ , pois ambas as máscaras são vazias.
7. **Cálculo:** Caso a união seja maior que zero, calcular

$$\text{IoU} = \frac{|\text{Intersecao}|}{|\text{Uniao}|}.$$

8. **Classificação:** Determinar a classificação qualitativa utilizando o valor de IoU **antes** do arredondamento.
9. **Arredondamento:** Exibir a IoU com quatro casas decimais.
10. **Saída:** Imprimir, nessa ordem, a interseção, a união, a IoU e a classificação.

#### 6.14.1.2 Restrições Computacionais

- Se a união for igual a 0, não deve ser realizada a divisão; a IoU deve ser definida como 1,0.

- As faixas de classificação utilizam comparações não estritas ( $\geq$ ).
- A classificação deve ser realizada utilizando o valor da IoU em precisão completa, antes do arredondamento para exibição.

#### 6.14.1.3 Fundamentação Teórica

A IoU é definida por

$$\text{IoU} = \frac{|R \cap P|}{|R \cup P|},$$

em que:

- $R$  representa o conjunto de pixels pertencentes à máscara de referência;
- $P$  representa o conjunto de pixels pertencentes à máscara predita;
- $|R \cap P|$  corresponde ao número de pixels pertencentes simultaneamente às duas máscaras;
- $|R \cup P|$  corresponde ao número de pixels pertencentes a pelo menos uma das máscaras.

| Faixa de IoU                  | Classificação | Interpretação                                 |
|-------------------------------|---------------|-----------------------------------------------|
| $\text{IoU} \geq 0,90$        | EXCELENTE     | Concordância muito elevada entre as máscaras. |
| $0,70 \leq \text{IoU} < 0,90$ | BOM           | Pequenas diferenças entre as máscaras.        |
| $0,50 \leq \text{IoU} < 0,70$ | ACEITAVEL     | Concordância parcial entre as máscaras.       |
| $\text{IoU} < 0,50$           | RUIM          | Baixa concordância entre as máscaras.         |

A IoU depende apenas da sobreposição entre as máscaras e, portanto, é independente do tamanho da imagem.

#### 6.14.1.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: inteiro  $L$ .
- Linha 2: inteiro  $C$ .
- Próximas  $L$  linhas: elementos binários (0 ou 1) da matriz **ref**.
- Próximas  $L$  linhas: elementos binários (0 ou 1) da matriz **pred**.

**Saída:**

- Linha 1: **Intersecao:** X
- Linha 2: **Uniao:** Y
- Linha 3: **IoU:** Z
- Linha 4: **Classificacao:** NOME

O valor de IoU deve ser impresso com quatro casas decimais.

#### 6.14.1.5 Exemplos



| Entrada | Saída                    | Observação                                                    |
|---------|--------------------------|---------------------------------------------------------------|
| 2       | Intersecao: 1            | A metade da região de referência foi corretamente segmentada. |
| 2       | Uniao: 2                 |                                                               |
| 1 1     | IoU: 0.5000              |                                                               |
| 0 0     | Classificacao: ACEITAVEL |                                                               |
| 1 0     |                          |                                                               |
| 0 0     |                          |                                                               |
| 2       | Intersecao: 0            | Ambas as máscaras são vazias; por convenção, IoU = 1,0.       |
| 2       | Uniao: 0                 |                                                               |
| 0 0     | IoU: 1.0000              |                                                               |
| 0 0     | Classificacao: EXCELENTE |                                                               |
| 0 0     |                          |                                                               |
| 0 0     |                          |                                                               |




Figura 6.21: Simulador: IoU entre máscara de referência e máscara predita

```
%%writefile EP06_01.py
# Código Python
```

Overwriting EP06\_01.py

```
TestSuite("EP06_01.py").run()
```

### 6.14.2 EP06\_02 ● Filtro de Marcadores por Circularidade

Após a segmentação de uma imagem, é comum que diversos componentes conexos sejam identificados. Em aplicações como a retificação de documentos, apenas alguns desses componentes correspondem aos marcadores de referência utilizados para o alinhamento da imagem. Um critério frequentemente empregado para selecionar esses marcadores é a **circularidade**, que mede o quão próxima a forma de um componente está de um círculo.

Neste exercício, cada componente é descrito por sua área  $A$  e seu perímetro  $P$ . O objetivo é calcular sua circularidade e decidir, a partir de um limiar fornecido, se o componente deve ser aceito ou rejeitado como candidato a marcador.

#### 6.14.2.1 📋 Diretrizes de Implementação

1. **Quantidade:** Ler o inteiro  $N$  (número de candidatos) e o limiar de circularidade  $C_{\text{limiar}}$  (número real).
2. **Dados dos candidatos:** Para cada um dos  $N$  candidatos, ler a área  $A$  (inteiro) e o perímetro  $P$  (número real).
3. **Circularidade:** Calcular  $C = \frac{4\pi A}{P^2}$ , em que:
  - $A$  é a área do componente;
  - $P$  é o perímetro do componente;
  - $C$  é a circularidade.
4. **Caso degenerado:** Se  $P = 0$ , considerar  $C = 0$  e classificar diretamente o candidato como REJEITADO.
5. **Classificação:** Se  $C > C_{\text{limiar}}$ , classificar o candidato como ACEITO; caso contrário, classificá-lo como REJEITADO.
6. **Arredondamento:** Exibir o valor de  $C$  com quatro casas decimais.
7. **Saída:** Para cada candidato, imprimir o valor de  $C$  seguido da classificação. Ao final, imprimir o número total de candidatos aceitos.

#### 6.14.2.2 📌 Restrições Computacionais

- Utilizar a constante  $\pi$  da biblioteca padrão da linguagem (por exemplo, `math.pi`), sem aproximações.
- A comparação deve ser realizada com o valor de  $C$  em precisão completa, antes do arredondamento para exibição.
- O critério de aceitação é estrito ( $C > C_{\text{limiar}}$ ).
- Se  $P = 0$ , a divisão não deve ser realizada.

#### 6.14.2.3 🧠 Fundamentação Teórica

A circularidade é um descritor geométrico definido por  $C = \frac{4\pi A}{P^2}$ , em que:

- $A$  é a área do componente;
- $P$  é o perímetro do componente;
- $C$  é a circularidade.

Para um círculo perfeito,  $C = 1$ . À medida que a forma se torna mais alongada ou irregular, o perímetro cresce mais rapidamente que a área, reduzindo o valor de  $C$ .

| Forma                       | Circularidade aproximada | Interpretação                   |
|-----------------------------|--------------------------|---------------------------------|
| Círculo                     | 1,0000                   | Forma circular.                 |
| Quadrado                    | 0,7854                   | Forma aproximadamente compacta. |
| Forma alongada ou irregular | $C \ll 1$                | Baixa circularidade.            |

| Forma   | Circularidade aproximada | Interpretação        |
|---------|--------------------------|----------------------|
| $P = 0$ | 0 (convenção adotada)    | Contorno degenerado. |

A circularidade é invariante à translação, à rotação e à escala, sendo amplamente utilizada para distinguir componentes aproximadamente circulares de outros formatos.

#### 6.14.2.4 📦 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: inteiro  $N$ .
- Linha 2: número real  $C_{\text{limiar}}$ .
- Próximas  $N$  linhas: área  $A$  (inteiro) e perímetro  $P$  (real), separados por espaço.

##### Saída:

- Uma linha para cada candidato, no formato **C ACEITO** ou **C REJEITADO**, com  $C$  apresentado com quatro casas decimais.
- Última linha: **Total aceitos: X**.

#### 6.14.2.5 📌 Exemplos

| Entrada | Saída            | Observação                                                           |
|---------|------------------|----------------------------------------------------------------------|
| 3       | 0.9941 ACEITO    | Candidato aproximadamente circular, forma compacta e forma alongada. |
| 0.6     | 0.7854 ACEITO    |                                                                      |
| 78 31.4 | 0.1745 REJEITADO |                                                                      |
| 100 40  | Total aceitos: 2 |                                                                      |
| 50 60   |                  |                                                                      |
| 1       | 0.0000 REJEITADO | Perímetro nulo: contorno degenerado.                                 |
| 0.9     | Total aceitos: 0 |                                                                      |
| 10 0    |                  |                                                                      |



Figura 6.22: Simulador: Filtro de Marcadores por Circularidade

```
%%writefile EP06_02.py
# Código Python
```

```
Overwriting EP06_02.py
```

```
TestSuite("EP06_02.py").run()
```

### 6.14.3 EP06\_03 ● Classificação de Marcações em Folhas de Resposta (OMR)

Após a retificação da folha e a segmentação dos quadros de respostas, o MCTest estima, para cada bolha, um **grau de preenchimento**, representado por um valor entre 0 e 100. A partir desses valores, o sistema deve determinar automaticamente a alternativa marcada, identificando também questões em branco e casos de múltiplas marcações.

Neste exercício, você implementará essa etapa de decisão do *pipeline* de OMR. A classificação depende de um limiar de preenchimento: pequenas variações nesse valor podem alterar o resultado da leitura automática.

#### 6.14.3.1 📋 Diretrizes de Implementação

1. **Parâmetros:** Ler os inteiros  $Q$  (número de questões) e  $K$  (número de alternativas por questão, com  $2 \leq K \leq 26$ ) e o limiar de preenchimento  $Th$  (número real entre 0 e 100).
2. **Graus de preenchimento:** Para cada uma das  $Q$  questões, ler os  $K$  valores reais correspondentes às alternativas A, B, C, ..., na ordem de entrada.
3. **Contagem de marcações:** Para cada questão, contar quantas alternativas possuem grau de preenchimento **estritamente maior** que  $Th$ .
4. **Classificação:**
  - Se nenhuma alternativa exceder  $Th$ , classificar a questão como **BRANCO**.
  - Se exatamente uma alternativa exceder  $Th$ , imprimir a letra correspondente (A, B, C, ...).
  - Se duas ou mais alternativas excederem  $Th$ , classificar a questão como **DUPLA\_MARCACAO**.
5. **Saída por questão:** Imprimir, na ordem de leitura, a classificação de cada questão.
6. **Totais:** Ao final, imprimir o número de questões OK (uma única marcação), **BRANCO** e **DUPLA\_MARCACAO**.

#### 6.14.3.2 📌 Restrições Computacionais

- **Comparação estrita:** apenas valores maiores que  $Th$  são considerados marcações válidas; valores exatamente iguais ao limiar não devem ser contabilizados.
- **Letras das alternativas:** o índice 0 corresponde à alternativa A, o índice 1 à alternativa B e assim sucessivamente.
- **Múltiplas marcações:** sempre que duas ou mais alternativas excederem o limiar, a classificação deve ser **DUPLA\_MARCACAO**, independentemente dos respectivos graus de preenchimento.

#### 6.14.3.3 🧠 Fundamentação Teórica

| Situação                                   | Classificação        | Interpretação          |
|--------------------------------------------|----------------------|------------------------|
| Exatamente uma alternativa acima do limiar | Letra da alternativa | Resposta válida        |
| Nenhuma alternativa acima do limiar        | BRANCO               | Questão não respondida |
| Duas ou mais alternativas acima do limiar  | DUPLA_MARCACAO       | Resposta ambígua       |

O limiar de preenchimento controla a sensibilidade do algoritmo. Valores muito baixos tendem a aumentar o número de **DUPLA\_MARCACAO**, enquanto valores muito altos podem aumentar a quantidade de questões classificadas como **BRANCO**.

#### 6.14.3.4 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: Inteiro  $Q$ .
- Linha 2: Inteiro  $K$ .
- Linha 3: Número real  $Th$ .
- Próximas  $Q$  linhas:  $K$  números reais, correspondentes aos graus de preenchimento das alternativas.
- Linha 1: Inteiro  $Q$  e  $K$ .

##### Saída:

- $Q$  linhas, cada uma contendo a classificação da respectiva questão.
- Linha final: OK:  $x$  BRANCO:  $y$  DUPLA\_MARCACAO:  $z$ .

#### 6.14.3.5 Exemplos

| Entrada     | Saída             | Observação                                                                                                                  |
|-------------|-------------------|-----------------------------------------------------------------------------------------------------------------------------|
| 3           | B                 | Na primeira questão apenas B supera o limiar; na segunda nenhuma alternativa o supera; na terceira, A e B excedem o limiar. |
| 4           | BRANCO            |                                                                                                                             |
| 50          | DUPLA_MARCACAO    |                                                                                                                             |
| 10 85 5 12  | OK: 1 BRANCO: 1   |                                                                                                                             |
| 20 15 18 22 | DUPLA_MARCACAO: 1 |                                                                                                                             |
| 90 88 10 5  |                   |                                                                                                                             |
| 1           | BRANCO            | Valores iguais ao limiar não são considerados marcações válidas.                                                            |
| 2           | OK: 0 BRANCO: 1   |                                                                                                                             |
| 50.0        | DUPLA_MARCACAO: 0 |                                                                                                                             |
| 50 50       |                   |                                                                                                                             |




Figura 6.23: Simulador: Classificação de Marcação OMR

```
%%writefile EP06_03.py
# Código Python
```

Overwriting EP06\_03.py

```
TestSuite("EP06_03.py").run()
```

#### 6.14.4 EP06\_04 Estimador de Inclinação por Mediana Angular (*Deskew*)

Após a detecção de bordas e a aplicação da Transformada de Hough, obtém-se um conjunto de retas candidatas à orientação predominante do documento. Cada reta fornece uma estimativa do ângulo de inclinação, calculada por

$$\text{ângulo} = \text{rad2deg}(\theta) - 90.$$

Entretanto, nem todas as retas correspondem às linhas do documento: algumas resultam de ruídos, sombras ou outros elementos da imagem. Neste exercício, você implementará a etapa de estimação robusta do ângulo de inclinação, filtrando os valores plausíveis e calculando sua mediana.

##### 6.14.4.1 Diretrizes de Implementação

1. **Quantidade:** Ler o inteiro  $M$ , correspondente ao número de ângulos estimados.
2. **Ângulos:** Ler os  $M$  valores reais, em graus.
3. **Filtragem:** Manter apenas os ângulos que satisfaçam **estritamente**  $-45 < \text{ângulo} < 45$ .
4. **Ausência de candidatos:** Se nenhum ângulo permanecer após a filtragem, imprimir exatamente `SEM_CORRECAO`.
5. **Mediana:** Caso existam ângulos válidos:
  - se a quantidade for ímpar, a mediana é o elemento central da sequência ordenada;
  - se for par, a mediana é a média aritmética dos dois elementos centrais.
6. **Saída:** Imprimir a mediana arredondada para duas casas decimais (arredondamento padrão, *round half away from zero*, com `np.floor(img + 0.5)`).

##### 6.14.4.2 Restrições Computacionais

- **Intervalo aberto:** ângulos iguais a  $-45$  ou  $45$  não devem ser considerados.
- **Precisão:** calcular a mediana utilizando os valores originais; o arredondamento deve ser realizado apenas na saída.
- **Caso vazio:** se não houver ângulos válidos, nenhuma mediana deve ser calculada.

##### 6.14.4.3 Fundamentação Teórica

| Situação                                                    | Resultado                                              |
|-------------------------------------------------------------|--------------------------------------------------------|
| Maioria dos ângulos concentrada em torno da inclinação real | A mediana aproxima a orientação do documento.          |
| Poucos ângulos discrepantes ( <i>outliers</i> )             | A mediana sofre pouca influência desses valores.       |
| Ângulos fora do intervalo ( $-45^\circ, 45^\circ$ )         | São descartados antes do cálculo.                      |
| Nenhum ângulo válido                                        | Não é aplicada correção ( <code>SEM_CORRECAO</code> ). |

A mediana é utilizada por ser mais robusta que a média na presença de poucos valores discrepantes, produzindo uma estimativa mais estável da inclinação predominante do documento.

##### 6.14.4.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $M$ .
- Linha 2:  $M$  números reais, correspondentes aos ângulos em graus.

**Saída:**

- Uma única linha contendo o ângulo estimado, com duas casas decimais, ou a palavra `SEM_CORRECAO` caso nenhum ângulo seja válido.

#### 6.14.4.5 📌 Exemplos

| Entrada                   | Saída        | Observação                                                                    |
|---------------------------|--------------|-------------------------------------------------------------------------------|
| 5<br>-50 -10.5 2.3 2.3 47 | 2.30         | Apenas os ângulos no intervalo $(-45, 45)$ são considerados; a mediana é 2,3. |
| 4<br>-46 50 45 -45        | SEM_CORRECAO | Nenhum ângulo pertence ao intervalo aberto $(-45, 45)$ .                      |




Figura 6.24: Simulador: Estimador de Inclinação por Mediana Angular

```
%%writefile EP06_04.py
# Código Python
```

Overwriting EP06\_04.py

```
TestSuite("EP06_04.py").run()
```

#### 6.14.5 EP06\_05 ● Normalização de Fundo por Divisão (Correção de Iluminação)

Um formulário foi fotografado sob iluminação não uniforme, fazendo com que um lado da folha apareça mais claro que o outro. Nessas condições, a limiarização global por Otsu pode produzir resultados insatisfatórios, pois um único limiar não separa adequadamente texto e fundo em toda a imagem. A solução apresentada no capítulo consiste em **normalizar o fundo**, dividindo a imagem original por uma versão fortemente suavizada de si mesma, que representa a iluminação de baixa frequência.

Neste exercício, a imagem original e o fundo suavizado (equivalente ao resultado de um `cv2.GaussianBlur` com  $\sigma$  elevado) já são fornecidos. Sua tarefa é implementar a etapa de normalização que produz a imagem corrigida.

##### 6.14.5.1 📌 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $L$  (linhas) e  $C$  (colunas).
2. **Imagem original:** Ler os  $L \times C$  valores inteiros da matriz `img` (intensidades entre 0 e 255).
3. **Fundo estimado:** Ler os  $L \times C$  valores inteiros da matriz `bg` (intensidades entre 0 e 255, sempre estritamente maiores que zero).
4. **Normalização:** Para cada posição  $(i, j)$ , calcular

$$\text{valor}(i, j) = \frac{\text{img}(i, j)}{\text{bg}(i, j)} \times 255.$$



5. **Arredondamento:** Arredondar o resultado para o inteiro mais próximo (*round half away from zero*, com `np.floor(img + 0.5)`).
6. **Saturação:** Limitar o valor obtido ao intervalo  $[0, 255]$ .
7. **Saída:** Imprimir a matriz `img_norm` resultante.

#### 6.14.5.2 Restrições Computacionais

- **Divisão por zero:** a entrada garante  $bg(i, j) > 0$  em todas as posições.
- **Ordem das operações:** primeiro arredondar, depois aplicar a saturação.
- **Processamento independente:** cada pixel deve ser normalizado individualmente, sem utilizar informações dos pixels vizinhos.

#### 6.14.5.3 Fundamentação Teórica

| Situação                                                    | Efeito da normalização                                                                                                                     |
|-------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------|
| $img(i, j) = bg(i, j)$                                      | Resultado igual a 255, correspondente ao fundo normalizado.                                                                                |
| $img(i, j) < bg(i, j)$                                      | Resultado menor que 255, preservando regiões mais escuras, como texto.                                                                     |
| $img(i, j) > bg(i, j)$<br>Fundo com iluminação não uniforme | Resultado superior a 255, posteriormente saturado.<br>A divisão reduz as variações lentas de iluminação, tornando a imagem mais homogênea. |

A divisão pelo fundo estimado reduz os efeitos da iluminação não uniforme e preserva o contraste entre o primeiro plano e o fundo, facilitando as etapas posteriores de segmentação.

#### 6.14.5.4 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Próximas  $L$  linhas: elementos da matriz `img`.
- Próximas  $L$  linhas: elementos da matriz `bg`.

##### Saída:

- Matriz `img_norm`, com  $L$  linhas e  $C$  colunas, contendo valores inteiros separados por espaço.

#### 6.14.5.5 Exemplos

| Entrada  | Saída       | Observação                                                                                                          |
|----------|-------------|---------------------------------------------------------------------------------------------------------------------|
| 2        | 153 255     | Valores superiores a 255 devem ser saturados;<br>$180/200 \times 255 = 229,5$ resulta em 230 após o arredondamento. |
| 2        | 230 128     |                                                                                                                     |
| 60 120   |             |                                                                                                                     |
| 180 40   |             |                                                                                                                     |
| 100 100  |             |                                                                                                                     |
| 200 80   |             | Apenas o primeiro valor permanece abaixo de 255 após a normalização.                                                |
| 1        | 128 255 255 |                                                                                                                     |
| 3        |             |                                                                                                                     |
| 30 60 90 |             |                                                                                                                     |
| 60 60 60 |             |                                                                                                                     |



Figura 6.25: Simulador: Normalização de Fundo por Divisão

```
%%writefile EP06_05.py
# Código Python
```

```
Overwriting EP06_05.py
```

```
TestSuite("EP06_05.py").run()
```

#### 6.14.6 EP06\_06 ● Mapa de Variância Local para Detecção de Textura

Uma fábrica de tecidos precisa inspecionar rolos de pano em tempo real, sem dispor de uma imagem de referência — cada rolo apresenta pequenas variações naturais. Nessa situação, a estratégia apresentada no capítulo consiste em analisar a **homogeneidade local da textura**: regiões uniformes apresentam baixa variância de intensidade em pequenas vizinhanças, enquanto riscos, manchas e falhas de fabricação produzem aumentos locais dessa variância.

Neste exercício, você implementará o núcleo desse método, calculando a variância local em uma janela deslizante e gerando uma máscara binária que identifica as regiões cuja variância excede um limiar.

##### 6.14.6.1 📋 Diretrizes de Implementação

1. **Dimensões e parâmetros:** Ler os inteiros  $L$ ,  $C$ ,  $k$  (tamanho da janela, sempre ímpar) e  $T$  (limiar de variância).
2. **Imagem:** Ler os  $L \times C$  valores inteiros da matriz de textura (intensidades entre 0 e 255).
3. **Tratamento das bordas:** Quando a janela ultrapassar os limites da imagem, utilizar **replicação de borda**, isto é, repetir o valor do pixel válido mais próximo.
4. **Média local:** Para cada posição  $(i, j)$ , calcular

$$\mu(i, j) = \frac{1}{k^2} \sum_{(p, q) \in \text{janela}} \text{textura}(p, q).$$

5. **Variância local:** Calcular a variância populacional da janela,

$$\sigma^2(i, j) = \frac{1}{k^2} \sum_{(p, q) \in \text{janela}} (\text{textura}(p, q) - \mu(i, j))^2,$$

ou, de forma equivalente,

$$\sigma^2(i, j) = \overline{x^2} - \mu(i, j)^2,$$

em que  $\overline{x^2}$  representa a média dos quadrados das intensidades.

6. **Arredondamento:** Arredondar a variância para o inteiro mais próximo (*round half away from zero*, com `np.floor(res_norm + 0.5)`).
7. **Limiarização:** Definir  $máscara(i, j) = 1$  se a variância arredondada for **estritamente maior** que  $T$ ; caso contrário, definir  $máscara(i, j) = 0$ .
8. **Saída:** Imprimir a máscara binária resultante.

#### 6.14.6.2 Restrições Computacionais

- **Replicação de borda:** utilizar o valor do pixel válido mais próximo sempre que a janela ultrapassar os limites da imagem.
- **Variância populacional:** utilizar denominador  $k^2$ , nunca  $k^2 - 1$ .
- **Comparação estrita:** a máscara deve ser calculada utilizando a condição  $\sigma_{\text{arred}}^2 > T$ .
- **Janela ímpar:** o valor de  $k$  é sempre ímpar, garantindo um pixel central.

#### 6.14.6.3 Fundamentação Teórica

| Situação                | Variância local                        | Interpretação                                                          |
|-------------------------|----------------------------------------|------------------------------------------------------------------------|
| Região uniforme         | Baixa                                  | Intensidades semelhantes na vizinhança.                                |
| Região contendo defeito | Alta                                   | A presença de intensidades distintas aumenta a dispersão dos valores.  |
| Janela pequena          | Maior sensibilidade a detalhes e ruído | Detecta alterações localizadas.                                        |
| Janela grande           | Resposta mais suave                    | Evidencia defeitos maiores, porém reduz a precisão de sua localização. |

A variância local mede a dispersão das intensidades em uma vizinhança. Regiões homogêneas apresentam baixa variância, enquanto alterações na textura aumentam essa medida, permitindo identificar possíveis defeitos por meio de uma simples limiarização.

#### 6.14.6.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Inteiro  $k$  (ímpar).
- Linha 4: Inteiro  $T$ .
- Próximas  $L$  linhas: elementos inteiros da matriz de textura.

**Saída:**

- Máscara binária (valores 0 ou 1), com  $L$  linhas e  $C$  colunas.

#### 6.14.6.5 Exemplos

| Entrada  | Saída | Observação                                                      |
|----------|-------|-----------------------------------------------------------------|
| 3        | 0 0 0 | O defeito aumenta a variância em todas as janelas que o contêm. |
| 3        | 1 1 1 |                                                                 |
| 3        | 1 1 1 |                                                                 |
| 50       |       |                                                                 |
| 10 10 10 |       |                                                                 |
| 10 10 10 |       | A textura é uniforme; a variância é nula em toda a imagem.      |
| 10 90 10 |       |                                                                 |
| 2        | 0 0   |                                                                 |
| 2        | 0 0   |                                                                 |
| 3        |       |                                                                 |
| 5        |       |                                                                 |
| 100 100  |       |                                                                 |
| 100 100  |       |                                                                 |




Figura 6.26: Simulador: Mapa de Variância Local para Detecção de Textura

```
%%writefile EP06_06.py
# Código Python

Overwriting EP06_06.py

TestSuite("EP06_06.py").run()
```

6.14.7 EP06\_07 Pipeline de Inspeção Industrial: Registro por Translação e Subtração

Em uma linha de produção, uma câmera fixa fotografa cada peça que passa pela esteira, comparando-a a uma imagem de referência sem defeitos. O problema: pequenas vibrações da esteira deslocam a peça em relação à posição de referência a cada captura. Se a subtração de imagens for aplicada diretamente, sem

correção, o deslocamento por si só já gera diferenças enormes — **falsos positivos** que mascaram os defeitos reais.

Este é o exercício mais completo do capítulo: você deve **primeiro registrar** (alinhar geometricamente) a imagem capturada usando um deslocamento conhecido  $(dx, dy)$ , fornecido por um sensor de posição da esteira, e **só então aplicar a subtração** com limiarização, exatamente como descrito na seção de inspeção industrial.

#### 6.14.7.1 Diretrizes de Implementação

1. **Dimensões e parâmetros:** Ler  $L, C$  (dimensões das imagens), o deslocamento inteiro conhecido  $dx, dy$  (podendo ser negativos) e o limiar de detecção  $T$  (inteiro).
2. **Imagens:** Ler a matriz de referência (**ref**,  $L \times C$ , sem defeitos) e a matriz capturada (**cap**,  $L \times C$ , possivelmente deslocada e com defeito).
3. **Registro por translação:** Construir a imagem alinhada **alin** aplicando o deslocamento  $(dx, dy)$  recebido:

$$\text{alin}(i, j) = \begin{cases} \text{cap}(i + dy, j + dx), & \text{se } (i + dy, j + dx) \in [0, L) \times [0, C) \\ 0, & \text{caso contrário} \end{cases}$$

4. **Preenchimento de borda:** As posições que “saem” da imagem capturada após o deslocamento recebem o valor **0** (*zero-padding* — fora do campo de visão da câmera; **note que este exercício usa zero, diferente da replicação de borda do EP06\_06**).
5. **Diferença absoluta:** Calcular, pixel a pixel,

$$\text{diff}(i, j) = |\text{ref}(i, j) - \text{alin}(i, j)|$$

6. **Limiarização:** Definir  $\text{mascara}(i, j) = 1$  se  $\text{diff}(i, j) > T$ ; caso contrário,  $\text{mascara}(i, j) = 0$ .
7. **Saída:** Nesta ordem — (a) a matriz **alin** ( $L \times C$ ); (b) a máscara de defeito ( $L \times C$ ); (c) uma última linha com o total de pixels classificados como defeituosos.

#### 6.14.7.2 Restrições Computacionais

- **Zero-padding, não replicação:** posições fora dos limites da imagem capturada, após o deslocamento, valem exatamente 0 — este é o ponto que mais diferencia este exercício do EP06\_06.
- **Comparação estrita:**  $\text{diff}(i, j) > T$ .
- **Sinal de  $(dx, dy)$ :** o deslocamento pode ser positivo ou negativo; a fórmula do passo 3 deve ser aplicada literalmente, sem inverter os sinais.
- **Todos os valores são inteiros:** não há arredondamento nesta etapa.

#### 6.14.7.3 Fundamentação Teórica

| Etapa omitida                     | Consequência                                                                                                    |
|-----------------------------------|-----------------------------------------------------------------------------------------------------------------|
| Pular o registro geométrico       | A borda inteira da imagem (introduzida pelo deslocamento) é marcada como “defeito” — falso positivo sistemático |
| Registro com $(dx, dy)$ incorreto | Peça e referência ficam desalinhadas; a subtração detecta contornos deslocados, não defeitos reais              |
| Limiar $T$ muito baixo            | Ruído de captura (variações de 1–2 níveis de cinza) é confundido com defeito                                    |
| Limiar $T$ muito alto             | Defeitos sutis deixam de ser detectados                                                                         |

O registro geométrico e a subtração são etapas complementares: o primeiro garante que ambas as imagens representem exatamente a mesma cena no mesmo referencial espacial; o segundo isola o que realmente mudou entre elas — idealmente, apenas os defeitos.

#### 6.14.7.4 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: Inteiro  $L$ .
- Linha 2: Inteiro  $C$ .
- Linha 3: Dois inteiros  $dx$  e  $dy$ , separados por espaço.
- Linha 4: Inteiro  $T$ .
- Próximas  $L$  linhas: elementos inteiros da matriz `ref`.
- Próximas  $L$  linhas: elementos inteiros da matriz `cap`.

##### Saída:

- $L$  linhas com a matriz `alin`.
- $L$  linhas com a máscara de defeito (0/1).
- Última linha: Total de pixels defeituosos:  $X$ .

#### 6.14.7.5 Exemplos

| Entrada  | Saída                          | Observação                                                                                                                                                                                    |
|----------|--------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 3        | 50 50 0                        | $dx = 1$ desloca a leitura uma coluna à direita; a última coluna de <code>alin</code> fica sem correspondência (vira 0) e é sistematicamente marcada; o defeito real (90) também é detectado. |
| 3        | 50 90 0                        |                                                                                                                                                                                               |
| 1 0      | 50 50 0                        |                                                                                                                                                                                               |
| 30       | 0 0 1                          |                                                                                                                                                                                               |
| 50 50 50 | 0 1 1                          |                                                                                                                                                                                               |
| 50 50 50 | 0 0 1                          |                                                                                                                                                                                               |
| 50 50 50 | Total de pixels defeituosos: 4 |                                                                                                                                                                                               |
| 0 50 50  |                                |                                                                                                                                                                                               |
| 0 50 90  |                                |                                                                                                                                                                                               |
| 0 50 50  |                                |                                                                                                                                                                                               |
| 2        | 10 10                          | Sem deslocamento ( $dx = dy = 0$ ): <code>alin</code> é idêntica a <code>cap</code> ; apenas o defeito real (60) é detectado.                                                                 |
| 2        | 10 60                          |                                                                                                                                                                                               |
| 0 0      | 0 0                            |                                                                                                                                                                                               |
| 20       | 0 1                            |                                                                                                                                                                                               |
| 10 10    | Total de pixels defeituosos: 1 |                                                                                                                                                                                               |
| 10 10    |                                |                                                                                                                                                                                               |
| 10 10    |                                |                                                                                                                                                                                               |
| 10 60    |                                |                                                                                                                                                                                               |

```
%%writefile EP06_07.py
# Código Python
```

```
Overwriting EP06_07.py
```

```
TestSuite("EP06_07.py").run()
```

#### 6.14.8 EP06\_08 Segmentação e Decodificação Real de *QRCode* com OpenCV

Nos exercícios anteriores, as grandezas intermediárias do *pipeline* de processamento de imagens — como áreas, perímetros, variâncias e deslocamentos — foram fornecidas diretamente ou calculadas a partir de matrizes numéricas, sem a necessidade de bibliotecas especializadas de Visão Computacional. Neste exercício de encerramento do capítulo, essa restrição é removida de forma intencional: será utilizada a biblioteca **OpenCV** (`cv2`) para localizar e decodificar um *QRCode* real presente em uma cena.




Figura 6.27: Simulador: *Pipeline* de Inspeção — Registro por Translação e Subtração

A proposta reproduz um fluxo simplificado de sistemas empregados em inspeção visual, automação industrial e leitura automática de documentos. Para manter a entrada de dados acessível ao contexto educacional, o carregamento da imagem será integrado à biblioteca didática `morph`, por meio da função `mm.readImg`.

A cena é fornecida no formato **PGM ASCII (P2)** e contém um único *QRCode* válido, além de diversos **objetos distratores**, como retângulos, regiões de ruído texturizado e blocos isolados. A segmentação baseada apenas em propriedades geométricas — como área e formato aproximadamente quadrado — é necessária para reduzir o espaço de busca, mas não é suficiente para identificar o código correto. A confirmação final será realizada exclusivamente pela tentativa de decodificação utilizando `cv2.QRCodeDetector`, procedimento compatível com aplicações reais de reconhecimento automático.

#### 6.14.8.1 Diretrizes de Implementação

##### 1. Leitura das dimensões e parâmetros

Ler, nesta ordem, por meio da entrada padrão:

- uma linha contendo o número de linhas  $L$ ;
- uma linha contendo o número de colunas  $C$ ;
- uma linha contendo os quatro parâmetros do algoritmo separados por espaço:
  - limiar de binarização  $T$  (inteiro);
  - área mínima  $A_{\min}$  (inteiro);
  - tolerância de aspecto  $tol$  (real);
  - margem  $M$  (inteiro, em pixels).

##### 2. Carregamento da imagem

Utilizar a função didática `f = mm.readImg(L, C)` para ler os  $L \times C$  valores da imagem em tons de cinza, obtendo um *array* NumPy do tipo `uint8`.

##### 3. Binarização

Aplicar limiarização binária invertida utilizando o limiar  $T$ . Todo pixel da imagem original com



intensidade estritamente maior que  $T$  deve ser convertido para 255, enquanto os demais devem assumir o valor 0.

#### 4. Detecção de contornos

Extrair os componentes conectados externos utilizando `cv2.findContours(...)` com os parâmetros:

- `cv2.RETR_EXTERNAL;`
- `cv2.CHAIN_APPROX_SIMPLE.`

#### 5. Filtragem geométrica

Para cada contorno encontrado:

- calcular o retângulo delimitador ( $x$ ,  $y$ ,  $w$ ,  $h$ ) por meio de `cv2.boundingRect`;
- manter apenas os candidatos que satisfaçam simultaneamente:

**Área mínima**

$$w \times h > A_{\min}$$

**Razão de aspecto**

$$\left| \frac{w}{h} - 1 \right| \leq \text{tol}$$

#### 6. Ordenação dos candidatos

Ordenar os candidatos pela área do retângulo delimitador

$$w \times h$$

em ordem decrescente.

Em caso de empate, preservar a ordem originalmente retornada por `cv2.findContours`.

#### 7. Verificação por decodificação

Para cada candidato, seguindo a ordem estabelecida:

- expandir o retângulo em  $M$  pixels nas quatro direções;
- limitar os índices para permanecerem dentro da imagem;
- extrair o recorte diretamente da imagem original  $f$ ;
- aplicar `cv2.QRCodeDetector().detectAndDecode(...)` sobre esse recorte.

#### 8. Critério de parada

Interromper imediatamente o processamento quando o primeiro candidato produzir uma *string* decodificada não vazia.

#### 9. Caso não encontrado

Se nenhum candidato for decodificado com sucesso, imprimir exatamente: `QRCODE_NAO_ENCONTRADO`

#### 10. Saída (caso encontrado)

Imprimir duas linhas.

Primeira linha: `linha` `coluna` `altura` `largura` utilizando o retângulo delimitador **original**, antes da expansão pela margem  $M$ .

Segunda linha: `texto_decodificado`

#### 6.14.8.2 Restrições Computacionais

- Utilizar funções do OpenCV para realizar a binarização, a detecção de contornos, o cálculo do retângulo delimitador e a decodificação do QRCode.
- A filtragem geométrica deve ocorrer obrigatoriamente antes da etapa de decodificação.
- Utilizar exclusivamente o limiar fixo  $T$  fornecido na entrada. Não é permitido utilizar métodos automáticos de limiarização, como Otsu ou limiarização adaptativa.
- Garantir que os recortes enviados ao decodificador permaneçam dentro dos limites da imagem.

#### 6.14.8.3 Fundamentação Teórica

| Etapa                        | Papel no pipeline                                                                                      | Consequência se omitida                                                                    |
|------------------------------|--------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------|
| <b>Filtragem geométrica</b>  | Reduz o espaço de busca selecionando apenas regiões compatíveis com a geometria esperada de um QRCode. | O decodificador processaria todos os contornos, incluindo ruídos e objetos distratores.    |
| <b>Decodificação</b>         | Confirma semanticamente se o candidato contém um QRCode válido.                                        | Objetos geometricamente semelhantes poderiam ser classificados incorretamente como QRCode. |
| <b>Margem <math>M</math></b> | Preserva a <i>quiet zone</i> ao redor do código, facilitando sua detecção.                             | A ausência dessa margem pode impedir o alinhamento e a leitura correta do código.          |

Este exercício integra conceitos estudados ao longo do capítulo em um único *pipeline* de Visão Computacional. A segmentação reduz o conjunto de regiões candidatas por meio de características geométricas, enquanto a etapa de decodificação valida o conteúdo da região utilizando um algoritmo especializado de reconhecimento.

#### 6.14.8.4 Especificação de Entrada e Saída (VPL)

Estrutura de Entrada

```
L
C
T A_min tol M
[matriz da imagem]
```

Estrutura de Saída (Sucesso)

```
linha coluna altura largura
texto_decodificado
```

Estrutura de Saída (Falha)

```
QRCODE_NAO_ENCONTRADO
```

#### 6.14.8.5 Arquivos de Referência (.pgm)

Para fins de validação, depuração local e análise de matrizes reais de pixels, os arquivos de imagem gerados no padrão ASCII P2 encontram-se disponíveis no diretório do projeto. Você pode utilizá-los para testar em decodificados do seu celular a aderência do seu código (salvar \*.pgm localmente para visualizar):

-  **Caso 1: Padrão Normal** – Contém um único código perfeitamente centralizado com distratores geométricos simples na periferia.
-  **Caso 2: Cenário Complexo** – Apresenta maior densidade de ruído texturizado e múltiplos distratores candidatos que testam os limites da filtragem por aspecto.

- 📄 **Caso 3: Mensagem Expandida** – Contém um QRCode estruturado a partir de uma cadeia de caracteres de maior comprimento, gerando maior densidade de módulos internos.
- 📄 **Caso 4: Geometria Compacta** – Avalia o comportamento do pipeline sob condições otimizadas de contraste e posicionamento limítrofe.
- 📄 **Caso 5: Cenário de Exclusão** – Imagem composta puramente por elementos distratores de alta área, projetada para validar o comportamento de falha controlada do programa.




Figura 6.28: Simulador: Segmentação Geométrica + Verificação por Decodificação de QRCode

```
%%writefile EP06_08.py
# Código Python
```

Overwriting EP06\_08.py

```
TestSuite("EP06_08.py").run()
```

## Capítulo 7

# Classificação de Imagens e Reconhecimento de Padrões



No **Capítulo 6**, a transição da Parte I para a Parte II foi apresentada por meio de duas aplicações que já exigiam decisões automatizadas: o reconhecimento de marcas em folhas de resposta (OMR) e a detecção de defeitos em inspeção industrial. Em ambos os casos, no entanto, as decisões dependiam de regras geométricas e de limiares definidos manualmente, como determinar se um disco era suficientemente circular ou se uma região era escura o bastante.

Este capítulo formaliza o problema mais geral subjacente a essas aplicações: dado um conjunto de exemplos rotulados, como treinar um sistema para **classificar automaticamente** novas imagens ou regiões de interesse? Essa questão está no núcleo do **Reconhecimento de Padrões**, disciplina que fundamenta grande parte das tarefas modernas de Visão Computacional, desde a classificação de imagens até a detecção de objetos e a segmentação semântica, exploradas nos próximos capítulos.

Serão estudados os principais **descritores clássicos de imagem** (cor, textura e forma/gradiente) e o classificador **k-Vizinhos mais Próximos** (*k-Nearest Neighbors* — k-NN), escolhido por sua simplicidade conceitual e por evidenciar, de forma direta, a relação entre o espaço de características, as métricas de distância e as fronteiras de decisão — conceitos que permanecem centrais mesmo em classificadores baseados em redes neurais profundas, estudados no capítulo final desta parte.

## 7.1 Objetivos do Capítulo

Ao final deste capítulo, o estudante deverá ser capaz de:

- Compreender o **pipeline clássico de reconhecimento de padrões**: aquisição, pré-processamento, extração de descritores, classificação e avaliação;
- **Extraair e interpretar descritores clássicos** de cor, textura (*Local Binary Patterns* — LBP) e forma/gradiente (*Histogram of Oriented Gradients* — HOG);
- **Implementar e treinar um classificador k-NN** para tarefas de classificação de imagens;
- **Avaliar classificadores** por meio de métricas como acurácia, matriz de confusão, precisão e revocação;
- **Analisar o efeito do parâmetro k** e da dimensionalidade do espaço de características no desempenho do classificador;
- **Reconhecer as limitações dos descritores artesanais** (*hand-crafted features*) e compreender a motivação para a transição, nos próximos capítulos, para descritores aprendidos automaticamente.

## 7.2 Configuração do Ambiente

Os exemplos deste capítulo utilizam bibliotecas amplamente empregadas em Processamento Digital de Imagens, Visão Computacional e Aprendizado de Máquina. O bloco abaixo instala os pacotes necessários; em ambientes que já os possuam, a execução pode ser ignorada.

```

# Instala apenas bibliotecas ausentes
import importlib
import subprocess
import sys

PACOTES = {
    "cv2": "opencv-python",
    "skimage": "scikit-image",
    "numpy": "numpy",
    "sklearn": "scikit-learn",
    "matplotlib": "matplotlib",
    "pandas": "pandas",
    "seaborn": "seaborn",
    "tabulate": "tabulate",
    "kaleido": "kaleido",
}

for modulo, pacote in PACOTES.items():
    try:
        importlib.import_module(modulo)
    except ImportError:
        subprocess.run(
            [sys.executable, "-m", "pip", "install", "-q", pacote],
            check=True
        )

# =====
# Bibliotecas
# =====

# Computação científica
import numpy as np
import pandas as pd

# Visualização
import matplotlib.cm as cm
import matplotlib.pyplot as plt
import seaborn as sns

# Visão computacional
import cv2
from skimage import data as skdata
from skimage.feature import hog, local_binary_pattern

# Aprendizado de máquina
from sklearn.datasets import load_digits, make_classification
from sklearn.model_selection import cross_val_score, train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import (
    accuracy_score,
    classification_report,
    confusion_matrix,
    f1_score,
    precision_score,
    recall_score,
)

```

Assim como no capítulo anterior, será utilizado o módulo didático `morph.py`, responsável por padronizar a leitura, a exibição e o processamento de imagens ao longo do livro.

```
import os
import urllib.request

if not os.path.exists("morph.py"):
    urllib.request.urlretrieve(
        "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph/morph.py",
        "morph.py",
    )

import morph
from morph import mm

print(f" Ambiente pronto. morph {getattr(morph, '__version__', 'local_file')}")
```

Ambiente pronto. morph 1.1.6

## 7.3 Um Problema Concreto: Classificação de Frutas

Antes de apresentar os fundamentos teóricos, considere o seguinte problema, que será utilizado como exemplo ao longo deste capítulo para ilustrar os principais conceitos de reconhecimento de padrões.

**O cenário:** Uma fazenda automatizada utiliza um sistema de Visão Computacional para separar maçãs, bananas e laranjas em linhas de embalagem.

**O desafio:** As frutas chegam à esteira em diferentes posições e orientações, sob condições de iluminação que podem variar. Além disso, folhas, sombras e pequenas oclusões podem dificultar sua identificação. Como desenvolver um sistema capaz de classificá-las corretamente?

**Uma possível abordagem:**

1. Extrair descritores que representem características relevantes das frutas:
  - **Cor:** distribuição predominante das cores;
  - **Textura:** diferenças na superfície da casca;
  - **Forma:** características geométricas do contorno.
2. Treinar um classificador utilizando exemplos previamente rotulados.
3. Utilizar o modelo treinado para classificar automaticamente novas frutas.

A Figure 7.1 ilustra, de forma conceitual, como diferentes frutas podem ser representadas em um espaço de características tridimensional.

💡 Reflita antes de continuar

Se cada fruta fosse representada apenas pelos valores de intensidade de seus pixels, seria possível distingui-las de forma confiável? Que tipos de informação poderiam ser extraídos da imagem para facilitar essa tarefa?

```
np.random.seed(42)

centros = {
    "Maçã": [0.8, 0.2, 0.9],
    "Banana": [0.3, 0.1, 0.2],
    "Laranja": [0.9, 0.8, 0.8],
}

fig = plt.figure(figsize=(5, 5))
ax = fig.add_subplot(projection="3d")
```

```

for fruta, centro, cor, marcador in zip(
    centros,
    centros.values(),
    ["red", "gold", "orange"],
    ["o", "s", "^"],
):
    X = np.clip(np.random.normal(centro, 0.08, (70, 3)), 0, 1)
    ax.scatter(X[:, 0], X[:, 1], X[:, 2],
               c=cor, marker=marcador, s=35,
               alpha=0.7, label=fruta)

ax.set(
    xlim=(0,1), ylim=(0,1), zlim=(0,1),
    xlabel="Intensidade de cor",
    ylabel="Textura",
    zlabel="Forma",
    title="Espaço de Características"
)
ax.view_init(elev=25, azim=-60)
ax.legend(title="Frutas")
ax.zaxis.labelpad = 0.01

plt.tight_layout()
plt.show()

```




Figura 7.1: Exemplo motivacional: diferentes frutas formando agrupamentos distintos em um espaço de características.



7.4 Panorama do Capítulo: O *Pipeline* Clássico de Classificação de Imagens

Antes de prosseguir, é útil apresentar uma visão integrada do que será estudado. A Figure 8.1 mostra o fluxo geral de um sistema clássico de classificação de imagens, desde a imagem de entrada até a etapa de atribuição do rótulo final. Nas próximas seções, cada uma das etapas desse processo será estudada em detalhes.




Figura 7.2: Panorama do *pipeline* clássico de classificação de imagens: extração de descritores (LBP, HOG), formação do espaço de características e classificação via k-NN. Não se aplica a modelos de *deep learning* (CNNs, YOLO), que aprendem *features end-to-end* diretamente dos pixels. **Fonte:** elaborado com auxílio do Gemini Notebook (Google, 2025).

**i** Escopo deste capítulo

Neste capítulo, o foco recai exclusivamente sobre o classificador k-NN, por sua simplicidade didática e por ilustrar de forma intuitiva o conceito de espaço de características. Outros classificadores tradicionais amplamente utilizados em Reconhecimento de Padrões — como Árvores de Decisão, Regras de Classificação e Máquinas de Vetores de Suporte (SVM) — são discutidos em profundidade em Quilici-Gonzalez; Zampirolli (2014), especialmente em sua 2ª edição, atualmente em produção (Quilici-Gonzalez; Zampirolli; Souza, 2026).

7.5 Fundamentos de Reconhecimento de Padrões

Um sistema de **reconhecimento de padrões** tem como objetivo atribuir uma categoria (rótulo) a uma observação — uma imagem inteira, uma região de interesse ou um sinal — com base em exemplos previamente rotulados. De forma geral, esse processo é organizado nas seguintes etapas:

1. **Aquisição:** obtenção da imagem ou do sinal a ser classificado;
2. **Pré-processamento:** normalização, remoção de ruído, correção geométrica ou de iluminação — etapas já estudadas nos capítulos anteriores;
3. **Extração de descritores (*features*):** transformação da imagem em um **vetor de características** de dimensão fixa, que representa as propriedades relevantes para a tarefa de classificação;

4. **Classificação:** aplicação de um modelo que associa o vetor de características a uma classe;
5. **Avaliação:** análise do desempenho do modelo em um conjunto de dados independente daquele utilizado para o treinamento.

O conjunto de todos os vetores de características possíveis constitui o **espaço de características** (*feature space*). Um bom descritor produz representações que aproximam, nesse espaço, observações da mesma classe e afastam observações de classes distintas. Essa propriedade favorece métodos de classificação baseados em proximidade, como o **k-NN**, e também beneficia diversos outros classificadores.

A Figure 7.1 ilustra esse conceito de forma esquemática: cada fruta é representada por um ponto em um espaço de características de três dimensões (cor, textura e forma). Embora esse espaço seja apenas uma simplificação didática, ele mostra como amostras da mesma classe tendem a formar agrupamentos, enquanto classes diferentes ocupam regiões distintas, facilitando a tarefa de classificação.

## 7.6 Extração de Descritores Clássicos

Antes da popularização das redes neurais profundas, os descritores de imagem eram, em sua maioria, projetados manualmente por especialistas (*hand-crafted features*), com base em propriedades estatísticas ou geométricas conhecidas. Três famílias clássicas são particularmente relevantes:

- **Descritores de cor:** histogramas de intensidade ou de matiz, que capturam a distribuição dos valores de cor de uma região, já introduzidos no **Capítulo 3** por meio da função `mm.hist`;
- **Descritores de textura:** capturam padrões locais de repetição, rugosidade ou orientação, como o *Local Binary Patterns* (LBP), estudado a seguir;
- **Descritores de forma/gradiente:** descrevem a distribuição das bordas e das orientações do gradiente, como o *Histogram of Oriented Gradients* (HOG), amplamente empregado na detecção de pessoas e outros objetos.

Para comparar a informação capturada por cada abordagem, a Figure 7.3 mostra como diferentes técnicas “enxergam” a mesma imagem.

```
# Carregar imagem de exemplo
imagem = skdata.camera()

# Aplicar descritores
lbp_img = local_binary_pattern(
    imagem,
    P=8,
    R=1,
    method="uniform"
)

# Converter o LBP para RGB apenas para facilitar a visualização
lbp_norm = (lbp_img - lbp_img.min()) / (lbp_img.max() - lbp_img.min() + 1e-8)
lbp_rgb = (cm.nipy_spectral(lbp_norm)[..., :3] * 255).astype("uint8")

hog_features, hog_img = hog(
    imagem,
    orientations=9,
    pixels_per_cell=(8, 8),
    cells_per_block=(2, 2),
    visualize=True,
)

# Exibição padronizada
mm.show(
    [imagem, lbp_rgb, hog_img],
    titles=[
```

```

"Imagem Original\n(como o humano vê)",
"LBP: Textura\n(cada cor = um código LBP)",
"HOG: Gradientes e Contornos\n(regiões claras = maior intensidade)",
],
cols=3,
figsize=(12, 4),
)

print("Observe como cada descritor destaca propriedades diferentes:")
print("• LBP: evidencia padrões locais de textura.")
print("• HOG: evidencia contornos e orientações das bordas.")
print("• Imagem original: contém apenas os valores de intensidade.")

```




Figura 7.3: Comparação visual de diferentes descritores aplicados à mesma imagem. Cada descritor revela aspectos distintos da cena.

Observe como cada descritor destaca propriedades diferentes:

- LBP: evidencia padrões locais de textura.
- HOG: evidencia contornos e orientações das bordas.
- Imagem original: contém apenas os valores de intensidade.

### 7.6.1 Local Binary Patterns (LBP)

O LBP é um descritor de textura que codifica, para cada pixel central  $g_c$ , a relação entre sua intensidade e a dos  $P$  vizinhos dispostos em uma vizinhança circular de raio  $R$ :

$$\text{LBP}_{P,R}(x_c, y_c) = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p, \quad s(z) = \begin{cases} 1, & z \geq 0 \\ 0, & z < 0 \end{cases}$$

em que:

- $(x_c, y_c)$  são as coordenadas do pixel central;
- $g_c$  é a intensidade do pixel central;
- $g_p$  é a intensidade do  $p$ -ésimo pixel vizinho;
- $P$  é o número de vizinhos considerados;
- $R$  é o raio da vizinhança circular;
- $p$  é o índice do vizinho, com  $p = 0, 1, \dots, P-1$ ;
- $s(z)$  é a função limiar definida na equação, em que  $z = g_p - g_c$ ; ela assume valor 1 quando  $z \geq 0$  e 0 quando  $z < 0$ ;
- $2^p$  corresponde ao peso binário associado ao  $p$ -ésimo vizinho.

O código LBP obtido descreve o padrão local de contraste ao redor do pixel. O histograma desses códigos forma um vetor de características compacto para representar a textura da imagem (Figure 7.4). Neste capítulo utiliza-se a variante **uniforme**, que agrupa padrões não uniformes em uma única categoria, reduzindo a dimensionalidade e aumentando a robustez do descritor.

```
plt.figure(figsize=(6, 4))

plt.hist(
    lbp_img.ravel(),
    bins=np.arange(-0.5, lbp_img.max() + 1.5, 1),
    density=True,
    edgecolor="black",
)

plt.title("Histograma dos códigos LBP")
plt.xlabel("Código LBP")
plt.ylabel("Frequência relativa")
plt.xticks(range(int(lbp_img.max()) + 1))
plt.grid(axis="y", alpha=0.3)

plt.tight_layout()
plt.show()
```




Figura 7.4: Histograma dos códigos LBP da imagem do cameramen. Cada barra representa a frequência relativa de um código LBP, formando o vetor de características utilizado para descrever a textura.

#### 💡 Função `local_binary_pattern`

A implementação utilizada neste capítulo é fornecida pela biblioteca `scikit-image`:

```
local_binary_pattern(
    imagem,
    P=8,
    R=1,
    method="uniform"
)
```

onde:

- **image**: imagem em escala de cinza;
- **P**: número de vizinhos igualmente espaçados na vizinhança circular;
- **R**: raio da vizinhança, em pixels;
- **method**: estratégia de codificação. Neste capítulo utiliza-se o valor "uniform".

A equação apresentada anteriormente descreve o **LBP original**. Na implementação adotada neste capítulo, a opção **method="uniform"** calcula inicialmente esse código e, em seguida, remapeia os padrões não uniformes para uma única categoria, reduzindo a dimensionalidade do descritor e tornando-o mais robusto a pequenas variações locais.

A Figure 7.3 apresenta a representação visual do LBP, enquanto a Figure 7.4 mostra o histograma dos códigos LBP utilizado como vetor de características.

O **Projeto Prático 2** (seção **Comparação de Descritores para Classificação de Texturas**) emprega o LBP na classificação de diferentes tipos de textura sintética.

### 7.6.2 Histogram of Oriented Gradients (HOG)

O HOG é um descritor que representa a forma de um objeto por meio da distribuição das orientações do gradiente local. Assim como no operador de Canny (**Capítulo 6**), calcula-se inicialmente o gradiente:

$$|\nabla f(x, y)| = \sqrt{\left(\frac{\partial f}{\partial x}\right)^2 + \left(\frac{\partial f}{\partial y}\right)^2}, \quad \theta(x, y) = \text{atan2}\left(\frac{\partial f}{\partial y}, \frac{\partial f}{\partial x}\right).$$

em que:

- $f(x, y)$  é a intensidade da imagem no pixel  $(x, y)$ ;
- $\frac{\partial f}{\partial x}$  e  $\frac{\partial f}{\partial y}$  são, respectivamente, as derivadas parciais da imagem nas direções horizontal e vertical;
- $|\nabla f(x, y)|$  é a magnitude do vetor gradiente no pixel  $(x, y)$ , indicando a intensidade da variação local da imagem;
- $\theta(x, y)$  é a orientação do vetor gradiente no pixel  $(x, y)$ , calculada pela função  $\text{atan2}$ , cujo resultado pertence ao intervalo  $(-\pi, \pi]$ .

Embora  $\theta(x, y)$ , como calculado pela função  $\text{atan2}$ , pertença ao intervalo  $(-\pi, \pi]$ , a implementação padrão do HOG utiliza o **gradiente não sinalizado** (*unsigned*): orientações opostas (por exemplo, 0 e  $\pi$ ) são tratadas como equivalentes, e os ângulos são mapeados para o intervalo  $[0, \pi)$  antes da construção do histograma. Essa escolha torna o descritor invariante à direção do contraste (por exemplo, uma borda clara-escura e uma borda escura-clara produzem a mesma orientação).

A imagem é então dividida em **células** (*cells*). Para cada célula, constrói-se um histograma das orientações do gradiente, ponderado pela magnitude correspondente. A concatenação dos histogramas de todas as células forma o vetor de características HOG, que representa a distribuição espacial das orientações do gradiente e captura informações sobre a forma e os contornos do objeto (Figure 7.5).

```
n = 100

plt.figure(figsize=(8, 3))
plt.bar(
    range(n),
```



```

hog_features[:n],
width=0.9
)

plt.title("Primeiros componentes do vetor HOG")
plt.xlabel(f"Índice do componente (0-{n-1}, de um total de {hog_features.shape[0]})")
plt.ylabel("Valor normalizado")
plt.grid(axis="y", alpha=0.3)

plt.tight_layout()
plt.show()

```




Figura 7.5: Primeiros 100 componentes do vetor de características HOG.

### 💡 Função hog

A extração do descritor HOG é realizada pela função:

```

hog(
    image,
    orientations=9,
    pixels_per_cell=(8, 8),
    cells_per_block=(2, 2),
    visualize=True,
)

```

Os principais parâmetros são:

- **image**: imagem de entrada;
- **orientations**: número de divisões angulares do histograma de orientações em cada célula;
- **pixels\_per\_cell**: tamanho, em pixels, de cada célula onde o histograma é calculado;
- **cells\_per\_block**: número de células utilizadas na normalização do descritor;
- **visualize**: quando **True**, retorna também uma imagem ilustrando os gradientes utilizados pelo HOG.

A equação apresentada anteriormente descreve o cálculo da magnitude e da orientação do gradiente, que constituem a base do descritor HOG. Na implementação adotada neste capítulo, a função `hog()` utiliza essas informações para construir histogramas de orientações em cada célula da imagem e, em seguida, realiza a normalização em blocos (`cells_per_block`), reduzindo a sensibilidade do descritor a variações de iluminação e contraste.

A Figure 7.3 apresenta a representação visual do HOG, enquanto a Figure 7.5 ilustra os primeiros componentes do vetor de características extraído da imagem.

O **Projeto Prático 1** (seção **Classificação de Dígitos Manuscritos com k-NN**) compara o desempenho de descritores HOG com o uso direto das intensidades dos pixels como vetor de características.

### 7.6.3 O Impacto da Escala e a Normalização de Características

O classificador  $k$ -NN toma suas decisões com base na distância entre os vetores de características. Por isso, a escala de cada característica influencia diretamente o resultado da classificação. Se uma variável apresentar valores muito maiores do que as demais (por exemplo, uma intensidade de cor variando de 0 a 255, enquanto um índice de circularidade varia de 0 a 1), ela tende a dominar o cálculo da distância, reduzindo a influência dos outros descritores.

Para evitar esse problema, aplica-se uma etapa de **normalização das características**, geralmente por meio da padronização (*Z-score standardization*). Nesse procedimento, cada característica passa a ter média igual a zero e desvio-padrão igual a um, tornando comparáveis grandezas originalmente medidas em escalas diferentes.

A padronização é realizada pela transformação

$$z = \frac{x - \mu}{\sigma},$$

em que:

- $x$  é o valor original da característica;
- $\mu$  é a média dessa característica calculada sobre o conjunto de treinamento;
- $\sigma$  é o desvio-padrão da característica;
- $z$  é o valor padronizado.

Após essa transformação, todas as características passam a possuir média igual a zero e desvio-padrão igual a um, permitindo que contribuam de forma equilibrada para o cálculo das distâncias.

#### Classe StandardScaler

A padronização utilizada neste capítulo é realizada pela classe `StandardScaler`, da biblioteca `scikit-learn`:

```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
X_norm = scaler.fit_transform(X)
```

em que:

- `StandardScaler()`: cria o objeto responsável pela padronização;
- `fit_transform(X)`: calcula a média e o desvio-padrão de cada característica do conjunto  $X$  e retorna a matriz padronizada.

Na prática, o método `fit_transform()` executa duas etapas: primeiro (`fit`), estima a média ( $\mu$ ) e o desvio-padrão ( $\sigma$ ) de cada característica; em seguida (`transform`), aplica a transformação de padronização apresentada anteriormente a todos os valores da matriz de entrada.

A **Figure 7.6** mostra o efeito da normalização. Visualmente, a distribuição dos pontos permanece a mesma; o que muda é a escala dos eixos. Sem a normalização, a característica de maior magnitude domina o cálculo das distâncias entre as amostras. Após a padronização, todas as características passam a contribuir de forma equilibrada para o cálculo das distâncias utilizadas pelo classificador  $k$ -NN.

```
# Dados sintéticos com escalas muito diferentes
np.random.seed(42)
X_demo = np.random.randn(20, 2) * [100, 1]
y_demo = np.array([0] * 10 + [1] * 10)
```



```

print("Efeito da normalização:")
print("  Característica 1: escala 100")
print("  Característica 2: escala 1")
print("\nSem normalização, a primeira característica domina o cálculo das distâncias.")
print("Com normalização, ambas contribuem de forma equilibrada.")
print("\nA normalização é essencial quando as características possuem escalas diferentes.")
fig, axes = plt.subplots(1, 2, figsize=(10, 4))

# Sem normalização
axes[0].scatter(
    X_demo[y_demo == 0, 0], X_demo[y_demo == 0, 1],
    c="blue", label="Classe 0"
)
axes[0].scatter(
    X_demo[y_demo == 1, 0], X_demo[y_demo == 1, 1],
    c="red", label="Classe 1"
)
axes[0].set_title("Sem Normalização\n(escalas diferentes)")
axes[0].set_xlabel("Característica 1 (escala 100)")
axes[0].set_ylabel("Característica 2 (escala 1)")
axes[0].legend()

# Com normalização
scaler = StandardScaler()
X_norm = scaler.fit_transform(X_demo)

axes[1].scatter(
    X_norm[y_demo == 0, 0], X_norm[y_demo == 0, 1],
    c="blue", label="Classe 0"
)
axes[1].scatter(
    X_norm[y_demo == 1, 0], X_norm[y_demo == 1, 1],
    c="red", label="Classe 1"
)
axes[1].set_title("Com Normalização\n(características balanceadas)")
axes[1].set_xlabel("Característica 1")
axes[1].set_ylabel("Característica 2")
axes[1].legend()

plt.tight_layout()
plt.show()

```

Efeito da normalização:

Característica 1: escala 100  
 Característica 2: escala 1

Sem normalização, a primeira característica domina o cálculo das distâncias.  
 Com normalização, ambas contribuem de forma equilibrada.

A normalização é essencial quando as características possuem escalas diferentes.




Figura 7.6: Importância da normalização das características para o classificador k-NN.

## 7.7 Mapa Conceitual

Até aqui, foram apresentados os descritores clássicos (LBP, HOG, pixels brutos) e a forma como eles organizam as amostras em um espaço de características. A Figure 7.7 sintetiza esse percurso e situa essas etapas dentro do fluxo geral de um sistema clássico de classificação de imagens, indicando também as etapas seguintes — classificação (k-NN) e avaliação dos resultados — que serão formalizadas nas próximas seções.

## 7.8 Descritores na Prática

Após conhecer os principais descritores clássicos, é natural perguntar como eles influenciam o desempenho de um classificador em situações próximas às encontradas na prática.

Nesta seção, compara-se o uso de três representações distintas das mesmas imagens: intensidades dos pixels, descritores LBP e descritores HOG. Para tornar o experimento mais realista, adiciona-se ruído sintético aos dados, em intensidades diferentes para cada descritor — uma forma simplificada de simular o fato de que, na prática, diferentes representações toleram de forma desigual as imperfeições da captura (ruído do sensor, pequenas variações de posição, etc.).

A Figure 7.8 apresenta as matrizes de confusão obtidas para cada descritor, permitindo identificar em quais classes ocorrem os principais erros de classificação. A interpretação dessas matrizes foi introduzida no **Capítulo 1**, quando foram apresentados os conceitos de **Verdadeiro Positivo (VP)**, **Falso Positivo (FP)**, **Verdadeiro Negativo (VN)** e **Falso Negativo (FN)**. Esses conceitos foram explorados nos **EPs 01\_02** (métricas de classificação) e **01\_03** (*mean Average Precision* – mAP), disponíveis em:

- [https://fzampirolli.github.io/pdi-vc/eps/py.pt/EP01\\_02.html](https://fzampirolli.github.io/pdi-vc/eps/py.pt/EP01_02.html)
- [https://fzampirolli.github.io/pdi-vc/eps/py.pt/EP01\\_03.html](https://fzampirolli.github.io/pdi-vc/eps/py.pt/EP01_03.html)

Neste capítulo, as matrizes de confusão são empregadas para analisar como diferentes descritores influenciam o desempenho do classificador.

Em seguida, a Figure 7.9 resume a acurácia global obtida por cada descritor.

Os resultados mostram que o desempenho do classificador depende diretamente da representação escolhida para descrever as imagens. Enquanto o uso direto das intensidades dos pixels é mais sensível às degradações introduzidas, os descritores LBP e HOG preservam melhor as informações relevantes para a classificação, resultando em maior desempenho nesse cenário. É importante ressaltar que os níveis de ruído aplicados a cada descritor foram escolhidos apenas para fins didáticos, de modo a ilustrar o princípio geral de que




Figura 7.7: Mapa conceitual do processo de classificação de imagens utilizando descritores clássicos (LBP, HOG, pixels brutos) e classificador tradicional (k-NN). Não se aplica a modelos de *deep learning* (CNNs, YOLO), que aprendem *features end-to-end* diretamente dos pixels.

descritores mais elaborados *podem* ser mais robustos a degradações — o que não significa que essa relação se verifique sempre, como o estudo de caso da próxima seção demonstrará.

### 💡 Como o experimento é realizado

Como o objetivo desta seção é comparar apenas o efeito dos descritores, gera-se um conjunto de dados sintético simples: três nuvens de pontos gaussianas, centradas nos mesmos valores de “cor, textura e forma” já utilizados na Figure 7.1 — o mesmo padrão empregado desde o início do capítulo para representar as três classes de frutas.

```
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, confusion_matrix
```

```
centros = {
    "Maçã": [0.8, 0.2, 0.9],
    "Banana": [0.3, 0.1, 0.2],
    "Laranja": [0.9, 0.8, 0.8],
}

n_por_classe = 100
X = np.vstack([
    np.random.normal(centro, 0.12, (n_por_classe, 3))
    for centro in centros.values()
])
y = np.repeat(list(centros.keys()), n_por_classe)
```

em que:

- `centros`: dicionário com o ponto médio de cada classe no espaço de características (cor, textura, forma);
- `n_por_classe`: número de amostras geradas por classe;
- `np.random.normal(centro, 0.12, (n_por_classe, 3))`: gera `n_por_classe` amostras ao redor de cada centro, com desvio-padrão 0,12 em cada dimensão;
- `np.repeat(list(centros.keys()), n_por_classe)`: gera o vetor de rótulos correspondente, na mesma ordem dos centros.

Em seguida, utiliza-se o fluxo de treinamento e avaliação:

- `train_test_split(X, y, test_size=0.3)`: divide os dados em treinamento (70%) e teste (30%);
- `KNeighborsClassifier(n_neighbors=5)`: cria um classificador  $k$ -NN com  $k = 5$  vizinhos;
- `fit(X_train, y_train)`: ajusta o modelo aos dados de treinamento;
- `predict(X_test)`: classifica as amostras de teste;
- `accuracy_score(y_test, y_pred)`: calcula a acurácia;
- `confusion_matrix(y_test, y_pred)`: gera a matriz de confusão.

Neste experimento, o conjunto de treinamento, o classificador e o método de avaliação permanecem exatamente os mesmos. A única diferença entre os experimentos é a representação utilizada para cada imagem (pixels brutos, LBP ou HOG), permitindo avaliar exclusivamente a influência do descritor sobre o desempenho do classificador.

```
classes = ["Maçã", "Banana", "Laranja"]

np.random.seed(42)

# Mesmos centros de classe (cor, textura, forma) utilizados no
# exemplo anterior, agora reaproveitados para gerar os dados
# sintéticos de treino e teste deste experimento.
centros = {
```

```

    "Maçã": [0.8, 0.2, 0.9],
    "Banana": [0.3, 0.1, 0.2],
    "Laranja": [0.9, 0.8, 0.8],
}

n_por_classe = 100
X = np.vstack([
    np.random.normal(centro, 0.12, (n_por_classe, 3))
    for centro in centros.values()
])
y = np.repeat(list(centros.keys()), n_por_classe)

# Simular descritores com diferentes níveis de sensibilidade ao ruído.
# Quanto maior o ruído adicionado, pior tende a ser a representação.
descritores = {
    "Pixels Brutos": X + 0.5 * np.random.randn(*X.shape),
    "LBP": X + 0.3 * np.random.randn(*X.shape),
    "HOG": X + 0.2 * np.random.randn(*X.shape),
}

# Criar uma única figura com 3 subplots lado a lado para as matrizes
fig, axes = plt.subplots(1, 3, figsize=(14, 4))
resultados = {}

for idx, (nome, Xd) in enumerate(descritores.items()):
    X_train, X_test, y_train, y_test = train_test_split(Xd, y, test_size=0.3, random_state=42)

    knn = KNeighborsClassifier(n_neighbors=5)
    knn.fit(X_train, y_train)
    y_pred = knn.predict(X_test)

    acc = accuracy_score(y_test, y_pred)
    resultados[nome] = acc

    # Matriz de confusão no subplot correspondente

    cm = confusion_matrix(y_test, y_pred, labels=classes)

    sns.heatmap(
        cm,
        annot=True,
        fmt="d",
        cmap="Blues",
        cbar=False,
        xticklabels=classes,
        yticklabels=classes,
        ax=axes[idx],
    )

    axes[idx].set_title(
        f"{nome}\nAcurácia: {acc:.3f}",
        fontsize=11,
        fontweight="bold"
    )
    axes[idx].set_xlabel("Classe Predita")
    axes[idx].set_ylabel("Classe Real")

plt.tight_layout()
plt.show()

```




Figura 7.8: Matrizes de confusão obtidas pelo classificador k-NN utilizando três descritores diferentes. As linhas representam a classe real (Maçã, Banana e Laranja) e as colunas a classe predita. Quanto maior a concentração de valores na diagonal principal, melhor o desempenho do descritor.

```
# Comparação visual em uma figura isolada
plt.figure(figsize=(6, 3.5))
nomes = list(resultados.keys())
acuracia = list(resultados.values())
colors = ['#6366f1', '#f97316', '#22c55e']

bars = plt.bar(nomes, acuracia, color=colors, width=0.5)
plt.ylabel('Acurácia Global')
plt.title('Desempenho Geral dos Descritores sob Ruído Realista', fontsize=12, fontweight='bold')
plt.ylim(0.5, 1.0)
plt.grid(axis='y', linestyle='--', alpha=0.5)

# Adicionar os valores acima das barras usando round padrão para exibição
for bar, val in zip(bars, acuracia):
    plt.text(bar.get_x() + bar.get_width()/2, bar.get_height() + 0.01,
             f'{val:.3f}', ha='center', fontweight='bold', fontsize=10)

plt.tight_layout()
plt.show()

print("Análise dos resultados:")
print("- Pixels Brutos: Sensíveis a variações locais de iluminação e ruído.")
print("- LBP: Boa tolerância para variações monotônicas de iluminação global.")
print("- HOG: Excelente para contornos e formas estáveis sob pequenas flutuações geométricas.")
```




Figura 7.9: Comparação detalhada de acurácia global em cenário realista. Observe como os descritores extraídos estruturalmente (LBP e HOG) superam o uso de intensidades puras de pixels brutos.

**Análise dos resultados:**

- Pixels Brutos: Sensíveis a variações locais de iluminação e ruído.
- LBP: Boa tolerância para variações monotônicas de iluminação global.
- HOG: Excelente para contornos e formas estáveis sob pequenas flutuações geométricas.

7.9 Um Problema Concreto: Simulando Descritores de Frutas

Retomando o problema de classificação de frutas apresentado no início do capítulo, cada imagem pode ser representada por um vetor de características (*feature vector*) obtido a partir da extração de descritores de cor, textura e forma. A Table 7.1 apresenta alguns descritores frequentemente utilizados em aplicações de Visão Computacional, incluindo técnicas introduzidas no Capítulo 3 e neste capítulo.

Tabela 7.1: Conjunto de descritores cromáticos, texturais e geométricos utilizados para representar imagens de frutas.

| Característica       | Descrição                                                     |
|----------------------|---------------------------------------------------------------|
| R, G, B              | intensidade média dos canais vermelho, verde e azul           |
| NC                   | intensidade média em níveis de cinza ( <i>grayscale</i> )     |
| LBP                  | descritor de textura ( <i>Local Binary Pattern</i> )          |
| HOG                  | descritor de forma ( <i>Histogram of Oriented Gradients</i> ) |
| Área                 | número de pixels do objeto                                    |
| Perímetro            | comprimento do contorno                                       |
| Circularidade        | medida de quão circular é o objeto                            |
| Razão largura/altura | proporção entre largura e altura da região                    |

Nesse exemplo, cada imagem é representada pelo vetor

$$X = (R, G, B, NC, LBP, HOG, \text{Área}, \text{Perímetro}, \text{Circularidade}, \text{Razão}).$$



### **i** Simplificação adotada nesta tabela

Na prática, LBP e HOG não são valores escalares, mas histogramas com dezenas ou centenas de componentes. Nesta seção, cada um deles é representado por um único valor apenas para simplificar a apresentação. Em aplicações reais, essas posições seriam substituídas pelas componentes completas dos respectivos histogramas.

Em aplicações reais, nem todos os descritores contribuem igualmente para distinguir as classes. Alguns fornecem informações mais relevantes, enquanto outros podem ser redundantes ou pouco discriminativos.

Para reproduzir esse cenário de forma controlada, será utilizado o `make_classification()`, da biblioteca `scikit-learn`. A função gera um conjunto de dados sintético cujas características podem ser interpretadas como descritores de imagens, permitindo definir quantas delas serão informativas para a classificação.

Neste exemplo, são geradas dez características sintéticas, das quais apenas sete (`n_informative=7`) participam da separação entre as três classes. As demais simulam atributos pouco informativos ou redundantes. A Figure 7.10 apresenta uma representação conceitual desse processo.

Antes de introduzir o algoritmo que será estudado em detalhe neste capítulo, cabe uma observação: para identificar, entre as dez características sintéticas, quais são mais discriminativas — e assim selecionar duas delas para a visualização em 2D —, utiliza-se um *Random Forest* apenas como ferramenta auxiliar de diagnóstico. O KNN, foco deste capítulo, é apresentado a seguir.

```
# Configuração para reprodução
np.random.seed(42)

# Geração de dados sintéticos com características controladas
X, y = make_classification(
    n_samples=300,
    n_features=10,
    n_informative=7,
    n_redundant=2,
    n_repeated=1,          # Uma característica é cópia de outra
    n_classes=3,
    n_clusters_per_class=1,
    random_state=42,
)

# Criar figura com dois subplots
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(14, 5))

# Subplot 1: Visualização das classes em 2D (usando duas características informativas)
# Identificar quais características são mais informativas
rf = RandomForestClassifier(n_estimators=100, random_state=42)
rf.fit(X, y)
importancias = rf.feature_importances_
caracteristicas_informativas = np.argsort(importancias)[-2:] # Duas mais importantes

cores = {0: "#e74c3c", 1: "#f1c40f", 2: "#e67e22"} # Maçã, Banana, Laranja
rotulos = {0: "Maçã", 1: "Banana", 2: "Laranja"}

for classe in range(3):
    idx = y == classe
    ax1.scatter(X[idx, caracteristicas_informativas[0]],
                X[idx, caracteristicas_informativas[1]],
                c=cores[classe], label=rotulos[classe],
                alpha=0.6, s=50, edgecolors="white", linewidth=0.5)

ax1.set_xlabel(f"Característica {caracteristicas_informativas[0]+1} (informativa)", fontsize=11)
```

```

ax1.set_ylabel(f"Característica {caracteristicas_informativas[1]+1} (informativa)", fontsize=11)
ax1.set_title("Classes no Espaço de Características\n(2 características informativas)",
              fontsize=12, fontweight="bold")
ax1.legend(loc="upper right")
ax1.grid(alpha=0.3)

# Subplot 2: Importância das características
bars = ax2.bar(range(1, 11), importancias, color="#4a90d9", alpha=0.7)
ax2.set_xlabel("Índice da Característica", fontsize=11)
ax2.set_ylabel("Importância", fontsize=11)
ax2.set_title("Importância de cada Característica\npara a Classificação",
              fontsize=12, fontweight="bold")
ax2.set_xticks(range(1, 11))
ax2.grid(axis="y", alpha=0.3)

# Colorir barras para destacar características
cores_barras = ["#e74c3c" if i < 7 else "#95a5a6" for i in range(10)]
for bar, cor in zip(bars, cores_barras):
    bar.set_color(cor)

# Adicionar legenda
from matplotlib.patches import Patch
legenda_elements = [
    Patch(facecolor="#e74c3c", label="Características Informativas (7)"),
    Patch(facecolor="#95a5a6", label="Características Redundantes (3)")
]
ax2.legend(handles=legenda_elements, loc="upper right")

# Anotar o número de características informativas
ax2.axhline(y=0.15, color="red", linestyle="--", alpha=0.3)
ax2.text(0.5, 0.17, "Limiar de importância", fontsize=9, color="red", alpha=0.7)

plt.tight_layout()
plt.show()

print("\n Análise dos dados gerados:")
print(f" • Total de amostras: {X.shape[0]}")
print(f" • Número de características: {X.shape[1]}")
print(f" • Características informativas: 7 (colunas 1 a 7 do gráfico)")
print(f" • Características redundantes: 2 (colunas 8 e 9)")
print(f" • Características repetidas: 1 (coluna 10)")
print(f" • Distribuição das classes: {np.bincount(y)}")

```




Figura 7.10: Ilustração do processo de geração de dados sintéticos com *make\_classification*. À esquerda, visualização das três classes em um espaço bidimensional formado por duas características informativas. À direita, importância relativa de cada característica para a classificação, evidenciando que apenas 7 das 10 características são efetivamente discriminativas, enquanto as demais são redundantes (2) ou repetidas (1).

#### Análise dos dados gerados:

- Total de amostras: 300
- Número de características: 10
- Características informativas: 7 (colunas 1 a 7 do gráfico)
- Características redundantes: 2 (colunas 8 e 9)
- Características repetidas: 1 (coluna 10)
- Distribuição das classes: [101 98 101]

## 7.10 Classificador k-NN: Como Funciona por Dentro

O **k-Nearest Neighbors (k-NN)** é um dos algoritmos de classificação mais simples e intuitivos da Aprendizagem de Máquina. Diferentemente de muitos classificadores, ele não constrói explicitamente um modelo durante a etapa de treinamento. Em vez disso, armazena as amostras rotuladas e, quando uma nova amostra precisa ser classificada, procura aquelas que mais se assemelham a ela.

O princípio do algoritmo baseia-se na hipótese de que amostras com características semelhantes tendem a pertencer à mesma classe. Para quantificar essa proximidade, o k-NN utiliza uma medida de distância entre os vetores de características.

Como exemplo, considere a Table 7.2, que apresenta uma versão simplificada do problema de classificação de frutas utilizando apenas duas características: intensidade de cor e circularidade, ambas normalizadas no intervalo de 0 a 1.

Tabela 7.2: Exemplo simplificado de classificação de frutas utilizando duas características normalizadas.

| Amostra         | Cor  | Circularidade | Classe |
|-----------------|------|---------------|--------|
| Fruta 1         | 0,82 | 0,88          | Maçã   |
| Fruta 2         | 0,30 | 0,20          | Banana |
| Fruta 3         | 0,88 | 0,85          | Maçã   |
| Fruta ? (teste) | 0,80 | 0,90          | ?      |

Observando apenas essas duas características, percebe-se que a fruta de teste está muito mais próxima das amostras rotuladas como **Maçã** do que da amostra rotulada como **Banana**. Na seção seguinte, essa noção intuitiva de proximidade será formalizada por meio de uma métrica de distância, utilizada pelo algoritmo para identificar os vizinhos mais próximos e decidir a classe da nova amostra.

### 7.10.1 Métrica de Distância

A proximidade entre duas amostras é normalmente quantificada pela **distância euclidiana**, definida por

$$d(x, x_i) = \|x - x_i\|_2 = \sqrt{\sum_{j=1}^n (x_j - x_{i,j})^2},$$

em que:

- $x$  é a amostra de teste;
- $x_i$  é uma amostra do conjunto de treinamento;
- $n$  é o número de características;
- $x_j$  e  $x_{i,j}$  representam a  $j$ -ésima característica.

Na implementação deste capítulo,  $x$  corresponde a uma linha de `X_test` e  $x_i$  a uma linha de `X_train`. O método `predict()` calcula automaticamente a distância entre  $x$  e todas as amostras de treinamento.

No exemplo da Table 7.2:

$$d(\text{teste}, \text{Fruta 1}) \approx 0,028, \quad d(\text{teste}, \text{Fruta 2}) \approx 0,860, \quad d(\text{teste}, \text{Fruta 3}) \approx 0,094.$$

Como as menores distâncias correspondem às Frutas 1 e 3, essas amostras serão utilizadas na etapa de decisão.

### 7.10.2 Regra de Decisão

Após ordenar as distâncias, o algoritmo seleciona os  $k$  vizinhos mais próximos. Seja  $N_k(x)$  esse conjunto. A classe predita é dada por

$$\hat{y} = \text{moda}\{y_i : x_i \in N_k(x)\},$$

em que  $y_i$  é o rótulo da amostra  $x_i$  e  $\hat{y}$  é a classe atribuída à amostra de teste.

No exemplo, para  $k = 3$ , os vizinhos são Fruta 1 (Maçã), Fruta 3 (Maçã) e Fruta 2 (Banana). Como **Maçã** recebe dois votos, essa é a classe predita.

#### Classe KNeighborsClassifier

Neste capítulo, o algoritmo é implementado com a classe `KNeighborsClassifier`, da biblioteca `scikit-learn`:

```
from sklearn.neighbors import KNeighborsClassifier

knn = KNeighborsClassifier(n_neighbors=3)
knn.fit(X_train, y_train)

y_pred = knn.predict(X_test)
```

em que:

- `KNeighborsClassifier(n_neighbors=3)`: define o valor de  $k$ ;
- `fit(X_train, y_train)`: armazena as amostras de treinamento (`X_train`) e seus rótulos (`y_train`);
- `predict(X_test)`: retorna as classes preditas para as amostras de `X_test`.

Internamente, `predict()` executa as etapas descritas anteriormente: calcula as distâncias, identifica os  $k$  vizinhos mais próximos e determina a classe por votação majoritária.

A Figure 7.11 ilustra esse procedimento em um conjunto bidimensional. A figura destaca os vizinhos utilizados na classificação, enquanto o console apresenta as etapas do algoritmo: cálculo das distâncias, ordenação, seleção dos vizinhos, votação e predição da classe.

```
def knn_passo_a_passo(X, y, x, k=3):
    """Executa as cinco etapas do algoritmo k-NN.
    Parâmetros: X (treino), y (rótulos), x (teste) e k (número de vizinhos).
    """
    # 1. Distâncias
    dist = [(np.linalg.norm(x-xi), yi, i) for i, (xi, yi) in enumerate(zip(X, y))]
    print(f"1. Distâncias calculadas: {len(dist)}")

    # 2. Ordenação
    dist.sort(key=lambda t: t[0])
    print("2. Distâncias ordenadas")

    # 3. Seleção
    vizinhos = dist[:k]
    print(f"3. {k} vizinhos mais próximos:")
    for d, c, _ in vizinhos:
        print(f"    {d:.4f} → {c}")

    # 4. Votação
    votos = {}
    for _, c, _ in vizinhos:
        votos[c] = votos.get(c, 0) + 1
    print("4. Votos:", votos)

    # 5. Decisão
    classe = max(votos, key=votos.get)
    print("5. Classe predita:", classe)

    return classe, vizinhos

# Dados de exemplo
np.random.seed(4)
X = np.r_[np.random.randn(15,2)+[2,2],
          np.random.randn(15,2)+[-2,-2]]
y = np.array(["Classe A"]*15 + ["Classe B"]*15)
x = np.array([0.5,0.5])

classe, vizinhos = knn_passo_a_passo(X, y, x)

# Visualização
plt.figure(figsize=(5,5))

for c, rotulo in [("Classe A","Classe A"), ("Classe B","Classe B")]:
    P = X[y==c]
    plt.scatter(P[:,0], P[:,1], s=80, label=rotulo)

plt.scatter(*x, marker="*", s=220, edgecolors="black", label="Teste")

for _, _, i in vizinhos:
    plt.scatter(*X[i], s=220, facecolors="none", edgecolors="black", linewidths=2)
    plt.plot([x[0], X[i,0]], [x[1], X[i,1]], "--", lw=1)

plt.xlabel("Característica 1")
plt.ylabel("Característica 2")
plt.title(f"k-NN ($k=3$): classe predita = {classe}")
```

```
plt.legend()
plt.grid(alpha=.3)
plt.axis("equal")
plt.tight_layout()
plt.show()
```

1. Distâncias calculadas: 30
2. Distâncias ordenadas
3. 3 vizinhos mais próximos:
  - 1.0850 → Classe A
  - 1.6379 → Classe B
  - 1.6382 → Classe A
4. Votos: {np.str\_('Classe A'): 2, np.str\_('Classe B'): 1}
5. Classe predita: Classe A




Figura 7.11: Classificação de uma nova amostra pelo algoritmo k-NN. O ponto de teste (estrela) é classificado a partir dos três vizinhos mais próximos, destacados por círculos.

### 7.10.3 O Papel do Parâmetro $k$

O parâmetro  $k$  determina quantos vizinhos participam da decisão de classificação.

- **Valores pequenos de  $k$**  (por exemplo,  $k = 1$ ) tornam o classificador mais sensível a ruídos e variações locais, produzindo fronteiras de decisão mais irregulares e favorecendo o *overfitting*.
- **Valores maiores de  $k$**  produzem fronteiras de decisão mais suaves, porém podem reduzir a sensibilidade a estruturas locais, favorecendo o *underfitting*.

Em problemas com duas classes, é comum utilizar valores ímpares de  $k$  para reduzir a ocorrência de empates. Outro aspecto importante é a **maldição da dimensionalidade** (*curse of dimensionality*). À medida que o

número de características aumenta, as distâncias entre as amostras tendem a se tornar mais semelhantes, dificultando a identificação de vizinhos realmente representativos.

### **i** Resumo

O algoritmo k-NN pode ser resumido em três etapas:

1. extrair o vetor de características da nova amostra;
2. identificar os  $k$  vizinhos mais próximos;
3. classificar a amostra pela classe mais frequente entre esses vizinhos.

O simulador da Figure 7.12 permite explorar visualmente o efeito do parâmetro  $k$  sobre a fronteira de decisão.




Figura 7.12: Simulador interativo da fronteira de decisão do k-NN: adicione pontos de treinamento e ajuste o valor de  $k$  para observar o efeito sobre a região de decisão.

## 7.11 Projeto Prático 1: Classificação de Dígitos Manuscritos com k-NN

As seções anteriores apresentaram o algoritmo k-NN por meio de um exemplo simplificado de classificação de frutas, utilizando apenas duas características. A seguir, o mesmo algoritmo é aplicado a um conjunto de dados de imagens, no qual cada amostra é representada por um vetor de maior dimensão.

Como estudo de caso, utiliza-se a base pública `load_digits`, disponibilizada pela biblioteca `scikit-learn`. Esse conjunto de dados contém 1797 imagens de dígitos manuscritos das classes de 0 a 9, cada uma com resolução de  $8 \times 8$  pixels em níveis de cinza. Cada imagem é representada por um vetor com 64 características,



correspondentes às intensidades dos pixels, e cada vetor possui um rótulo indicando o dígito correspondente.

A base `load_digits` é disponibilizada pela biblioteca `scikit-learn` e é utilizada neste capítulo para ilustrar a aplicação do algoritmo k-NN. Além de estar disponível diretamente no `scikit-learn`, ela dispensa etapas adicionais de obtenção e preparação dos dados, permitindo concentrar a atenção na implementação e na avaliação do classificador.

A Figure 7.13 apresenta uma amostra das imagens da base de dados.

```
digits = load_digits()
print(f"Total de amostras: {digits.data.shape[0]}, dimensão do vetor: {digits.data.shape[1]}")
print(f"Classes: {[int(i) for i in sorted(set(digits.target))]}")

n_amostras = 16
imgs = list(digits.images[:n_amostras])
imgs_titles = [str(label) for label in digits.target[:n_amostras]]
mm.show(imgs, titles=imgs_titles, cols=8, figsize=(12, 4))
```

```
Total de amostras: 1797, dimensão do vetor: 64
Classes: [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]
```




Figura 7.13: Amostra de dígitos manuscritos da base `load_digits`, utilizada como estudo de caso de classificação.

### 7.11.1 Classificação com Vetores de Intensidade

Neste primeiro experimento, cada imagem de dimensão  $8 \times 8$  é representada diretamente pelas intensidades de seus 64 pixels, sem a extração de descritores adicionais. Assim, cada amostra corresponde a um vetor de 64 características, utilizado como entrada do classificador k-NN.

Em seguida, o conjunto de dados é dividido em subconjuntos de treinamento e teste, preservando a proporção das dez classes por meio do parâmetro `stratify=y`. O classificador é treinado com  $k = 3$  e avaliado sobre o conjunto de teste utilizando a acurácia e a matriz de confusão apresentada na Figure 7.14.

```
X, y = digits.data, digits.target

X_treino, X_teste, y_treino, y_teste = train_test_split(
    X, y, test_size=0.3, random_state=42, stratify=y
)

n_neighbors = 3
knn_pixels = KNeighborsClassifier(n_neighbors=n_neighbors)
knn_pixels.fit(X_treino, y_treino)
pred_pixels = knn_pixels.predict(X_teste)

acc_pixels = accuracy_score(y_teste, pred_pixels)
print(f"Acurácia (vetores de intensidade, k={n_neighbors}): {acc_pixels:.4f}")
```

```

cm = confusion_matrix(y_teste, pred_pixels)

plt.figure(figsize=(5,4))
plt.imshow(cm, cmap="Blues")

for i in range(cm.shape[0]):
    for j in range(cm.shape[1]):
        plt.text(
            j, i, cm[i, j],
            ha="center", va="center",
            color="white" if cm[i, j] > cm.max()/2 else "black",
            fontsize=9
        )

plt.title("Matriz de Confusão - Pixels Brutos")
plt.xlabel("Classe Predita")
plt.ylabel("Classe Real")
plt.xticks(range(10))
plt.yticks(range(10))
plt.colorbar(fraction=0.046)
plt.tight_layout()
plt.show()

```

Acurácia (vetores de intensidade, k=3): 0.9870




Figura 7.14: Matriz de confusão do classificador k-NN treinado com vetores de intensidade brutos (pixels).

### 7.11.2 Classificação com Descritores HOG

No experimento anterior, cada imagem foi representada diretamente pelas intensidades de seus pixels. Nesta seção, essa representação é substituída por descritores HOG (*Histogram of Oriented Gradients*), que codificam informações sobre a distribuição das orientações dos gradientes da imagem.

Mantêm-se o mesmo particionamento dos dados, o mesmo classificador k-NN e o mesmo protocolo de avaliação, alterando apenas a representação das imagens. A Figure 7.15 compara os resultados obtidos com

vetores de intensidade e com descritores HOG.

```
descritores_hog = np.array([
    hog(img, orientations=8, pixels_per_cell=(4, 4), cells_per_block=(1, 1))
    for img in digits.images
])
print(f"Dimensão do vetor HOG: {descritores_hog.shape[1]}")

Xh_treino, Xh_teste, yh_treino, yh_teste = train_test_split(
    descritores_hog, y, test_size=0.3, random_state=42, stratify=y
)

n_neighbors = 3
knn_hog = KNeighborsClassifier(n_neighbors=n_neighbors)
knn_hog.fit(Xh_treino, yh_treino)
pred_hog = knn_hog.predict(Xh_teste)
acc_hog = accuracy_score(yh_teste, pred_hog)
print(f"Acurácia (descriptor HOG, k={n_neighbors}): {acc_hog:.4f}")

plt.figure(figsize=(4, 3))
plt.bar(["Pixels brutos", "HOG"], [acc_pixels, acc_hog], color=["#6366f1", "#f97316"])
plt.ylim(0, 1.1) # Aumenta o limite superior para dar espaço
plt.ylabel("Acurácia")
plt.title("Comparação de Descritores")
for i, v in enumerate([acc_pixels, acc_hog]):
    plt.text(i, v + 0.02, f"{v:.3f}", ha="center") # Aumenta o deslocamento vertical
plt.tight_layout()
```

Dimensão do vetor HOG: 32  
Acurácia (descriptor HOG, k=3): 0.7593




Figura 7.15: Comparação de acurácia entre descritores de pixels brutos e HOG para o classificador k-NN (k=3) na base de dígitos.

#### **i** Por que isso acontece?

Na Figure 7.15, o classificador treinado com vetores de **intensidade dos pixels** alcança maior acurácia (0.987) do que aquele baseado em descritores **HOG** (0.759). Esse resultado está relacionado às características da base `load_digits`.

As imagens possuem resolução de apenas  $8 \times 8$  pixels, encontram-se aproximadamente centralizadas

e apresentam pouca variação de iluminação, escala e orientação. Nesse cenário, as intensidades dos pixels preservam praticamente toda a informação necessária para distinguir as classes. Em contraste, o HOG resume a imagem em histogramas de orientações dos gradientes, reduzindo parte do detalhamento espacial disponível nos pixels originais.

Essa redução de informação pode dificultar a separação de dígitos visualmente semelhantes, como 3 e 8 ou 4 e 9, especialmente quando a resolução da imagem é baixa.

Em problemas com imagens de maior resolução ou sujeitas a variações de iluminação, posição, escala ou pequenas deformações, descritores como o HOG tendem a representar melhor a estrutura local da imagem do que os valores individuais dos pixels. Assim, este experimento ilustra um princípio importante da Aprendizagem de Máquina: **a representação dos dados deve ser escolhida de acordo com as características do problema e não pela complexidade do descritor.**

## 7.12 Avaliação de Classificadores

Nas seções anteriores, a qualidade do classificador foi analisada por meio da acurácia e da matriz de confusão. Nesta seção, essas ferramentas são complementadas por métricas utilizadas na avaliação de modelos e por um procedimento para selecionar o valor do parâmetro  $k$ .

A acurácia corresponde à proporção de amostras classificadas corretamente. Embora seja uma medida simples e amplamente utilizada, ela pode ser insuficiente quando as classes apresentam distribuições muito desbalanceadas.

A partir da matriz de confusão — introduzida no **Capítulo 1** e utilizada ao longo deste capítulo — podem ser calculadas métricas por classe, como precisão e revocação:

$$\text{Precisão} = \frac{VP}{VP + FP}, \quad \text{Revocação} = \frac{VP}{VP + FN},$$

em que  $VP$ ,  $FP$  e  $FN$  representam, respectivamente, o número de verdadeiros positivos, falsos positivos e falsos negativos da classe analisada. A precisão quantifica a proporção de predições positivas corretas, enquanto a revocação mede a capacidade do classificador de identificar os exemplos pertencentes à classe.

### 7.12.1 Escolha de $k$ por Validação Cruzada

Nos experimentos anteriores, adotou-se  $k = 3$  para ilustrar o funcionamento do algoritmo. Entretanto, esse parâmetro influencia diretamente o desempenho do classificador e, na prática, deve ser selecionado a partir dos dados.

Uma abordagem amplamente utilizada é a **validação cruzada** (*cross-validation*), na qual o conjunto de treinamento é dividido em partições sucessivas para estimar o desempenho do modelo em dados não utilizados durante o treinamento.

O código a seguir calcula a acurácia média obtida por validação cruzada de cinco partições (*5-fold cross-validation*) para diferentes valores de  $k$ . A Figure 7.16 apresenta os resultados, permitindo identificar a região em que o classificador atinge melhor desempenho.

```
valores_k = range(1, 16)
acuracias_medias = []

for k in valores_k:
    modelo = KNeighborsClassifier(n_neighbors=k)
    scores = cross_val_score(modelo, X, y, cv=5)
    acuracias_medias.append(scores.mean())

melhor_k = list(valores_k)[int(np.argmax(acuracias_medias))]
print(f"Melhor valor de k encontrado: {melhor_k} (acurácia média={max(acuracias_medias):.4f})")
```

```
plt.figure(figsize=(6, 4))
plt.plot(list(valores_k), acuracias_medias, marker="o", color="#4f46e5")
plt.axvline(melhor_k, color="#f97316", linestyle="--", label=f"melhor k = {melhor_k}")
plt.xlabel("k")
plt.ylabel("Acurácia média (validação cruzada)")
plt.title("Seleção de k por Validação Cruzada")
plt.legend()
plt.grid(alpha=0.3)
plt.tight_layout()
```

Melhor valor de k encontrado: 2 (acurácia média=0.9672)




Figura 7.16: Acurácia média por validação cruzada (5 partições) em função do parâmetro  $k$ , para a base de dígitos com vetores de intensidade brutos.

### 7.12.2 O Compromisso entre Viés e Variância: Diagnóstico de *Overfitting* e *Underfitting*

O hiperparâmetro  $k$  influencia a complexidade da fronteira de decisão do classificador  $k$ -NN e, consequentemente, sua capacidade de generalização. Em termos gerais, valores pequenos de  $k$  tornam o modelo mais sensível às amostras de treinamento, enquanto valores maiores produzem fronteiras de decisão mais suaves.

Esses comportamentos estão associados ao compromisso entre **viés** (*bias*) e **variância** (*variance*). Valores muito pequenos de  $k$  tendem a aumentar o risco de **sobreajuste** (*overfitting*), especialmente em conjuntos de dados ruidosos, ao passo que valores muito grandes podem levar ao **subajuste** (*underfitting*), reduzindo a capacidade do modelo de capturar estruturas locais dos dados.

Enquanto a Figure 7.16 apresentou apenas a acurácia média obtida por validação cruzada, a Figure 7.17 compara as acurácias de treinamento e de teste para diferentes valores de  $k$ . As regiões destacadas no gráfico representam o comportamento esperado do algoritmo: maior risco de sobreajuste para valores pequenos de  $k$ , uma região intermediária que frequentemente produz bom equilíbrio entre viés e variância e maior risco de subajuste para valores elevados de  $k$ .

Entretanto, essas regiões devem ser interpretadas apenas como uma referência conceitual. O comportamento observado depende das características do conjunto de dados. Na base `load_digits`, por exemplo, as imagens

apresentam pouca variabilidade e boa separação entre as classes, de modo que valores pequenos de  $k$  podem apresentar desempenho semelhante — ou até superior — aos demais, sem evidenciar um sobreajuste significativo.

```
k_values = range(1, 16)
train_acc, test_acc = [], []

for k in k_values:
    knn = KNeighborsClassifier(n_neighbors=k).fit(X_treino, y_treino)
    train_acc.append(accuracy_score(y_treino, knn.predict(X_treino)))
    test_acc.append(accuracy_score(y_teste, knn.predict(X_teste)))

plt.figure(figsize=(9,5))
plt.plot(k_values, train_acc, "o-", lw=2, label="Treinamento")
plt.plot(k_values, test_acc, "s-", lw=2, label="Teste")

plt.axvspan(1, 3, color="#fca5a5", alpha=.25, label="Maior risco de overfitting")
plt.axvspan(3,11, color="#86efac", alpha=.25, label="Compromisso entre viés e variância")
plt.axvspan(11,15, color="#93c5fd", alpha=.25, label="Maior risco de underfitting")

plt.xlabel("Número de vizinhos ($k$)")
plt.ylabel("Acurácia")
plt.xticks(k_values)
plt.grid(alpha=.3)
plt.legend(loc="upper right")
plt.tight_layout()
plt.show()

maior_acc = max(test_acc)
melhores_k = [k for k, a in zip(k_values, test_acc) if np.isclose(a, maior_acc)]

print("Interpretação")
print("- Valores pequenos de k: maior risco de overfitting.")
print("- Valores intermediários: melhor compromisso entre viés e variância.")
print("- Valores grandes de k: maior risco de underfitting.")
print("\nAs regiões coloridas representam tendências gerais;")
print("o comportamento observado depende do conjunto de dados.")
print(f"\nMaior acurácia no teste: {maior_acc:.3f}")
print(f"Valores de k que atingiram essa acurácia: {melhores_k}")
```




Figura 7.17: Acurácia nos conjuntos de treinamento e teste para diferentes valores de  $k$ . As regiões coloridas representam, de forma conceitual, tendências de comportamento do classificador: maior risco de sobreajuste (vermelho), compromisso entre viés e variância (verde) e maior risco de subajuste (azul).

#### Interpretação

- Valores pequenos de  $k$ : maior risco de overfitting.
- Valores intermediários: melhor compromisso entre viés e variância.
- Valores grandes de  $k$ : maior risco de underfitting.

As regiões coloridas representam tendências gerais;  
o comportamento observado depende do conjunto de dados.

Maior acurácia no teste: 0.987

Valores de  $k$  que atingiram essa acurácia: [1, 2, 3, 5]

## 7.13 Projeto Prático 2: Comparação de Descritores para Classificação de Texturas

No **Capítulo 6**, a variância local foi utilizada como descritor de textura para **detectar** anomalias em superfícies industriais, distinguindo amostras **conformes** e **defeituosas**. Neste projeto, o problema é reformulado como uma tarefa de **classificação multiclasse**, na qual diferentes representações da imagem são utilizadas como entrada para um classificador.

Serão considerados três tipos de descritores: as **intensidades dos pixels**, o **Local Binary Patterns (LBP)** e o **Histogram of Oriented Gradients (HOG)**. Para cada representação, será extraído um vetor de características que servirá de entrada para o algoritmo dos  $k$  vizinhos mais próximos ( $k$ -NN). Ao final, serão comparadas as acurácias obtidas por cada descritor nas condições definidas para este experimento.

A avaliação será realizada por meio de **validação cruzada estratificada em cinco partições (5-fold stratified cross-validation)**. Nesse procedimento, o conjunto de dados é dividido em cinco subconjuntos preservando a proporção entre as classes. Em cada iteração, uma partição é utilizada para teste e as quatro restantes para treinamento, repetindo-se o processo até que todas as partições tenham sido utilizadas como conjunto de teste. Ao término das cinco execuções, são calculadas a acurácia média e o desvio-padrão para



cada descritor.

O conjunto de dados é composto por três classes de texturas sintéticas: **granular**, obtida a partir de ruído gaussiano suavizado; **listrada**, formada por padrões senoidais periódicos; e **manchada**, composta por regiões circulares sobrepostas. Para introduzir variabilidade entre as amostras, todas as imagens recebem uma perturbação por ruído gaussiano de baixa intensidade. A Figure 7.18 apresenta exemplos das três classes utilizadas no experimento.

```
rng = np.random.default_rng(42)

def gerar_textura(classe, tamanho=64, ruido=0.10):
    """Gera uma textura sintética 64x64 pertencente a uma das três classes."""
    if classe == "granular":
        escala = rng.uniform(0.14, 0.22)
        img = rng.normal(0.5, escala, (tamanho, tamanho))
        img = cv2.GaussianBlur(img.astype(np.float32), (3, 3), 0)

    elif classe == "listrada":
        n_periodos = rng.uniform(4, 8)
        amplitude = rng.uniform(0.22, 0.38)
        eixo_x = np.linspace(0, n_periodos * np.pi, tamanho)
        base = 0.5 + amplitude * np.sin(eixo_x)
        img = np.tile(base, (tamanho, 1)).astype(np.float32)
        img += rng.normal(0, 0.09, (tamanho, tamanho)).astype(np.float32)

    elif classe == "manchada":
        img = np.full((tamanho, tamanho), 0.5, dtype=np.float32)
        n_manchas = rng.integers(5, 11)
        for _ in range(n_manchas):
            cx, cy = rng.integers(0, tamanho, 2)
            raio = int(rng.integers(3, 11))
            intensidade = float(rng.uniform(0.15, 0.9))
            cv2.circle(img, (int(cx), int(cy)), raio, intensidade, -1)
        img = cv2.GaussianBlur(img, (5, 5), 0)

    else:
        raise ValueError(f"Classe desconhecida: {classe}")

    img = img + rng.normal(0, ruido, (tamanho, tamanho)).astype(np.float32)
    img = np.clip(img, 0, 1)
    return (img * 255).astype(np.uint8)

classes_textura = ["granular", "listrada", "manchada"]
amostras = [gerar_textura(c) for c in classes_textura]

mm.show(amostras, titles=classes_textura, cols=3, figsize=(9, 3))
```




Figura 7.18: Amostras sintéticas das três classes de textura utilizadas no experimento de classificação, geradas com ruído gaussiano e variabilidade intra-classe.

### 7.13.1 Pipeline de Extração de Características e Avaliação Comparativa

Para comparar o desempenho de diferentes formas de representação das imagens, foi gerado um conjunto de dados balanceado contendo 60 amostras para cada classe. A partir desse conjunto, foram extraídos três tipos de vetores de características, cada um representando aspectos distintos da informação visual:

1. **Pixels brutos:** vetor obtido pelo achatamento (*flattening*) da matriz de intensidades da imagem, resultando em um vetor de  $64 \times 64 = 4096$  atributos;
2. **Histograma LBP uniforme:** histograma normalizado das frequências dos padrões locais produzidos pelo operador LBP uniforme, composto por 10 atributos;
3. **Descritor HOG:** vetor formado por histogramas de gradientes orientados, que representam a distribuição espacial das orientações das bordas, totalizando 128 atributos.

Como esses descritores possuem escalas e dimensionalidades distintas, os vetores de características são padronizados utilizando o `StandardScaler`, de modo que cada atributo apresente média zero e desvio-padrão unitário. Essa etapa evita que atributos com maior amplitude influenciem desproporcionalmente o cálculo das distâncias euclidianas empregado pelo classificador.

A avaliação é realizada utilizando o algoritmo  $k$ -NN com  $k = 5$ , sob o mesmo protocolo de validação cruzada estratificada em cinco partições descrito na seção anterior. A acurácia média obtida ao longo das cinco execuções, ver Figure 7.19, fornece uma estimativa mais estável do desempenho do classificador, reduzindo a dependência de uma única divisão entre treinamento e teste.

```
rng = np.random.default_rng(42)

# 1. Geração da base de dados
X_bruto, X_lbp, X_hog, y_textura = [], [], [], []

for classe in classes_textura:
    for _ in range(60):
        img = gerar_textura(classe, ruído=0.10)

        # Extração 1: Pixels brutos
        X_bruto.append(img.ravel())

        # Extração 2: Histograma LBP uniforme
        lbp = local_binary_pattern(img, P=8, R=1, method="uniform")
        hist_lbp, _ = np.histogram(lbp, bins=10, range=(0, 10), density=True)
        X_lbp.append(hist_lbp)
```

```

# Extração 3: Descritor HOG
feat_hog = hog(img, orientations=8, pixels_per_cell=(16, 16), cells_per_block=(1, 1))
X_hog.append(feat_hog)

y_textura.append(classe)

y_textura = np.array(y_textura)
descritores = {
    "Pixels Brutos": np.array(X_bruto),
    "LBP (Textura)": np.array(X_lbp),
    "HOG (Forma)": np.array(X_hog)
}

# 2. Avaliação estatística via 5-fold cross-validation
resultados_media = {}
resultados_desvio = {}

knn = KNeighborsClassifier(n_neighbors=5)
scaler = StandardScaler()

for nome, X_dados in descritores.items():
    X_norm = scaler.fit_transform(X_dados)
    scores = cross_val_score(knn, X_norm, y_textura, cv=5, scoring="accuracy")
    resultados_media[nome] = scores.mean()
    resultados_desvio[nome] = scores.std()
    print(f"{nome:15s} -> Acurácia Média: {scores.mean():.4f} (± {scores.std():.4f})")

# 3. Plotagem do gráfico comparativo formal
plt.figure(figsize=(7, 4.5))
nomes_desc = list(resultados_media.keys())
medias = list(resultados_media.values())
desvios = list(resultados_desvio.values())

bars = plt.bar(nomes_desc, medias, yerr=desvios, capsize=6,
               color=["#6366f1", "#9333ea", "#f97316"],
               width=0.45, edgecolor="black", alpha=0.85)
plt.ylabel("Acurácia Média (5-Fold CV)", fontsize=11)
plt.title("Análise Comparativa de Descritores para Classificação de Texturas",
          fontsize=12, fontweight="bold")
plt.ylim(0.3, 1.1)
plt.grid(axis="y", linestyle="--", alpha=0.5)

for bar in bars:
    h = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2,
             h + 0.03, f"{h:.3f}", ha="center", fontweight="bold")

plt.tight_layout()
plt.show()

```

```

Pixels Brutos    -> Acurácia Média: 0.6889 (± 0.0478)
LBP (Textura)    -> Acurácia Média: 0.7611 (± 0.0648)
HOG (Forma)      -> Acurácia Média: 0.4889 (± 0.0624)

```




Figura 7.19: Acurácia média obtida via validação cruzada (5-fold) para os descritores de Pixels Brutos, LBP e HOG aplicados à base de texturas sintéticas.

#### **i** Por que funciona? — LBP como representação de texturas

O descritor LBP representa a textura de uma imagem por meio de um histograma normalizado que contabiliza a frequência dos padrões locais de intensidade. Em vez de armazenar diretamente os valores dos pixels ou suas posições, essa representação resume a distribuição das microestruturas presentes na imagem, produzindo um vetor de características compacto.

Neste experimento, foram comparados três tipos de descritores: pixels brutos, LBP e HOG. Os vetores formados pelos **pixels brutos** preservam todas as intensidades da imagem, mas também incorporam variações decorrentes de ruído e pequenos deslocamentos espaciais, o que pode dificultar a comparação entre amostras por meio da distância euclidiana.

O descritor **HOG** representa a distribuição das orientações dos gradientes, sendo adequado para descrever formas e contornos. Como as imagens utilizadas neste projeto diferem principalmente pelas propriedades de textura, e não pela presença de contornos bem definidos, essa representação tende a capturar menos informações discriminativas do que o LBP.

Já o **LBP** foi desenvolvido especificamente para caracterizar padrões locais de textura. Seu histograma descreve a frequência das microestruturas presentes na imagem, independentemente de sua posição exata, tornando a representação menos sensível a pequenas variações espaciais e a mudanças monotônicas de iluminação.

Embora os histogramas das diferentes classes apresentem distribuições distintas, o ruído gaussiano introduzido na geração das imagens aumenta a variabilidade entre amostras da mesma classe e pode produzir regiões de sobreposição no espaço de características. Como consequência, algumas texturas podem ser confundidas pelo classificador. Ainda assim, quando as características relevantes para distinguir as classes estão associadas aos padrões locais de textura, espera-se que descritores projetados para essa finalidade, como o LBP, produzam representações mais informativas do que aquelas baseadas apenas nas intensidades dos pixels ou nas orientações dos gradientes.

### 7.13.2 Diagnóstico Fino do Classificador: Precisão, Revocação e F1-Score

A acurácia resume o desempenho do classificador em um único valor, mas não indica como esse desempenho se distribui entre as diferentes classes. Para uma análise mais detalhada, utilizam-se métricas calculadas individualmente para cada classe.

A **precisão** (*precision*) mede a proporção de amostras classificadas como pertencentes a uma classe que realmente pertencem a ela. A **revocação** (*recall*) mede a proporção de amostras da classe que foram corretamente identificadas pelo classificador. O **F1-score** corresponde à média harmônica entre precisão e revocação, fornecendo um indicador que equilibra ambas as medidas.

O relatório também informa o **suporte** (*support*), isto é, o número de amostras de cada classe presentes no conjunto de teste. Essa informação é importante para contextualizar as métricas, pois resultados obtidos sobre poucas amostras tendem a apresentar maior variabilidade.

A Figure 7.20 apresenta essas métricas para as três classes de textura. Em conjunto, elas permitem identificar diferenças de desempenho que não são evidentes apenas pela acurácia. Por exemplo, uma classe pode apresentar alta precisão e menor revocação, indicando que o classificador comete poucos falsos positivos, mas deixa de identificar parte das amostras que realmente pertencem àquela classe. Esse tipo de análise auxilia na compreensão das limitações do modelo e na identificação de possíveis estratégias para seu aprimoramento.

```
X_lbp_data = np.array(X_lbp)
y_textura_data = np.array(y_textura)

# Realizar um split de treino/teste para o relatório detalhado
Xt_treino, Xt_teste, yt_treino, yt_teste = train_test_split(
    X_lbp_data, y_textura_data, test_size=0.3, random_state=42, stratify=y_textura_data
)

# Escalar os dados
scaler = StandardScaler()
Xt_treino_scaled = scaler.fit_transform(Xt_treino)
Xt_teste_scaled = scaler.transform(Xt_teste)

# Treinar o classificador k-NN
knn_textura = KNeighborsClassifier(n_neighbors=5)
knn_textura.fit(Xt_treino_scaled, yt_treino)

y_pred = knn_textura.predict(Xt_teste_scaled)

report = classification_report(
    yt_teste,
    y_pred,
    target_names=classes_textura,
    output_dict=True
)

print("=== RELATÓRIO DE CLASSIFICAÇÃO DETALHADO ===")
print(f"{'Classe':<12} {'Precisão':>10} {'Revocação':>12} {'F1-score':>10} {'Suporte':>10}")
for classe in classes_textura:
    r = report[classe]
    print(f"{'classe':<12} {r['precision']:>10.2f} {r['recall']:>12.2f} "
          f"{r['f1-score']:>10.2f} {r['support']:>10.0f}")

precision = precision_score(yt_teste, y_pred, average=None, labels=classes_textura)
recall = recall_score(yt_teste, y_pred, average=None, labels=classes_textura)
f1 = f1_score(yt_teste, y_pred, average=None, labels=classes_textura)

fig, ax = plt.subplots(figsize=(10, 5))
x = np.arange(len(classes_textura))
```

```

width = 0.25

bars1 = ax.bar(x - width, precision, width, label='Precisão', color='#6366f1', alpha=0.8)
bars2 = ax.bar(x, recall, width, label='Revocação', color='#f97316', alpha=0.8)
bars3 = ax.bar(x + width, f1, width, label='F1-Score', color='#22c55e', alpha=0.8)

ax.set_xlabel('Classe', fontsize=12)
ax.set_ylabel('Score', fontsize=12)
ax.set_title('Métricas por Classe - Classificação de Texturas', fontsize=14, fontweight='bold')
ax.set_xticks(x)
ax.set_xticklabels(classes_textura)
ax.legend(loc='upper right')
ax.set_ylim(0, 1.35)
ax.grid(axis='y', alpha=0.3)

for bars in [bars1, bars2, bars3]:
    for bar in bars:
        height = bar.get_height()
        ax.text(bar.get_x() + bar.get_width()/2., height + 0.02,
                f'{height:.2f}', ha='center', va='bottom', fontsize=9)

plt.tight_layout()
plt.show()

print("Interpretação das métricas:")
print("- Precisão: entre as amostras classific. como pertencentes à classe,",
      "quantas estavam corretas?")
print("- Revocação: entre as amostras que realmente pertencem à classe, quantas",
      "foram identificadas?")
print("- F1-Score: média harmônica entre precisão e revocação.")
print("- Suporte: número de amostras reais de cada classe presentes no conjunto de teste.")
print("\nO suporte não mede desempenho; ele apenas informa quantos exemplos de cada",
      "classe foram utilizados na avaliação.")

```

=== RELATÓRIO DE CLASSIFICAÇÃO DETALHADO ===

| Classe   | Precisão | Revocação | F1-score | Suporte |
|----------|----------|-----------|----------|---------|
| granular | 0.67     | 0.78      | 0.72     | 18      |
| lustrada | 0.55     | 0.61      | 0.58     | 18      |
| manchada | 1.00     | 0.72      | 0.84     | 18      |




Figura 7.20: Métricas de avaliação detalhadas para o classificador  $k$ -NN com descritores LBP

#### Interpretação das métricas:

- **Precisão:** entre as amostras classificadas como pertencentes à classe, quantas estavam corretas?
- **Revocação:** entre as amostras que realmente pertencem à classe, quantas foram identificadas?
- **F1-Score:** média harmônica entre precisão e revocação.
- **Suporte:** número de amostras reais de cada classe presentes no conjunto de teste.

O suporte não mede desempenho; ele apenas informa quantos exemplos de cada classe foram utilizados na avaliação.

## 7.14 Limitações dos Descritores Artesanais

Os experimentos deste capítulo mostram que descritores clássicos podem ser bastante eficazes em tarefas de classificação, mas também apresentam limitações importantes:

- **Especificidade:** cada descritor foi desenvolvido para representar um determinado tipo de informação, como cor, textura ou forma. Assim, um descritor adequado para uma tarefa pode não ser o mais apropriado para outra.
- **Dependência de hiperparâmetros:** o desempenho de descritores como LBP e HOG depende da escolha de parâmetros, como raio de vizinhança, número de pontos amostrados, tamanho da célula e número de orientações, que precisam ser ajustados conforme a aplicação.
- **Representação limitada:** descritores de cor, textura e gradiente capturam propriedades de baixo nível da imagem, mas não representam diretamente conceitos semânticos mais complexos, como objetos ou cenas.
- **Maldição da dimensionalidade:** descritores muito extensos podem reduzir a eficácia de classificadores baseados em distância, como o  $k$ -NN.

Essas limitações motivam a evolução das técnicas estudadas nos próximos capítulos. O **Capítulo 8** apresenta métodos clássicos para detecção e correspondência de características em imagens, enquanto o **Capítulo 9** introduz as **Redes Neurais Convolucionais**, capazes de aprender automaticamente representações adequadas para cada tarefa a partir dos dados.



## 7.15 Resumo

Neste capítulo foram apresentados os fundamentos do reconhecimento de padrões aplicado a imagens. Os principais conceitos estudados foram:

- **Pipeline de reconhecimento de padrões:** aquisição, pré-processamento, extração de descritores, classificação e avaliação.
- **Descritores clássicos:** descritores de cor, LBP para textura e HOG para forma, utilizados para representar diferentes características das imagens.
- **Normalização de características:** padronização (*Z-score*) para evitar que atributos de maior magnitude dominem o cálculo das distâncias.
- **Classificador  $k$ -NN:** classificação baseada nos  $k$  vizinhos mais próximos no espaço de características.
- **Escolha do parâmetro  $k$ :** influência do valor de  $k$  sobre o desempenho do classificador e uso da validação cruzada para sua seleção.
- **Avaliação de classificadores:** acurácia, matriz de confusão, precisão, revocação e F1-score como métricas complementares de desempenho.
- **Limitações dos descritores artesanais:** especificidade, dependência de hiperparâmetros e dificuldade em representar informações de alto nível.

Os conceitos foram ilustrados por meio de experimentos com a base pública `load_digits`, texturas sintéticas geradas para fins didáticos e dados simulados de descritores de frutas.

## 7.16 Uso do Gemini Notebook como Tutor

Nesta edição, o **Gemini Notebook** é apresentado como uma ferramenta de apoio ao estudo. O sistema utiliza exclusivamente os documentos disponibilizados pelo autor como fonte de conhecimento, permitindo explorar os conceitos do capítulo por meio de perguntas, resumos e explicações relacionadas ao material estudado.

 Estude com o Tutor Inteligente

 [ACESSAR Gemini Notebook: CAPÍTULO 07](#)

### Aviso sobre Conteúdo Gerado por IA

As respostas fornecidas pelo Gemini Notebook podem conter imprecisões ou omissões. Sempre que necessário, confirme as informações utilizando o material deste capítulo e outras fontes acadêmicas confiáveis. A execução dos exemplos práticos apresentados ao longo do texto continua sendo a melhor forma de consolidar os conceitos estudados.

## 7.17 Lista de Exercícios

Os exercícios a seguir exploram e estendem os conceitos apresentados neste capítulo por meio de adaptações dos algoritmos implementados, análises experimentais e comparações entre diferentes abordagens.

1. **(10%)** Implemente um descritor de cor (histograma RGB ou HSV, com pelo menos 16 *bins* por canal) para as três classes de frutas simuladas na Figure 7.1. Treine um classificador  $k$ -NN com esse descritor, compare sua acurácia com a obtida pelos descritores LBP e HOG (Figure 7.9) e discuta em quais situações a informação de cor é mais discriminativa.
2. **(15%)** Investigue o efeito da normalização de características (*Z-score*) sobre o desempenho do  $k$ -NN em um espaço de atributos heterogêneo, combinando descritores de cor, LBP e HOG em um único vetor. Compare os resultados obtidos com e sem normalização para pelo menos três valores de  $k$ .
3. **(15%)** Reproduza a análise de *overfitting* e *underfitting* da Figure 7.17 variando o tamanho do conjunto de treinamento (por exemplo, 20%, 50% e 80% da base `load_digits`). Discuta como a quantidade de

exemplos influencia a escolha do valor de  $k$ .

4. **(15%)** Estenda o Projeto Prático 2 adicionando uma quarta classe sintética de textura. Avalie precisão, revocação e F1-score para cada classe, seguindo o padrão da Figure 7.20, e analise o impacto da nova classe na matriz de confusão.
5. **(15%)** Implemente manualmente o classificador  $k$ -NN, sem utilizar `sklearn`:  
`sklearn.neighbors.KNeighborsClassifier`,  
 completando a função `knn_passo_a_passo` apresentada no capítulo. Compare a acurácia e o tempo de execução da implementação manual com a implementação do `scikit-learn` em conjuntos de dados de tamanhos crescentes e relacione os resultados à maldição da dimensionalidade.
6. **(15%)** Investigue a influência dos parâmetros `orientations`, `pixels_per_cell` e `cells_per_block` do descritor HOG na base `load_digits`. Avalie pelo menos quatro combinações de parâmetros e discuta o compromisso entre dimensionalidade do descritor e desempenho do classificador.
7. **(15%)** Avalie a influência dos parâmetros  $P$  (número de vizinhos) e  $R$  (raio) do descritor LBP na classificação das texturas sintéticas do Projeto Prático 2, considerando  $P \in \{4, 8, 16\}$  e  $R \in \{1, 2, 3\}$ . Analise como esses parâmetros afetam a capacidade discriminativa do descritor.
8. **(Bônus – 10%)** Implemente manualmente a validação cruzada  $k$ -fold para o classificador  $k$ -NN na base `load_digits`, sem utilizar `cross_val_score`, e compare os resultados com os obtidos pela implementação do `scikit-learn` apresentada na Figure 7.16.

## Referências do Capítulo

A fundamentação teórica e os experimentos apresentados neste capítulo baseiam-se nas seguintes referências:

- Gonzalez; Woods (2018), pelos fundamentos de descritores estatísticos de textura e das operações de pré-processamento aplicadas à extração de características.
- Szeliski (2022), pela apresentação do pipeline clássico de reconhecimento de padrões, da extração de descritores e da avaliação de classificadores em Visão Computacional.
- Duda; Hart; Stork (2001), pelos fundamentos teóricos do reconhecimento de padrões, do classificador  $k$ -NN e da relação entre viés e variância.
- Cover; Hart (1967), pela formulação original do algoritmo dos  $k$  vizinhos mais próximos.
- Ojala; Pietikäinen; Mäenpää (2002), pela formulação do descritor *Local Binary Patterns* (LBP) e de sua variante uniforme, utilizada neste capítulo.
- Dalal; Triggs (2005), pela formulação do descritor *Histogram of Oriented Gradients* (HOG), empregado na representação de forma e contorno.
- Pedregosa et al. (2011), pela implementação do classificador  $k$ -NN, das métricas de avaliação e da validação cruzada na biblioteca `scikit-learn`.
- Quilici-Gonzalez; Zampiroli (2014), pela apresentação didática de classificadores tradicionais de Reconhecimento de Padrões, como Árvores de Decisão, Regras de Classificação e Máquinas de Vetores de Suporte (SVM), complementares ao classificador  $k$ -NN explorado neste capítulo.
- Quilici-Gonzalez; Zampiroli; Souza (2026), pela atualização e ampliação desses conteúdos em sua 2ª edição, atualmente em produção.

## 7.18 Parte Prática com Exercícios de Programação

A presente lista de exercícios de programação (EP) consolida as formulações teóricas apresentadas ao longo do Capítulo 7 — Classificação de Imagens e Reconhecimento de Padrões — por meio de uma trilha prática aplicada. Diferentemente da manipulação direta de pixels dos capítulos anteriores, os EPs deste

capítulo trabalham com as **grandezas intermediárias** de um *pipeline* real de reconhecimento de padrões — vetores de características, distâncias, rótulos previstos e reais, códigos binários locais e histogramas de orientação — permitindo validar manualmente cada etapa do raciocínio sem depender de bibliotecas externas de aprendizado de máquina.

O encadeamento dos exercícios reproduz o fluxo conceitual do capítulo: inicia-se com a implementação manual da regra de decisão do classificador **k-NN** sobre um pequeno espaço de características; em seguida, revisita-se, sob a ótica da normalização de características, o classificador implementado no primeiro exercício da lista; avança-se para o cálculo das métricas de **avaliação** (matriz de confusão, precisão e revocação) a partir de rótulos previstos e reais; prossegue-se com a codificação manual do descritor de textura **LBP** a partir de uma vizinhança  $3 \times 3$ ; aprofunda-se no cálculo do histograma de orientações do descritor **HOG** para uma única célula; avança-se, em seguida, para a integração de **extração de descritores**, **classificação k-NN** e **avaliação multi-classe** em um *pipeline* completo de reconhecimento de texturas; e conclui-se com a aplicação desse mesmo *pipeline* sobre uma **imagem real** (formato PGM), em que o descritor LBP é calculado diretamente sobre os pixels de um mosaico de texturas.

## 🎯 Objetivo deste Caderno

O caderno permite desenvolver, validar, organizar e testar soluções de **Exercícios de Programação (EPs)** em ambientes interativos, como o Colab, com os mesmos casos de teste do Moodle, copiando para lá apenas na hora de registrar a nota oficial.

## Download

Baixe `morph.py` e `testsuite.py` executando a célula abaixo:

```
import os, sys, importlib, inspect, urllib.request

# URLs do repositório
BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph"
for f in ["morph.py", "testsuite.py"]:
    if not os.path.exists(f):
        urllib.request.urlretrieve(f"{BASE_URL}/{f}", f)

import morph, testsuite
importlib.reload(morph); importlib.reload(testsuite)
from morph import mm
from testsuite import TestSuite

print(f" Ambiente pronto. Morph: {morph.__version__} | TestSuite: {testsuite.__version__}")
```

Ambiente pronto. Morph: 1.1.7 | TestSuite: 1.1.2

## Executando os Testes

Para avaliar os testes, execute `TestSuite("EP07_01.extensão").run()` numa nova célula, trocando a extensão pela da linguagem usada (`.py`, `.java`, `.c`, `.cpp`, `.js` ou `.r`). O sistema baixa os casos de teste do GitHub, executa o programa e calcula a nota automaticamente.

Para testar código Python diretamente, sem salvar arquivo, use `run_code(codigo)` passando o código como *string* numa variável `codigo`:

```
codigo = """
# ... seu código aqui ...
"""

TestSuite("EP07_01").run_code(codigo)
```

## Resumo dos Métodos do `morph.py` (Cap. 7)

A biblioteca `morph.py` disponibiliza duas versões para a maioria dos algoritmos: uma **didática** (métodos terminados em 0), implementada passo a passo em NumPy, e outra **clássica**, baseada nas bibliotecas `scikit-learn` e `scikit-image`. As implementações didáticas são utilizadas nos **Exercícios de Programação (EPs)**, pois não dependem de bibliotecas externas e executam dentro do limite de memória do ambiente **VPL** do Moodle. Já as versões clássicas são mais eficientes e indicadas para experimentos em ambientes como Colab e Jupyter Notebook, mas normalmente **não podem ser utilizadas nos EPs** do Moodle, pois a biblioteca `scikit-learn` excede a memória disponível no VPL.

1. **Leitura dos dados (`readClasses`, `readDataset`, `readTrain`, `readTest`)**  
Padronizam a entrada dos conjuntos de treinamento e teste, retornando as matrizes de características ( $X$ ) e os vetores de rótulos ( $y$ ).
2. **Classificação (`knn0` / `knn`)**  
Implementam o algoritmo dos **k-vizinhos mais próximos (k-NN)** para classificação binária e multiclasse, utilizando distância Euclidiana ou Manhattan.
3. **Normalização (`zscore0` / `zscore`)**  
Aplicam a normalização *z-score* aos atributos, reduzindo diferenças de escala antes da classificação.
4. **Avaliação (`confusion0` / `confusion`)**  
Calculam a matriz de confusão e métricas como acurácia, precisão e revocação, tanto para problemas binários quanto multiclasse.
5. **Descritor de textura (`lbp0` / `lbp`)**  
Calculam o **Local Binary Pattern (LBP)**, permitindo obter o mapa LBP, o código de um pixel ou o histograma de uma região da imagem.
6. **Descritor de forma (`hog0` / `hog`)**  
Calculam o **Histogram of Oriented Gradients (HOG)**, produzindo histogramas das orientações dos gradientes para representar informações de forma e contorno.

### 7.18.1 EP07\_01 ● Classificador k-NN Passo a Passo

O `KNeighborsClassifier` do `scikit-learn`, usado ao longo do capítulo, esconde por trás de uma única chamada (`.fit` / `.predict`) uma regra de decisão bastante simples: para cada nova observação, calcular a distância a todos os exemplos de treinamento, selecionar os  $k$  mais próximos e votar pela classe majoritária entre eles.

Antes de confiar na biblioteca, você foi encarregado de implementar essa regra do zero, para um espaço de características bidimensional, exatamente como o simulador interativo de fronteira de decisão do capítulo faz internamente a cada clique do usuário.

#### 7.18.1.1 📋 Diretrizes de Implementação

1. **Quantidade e parâmetro:** Ler o inteiro  $N$  (número de exemplos de treinamento) e o inteiro ímpar  $k$  (número de vizinhos).
2. **Exemplos de treinamento:** Para cada um dos  $N$  exemplos, ler três valores: as coordenadas  $x$  e  $y$  (reais) e o rótulo  $r$  (inteiro, 0 ou 1).
3. **Consultas:** Ler o inteiro  $Q$  (número de pontos de consulta) e, em seguida, as coordenadas  $x_q$ ,  $y_q$  (reais) de cada consulta.
4. **Distância:** Para cada consulta, calcular a distância euclidiana até **todos** os exemplos de treinamento:

$$d(x_q, x_i) = \sqrt{(x_q - x_i)^2 + (y_q - y_i)^2}.$$

5. **Seleção dos vizinhos:** Ordenar os exemplos por distância crescente e selecionar os  $k$  primeiros. Em caso de **empate de distância** na fronteira do  $k$ -ésimo vizinho, desempate pelo exemplo lido **primeiro** na entrada (ordem de leitura estável).

6. **Votação majoritária:** Contar os votos de cada classe entre os  $k$  vizinhos selecionados. Se houver **empate na votação** (apenas possível quando  $k$  é par, o que não deve ocorrer pela diretriz do item 1, mas trate defensivamente), atribua a classe do vizinho mais próximo entre as classes empatadas.
7. **Saída:** Para cada consulta, na ordem de entrada, imprimir a classe prevista. Ao final, imprimir o total de consultas classificadas como classe 1.

#### 7.18.1.2 Restrições Computacionais

- **Métrica fixa:** utilize exclusivamente a distância euclidiana (não a *squared distance*) para a ordenação, embora o resultado da comparação seja o mesmo.
- **k sempre ímpar:** a entrada garante  $k$  ímpar e  $k \leq N$ ; ainda assim, implemente o desempate do item 6 por robustez.
- **Estabilidade:** ao ordenar por distância, preserve a ordem relativa de exemplos com a mesma distância (ordenação estável).

#### 7.18.1.3 Fundamentação Teórica

| Elemento                  | Papel no k-NN                                                    |
|---------------------------|------------------------------------------------------------------|
| Espaço de características | Conjunto de todos os vetores $(x, y)$ possíveis                  |
| Distância euclidiana      | Medida de similaridade entre observações                         |
| $k$ pequeno               | Fronteira irregular, alta variância                              |
| $k$ grande                | Fronteira suave, alto viés                                       |
| Votação majoritária       | Regra de decisão $\hat{y} = \text{moda}\{y_i : x_i \in N_k(x)\}$ |

#### 7.18.1.4 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: Inteiros  $N$  e  $k$ , separados por espaço.
- Próximas  $N$  linhas: três valores por linha —  $x$ ,  $y$  (reais) e  $r$  (inteiro  $\in \{0, 1\}$ ), separados por espaço.
- Próxima linha: inteiro  $Q$ .
- Próximas  $Q$  linhas: dois valores por linha —  $x_q$ ,  $y_q$  (reais), separados por espaço.

##### Saída:

- $Q$  linhas, cada uma com a classe prevista (0 ou 1) para a respectiva consulta, na ordem de entrada.
- Última linha: **Total classe 1: X.**

#### 7.18.1.5 Exemplos

| Entrada | Saída             | Observação                                   |
|---------|-------------------|----------------------------------------------|
| 4 3     | 0                 | Consulta próxima do agrupamento de classe 0. |
| 0 0 0   | Total classe 1: 0 |                                              |
| 1 0 0   |                   |                                              |
| 5 5 1   |                   |                                              |
| 6 5 1   |                   |                                              |
| 1       |                   |                                              |
| 1 1     |                   |                                              |

| Entrada | Saída             | Observação                                                          |
|---------|-------------------|---------------------------------------------------------------------|
| 4 1     | 0                 | Com $k = 1$ , cada consulta herda a classe do vizinho mais próximo. |
| 0 0 0   | 1                 |                                                                     |
| 1 0 0   | Total classe 1: 1 |                                                                     |
| 5 5 1   |                   |                                                                     |
| 6 5 1   |                   |                                                                     |
| 2       |                   |                                                                     |
| 0.9 0.1 |                   |                                                                     |
| 5.5 5.1 |                   |                                                                     |



Figura 7.21: Simulador: Classificador k-NN Passo a Passo

```
%%writefile EP07_01.py
# Código Python
```

```
Writing EP07_01.py
```

```
TestSuite("EP07_01.py").run()
```

### 7.18.2 EP07\_02 ● Normalização *Z-score* e Robustez do k-NN a Escalas Distintas

Este exercício revisita o classificador implementado no **EP07\_01**, desta vez sob a ótica discutida na seção *O Impacto da Escala e a Normalização de Características* do capítulo: o k-NN decide com base na distância entre vetores, de modo que uma característica medida em uma escala muito maior do que as demais tende a **dominar** o cálculo da distância, mesmo quando ela não é a mais relevante para separar as classes.

Um sistema de inspeção registra, para cada peça, sua **área** (em pixels, podendo chegar a centenas ou milhares) e sua **circularidade** (sempre entre 0 e 1). Você foi encarregado de classificar novas peças por k-NN de duas formas — com e sem a padronização *Z-score* apresentada no capítulo — e de reportar em quais casos as duas abordagens **divergem**.

#### 7.18.2.1 📄 Diretrizes de Implementação

1. **Quantidade e parâmetro:** Ler o inteiro  $N$  (número de exemplos de treinamento) e o inteiro ímpar  $k$ .



2. **Exemplos de treinamento:** Para cada um dos  $N$  exemplos, ler três valores: a área  $x_1$  (real), a circularidade  $x_2$  (real) e o rótulo  $r$  (inteiro, 0 ou 1).
3. **Consultas:** Ler o inteiro  $Q$  e, em seguida, as coordenadas  $x_1, x_2$  de cada consulta.
4. **Classificação sem normalização:** Para cada consulta, classifique-a por k-NN diretamente sobre  $(x_1, x_2)$ , com distância euclidiana e as mesmas regras de desempate do EP07\_01 (ordem de leitura para distâncias empatadas; vizinho mais próximo entre classes empatadas na votação).
5. **Parâmetros de normalização:** Calcule a média  $\mu_j$  e o desvio-padrão **populacional**  $\sigma_j$  (divisão por  $N$ , não por  $N - 1$  — a mesma convenção adotada pela classe `StandardScaler`) de cada característica  $j \in \{1, 2\}$ , **exclusivamente sobre o conjunto de treinamento**.
6. **Padronização:** Transforme cada característica de treinamento e de consulta por

$$z_j = \frac{x_j - \mu_j}{\sigma_j}.$$

Se  $\sigma_j = 0$  (característica constante no treinamento), defina  $z_j = 0$  para todas as amostras dessa característica, evitando a divisão por zero.

7. **Classificação com normalização:** Repita a classificação k-NN do item 4, agora sobre os vetores padronizados  $(z_1, z_2)$ , com as mesmas regras de desempate.
8. **Saída:** Para cada consulta, na ordem de entrada, imprimir as classes previstas. Ao final, imprimir o número de consultas em que as duas classificações **divergem**.

### 7.18.2.2 Restrições Computacionais

- **Ajuste apenas no treino:**  $\mu_j$  e  $\sigma_j$  são calculados unicamente a partir do conjunto de treinamento e reaplicados às consultas — nunca recalculados a partir delas. Essa prática evita o **vazamento de dados** (*data leakage*), mencionado na seção de normalização do capítulo.
- **Desvio-padrão populacional:** utilize  $\sigma_j = \sqrt{\frac{1}{N} \sum_i (x_{i,j} - \mu_j)^2}$ , e não a versão amostral (divisão por  $N - 1$ ).
- **Característica constante:** trate  $\sigma_j = 0$  como caso especial (item 6); não deve ocorrer erro de divisão por zero.
- **Regras de desempate:** reutilize exatamente as convenções do EP07\_01, tanto na seleção dos  $k$  vizinhos quanto na votação majoritária.

### 7.18.2.3 Fundamentação Teórica

| Elemento                               | Papel                                                                                                                            |
|----------------------------------------|----------------------------------------------------------------------------------------------------------------------------------|
| Padronização <i>Z-score</i>            | Reescala cada característica para média 0 e desvio-padrão 1, tornando escalas heterogêneas comparáveis                           |
| Ajuste ( <i>fit</i> ) apenas no treino | Garante que a avaliação sobre as consultas reflita apenas o que o modelo aprendeu no treinamento                                 |
| Distância euclidiana sem normalização  | Dominada pela característica de maior amplitude — aqui, a área                                                                   |
| Predição divergente                    | Evidencia que a escala das características, e não apenas o algoritmo ou os dados, pode determinar a fronteira de decisão do k-NN |

Este exercício reforça, de forma controlada, a razão pela qual o `StandardScaler` é aplicado antes do k-NN ao longo do capítulo: sem essa etapa, características de circularidade — mesmo sendo altamente discriminativas — podem ser praticamente ignoradas pelo classificador diante de uma característica de área com amplitude centenas de vezes maior.



### 7.18.2.4 Especificação de Entrada e Saída (VPL)

#### Entrada:

- Linha 1: Inteiros  $N$  e  $k$ , separados por espaço.
- Próximas  $N$  linhas: três valores por linha —  $x_1$ ,  $x_2$  (reais) e  $r$  (inteiro  $\in \{0, 1\}$ ), separados por espaço.
- Próxima linha: inteiro  $Q$ .
- Próximas  $Q$  linhas: dois valores por linha —  $x_1$ ,  $x_2$  (reais) da consulta, separados por espaço.

#### Saída:

- $Q$  linhas, no formato `SemNorm=<0|1> ComNorm=<0|1>`, na ordem de entrada das consultas.
- Última linha: `Divergiu: <int>`.

### 7.18.2.5 Exemplos

| Entrada                                                                  | Saída                              | Observação                                                                                                                                                                                                                                                    |
|--------------------------------------------------------------------------|------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 4 3<br>10 0.9 0<br>12 0.85 0<br>900 0.2 1<br>950 0.25 1<br>1<br>500 0.88 | SemNorm=1 ComNorm=0<br>Divergiu: 1 | Sem normalização, a área (escala de centenas) domina a distância e a consulta é classificada como classe 1. Após a padronização, a circularidade — muito mais próxima das amostras de classe 0 — passa a pesar de forma comparável, e a predição muda para 0. |
| 2 1<br>0 0.5 0<br>100 0.5 1<br>1<br>60 0.5                               | SemNorm=1 ComNorm=1<br>Divergiu: 0 | A circularidade é constante no treinamento ( $\sigma_2 = 0$ ); pela regra do item 6, $z_2 = 0$ para todas as amostras, e a classificação depende apenas da área em ambos os casos.                                                                            |

Simulador: Normalização Z-score e Distância k-NN

padronização de características

Cada exemplo tem duas características — área (pixels) e circularidade (0 a 1). Alterne entre distância bruta e padronizada (Z-score) para a mesma consulta (★) e observe se a classe prevista muda.

★ consulta: área=500, circularidade=0.88

Sem normalização

Com normalização (Z-score)

**P3 (r=1)**  
 área=900, circ=0.2  
 d=400.001  
**VOTA**

**P4 (r=1)**  
 área=950, circ=0.25  
 d=450.000  
**VOTA**

**P2 (r=0)**  
 área=12, circ=0.85  
 d=488.000  
**VOTA**

**P1 (r=0)**  
 área=10, circ=0.9  
 d=490.000  
**VOTA**

SEM normalização | k=3 | votos classe0=1, classe1=2 | classe prevista=1

Figura 7.22: Simulador: Efeito da Normalização Z-score na Distância k-NN

```
%%writefile EP07_02.py
# Código Python
```

```
Writing EP07_02.py
```

```
TestSuite("EP07_02.py").run()
```

### 7.18.3 EP07\_03 ● Avaliação por Matriz de Confusão

Um classificador binário de qualidade de solda foi treinado e testado em uma linha de produção. Para cada peça inspecionada, o sistema registrou o rótulo **real** (obtido por um especialista) e o rótulo **previsto** pelo classificador, em que 1 representa “defeituosa” e 0 representa “conforme”.

A gerência de qualidade quer saber não apenas a acurácia do sistema, mas também sua **precisão** (quando o sistema aponta defeito, com que frequência ele está certo?) e sua **revocação** (de todas as peças realmente defeituosas, quantas o sistema conseguiu identificar?) — a distinção discutida na seção de avaliação de classificadores do capítulo.

#### 7.18.3.1 📋 Diretrizes de Implementação

1. **Quantidade:** Ler o inteiro  $N$  (número de peças inspecionadas).
2. **Dados de cada peça:** Para cada uma das  $N$  peças, ler dois inteiros — o rótulo real  $y$  e o rótulo previsto  $\hat{y}$  (ambos  $\in \{0, 1\}$ ).
3. **Matriz de confusão:** Considerando a classe 1 (defeituosa) como **positiva**, contar:
  - $VP$  (Verdadeiro Positivo):  $y = 1$  e  $\hat{y} = 1$ ;
  - $FP$  (Falso Positivo):  $y = 0$  e  $\hat{y} = 1$ ;
  - $FN$  (Falso Negativo):  $y = 1$  e  $\hat{y} = 0$ ;
  - $VN$  (Verdadeiro Negativo):  $y = 0$  e  $\hat{y} = 0$ .
4. **Métricas:** Calcular

$$\text{Acurácia} = \frac{VP + VN}{N}, \quad \text{Precisão} = \frac{VP}{VP + FP}, \quad \text{Revocação} = \frac{VP}{VP + FN}.$$

5. **Casos degenerados:** Se  $VP + FP = 0$  (nenhuma predição positiva), imprima `Precisao: indefinida`. Se  $VP + FN = 0$  (nenhum caso positivo real), imprima `Revocacao: indefinida`.
6. **Arredondamento:** Todas as métricas numéricas devem ser arredondadas para 4 casas decimais (*round half away from zero*) apenas na exibição.

#### 7.18.3.2 🚫 Restrições Computacionais

- **Convenção de classe positiva fixa:** a classe 1 é sempre a classe positiva neste exercício, independentemente de sua frequência relativa.
- **Proteção de divisão por zero:** implemente os casos degenerados do item 5 antes de realizar a divisão.
- **Ordem de saída:** siga exatamente a ordem especificada na seção de saída, mesmo nos casos degenerados.

#### 7.18.3.3 🧠 Fundamentação Teórica

| Métrica   | Pergunta que responde                                        | Sensível a desbalanceamento?                    |
|-----------|--------------------------------------------------------------|-------------------------------------------------|
| Acurácia  | Qual fração das peças foi classificada corretamente?         | Sim — pode mascarar erros na classe minoritária |
| Precisão  | Das peças apontadas como defeituosas, quantas realmente são? | Penaliza falsos positivos                       |
| Revocação | Das peças realmente defeituosas, quantas foram detectadas?   | Penaliza falsos negativos                       |

Em um contexto industrial, uma **revocação** baixa é frequentemente mais grave do que uma **precisão** baixa: deixar passar uma peça defeituosa (falso negativo) tende a ser mais custoso do que inspecionar manualmente uma peça boa apontada por engano (falso positivo).

#### 7.18.3.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $N$ .
- Próximas  $N$  linhas: dois inteiros por linha —  $y$  e  $\hat{y}$ , separados por espaço.

**Saída (nesta ordem exata):**

```
VP=<int> FP=<int> FN=<int> VN=<int>
Acuracia: <valor ou métrica indefinida>
Precisao: <valor ou indefinida>
Revocacao: <valor ou indefinida>
```

#### 7.18.3.5 Exemplos

| Entrada                       | Saída                                                                                    | Observação                              |
|-------------------------------|------------------------------------------------------------------------------------------|-----------------------------------------|
| 4<br>1 1<br>0 1<br>1 0<br>0 0 | VP=1 FP=1 FN=1 VN=1<br>Acuracia: 0.5000<br>Precisao: 0.5000<br>Revocacao: 0.5000         | Um erro de cada tipo.                   |
| 3<br>0 0<br>0 0<br>0 0        | VP=0 FP=0 FN=0 VN=3<br>Acuracia: 1.0000<br>Precisao: indefinida<br>Revocacao: indefinida | Nenhum caso positivo real nem previsto. |

 Simulador: Precisão x Revocação
 

 linha de produção

Escolha um cenário de inspeção e observe como acurácia, precisão e revocação reagem de forma diferente.

Cenário A: erros equilibrados

Cenário B: muitos falsos negativos

Cenário C: nenhum defeito real

Cenário D: muitos falsos positivos

Peça 1

real=1, prev=1

Peça 2

real=0, prev=1

Peça 3

real=1, prev=0

Peça 4

real=0, prev=0

VP=1 FP=1 FN=1 VN=1 | Acuracia=0.5000 Precisao=0.5000 Revocacao=0.5000

Figura 7.23: Simulador: Precisão x Revocação

```
%%writefile EP07_03.py
# Código Python
```

```
Writing EP07_03.py
```

```
TestSuite("EP07_03.py").run()
```

### 7.18.4 EP07\_04 ● Codificação Manual do Descritor LBP

A função `local_binary_pattern` do `scikit-image`, utilizada no projeto de classificação de texturas, calcula automaticamente o código LBP de cada pixel de uma imagem. Antes de utilizá-la como uma caixa-preta, você foi encarregado de implementar manualmente o cálculo do código LBP clássico ( $P = 8$ ,  $R = 1$ ) para o pixel central de uma vizinhança  $3 \times 3$ , exatamente como definido na equação do capítulo.

Além do código, o sistema de inspeção de texturas também precisa saber se aquele padrão é **uniforme** — um padrão é uniforme quando o número de transições ( $0 \rightarrow 1$  ou  $1 \rightarrow 0$ ) ao percorrer os 8 bits **circularmente** (voltando do último bit ao primeiro) é **no máximo 2**, propriedade explorada pela variante *uniforme* do LBP mencionada no capítulo.

#### 7.18.4.1 📋 Diretrizes de Implementação

1. **Quantidade:** Ler o inteiro  $T$  (número de vizinhanças a processar).
2. **Dados de cada vizinhança:** Para cada uma das  $T$  vizinhanças, ler uma matriz  $3 \times 3$  de inteiros (intensidades), fornecida em 3 linhas de 3 valores cada. O pixel central é a posição `[1][1]`.
3. **Ordem dos vizinhos:** Percorra os 8 vizinhos em sentido **horário**, iniciando no canto superior esquerdo, na seguinte ordem de posições `[linha][coluna]`: `[0][0]`, `[0][1]`, `[0][2]`, `[1][2]`, `[2][2]`, `[2][1]`, `[2][0]`, `[1][0]`. Esse é o índice  $p = 0, 1, \dots, 7$  da equação do LBP.
4. **Função limiar:** Para cada vizinho  $p$  com intensidade  $g_p$  e centro  $g_c$ , calcule  $s(g_p - g_c)$ , que vale 1 se  $g_p \geq g_c$  e 0 caso contrário.
5. **Código LBP:** Calcule

$$\text{LBP} = \sum_{p=0}^7 s(g_p - g_c) 2^p.$$

6. **Transições:** Considerando a sequência circular de bits  $s_0, s_1, \dots, s_7$  (na ordem do item 3), conte quantos pares consecutivos **adjacentes na sequência circular** (incluindo o par  $s_7, s_0$ ) diferem entre si.
7. **Classificação:** Se o número de transições for  $\leq 2$ , classifique como **UNIFORME**; caso contrário, **NAO\_UNIFORME**.
8. **Saída:** Para cada vizinhança, na ordem de entrada, imprimir o código LBP (inteiro decimal, 0–255), o número de transições e a classificação.

#### 7.18.4.2 📌 Restrições Computacionais

- **Ordem fixa dos vizinhos:** a ordem do item 3 é obrigatória — invertê-la produz um código numericamente diferente, mesmo representando o mesmo padrão visual.
- **Comparação não estrita:**  $s(z) = 1$  quando  $z \geq 0$  (o próprio capítulo define a igualdade como incluída no caso 1).
- **Contagem circular:** não esqueça o par que fecha o ciclo ( $s_7$  com  $s_0$ ); ignorar esse par é um erro comum que classifica incorretamente padrões uniformes.

#### 7.18.4.3 🧠 Fundamentação Teórica

| Padrão (bits $s_0 \dots s_7$ ) | Transições | Interpretação                                 |
|--------------------------------|------------|-----------------------------------------------|
| 00000000 ou 11111111           | 0          | Região homogênea (mancha clara ou escura)     |
| 00001111                       | 2          | Borda simples entre duas regiões              |
| 01010101                       | 8          | Textura de contraste alternado — não uniforme |

Padrões uniformes concentram-se em regiões de textura suave ou bordas simples; padrões não uniformes tendem a corresponder a ruído de alta frequência. Por isso, o histograma LBP *uniforme*, usado no projeto de

classificação de texturas, agrupa todos os padrões não uniformes em um único compartimento, reduzindo a dimensionalidade do descritor.

7.18.4.4  Especificação de Entrada e Saída (VPL)

Entrada:

- Linha 1: Inteiro  $T$ .
- Para cada vizinhança: 3 linhas com 3 inteiros cada (matriz  $3 \times 3$ ).

Saída:

- $T$  linhas, no formato `LBP=<int> transicoes=<int> <UNIFORME|NAO_UNIFORME>`.

7.18.4.5  Exemplos

| Entrada                               | Saída                                | Observação                                            |
|---------------------------------------|--------------------------------------|-------------------------------------------------------|
| 1<br>10 10 10<br>10 50 10<br>10 10 10 | LBP=0 transicoes=0 UNIFORME          | Centro é o mais claro; todos os vizinhos geram bit 0. |
| 1<br>90 90 90<br>10 50 10<br>90 90 90 | LBP=119 transicoes=4<br>NAO_UNIFORME | Vizinhos claros e escuros alternados na vizinhança.   |

Simulador: Código LBP de uma Vizinhança 3x3

P=8, R=1

Clique em uma célula da vizinhança para alternar entre claro e escuro (o centro, em destaque, é fixo) e observe o código LBP resultante. O rótulo pequeno em cada célula é o índice  $p$  da equação.

Exemplo 1: mancha homogênea

Exemplo 2: padrão alternado

p090

p190

p290

p710

50

p310

p690

p590

p490

bits(p0..p7)=11101110 | LBP=119 | transições=4 | NAO\_UNIFORME

Figura 7.24: Simulador: Codigo LBP

```
%%writefile EP07_04.py
# Código Python

Writing EP07_04.py

TestSuite("EP07_04.py").run()
```

### 7.18.5 EP07\_05 Histograma de Orientações de uma Célula HOG

A função `hog` do `scikit-image`, empregada no projeto de classificação de dígitos, divide a imagem em pequenas **células** e, para cada uma, constrói um histograma das orientações do gradiente ponderado pela magnitude — exatamente a etapa central descrita na seção sobre o descritor HOG do capítulo.

Você foi encarregado de implementar esse cálculo para uma única célula, a partir dos valores de magnitude e orientação do gradiente **já calculados** para cada pixel da célula (dispensando o cálculo das derivadas parciais).

#### 7.18.5.1 Diretrizes de Implementação

1. **Dimensões:** Ler os inteiros  $n$  (a célula tem  $n \times n$  pixels) e  $B$  (número de compartimentos do histograma).
2. **Magnitudes:** Ler  $n$  linhas com  $n$  valores reais cada, representando  $|\nabla f(x, y)|$  para cada pixel da célula.
3. **Orientações:** Ler mais  $n$  linhas com  $n$  valores reais cada, representando  $\theta(x, y)$  em **graus**, já convertido para o intervalo **não sinalizado**  $[0^\circ, 180^\circ)$ , como convencionalmente utilizado pelo HOG.
4. **Compartimentos:** Os  $B$  compartimentos cobrem  $[0^\circ, 180^\circ)$  em faixas iguais de largura  $180/B$  graus. Um pixel com orientação  $\theta$  pertence ao compartimento  $\lfloor \theta / (180/B) \rfloor$ ; se esse índice for igual a  $B$  (possível apenas quando  $\theta$  é exatamente  $180^\circ$ , o que não deve ocorrer pela diretriz do item 3), utilize o compartimento  $B - 1$ .
5. **Histograma bruto:** Para cada pixel, acumule sua **magnitude** (não sua contagem) no compartimento correspondente:

$$H[b] = \sum_{(x,y) : \text{bin}(\theta(x,y))=b} |\nabla f(x, y)|.$$

6. **Normalização L2:** Após construir  $H$ , normalize-o para obter  $\hat{H}$ :

$$\hat{H}[b] = \frac{H[b]}{\sqrt{\sum_{j=0}^{B-1} H[j]^2 + \epsilon}}, \quad \epsilon = 10^{-6}.$$

7. **Saída:** Imprimir o histograma bruto  $H$  (arredondado a 2 casas decimais) em uma linha, seguido do histograma normalizado  $\hat{H}$  (arredondado a 4 casas decimais) em outra linha, ambos com os  $B$  valores separados por espaço, na ordem dos compartimentos.

#### 7.18.5.2 Restrições Computacionais

- **Binning não sinalizado:** o intervalo de orientações é  $[0, 180)$ , não  $[0, 360)$  — gradientes em direções opostas (diferença de  $180^\circ$ ) contribuem para o **mesmo** compartimento, convenção padrão do HOG para detecção de objetos.
- **Acumulação por magnitude, não por contagem:** o histograma pondera cada pixel por sua magnitude de gradiente, não simplesmente conta quantos pixels caem em cada compartimento.
- **Constante de estabilização:** o  $\epsilon = 10^{-6}$  no denominador da normalização evita divisão por zero quando a célula é completamente homogênea (todas as magnitudes nulas).

#### 7.18.5.3 De onde vêm as matrizes de entrada

Antes deste EP, cada pixel  $(x, y)$  da imagem passa por:

$$G_x = f(x+1, y) - f(x-1, y), \quad G_y = f(x, y+1) - f(x, y-1)$$

$$|\nabla f| = \sqrt{G_x^2 + G_y^2}, \quad \theta_{\text{sinal}} = \text{atan2}(G_y, G_x)$$

Como o HOG ignora a polaridade do contraste, o ângulo é dobrado para o intervalo não sinalizado:

$$\theta = \theta_{\text{sinal}} \bmod 180^\circ$$

Repetindo isso para todos os pixels de uma célula  $n \times n$ , obtêm-se as duas matrizes de entrada deste exercício: **magnitudes**  $|\nabla f|$  e **orientações**  $\theta \in [0^\circ, 180^\circ)$ .

#### 7.18.5.4 Fundamentação Teórica

| Etapa                     | Papel                                                                                  |
|---------------------------|----------------------------------------------------------------------------------------|
| Magnitude do gradiente    | Pondera a contribuição de cada pixel — bordas fortes pesam mais que ruído fraco        |
| Orientação não sinalizada | Torna o descritor invariante à polaridade do contraste (claro→escuro vs. escuro→claro) |
| Histograma por célula     | Resume a distribuição local de bordas em um vetor compacto                             |
| Normalização L2           | Reduz a sensibilidade do descritor a variações globais de iluminação e contraste       |

A concatenação dos histogramas normalizados de todas as células da imagem — não implementada neste exercício — forma o vetor de características HOG completo, utilizado como entrada do classificador k-NN no projeto do capítulo.

#### 7.18.5.5 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: Inteiros  $n$  e  $B$ .
- Próximas  $n$  linhas:  $n$  magnitudes reais cada.
- Próximas  $n$  linhas:  $n$  orientações reais (graus,  $[0, 180)$ ) cada.

##### Saída:

- Linha 1: os  $B$  valores do histograma bruto, arredondados a 2 casas decimais.
- Linha 2: os  $B$  valores do histograma normalizado, arredondados a 4 casas decimais.

#### 7.18.5.6 Exemplos

| Entrada                                       | Saída                                              | Observação                                                                                            |
|-----------------------------------------------|----------------------------------------------------|-------------------------------------------------------------------------------------------------------|
| 2 2<br>1.0 2.0<br>3.0 4.0<br>10 100<br>170 20 | 5.00 5.00<br>0.7071 0.7071                         | Bin de largura $90^\circ$ : $[0, 90)$ e $[90, 180)$ ; magnitudes 1 e 4 caem no bin 0, 2 e 3 no bin 1. |
| 2 4<br>0.0 0.0<br>0.0 0.0<br>0 0<br>0 0       | 0.00 0.00 0.00 0.00<br>0.0000 0.0000 0.0000 0.0000 |                                                                                                       |
|                                               |                                                    | Célula homogênea: $\epsilon$ evita divisão por zero.                                                  |

```
%%writefile EP07_05.py
# Código Python
```

Writing EP07\_05.py





Figura 7.25: Simulador Didático: Histograma HOG de uma Celula (mapeamento de ângulos para bins)

```
TestSuite("EP07_05.py").run()
```

### 7.18.6 EP07\_06 Pipeline Completo: Descritores + k-NN + Avaliação Multi-Classe

Este exercício integra as três etapas centrais do capítulo em um único *pipeline*, reproduzindo em miniatura o **Projeto Prático 2** (classificação de texturas sintéticas por LBP): um conjunto de histogramas de descritores **já extraídos** (como se fossem histogramas LBP) é utilizado para treinar um classificador k-NN, que por sua vez é avaliado sobre um conjunto de teste independente por meio de uma matriz de confusão multi-classe.

Diferentemente do EP07\_01, aqui o espaço de características tem dimensão arbitrária  $H$  (o tamanho do histograma), existem mais de duas classes, e a métrica de distância é um parâmetro de entrada — permitindo reproduzir o experimento de comparação de métricas discutido no capítulo.

#### 7.18.6.1 Diretrizes de Implementação

1. **Classes:** Ler o inteiro  $C$  (número de classes) seguido de  $C$  nomes de classe (*strings* sem espaço), na ordem em que devem aparecer na matriz de confusão.
2. **Configuração:** Ler o inteiro  $H$  (dimensão dos histogramas), a *string*  $M$  (métrica: **euclidiana** ou **manhattan**) e o inteiro ímpar  $k$ .
3. **Treinamento:** Ler o inteiro  $N$  e, em seguida,  $N$  linhas, cada uma contendo o nome da classe seguido de  $H$  valores reais (o histograma de descritor).
4. **Teste:** Ler o inteiro  $Q$  e, em seguida,  $Q$  linhas, cada uma contendo o nome da classe **real** seguido de  $H$  valores reais (o histograma de descritor da amostra de teste).
5. **Distância:** Para cada amostra de teste, calcule a distância a cada exemplo de treinamento usando a métrica  $M$ :

$$d_{\text{euclidiana}}(u, v) = \sqrt{\sum_{j=1}^H (u_j - v_j)^2}, \quad d_{\text{manhattan}}(u, v) = \sum_{j=1}^H |u_j - v_j|.$$

6. **Classificação k-NN:** Selecione os  $k$  exemplos de treinamento mais próximos (desempate de distância pela ordem de leitura, como no EP07\_01) e classifique pela classe majoritária entre eles. Em caso de **empate de votação** entre duas ou mais classes, escolha a que aparece **primeiro** na lista de classes do item 1.
7. **Matriz de confusão:** Construa uma matriz  $C \times C$  em que a linha corresponde à classe real e a coluna à classe prevista, seguindo a ordem de classes do item 1.
8. **Acurácia:** Calcule a acurácia global como a razão entre acertos e  $Q$ .
9. **Saída:** Para cada amostra de teste, na ordem de entrada, imprimir a classe prevista. Em seguida, imprimir a matriz de confusão (uma linha por classe real, valores separados por espaço, na ordem das classes). Por fim, imprimir a acurácia arredondada a 4 casas decimais.

#### 7.18.6.2 Restrições Computacionais

- **Métrica selecionável:** implemente ambas as distâncias; a métrica  $M$  define qual é utilizada em toda a execução (não é possível misturar métricas na mesma chamada).
- **Desempate de votação determinístico:** o critério do item 6 (ordem da lista de classes) deve ser seguido mesmo quando o empate envolve mais de duas classes.
- **Independência de treino e teste:** não há necessidade de validar que as amostras de teste não aparecem no treino — assuma que a entrada é válida.

#### 7.18.6.3 Fundamentação Teórica

| Etapas do exercício                      | Etapas correspondentes no capítulo                                 |
|------------------------------------------|--------------------------------------------------------------------|
| Histogramas de treino/teste já extraídos | <code>descriptor_lbp</code> aplicado às texturas sintéticas        |
| Distância euclidiana ou Manhattan        | Parâmetro <code>metric</code> do <code>KNeighborsClassifier</code> |

| Etapa do exercício                   | Etapa correspondente no capítulo                           |
|--------------------------------------|------------------------------------------------------------|
| Votação majoritária com $k$ vizinhos | <code>KNeighborsClassifier.predict</code>                  |
| Matriz de confusão $C \times C$      | <code>confusion_matrix</code> do <code>scikit-learn</code> |
| Acurácia global                      | <code>accuracy_score</code> do <code>scikit-learn</code>   |

Este exercício evidencia, de forma controlada, um resultado discutido no capítulo: a **escolha da métrica de distância** e do **valor de  $k$**  pode alterar a classe prevista para uma mesma amostra, mesmo mantendo fixo o descritor utilizado — reforçando que, no reconhecimento de padrões clássico, o descritor, a métrica e o classificador formam um sistema interdependente, e não peças isoladas.

#### 7.18.6.4 📦 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: inteiro  $C$  seguido de  $C$  nomes de classe.
- Linha 2: inteiro  $H$ , *string*  $M$  e inteiro  $k$ .
- Linha 3: inteiro  $N$ .
- Próximas  $N$  linhas de treinamento: nome da classe seguido de  $H$  reais.
- Próxima linha: inteiro  $Q$ .
- Próximas  $Q$  linhas de teste: nome da classe real seguido de  $H$  reais.

##### Saída:

- $Q$  linhas com a classe prevista de cada amostra de teste, na ordem de entrada.
- $C$  linhas com a matriz de confusão (uma linha por classe real).
- Última linha: **Acuracia:** <valor>.

#### 7.18.6.5 📌 Exemplos

| Entrada (resumida)  | Saída            | Observação                                                                   |
|---------------------|------------------|------------------------------------------------------------------------------|
| 2 granular listrada | granular         | Com $k = 1$ , cada teste é classificado pelo vizinho de treino mais próximo. |
| 2 euclidiana 1      | listrada         |                                                                              |
| 4                   | 1 0              |                                                                              |
| granular 0.9 0.1    | 0 1              |                                                                              |
| granular 0.8 0.2    | Acuracia: 1.0000 |                                                                              |
| listrada 0.1 0.9    |                  |                                                                              |
| listrada 0.2 0.8    |                  |                                                                              |
| 2                   |                  |                                                                              |
| granular 0.85 0.15  |                  |                                                                              |
| listrada 0.15 0.85  |                  |                                                                              |

##### **i** Note

Este simulador usa um conjunto simplificado de **3 classes** (**granular**, **listrada**, **manchada**) sobre pontos 2D fictícios, apenas para ilustrar o *pipeline* de votação, desempate e matriz de confusão do k-NN. No **EP07\_07**, você aplicará essa mesma lógica a um mosaico de imagem real, que introduz uma quarta classe (**xadrez**) e substitui os pontos 2D por histogramas LBP extraídos diretamente dos pixels da imagem.

```
%%writefile EP07_06.py
# Código Python
```

Overwriting EP07\_06.py




Figura 7.26: Simulador: Pipeline k-NN Multi-Classe (votacao, desempate e matriz de confusao)

```
TestSuite("EP07_06.py").run()
```

### 7.18.7 EP07\_07 ● Classificação Real de um Mosaico de Texturas via LBP + k-NN

Nos exercícios anteriores, o descritor LBP (**EP07\_04**) e o classificador k-NN multiclasse (**EP07\_06**) foram estudados separadamente, sempre a partir de dados já fornecidos na entrada — vizinhanças  $3 \times 3$  isoladas ou histogramas previamente extraídos. Neste exercício de encerramento do capítulo, o programa deverá **ler uma imagem real**, no formato **PGM ASCII (P2)**, calcular o descritor LBP diretamente a partir dos pixels e, em seguida, classificar cada região por meio do k-NN, reproduzindo, em escala reduzida, o fluxo completo de um sistema de reconhecimento de texturas. Essa abordagem também antecipa a ideia de **classificação por mosaico de regiões**, relacionada à segmentação semântica estudada em um capítulo posterior.

O simulador interativo do **EP07\_06** utilizava apenas três classes (**granular**, **listrada** e **manchada**) representadas por pontos bidimensionais fictícios. Neste exercício, acrescenta-se uma quarta classe, **xadrez**, e os pontos são substituídos por histogramas LBP extraídos de uma imagem real.

A imagem de entrada é um **mosaico** formado por uma grade  $G \times G$  de blocos quadrados de  $S \times S$  pixels. Cada bloco contém uma amostra de uma das quatro classes de textura sintética do capítulo: **granular**, **listrada**, **manchada** ou **xadrez** (padrão de tabuleiro com intensidades alternadas). Como nos demais exercícios do livro, o carregamento da imagem é realizado pela função didática `mm.readImg`.

💡 Por que um mosaico único, e não várias imagens?

A entrada reúne as  $G \times G$  amostras de textura em um único arquivo **PGM**, apenas para simplificar a leitura dos dados e evitar a abertura de vários arquivos. Para o algoritmo, isso não altera o processamento: cada bloco é tratado de forma independente, como se fosse uma imagem isolada. A única exceção é a **exclusão da borda** (item 4 a seguir).

#### 7.18.7.1 📋 Diretrizes de Implementação

##### 1. Leitura das dimensões da imagem

Ler, por meio da entrada padrão, duas linhas contendo, respectivamente, o número de linhas  $L$  e o número de colunas  $C$  do mosaico (ambos múltiplos do tamanho de bloco  $S$ , com  $L = C$ ).

##### 2. Carregamento da imagem

Utilizar a função didática

```
f = mm.readImg(L, C)
```

para ler os  $L \times C$  valores de intensidade (tons de cinza, `uint8`) do mosaico.

##### 3. Parâmetros da grade

Ler o inteiro  $G$  (número de blocos por lado) e o inteiro  $S$  (tamanho do lado de cada bloco, em pixels), satisfazendo  $L = C = G \times S$ .

##### 4. Cálculo do código LBP por pixel

Para cada pixel **interior** da imagem (ou seja, que não esteja na borda global de `f` — linha ou coluna 0 ou  $L - 1 / C - 1$ ), calcule o código LBP com  $P = 8$  vizinhos e raio  $R = 1$ , percorrendo os vizinhos em sentido **horário** a partir do canto superior esquerdo, exatamente como no EP07\_04: `[lin-1][col-1]`, `[lin-1][col]`, `[lin-1][col+1]`, `[lin][col+1]`, `[lin+1][col+1]`, `[lin+1][col]`, `[lin+1][col-1]`, `[lin][col-1]`.

Pixels na borda global da imagem **não** possuem vizinhança completa e devem ser **ignorados** (não contribuem para nenhum histograma). Isso inclui pixels de borda que caem no interior de um bloco (a exclusão é sempre em relação à borda da imagem inteira, não à borda de cada bloco).

### 5. Histograma LBP uniforme por bloco (10 compartimentos)

Para cada bloco  $(i, j)$  da grade  $(i, j = 0, \dots, G - 1)$ , acumule, entre seus pixels válidos (item 4), um histograma  $H^{(i,j)}$  de 10 compartimentos:

- Considerando a sequência circular de bits  $s_0, \dots, s_7$  do pixel (mesma regra de transições do EP07\_04): se o número de transições for  $\leq 2$  (padrão **uniforme**), o pixel contribui para o compartimento  $\text{popcount}(s_0, \dots, s_7) \in \{0, \dots, 8\}$  (número de bits iguais a 1);
- Caso contrário (padrão **não uniforme**), o pixel contribui para o compartimento 9.

Ao final, normalize o histograma de cada bloco dividindo pelo número de pixels válidos nele contidos, obtendo  $\hat{H}^{(i,j)}$ , com  $\sum_{b=0}^9 \hat{H}^{(i,j)}[b] = 1$ .

### 6. Protótipos de treinamento

Ler o inteiro  $Ncl$  (número de classes) seguido de  $Ncl$  nomes de classe (ordem que define a matriz de confusão e o desempate de votação, como no EP07\_06); em seguida, ler a *string*  $M$  (métrica: **euclidiana** ou **manhattan**) e o inteiro ímpar  $k$ ; por fim, ler o inteiro  $N$  (número de protótipos) e, para cada um, o nome da classe seguido de 10 valores reais (histograma protótipo já normalizado).

### 7. Classificação k-NN de cada bloco

Para cada bloco, calcule a distância de  $\hat{H}^{(i,j)}$  a cada um dos  $N$  protótipos, usando a métrica  $M$  (mesmas fórmulas do EP07\_06). Selecione os  $k$  protótipos mais próximos (desempate de distância pela ordem de leitura dos protótipos) e classifique pela classe majoritária (desempate de votação pela ordem das classes do item 6).

### 8. Rótulos reais e avaliação

Ler, em uma única linha, os  $G \times G$  nomes de classe **reais** de cada bloco, em ordem de leitura por linha da grade (bloco  $(0, 0)$ ,  $(0, 1)$ , ...,  $(0, G - 1)$ ,  $(1, 0)$ , ...). Construa a matriz de confusão  $Ncl \times Ncl$  (linha = classe real, coluna = classe prevista) e a acurácia global.

### 9. Saída

Imprimir, para cada bloco (na mesma ordem de leitura dos rótulos reais do item 8), a classe prevista. Em seguida, imprimir a matriz de confusão (uma linha por classe real, na ordem do item 6). Por fim, imprimir a acurácia, arredondada a 4 casas decimais.

#### 7.18.7.2 📌 Restrições Computacionais

- **Descritor fixo:**  $P = 8$ ,  $R = 1$  e 10 compartimentos (conforme item 5) são fixos neste exercício — não são lidos da entrada.
- **Exclusão de borda global, não de bloco:** um pixel no limite entre dois blocos, mas no interior da imagem, é válido e contribui normalmente para o histograma do bloco ao qual pertence.
- **Ordem de leitura como critério de desempate:** tanto o desempate de distância (item 7) quanto o de votação (item 7) seguem exatamente as mesmas convenções do EP07\_01 e do EP07\_06.
- **Protótipos como entrada, não aprendidos:** diferentemente do Projeto Prático 2, os histogramas de treinamento são fornecidos diretamente na entrada; o programa não deve gerar texturas sintéticas.

#### 7.18.7.3 🧠 Fundamentação Teórica

| Etapa do exercício                           | Etapa correspondente no capítulo                                    |
|----------------------------------------------|---------------------------------------------------------------------|
| Leitura da imagem via <code>mm.imread</code> | Aquisição da imagem no <i>pipeline</i> de reconhecimento de padrões |

| Etapa do exercício                                    | Etapa correspondente no capítulo                                                                |
|-------------------------------------------------------|-------------------------------------------------------------------------------------------------|
| Código LBP por pixel (EP07_04)                        | <code>local_binary_pattern(imagem, P=8, R=1, method="uniform")</code>                           |
| Histograma de 10 compartimentos por bloco             | Função <code>descritor_lbp</code> do Projeto Prático 2 ( <code>bins=10, range=(0, P+2)</code> ) |
| Classificação k-NN com métrica selecionável (EP07_06) | <code>KNeighborsClassifier</code> treinado sobre <code>X_textura</code>                         |
| Matriz de confusão $N_{cl} \times N_{cl}$ e acurácia  | <code>confusion_matrix</code> e <code>accuracy_score</code> sobre <code>yt_teste</code>         |

Este exercício evidencia, com pixels reais em vez de valores sintéticos, uma limitação discutida na seção final do capítulo: classes de textura visualmente distintas para um observador humano — como **granular** e **manchada** — podem produzir histogramas LBP semelhantes quando a vizinhança considerada é pequena ( $R = 1$ ), pois ambas apresentam alta frequência de padrões não uniformes na escala de um único pixel. Já a classe **xadrez**, por possuir bordas regulares e repetitivas, tende a ser separada com maior facilidade. Espera-se que a matriz de confusão produzida reflita exatamente esse padrão de confusão parcial.

#### 7.18.7.4 Especificação de Entrada e Saída (VPL)

##### Entrada:

```
L
C
[matriz L x C da imagem]
G S
Ncl nome_classe_1 ... nome_classe_Ncl
M k
N
nome_classe h0 h1 ... h9      (repetida N vezes)
rotulo(0,0) rotulo(0,1) ... rotulo(G-1,G-1)
```

##### Saída:

- $G \times G$  linhas com a classe prevista de cada bloco, na ordem de leitura da grade.
- $N_{cl}$  linhas com a matriz de confusão (uma linha por classe real, valores separados por espaço).
- Última linha: **Acuracia:** <valor>.

#### 7.18.7.5 Exemplo (verificação manual)

Para conferir a implementação do descritor antes de testá-la sobre um mosaico completo, considere uma imagem  $6 \times 6$  **homogênea**, com todos os pixels de intensidade 100, tratada como um único bloco ( $G = 1$ ,  $S = 6$ ). Como todo pixel interior tem os 8 vizinhos com intensidade igual à do centro ( $g_p \geq g_c$  em todos os casos), todos os bits  $s_p$  valem 1, o número de transições é 0 (uniforme) e o compartimento é `popcount(11111111) = 8`. O histograma do único bloco é, portanto, 0 0 0 0 0 0 0 0 1 0.



| Entrada (resumida)                    | Saída            | Observação                               |
|---------------------------------------|------------------|------------------------------------------|
| 6                                     | uniforme         | Distância do bloco ao protótipo          |
| 6                                     | 1 0              | <b>uniforme</b> é exatamente 0; a classe |
| [36 valores iguais a 100]             | 0 0              | <b>outra</b> não aparece no rótulo real, |
| 1 6                                   | Acuracia: 1.0000 | por isso sua linha na matriz de          |
| 2 uniforme outra                      |                  | confusão é nula.                         |
| euclidiana 1                          |                  |                                          |
| 2                                     |                  |                                          |
| uniforme 0 0 0 0 0 0 0 1 0            |                  |                                          |
| outra 0.1 0.1 0.1 0.1 0.1 0.1 0.1 0.1 |                  |                                          |
| 0.1 0.1                               |                  |                                          |
| uniforme                              |                  |                                          |

### 7.18.7.6 📁 Arquivos de Referência (.pgm)

Para depuração local, dois mosaicos de teste no padrão ASCII P2 são disponibilizados (anexados a esta entrega; ao integrá-los ao repositório do capítulo, salve-os em `all/cap07/dados/EP07/`):

- 📁 **Caso 1 — Mosaico simples (Caso1\_Mosaico\_Simples.pgm)**: grade  $2 \times 2$  de blocos de  $24 \times 24$  pixels, uma amostra de cada uma das quatro classes, com baixo ruído — útil para validar a leitura da imagem e a lógica de classificação em um cenário controlado.
- 📁 **Caso 2 — Mosaico misto (Caso2\_Mosaico\_Misto.pgm)**: grade  $3 \times 3$  de blocos de  $16 \times 16$  pixels, com classes repetidas e maior variabilidade — cenário em que a confusão entre **granular** e **manchada** discutida na Fundamentação Teórica tende a se manifestar.

A Figure 7.27 exhibe os dois mosaicos, para inspeção visual antes da implementação.

```
import os
import urllib.request
import numpy as np

def garantir_e_baixar_arquivo(nome_arquivo):
    diretorio_local = "dados/EP07"
    caminho_local = os.path.join(diretorio_local, nome_arquivo)

    # Criar o diretório local se ele não existir
    if not os.path.exists(diretorio_local):
        os.makedirs(diretorio_local)

    # Se o arquivo não existir localmente, baixa do repositório remoto
    if not os.path.exists(caminho_local):
        url_base = "https://raw.githubusercontent.com/fzampirolli/"
        url_base += "pdi-vc/master/all/cap07/dados/EP07"
        url_arquivo = f"{url_base}/{nome_arquivo}"
        print(f"Baixando {nome_arquivo} do GitHub...")
        try:
            urllib.request.urlretrieve(url_arquivo, caminho_local)
        except Exception as e:
            raise IOError(f"Erro ao baixar {nome_arquivo} do GitHub. ",
                          "Verifique a conexão ou a URL. Detalhes: {e}")

    return caminho_local

def ler_pgm_p2(caminho):
    with open(caminho) as f:
        linhas = [l for l in f.read().split() if l]
    assert linhas[0] == "P2"
```

```

C, L = int(linhas[1]), int(linhas[2])
maxv = int(linhas[3])
valores = list(map(int, linhas[4:4 + L * C]))
return np.array(valores, dtype=np.uint8).reshape(L, C)


# Garante o download e obtém o caminho correto
arq_caso1 = garantir_e_baixar_arquivo("Caso1_Mosaico_Simples.pgm")
arq_caso2 = garantir_e_baixar_arquivo("Caso2_Mosaico_Misto.pgm")

# Lê as matrizes PGM
caso1 = ler_pgm_p2(arq_caso1)
caso2 = ler_pgm_p2(arq_caso2)

mm.show(
    [caso1, caso2],
    titles=[
        "Caso 1: Mosaico Simples\n(2x2 blocos, 1 amostra/classe)",
        "Caso 2: Mosaico Misto\n(3x3 blocos, classes repetidas)",
    ],
    cols=2,
    figsize=(8, 4),
)

```

Caso 1: Mosaico Simples  
(2x2 blocos, 1 amostra/classe)



Caso 2: Mosaico Misto  
(3x3 blocos, classes repetidas)




Figura 7.27: Mosaicos de referência (formato PGM ASCII) utilizados no EP07\_07. Caso 1: grade 2x2 com uma amostra de cada classe. Caso 2: grade 3x3 com classes repetidas e maior variabilidade.

```

%%writefile EP07_07.py
# Código Python

```

Overwriting EP07\_07.py

```

TestSuite("EP07_07.py").run()

```

**Simulador: Classificação de Mosaico via LBP + k-NN** ● pipeline completo

Mosaico 3x3 de blocos 12x12 (L=C=36). LBP (P=8,R=1) calculado pixel a pixel, com exclusão da borda global. Ajuste k e a métrica e observe a classificação de cada bloco frente a 8 protótipos (2 por classe).

⚠ Texturas sintéticas geradas por código, não os arquivos .pgm reais do EP07\_07. Use este simulador para entender o fluxo do algoritmo, não como referência de dificuldade entre as classes.

**k (número de vizinhos)** 1 **Métrica**

euclidiana ▼

|                                                                                     |                                    |                                    |                                    |
|-------------------------------------------------------------------------------------|------------------------------------|------------------------------------|------------------------------------|
|  | Real: granular<br>Pred: granular ✓ | Real: listrada<br>Pred: listrada ✓ | Real: manchada<br>Pred: manchada ✓ |
|  | Real: xadrez<br>Pred: granular ✗   | Real: granular<br>Pred: granular ✓ | Real: manchada<br>Pred: manchada ✓ |
|  | Real: listrada<br>Pred: listrada ✓ | Real: xadrez<br>Pred: granular ✗   | Real: granular<br>Pred: granular ✓ |

Classes preditas (ordem de leitura da grade):  
granular listrada manchada granular granular manchada listrada granular granular

Matriz de confusão (linhas=real, colunas=predita; ordem granular,listrada,manchada,xadrez):

```

3 0 0 0
0 2 0 0
0 0 2 0
2 0 0 0

```

Acuracia: 0.7778

Figura 7.28: Simulador: Classificação de um Mosaico de Texturas via LBP + k-NN

## Capítulo 8

# Compreendendo Cenas: Correspondência de Características, Detecção e Segmentação



No **Capítulo 7**, foi estudado como representar imagens por meio de descritores e utilizar essas representações para tarefas de classificação. Neste capítulo, o problema é ampliado: além de reconhecer padrões, torna-se necessário estabelecer correspondências entre diferentes imagens, localizar automaticamente objetos de interesse e interpretar a organização espacial de uma cena.

Esses problemas constituem algumas das principais tarefas da Visão Computacional e representam uma etapa natural após a classificação de imagens. Para resolvê-los, serão apresentados métodos clássicos de correspondência de características, detecção de objetos e segmentação de imagens, bem como uma visão geral das abordagens modernas baseadas em *Deep Learning*, preparando a transição para o **Capítulo 9**.



## 8.1 Objetivos do Capítulo

Ao concluir este capítulo, o estudante deverá ser capaz de:


- **Estabelecer correspondências entre imagens** utilizando detectores e descritores locais, estimando transformações geométricas por meio de homografias para o registro e a correção de perspectiva;
- **Localizar objetos de interesse** em imagens utilizando métodos clássicos de detecção e avaliar os resultados por meio de métricas como a *Intersection over Union (IoU)* e da técnica de *Non-Maximum Suppression (NMS)*;
- **Diferenciar os paradigmas de segmentação** — semântica, de instâncias e panóptica — compreendendo que a segmentação panóptica unifica a segmentação semântica e a segmentação de instâncias, proporcionando uma descrição mais completa da cena, e aplicar métodos clássicos de segmentação;
- **Extraír descritores geométricos e topológicos** de objetos segmentados e exportá-los como anotações estruturadas (CSV ou formato YOLO), validando a qualidade das anotações por meio da métrica IoU;
- **Relacionar os métodos clássicos de correspondência, detecção e segmentação** com as abordagens modernas baseadas em *Deep Learning*, estudadas no **Capítulo 9**.

A *Figure 8.1* apresenta uma visão geral dos principais conceitos e das relações entre os tópicos abordados neste capítulo, servindo como um mapa conceitual para orientar a leitura.

# Visão Computacional: Do Pixel à Compreensão da Cena



Extrair significado e contexto de imagens através de algoritmos clássicos de correspondência, detecção e segmentação.



© NotebookLM

Figura 8.1: Visão geral dos principais conceitos abordados neste capítulo, incluindo correspondência de características, detecção de objetos, segmentação de imagens e suas relações com abordagens modernas baseadas em *Deep Learning*. **Fonte:** elaborado com auxílio do Gemini Notebook (Google, 2025).

## 8.2 Configuração do Ambiente

```
import importlib
import subprocess
import sys

for mod, pkg in {
    "cv2": "opencv-python",
    "skimage": "scikit-image",
    "numpy": "numpy",
    "sklearn": "scikit-learn",
    "matplotlib": "matplotlib",
}.items():
    try:
        importlib.import_module(mod)
    except ImportError:
        subprocess.run([sys.executable, "-m", "pip", "install", "-q", pkg], check=True)

import cv2
import numpy as np
import importlib
import matplotlib.pyplot as plt
import matplotlib.patches as patches
from skimage import data as skdata
from skimage.filters import threshold_otsu
from skimage.measure import label
from skimage.morphology import remove_small_objects, opening, disk

import os
import urllib.request
```

```
if not os.path.exists("morph.py"):
    urllib.request.urlretrieve(
        "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph/morph.py",
        "morph.py",
    )

import morph
importlib.reload(morph);
from morph import mm

print(f" Ambiente pronto. morph {getattr(morph, '__version__', 'local_file')}")
```

Ambiente pronto. morph 1.1.7

## 8.3 Detectores e Descritores Locais de Características

No capítulo anterior, cada imagem foi representada por um único vetor de características utilizado para classificação. Em diversas aplicações, entretanto, é necessário comparar apenas partes da imagem, estabelecendo correspondências entre regiões observadas em diferentes instantes, posições ou pontos de vista. Essa tarefa requer uma representação local da imagem, capaz de identificar estruturas suficientemente distintas para serem reencontradas em outras imagens.

Esse processo é realizado em duas etapas complementares. Inicialmente, um **detector** identifica pontos de interesse (*keypoints*), normalmente associados a cantos ou regiões com variações significativas de intensidade. Em seguida, um **descriptor** representa numericamente a vizinhança de cada ponto detectado, permitindo comparar regiões correspondentes entre diferentes imagens.

Uma vez obtidos os pares (*ponto*, *descriptor*), a correspondência (*matching*) consiste em encontrar, para cada descriptor de uma imagem, o descriptor mais semelhante na outra. Essas correspondências constituem a base de diversas aplicações, como registro de imagens, reconstrução tridimensional, navegação visual e realidade aumentada.

### 8.3.1 O Algoritmo ORB (*Oriented FAST and Rotated BRIEF*)

Neste capítulo será utilizado o **ORB**, um detector e descriptor local que combina eficiência computacional e robustez a rotações. O algoritmo reúne três componentes principais:

- **FAST** (*Features from Accelerated Segment Test*), responsável pela detecção dos pontos-chave;
- **BRIEF** (*Binary Robust Independent Elementary Features*), responsável pela construção do descriptor binário;
- um mecanismo de **estimativa da orientação da vizinhança**, que torna o descriptor aproximadamente invariante à rotação.

O detector **FAST** percorre todos os pixels da imagem. Para cada pixel candidato, analisa um círculo de **16 pixels** ao seu redor. Se um conjunto de pixels consecutivos apresentar intensidade significativamente maior ou menor que a intensidade do pixel central, esse pixel é considerado um **ponto-chave** (*keypoint*). Em seguida, candidatos muito próximos são filtrados, preservando apenas os mais representativos.

Após a detecção dos pontos-chave, o descriptor **BRIEF** é calculado em uma vizinhança ao redor de cada ponto-chave, e não apenas sobre os 16 pixels utilizados pelo FAST. Nessa região, um **padrão de amostragem**, formado por um conjunto fixo de pares de pontos ( $x, y$ ) distribuídos em uma janela ao redor do ponto-chave, é utilizado para realizar comparações de intensidade segundo a Equation 8.1. No ORB, a **orientação predominante da vizinhança** é estimada a partir da distribuição das intensidades nessa região, e o padrão de amostragem é rotacionado de acordo com essa orientação. Além disso, o ORB utiliza uma versão otimizada do BRIEF, denominada **rBRIEF** (*Rotated BRIEF*), na qual os pares de pontos são selecionados para produzir descritores mais discriminativos e com baixa correlação entre seus bits.



$$\tau(p; x, y) = \begin{cases} 1, & \text{se } I(x) < I(y), \\ 0, & \text{caso contrário,} \end{cases} \quad (8.1)$$

em que:

- $p$  é o ponto-chave detectado pelo FAST;
- $x$  e  $y$  são dois pontos da vizinhança de  $p$ , escolhidos pelo padrão de amostragem do BRIEF;
- $I(\cdot)$  representa a intensidade de um pixel;
- $\tau(p; x, y)$  é o resultado da comparação binária entre os pontos  $x$  e  $y$ .

Cada comparação gera um bit do descritor. A concatenação de todas essas comparações forma o descritor binário associado ao ponto-chave.

Como o descritor é binário, a similaridade entre dois pontos é medida pela **distância de Hamming**, correspondente ao número de bits diferentes entre dois descritores. Essa métrica pode ser calculada de forma muito eficiente por operações lógicas sobre os bits, tornando o ORB adequado para aplicações em tempo real.

### 8.3.2 Explorando o Simulador do ORB

A Figure 8.3 ilustra, de forma interativa, como o descritor **ORB** é construído. Cada segmento representa um dos **32 pares de pontos**  $(x, y)$  utilizados na Equation 8.1. A cor do segmento indica o resultado da comparação de intensidades: **verde** quando  $I(x) < I(y)$  (bit igual a 1) e **vermelho** caso contrário (bit igual a 0). A seta **amarela** representa a orientação predominante da vizinhança, estimada a partir do centróide de intensidade. O padrão de amostragem do BRIEF é rotacionado de acordo com essa orientação, tornando o descritor aproximadamente invariante à rotação.

Inicialmente, deixe o ruído em zero e compare a sequência de bits com o *slider* em  $0^\circ$  e depois em  $15^\circ$  (anote o valor do campo “Assinatura do Descritor Binário” em cada caso):

```
0° : 00000000000000100000011111100010
15° : 00000000000000100000011111100010
```

Nesse exemplo, ambos os descritores são idênticos, e o painel “Dist. Hamming” confirma distância zero — evidência de que a estimativa de orientação está compensando corretamente a rotação da imagem.

Agora clique em “Adicionar Ruído” e repita o experimento. Como o ruído é gerado aleatoriamente a cada execução, os valores abaixo são apenas um exemplo — os seus serão diferentes, mas devem apresentar uma distância de Hamming de magnitude semelhante (tipicamente entre 6 e 14 bits, de um total de 32):

```
0° : 01000000001000110110011111101010
15° : 1011000000101110010011111100010
```

O ruído altera parte das comparações de intensidade, modificando alguns bits do descritor. A diferença entre dois descritores é medida pela **distância de Hamming**, correspondente ao número de posições em que os bits diferem. Para os descritores acima, essa distância é igual a **10**.

Uma forma eficiente de calcular essa distância em Python consiste em aplicar a operação **XOR** ( $\wedge$ ), que identifica os bits diferentes, seguida do método `bit_count()`, que contabiliza quantos bits iguais a 1 existem no resultado.

```
def hamming(a: int, b: int) -> int:
    return (a ^ b).bit_count()
a = 0b01000000001000110110011111101010
b = 0b1011000000101110010011111100010
hamming(a, b)
```

10

A Figure 8.2 compara essa implementação com uma versão baseada na comparação de caracteres e com a implementação otimizada do OpenCV (`cv2.NORM_HAMMING`).



```

import random, timeit, cv2, numpy as np, pandas as pd
import matplotlib.pyplot as plt

BITS, N = 256, 100_000
A = [''.join(random.choice('01') for _ in range(BITS)) for _ in range(N)]
B = [''.join(random.choice('01') for _ in range(BITS)) for _ in range(N)]
Ai, Bi = map(lambda L: [int(x,2) for x in L], (A,B))
Acv = np.array([[int(s[i:i+8],2) for i in range(0,BITS,8)] for s in A], np.uint8)
Bcv = np.array([[int(s[i:i+8],2) for i in range(0,BITS,8)] for s in B], np.uint8)

H = [
    ("Strings", lambda: sum(sum(x!=y for x,y in zip(a,b)) for a,b in zip(A,B))),
    ("XOR+bit_count()", lambda: sum((a^b).bit_count() for a,b in zip(Ai,Bi))),
    ("OpenCV", lambda: sum(cv2.norm(a,b,cv2.NORM_HAMMING) for a,b in zip(Acv,Bcv)))
]

df = pd.DataFrame(
    [(n, timeit.timeit(f, number=1)) for n,f in H],
    columns=["Método", "Tempo (s)"]
)
df["Speedup"] = (df.iloc[0,1]/df["Tempo (s)"]).round(1)

print(df)

plt.figure(figsize=(6,3))
plt.bar(df["Método"], df["Tempo (s)"])
plt.ylabel("Tempo (s)")
plt.show()

```

|   | Método          | Tempo (s) | Speedup |
|---|-----------------|-----------|---------|
| 0 | Strings         | 1.353989  | 1.0     |
| 1 | XOR+bit_count() | 0.011943  | 113.4   |
| 2 | OpenCV          | 0.184508  | 7.3     |




Figura 8.2: Comparação do desempenho de diferentes implementações da distância de Hamming.

## 8.4 Correspondência de Características e Homografia com ORB

Para ilustrar o processo de correspondência de características, utiliza-se uma cena sintética obtida pela rotação de 20° da imagem original. Essa transformação simula uma segunda captura da mesma cena sob




Figura 8.3: Simulador interativo do descritor ORB: explore a lógica de rotação e construção do descritor binário. Altere a rotação para observar como o padrão de amostragem de testes binários do BRIEF (linhas verdes e vermelhas) se orienta dinamicamente para garantir a invariância angular.

outro ponto de vista. A Figure 8.4 apresenta a imagem de referência e sua versão rotacionada, que serão utilizadas nas etapas seguintes.

```
caminho_local = "dados/fig-08-Gemini-faces3.png"
url_imagem = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/all/cap08/"
url_imagem += caminho_local

if not os.path.exists(caminho_local):
    mm.write(mm.read(url_imagem), caminho_local)

img_original = mm.read(caminho_local)
img_cena = mm.rotate(img_original, angle=20)

mm.show([img_original, img_cena],
        titles=["Original", "Rotação (20°)",
               cols=2, figsize=(8, 4))
```



Figura 8.4: Imagem original gerada pelo Gemini e versão rotacionada (20°), simulando uma mudança de ponto de vista.

### 8.4.1 Detectando e Correspondendo Características com ORB

Com as duas imagens disponíveis, o **ORB** detecta os pontos-chave e calcula seus descritores binários. Em seguida, o **BFMatcher** da biblioteca **cv2** estabelece as correspondências entre os descritores utilizando a distância de Hamming e a verificação mútua (*cross-check*). Por fim, as correspondências são ordenadas da menor para a maior distância de Hamming, priorizando os pares potencialmente mais confiáveis. No código a seguir, que gera a Figure 8.5, destacam-se os seguintes passos:

1. `cv2.ORB_create(nfeatures=500)` instancia o detector ORB, limitando a busca aos **500 pontos-chave** mais representativos de cada imagem. Essa restrição reduz o custo computacional e evita a seleção de pontos pouco distintivos.
2. `orb.detectAndCompute(...)` executa, em uma única chamada, a detecção dos pontos-chave pelo **FAST** e o cálculo dos descritores pelo **BRIEF orientado**, retornando a lista de pontos-chave (**kp**) e seus descritores binários de **256 bits (des)**.
3. `cv2.BFMatcher(cv2.NORM_HAMMING, crossCheck=True)` cria um comparador por força bruta (*Brute-Force Matcher*), que utiliza a **distância de Hamming** — a mesma métrica explorada na Figure 8.3 — para comparar cada descritor da imagem original com todos os descritores da imagem rotacionada. O parâmetro `crossCheck=True` preserva apenas os pares em que a melhor correspondência é recíproca, isto é, quando o melhor correspondente de A é B e, simultaneamente, o melhor correspondente de B é A. Esse critério elimina grande parte das correspondências ambíguas.
4. `matches = sorted(...)` ordena as correspondências da menor para a maior distância de Hamming. Quanto menor essa distância, maior a similaridade entre os descritores e, consequentemente, maior a probabilidade de a correspondência estar correta.

A Figure 8.5 apresenta apenas as cinco correspondências com menor distância de Hamming. Embora esses pares sejam os mais promissores, ainda não existe qualquer restrição geométrica entre os pontos correspondentes. Como consequência, algumas ligações podem representar falsas correspondências (*false matches*), justificando o uso do **RANSAC** na etapa seguinte para identificar apenas as correspondências geometricamente consistentes.

```
orb = cv2.ORB_create(nfeatures=500)
kp1, des1 = orb.detectAndCompute(img_original, None)
kp2, des2 = orb.detectAndCompute(img_cena, None)
print(f"Pontos de interesse detectados: {len(kp1)} (original), {len(kp2)} (cena)")

bf = cv2.BFMatcher(cv2.NORM_HAMMING, crossCheck=True)
matches = sorted(
    bf.match(des1, des2),
    key=lambda m: m.distance
)
print(f"Correspondências encontradas: {len(matches)}")

def draw_matches_destacado(img1, kp1, img2, kp2, matches, espessura=2, raio_ponto=4,
                           seed=42, cor_fixa=None):
    """Desenha as imagens lado a lado com linhas conectando os pontos correspondentes.
    Se cor_fixa=None, cada correspondência recebe uma cor aleatória (facilita distinguir
    ligações individuais). Se cor_fixa for definida (ex: verde), todas as linhas usam a
    mesma cor - útil para destacar um subconjunto específico, como os inliers do RANSAC.
    """
    h1, w1 = img1.shape[:2]
    h2, w2 = img2.shape[:2]
    h = max(h1, h2)
    canvas = np.zeros((h, w1 + w2, 3), dtype=np.uint8)
    canvas[:h1, :w1] = cv2.cvtColor(img1, cv2.COLOR_GRAY2BGR) if img1.ndim == 2 else img1
    canvas[:h2, w1:w1+w2] = cv2.cvtColor(img2, cv2.COLOR_GRAY2BGR) if img2.ndim == 2 else img2

    rng = np.random.RandomState(seed) # seed fixa = cores reproduzíveis a cada execução

    for m in matches:
        pt1 = tuple(np.round(kp1[m.queryIdx].pt).astype(int))
        pt2 = tuple(np.round(kp2[m.trainIdx].pt).astype(int) + np.array([w1, 0]))

        cor = cor_fixa if cor_fixa is not None else \
            tuple(int(c) for c in rng.randint(60, 256, size=3))

        cv2.line(canvas, pt1, pt2, cor, espessura, lineType=cv2.LINE_AA)
        cv2.circle(canvas, pt1, raio_ponto, cor, -1, lineType=cv2.LINE_AA)
        cv2.circle(canvas, pt2, raio_ponto, cor, -1, lineType=cv2.LINE_AA)

    return canvas

# experimente as 5 piores: matches[-5:]
img_matches = draw_matches_destacado(
    img_original, kp1, img_cena, kp2, matches[:5],
    espessura=10, raio_ponto=15
)
mm.show([img_matches], titles=["Top 5 Correspondências ORB"], cols=1, figsize=(10, 5))
```

Pontos de interesse detectados: 500 (original), 500 (cena)  
Correspondências encontradas: 300





Figura 8.5: As 5 melhores correspondências de características ORB entre a imagem original e a cena sintética, antes da filtragem por RANSAC.

A função `draw_matches_destacado()` possui apenas finalidade de visualização: ela posiciona as imagens lado a lado e desenha linhas entre os pares correspondentes, não interferindo na estimação das correspondências.

## 8.5 Modelagem Matemática: Homografia e RANSAC

### 8.5.1 Homografia

Nos Exercícios 10 e 11 do Capítulo 2, as funções `cv2.getPerspectiveTransform` e `cv2.warpPerspective` foram utilizadas para corrigir a perspectiva de imagens a partir de **quatro pares de pontos correspondentes** informados manualmente. Neste capítulo, essas correspondências passam a ser obtidas automaticamente pelo ORB, tornando possível estimar a transformação entre duas imagens sem intervenção do usuário.

Matematicamente, essa transformação é descrita por uma **homografia**, representada por uma matriz  $3 \times 3$  que relaciona as coordenadas de um mesmo plano observado sob diferentes pontos de vista:

$$\begin{bmatrix} x' \\ y' \\ w' \end{bmatrix} = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}.$$

Após a normalização das coordenadas homogêneas, obtém-se o ponto correspondente

$$\left( \frac{x'}{w'}, \frac{y'}{w'} \right).$$

Como a homografia é definida a menos de um fator de escala, ela possui **oito graus de liberdade**. Consequentemente, são necessários, no mínimo, **quatro pares de pontos correspondentes** para estimar seus parâmetros.

Na prática, porém, as correspondências produzidas automaticamente pelo ORB podem conter associações incorretas (*outliers*). Para estimar a homografia de forma confiável mesmo na presença desses erros, utiliza-se o algoritmo **RANSAC**, apresentado na próxima seção.

### 8.5.2 RANSAC

O **RANSAC** (*Random Sample Consensus*) é um algoritmo de estimação robusta capaz de ajustar um modelo geométrico mesmo na presença de observações incorretas (*outliers*). Neste capítulo, o modelo de interesse é uma **homografia**, estimada a partir das correspondências produzidas pelo ORB.

Em cada iteração, o algoritmo:

1. seleciona aleatoriamente um pequeno subconjunto de correspondências (quatro pares de pontos, no caso da homografia);
2. estima uma homografia candidata a partir desse subconjunto;
3. verifica quais correspondências são compatíveis com essa transformação, classificando-as como *inliers* ou *outliers*;
4. registra a homografia que produz o maior número de *inliers*;
5. reestima a homografia utilizando apenas os *inliers* encontrados.

Embora o exemplo deste capítulo utilize uma homografia, o RANSAC é um algoritmo de propósito geral e pode ser empregado para estimar diversos modelos geométricos, como retas, circunferências, planos e outras transformações. Em todos os casos, o princípio é o mesmo: gerar modelos candidatos a partir de pequenas amostras aleatórias e selecionar aquele que apresenta o maior consenso entre os dados.

Para compreender esse processo de forma gradual, são apresentados dois simuladores.

O primeiro, mostrado na Figure 8.6, utiliza o exemplo mais simples possível: o ajuste de uma **reta** a um conjunto de pontos contendo aproximadamente **25% de outliers**. O objetivo é compreender as etapas fundamentais do algoritmo — amostrar, estimar um modelo, identificar os *inliers* e repetir o processo — sem a complexidade do registro entre imagens.



Figura 8.6: Simulador interativo do algoritmo RANSAC: ajuste o limiar de distância e execute o algoritmo para observar a separação entre *inliers* e *outliers*.

O segundo simulado, apresentado na Figure 8.7, aproxima-se do problema estudado neste capítulo. Em vez de um único conjunto de pontos, são consideradas **duas imagens** contendo correspondências entre pontos-chave. Algumas correspondências estão corretas (*inliers*), enquanto outras são incorretas (*outliers*), resultantes de erros no processo de correspondência dos descritores. Nesse simulador, o modelo estimado é uma **transformação de similaridade** (rotação, escala e translação), mais simples que uma homografia

completa, mas suficiente para ilustrar o problema de registro entre imagens.

Em ambos os simuladores, o algoritmo executado segue exatamente o mesmo princípio utilizado posteriormente para estimar a homografia. A única diferença está no modelo geométrico ajustado.

Ajuste o limiar de distância e execute o algoritmo em cada simulador para observar como o RANSAC identifica os *inliers*, descarta os *outliers* e estima um modelo consistente utilizando apenas as correspondências válidas.




Figura 8.7: Simulador interativo do RANSAC aplicado ao registro de imagens: pontos-chave de duas imagens são casados por um descritor, algumas correspondências são espúrias (*outliers*), e o RANSAC estima a transformação de similaridade que alinha a maioria delas.

### 8.5.3 Estimando a Homografia com RANSAC

Após obter as correspondências entre os pontos-chave pelo ORB, o próximo passo consiste em estimar a **homografia** entre as duas imagens. Para isso, utiliza-se a função `cv2.findHomography()`, que emprega o algoritmo **RANSAC** para calcular essa transformação e retornar uma máscara indicando quais correspondências foram classificadas como *inliers*.

O código a seguir realiza quatro operações principais:

1. extrai as coordenadas dos pontos correspondentes em cada imagem;
2. estima a homografia por meio de `cv2.findHomography(..., cv2.RANSAC)`;
3. recebe a máscara produzida pelo RANSAC, na qual cada correspondência é classificada como *inlier* ou *outlier*;
4. utiliza essa máscara para selecionar apenas as correspondências classificadas como *inliers*.

A Figure 8.8 apresenta apenas as correspondências classificadas como *inliers*. Observa-se que esses pares



de pontos são compatíveis com uma mesma transformação geométrica, enquanto as correspondências inconsistentes (*outliers*) são descartadas. Como consequência, a homografia estimada representa de forma mais fiel a relação geométrica entre as duas imagens.

```
pts1 = np.float32([kp1[m.queryIdx].pt for m in matches])
pts2 = np.float32([kp2[m.trainIdx].pt for m in matches])

H, mascara_inliers = cv2.findHomography(pts1, pts2, cv2.RANSAC, ransacReprojThreshold=5.0)
n_inliers = int(mascara_inliers.sum())
print(f"Matriz de homografia estimada:\n{H}\n")
print(f"Inliers: {n_inliers} de {len(matches)} correspondências \
      ({100*n_inliers/len(matches):.1f}%)")

matches_inliers = [m for m, ok in zip(matches, mascara_inliers.ravel()) if ok]

img_inliers = draw_matches_destacado(
    img_original, kp1, img_cena, kp2, matches_inliers,
    espessura=2, raio_ponto=4, cor_fixa=(0, 200, 0) # verde (BGR)
)
mm.show([img_inliers], titles=[f"Correspondências Inliers (RANSAC) - \
                               {n_inliers}/{len(matches)}"], cols=1, figsize=(10, 5))
```

```
Matriz de homografia estimada:
[[ 9.39407240e-01  3.41706397e-01 -1.77390658e+02]
 [-3.41929137e-01  9.39717641e-01  5.27534018e+02]
 [-1.12175998e-07 -4.86089683e-08  1.00000000e+00]]

Inliers: 285 de 300 correspondências      (95.0%)
```



Figura 8.8: Correspondências classificadas como *inliers* (verde) pelo RANSAC ao estimar a homografia entre as duas imagens.

#### 8.5.4 Registrando a Imagem

Após estimar a homografia, o passo seguinte consiste em utilizá-la para registrar a imagem da cena no sistema de coordenadas da imagem original. Esse processo permite alinhar as duas imagens, facilitando a comparação entre elas.

O código realiza três operações principais:

1. aplica a transformação projetiva por meio de `cv2.warpPerspective()`, utilizando a opção `cv2.WARP_INVERSE_MAP`, que aplica internamente a transformação inversa sem a necessidade de calcular explicitamente  $H^{-1}$ ;
2. calcula a diferença absoluta pixel a pixel entre a imagem registrada e a imagem original por meio de `cv2.absdiff()`;

3. exibe a imagem original, a cena rotacionada, a imagem registrada e um mapa das diferenças entre as duas imagens.

A Figure 8.9 apresenta o resultado do registro. Observa-se que a imagem registrada torna-se visualmente muito próxima da imagem original, indicando que a homografia estimada conseguiu alinhar corretamente as duas vistas da mesma cena. O mapa de diferenças evidencia apenas as regiões em que ainda existem pequenas discrepâncias decorrentes de erros de interpolação, quantização e da própria estimativa da homografia.

```
h, w = img_original.shape[:2]

# WARP_INVERSE_MAP: aplica H "de trás para frente", dispensando o cálculo manual de H^-1
img_registrada = cv2.warpPerspective(img_cena, H, (w, h), flags=cv2.WARP_INVERSE_MAP)

erro = cv2.absdiff(img_original, img_registrada)

mm.show( # mostra mm.gray(erro)>10 em níveis de cinza
    [img_original, img_cena, img_registrada, mm.gray(erro)>10],
    titles=["Original", "Cena (rotacionada)", "Registrada", "Diferença"],
    cols=2,
    figsize=(14, 8),
)
```



Figura 8.9: Registro da imagem da cena utilizando a homografia inversa estimada pelo RANSAC.

### **i** 🧠 Por que funciona? — Robustez por consenso

Muitos métodos de estimação ajustam um modelo utilizando **todas** as observações disponíveis, procurando minimizar o erro total entre os dados observados e o modelo ajustado (abordagem conhecida como **mínimos quadrados**). Quando existem *outliers*, essas observações incorretas podem deslocar significativamente o resultado obtido.

O **RANSAC** segue uma estratégia diferente. Em vez de utilizar todos os dados simultaneamente, ele estima sucessivos modelos a partir de pequenas amostras aleatórias. Cada modelo é então avaliado pelo



número de correspondências compatíveis com ele. Ao final das iterações, é selecionado o modelo que apresenta o maior consenso entre os dados, isto é, o maior número de *inliers*.

Dois parâmetros exercem papel fundamental no algoritmo:

- o **limiar de reprojeção**, que define a distância máxima para que uma correspondência seja classificada como *inlier*;
- o **número de iterações**, que deve ser suficientemente grande para aumentar a probabilidade de selecionar pelo menos uma amostra livre de *outliers*.

Embora bastante robusto, o RANSAC pressupõe que exista um modelo geométrico predominante nos dados. Seu desempenho tende a diminuir quando a proporção de *inliers* é muito pequena ou quando diferentes estruturas geométricas coexistem na mesma cena, dificultando a identificação de um único modelo dominante.

## 8.6 Detecção de Objetos: *Haar Cascade* (Viola-Jones)

A correspondência de características responde à pergunta: “**onde está o mesmo objeto ou padrão observado anteriormente?**”. A **detecção de objetos** resolve um problema mais geral: localizar automaticamente instâncias de uma **categoria** (por exemplo, faces humanas), mesmo que os objetos específicos nunca tenham sido observados durante o treinamento. Enquanto o ORB necessita de duas imagens para estabelecer correspondências entre pontos, o **Haar Cascade** opera sobre uma única imagem, identificando diretamente as regiões candidatas a conter o objeto procurado.

O algoritmo **Haar Cascade**, proposto por Viola e Jones (Viola; Jones, 2001; Viola; Jones, 2004), combina características Haar, imagens integrais e uma cascata de classificadores para realizar a detecção de objetos de forma eficiente. Embora atualmente existam métodos mais recentes baseados em redes neurais convolucionais, o Haar Cascade permanece disponível na biblioteca OpenCV e constitui um exemplo clássico para o estudo de técnicas de detecção de objetos.

Seu funcionamento baseia-se em três componentes principais:

1. **Características Haar:** filtros retangulares simples que medem diferenças de intensidade entre regiões vizinhas da imagem, explorando **padrões de contraste característicos** do objeto, como a região dos olhos geralmente mais escura que a testa;
2. **Imagem integral:** estrutura de dados que permite calcular rapidamente a soma dos pixels de qualquer região retangular da imagem:

$$I_{\text{integral}}(x, y) = \sum_{x' \leq x, y' \leq y} I(x', y'),$$

reduzindo significativamente o custo computacional da avaliação das características Haar. Com essa estrutura, a soma dos pixels de qualquer retângulo pode ser obtida com apenas quatro acessos à imagem integral;

3. **Cascata de classificadores:** durante o treinamento, o algoritmo AdaBoost seleciona e combina classificadores simples em uma sequência de estágios. Na detecção, regiões que claramente **não correspondem ao objeto** são descartadas logo nos primeiros estágios, enquanto apenas as candidatas mais promissoras passam pelas etapas seguintes, mais precisas e computacionalmente mais caras. Essa estratégia permite realizar uma busca eficiente em diferentes posições e escalas da imagem.

O código a seguir, que gera a Figure 8.10, utiliza classificadores treinados previamente e disponibilizados pelo OpenCV para detectar **faces** e, em seguida, restringe a busca por **olhos** apenas ao interior de cada face detectada. Essa estratégia reduz falsos positivos e diminui o custo computacional, pois evita realizar a busca por olhos em toda a imagem.

Durante a detecção, uma janela percorre a imagem em diferentes posições e escalas. A função `detectMultiScale()` realiza essa busca automaticamente. O parâmetro `scaleFactor` controla o fator de redução entre escalas consecutivas da janela, enquanto `minNeighbors` define o número mínimo de detecções vizinhas necessárias para confirmar um objeto, reduzindo detecções espúrias. O parâmetro `minSize` estabelece o menor tamanho de objeto considerado durante a busca.

A função retorna uma lista de retângulos, cada um descrito pelas coordenadas do canto superior esquerdo e pelas dimensões (`x`, `y`, `largura`, `altura`). Esses retângulos delimitam as regiões classificadas como objetos pelo detector e são utilizados para desenhar as caixas mostradas na Figure 8.10.

```
def get_cascade(nome):
    """Baixa (se necessário) e carrega um classificador Haar Cascade do OpenCV."""
    caminho = f"haarcascades/{nome}"
    os.makedirs("haarcascades", exist_ok=True)
    if not os.path.exists(caminho):
        url = f"https://raw.githubusercontent.com/opencv/opencv/master/data/haarcascades/{nome}"
        urllib.request.urlretrieve(url, caminho)
    return cv2.CascadeClassifier(caminho)

# Mais utilizado
#face_cascade = get_cascade("haarcascade_frontalface_default.xml")

# Mais preciso, porém mais lento
face_cascade = get_cascade("haarcascade_frontalface_alt2.xml")

# Compromisso entre velocidade e precisão
#face_cascade = get_cascade("haarcascade_frontalface_alt.xml")

# Muito rápido, porém menos preciso
#face_cascade = get_cascade("haarcascade_frontalface_alt_tree.xml")

# para os olhos, mais utilizado
#eye_cascade = get_cascade("haarcascade_eye.xml")
eye_cascade = get_cascade("haarcascade_eye_tree_eyeglasses.xml")

img_original = mm.read(caminho_local)

# Escala de cinza + equalização de histograma (Capítulo 3), como o Haar Cascade espera
img_rgb = mm.rotate(img_original, angle=0)
img_gray = cv2.equalizeHist(cv2.cvtColor(img_rgb, cv2.COLOR_RGB2GRAY))

# Detecta faces e, dentro de cada uma, tenta detectar os olhos
faces = face_cascade.detectMultiScale(
    img_gray,
    scaleFactor=1.1,      # Passos maiores entre escalas: mais rápido, porém menos sensível
    minNeighbors=3,       # N° mínimo de detecções sobrepostas para confirmar uma face
    minSize=(90, 90)      # Ignora regiões candidatas menores que 30×30 px
)

img_annotada = img_rgb.copy()
for (x, y, w, h) in faces:
    cv2.rectangle(img_annotada, (x, y), (x + w, y + h), (0, 255, 0), 3)
    olhos = eye_cascade.detectMultiScale(
        img_gray[y:y+h, x:x+w],
        scaleFactor=1.02,
        minNeighbors=4,
        minSize=(15, 15)
    )
    for (ex, ey, ew, eh) in olhos:
        cv2.rectangle(img_annotada, (x+ex, y+ey), (x+ex+ew, y+ey+eh), (255, 0, 0), 4)

print(f"Regiões detectadas como face: {len(faces)}")
mm.show([img_annotada], titles=
    ["Detecção Haar Cascade: faces (verde) e olhos (vermelho)"],
    cols=1, figsize=(8, 8))
```

Regiões detectadas como face: 5

### Detecção Haar Cascade: faces (verde) e olhos (vermelho)



Figura 8.10: Detecção de faces e olhos com *Haar Cascade*.

#### **i** 🧠 Por que funciona? — E por que também falha

Na imagem utilizada neste exemplo, o classificador detecta a face e os olhos, mas também pode marcar uma segunda região sobre parte do fundo da imagem como se fosse uma face. Esse é um exemplo de **falso positivo**: a distribuição local de intensidades nessa região é suficientemente semelhante aos padrões aprendidos durante o treinamento para que a cascata a classifique incorretamente como um rosto.

Esse comportamento evidencia uma das principais limitações do *Haar Cascade*. Como o método baseia sua decisão apenas em características Haar, isto é, diferenças de intensidade entre regiões retangulares, ele não representa explicitamente a forma ou o significado dos objetos presentes na imagem. Assim, texturas e padrões de contraste semelhantes aos encontrados em faces podem produzir detecções incorretas. Além disso, seu desempenho tende a diminuir diante de grandes variações de pose, oclusões, expressões faciais e condições de iluminação diferentes daquelas presentes nos dados utilizados para o treinamento.

Apesar dessas limitações, o *Haar Cascade* permanece útil em aplicações que priorizam baixo custo computacional. Em situações que exigem maior capacidade de generalização diante de variações na aparência dos objetos, métodos modernos baseados em redes neurais profundas costumam apresentar melhor desempenho.

## 8.7 Detecção de Objetos: Caixas Delimitadoras, IoU e NMS

Embora os métodos de detecção de objetos utilizem estratégias bastante diferentes — do *Haar Cascade* aos detectores modernos baseados em redes neurais profundas —, seus resultados são normalmente representados por **caixas delimitadoras** (*bounding boxes*), definidas pelas coordenadas  $(x_{min}, y_{min}, x_{max}, y_{max})$ .

### 8.7.1 Intersection over Union (IoU)

A métrica **Intersection over Union (IoU)** quantifica a sobreposição entre duas caixas delimitadoras, por exemplo, a detecção produzida por um algoritmo e a anotação de referência (*ground truth*):

$$\text{IoU}(A, B) = \frac{\text{área}(A \cap B)}{\text{área}(A \cup B)} \in [0, 1].$$

Quanto mais próximo de 1, maior a concordância entre as caixas; o valor 0 indica ausência de sobreposição. Em avaliações de detectores de objetos, é comum considerar uma detecção correta quando  $\text{IoU} \geq 0,5$ , embora aplicações específicas possam adotar limiares diferentes.

A métrica IoU não é utilizada apenas para avaliar detectores. Ela também constitui o critério empregado pelo algoritmo de **Supressão de Não-Máximos** para decidir quando duas caixas delimitadoras representam o mesmo objeto e, portanto, uma delas deve ser eliminada.

### 8.7.2 Supressão de Não-Máximos (NMS)

Durante a detecção, é comum que várias caixas delimitadoras sejam associadas ao mesmo objeto. A **Supressão de Não-Máximos** (*Non-Maximum Suppression*, NMS) elimina essa redundância em três etapas:

1. ordena as detecções pela pontuação de confiança, da maior para a menor;
2. mantém a caixa de maior confiança e elimina aquelas cujo IoU com ela excede um determinado limiar;
3. repete o processo com as caixas restantes até que não existam sobreposições relevantes.

O exemplo da Figure 8.11 ilustra esse procedimento com dois objetos, cada um inicialmente representado por várias caixas sobrepostas. Neste exemplo, cada caixa delimitadora recebe uma **pontuação de confiança**, que representa o grau de confiança do detector de que aquela região contém o objeto procurado.

Em vez de implementar o algoritmo manualmente, utiliza-se a função `cv2.dnn.NMSBoxes`, que implementa a Supressão de Não-Máximos empregada em diversos detectores modernos. A função `desenhar_caixas` exibe, lado a lado, as caixas antes e depois do NMS, evidenciando a redução de cinco detecções para apenas duas, preservando apenas a caixa de maior confiança para cada objeto.

```
def desenhar_caixas(caixas, pontuacoes, indices, cor, tamanho=(450, 450)):
    """Desenha as caixas (e suas pontuações) indicadas em `indices` sobre um fundo branco."""
    tela = np.full((tamanho[1], tamanho[0], 3), 255, dtype=np.uint8)
    for i in indices:
        x0, y0, x1, y1 = caixas[i]
        cv2.rectangle(tela, (x0, y0), (x1, y1), cor, 2)
        cv2.putText(tela, f"{pontuacoes[i]:.2f}", (x0, y0 - 8),
                    cv2.FONT_HERSHEY_SIMPLEX, 0.5, cor, 1, cv2.LINE_AA)
    return tela

caixas = np.array([
    [50, 50, 150, 150], [60, 55, 155, 145], [58, 60, 160, 150],
    [300, 300, 400, 420], [310, 305, 395, 415],
])
pontuacoes = np.array([0.90, 0.75, 0.60, 0.95, 0.70])

# cv2.dnn.NMSBoxes espera caixas no formato (x, y, largura, altura)
caixas_xywh = np.column_stack([
    caixas[:, 0], caixas[:, 1],
    caixas[:, 2] - caixas[:, 0], caixas[:, 3] - caixas[:, 1]
])

mantidas = cv2.dnn.NMSBoxes(
    bboxes=caixas_xywh.tolist(),
```



```


scores=pontuacoes.tolist(),
score_threshold=0.0, # nenhum corte por confiança mínima aqui
nms_threshold=0.5 # limiar de IoU para considerar duas caixas redundantes
).flatten()

img_antes = desenhar_caixas(caixas, pontuacoes, range(len(caixas)), cor=(220, 38, 38))
img_depois = desenhar_caixas(caixas, pontuacoes, mantidas, cor=(22, 163, 74))

mm.show(
    [img_antes, img_depois],
    titles=[f"Antes do NMS ({len(caixas)} caixas)", \
            f"Depois do NMS ({len(mantidas)} caixa(s))"],
    cols=2, figsize=(9, 4.5)
)

```

Antes do NMS (5 caixas)



Depois do NMS (2 caixa(s))



Figura 8.11: Efeito da Supressão de Não-Máximos (NMS): múltiplas detecções redundantes (esquerda) são reduzidas a uma detecção por objeto (direita).

### **i** 🧠 Por que funciona? — Eliminação de Redundâncias

O **NMS** (*Non-Maximum Suppression*) não altera a qualidade das detecções produzidas pelo detector. Sua função é eliminar **caixas delimitadoras redundantes** que representam o mesmo objeto, preservando apenas aquela com maior pontuação de confiança.

Sua eficácia depende do limiar de IoU adotado. Um valor muito baixo pode eliminar caixas correspondentes a objetos diferentes cuja sobreposição seja elevada, enquanto um valor muito alto pode manter várias caixas sobrepostas para um mesmo objeto.

O NMS também **não elimina falsos positivos isolados**. Se uma região incorreta for detectada por apenas uma caixa, ela será preservada, pois não existe outra detecção redundante para compará-la. Por esse motivo, o NMS é aplicado como uma etapa de **pós-processamento**, utilizando apenas as caixas delimitadoras e suas pontuações de confiança produzidas pelo detector.



## 8.8 Segmentação Visual: Semântica, de Instâncias e Panóptica

Uma caixa delimitadora indica aproximadamente a posição de um objeto, mas não identifica quais pixels lhe pertencem. A **segmentação visual** resolve esse problema atribuindo um rótulo a cada pixel da imagem. Conforme a informação produzida, distinguem-se três paradigmas principais, resumidos na Table 8.1.

Tabela 8.1: Comparação entre os principais paradigmas de segmentação visual.

| Paradigma            | Pergunta que responde                              | Distingue objetos da mesma classe?                                                    |
|----------------------|----------------------------------------------------|---------------------------------------------------------------------------------------|
| <b>Semântica</b>     | “A que classe pertence cada pixel?”                | Não. Todos os pixels de uma mesma classe recebem o mesmo rótulo.                      |
| <b>De instâncias</b> | “Quais pixels pertencem a cada objeto individual?” | Sim. Cada objeto recebe um identificador próprio.                                     |
| <b>Panóptica</b>     | Combina as duas anteriores.                        | Sim. Cada pixel recebe uma classe e, quando aplicável, um identificador de instância. |

Na segmentação **semântica**, cada pixel recebe apenas o rótulo de sua classe. Na segmentação **de instâncias**, além da classe, objetos distintos pertencentes à mesma categoria são diferenciados entre si. Já a segmentação **panóptica** combina essas duas informações, atribuindo a cada pixel uma classe e, quando aplicável, um identificador de instância.

### 8.8.1 Segmentação Semântica por Limiarização

Antes da popularização dos métodos baseados em redes neurais profundas — tema do **Capítulo 9** —, muitas aplicações de segmentação eram resolvidas por técnicas clássicas de processamento de imagens. Um dos exemplos mais simples consiste em separar objeto e fundo por **limiarização**, produzindo uma máscara binária. Essa máscara caracteriza uma **segmentação semântica**, pois cada pixel passa a pertencer a uma das duas classes: **moeda** ou **fundo**.

A Figure 8.12 utiliza a imagem de moedas da biblioteca `scikit-image`. Esse exemplo retoma os conceitos de limiarização e morfologia matemática estudados no **Capítulo 4**, em substituição ao exemplo anterior, que utilizava outra imagem de moedas.

Inicialmente, aplica-se um **fechamento morfológico** para suavizar pequenas imperfeições na superfície das moedas. Em seguida, a **limiarização de Otsu** produz a máscara binária que separa moedas e fundo. Após a remoção dos objetos conectados à borda da imagem, o preenchimento de regiões internas e a eliminação de pequenos ruídos por operações morfológicas, obtém-se uma máscara semântica adequada para as etapas seguintes.

### 8.8.2 Segmentação de Instâncias por Rotulação

Uma máscara semântica informa apenas a classe de cada pixel, mas não distingue objetos diferentes pertencentes à mesma categoria. Para obter uma **segmentação de instâncias**, aplica-se a **rotulação de componentes conectados**, que atribui um identificador diferente a cada região conexa da máscara binária.

Neste exemplo, cada componente conectado corresponde a uma moeda individual. Assim, a rotulação produz uma segmentação de instâncias, permitindo identificar, contar e medir separadamente cada moeda presente na imagem.

```
img_moedas = skdata.coins()

# 1. Fechamento morfológico: suaviza bordas e preenche pequenas falhas na
# superfície das moedas antes da limiarização
```

```
fechamento = mm.close(img_moedas, mm.sedisk(4))

# 2. Limiarização de Otsu (Capítulo 4): separa moedas (claras) do fundo (escuro)
mascara_bruta = mm.threshold(fechamento)

# 3. Remove objetos conectados à borda da imagem - moedas cortadas nas
#     extremidades não formam instâncias completas e atrapalhariam a contagem
mascara_sem_borda = mm.edgeoff(mascara_bruta)

# 4. Fechamento de buracos: preenche eventuais regiões internas não detectadas
#     pelo threshold, garantindo que cada moeda seja um disco sólido
mascara_semantica = mm.clohole(mascara_sem_borda)

# 5. Abertura morfológica: remove ruído residual e desconecta moedas que
#     porventura se tocam, preparando a máscara para a Rotulação
mascara_limpa = mm.open(mascara_semantica, mm.sedisk(6))

# 6. Rotulação de componentes conectados: cada moeda isolada recebe um
#     identificador de instância distinto
rotulos_instancias = mm.label(mascara_limpa)

print(f"Instâncias (moedas individuais) identificadas: {np.max(rotulos_instancias)}")

mm.show(
    [img_moedas, mascara_bruta, mascara_sem_borda, mascara_semantica,
     mascara_limpa, rotulos_instancias],
    titles=[
        "Original",
        "1. Limiarização (Otsu)",
        "2. Remoção de bordas",
        "3. Preenchimento de buracos\n(máscara semântica: moeda x fundo)",
        "4. Abertura (limpeza)",
        "5. Rotulação\n(segmentação de instâncias)"
    ],
    cols=3, figsize=(10, 6)
)
```

Instâncias (moedas individuais) identificadas: 24




Figura 8.12: Segmentação clássica (não baseada em aprendizado profundo): máscara semântica (moeda x fundo) via limiarização de Otsu, e segmentação de instâncias via rotulação de componentes conectados.

**i** 🧠 Por que funciona? — E onde a abordagem clássica encontra limitações

Neste exemplo, a segmentação é facilitada pelo contraste entre as moedas e o fundo e pela relativa homogeneidade de intensidade no interior de cada moeda. A limiarização de Otsu separa eficientemente essas duas regiões, enquanto as operações morfológicas removem pequenas imperfeições da máscara binária. Por fim, a rotulação de componentes conectados atribui um identificador distinto a cada região conexa, produzindo uma segmentação de instâncias.

Essa estratégia, entretanto, depende diretamente da qualidade da máscara binária. Se dois objetos estiverem unidos, sobrepostos ou apresentarem contraste insuficiente em relação ao fundo, eles poderão ser representados por uma única região ou deixar de ser segmentados corretamente. Além disso, métodos baseados predominantemente na intensidade dos pixels possuem capacidade limitada para distinguir objetos de classes diferentes com aparência semelhante.

Métodos modernos de segmentação baseados em redes neurais profundas aprendem representações visuais diretamente a partir dos dados de treinamento, o que geralmente lhes confere maior capacidade de lidar com variações de iluminação, textura, forma e oclusão. A segmentação panóptica amplia essa abordagem ao combinar, em uma única representação, a classificação semântica de todos os pixels e a identificação individual dos objetos presentes na cena.

### 8.8.3 Alternativa: Transformada de Distância + *Watershed*

A abertura morfológica pode separar moedas que se tocam por meio da erosão da máscara binária. Entretanto, essa operação modifica o contorno de todos os objetos, inclusive daqueles que já estavam isolados. Uma alternativa, introduzida no **Capítulo 4**, consiste em combinar a **transformada de distância** com o algoritmo *watershed*, utilizando marcadores obtidos a partir da própria máscara binária.

O procedimento é realizado em três etapas:

1. calcula-se a **transformada de distância** da máscara binária, atribuindo a cada pixel do objeto sua

- distância até o fundo mais próximo;
2. aplica-se um limiar à transformada de distância para obter **marcadores** localizados nas regiões centrais das moedas;
3. utiliza-se o algoritmo *watershed* para expandir esses marcadores até as fronteiras entre os objetos, separando moedas que se encontram em contato.

A Figure 8.13 apresenta essas etapas. Os marcadores são obtidos nas regiões centrais da transformada de distância e utilizados como sementes para o *watershed*, que propaga cada rótulo até encontrar as fronteiras entre objetos vizinhos.

Comparando com a abertura morfológica, ambas as abordagens conseguem separar moedas em contato. Entretanto, como o *watershed* utiliza marcadores para dividir regiões conectadas, sem aplicar erosão diretamente à máscara, os contornos originais tendem a ser mais bem preservados, favorecendo a obtenção de medidas geométricas, como área, perímetro e circularidade.

```
# Reaproveita a máscara semântica ANTES da abertura agressiva (sem erosão do contorno)
mascara_base = mascara_semantica

# 1. Transformada de distância: cada pixel da máscara recebe a distância até o fundo próximo
distancia = mm.dist(mascara_base)

# Marcadores obtidos por limiarização da transformada de distância.
# As regiões centrais das moedas permanecem conectadas e são utilizadas
# como sementes para o algoritmo watershed.
marcadores = mm.label(
    np.uint8(distancia > 0.5 * distancia.max())
)

# 3. Watershed: propaga cada marcador dentro da máscara até os pontos de contato entre moedas
rotulos_watershed = mm.watershed(marcadores, mascara_base)

print(f"Abertura morfológica (mascara_limpa): {np.max(rotulos_instancias)} instâncias")
print(f"Distância + watershed: {np.max(rotulos_watershed)} instâncias")

mm.show(
    [mascara_base, distancia, mm.dil(marcadores, mm.sedisk(5)), rotulos_watershed],
    titles=[
        "Máscara semântica\n(sem abertura, sem erosão)",
        "Transformada de distância",
        "Marcadores\n(máximos regionais)",
        "Watershed\n(instâncias separadas)"
    ],
    cols=4, figsize=(11, 3.2)
)
```

```
Abertura morfológica (mascara_limpa): 24 instâncias
Distância + watershed: 24 instâncias
```




Figura 8.13: Separação de moedas que se tocam via transformada de distância + *watershed*, sem erosão do contorno das moedas.

#### Por que funciona? — Marcadores e *Watershed*

A transformada de distância atribui valores maiores aos pixels mais afastados do fundo, que normalmente se encontram nas regiões mais centrais dos objetos. Ao aplicar um limiar a essa transformada, obtêm-se marcadores localizados no interior de cada moeda, favorecendo a obtenção de um marcador para cada objeto.

O algoritmo *watershed* utiliza esses marcadores como sementes e propaga seus rótulos até que duas regiões em crescimento se encontrem. Os pontos de encontro entre essas regiões definem as fronteiras entre objetos adjacentes.

O desempenho desse método depende da qualidade dos marcadores. Objetos muito alongados, com formas irregulares ou contendo múltiplos máximos na transformada de distância podem gerar marcadores adicionais, resultando em uma segmentação excessiva (*oversegmentation*). Em aplicações mais complexas, métodos modernos de segmentação de instâncias baseados em redes neurais profundas aprendem diretamente, a partir dos dados de treinamento, representações adequadas para separar os objetos, dispensando a construção explícita de marcadores e outras heurísticas geométricas.

### 8.8.4 Medição e Extração de Atributos com `mm.measure`

Após a segmentação e a rotulação dos objetos, o próximo passo consiste em medir suas propriedades geométricas. Para isso, a biblioteca `morph` disponibiliza a função `mm.measure`, que recebe uma imagem **binária** e retorna, para cada objeto, um conjunto de descritores geométricos organizado em uma lista de dicionários.

Entre os descritores calculados destacam-se a **área**, o **perímetro**, o **centroide**, a **caixa delimitadora** (*bounding box*), a **circularidade**, a **solidez** e o número de **vértices** do contorno aproximado. Esses vértices são obtidos aproximando-se o contorno por um polígono simplificado, calculado pela função `approxPolyDP`, que preserva a forma geral do objeto utilizando um número reduzido de segmentos.

A circularidade é definida por

$$\text{Circularidade} = \frac{4\pi \cdot \text{Área}}{\text{Perímetro}^2},$$

assumindo valor igual a 1 para um círculo perfeito e valores menores para formas progressivamente menos circulares.

A solidez é dada por

$$\text{Solidez} = \frac{\text{Área}}{\text{Área do Fecho Convexo}},$$

indicando o quanto o objeto preenche seu fecho convexo. Valores próximos de 1 caracterizam objetos convexos, enquanto valores menores indicam a presença de concavidades.

O número de vértices fornece uma indicação da complexidade da forma do objeto. Por exemplo, um triângulo tende a produzir três vértices e um retângulo quatro, enquanto objetos de contorno curvo, como moedas, costumam resultar em polígonos com maior número de vértices, dependendo da precisão adotada na aproximação.

Como as moedas deste exemplo apresentam contornos aproximadamente circulares e convexos, espera-se que a circularidade assuma valores elevados (tipicamente entre 0,8 e 0,9) e que a solidez permaneça muito próxima de 1. O número de vértices depende do parâmetro utilizado na aproximação poligonal (**precision**), aumentando à medida que a aproximação preserva mais detalhes do contorno. Em conjunto, esses descritores podem ser empregados na classificação de objetos, na identificação de componentes espúrios remanescentes da segmentação e na realização de medições quantitativas sobre a imagem.

```
# mm.measure recebe uma imagem binária; cada componente conexo corresponde
# a uma moeda individual.
medidas = mm.measure(mascara_limpa, precision=0.01)

if medidas:
    print(f"Total de objetos catalogados: {len(medidas)}")
    print(f"{'ID':<4}{'Área':<10}{'Perímetro':<12}{'Circularidade':<14}",end="")
    print(f"{'Solidez':<10}{'Vértices':<8}")
    for m in medidas:
        print(f"{m['id']:<4}{m['area']:<10.1f}{m['perimeter']:<12.2f}"
              f"{m['circularity']:<15.3f}{m['solidity']:<10.3f}{m['vertices']:<8}")
else:
    print("Nenhuma medida retornada.")
```

```
Total de objetos catalogados: 24
ID  Área      Perímetro   Circularidade  Solidez  Vértices
1   1376.5    140.47      0.877          0.979    11
2   1299.5    136.47      0.877          0.978    10
3   1628.0    154.37      0.859          0.980    12
4   1866.0    162.71      0.886          0.985    11
5   2127.0    178.37      0.840          0.973    12
6   2328.0    181.68      0.886          0.983    10
7   1086.5    124.81      0.876          0.979    13
8   1053.5    121.50      0.897          0.983    9
9   1399.5    140.47      0.891          0.985    13
10  1449.0    147.05      0.842          0.972    13
11  1642.5    153.30      0.878          0.982    13
12  2987.5    207.58      0.871          0.981    13
13  1036.5    121.15      0.887          0.981    12
14  1050.5    123.15      0.870          0.979    11
15  1110.0    126.23      0.875          0.975    11
16  1135.0    127.05      0.884          0.986    11
17  1250.5    135.64      0.854          0.975    13
18  1802.0    160.71      0.877          0.982    10
19  1067.5    122.33      0.896          0.986    11
20  1154.5    129.64      0.863          0.977    10
21  1356.0    139.88      0.871          0.978    13
22  1549.5    149.30      0.874          0.982    12
23  1592.0    149.54      0.895          0.984    13
24  2509.5    187.92      0.893          0.987    14
```

Observa-se que foram identificadas **24 moedas**. As medidas de solidez permanecem próximas de 1, indicando contornos essencialmente convexos, enquanto a circularidade varia entre aproximadamente 0,84 e 0,90 devido às irregularidades do contorno discretizado. O número de vértices varia entre 9 e 14, refletindo a aproximação poligonal utilizada para representar cada moeda.



### 8.8.5 Exportação de Anotações: de `mm.measure` ao Formato YOLO

Além dos descritores geométricos, `mm.measure` calcula, para cada objeto, sua **caixa delimitadora** (*bounding box*). Essas informações podem ser exportadas automaticamente pela função `mm.saveMeasures`, permitindo gerar arquivos de anotação para diferentes aplicações sem a necessidade de rotulação manual.

A função suporta três formatos de saída:

- `fmt="csv"`: exporta todos os descritores geométricos, sendo útil para análise exploratória, medição e classificação baseada em atributos;
- `fmt="txt"`: grava os descritores em formato tabular simples;
- `fmt="yolo"`: gera anotações compatíveis com o formato utilizado pelos detectores da família **YOLO** (*You Only Look Once*).

No formato YOLO, cada objeto é representado por uma linha contendo

$$\text{classe } x_c \ y_c \ w_n \ h_n,$$

em que  $(x_c, y_c)$  representa o centro da caixa delimitadora e  $(w_n, h_n)$  suas dimensões, todos normalizados pelas dimensões da imagem:

$$x_c = \frac{x + w/2}{W}, \quad y_c = \frac{y + h/2}{H}, \quad w_n = \frac{w}{W}, \quad h_n = \frac{h}{H},$$

em que  $(x, y)$  correspondem às coordenadas do canto superior esquerdo da caixa delimitadora,  $(w, h)$  às suas dimensões em pixels e  $(W, H)$  à largura e à altura da imagem. A normalização torna as anotações independentes da resolução da imagem, permitindo utilizar o mesmo formato em imagens de diferentes tamanhos.

O código a seguir exporta as medidas extraídas das moedas para os formatos **CSV** e **YOLO**. A saída em CSV preserva todos os descritores geométricos calculados por `mm.measure`, enquanto o arquivo no formato YOLO contém apenas a classe e a caixa delimitadora normalizada de cada objeto, conforme exigido pelos detectores dessa família.

Essa representação será utilizada novamente no **Capítulo 9**, dedicado aos métodos de detecção de objetos baseados em *Deep Learning*.

```
# Exporta as medidas extraídas das moedas em dois formatos de anotação
altura_img, largura_img = img_moedas.shape[:2]

mm.saveMeasures("moedas.csv", medidas, fmt="csv")
mm.saveMeasures("moedas.txt", medidas, fmt="yolo",
                img_width=largura_img, img_height=altura_img, class_id=0)

print("--- Trecho de moedas.csv ---")
with open("moedas.csv") as f:
    for linha in f.readlines()[:4]:
        print(linha.rstrip())

print("\n--- Trecho de moedas.txt (formato YOLO) ---")
with open("moedas.txt") as f:
    for linha in f.readlines()[:4]:
        print(linha.rstrip())
```

```
--- Trecho de moedas.csv ---
id,area,perimeter,cx,cy,x,w,h,circularity,solidity,vertices
1,1376.5,140.47,359.57,268.85,338,250,45,41,0.877,0.979,11
2,1299.5,136.47,115.16,266.56,95,247,42,42,0.877,0.978,10
3,1628.0,154.37,245.55,264.02,222,243,49,46,0.859,0.98,12
```

```
--- Trecho de moedas.txt (formato YOLO) ---
0 0.938802 0.892739 0.117188 0.135314
0 0.302083 0.884488 0.109375 0.138614
0 0.641927 0.877888 0.127604 0.151815
0 0.789062 0.877888 0.130208 0.158416
```

### 8.8.6 Validação de Anotações por IoU: `mm.verifyBoundingBox`

Antes de utilizar anotações no treinamento ou na avaliação de modelos, é importante verificar se elas concordam com um conjunto de referência (*ground truth*).

A função `mm.verifyBoundingBox` realiza essa comparação utilizando a métrica **IoU** (*Intersection over Union*), apresentada anteriormente neste capítulo. Para cada caixa delimitadora candidata, a função calcula sua sobreposição com as caixas do gabarito e contabiliza aquelas cujo IoU é superior a um limiar especificado.

No exemplo a seguir, constrói-se um **gabarito sintético** a partir das cinco primeiras caixas delimitadoras obtidas por `mm.measure`. Como as anotações comparadas são as mesmas utilizadas para construir o gabarito, espera-se que cada objeto encontre exatamente uma correspondência com  $\text{IoU} \geq 0,5$ . O objetivo é apenas ilustrar o funcionamento da função `mm.verifyBoundingBox`; em aplicações reais, o gabarito deve ser obtido independentemente, por exemplo, por anotação manual.

```
# Matriz de gabaritos sintética no formato (classe, x1, y1, x2, y2), normalizado
gabaritos = np.array([
    [0, *(m["bbox"][0] + d) / largura_img for d in (0,)],
    (m["bbox"][1]) / altura_img,
    (m["bbox"][0] + m["bbox"][2]) / largura_img,
    (m["bbox"][1] + m["bbox"][3]) / altura_img]
    for m in medidas[:5]
])

acertos = 0
for m in medidas[:5]:
    correspondencias = mm.verifyBoundingBox(
        object_id=0, bbox=m["bbox"], matrix=gabaritos,
        width=largura_img, height=altura_img, threshold=0.5
    )
    acertos += int(correspondencias > 0)
    print(f"Objeto {m['id']}: {correspondencias} gabarito(s) casam com IoU >= 0.5")

print(f"\nTotal de objetos validados: {acertos}/{len(medidas[:5])}")
```

```
Objeto 1: 1 gabarito(s) casam com IoU >= 0.5
Objeto 2: 1 gabarito(s) casam com IoU >= 0.5
Objeto 3: 1 gabarito(s) casam com IoU >= 0.5
Objeto 4: 1 gabarito(s) casam com IoU >= 0.5
Objeto 5: 1 gabarito(s) casam com IoU >= 0.5

Total de objetos validados: 5/5
```

Observa-se que os cinco objetos foram corretamente associados aos respectivos gabaritos, resultando em cinco correspondências válidas. Em aplicações reais, essa mesma estratégia pode ser empregada para comparar automaticamente as caixas delimitadoras produzidas por um detector com anotações de referência, permitindo avaliar quantitativamente seu desempenho por meio da métrica IoU.

### 8.8.7 Visualização de Anotações Salvas: `mm.showBoundingBox`

Após exportar as anotações, é conveniente verificar se as caixas delimitadoras foram gravadas corretamente. Para isso, a biblioteca `morph` disponibiliza a função `mm.showBoundingBox`, ilustrada na Figure 8.14.

A função lê um arquivo de anotações nos formatos `yolo`, `csv` ou `txt`, reconstrói as **caixas delimitadoras** (*bounding boxes*) e as sobrepõe à imagem original, facilitando a inspeção visual do resultado. Dessa forma, torna-se possível confirmar rapidamente se as anotações estão alinhadas aos objetos, sem a necessidade de examiná-las manualmente.

Essa função complementa `mm.verifyBoundingBox`. Enquanto `mm.verifyBoundingBox` realiza uma **validação quantitativa**, comparando as anotações com um conjunto de referência por meio da métrica IoU, `mm.showBoundingBox` fornece uma **validação qualitativa**, permitindo inspecionar visualmente as caixas delimitadoras reconstruídas.

```
caminho_yolo = "moedas.txt"
img_annotada = mm.showBoundingBox(img_moedas, caminho_yolo, fmt="yolo")
```

Bounding boxes (moedas.txt)




Figura 8.14: *Bounding boxes* reconstruídas a partir do arquivo de anotações YOLO exportado por `mm.saveMeasures`, sobrepostas à imagem original das moedas.

#### Por que funciona? — Da Segmentação às Anotações

Após segmentar uma imagem, é possível medir automaticamente cada objeto (`mm.measure`) e converter essas medidas em anotações (`mm.saveMeasures`) para diferentes formatos, incluindo o utilizado pelos detectores da família YOLO. Esse procedimento permite gerar automaticamente conjuntos iniciais de anotações em cenários controlados, reduzindo significativamente o trabalho de rotulação manual.

Antes de utilizar essas anotações no treinamento ou na avaliação de modelos, recomenda-se compará-las com um conjunto de referência (*ground truth*). A função `mm.verifyBoundingBox` automatiza essa etapa por meio da métrica **IoU**, permitindo quantificar a concordância entre as caixas delimitadoras geradas e as anotações de referência. Complementarmente, `mm.showBoundingBox` possibilita uma inspeção visual das anotações reconstruídas sobre a imagem original, facilitando a identificação de erros de normalização, posicionamento ou ordenação das coordenadas que podem não ser evidentes em uma validação apenas numérica.

Em conjunto, `mm.measure`, `mm.saveMeasures`, `mm.verifyBoundingBox` e `mm.showBoundingBox` implementam um fluxo completo para medir objetos segmentados, gerar anotações, avaliá-las e inspecioná-las visualmente. Quando a segmentação produz resultados confiáveis, esse fluxo pode reduzir significativamente a necessidade de rotulação manual na construção de conjuntos de dados.

## 8.9 Visão Geral dos Modelos Modernos

As técnicas apresentadas neste capítulo — como detectores em cascata, segmentação baseada em limiarização e pós-processamento por IoU e NMS — permanecem importantes para compreender os fundamentos da Visão Computacional. Atualmente, entretanto, muitas aplicações utilizam modelos de **Aprendizado Profundo**, capazes de aprender automaticamente representações discriminativas a partir de grandes conjuntos de dados, dispensando a definição manual de características.

A Table 8.2 apresenta algumas arquiteturas representativas para detecção e segmentação de imagens. O objetivo é apenas situá-las no contexto das tarefas estudadas neste capítulo. Seus princípios de funcionamento, treinamento e aplicação serão discutidos em detalhes no **Capítulo 9**.

Tabela 8.2: Arquiteturas representativas de Aprendizado Profundo para detecção e segmentação de imagens.

| Modelo                                     | Tarefa                                   | Ideia central                                                                                                                                                                                                                                                       |
|--------------------------------------------|------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>YOLO</b> ( <i>You Only Look Once</i> )  | Detecção de objetos                      | Detecta objetos em uma única passada pela rede, estimando classes e caixas delimitadoras. Versões recentes, como o <b>YOLO26</b> (2026), eliminam a etapa de <i>Non-Maximum Suppression</i> (NMS), tornando a inferência totalmente <i>end-to-end</i> .             |
| <b>Faster R-CNN</b>                        | Detecção de objetos                      | Gera regiões candidatas e as refina antes da classificação, priorizando precisão.                                                                                                                                                                                   |
| <b>SSD</b> ( <i>Single Shot Detector</i> ) | Detecção de objetos                      | Detecta objetos em diferentes escalas em uma única passada, buscando equilíbrio entre velocidade e precisão.                                                                                                                                                        |
| <b>U-Net</b>                               | Segmentação semântica                    | Produz uma máscara que classifica cada pixel da imagem segundo sua classe.                                                                                                                                                                                          |
| <b>Mask R-CNN</b>                          | Segmentação de instâncias                | Estende o Faster R-CNN acrescentando uma máscara individual para cada objeto detectado.                                                                                                                                                                             |
| <b>Segment Anything (SAM)</b>              | Segmentação orientada por <i>prompts</i> | Segmenta objetos a partir de indicações como pontos, caixas delimitadoras ou máscaras. Evoluiu para o <b>SAM 2</b> , com suporte a vídeo e rastreamento temporal de objetos, e o <b>SAM 3</b> , que permite segmentação guiada diretamente por descrições em texto. |

Observa-se uma evolução das tarefas abordadas neste capítulo. Modelos como **YOLO**, **Faster R-CNN** e **SSD** localizam objetos por meio de caixas delimitadoras. O **Mask R-CNN** amplia essa capacidade ao produzir também uma máscara para cada instância detectada. Já modelos mais recentes, como o **Segment Anything (SAM)**, permitem segmentar objetos a partir de diferentes tipos de *prompts*, tornando o processo mais flexível.

Essa evolução acompanha a sequência de conceitos desenvolvida ao longo do capítulo: da correspondência de características e da localização aproximada por caixas delimitadoras até a segmentação precisa dos pixels pertencentes a cada objeto. No **Capítulo 9**, essas tarefas serão revisitadas sob a perspectiva do Aprendizado Profundo, explorando como redes neurais modernas aprendem automaticamente representações capazes de superar muitas das limitações dos métodos clássicos apresentados aqui.

## 8.10 Limitações das Abordagens Clássicas e Motivação para o *Deep Learning*

Os exemplos desenvolvidos neste capítulo ilustram três problemas fundamentais da Visão Computacional: **correspondência de características**, **detecção de objetos** e **segmentação de imagens**. Embora as técnicas clássicas apresentadas sejam eficientes em diversos cenários, todas compartilham uma limitação importante: baseiam-se em características definidas manualmente para descrever ou identificar os objetos de interesse.

- O **ORB** utiliza descritores binários capazes de estabelecer correspondências entre pontos sob rotações e mudanças moderadas de escala, mas não foi concebido para reconhecer categorias de objetos.
- O **Haar Cascade** emprega um conjunto fixo de filtros retangulares, funcionando bem para objetos com aparência relativamente padronizada, como faces frontais, mas tornando-se mais suscetível a falsos positivos em cenas complexas.
- A **segmentação por limiarização** explora diferenças de intensidade entre objeto e fundo, sendo adequada para imagens com bom contraste, porém limitada diante de variações de iluminação, texturas ou cenas contendo múltiplas classes de objetos.

Em todos esses casos, o desempenho depende da capacidade das características escolhidas representarem adequadamente a variabilidade presente nas imagens. Em aplicações reais, fatores como mudanças de pose, iluminação, escala, oclusões e diversidade de categorias tornam essa tarefa cada vez mais difícil, reduzindo a generalização dos métodos clássicos.

O **Capítulo 9** apresenta uma abordagem diferente para esses problemas por meio das **Redes Neurais Convolucionais (CNNs)**. Em vez de utilizar características definidas manualmente, esses modelos aprendem automaticamente, a partir de grandes conjuntos de dados, representações adequadas para cada tarefa. As arquiteturas modernas apresentadas na seção anterior — como **YOLO**, **Faster R-CNN**, **U-Net**, **Mask R-CNN** e **Segment Anything (SAM)** — seguem esse princípio e representam uma evolução das técnicas clássicas estudadas neste capítulo, ampliando sua capacidade de lidar com a diversidade e a complexidade das imagens do mundo real.

## 8.11 Resumo

Neste capítulo foram estudados métodos clássicos de Visão Computacional para **correspondência de características**, **detecção de objetos** e **segmentação de imagens**. Ao final, foram apresentadas algumas arquiteturas modernas baseadas em Aprendizado Profundo, preparando a transição para o **Capítulo 9**. Os principais conceitos abordados foram:

- **ORB**: detecção de pontos-chave, construção de descritores binários e correspondência de características por meio da distância de Hamming.
- **Homografia e RANSAC**: estimativa robusta de transformações projetivas para registro de imagens e eliminação de correspondências inconsistentes.
- **Haar Cascade**: detecção de objetos utilizando características Haar, imagem integral e classificadores em cascata.
- **Segmentação clássica**: limiarização, operações morfológicas, rotulação de componentes conectados, transformada de distância e algoritmo *watershed* para segmentação de instâncias.
- **Medição e anotação de objetos**: extração de atributos geométricos com `mm.measure`, exportação automática de anotações (`mm.saveMeasures`) e validação por IoU (`mm.verifyBoundingBox`) e inspeção visual (`mm.showBoundingBox`).
- **Avaliação de detecções**: utilização da métrica **Intersection over Union (IoU)** e da **Supressão de Não-Máximos (NMS)**.
- **Modelos modernos**: visão geral das arquiteturas **YOLO**, **Faster R-CNN**, **SSD**, **U-Net**, **Mask R-CNN** e **Segment Anything (SAM)**, que servirão de base para o estudo dos métodos de Aprendizado Profundo no **Capítulo 9**.

## Próximos Passos

Neste capítulo foram apresentados métodos clássicos para resolver problemas de **correspondência de características**, **detecção de objetos** e **segmentação de imagens**, baseados em descritores, filtros e modelos geométricos definidos manualmente.

No **Capítulo 9**, esses mesmos problemas serão revisitados sob a perspectiva do **Aprendizado Profundo**, com ênfase nas **Redes Neurais Convolucionais (CNNs)**. Em vez de utilizar características projetadas manualmente, esses modelos aprendem automaticamente representações a partir de grandes conjuntos de dados, constituindo a base dos principais sistemas modernos de Visão Computacional para detecção, segmentação e reconhecimento de objetos.

## 8.12 Uso do Gemini Notebook como Apoio ao Estudo

O **Gemini Notebook** pode ser utilizado como ferramenta complementar para revisar os conceitos apresentados neste capítulo. A partir do conteúdo disponibilizado como referência, ele permite responder perguntas, elaborar resumos, esclarecer dúvidas e explorar os tópicos de forma interativa.

Acesso ao Notebook do Capítulo



**ACESSAR Gemini Notebook: CAPÍTULO 08**

As respostas geradas pelo Gemini Notebook são produzidas automaticamente e podem conter imprecisões. Utilize-as como material complementar de estudo, confrontando as informações com o conteúdo deste livro e, quando necessário, com outras fontes acadêmicas.

## 8.13 Lista de Exercícios

Os exercícios a seguir consolidam os conceitos apresentados neste capítulo por meio de adaptações, experimentos e extensões dos algoritmos desenvolvidos ao longo do texto, utilizando a biblioteca didática **morph**.

1. (10%) Investigue a influência de rotações na estabilidade do detector e descritor **ORB**. Utilizando a imagem `skimage.data.astronaut()`, gere versões rotacionadas em ângulos de  $0^\circ$ ,  $45^\circ$ ,  $90^\circ$ ,  $135^\circ$ ,  $180^\circ$ . Para cada caso, determine o número de correspondências obtidas pelo **BFMatcher** e a fração de *inliers* identificados pelo **RANSAC**. Apresente os resultados em uma tabela e discuta a robustez do método às rotações analisadas.
2. (15%) Compare o detector de cantos **FAST** com o detector de **Harris** (Capítulo 6). Meça o tempo médio de execução e o número de pontos detectados nas imagens `skimage.data.camera()`, `skimage.data.gravel()` e `skimage.data.brick()`. Discuta as vantagens e limitações de cada detector em termos de velocidade e repetibilidade.
3. (15%) Investigue a sensibilidade do **Haar Cascade** à presença de ruído e desfoque. Adicione ruído gaussiano ( $\sigma \in 5, 10, 20$ ) e desfoque de movimento à imagem `skimage.data.astronaut()`. Varie os parâmetros `scaleFactor` e `minNeighbors` da função `detectMultiScale()` e discuta os efeitos sobre falsos positivos, falsos negativos e número de faces detectadas.
4. (15%) Implemente manualmente a métrica **Intersection over Union (IoU)** para caixas delimitadoras e compare seus resultados com a função `mm.IoU`. Em seguida, crie uma caixa de referência e dez caixas obtidas por deslocamentos e variações de escala, construindo um gráfico que relacione o deslocamento aplicado com o valor de IoU obtido.
5. (15%) Avalie o algoritmo de **Supressão de Não-Máximos (NMS)**. Crie uma cena sintética contendo três objetos, cada um representado por pelo menos cinco caixas sobrepostas com diferentes pontuações de confiança. Execute o algoritmo para limiares de IoU iguais a 0.2, 0.4, 0.6, 0.8, visualize os resultados e discuta a influência desse parâmetro na quantidade de caixas mantidas.



6. **(15%)** Aplique o pipeline de segmentação apresentado neste capítulo (limiarização de Otsu, operações morfológicas e `mm.measure`) à imagem `skimage.data.coins()`. Exporte as medidas utilizando `mm.saveMeasures(fmt="csv")` e produza histogramas das distribuições de área, circularidade e solidez. Discuta quais desses atributos são mais adequados para caracterizar as moedas.
7. **(15%)** Construa uma imagem sintética contendo círculos, retângulos e triângulos, alguns parcialmente sobrepostos. Realize a segmentação, extraia as medidas com `mm.measure` e gere automaticamente as anotações no formato YOLO utilizando `mm.saveMeasures(fmt="yolo")`. Em seguida, modifique deliberadamente algumas *bounding boxes* e utilize `mm.verifyBoundingBox` para avaliar, em diferentes limiares de IoU, quantas anotações permanecem válidas. Discuta a influência da sobreposição entre objetos na qualidade das anotações obtidas.
8. **(Bônus – 10%)** Desenvolva um classificador simples, como **k-NN** (Capítulo 7), utilizando apenas os atributos geométricos produzidos por `mm.measure` (área, circularidade, solidez e número de vértices). Utilize um conjunto de formas sintéticas (círculos, retângulos e triângulos) com diferentes escalas e rotações, avalie a acurácia obtida e discuta a capacidade desses descritores em distinguir diferentes classes de objetos.

## Referências do Capítulo

Os conceitos e algoritmos apresentados neste capítulo foram fundamentados em referências clássicas e contemporâneas da literatura de PDI-VC:

- Gonzalez; Woods (2018), para os fundamentos de segmentação de imagens, operações morfológicas, rotulação de componentes conexos e extração de atributos geométricos.
- Szeliski (2022), para os conceitos de correspondência de características, transformações geométricas, homografias, detecção de objetos e segmentação em Visão Computacional.
- ([rublee2011orb?](#)), para a descrição do algoritmo **ORB** (*Oriented FAST and Rotated BRIEF*), utilizado na detecção, descrição e correspondência de características locais.
- ([fischler1981random?](#)), para a formulação original do algoritmo **RANSAC** (*Random Sample Consensus*), empregado na estimação robusta de modelos geométricos na presença de dados inconsistentes.
- Viola; Jones (2001), Viola; Jones (2004) e Lienhart; Maydt (2002), para os fundamentos do detector **Haar Cascade**, incluindo características de Haar, imagem integral, classificadores em cascata e extensões utilizadas em implementações modernas.
- ([kirillov2019panoptic?](#)), para a definição da **segmentação panóptica**, que integra segmentação semântica e segmentação de instâncias em uma única representação.
- Redmon et al. (2016), Ren et al. (2015), Ronneberger; Fischer; Brox (2015), ([he2017mask?](#)) e Kirillov et al. (2023), para modelos modernos baseados em Aprendizado Profundo aplicados à detecção e segmentação de imagens, incluindo **YOLO**, **Faster R-CNN**, **U-Net**, **Mask R-CNN** e **Segment Anything (SAM)**.



### 8.14 Parte Prática com Exercícios de Programação

A presente lista de exercícios de programação (EP) consolida as formulações teóricas apresentadas ao longo do Capítulo 8 — Correspondência de Características, Detecção de Objetos e Segmentação Clássica — por meio de uma trilha prática aplicada. Assim como no capítulo anterior, os EPs isolam as **grandezas intermediárias** de cada técnica — a distância entre descritores binários, os termos de uma imagem integral, a contagem de *inliers* de um modelo candidato, a sobreposição entre caixas delimitadoras e o rótulo de cada componente conectado — permitindo validar manualmente cada etapa do raciocínio sem depender do OpenCV nem de imagens externas.

O encadeamento dos exercícios reproduz o fluxo conceitual do capítulo: inicia-se com a **distância de Hamming**, coração da correspondência de descritores binários como o ORB; avança-se para a contagem de **inliers** que sustenta o **RANSAC** na estimação robusta de uma homografia; prossegue-se com a **imagem integral**, o truque computacional que torna o **Haar Cascade** viável em tempo real; aprofunda-se em **IoU** e **Supressão de Não-Máximos**, o pós-processamento comum a praticamente todo detector de objetos; e conclui-se com a **rotulação de componentes conectados**, a abordagem clássica — e suas limitações — para segmentar instâncias individuais em uma máscara binária.

## 🎯 Objetivo deste Caderno

O caderno permite desenvolver, validar, organizar e testar soluções de **Exercícios de Programação (EPs)** em ambientes interativos, como o Colab, com os mesmos casos de teste do Moodle, copiando para lá apenas na hora de registrar a nota oficial.

## Download

Baixe `morph.py` e `testsuite.py` executando a célula abaixo:

```
import os, sys, importlib, inspect, urllib.request

# URLs do repositório
BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph"
for f in ["morph.py", "testsuite.py"]:
    if not os.path.exists(f):
        urllib.request.urlretrieve(f"{BASE_URL}/{f}", f)

import morph, testsuite
importlib.reload(morph); importlib.reload(testsuite)
from morph import mm
from testsuite import TestSuite

print(f" Ambiente pronto. Morph: {morph.__version__} | TestSuite: {testsuite.__version__}")
```

Ambiente pronto. Morph: 1.1.7 | TestSuite: 1.1.2

## Executando os Testes

Para avaliar os testes, execute `TestSuite("EP08_01.extensão").run()` numa nova célula, trocando a extensão pela da linguagem usada (`.py`, `.java`, `.c`, `.cpp`, `.js` ou `.r`). O sistema baixa os casos de teste do GitHub, executa o programa e calcula a nota automaticamente.

Para testar código Python diretamente, sem salvar arquivo, use `run_code(codigo)` passando o código como *string* numa variável `codigo`:

```
codigo = """
# ... seu código aqui ...
"""

TestSuite("EP08_01").run_code(codigo)
```

## Resumo dos Métodos do `morph.py` (Cap. 8)

A biblioteca `morph.py` disponibiliza funções para análise de componentes conexos, extração de contornos, métricas geométricas e anotações:

1. **Componentes e Contornos** (`connectedComponents`, `findContours`) Rotulam regiões conexas e extraem os contornos de imagens binárias.
2. **Propriedades do Contorno** (`contourArea`, `arcLength`, `convexHull`, `approxPolyDP`, `fitLine`) Calculam área, perímetro, fecho convexo, aproximação poligonal e ajuste de reta para um contorno.

3. **Geometria Envolvente** (`boundingRect`, `minAreaRect`, `boxPoints`, `minEnclosingCircle`, `fitEllipse`) Determinam retângulos envolventes (alinhados ou orientados), elipses e o menor círculo delimitador.
4. **Extração e Persistência de Medidas** (`measure`, `saveMeasures`) Extraem descritores geométricos dos objetos (área, circularidade, solidez, centroide) e exportam os dados para CSV, texto ou formato YOLO.
5. **Avaliação e Visualização** (`IoU`, `verifyBoundingBox`, `showBoundingBox`) Calculam a intersecção sobre união (*Intersection over Union*), validam bounding boxes com gabaritos e desenhavam caixas delimitadoras anotadas sobre a imagem.

### 8.14.1 EP08\_01 ● Distância de Hamming e Correspondência de Descritores Binários

O ORB, usado no Projeto Prático 1 deste capítulo, descreve a vizinhança de cada ponto de interesse como uma sequência de bits — e, por isso, a comparação entre dois descritores não usa a distância euclidiana do k-NN do Capítulo 7, e sim a **distância de Hamming**: o número de posições em que os bits diferem. Antes de chamar `cv2.BFMatcher(cv2.NORM_HAMMING)`, você foi encarregado de implementar manualmente essa correspondência (*matching*) por força bruta — a mesma etapa que, executada internamente pelo OpenCV, precede a estimação robusta da homografia por RANSAC.

#### 8.14.1.1 📋 Diretrizes de Implementação

1. **Quantidades:** Ler os inteiros  $N$  e  $M$  — número de descritores extraídos da imagem A e da imagem B, respectivamente.
2. **Descritores de A:** Ler  $N$  linhas, cada uma contendo um descritor binário (uma *string* de caracteres 0 e 1, todos do mesmo comprimento).
3. **Descritores de B:** Ler  $M$  linhas, no mesmo formato.
4. **Limiar:** Ler o inteiro  $\tau$  — distância de Hamming máxima aceitável para considerar uma correspondência válida.
5. **Distância de Hamming:** Para dois descritores binários  $a$  e  $b$  de mesmo comprimento,

$$d_H(a, b) = \sum_k \mathbb{1}[a_k \neq b_k],$$

ou seja, a contagem de posições em que os bits diferem.

6. **Correspondência por vizinho mais próximo:** Para cada descritor  $a_i$  de A ( $i$  na ordem de leitura, começando em 0), calcule sua distância de Hamming a **todos** os descritores de B e encontre o de menor distância. Em caso de empate entre dois ou mais descritores de B com a mesma distância mínima, escolha o de **menor índice**.
7. **Filtragem pelo limiar:** Se a menor distância encontrada for  $\leq \tau$ , a correspondência é válida; caso contrário,  $a_i$  não possui correspondência.
8. **Saída:** Para cada  $i$  de 0 a  $N - 1$ , na ordem de leitura, imprimir uma linha: `i j d` se houver correspondência válida (onde  $j$  é o índice do descritor de B escolhido e  $d$  sua distância), ou `i -1` caso contrário. Ao final, imprimir **Total correspondências válidas: X**.

#### 8.14.1.2 📌 Restrições Computacionais

- **Mesmo comprimento:** todos os descritores (de A e de B) têm exatamente o mesmo número de bits.
- **Força bruta:** compare cada descritor de A a **todos** os de B — não é necessário nenhum tipo de indexação ou estrutura de aceleração.
- **Desempate por menor índice em B, e nunca por ordem de leitura de A** (que já é natural, pois cada  $a_i$  é tratado de forma independente).

#### 8.14.1.3 🧠 Fundamentação Teórica

| Elemento                  | Papel na correspondência ORB                                                                                                                                                      |
|---------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Descritor binário (BRIEF) | Cada bit é o resultado de uma comparação de intensidade entre dois pixels da vizinhança                                                                                           |
| Distância de Hamming      | Métrica de dissimetria entre <i>strings</i> binárias; muito mais rápida de calcular que a distância euclidiana (operação XOR + contagem de bits)                                  |
| Vizinho mais próximo      | Critério de correspondência: cada ponto de A é pareado ao ponto de B com descritor mais similar                                                                                   |
| Limiar $\tau$             | Filtra correspondências pouco confiáveis antes mesmo do RANSAC — mas, como discutido no capítulo, algumas correspondências incorretas ainda passam, exigindo a robustez do RANSAC |

#### 8.14.1.4 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: Inteiros  $N$  e  $M$ .
- Próximas  $N$  linhas: um descritor binário por linha (*string* de 0s e 1s).
- Próximas  $M$  linhas: um descritor binário por linha, no mesmo formato.
- Última linha: Inteiro  $\tau$ .

##### Saída:

- $N$  linhas, uma por descritor de A, no formato  $i \ j \ d$  ou  $i \ -1$ .
- Última linha: Total correspondências válidas:  $X$ .

#### 8.14.1.5 Exemplos

| Entrada  | Saída                             | Observação                                                                                                                   |
|----------|-----------------------------------|------------------------------------------------------------------------------------------------------------------------------|
| 3 3      | 0 0 1                             | O descritor 11110000 não encontra correspondência: seu vizinho mais próximo está a distância 4, acima do limiar $\tau = 2$ . |
| 10101010 | 1 -1                              |                                                                                                                              |
| 11110000 | 2 1 1                             |                                                                                                                              |
| 00001111 | Total correspondências válidas: 2 |                                                                                                                              |
| 10101011 |                                   |                                                                                                                              |
| 00001110 |                                   |                                                                                                                              |
| 11111111 |                                   |                                                                                                                              |
| 2        |                                   |                                                                                                                              |

```
%%writefile EP08_01.py
# Código Python
```

```
Writing EP08_01.py
```

```
TestSuite("EP08_01.py").run()
```

#### 8.14.2 EP08\_02 Homografia e RANSAC: A Votação por *Inliers*

O RANSAC, apresentado na seção “Modelagem Matemática: Homografia e RANSAC”, repete um ciclo de três passos — sortear uma amostra mínima, estimar um modelo candidato, e contar quantas correspondências são consistentes com ele (os *inliers*) — mantendo ao final o modelo mais votado. A etapa de estimação do modelo a partir de 4 pontos (passo 2) envolve álgebra linear que foge ao escopo deste EP; aqui, você




Figura 8.15: Simulador: Distância de Hamming entre Dois Descritores Binários

recebe diretamente um conjunto de homografias **já candidatas** — como se cada uma tivesse sido estimada a partir de uma amostra aleatória diferente — e é encarregado de reproduzir exatamente o passo decisivo do algoritmo: **aplicar cada modelo a todas as correspondências e contar seus *inliers***, escolhendo o vencedor.

#### 8.14.2.1 Diretrizes de Implementação

1. **Correspondências:** Ler o inteiro  $N$  e, em seguida,  $N$  linhas com quatro reais cada,  $x \ y \ x' \ y'$  — um ponto da imagem A e seu correspondente (possivelmente incorreto) na imagem B, exatamente como produzido pela etapa de *matching* do EP08\_01.
2. **Modelos candidatos:** Ler o inteiro  $K$  (número de homografias candidatas) e o real  $\varepsilon$  (limiar de erro de reprojeção). Em seguida, ler  $K$  linhas, cada uma com nove reais  $h_{11} \ h_{12} \ h_{13} \ h_{21} \ h_{22} \ h_{23} \ h_{31} \ h_{32} \ h_{33}$  — os elementos da matriz  $H$  candidata, em ordem de leitura por linha (*row-major*).
3. **Reprojeção:** Para cada correspondência  $(x, y, x', y')$  e cada modelo candidato  $H_k$ , calcular o ponto projetado

$$\begin{bmatrix} \hat{x} \\ \hat{y} \\ \hat{w} \end{bmatrix} = H_k \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}, \quad (\hat{x}/\hat{w}, \hat{y}/\hat{w}) \text{ é o ponto projetado.}$$

4. **Erro de reprojeção:**  $e = \sqrt{(\hat{x}/\hat{w} - x')^2 + (\hat{y}/\hat{w} - y')^2}$ .
5. **Contagem de *inliers*:** Uma correspondência é um *inlier* do modelo  $H_k$  se  $e \leq \varepsilon$ .
6. **Seleção do melhor modelo:** O modelo vencedor é o de maior número de *inliers*; em caso de empate, escolha o de **menor índice**  $k$  (o primeiro encontrado durante o ciclo iterativo do RANSAC).
7. **Saída:** Para cada modelo  $k$  de 0 a  $K - 1$ , na ordem de leitura, imprimir **Modelo k: I inliers**. Ao final, imprimir **Melhor modelo: k\_best com I\_best inliers**.

#### 8.14.2.2 Restrições Computacionais

- **Comparação inclusiva:** um erro de reprojeção **exatamente igual** a  $\varepsilon$  conta como *inlier* ( $e \leq \varepsilon$ ).
- **Sem estimação de  $H$ :** as matrizes já são fornecidas prontas — não é necessário (nem esperado) resolver nenhum sistema linear.
- **Empate resolvido pelo menor índice**, refletindo o comportamento natural de um algoritmo iterativo que percorre os modelos em ordem e só substitui o melhor encontrado até então quando um novo modelo o **supera estritamente**.

#### 8.14.2.3 Fundamentação Teórica

| Elemento                         | Papel no RANSAC                                                                                                                                  |
|----------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------|
| Amostra mínima (4 pares)         | Suficiente para determinar os 8 graus de liberdade de uma homografia                                                                             |
| Modelo candidato $H_k$           | Estimado a partir de uma amostra mínima; pode ser bom ou ruim, dependendo se a amostra continha <i>outliers</i>                                  |
| Erro de reprojeção               | Mede o quão bem o modelo “prevê” cada correspondência observada                                                                                  |
| <i>Inlier</i> vs. <i>outlier</i> | Correspondências consistentes com o modelo vencedor ( <i>inliers</i> ) vs. as demais, tipicamente correspondências incorretas do <i>matching</i> |
| Refinamento final                | Na prática, após escolher o melhor modelo, o RANSAC o recalcula usando <b>apenas</b> seus <i>inliers</i> — passo não exigido neste EP            |

#### 8.14.2.4 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: Inteiro  $N$ .
- Próximas  $N$  linhas: quatro reais  $x \ y \ x' \ y'$ .
- Próxima linha: Inteiro  $K$  e real  $\varepsilon$ .
- Próximas  $K$  linhas: nove reais (elementos de  $H_k$ , *row-major*).

##### Saída:

- $K$  linhas no formato Modelo k: I inliers.
- Última linha: Melhor modelo: k\_best com I\_best inliers.

#### 8.14.2.5 Exemplos

| Entrada           | Saída                          | Observação                                                                                                                                                                      |
|-------------------|--------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 5                 | Modelo 0: 4 inliers            | O Modelo 0 (escala $\times 2$ ) explica corretamente 4 das 5 correspondências; a 5ª, $(5, 5) \rightarrow (1, 1)$ , é um <i>outlier</i> que nenhum dos dois modelos explica bem. |
| 0 0 0 0           | Modelo 1: 1 inliers            |                                                                                                                                                                                 |
| 1 1 2 2           | Melhor modelo: 0 com 4 inliers |                                                                                                                                                                                 |
| 2 0 4 0           |                                |                                                                                                                                                                                 |
| 0 2 0 4           |                                |                                                                                                                                                                                 |
| 5 5 1 1           |                                |                                                                                                                                                                                 |
| 2 0.5             |                                |                                                                                                                                                                                 |
| 2 0 0 0 2 0 0 0 1 |                                |                                                                                                                                                                                 |
| 1 0 0 0 1 0 0 0 1 |                                |                                                                                                                                                                                 |

```
%%writefile EP08_02.py
# Código Python
```

```
Writing EP08_02.py
```

```
TestSuite("EP08_02.py").run()
```






Figura 8.16: Simulador: RANSAC — Votação por Inliers entre Modelos Candidatos

### 8.14.3 EP08\_03 ● Imagem Integral: Somas Retangulares em Tempo Constante

Imagine uma câmera de segurança processando 30 quadros por segundo, e para cada quadro o sistema precisa varrer a imagem em dezenas de posições e escalas diferentes, testando em cada uma um conjunto de características retangulares para decidir “há um rosto aqui?”. Se calcular a soma de intensidades de cada retângulo exigisse somar pixel a pixel, o sistema não teria a menor chance de rodar em tempo real — o gargalo estaria justamente na parte mais repetida do algoritmo. É exatamente esse gargalo que a imagem integral elimina.

O Haar Cascade avalia milhares de características retangulares por janela, em múltiplas posições e escalas — algo inviável em tempo real se cada retângulo exigisse somar seus pixels um a um. A **imagem integral**, definida na seção sobre Haar Cascade, resolve esse problema: uma vez pré-computada, a soma de intensidades de **qualquer** região retangular é obtida com apenas quatro consultas e três operações aritméticas, independentemente do tamanho do retângulo.

Você foi encarregado de implementar essa estrutura do zero: primeiro, calcular a imagem integral a partir da imagem original; em seguida, respondê-la para consultas retangulares arbitrárias.

#### 8.14.3.1 📋 Diretrizes de Implementação

1. **Entrada:** Ler as dimensões  $H \times W$  da imagem e seus  $H \times W$  valores inteiros de intensidade.
2. **Imagem integral:** Calcular, para cada posição  $(i,j)$  (indexação a partir de 0, [linha][coluna]),

$$II(i,j) = \sum_{i' \leq i, j' \leq j} I(i',j'),$$

ou seja, a soma de todos os pixels acima e à esquerda de  $(i,j)$ , incluindo a própria posição.

3. **Consultas:** Ler o inteiro  $Q$  e, em seguida,  $Q$  linhas, cada uma com quatro inteiros  $x_1 \ y_1 \ x_2 \ y_2$  — os cantos superior-esquerdo e inferior-direito de um retângulo, **ambos inclusivos**, com  $0 \leq x_1 \leq x_2 < W$  e  $0 \leq y_1 \leq y_2 < H$ .
4. **Soma retangular em  $O(1)$ :** Para cada consulta, calcular a soma de intensidades dentro do retângulo usando exclusivamente valores já presentes em  $II$  (sem percorrer os pixels originais):

$$S(x_1, y_1, x_2, y_2) = II(y_2, x_2) - II(y_2, x_1 - 1) - II(y_1 - 1, x_2) + II(y_1 - 1, x_1 - 1),$$

tratando qualquer termo com índice de linha ou coluna igual a  $-1$  como 0.

5. **Saída:** Primeiro, imprimir a imagem integral completa —  $H$  linhas com  $W$  inteiros cada. Em seguida, para cada consulta, imprimir um único inteiro: a soma da região correspondente.

### 8.14.3.2 Restrições Computacionais

- **Não recalcule por força bruta:** a resposta a cada consulta deve usar a fórmula de quatro termos sobre  $II$ , não uma soma direta dos pixels do retângulo (ainda que o resultado numérico seja o mesmo, o objetivo do exercício é justamente essa técnica).
- **Retângulos com coordenadas inclusivas:**  $(x_1, y_1)$  e  $(x_2, y_2)$  pertencem à região somada.
- **Tratamento de borda:** ao consultar  $II$  com índice  $-1$  (quando  $x_1 = 0$  ou  $y_1 = 0$ ), utilize o valor 0.

### 8.14.3.3 Fundamentação Teórica

| Elemento                       | Papel no Haar Cascade                                                                                                                            |
|--------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------|
| Imagem integral $II$           | Pré-computada uma única vez por imagem, em tempo $O(HW)$                                                                                         |
| Consulta em $O(1)$             | Cada característica Haar (diferença entre somas de regiões retangulares) é avaliada com poucas operações, independentemente da área do retângulo |
| Escalabilidade                 | É essa constância que viabiliza avaliar milhares de características, em múltiplas posições e escalas, em tempo real                              |
| Princípio de inclusão-exclusão | Os quatro termos da fórmula somam a região desejada e subtraem exatamente as áreas contadas em excesso                                           |

### 8.14.3.4 Especificação de Entrada e Saída (VPL)

#### Entrada:

- Linha 1: Inteiros  $H$  e  $W$ .
- Próximas  $H$  linhas:  $W$  inteiros cada (imagem original).
- Próxima linha: Inteiro  $Q$ .
- Próximas  $Q$  linhas: quatro inteiros  $x_1$   $y_1$   $x_2$   $y_2$ .

#### Saída:

- $H$  linhas com  $W$  inteiros cada (a imagem integral).
- $Q$  linhas, uma por consulta, com a soma da região correspondente.

### 8.14.3.5 Exemplos

| Entrada                                                                                                     | Saída                                                                                  | Observação                                                                                                                                                                                                                                   |
|-------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 3 3<br>1 2 3<br>4 5 6<br>7 8 9<br>1<br>0 0 2 2<br>3 3<br>1 2 3<br>4 5 6<br>7 8 9<br>2<br>1 1 2 2<br>0 0 1 1 | 1 3 6<br>5 12 21<br>12 27 45<br>45<br><br><br>1 3 6<br>5 12 21<br>12 27 45<br>28<br>12 | A consulta cobre a imagem inteira; a soma coincide com $II(2, 2)$ e com a soma de todos os 9 valores.<br><br><br>A primeira consulta usa os quatro termos da fórmula; a segunda coincide diretamente com $II(1, 1)$ , pois começa na origem. |




Figura 8.17: Simulador: Soma Retangular em  $O(1)$  — Múltiplas Situações de Borda

```
%%writefile EP08_03.py
# Código Python
```

```
Writing EP08_03.py
```

```
TestSuite("EP08_03.py").run()
```

#### 8.14.4 EP08\_04 IoU e Supressão de Não-Máximos (NMS)

A figura desta seção mostrou o efeito da Supressão de Não-Máximos sobre um conjunto de caixas produzidas por um detector do tipo *sliding window*: múltiplas detecções redundantes por objeto foram reduzidas a uma única caixa por objeto. Você foi encarregado de reimplementar, byte a byte, as duas funções que produziram aquele resultado — `calcular_iou` e `supressao_ao_maximos` — para confirmar, com suas próprias mãos, exatamente os números que o capítulo apresentou.

##### 8.14.4.1 Diretrizes de Implementação

1. **Entrada:** Ler o inteiro  $N$  (número de caixas) e o real  $\tau$  (limiar de IoU). Em seguida, ler  $N$  linhas, cada uma com cinco reais  $x_{min}$   $y_{min}$   $x_{max}$   $y_{max}$  `score`.
2. **Interseção sobre União:** Para duas caixas  $A$  e  $B$ ,

$$\text{IoU}(A, B) = \frac{\text{área}(A \cap B)}{\text{área}(A \cup B)},$$

com área de interseção nula quando as caixas não se sobrepõem.

3. **Algoritmo de NMS** (exatamente como descrito no capítulo):
  - a. Ordene as caixas por `score` decrescente (empates mantêm a ordem de leitura original).
  - b. Selecione a caixa de maior pontuação entre as restantes; adicione-a à saída e remova-a da lista.
  - c. Descarte, da lista restante, **todas** as caixas cujo IoU com a caixa selecionada seja **maior ou igual** a  $\tau$  — apenas as caixas com  $\text{IoU} < \tau$  permanecem candidatas.
  - d. Repita (b)–(c) até que a lista de restantes esteja vazia.
4. **Saída:** Para cada caixa mantida, na ordem em que foi selecionada, imprimir seu índice original (posição de leitura, a partir de 0) e seu `score`, com 2 casas decimais. Ao final, imprimir **Total mantidas: X**.

##### 8.14.4.2 Restrições Computacionais

- **Atenção ao sentido do limiar:** ao contrário do que se poderia supor, uma caixa é **suprimida** quando  $\text{IoU} \geq \tau$  (não apenas quando  $\text{IoU} > \tau$ ) — siga exatamente esse critério, o mesmo do código de referência do capítulo.
- **Índices originais:** a saída referencia a posição de leitura de cada caixa na entrada, não sua posição após a ordenação por `score`.
- **Área sem soma de 1 pixel:** use  $\text{área} = (x_{max} - x_{min}) \times (y_{max} - y_{min})$ , exatamente como no capítulo (sem o ajuste “+1” às vezes usado em outras convenções).

##### 8.14.4.3 Fundamentação Teórica

| Elemento | Papel no pós-processamento                                         |
|----------|--------------------------------------------------------------------|
| IoU      | Quantifica a sobreposição espacial entre duas caixas delimitadoras |

| Elemento                             | Papel no pós-processamento                                                                                        |
|--------------------------------------|-------------------------------------------------------------------------------------------------------------------|
| <i>Sliding window</i> (Haar Cascade) | Produce tipicamente várias detecções sobrepostas para o mesmo objeto, em posições e escalas próximas              |
| Limiar $\tau$                        | Controla a agressividade da supressão: baixo demais funde objetos próximos; alto demais deixa passar redundâncias |
| Ordenação por <b>score</b>           | Garante que, entre caixas redundantes, a de maior confiança sempre sobrevive                                      |

8.14.4.4 📦 Especificação de Entrada e Saída (VPL)

Entrada:

- Linha 1: Inteiro  $N$  e real  $\tau$ .
- Próximas  $N$  linhas: cinco reais  $x_{min}$   $y_{min}$   $x_{max}$   $y_{max}$  **score**.

Saída:

- Uma linha por caixa mantida, na ordem de seleção: **índice** **score** (score com 2 casas decimais).
- Última linha: **Total mantidas: X**.

8.14.4.5 📌 Exemplos

| Entrada              | Saída             | Observação                                                                                                                                                                                |
|----------------------|-------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 5 0.4                | 3 0.95            | Exatamente o exemplo da figura do capítulo: 5 caixas redundantes (2 objetos) tornam-se 2 detecções finais. O IoU entre a 1ª e a 2ª caixas é $\approx 0,775$ , bem acima de $\tau = 0,4$ . |
| 50 50 150 150 0.90   | 0 0.90            |                                                                                                                                                                                           |
| 60 55 155 145 0.75   | Total mantidas: 2 |                                                                                                                                                                                           |
| 58 60 160 150 0.60   |                   |                                                                                                                                                                                           |
| 300 300 400 420 0.95 |                   |                                                                                                                                                                                           |
| 310 305 395 415 0.70 |                   |                                                                                                                                                                                           |



Figura 8.18: Simulador: IoU e Supressão de Não-Máximos

```
%%writefile EP08_04.py
# Código Python
```

```
Writing EP08_04.py
```

```
TestSuite("EP08_04.py").run()
```

### 8.14.5 EP08\_05 Rotulação de Componentes Conectados: Segmentação de Instâncias

O exemplo de segmentação clássica deste capítulo separou “instâncias” de moedas simplesmente pela sua desconexão espacial na máscara binária resultante da limiarização de Otsu. Essa etapa final — rotular cada componente conectado com um identificador de instância — é exatamente o que você foi encarregado de implementar aqui, do zero, sobre uma máscara binária já pronta (0 = fundo, 1 = objeto), como se fosse uma reimplementação manual de `cv2.connectedComponents`.

Este exercício também expõe, de forma muito concreta, a limitação discutida no capítulo: o resultado depende inteiramente de como se define “vizinhança” entre pixels — e, como você verá no segundo exemplo, dois pixels em diagonal podem ser considerados a mesma instância ou instâncias diferentes, dependendo exclusivamente da **conectividade** escolhida, não de qualquer noção semântica de objeto.

#### 8.14.5.1 Diretrizes de Implementação

1. **Entrada:** Ler as dimensões  $H \times W$  da máscara binária e seus  $H \times W$  valores (0 ou 1).
2. **Conectividade:** Ler o inteiro  $c \in \{4, 8\}$ . Na conectividade 4, os vizinhos de  $(i, j)$  são  $(i-1, j)$ ,  $(i+1, j)$ ,  $(i, j-1)$  e  $(i, j+1)$ . Na conectividade 8, somam-se as quatro diagonais:  $(i-1, j-1)$ ,  $(i-1, j+1)$ ,  $(i+1, j-1)$  e  $(i+1, j+1)$ .
3. **Descoberta de componentes:** Percorrendo a máscara em varredura linha a linha, da esquerda para a direita e de cima para baixo, sempre que um pixel de valor 1 ainda sem rótulo for encontrado, ele inicia um **novo componente**: atribua a ele o próximo rótulo disponível (o primeiro componente descoberto recebe o rótulo 1, o segundo o rótulo 2, e assim por diante) e propague esse mesmo rótulo a todos os pixels de valor 1 alcançáveis a partir dele por uma cadeia de vizinhos (de acordo com a conectividade escolhida) — por busca em largura, profundidade, ou *union-find*, à sua escolha.
4. **Pixels de fundo:** permanecem com rótulo 0 e não pertencem a nenhuma instância.
5. **Saída:** Primeiro, imprimir o mapa de rótulos completo —  $H$  linhas com  $W$  inteiros cada. Em seguida, para cada rótulo  $\ell$  de 1 a  $K$  (na ordem de descoberta), imprimir **Instância 1: A pixels**, onde  $A$  é a quantidade de pixels com aquele rótulo. Por fim, imprimir **Total de instâncias: K**.

#### 8.14.5.2 Restrições Computacionais

- **Ordem de descoberta = ordem de varredura:** os rótulos são numerados na ordem em que cada novo componente é encontrado pela varredura linha a linha, não por tamanho ou posição.
- **Conectividade explícita:** dois pixels de valor 1 só pertencem à mesma instância se existir uma cadeia de vizinhos **de acordo com**  $c$  ligando um ao outro — não use a conectividade oposta por engano.
- **Máscara binária pura:** todos os valores de entrada são exatamente 0 ou 1.

#### 8.14.5.3 Fundamentação Teórica

| Elemento                    | Papel na segmentação clássica de instâncias                                                                                               |
|-----------------------------|-------------------------------------------------------------------------------------------------------------------------------------------|
| Limiarização (Otsu, Cap. 4) | Etapa anterior que produz a máscara binária a partir da imagem de intensidade                                                             |
| Componente conectado        | Cada instância é definida <b>apenas</b> por conectividade espacial dos pixels de objeto, sem qualquer noção de forma, classe ou aparência |



| Elemento              | Papel na segmentação clássica de instâncias                                                                                                                          |
|-----------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Conectividade 4 vs. 8 | Parâmetro que altera o resultado: sob conectividade 8, dois blobs unidos apenas na diagonal tornam-se uma única instância                                            |
| Limitação central     | A técnica funde instâncias que se tocam ou se sobrepõem (mesmo que sejam objetos claramente distintos), pois não há noção de “objeto” — apenas de “região conectada” |

#### 8.14.5.4 Especificação de Entrada e Saída (VPL)

##### Entrada:

- Linha 1: Inteiros  $H$  e  $W$ .
- Próximas  $H$  linhas:  $W$  inteiros (0 ou 1) cada.
- Última linha: Inteiro  $c$  (4 ou 8).

##### Saída:

- $H$  linhas com  $W$  inteiros cada (o mapa de rótulos).
- Uma linha por instância, na ordem de descoberta: **Instância 1: A pixels.**
- Última linha: **Total de instâncias: K.**

#### 8.14.5.5 Exemplos

| Entrada                                                                                          | Saída                                                                                                                                                              | Observação                                                                                                                                                                                                                                               |
|--------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 6 6<br>0 0 0 0 0<br>0 1 1 0 0 0<br>0 1 1 0 0 0<br>0 0 0 0 0 0<br>0 0 0 0 1 1<br>0 0 0 0 1 1<br>8 | 0 0 0 0 0 0<br>0 1 1 0 0 0<br>0 1 1 0 0 0<br>0 0 0 0 0 0<br>0 0 0 0 2 2<br>0 0 0 0 2 2<br>Instância 1: 4 pixels<br>Instância 2: 4 pixels<br>Total de instâncias: 2 | Dois blocos $2 \times 2$ claramente separados: o resultado é o mesmo sob conectividade 4 ou 8.                                                                                                                                                           |
| 2 2<br>1 0<br>0 1<br>8                                                                           | 1 0<br>0 1<br>Instância 1: 2 pixels<br>Total de instâncias: 1                                                                                                      | Sob conectividade 8, os dois pixels em diagonal pertencem à <b>mesma</b> instância. Repita este exemplo com $c = 4$ : o resultado passa a ser 2 instâncias de 1 pixel cada — puramente pela mudança de conectividade, sem qualquer diferença na máscara. |

```
%%writefile EP08_05.py
# Código Python
```

```
Overwriting EP08_05.py
```

```
TestSuite("EP08_05.py").run()
```




Figura 8.19: Simulador: Rotulação de Componentes Conectados — Conectividade 4 vs. 8

#### 8.14.6 EP08\_06 ● Segmentação de Instâncias em Imagem Real: Objetos Geométricos

O exemplo de segmentação clássica deste capítulo separou “instâncias” de moedas por desconexão espacial na máscara binária resultante da limiarização de Otsu. Neste exercício você vai aplicar a mesma ideia — mas agora sobre uma imagem real com objetos geométricos variados — encadeando pré-processamento, binarização, extração de contornos (`cv2.findContours`) e validação do resultado contra um gabarito de *bounding boxes*.

Diferente do exercício anterior (rotulação sobre máscara já pronta), aqui você parte da **imagem original**: a qualidade da sua segmentação depende diretamente das escolhas de pré-processamento (filtragem, limiarização, operações morfológicas) feitas antes de rotular os componentes.

##### 8.14.6.1 📋 Diretrizes de Implementação

1. **Entrada:** utilizar a imagem `00000.jpg`.
2. **Pré-processamento e segmentação:** aplicar as etapas necessárias (filtragem, binarização e operações morfológicas) para separar automaticamente os objetos do fundo, sem recortes manuais.
3. **Rotulação e medição:** para cada objeto segmentado, determinar:
  - área;
  - centro de massa (centroide);
  - tipo, conforme o conjunto `obj2`.
4. **Anotação visual:** escrever, no interior de cada objeto, sua área e a sigla do tipo (`obj2`).
5. **Validação (IoU):** calcular o *Intersection over Union* (IoU) entre o *bounding box* detectado (`cv2.boundingRect`) e o *bounding box* de gabarito do tipo correspondente. Um objeto é considerado corretamente segmentado apenas se houver exatamente um *bounding box* do tipo correto com **IoU 0,5**.
6. **Saída:** imprimir, para cada objeto detectado, seu identificador, tipo e se foi validado com sucesso (`acertou=1`) ou não. A impressão deve seguir a ordem das classes de `obj2` (0=Tria ... 8=Cruz); dentro da mesma classe, ordenar os objetos pela coordenada vertical do centroide (`cy`) crescente. Ao final, imprimir a acurácia geral.

##### 8.14.6.2 🚫 Restrições Computacionais

- **Sem recorte manual:** toda a segmentação deve ser feita sobre a imagem completa.
- **Conjunto de classes fixo:**

```
obj = ['Triangulo', 'Quadrado', 'Pendagono', 'Hexagono', 'Heptagono', 'Circulo',
       'Elipse', 'Estrela', 'Cruz']
obj2 = ['Tria', 'Quad', 'Pent', 'Hexa', 'Hept', 'Circ', 'Elip', 'Estr', 'Cruz']
```

- **Dimensão da imagem:** 608×608 pixels — usada para desnormalizar as coordenadas do arquivo TXT.
- **Validação por centro de massa:** um objeto só é considerado corretamente segmentado se seu centroide estiver estritamente dentro do *bounding box* do gabarito correspondente ao mesmo tipo de objeto.

#### 8.14.6.3 🧠 Fundamentação Teórica

| Elemento                                          | Papel na segmentação de instâncias                                                                                 |
|---------------------------------------------------|--------------------------------------------------------------------------------------------------------------------|
| Pré-processamento (filtragem, limiarização)       | Etapa que produz a máscara binária a partir da imagem de intensidade original                                      |
| <code>cv2.findContours</code>                     | Extraí os contornos dos componentes conectados na máscara binária                                                  |
| Momentos geométricos ( <code>cv2.moments</code> ) | Permitem calcular o centro de massa (centroide) de cada contorno                                                   |
| <code>approxPolyDP</code> / vértices              | Auxilia na classificação do tipo de objeto (nº de lados aproximado)                                                |
| Validação via <i>bounding box</i>                 | Confirma se a instância segmentada corresponde espacialmente a um objeto do gabarito, medindo a acurácia do método |

#### 8.14.6.4 📌 Exemplo de Saída Esperada

```
Objeto 1: tipo=Tria, validado=True
...
Acurácia: 88.89%
```

**Parâmetros fixos para reprodutibilidade:** para que a saída bata com o gabarito de correção automática, utilize exatamente: filtro de área mínima de 300 pixels; `cv2.approxPolyDP` com `epsilon = 0.02 * perímetro`; limiar de solidez 0.92 e contagem de vértices 9 (com 11 para diferenciar Cruz de Estrela) para formas côncavas; razão de aspecto 1.15 para diferenciar Círculo de Elipse; limiar de IoU = 0.5 na validação.

#### 8.14.6.5 📁 Arquivos de Referência (.jpg e .txt)

Para depuração local, são disponibilizados dois arquivos de referência (incluídos nesta entrega; ao integrá-los ao repositório do capítulo, salve-os em `all/cap08/dados/EP08/`):

- 📄 **Imagem (00000.jpg):** imagem de objetos geométricos utilizada como entrada do exercício. O objetivo é segmentar automaticamente cada objeto, determinar seu tipo e calcular suas medidas.
- 📄 **Gabarito (00000.txt):** arquivo contendo as *bounding boxes* normalizadas dos objetos presentes na imagem. Cada linha possui o identificador da classe e as coordenadas normalizadas dos cantos superior esquerdo e inferior direito, sendo utilizado para validar automaticamente a segmentação.

A Figure 8.20 apresenta a imagem de entrada e a mesma imagem com as *bounding boxes* desenhadas a partir do arquivo de gabarito.

```
import os
import urllib.request
from morph import mm

def garantir_e_baixar(nome):
```

```

pasta = "dados/EP06"
caminho = os.path.join(pasta, nome)

os.makedirs(pasta, exist_ok=True)

if not os.path.exists(caminho):
    url = (
        "https://raw.githubusercontent.com/"
        "fzampirolli/pdi-vc/master/all/cap08/dados/EP06/"
        + nome
    )
    print(f"Baixando {nome}...")
    urllib.request.urlretrieve(url, caminho)

return caminho

img_arq = garantir_e_baixar("00000.jpg")
txt_arq = garantir_e_baixar("00000.txt")

img = mm.read(img_arq)
img_bb = mm.showBoundingBox(img, txt_arq, fmt="yolo", show=False)

mm.show(
    [img, img_bb],
    titles=[
        "Imagem original",
        "Bounding boxes do gabarito"
    ],
    cols=2,
    figsize=(10,5)
)

```




Figura 8.20: Imagem utilizada no EP08\_06. À esquerda, a imagem original. À direita, a imagem com as *bounding boxes* do arquivo de gabarito.



Figura 8.21: Simulador: Acurácia de Segmentação em Múltiplos Objetos (IoU)

```
%%writefile EP08_06.py  
# Código Python
```

```
Overwriting EP08_06.py
```

```
TestSuite("EP08_06.py").run()
```



## Capítulo 9

# Aprendizado Profundo para Visão Computacional



**Este capítulo encontra-se em desenvolvimento.**

Os capítulos anteriores apresentaram os fundamentos da Visão Computacional por meio de métodos clássicos de extração e representação de características. No **Capítulo 7**, descritores como *Local Binary Patterns* (LBP) e *Histogram of Oriented Gradients* (HOG) mostraram como informações de textura e forma podem ser representadas por descritores projetados manualmente. No **Capítulo 8**, algoritmos como *Oriented FAST and Rotated BRIEF* (ORB) e *Haar Cascade* ilustraram a aplicação desses descritores em tarefas de correspondência de características, detecção e reconhecimento de objetos.

Embora essas técnicas continuem relevantes por sua interpretabilidade e eficiência computacional, sua utilização depende da definição prévia de descritores adequados para cada problema. Essa etapa, denominada **engenharia de características** (*feature engineering*), pode limitar a capacidade de adaptação do modelo a novos cenários.

O *Deep Learning* propõe uma abordagem diferente: em vez de especificar manualmente as características da imagem, o modelo aprende automaticamente representações a partir dos dados durante o treinamento, processo conhecido como **aprendizado de representações** (*representation learning*). Na Visão Computacional, essa estratégia é implementada principalmente por meio das **Redes Neurais Convolucionais** (*Convolutional Neural Networks* — *CNNs*), nas quais os filtros convolucionais deixam de possuir coeficientes fixos e passam a ser aprendidos por algoritmos de otimização.

Embora representem uma mudança na forma de construir sistemas de reconhecimento de padrões, as *CNNs* preservam conceitos estudados ao longo deste livro. A convolução, apresentada no **Capítulo 3**, continua sendo a operação responsável pela extração local de informações; a principal diferença é que os filtros são aprendidos automaticamente durante o treinamento. Essa capacidade permitiu o desenvolvimento de modelos com elevado desempenho em tarefas como classificação de imagens, detecção de objetos, segmentação semântica e reconhecimento facial.

Este capítulo apresenta esses conceitos de forma gradual. Inicialmente, será estudada a arquitetura das *CNNs* e sua relação com a convolução bidimensional. Em seguida, serão discutidos os principais componentes do treinamento de redes neurais, incluindo funções de ativação, função de perda, retropropagação (*backpropagation*) e algoritmos de otimização. Por fim, serão apresentados *transfer learning*, arquiteturas modernas para Visão Computacional e aplicações em problemas como realidade aumentada, fotogrametria e visão estereoscópica.

## 9.1 Objetivos do Capítulo

Ao final deste capítulo, o estudante deverá ser capaz de:

- Explicar a relação entre a convolução utilizada nas *CNNs* e a convolução com *kernels* fixos estudada no **Capítulo 3**;

- Compreender a arquitetura básica de uma *CNN* e a função de suas principais camadas;
- Implementar, treinar e avaliar modelos de *CNN* para classificação de imagens;
- Aplicar **transferência de aprendizado** (*transfer learning*) para adaptar modelos pré-treinados a novos problemas;
- Utilizar modelos pré-treinados em tarefas de classificação, detecção de objetos e segmentação de imagens;
- Implementar, treinar e avaliar uma arquitetura *U-Net* para segmentação semântica, comparando seus resultados com abordagens clássicas;
- Preparar conjuntos de dados anotados e integrá-los a um *pipeline* de treinamento utilizando plataformas como o **Roboflow**;
- Integrar conceitos de geometria computacional e *Deep Learning* em aplicações de realidade aumentada, fotogrametria e visão estereoscópica.

A Figure 9.1 apresenta uma visão geral da organização dos principais conceitos estudados neste capítulo e das relações entre eles.




Figura 9.1: Visão geral dos principais conceitos abordados neste capítulo. **Fonte:** elaborado com auxílio do Gemini Notebook (Google, 2025).

## 9.2 Panorama: Classificação, Deteção e Segmentação

As tarefas de Visão Computacional diferenciam-se principalmente pela informação produzida como saída. A **classificação** atribui um único rótulo à imagem inteira. A **deteção de objetos** identifica e localiza os objetos presentes na cena. Já a **segmentação** fornece uma descrição mais detalhada, associando uma classe a cada pixel e, em algumas abordagens, distinguindo diferentes instâncias de uma mesma categoria..

A Table 9.1 resume as principais tarefas estudadas ao longo deste livro, destacando a pergunta que cada uma procura responder e a granularidade das informações produzidas.

Tabela 9.1: Comparativo entre as principais tarefas de Visão Computacional segundo a granularidade da informação produzida.

| Tarefa                           | Pergunta respondida                              | Granularidade da saída                                               | Capítulo |
|----------------------------------|--------------------------------------------------|----------------------------------------------------------------------|----------|
| <b>Classificação</b>             | “Qual é a classe desta imagem?”                  | Um único rótulo para a imagem inteira                                | 7 e 9    |
| <b>Deteção de objetos</b>        | “Quais objetos existem e onde estão?”            | Classe e caixa delimitadora ( <i>bounding box</i> ) para cada objeto | 8 e 9    |
| <b>Segmentação semântica</b>     | “A que classe pertence cada pixel?”              | Um rótulo de classe para cada pixel                                  | 8 e 9    |
| <b>Segmentação de instâncias</b> | “Quais pixels pertencem a cada objeto?”          | Um rótulo por pixel para cada instância                              | 8 e 9    |
| <b>Segmentação panóptica</b>     | “Qual é a classe e a identidade de cada objeto?” | Classe e identificador de instância para cada pixel                  | 8 e 9    |

Essas tarefas representam níveis crescentes de interpretação da imagem. A classificação descreve a cena de forma global, a detecção acrescenta a localização dos objetos e a segmentação produz uma representação espacial detalhada, tornando possível analisar cada região da imagem individualmente.

Este capítulo concentra-se na utilização de *CNNs* para classificação de imagens, detecção de objetos e segmentação semântica. Inicialmente, serão apresentados os fundamentos do treinamento de redes neurais e da técnica de *transfer learning*. Em seguida, será estudada a arquitetura *U-Net* para segmentação semântica e o uso de conjuntos de dados anotados em *pipelines* de treinamento. Por fim, serão discutidas aplicações que integram *Deep Learning* e geometria computacional em problemas como realidade aumentada, fotogrametria e visão estereoscópica.

### 9.3 Configuração do Ambiente

Os exemplos deste capítulo utilizam o **PyTorch**, um *framework* amplamente empregado no desenvolvimento e treinamento de modelos de *Deep Learning*. O código a seguir verifica a disponibilidade das bibliotecas necessárias e instala automaticamente aquelas que não estiverem presentes no ambiente de execução.

Caso o **PyTorch** ainda não esteja instalado, será selecionada automaticamente uma versão compatível com o hardware disponível. Se houver uma GPU NVIDIA com suporte ao **CUDA**, será utilizada a versão correspondente; caso contrário, será instalada a versão para execução em CPU.

Em seguida, o ambiente é inicializado por meio da importação das bibliotecas utilizadas ao longo do capítulo, da definição de uma semente aleatória para favorecer a reprodutibilidade dos experimentos e da obtenção do arquivo `morph.py`, caso ele ainda não esteja disponível no diretório de trabalho.

```
import importlib, subprocess, sys, shutil, os, urllib.request

for mod, pkg in {
    "cv2": "opencv-python",
    "skimage": "scikit-image",
    "numpy": "numpy",
    "sklearn": "scikit-learn",
    "matplotlib": "matplotlib",
}.items():
    try:
        importlib.import_module(mod)
    except ImportError:
        subprocess.run([sys.executable, "-m", "pip", "install", "-q", pkg], check=True)

try:
    import torch
```

```

except ImportError:
    args = (
        ["torch", "torchvision"]
        if shutil.which("nvidia-smi")
        else ["--index-url", "https://download.pytorch.org/whl/cpu",
            "torch", "torchvision"]
    )
    subprocess.run([sys.executable, "-m", "pip", "install", "-q", *args], check=True)
    import torch

import cv2
import numpy as np
import matplotlib.pyplot as plt
import torch.nn as nn
import torch.optim as optim
from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split
from skimage import data as skdata

torch.manual_seed(42)

if not os.path.exists("morph.py"):
    urllib.request.urlretrieve(
        "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph/morph.py",
        "morph.py",
    )

import morph
from morph import mm

device = "cuda" if torch.cuda.is_available() else "cpu"
gpu = f"({torch.cuda.get_device_name(0)})" if device == "cuda" else ""

print(
    f" Ambiente pronto. morph {getattr(morph, '__version__', 'local_file')} | "
    f"PyTorch {torch.__version__} | {device}{gpu}"
)

```

Ambiente pronto. morph 1.1.7 | PyTorch 2.12.1+cpu | cpu

## 9.4 Da Convolução Fixa à Convolução Aprendida

O **Capítulo 3** apresentou a convolução espacial utilizando *kernels* fixos, como os operadores de Sobel, projetados para realçar características específicas de uma imagem. Nos **Capítulos 7 e 8**, esse mesmo princípio foi empregado em descritores como *Histogram of Oriented Gradients (HOG)*, *Local Binary Patterns (LBP)* e *Oriented FAST and Rotated BRIEF (ORB)*, além do detector *Haar Cascade*. Em todas essas abordagens, os filtros ou descritores são definidos antes da execução do algoritmo e permanecem inalterados durante o processamento.

A Figure 9.2 relembra o funcionamento da convolução espacial. O simulador permite selecionar diferentes *kernels* e acompanhar o deslocamento da janela de convolução sobre uma imagem. Em cada posição, os coeficientes do *kernel* são combinados com a vizinhança correspondente da imagem para produzir um valor do **mapa de características** (*feature map*). O exemplo também ilustra o **compartilhamento de pesos** (*weight sharing*), em que o mesmo *kernel* é aplicado em todas as posições da imagem.

As *CNNs* preservam essa operação, mas substituem *kernels* fixos por **filtros aprendidos**. Em vez de definir previamente seus coeficientes, a rede ajusta esses valores durante o treinamento a partir de exemplos rotulados, buscando minimizar uma **função de perda** (*loss function*), que mede a diferença entre as previsões do modelo e as respostas esperadas.



Assim, a principal diferença entre os métodos clássicos e as *CNNs* não está na operação de convolução, mas na forma como os filtros são obtidos. Enquanto os primeiros utilizam filtros projetados manualmente, as *CNNs* aprendem automaticamente representações adequadas à tarefa a partir dos dados de treinamento.




Figura 9.2: Simulador interativo de convolução 2D clássica: escolha entre as três imagens sintéticas de entrada 12x12 (casa, rosto feliz ou triste) e um filtro 3x3 (Sobel V, Sobel H, Nitidez ou Idêntidade) e avance passo a passo para observar como os produtos internos locais do campo receptivo constroem o mapa de características célula a célula.

Para compreender como esse aprendizado ocorre, é necessário estudar a unidade básica de processamento das redes neurais: o **neurônio artificial**.

### 9.4.1 Neurônio Artificial

O **neurônio artificial** (*artificial neuron*) é a unidade fundamental de processamento de uma rede neural. Proposto no modelo **Perceptron** (Rosenblatt, 1958), ele constitui a base das arquiteturas modernas de *Deep Learning* (Goodfellow; Bengio; Courville, 2016). O termo **aprendizado profundo** (*Deep Learning*) refere-se ao uso de redes neurais com múltiplas camadas de processamento, capazes de aprender representações hierárquicas dos dados. Nas primeiras camadas, a rede aprende características simples, como bordas e texturas; nas camadas mais profundas, essas representações são progressivamente combinadas para identificar estruturas e objetos mais complexos.

Cada neurônio recebe um conjunto de entradas, calcula uma combinação linear desses valores e aplica uma **função de ativação** (*activation function*), produzindo um único valor de saída.

Matematicamente, a combinação linear é dada por

$$z = \sum_{i=1}^n w_i x_i + b,$$

em que  $x_i$  representam as entradas,  $w_i$  os pesos associados a cada entrada e  $b$  o **viés** (*bias*). A saída do neurônio é então obtida pela aplicação da função de ativação:

$$y = f(z).$$

Nas *CNNs*, esse princípio é utilizado em diferentes tipos de camadas. Nas **camadas convolucionais** (*convolutional layers*), cada neurônio processa apenas uma pequena região da entrada, denominada **campo receptivo** (*receptive field*), preservando a organização espacial da imagem. Nas **camadas totalmente conectadas** (*fully connected layers*), cada neurônio recebe todas as saídas da camada anterior, combinando as características extraídas para produzir a saída final da rede, como a classe atribuída à imagem.

A Figure 9.3 ilustra o funcionamento de um neurônio artificial. O simulador permite modificar as entradas ( $x_1$  e  $x_2$ ), os pesos ( $w_1$  e  $w_2$ ), o viés ( $b$ ) e a função de ativação, observando em tempo real o cálculo da combinação linear, a aplicação da função  $f(z)$  e a saída produzida pelo neurônio. Também é possível alternar entre uma camada convolucional e uma camada totalmente conectada, evidenciando as diferenças na forma como cada neurônio estabelece suas conexões.




Figura 9.3: Simulador interativo do Neurônio Artificial em contexto de CNN: alterne entre um neurônio de camada convolucional (onde  $x_i$  são intensidades de pixel em um campo receptivo e  $w_i$  são pesos do *kernel*) e um neurônio de camada totalmente conectada, ajustando entradas, pesos, viés e função de ativação para visualizar o cálculo de  $z$  e da saída  $y$  em tempo real.

Em uma CNN, milhares de neurônios são organizados em camadas com funções específicas. As primeiras camadas são responsáveis pela extração de características por meio da convolução, enquanto as últimas realizam a classificação a partir das características aprendidas.



### 9.4.2 Camada Convolutiva

A **camada convolutiva** (*convolutional layer*) é responsável pela extração de características da imagem. Cada filtro gera um **mapa de características** (*feature map*), cuja intensidade em cada posição indica a resposta do filtro à região correspondente da entrada.

A operação realizada é a mesma convolução espacial apresentada no **Capítulo 3**. Considerando um *kernel*  $K$  de dimensão  $k \times k$ , o valor produzido na posição  $(i, j)$  é dado por

$$F(i, j) = \sum_{u=0}^{k-1} \sum_{v=0}^{k-1} K(u, v) I(i + u, j + v).$$

A principal diferença em relação aos métodos clássicos está na obtenção do *kernel*  $K$ . Em filtros tradicionais, seus coeficientes são definidos manualmente para destacar características específicas da imagem. Nas *CNNs*, os coeficientes são inicializados automaticamente e ajustados durante o treinamento por meio da **retropropagação do erro** (*backpropagation*), tornando cada filtro especializado em identificar padrões relevantes para a tarefa em estudo.

Dois conceitos caracterizam essa camada:

- **Compartilhamento de pesos** (*weight sharing*): o mesmo filtro é aplicado em todas as posições da imagem, reduzindo significativamente o número de parâmetros do modelo.
- **Campo receptivo** (*receptive field*): cada neurônio convolutivo processa apenas uma pequena vizinhança da imagem, preservando a estrutura espacial dos dados.

Ao empilhar várias camadas convolucionais, a rede passa a aprender uma **hierarquia de características**. As primeiras camadas tendem a detectar padrões simples, como bordas e texturas, enquanto as camadas mais profundas combinam essas informações para representar estruturas progressivamente mais complexas.

Após a convolução, o mapa de características é submetido a uma função de ativação, introduzindo não linearidade no modelo e aumentando sua capacidade de representar relações complexas entre os dados.

A Figure 9.4 ilustra esse processo. O simulador mostra o deslocamento de um *kernel* sobre a imagem de entrada ( $I$ ), permitindo acompanhar o cálculo realizado em cada **campo receptivo**. Em cada posição, o produto escalar entre o *kernel* e a vizinhança da imagem produz um valor intermediário ( $z$ ), que é transformado pela função de ativação para gerar o correspondente valor do **mapa de características** ( $F$ ). Também é possível selecionar diferentes filtros, habilitar o uso de *zero-padding* e observar, em tempo real, como essas configurações influenciam o resultado da convolução.

### 9.4.3 Função de Ativação

A convolução é uma operação linear. Para que uma rede neural possa modelar relações não lineares entre as entradas e as saídas, aplica-se uma **função de ativação** (*activation function*) após cada camada convolutiva.

A função mais utilizada em *CNNs* é a **ReLU** (*Rectified Linear Unit*), definida por

$$\text{ReLU}(x) = \max(0, x).$$

Essa função mantém inalterados os valores positivos e substitui por zero os valores negativos, introduzindo não linearidade no modelo e favorecendo o treinamento de redes profundas com baixo custo computacional (Goodfellow; Bengio; Courville, 2016).

A Figure 9.5 ilustra o funcionamento da **ReLU** aplicada tanto a valores individuais quanto a um mapa de características. Ao mover o controle deslizante, é possível observar como a função transforma cada valor de entrada e como essa operação modifica o mapa de características, comparando a saída antes e depois da ativação.




Figura 9.4: Simulador interativo da Camada Convolutiva: escolha entre três imagens de entrada 12×12 (casa, rosto feliz ou rosto triste) para observar como os mesmos *kernels* fixos reagem a diferentes bordas e formas. Navegue pelo campo receptivo com os botões ou reprodução automática, ajuste a função de ativação e alterne o zero-padding, acompanhando o mapa de características sendo revelado célula a célula, com o cálculo detalhado termo a termo e a fórmula da dimensão de saída em tempo real.



Figura 9.5: Simulador interativo da função de ativação ReLU: arraste o controle para ver como valores negativos são zerados e valores positivos são preservados, tanto na curva quanto em um mapa de características real.

Os mapas de características resultantes da convolução e da ativação preservam a estrutura espacial da imagem. Em muitas arquiteturas, a etapa seguinte consiste em reduzir sua resolução por meio de uma operação de *pooling*.

#### 9.4.4 Pooling

A camada de *pooling* reduz a resolução espacial dos mapas de características, preservando as informações mais relevantes para as etapas seguintes do processamento. A operação mais utilizada é o *max-pooling*, que seleciona o maior valor em cada janela da imagem:

$$P(i, j) = \max_{(u, v) \in \text{janela}(i, j)} F(u, v).$$

Essa redução diminui o custo computacional das camadas subsequentes e torna a representação mais robusta a pequenas variações na posição dos padrões presentes na imagem.

A Figure 9.6 apresenta o funcionamento dessa operação sobre um mapa de características de  $8 \times 8$  pixels, reduzido para  $4 \times 4$  por meio de janelas de  $2 \times 2$  com passo igual a 2. O simulador permite alternar entre o *max-pooling*, que seleciona o maior valor de cada janela, e o *average-pooling*, que calcula a média dos valores da região correspondente. Ao avançar janela por janela, é possível acompanhar como cada estratégia reduz a resolução espacial e sintetiza as informações produzidas pela convolução.

Em conjunto, convolução, função de ativação e *pooling* formam o bloco básico utilizado na construção de uma CNN.

#### 9.4.5 Treinamento de Redes Neurais: Como as CNNs Aprendem

Uma CNN aprende ajustando automaticamente seus parâmetros — incluindo os coeficientes dos filtros convolucionais, os pesos das camadas totalmente conectadas e os vieses (*biases*) — a partir de exemplos rotulados. Esse processo de treinamento é realizado de forma iterativa e envolve três etapas principais: medir o erro produzido pela rede por meio de uma *função de perda* (*loss function*), calcular como esse erro depende de cada parâmetro utilizando a *retropropagação* (*backpropagation*) e atualizar os parâmetros com um *algoritmo de otimização* (*optimizer*).



Figura 9.6: Simulador interativo de *pooling*: escolha entre *max-pooling* e *average-pooling* e avance passo a passo para observar a redução da resolução espacial do mapa de características.

#### 9.4.5.1 Função de Perda (*Loss Function*)

A **função de perda** (*loss function*) quantifica a diferença entre a previsão produzida pela rede e a resposta correta, denominada **verdade de referência** (*ground truth*). O resultado é um único valor escalar  $L$ , que representa o desempenho atual do modelo: quanto menor a perda, mais próxima a previsão está da resposta esperada.

Em problemas de classificação multiclasse, a função mais utilizada é a **Entropia Cruzada** (*Cross-Entropy Loss*), aplicada às probabilidades produzidas pela camada **Softmax**:

$$L = - \sum_{c=1}^C y_c \log(\hat{y}_c),$$

em que  $C$  é o número de classes,  $y_c$  representa o rótulo real em codificação *one-hot* e  $\hat{y}_c$  corresponde à probabilidade prevista para a classe  $c$ . A perda assume valores próximos de zero quando a rede atribui alta probabilidade à classe correta e aumenta rapidamente à medida que essa probabilidade diminui.

A Figure 9.7 ilustra esse comportamento. O simulador permite selecionar a classe correta e modificar as probabilidades produzidas pela camada *Softmax*, mostrando em tempo real como a função de perda varia em função dessas probabilidades.

#### 9.4.5.2 Retropropagação (*Backpropagation*)

Após o cálculo da perda, é necessário determinar como cada parâmetro da rede contribui para esse resultado. Essa etapa é realizada pelo algoritmo de **retropropagação** (*backpropagation*), que utiliza a **Regra da Cadeia** do cálculo diferencial para calcular o gradiente da função de perda em relação a cada parâmetro da rede.

Para um parâmetro  $w$ , esse gradiente é dado por



Figura 9.7: Simulador interativo da Função de Perda (*Cross-Entropy*): selecione a classe real da imagem (Casa, Feliz ou Triste) e ajuste as probabilidades estimadas pela Softmax para visualizar o cálculo da penalização escalar e o gráfico do logaritmo negativo em tempo real.

$$\frac{\partial L}{\partial w}.$$

O gradiente indica como a perda varia em relação a pequenas alterações em  $w$ . Um gradiente positivo indica que aumentar esse parâmetro aumenta a perda, enquanto um gradiente negativo indica que seu aumento tende a reduzi-la.

A Figure 9.8 apresenta esse processo de forma visual. O simulador mostra, passo a passo, a propagação do gradiente da camada de saída até as primeiras camadas convolucionais, evidenciando a aplicação sucessiva da Regra da Cadeia.

### 9.4.5.3 Algoritmos de Otimização

Após o cálculo dos gradientes, um **algoritmo de otimização** (*optimizer*) atualiza os parâmetros da rede para reduzir a função de perda. Em redes neurais profundas, essa busca ocorre em um espaço de alta dimensão e, em geral, **não convexo**, tornando a otimização um problema desafiador (Goodfellow; Bengio; Courville, 2016).

Para facilitar a compreensão desse processo, a Figure 9.9 utiliza uma **superfície de perda simplificada**, composta por um mínimo global, um mínimo local e uma barreira entre essas regiões. O **mínimo global** corresponde ao menor valor da função de perda e representa, nessa superfície, o melhor conjunto de parâmetros da rede. Já um **mínimo local** também apresenta baixa perda, mas ainda pode estar distante da melhor solução. Quando a otimização fica retida em um mínimo local, os ajustes dos filtros, pesos e vieses tornam-se muito pequenos, fazendo com que o treinamento pare antes de alcançar um modelo com menor erro. Embora essa representação seja simplificada, ela permite visualizar o comportamento dos principais algoritmos de otimização.

Gradiente Descendente Estocástico (*SGD*)

O **Gradiente Descendente Estocástico** (*Stochastic Gradient Descent — SGD*) atualiza os parâmetros na direção oposta ao gradiente:





Figura 9.8: Simulador interativo de *Backpropagation*: avance os passos da Regra da Cadeia para acompanhar o fluxo do sinal de erro no sentido inverso da rede, observando a computação das derivadas parciais do gradiente em cada camada.

$$w_{\text{novo}} = w_{\text{atual}} - \eta \frac{\partial L}{\partial w},$$

em que  $\eta$  é a **taxa de aprendizado** (*learning rate*), responsável por controlar o tamanho da atualização.

O *SGD* utiliza apenas o gradiente da iteração atual. No simulador, quando a busca alcança um mínimo local, os gradientes tornam-se muito pequenos e as atualizações praticamente cessam. Como consequência, os parâmetros da rede deixam de evoluir e o treinamento permanece nessa solução, mesmo que exista outra região da superfície com menor perda.

Otimizadores Adaptativos: *Adam*

O **Adam** (*Adaptive Moment Estimation*) combina estimativas adaptativas dos primeiros e segundos momentos dos gradientes (Kingma; Ba, 2015). Para isso, emprega duas estratégias principais:

- **Momento** (*momentum*): utiliza um histórico dos gradientes para suavizar a trajetória de atualização e acumular impulso ao longo da otimização.
- **Taxa de aprendizado adaptativa**: ajusta automaticamente o tamanho da atualização de cada parâmetro com base no comportamento recente de seus gradientes.

Essas estratégias podem permitir que a busca ultrapasse pequenas barreiras da superfície de perda e continue atualizando os parâmetros em direção a soluções de menor erro. No simulador, isso é representado pela possibilidade de o *Adam* transpor a barreira entre o mínimo local e o mínimo global. Entretanto, esse comportamento depende da posição inicial dos parâmetros e da taxa de aprendizado, não havendo garantia de que o algoritmo alcance o mínimo global.

A Figure 9.9 permite comparar as trajetórias do *SGD* e do *Adam*, variando a posição inicial dos parâmetros e a taxa de aprendizado para observar como essas escolhas influenciam o processo de otimização.

#### 9.4.6 Arquitetura de uma CNN

Uma CNN destinada à classificação de imagens é formada pela combinação desses blocos fundamentais de extração de características e pela aplicação contínua do ciclo de treinamento (passo à frente e retropropagação).






Figura 9.9: Simulador interativo dos Algoritmos de Otimização: compare a trajetória do SGD e do Adam sobre uma superfície de perda não convexa com mapa de calor e curvas de nível. A linha sólida mostra o otimizador selecionado avançando passo a passo; a linha tracejada mostra, para comparação instantânea, o caminho completo que o outro otimizador percorreria a partir do mesmo ponto inicial. Observe como o SGD fica retido no Mínimo Local à direita, enquanto o Adam pode ou não transpor a barreira central dependendo do impulso acumulado e da taxa de aprendizado. Clique em qualquer ponto do mapa para redefinir o ponto inicial dos pesos.

**Passo à Frente (Forward Pass)**

Entrada      [Convolução → ReLU → Pooling] × N      Flatten      FC      Softmax      Previsão

Retropropagação (Backpropagation)      [Otimizador]      Função de Perda (Loss)

Após o último bloco convolucional, a operação **Flatten** reorganiza os mapas de características multidimensionais em um único vetor. Esse vetor alimenta as **camadas totalmente conectadas** (*fully connected layers*), que combinam as características extraídas para produzir os valores brutos de decisão da rede.

Na camada final, a função **Softmax** converte esses valores em uma distribuição de probabilidades sobre as classes do problema. Durante o treinamento, essa saída é comparada ao rótulo real para calcular a perda, disparar o *backpropagation* e atualizar os *kernels* via otimizador.

A Figure 9.10 reúne esses componentes em um único fluxo interativo. O simulador permite explorar tanto o comportamento das camadas no *Forward Pass* quanto o processo de aprendizado: é possível selecionar uma imagem de entrada (12×12), navegar pelos blocos — Entrada, Convolução + **ReLU**, *Pooling*, **Flatten**, camadas densas e **Softmax** — e executar **passos de treinamento**, observando a redução da perda (*Loss*), a propagação dos gradientes e o ajuste automático dos filtros em tempo real.

**i**  **Síntese** — Da convolução ao aprendizado de representações

Os simuladores apresentados nesta seção mostram, passo a passo, como uma *CNN* transforma uma imagem em uma previsão e como seus parâmetros são ajustados durante o treinamento.

- **Convolução:** aplica os filtros sobre a imagem para extrair características locais, produzindo mapas de características por meio do **compartilhamento de pesos** (*weight sharing*).
- **ReLU:** introduz não linearidade, permitindo que a rede represente relações mais complexas entre os dados.
- **Pooling:** reduz a resolução dos mapas de características, preservando as informações mais relevantes e reduzindo o custo computacional.
- **Flatten:** reorganiza os mapas de características em um vetor unidimensional, permitindo sua utilização pelas camadas totalmente conectadas.
- **Camada totalmente conectada:** combina as características extraídas pelas camadas anteriores para produzir os escores (*logits*) de cada classe.
- **Softmax:** converte esses escores em uma distribuição de probabilidades, utilizada para gerar a previsão da rede.
- **Função de perda:** compara a previsão com a **verdade de referência** (*ground truth*), quantificando o erro cometido pela rede.
- **Retropropagação:** calcula o gradiente da função de perda em relação a cada parâmetro da rede.
- **Otimizador:** atualiza filtros, pesos e vieses para reduzir a função de perda, iniciando uma nova iteração de treinamento.

Ao longo das iterações, os filtros convolucionais deixam de possuir valores aleatórios e passam a representar padrões úteis para a tarefa. Em geral, as primeiras camadas aprendem características simples, como bordas, contrastes e texturas, enquanto as camadas mais profundas combinam essas informações para formar representações progressivamente mais abstratas, utilizadas na classificação da imagem.

## 9.5 Projeto Prático 1: Uma CNN do Zero para os Dígitos do Capítulo 7

Para tornar a comparação com o Capítulo 7 direta, esta CNN é treinada sobre a **mesma base load\_digits** utilizada naquele capítulo — a diferença está inteiramente na forma como as características são obtidas: antes, pixels brutos ou HOG, calculados manualmente; agora, filtros convolucionais, aprendidos durante o treinamento.

Simulador: Arquitetura Completa de uma CNN
Entrada (12×12) → Conv → Pool → FC → Softmax

IMAGEM DE ENTRADA DO PIPELINE (12×12)

Casa
Feliz
Triste

Entrada  
12×12


Conv1 + ReLU  
10×10×4

Pooling1  
5×5×4

Flatten  
100 valores

Camada Densa (FC)  
16 neurônios

Softmax  
3 classes



Entrada — dimensão: 12×12

A **imagem de entrada** é representada como uma matriz de pixels 12×12. É a mesma estrutura (casa, rosto feliz ou triste) do simulador anterior.

Imagem em escala de cinza 12×12 com margem fixa de zeros.

Treinamento (Forward Pass + Retropropagação)

Entrada ▶ Conv+ReLU ▶ Pool ▶ Flatten ▶ FC ▶ Softmax ▶ Previsão

Perda ◀ Otimizador ◀ Retropropagação ◀ (a cada passo)

PERDA (LOSS)

perda aparecerá aqui

ACURÁCIA

acurácia aparecerá aqui

Loss: —

Acurácia: —

Passo de treinamento: 0

Passo Único
Treinar
Pesos Novos

Os *kernels* e pesos começam **aleatórios** (não são mais os filtros fixos do simulador anterior). A cada passo, a rede faz o *forward pass* nas 3 imagens, calcula a perda (*cross-entropy*) e a **acurácia** (quantas das 3 imagens são classificadas corretamente), retropropaga o erro e ajusta todos os pesos (inclusive os *kernels* da convolução) via gradiente descendente. ⚠ Como o "conjunto de treino" tem apenas 3 exemplos, isso demonstra o **mecanismo** do treinamento (perda caindo, acurácia subindo, pesos mudando) — não a capacidade de generalizar para imagens novas, que exigiria muito mais dados.

Figura 9.10: Simulador interativo da arquitetura de uma CNN: escolha uma das imagens de entrada 12×12 (casa, rosto feliz ou triste), clique em cada bloco do *pipeline* — Entrada, Conv+ReLU, Pooling, Flatten, FC e Softmax — e execute passos de treinamento reais (*forward pass* + retropropagação) para observar a perda e a acurácia evoluindo, os *kernels* sendo ajustados e o Softmax passando a apontar a classe correta.

Francisco de Assis Zampirolli

UFABC

516

```

digits = load_digits()
X = digits.images.astype(np.float32) / 16.0
y = digits.target

X_treino, X_teste, y_treino, y_teste = train_test_split(
    X, y, test_size=0.25, random_state=42, stratify=y
)

X_treino_t = torch.tensor(X_treino).unsqueeze(1)  # (N, 1, 8, 8)
y_treino_t = torch.tensor(y_treino, dtype=torch.long)
X_teste_t = torch.tensor(X_teste).unsqueeze(1)
y_teste_t = torch.tensor(y_teste, dtype=torch.long)

class CNNDigitos(nn.Module):
    # CNN simples: duas camadas convolucionais + pooling, seguidas de camadas densas.
    def __init__(self, n_classes=10):
        super().__init__()
        self.conv1 = nn.Conv2d(1, 8, kernel_size=3, padding=1)  # 8x8 -> 8x8, 8 filtros
        self.conv2 = nn.Conv2d(8, 16, kernel_size=3, padding=1)  # 4x4 -> 4x4, 16 filtros
        self.pool = nn.MaxPool2d(2, 2)
        self.fc1 = nn.Linear(16 * 2 * 2, 32)
        self.fc2 = nn.Linear(32, n_classes)
        self.relu = nn.ReLU()

    def forward(self, x):
        x = self.pool(self.relu(self.conv1(x)))  # 8x8 -> 4x4
        x = self.pool(self.relu(self.conv2(x)))  # 4x4 -> 2x2
        x = x.view(x.size(0), -1)
        x = self.relu(self.fc1(x))
        return self.fc2(x)

modelo_cnn = CNNDigitos()
print(f"Parâmetros treináveis: {sum(p.numel() for p in modelo_cnn.parameters())}")

otimizador = optim.Adam(modelo_cnn.parameters(), lr=1e-2)
criterio = nn.CrossEntropyLoss()

n = X_treino_t.size(0)
tam_lote = 32
epocas = 60
historico_perda, historico_acc = [], []

for epoca in range(epocas):
    modelo_cnn.train()
    perm = torch.randperm(n)
    perda_epoca = 0.0
    for i in range(0, n, tam_lote):
        idx = perm[i:i + tam_lote]
        otimizador.zero_grad()
        saida = modelo_cnn(X_treino_t[idx])
        perda = criterio(saida, y_treino_t[idx])
        perda.backward()
        otimizador.step()
        perda_epoca += perda.item() * len(idx)

    modelo_cnn.eval()
    with torch.no_grad():
        acc_teste = (modelo_cnn(X_teste_t).argmax(dim=1) == y_teste_t).float().mean().item()
    historico_perda.append(perda_epoca / n)
    historico_acc.append(acc_teste)

```

```
acc_final_cnn = historico_acc[-1]
print(f"Acurácia final da CNN no conjunto de teste: {acc_final_cnn:.4f}")

fig, ax1 = plt.subplots(figsize=(6, 4))
ax1.plot(historico_perda, color="#dc2626", label="Perda (treino)")
ax1.set_xlabel("Época")
ax1.set_ylabel("Perda", color="#dc2626")
ax2 = ax1.twinx()
ax2.plot(historico_acc, color="#2563eb", label="Acurácia (teste)")
ax2.set_ylabel("Acurácia (teste)", color="#2563eb")
plt.title("Treinamento da CNN - Base de Dígitos")
fig.tight_layout()
```

Parâmetros treináveis: 3658

Acurácia final da CNN no conjunto de teste: 0.9733




Figura 9.11: Curva de treinamento de uma CNN simples na base de dígitos: perda de treinamento e acurácia no conjunto de teste ao longo das épocas.

### 9.5.1 Comparando com o Capítulo 7

A tabela a seguir reúne os resultados obtidos na mesma base de dados, com as três abordagens estudadas ao longo do livro:

```
# Valores obtidos no Capítulo 7 (k-NN, k=3), reproduzidos aqui para comparação direta
ACC_KNN_PIXELS_CAP7 = 0.9844
ACC_KNN_HOG_CAP7 = 0.7578

metodos = ["k-NN\n(pixels brutos)", "k-NN\n(HOG)", "CNN\n(este capítulo)"]
acuracias = [ACC_KNN_PIXELS_CAP7, ACC_KNN_HOG_CAP7, acc_final_cnn]

plt.figure(figsize=(5, 4))
cores = ["#6366f1", "#f97316", "#16a34a"]
plt.bar(metodos, acuracias, color=cores)
```

```
plt.ylim(0, max(acuracias) + 0.08)
plt.ylabel("Acurácia (conjunto de teste)")
plt.title("Cap. 7 vs. Cap. 9 - Base de Dígitos")
for i, v in enumerate(acuracias):
    plt.text(i, v + 0.02, f"{v:.3f}", ha="center")
plt.tight_layout()
```




Figura 9.12: Comparação de acurácia entre os classificadores clássicos do Capítulo 7 (pixels brutos e HOG com k-NN) e a CNN treinada neste capítulo, na mesma base de dígitos.

**i** 🧠 Por que funciona? — E por que a CNN nem sempre “ganha”

O resultado observado aqui **repete o padrão já visto no Capítulo 7**: a CNN, apesar de aprender automaticamente suas características, não supera necessariamente o k-NN com pixels brutos nesta base específica. A explicação é a mesma: `load_digits` é uma base pequena (menos de 1800 exemplos), com imagens já centralizadas, normalizadas e de baixíssima resolução ( $8 \times 8$ ) — condições em que a comparação direta de intensidades já é altamente informativa, e há poucos dados para que a rede aprenda filtros verdadeiramente superiores aos descritores simples.

O verdadeiro diferencial das CNNs aparece em cenários que descritores artesanais e classificadores simples não conseguem endereçar: imagens maiores e mais realistas, com milhares de categorias, variação substancial de pose, iluminação e fundo, e conjuntos de treinamento massivos — exatamente o regime em que os modelos apresentados na seção “Aplicações em Larga Escala”, mais adiante, foram treinados. A lição pedagógica que atravessa os Capítulos 7, 8 e 9 deste livro é consistente: **a sofisticação de um método deve ser proporcional à complexidade do problema** — usar uma CNN para um problema que um k-NN resolve igualmente bem é desperdício de recursos computacionais, não uma virtude.

## 9.6 Transferência de Aprendizado

Treinar uma CNN do zero, como no projeto anterior, exige dados suficientes para ajustar todos os seus parâmetros de forma confiável — uma limitação severa quando se dispõe de poucos exemplos rotulados



para a tarefa de interesse. A **transferência de aprendizado** (*transfer learning*) contorna essa limitação reaproveitando um extrator de características já treinado em uma tarefa relacionada:

1. Treina-se (ou obtém-se já treinada) uma CNN em uma tarefa de origem, tipicamente com muitos dados disponíveis;
2. As camadas convolucionais iniciais — que tendem a aprender características gerais, como bordas e texturas, pouco específicas da tarefa de origem — são **congeladas** (seus pesos deixam de ser atualizados);
3. Apenas as camadas finais (geralmente a(s) camada(s) totalmente conectada(s)) são substituídas e **treinadas do zero** para a nova tarefa, com muito menos dados e muito menos tempo de treinamento do que seriam necessários para treinar a rede inteira.

Esse princípio é o motivo pelo qual modelos pré-treinados em bases massivas, como a ImageNet (mais de um milhão de imagens em mil categorias), tornaram-se o ponto de partida padrão de praticamente qualquer projeto moderno de visão computacional, mesmo quando a tarefa final é bastante diferente da classificação de objetos genéricos.

```
# Divide as classes de dígitos em dois domínios disjuntos:
# Domínio A (0-4): usado para treinar o extrator de características "pré-treinado"
# Domínio B (5-9): tarefa de destino, com poucos dados disponíveis
classes_A, classes_B = [0, 1, 2, 3, 4], [5, 6, 7, 8, 9]
mask_A, mask_B = np.isin(y, classes_A), np.isin(y, classes_B)
XA, yA = X[mask_A], y[mask_A]
XB, yB = X[mask_B], y[mask_B] - 5 # reindexa para 0..4

XA_tr, XA_te, yA_tr, yA_te = train_test_split(XA, yA, test_size=0.25, random_state=42, stratify=yA)
XB_tr, XB_te, yB_tr, yB_te = train_test_split(XB, yB, test_size=0.25, random_state=42, stratify=yB)

# Simula escassez de dados no domínio de destino: apenas 20 exemplos rotulados
rng = np.random.default_rng(0)
idx_poucos = rng.choice(len(XB_tr), size=20, replace=False)
XB_tr_poucos, yB_tr_poucos = XB_tr[idx_poucos], yB_tr[idx_poucos]

def para_tensor(Ximg, yarr):
    return torch.tensor(Ximg).unsqueeze(1), torch.tensor(yarr, dtype=torch.long)

XA_tr_t, yA_tr_t = para_tensor(XA_tr, yA_tr)
XA_te_t, yA_te_t = para_tensor(XA_te, yA_te)
XB_tr_t, yB_tr_t = para_tensor(XB_tr_poucos, yB_tr_poucos)
XB_te_t, yB_te_t = para_tensor(XB_te, yB_te)

class ExtratorConv(nn.Module):
    # Bloco convolucional reaproveitável entre tarefas.
    def __init__(self):
        super().__init__()
        self.conv1 = nn.Conv2d(1, 8, 3, padding=1)
        self.conv2 = nn.Conv2d(8, 16, 3, padding=1)
        self.pool = nn.MaxPool2d(2, 2)
        self.relu = nn.ReLU()

    def forward(self, x):
        x = self.pool(self.relu(self.conv1(x)))
        x = self.pool(self.relu(self.conv2(x)))
        return x.view(x.size(0), -1)

class CNNCompleta(nn.Module):
    def __init__(self, n_classes):
        super().__init__()
        self.extrator = ExtratorConv()
```

```

        self.fc1 = nn.Linear(64, 32)
        self.fc2 = nn.Linear(32, n_classes)
        self.relu = nn.ReLU()

    def forward(self, x):
        x = self.extrator(x)
        x = self.relu(self.fc1(x))
        return self.fc2(x)

def treinar(modelo, X_t, y_t, epocas, lr, tam_lote=16, parametros=None):
    params = parametros if parametros is not None else modelo.parameters()
    otim = optim.Adam(params, lr=lr)
    crit = nn.CrossEntropyLoss()
    n_amstras = X_t.size(0)
    for _ in range(epocas):
        perm = torch.randperm(n_amstras)
        for i in range(0, n_amstras, tam_lote):
            idx = perm[i:i + tam_lote]
            otim.zero_grad()
            perda = crit(modelo(X_t[idx]), y_t[idx])
            perda.backward()
            otim.step()

def calcular_acuracia(modelo, X_t, y_t):
    modelo.eval()
    with torch.no_grad():
        pred = modelo(X_t).argmax(dim=1)
    return (pred == y_t).float().mean().item()

# 1) Treina o modelo "de origem" no domínio A
modelo_origem = CNNCompleta(n_classes=5)
treinar(modelo_origem, XA_tr_t, yA_tr_t, epocas=40, lr=1e-2)
print(f"Acurácia no domínio de origem A (dígitos 0-4): {calcular_acuracia(modelo_origem, XA_te_t, yA_te_t)}")

# 2) Transferência: reaproveita o extrator (congelado), treina apenas a nova cabeça
modelo_transferencia = CNNCompleta(n_classes=5)
modelo_transferencia.extrator.load_state_dict(modelo_origem.extrator.state_dict())
for p in modelo_transferencia.extrator.parameters():
    p.requires_grad = False

treinar(
    modelo_transferencia, XB_tr_t, yB_tr_t, epocas=40, lr=1e-2,
    parametros=list(modelo_transferencia.fc1.parameters()) + list(modelo_transferencia.fc2.parameters())
)
acc_transferencia = calcular_acuracia(modelo_transferencia, XB_te_t, yB_te_t)

# 3) Do zero: mesmo pouco dado, mesmas épocas, mas sem reaproveitar nada
modelo_do_zero = CNNCompleta(n_classes=5)
treinar(modelo_do_zero, XB_tr_t, yB_tr_t, epocas=40, lr=1e-2)
acc_do_zero = calcular_acuracia(modelo_do_zero, XB_te_t, yB_te_t)

print(f"Domínio de destino B (dígitos 5-9), apenas {len(XB_tr_poucos)} exemplos de treino:")
print(f"  Com transferência (extrator congelado): {acc_transferencia:.4f}")
print(f"  Treinando do zero (mesmos dados/épocas): {acc_do_zero:.4f}")

plt.figure(figsize=(4.5, 4))
plt.bar(["Do zero", "Transferência"], [acc_do_zero, acc_transferencia], color=["#dc2626", "#16a34a"])
plt.ylim(0, max([acc_do_zero, acc_transferencia]) + 0.08)
plt.ylabel("Acurácia no domínio B (teste)")
plt.title(f"Efeito da Transferência ({len(XB_tr_poucos)} exemplos de treino)")

```

```
for i, v in enumerate([acc_do_zero, acc_transferencia]):  
    plt.text(i, v + 0.02, f"{v:.3f}", ha="center")  
plt.tight_layout()
```

Acurácia no domínio de origem A (dígitos 0-4): 1.0000  
Domínio de destino B (dígitos 5-9), apenas 20 exemplos de treino:  
Com transferência (extrator congelado): 0.7277  
Treinando do zero (mesmos dados/épocas): 0.6786




Figura 9.13: Comparação de acurácia entre treinar do zero e reaproveitar (transferir) um extrator de características já treinado, ambos com o mesmo pequeno número de exemplos rotulados na tarefa de destino.

**i** 🧠 Por que funciona? — E quando não funciona

Com apenas 20 exemplos rotulados no domínio de destino, o modelo treinado do zero mal consegue superar um classificador aleatório — não há dados suficientes para ajustar todos os parâmetros da rede de forma confiável. O modelo com transferência de aprendizado, por outro lado, já parte de um extrator de características capaz de identificar bordas, curvas e traços característicos de dígitos manuscritos em geral (aprendidos a partir dos dígitos 0-4) — restando à nova cabeça apenas a tarefa, muito mais simples, de aprender a combinar essas características já úteis para distinguir os dígitos 5-9.

**Quando a transferência ajuda:** quando a tarefa de origem e a de destino compartilham estatísticas visuais de baixo e médio nível — o que é razoável esperar entre dígitos manuscritos diferentes, como neste experimento, ou, mais amplamente, entre a maioria das imagens naturais e uma tarefa de nicho.

**Quando a transferência falha ou até prejudica** (fenômeno conhecido como *transferência negativa*): quando o domínio de origem é excessivamente diferente do domínio de destino — por exemplo, transferir um extrator treinado em fotografias naturais para radiografias médicas ou imagens de satélite pode não trazer benefício algum, e em alguns casos até atrapalhar, se as características de baixo nível relevantes forem muito distintas entre os dois domínios. Nesses casos, um ajuste fino (*fine-tuning*) parcial das camadas convolucionais — em vez de congelá-las por completo — costuma produzir melhores resultados.

## 9.7 Aplicações em Larga Escala com Modelos Pré-treinados

Os experimentos anteriores utilizaram CNNs pequenas, treinadas em minutos em uma base de poucas centenas de exemplos. Na prática profissional, é extremamente comum utilizar diretamente modelos **já treinados** em bases massivas — como a ImageNet, com mais de um milhão de imagens em mil categorias — como ponto de partida (via transferência de aprendizado) ou mesmo diretamente, sem qualquer re-treinamento.

### ! Important

As células desta seção **não são executadas automaticamente** neste notebook: o carregamento desses modelos exige o download de pesos pré-treinados (centenas de megabytes) diretamente dos servidores do PyTorch, o que requer conexão à internet no ambiente de execução. O código é apresentado tal como seria executado em um ambiente com conectividade, para fins de referência.

### 9.7.1 Classificação de Imagens

O padrão de uso é sempre o mesmo: carregar a arquitetura com pesos pré-treinados e, para uma nova tarefa, substituir apenas a camada final, como discutido na seção de transferência de aprendizado.

```
import torchvision.models as models

# Carrega uma ResNet-18 pré-treinada na ImageNet (requer internet)
modelo_resnet = models.resnet18(weights=models.ResNet18_Weights.DEFAULT)

# Transferência de aprendizado: congela o extrator de características
for parametro in modelo_resnet.parameters():
    parametro.requires_grad = False

# Substitui a camada final (originalmente 1000 classes da ImageNet)
# por uma nova camada adequada à tarefa de destino (ex.: 3 classes)
n_classes_destino = 3
modelo_resnet.fc = nn.Linear(modelo_resnet.fc.in_features, n_classes_destino)

# A partir daqui, apenas `modelo_resnet.fc` seria treinada com os dados da nova tarefa
```

### 9.7.2 Detecção de Objetos

Modelos como o **Faster R-CNN**, apresentado no Capítulo 8, estão disponíveis prontos para uso, já treinados para detectar até 91 categorias de objetos comuns (base COCO):

```
import matplotlib.pyplot as plt
import matplotlib.patches as patches
from PIL import Image
from torchvision.models.detection import fasterrcnn_resnet50_fpn
from torchvision.transforms.functional import to_tensor

from PIL import Image
from urllib.request import urlopen

img = Image.open(urlopen(
    "https://raw.githubusercontent.com/pytorch/hub/master/images/dog.jpg"
)).convert("RGB")
modelo = fasterrcnn_resnet50_fpn(weights="DEFAULT").eval()

with torch.no_grad():
    pred = modelo([to_tensor(img)])[0]

fig, ax = plt.subplots(figsize=(6, 4))
```

```
ax.imshow(img)

for box, score in zip(pred["boxes"], pred["scores"]):
    if score < 0.8:
        continue
    x1, y1, x2, y2 = box.numpy()
    ax.add_patch(patches.Rectangle((x1, y1), x2-x1, y2-y1,
                                   fill=False, edgecolor="red", linewidth=2))

ax.set_axis_off()
plt.show()
```



### 9.7.3 Segmentação Semântica

De forma análoga, modelos de segmentação semântica pré-treinados retornam diretamente um mapa de classes por pixel:

```
import torch
import matplotlib.pyplot as plt
from PIL import Image
from urllib.request import urlopen
from torchvision.transforms.functional import to_tensor
from torchvision.models.segmentation import deeplabv3_resnet50

img = Image.open(urlopen(
    "https://raw.githubusercontent.com/pytorch/hub/master/images/dog.jpg"
)).convert("RGB")

modelo = deeplabv3_resnet50(weights="DEFAULT").eval()

with torch.no_grad():
    mapa = modelo(to_tensor(img).unsqueeze(0))["out"].argmax(1).squeeze()

plt.imshow(mapa)
plt.axis("off")
plt.show()
```



## 9.8 Projeto Prático 2: Detecção de Objetos com YOLO e Transferência de Aprendizado

A subseção anterior mostrou, por meio do **Faster R-CNN**, um modelo de detecção pré-treinado sendo usado “como está”, sem qualquer re-treinamento. O Faster R-CNN pertence à família de detectores **de dois estágios**: uma primeira rede propõe regiões candidatas a conter um objeto (*region proposals*) e uma segunda rede classifica e refina cada região — a mesma lógica de “propor, depois verificar” já discutida no Capítulo 8 a propósito do Haar Cascade em cascata.

A família **YOLO** (*You Only Look Once*) segue uma filosofia distinta, de **um único estágio**: a imagem é dividida conceitualmente em uma grade, e uma única rede convolucional prevê, em uma única passagem direta, as caixas delimitadoras, a confiança de haver um objeto e a classe de cada região — sem uma etapa separada de proposta de regiões. Essa simplificação é o que torna a família YOLO especialmente adequada à detecção **em tempo real**, citada na seção de encerramento deste capítulo como uma das direções naturais de aprofundamento.

Nesta seção, o princípio de **transferência de aprendizado** — já demonstrado para classificação, com uma CNN pequena treinada nos dígitos do Capítulo 7 — é aplicado a uma **tarefa de detecção**: partindo de um YOLO pré-treinado na base COCO (fotografias naturais, 80 categorias), o modelo é ajustado (*fine-tuned*) para uma tarefa de detecção bastante diferente — localizar e classificar **objetos geométricos sintéticos** (triângulos, quadrados, estrelas, etc.), variando em cor, tamanho e rotação.

### 9.8.1 Gerando um Conjunto de Dados Sintético de Objetos Geométricos

O cenário reproduzido aqui é inspirado em uma avaliação prática comum em disciplinas de Visão Computacional: dado um conjunto de imagens contendo objetos geométricos gerados aleatoriamente, treinar um detector capaz de localizar e classificar cada objeto em nove classes:

```
classes = ['Triangle', 'Square', 'Pentagon', 'Hexagon',  
          'Heptagon', 'Circle', 'Ellipse', 'Star', 'Cross']
```

Cada objeto varia aleatoriamente em **cor**, **tamanho** e **rotação**, e cada imagem pode conter um ou mais objetos. Para cada imagem, um arquivo TXT associado descreve, em uma linha por objeto, a classe e a caixa



delimitadora no **formato YOLO**: a classe seguida de quatro valores normalizados entre 0 e 1 — centro em  $x$ , centro em  $y$ , largura e altura, todos expressos como fração da largura ou da altura da imagem, por exemplo:

```
0 0.2895 0.2007 0.3750 0.2862
```

Essa é exatamente a convenção de anotação esperada pelas bibliotecas de treinamento de YOLO (como a **ultralytics**, usada a seguir) — de modo que, caso o leitor tenha acesso a um conjunto de imagens reais anotado neste mesmo formato, basta organizá-lo na estrutura de pastas descrita adiante para reutilizar todo o restante do código sem qualquer alteração.

Como não há, neste notebook, acesso a um conjunto de imagens reais, o código a seguir **gera sinteticamente** um pequeno conjunto de dados com as mesmas características do cenário descrito: formas geométricas com cor, tamanho e rotação aleatórios, desenhadas com o OpenCV, já anotadas no formato YOLO.

```
import os, random

CLASSES = ['Triangle', 'Square', 'Pentagon', 'Hexagon',
            'Heptagon', 'Circle', 'Ellipse', 'Star', 'Cross']
N_LADOS = {'Triangle': 3, 'Square': 4, 'Pentagon': 5, 'Hexagon': 6, 'Heptagon': 7}

def poligono_regular(cx, cy, r, n_lados, rot_graus):
    ang0 = np.deg2rad(rot_graus - 90)
    angs = ang0 + 2 * np.pi * np.arange(n_lados) / n_lados
    return np.stack([cx + r * np.cos(angs), cy + r * np.sin(angs)], axis=1)

def poligono_estrela(cx, cy, r_externo, rot_graus, n_pontas=5):
    r_interno = r_externo * 0.45
    ang0 = np.deg2rad(rot_graus - 90)
    angs = ang0 + np.pi * np.arange(2 * n_pontas) / n_pontas
    raios = np.where(np.arange(2 * n_pontas) % 2 == 0, r_externo, r_interno)
    return np.stack([cx + raios * np.cos(angs), cy + raios * np.sin(angs)], axis=1)

def poligono_cruz(cx, cy, r, rot_graus, espessura_rel=0.35):
    w = r * espessura_rel
    base = np.array([
        (-w, -r), (w, -r), (w, -w), (r, -w), (r, w), (w, w),
        (w, r), (-w, r), (-w, w), (-r, w), (-r, -w), (-w, -w),
    ])
    theta = np.deg2rad(rot_graus)
    R = np.array([[np.cos(theta), -np.sin(theta)], [np.sin(theta), np.cos(theta)]])
    return base @ R.T + np.array([cx, cy])

def desenha_objeto(img, classe_idx, cx, cy, tamanho, rotacao, cor):
    nome = CLASSES[classe_idx]
    if nome in N_LADOS:
        pts = poligono_regular(cx, cy, tamanho, N_LADOS[nome], rotacao)
        cv2.fillPoly(img, [pts.astype(np.int32)], cor)
        xs, ys = pts[:, 0], pts[:, 1]
    elif nome == 'Star':
        pts = poligono_estrela(cx, cy, tamanho, rotacao)
        cv2.fillPoly(img, [pts.astype(np.int32)], cor)
        xs, ys = pts[:, 0], pts[:, 1]
    elif nome == 'Cross':
        pts = poligono_cruz(cx, cy, tamanho, rotacao)
        cv2.fillPoly(img, [pts.astype(np.int32)], cor)
        xs, ys = pts[:, 0], pts[:, 1]
```

```

elif nome == 'Circle':
    cv2.circle(img, (int(cx), int(cy)), int(tamanho), cor, -1)
    xs, ys = np.array([cx - tamanho, cx + tamanho]), np.array([cy - tamanho, cy + tamanho])
else: # Ellipse
    eixo = (int(tamanho), int(tamanho * 0.6))
    cv2.ellipse(img, (int(cx), int(cy)), eixo, rotacao, 0, 360, cor, -1)
    ang = np.deg2rad(rotacao)
    dx = np.hypot(eixo[0] * np.cos(ang), eixo[1] * np.sin(ang))
    dy = np.hypot(eixo[0] * np.sin(ang), eixo[1] * np.cos(ang))
    xs, ys = np.array([cx - dx, cx + dx]), np.array([cy - dy, cy + dy])
return xs.min(), ys.min(), xs.max(), ys.max()

def gera_imagem(tam_img=160, n_objetos=(1, 3), rng=None):
    rng = rng or random.Random()
    img = np.full((tam_img, tam_img, 3), 255, dtype=np.uint8)
    anotacoes = []
    for _ in range(rng.randint(*n_objetos)):
        classe_idx = rng.randrange(len(CLASSES))
        tamanho = rng.randint(tam_img // 10, tam_img // 5)
        cx = rng.randint(tamanho + 2, tam_img - tamanho - 2)
        cy = rng.randint(tamanho + 2, tam_img - tamanho - 2)
        rotacao = rng.uniform(0, 360)
        cor = tuple(rng.sample(range(30, 226), 3))
        x0, y0, x1, y1 = desenha_objeto(img, classe_idx, cx, cy, tamanho, rotacao, cor)
        x0, y0 = max(x0, 0), max(y0, 0)
        x1, y1 = min(x1, tam_img), min(y1, tam_img)
        xc, yc = (x0 + x1) / 2 / tam_img, (y0 + y1) / 2 / tam_img
        w, h = (x1 - x0) / tam_img, (y1 - y0) / tam_img
        anotacoes.append((classe_idx, xc, yc, w, h))
    return img, anotacoes

# Monta o conjunto de dados no formato esperado pela biblioteca `ultralalytics`:
# shapes_dataset/{images,labels}/{train,val}/*.{jpg,txt} + data.yaml
base_dir = "shapes_dataset"
rng_global = random.Random(42)
for split, n_imgs in [("train", 90), ("val", 20)]:
    os.makedirs(f"{base_dir}/images/{split}", exist_ok=True)
    os.makedirs(f"{base_dir}/labels/{split}", exist_ok=True)
    for i in range(n_imgs):
        img, anotacoes = gera_imagem(rng=rng_global)
        cv2.imwrite(f"{base_dir}/images/{split}/{i:04d}.jpg", img)
        with open(f"{base_dir}/labels/{split}/{i:04d}.txt", "w") as f:
            for c, xc, yc, w, h in anotacoes:
                f.write(f"{c} {xc:.4f} {yc:.4f} {w:.4f} {h:.4f}\n")

with open(f"{base_dir}/data.yaml", "w") as f:
    f.write(f"path: {os.path.abspath(base_dir)}\ntrain: images/train\nval: images/val\nnames:\n")
    for i, nome in enumerate(CLASSES):
        f.write(f" {i}: {nome}\n")

print("Dataset sintético gerado: 90 imagens de treino, 20 de validação.")

# Visualiza três amostras com as caixas delimitadoras sobrepostas
fig, axs = plt.subplots(1, 3, figsize=(10, 3.5))
cores_plot = plt.cm.tab10(np.linspace(0, 1, len(CLASSES)))
for ax, i in zip(axs, [0, 1, 2]):
    img = cv2.cvtColor(cv2.imread(f"{base_dir}/images/train/{i:04d}.jpg"), cv2.COLOR_BGR2RGB)
    ax.imshow(img)

```

```

tam_img = img.shape[0]
with open(f"{base_dir}/labels/train/{i:04d}.txt") as f:
    for linha in f:
        c, xc, yc, w, h = map(float, linha.split())
        c = int(c)
        x0, y0 = (xc - w / 2) * tam_img, (yc - h / 2) * tam_img
        ax.add_patch(plt.Rectangle((x0, y0), w * tam_img, h * tam_img,
                                   fill=False, edgecolor=cores_plot[c], linewidth=2))
        ax.text(x0, max(y0 - 3, 0), CLASSES[c], color=cores_plot[c], fontsize=8, weight="bold")
    ax.set_axis_off()
plt.tight_layout()
plt.show()

```

Dataset sintético gerado: 90 imagens de treino, 20 de validação.



Figura 9.14: Amostras do conjunto de dados sintético de objetos geométricos, com as caixas delimitadoras no formato YOLO sobrepostas.

### 9.8.2 Ajuste Fino de um YOLO Pré-treinado

A biblioteca `ultralytics` fornece uma interface de alto nível para carregar arquiteturas YOLO com pesos pré-treinados na base COCO e ajustá-las (*fine-tuning*) a uma nova tarefa — exatamente o padrão de transferência de aprendizado já discutido para classificação, mas agora aplicado à detecção: em vez de apenas substituir a última camada, a cabeça de detecção é reconfigurada para as novas classes (nove formas geométricas em vez de 80 categorias da COCO), e o treinamento é conduzido por poucas épocas sobre o conjunto de dados sintético.

#### ! Important

A célula a seguir **não é executada automaticamente** neste notebook: o carregamento do modelo pré-treinado exige o download de seus pesos a partir dos servidores da Ultralytics/GitHub, o que requer conexão à internet no ambiente de execução, além da instalação da biblioteca `ultralytics`. Em um ambiente com GPU, o treinamento abaixo (15 épocas, ~110 imagens de  $160 \times 160$ ) leva menos de um minuto; em CPU, alguns minutos.

```

try:
    from ultralytics import YOLO
except ImportError:
    subprocess.run([sys.executable, "-m", "pip", "install", "-q", "ultralytics"], check=True)
    from ultralytics import YOLO

# Carrega o YOLOv8-nano com pesos pré-treinados na base COCO (transferência de aprendizado)

```

```

modelo_yolo = YOLO("yolov8n.pt")

# Ajuste fino: `freeze=10` mantém congeladas as 10 primeiras camadas do backbone
# (características genéricas de baixo nível, como bordas e contornos), treinando
# apenas as camadas finais e a cabeça de detecção para as novas 9 classes -
# o mesmo princípio de congelamento parcial discutido no Exercício 3.
resultados = modelo_yolo.train(
    data="shapes_dataset/data.yaml",
    epochs=15,
    imgsz=160,
    batch=8,
    freeze=10,
    verbose=False,
    plots=False,
)

metricas = modelo_yolo.val()
print(f"mAP50 no conjunto de validação: {metricas.box.map50:.3f}")

```

New <https://pypi.org/project/ultralytics/8.4.105> available Update with 'pip install -U ultralytics'  
 Ultralytics 8.4.87 Python-3.13.5 torch-2.12.1+cpu CPU (Intel Core i7-4870HQ 2.50GHz)  
 engine/trainer: agnostic\_nms=False, amp=True, angle=1.0, augment=False, auto\_augment=randaugment, batch=1  
 Overriding model.yaml nc=80 with nc=9

|    | from         | n | params | module                               | arguments                               |
|----|--------------|---|--------|--------------------------------------|-----------------------------------------|
| 0  | -1           | 1 | 464    | ultralytics.nn.modules.conv.Conv     | [3, 16, 3, 2]                           |
| 1  | -1           | 1 | 4672   | ultralytics.nn.modules.conv.Conv     | [16, 32, 3, 2]                          |
| 2  | -1           | 1 | 7360   | ultralytics.nn.modules.block.C2f     | [32, 32, 1, True]                       |
| 3  | -1           | 1 | 18560  | ultralytics.nn.modules.conv.Conv     | [32, 64, 3, 2]                          |
| 4  | -1           | 2 | 49664  | ultralytics.nn.modules.block.C2f     | [64, 64, 2, True]                       |
| 5  | -1           | 1 | 73984  | ultralytics.nn.modules.conv.Conv     | [64, 128, 3, 2]                         |
| 6  | -1           | 2 | 197632 | ultralytics.nn.modules.block.C2f     | [128, 128, 2, True]                     |
| 7  | -1           | 1 | 295424 | ultralytics.nn.modules.conv.Conv     | [128, 256, 3, 2]                        |
| 8  | -1           | 1 | 460288 | ultralytics.nn.modules.block.C2f     | [256, 256, 1, True]                     |
| 9  | -1           | 1 | 164608 | ultralytics.nn.modules.block.SPPF    | [256, 256, 5]                           |
| 10 | -1           | 1 | 0      | torch.nn.modules.upsampling.Upsample | [None, 2, 'nearest']                    |
| 11 | [-1, 6]      | 1 | 0      | ultralytics.nn.modules.conv.Concat   | [1]                                     |
| 12 | -1           | 1 | 148224 | ultralytics.nn.modules.block.C2f     | [384, 128, 1]                           |
| 13 | -1           | 1 | 0      | torch.nn.modules.upsampling.Upsample | [None, 2, 'nearest']                    |
| 14 | [-1, 4]      | 1 | 0      | ultralytics.nn.modules.conv.Concat   | [1]                                     |
| 15 | -1           | 1 | 37248  | ultralytics.nn.modules.block.C2f     | [192, 64, 1]                            |
| 16 | -1           | 1 | 36992  | ultralytics.nn.modules.conv.Conv     | [64, 64, 3, 2]                          |
| 17 | [-1, 12]     | 1 | 0      | ultralytics.nn.modules.conv.Concat   | [1]                                     |
| 18 | -1           | 1 | 123648 | ultralytics.nn.modules.block.C2f     | [192, 128, 1]                           |
| 19 | -1           | 1 | 147712 | ultralytics.nn.modules.conv.Conv     | [128, 128, 3, 2]                        |
| 20 | [-1, 9]      | 1 | 0      | ultralytics.nn.modules.conv.Concat   | [1]                                     |
| 21 | -1           | 1 | 493056 | ultralytics.nn.modules.block.C2f     | [384, 256, 1]                           |
| 22 | [15, 18, 21] | 1 | 753067 | ultralytics.nn.modules.head.Detect   | [9, 16, None, [64, 128, 256, 320, 384]] |

Model summary: 130 layers, 3,012,603 parameters, 3,012,587 gradients, 8.2 GFLOPs

Transferred 319/355 items from pretrained weights  
 Freezing layer 'model.0.conv.weight'  
 Freezing layer 'model.0.bn.weight'  
 Freezing layer 'model.0.bn.bias'  
 Freezing layer 'model.1.conv.weight'  
 Freezing layer 'model.1.bn.weight'  
 Freezing layer 'model.1.bn.bias'  
 Freezing layer 'model.2.cv1.conv.weight'  
 Freezing layer 'model.2.cv1.bn.weight'  
 Freezing layer 'model.2.cv1.bn.bias'

```

Freezing layer 'model.2.cv2.conv.weight'
Freezing layer 'model.2.cv2.bn.weight'
Freezing layer 'model.2.cv2.bn.bias'
Freezing layer 'model.2.m.0.cv1.conv.weight'
Freezing layer 'model.2.m.0.cv1.bn.weight'
Freezing layer 'model.2.m.0.cv1.bn.bias'
Freezing layer 'model.2.m.0.cv2.conv.weight'
Freezing layer 'model.2.m.0.cv2.bn.weight'
Freezing layer 'model.2.m.0.cv2.bn.bias'
Freezing layer 'model.3.conv.weight'
Freezing layer 'model.3.bn.weight'
Freezing layer 'model.3.bn.bias'
Freezing layer 'model.4.cv1.conv.weight'
Freezing layer 'model.4.cv1.bn.weight'
Freezing layer 'model.4.cv1.bn.bias'
Freezing layer 'model.4.cv2.conv.weight'
Freezing layer 'model.4.cv2.bn.weight'
Freezing layer 'model.4.cv2.bn.bias'
Freezing layer 'model.4.m.0.cv1.conv.weight'
Freezing layer 'model.4.m.0.cv1.bn.weight'
Freezing layer 'model.4.m.0.cv1.bn.bias'
Freezing layer 'model.4.m.0.cv2.conv.weight'
Freezing layer 'model.4.m.0.cv2.bn.weight'
Freezing layer 'model.4.m.0.cv2.bn.bias'
Freezing layer 'model.4.m.1.cv1.conv.weight'
Freezing layer 'model.4.m.1.cv1.bn.weight'
Freezing layer 'model.4.m.1.cv1.bn.bias'
Freezing layer 'model.4.m.1.cv2.conv.weight'
Freezing layer 'model.4.m.1.cv2.bn.weight'
Freezing layer 'model.4.m.1.cv2.bn.bias'
Freezing layer 'model.5.conv.weight'
Freezing layer 'model.5.bn.weight'
Freezing layer 'model.5.bn.bias'
Freezing layer 'model.6.cv1.conv.weight'
Freezing layer 'model.6.cv1.bn.weight'
Freezing layer 'model.6.cv1.bn.bias'
Freezing layer 'model.6.cv2.conv.weight'
Freezing layer 'model.6.cv2.bn.weight'
Freezing layer 'model.6.cv2.bn.bias'
Freezing layer 'model.6.m.0.cv1.conv.weight'
Freezing layer 'model.6.m.0.cv1.bn.weight'
Freezing layer 'model.6.m.0.cv1.bn.bias'
Freezing layer 'model.6.m.0.cv2.conv.weight'
Freezing layer 'model.6.m.0.cv2.bn.weight'
Freezing layer 'model.6.m.0.cv2.bn.bias'
Freezing layer 'model.6.m.1.cv1.conv.weight'
Freezing layer 'model.6.m.1.cv1.bn.weight'
Freezing layer 'model.6.m.1.cv1.bn.bias'
Freezing layer 'model.6.m.1.cv2.conv.weight'
Freezing layer 'model.6.m.1.cv2.bn.weight'
Freezing layer 'model.6.m.1.cv2.bn.bias'
Freezing layer 'model.7.conv.weight'
Freezing layer 'model.7.bn.weight'
Freezing layer 'model.7.bn.bias'
Freezing layer 'model.8.cv1.conv.weight'
Freezing layer 'model.8.cv1.bn.weight'
Freezing layer 'model.8.cv1.bn.bias'
Freezing layer 'model.8.cv2.conv.weight'
Freezing layer 'model.8.cv2.bn.weight'
Freezing layer 'model.8.cv2.bn.bias'

```

```

Freezing layer 'model.8.m.0.cv1.conv.weight'
Freezing layer 'model.8.m.0.cv1.bn.weight'
Freezing layer 'model.8.m.0.cv1.bn.bias'
Freezing layer 'model.8.m.0.cv2.conv.weight'
Freezing layer 'model.8.m.0.cv2.bn.weight'
Freezing layer 'model.8.m.0.cv2.bn.bias'
Freezing layer 'model.9.cv1.conv.weight'
Freezing layer 'model.9.cv1.bn.weight'
Freezing layer 'model.9.cv1.bn.bias'
Freezing layer 'model.9.cv2.conv.weight'
Freezing layer 'model.9.cv2.bn.weight'
Freezing layer 'model.9.cv2.bn.bias'
Freezing layer 'model.22.dfl.conv.weight'
train: Fast image access (ping: 0.0±0.0 ms, read: 149.6±47.7 MB/s, size: 3.3 KB)
train: Scanning /home/fz/fz/VSCode/pdi-vc/all/cap09/shapes_dataset/labels/train.cache... 90 images, 0 backgr
val: Fast image access (ping: 0.0±0.0 ms, read: 129.6±67.7 MB/s, size: 2.8 KB)
val: Scanning /home/fz/fz/VSCode/pdi-vc/all/cap09/shapes_dataset/labels/val.cache... 20 images, 0 backgr
optimizer: 'optimizer=auto' found, ignoring 'lr0=0.01' and 'momentum=0.937' and determining best 'optimi
optimizer: AdamW(lr=0.000769, momentum=0.9) with parameter groups 57 weight(decay=0.0), 64 weight(decay=
Image sizes 160 train, 160 val
Using 0 dataloader workers
Logging results to /home/fz/fz/VSCode/pdi-vc/runs/detect/train-11
Starting training for 15 epochs...

  Epoch  GPU_mem  box_loss  cls_loss  dfl_loss  Instances  Size
  1/15    OG      1.127     4.423     1.062      13      160: 100%      12/12 3.5it/s
      Class  Images  Instances  Box(P)      R      mAP50  mAP50-95): 100%      2/
      all      20      42      0.00106    0.0509    0.00272    0.000599

  Epoch  GPU_mem  box_loss  cls_loss  dfl_loss  Instances  Size
  2/15    OG      0.9577     4.209     1.002      12      160: 100%      12/12 5.5it/s
      Class  Images  Instances  Box(P)      R      mAP50  mAP50-95): 100%      2/
      all      20      42      0.00169    0.0809    0.0246     0.0158

  Epoch  GPU_mem  box_loss  cls_loss  dfl_loss  Instances  Size
  3/15    OG      0.9043     3.92      0.9969       6      160: 100%      12/12 5.8it/s
      Class  Images  Instances  Box(P)      R      mAP50  mAP50-95): 100%      2/
      all      20      42      0.00425    0.31     0.0406     0.0316

  Epoch  GPU_mem  box_loss  cls_loss  dfl_loss  Instances  Size
  4/15    OG      0.9254     3.749     0.9582       6      160: 100%      12/12 6.8it/s
      Class  Images  Instances  Box(P)      R      mAP50  mAP50-95): 100%      2/
      all      20      42      0.00813    0.714    0.185     0.133

  Epoch  GPU_mem  box_loss  cls_loss  dfl_loss  Instances  Size
  5/15    OG      0.8726     3.547     0.9462       8      160: 100%      12/12 6.5it/s
      Class  Images  Instances  Box(P)      R      mAP50  mAP50-95): 100%      2/
      all      20      42      0.0091     0.851    0.217     0.167
Closing dataloader mosaic

  Epoch  GPU_mem  box_loss  cls_loss  dfl_loss  Instances  Size
  6/15    OG      0.7476     2.992     0.8903       5      160: 100%      12/12 6.2it/s
      Class  Images  Instances  Box(P)      R      mAP50  mAP50-95): 100%      2/
      all      20      42      0.711     0.133    0.286     0.235

  Epoch  GPU_mem  box_loss  cls_loss  dfl_loss  Instances  Size
  7/15    OG      0.7317     2.893     0.9156       4      160: 100%      12/12 5.3it/s
      Class  Images  Instances  Box(P)      R      mAP50  mAP50-95): 100%      2/
      all      20      42      0.675     0.25     0.371     0.32

```



|                                                                                                          |          |          |           |          |           |       |            |       |         |
|----------------------------------------------------------------------------------------------------------|----------|----------|-----------|----------|-----------|-------|------------|-------|---------|
| Epoch                                                                                                    | GPU_mem  | box_loss | cls_loss  | df1_loss | Instances | Size  |            |       |         |
| 8/15                                                                                                     | OG       | 0.7265   | 2.611     | 0.8811   | 3         | 160:  | 100%       | 12/12 | 5.3it/s |
|                                                                                                          | Class    | Images   | Instances | Box(P    | R         | mAP50 | mAP50-95): | 100%  | 2/      |
|                                                                                                          | all      | 20       | 42        | 0.452    | 0.316     | 0.4   | 0.342      |       |         |
| Epoch                                                                                                    | GPU_mem  | box_loss | cls_loss  | df1_loss | Instances | Size  |            |       |         |
| 9/15                                                                                                     | OG       | 0.6889   | 2.506     | 0.8901   | 4         | 160:  | 100%       | 12/12 | 7.5it/s |
|                                                                                                          | Class    | Images   | Instances | Box(P    | R         | mAP50 | mAP50-95): | 100%  | 2/      |
|                                                                                                          | all      | 20       | 42        | 0.315    | 0.448     | 0.447 | 0.379      |       |         |
| Epoch                                                                                                    | GPU_mem  | box_loss | cls_loss  | df1_loss | Instances | Size  |            |       |         |
| 10/15                                                                                                    | OG       | 0.6651   | 2.391     | 0.8934   | 5         | 160:  | 100%       | 12/12 | 4.9it/s |
|                                                                                                          | Class    | Images   | Instances | Box(P    | R         | mAP50 | mAP50-95): | 100%  | 2/      |
|                                                                                                          | all      | 20       | 42        | 0.308    | 0.534     | 0.434 | 0.368      |       |         |
| Epoch                                                                                                    | GPU_mem  | box_loss | cls_loss  | df1_loss | Instances | Size  |            |       |         |
| 11/15                                                                                                    | OG       | 0.6738   | 2.345     | 0.8911   | 6         | 160:  | 100%       | 12/12 | 5.1it/s |
|                                                                                                          | Class    | Images   | Instances | Box(P    | R         | mAP50 | mAP50-95): | 100%  | 2/      |
|                                                                                                          | all      | 20       | 42        | 0.623    | 0.464     | 0.506 | 0.444      |       |         |
| Epoch                                                                                                    | GPU_mem  | box_loss | cls_loss  | df1_loss | Instances | Size  |            |       |         |
| 12/15                                                                                                    | OG       | 0.6777   | 2.162     | 0.871    | 6         | 160:  | 100%       | 12/12 | 5.3it/s |
|                                                                                                          | Class    | Images   | Instances | Box(P    | R         | mAP50 | mAP50-95): | 100%  | 2/      |
|                                                                                                          | all      | 20       | 42        | 0.473    | 0.563     | 0.545 | 0.472      |       |         |
| Epoch                                                                                                    | GPU_mem  | box_loss | cls_loss  | df1_loss | Instances | Size  |            |       |         |
| 13/15                                                                                                    | OG       | 0.6348   | 2.054     | 0.87     | 4         | 160:  | 100%       | 12/12 | 5.0it/s |
|                                                                                                          | Class    | Images   | Instances | Box(P    | R         | mAP50 | mAP50-95): | 100%  | 2/      |
|                                                                                                          | all      | 20       | 42        | 0.67     | 0.528     | 0.578 | 0.515      |       |         |
| Epoch                                                                                                    | GPU_mem  | box_loss | cls_loss  | df1_loss | Instances | Size  |            |       |         |
| 14/15                                                                                                    | OG       | 0.6287   | 2.061     | 0.8757   | 4         | 160:  | 100%       | 12/12 | 9.1it/s |
|                                                                                                          | Class    | Images   | Instances | Box(P    | R         | mAP50 | mAP50-95): | 100%  | 2/      |
|                                                                                                          | all      | 20       | 42        | 0.68     | 0.539     | 0.579 | 0.509      |       |         |
| Epoch                                                                                                    | GPU_mem  | box_loss | cls_loss  | df1_loss | Instances | Size  |            |       |         |
| 15/15                                                                                                    | OG       | 0.6407   | 1.984     | 0.8761   | 5         | 160:  | 100%       | 12/12 | 5.3it/s |
|                                                                                                          | Class    | Images   | Instances | Box(P    | R         | mAP50 | mAP50-95): | 100%  | 2/      |
|                                                                                                          | all      | 20       | 42        | 0.656    | 0.557     | 0.581 | 0.499      |       |         |
| 15 epochs completed in 0.011 hours.                                                                      |          |          |           |          |           |       |            |       |         |
| Optimizer stripped from /home/fz/fz/VSCode/pdi-vc/runs/detect/train-11/weights/last.pt, 6.2MB            |          |          |           |          |           |       |            |       |         |
| Optimizer stripped from /home/fz/fz/VSCode/pdi-vc/runs/detect/train-11/weights/best.pt, 6.2MB            |          |          |           |          |           |       |            |       |         |
| Validating /home/fz/fz/VSCode/pdi-vc/runs/detect/train-11/weights/best.pt...                             |          |          |           |          |           |       |            |       |         |
| Ultralytics 8.4.87 Python-3.13.5 torch-2.12.1+cpu CPU (Intel Core i7-4870HQ 2.50GHz)                     |          |          |           |          |           |       |            |       |         |
| Model summary (fused): 73 layers, 3,007,403 parameters, 0 gradients, 8.1 GFLOPs                          |          |          |           |          |           |       |            |       |         |
|                                                                                                          | Class    | Images   | Instances | Box(P    | R         | mAP50 | mAP50-95): | 100%  | 2/      |
|                                                                                                          | all      | 20       | 42        | 0.669    | 0.528     | 0.582 | 0.519      |       |         |
| Speed: 1.0ms preprocess, 16.3ms inference, 0.0ms loss, 0.6ms postprocess per image                       |          |          |           |          |           |       |            |       |         |
| Ultralytics 8.4.87 Python-3.13.5 torch-2.12.1+cpu CPU (Intel Core i7-4870HQ 2.50GHz)                     |          |          |           |          |           |       |            |       |         |
| Model summary (fused): 73 layers, 3,007,403 parameters, 0 gradients, 8.1 GFLOPs                          |          |          |           |          |           |       |            |       |         |
| val: Fast image access (ping: 0.0±0.0 ms, read: 248.0±90.6 MB/s, size: 3.8 KB)                           |          |          |           |          |           |       |            |       |         |
| val: Scanning /home/fz/fz/VSCode/pdi-vc/all/cap09/shapes_dataset/labels/val.cache... 20 images, 0 backgr |          |          |           |          |           |       |            |       |         |
|                                                                                                          | Class    | Images   | Instances | Box(P    | R         | mAP50 | mAP50-95): | 100%  | 2/      |
|                                                                                                          | all      | 20       | 42        | 0.669    | 0.528     | 0.582 | 0.519      |       |         |
|                                                                                                          | Triangle | 2        | 2         | 1        | 0         | 0.215 | 0.177      |       |         |
|                                                                                                          | Square   | 6        | 6         | 0.827    | 0.667     | 0.817 | 0.755      |       |         |
|                                                                                                          | Pentagon | 4        | 5         | 0.161    | 0.2       | 0.238 | 0.229      |       |         |
|                                                                                                          | Hexagon  | 2        | 2         | 1        | 0         | 0.181 | 0.0766     |       |         |

|          |   |   |       |       |       |       |
|----------|---|---|-------|-------|-------|-------|
| Heptagon | 1 | 1 | 0.491 | 0.982 | 0.497 | 0.448 |
| Circle   | 7 | 7 | 0.635 | 0.259 | 0.574 | 0.498 |
| Ellipse  | 2 | 2 | 0.293 | 1     | 0.995 | 0.995 |
| Star     | 8 | 9 | 0.899 | 1     | 0.995 | 0.837 |
| Cross    | 7 | 8 | 0.719 | 0.642 | 0.726 | 0.653 |

Speed: 0.5ms preprocess, 20.6ms inference, 0.0ms loss, 0.7ms postprocess per image

Results saved to /home/fz/fz/VSCode/pdi-vc/runs/detect/val-6

mAP50 no conjunto de validação: 0.582

```

resultado = modelo_yolo.predict("shapes_dataset/images/val/0000.jpg", conf=0.4, verbose=False)[0]

fig, ax = plt.subplots(figsize=(4, 4))
ax.imshow(cv2.cvtColor(resultado.orig_img, cv2.COLOR_BGR2RGB))
for box in resultado.bboxes:
    x0, y0, x1, y1 = box.xyxy[0].tolist()
    classe, conf = CLASSES[int(box.cls)], float(box.conf)
    ax.add_patch(plt.Rectangle((x0, y0), x1 - x0, y1 - y0,
                              fill=False, edgecolor="red", linewidth=2))
    ax.text(x0, max(y0 - 3, 0), f"{classe} {conf:.2f}", color="red", fontsize=8, weight="bold")
ax.set_axis_off()
plt.show()

```



Figura 9.15: Detecções do YOLO ajustado por transferência de aprendizado em uma imagem de validação não vista durante o treinamento.

```

import os
from ultralytics import YOLO

# 1. Definição das classes do problema geométrico
CLASSES_GEOMETRICAS = [
    'Triangle', 'Square', 'Pentagon', 'Hexagon',
    'Heptagon', 'Circle', 'Ellipse', 'Star', 'Cross'
]

# 2. Configuração do arquivo de dados (dataset.yaml) exigido pelo YOLO
yaml_content = """
train: ./shapes_dataset/images/train
val: ./shapes_dataset/images/val

```

```

nc: 9
names: ['Triangle', 'Square', 'Pentagon', 'Hexagon', 'Heptagon', 'Circle', 'Ellipse', 'Star', 'Cross']
"""

with open("dataset.yaml", "w") as f:
    f.write(yaml_content)

# 3. Carrega um modelo YOLO nano pré-treinado (Extrator de características congelado/inicializado)
# 0 sufixo 'n' indica a versão mais leve, ideal para restrições computacionais
modelo_yolo = YOLO("yolov8n.pt")

# 4. Transferência de Aprendizado / Ajuste Fino (Fine-tuning)
# 0 framework adapta automaticamente a camada de saída para 9 classes
resultados = modelo_yolo.train(
    data="dataset.yaml",
    epochs=4,
    imgsz=640,
    batch=16,
    device=device # Reaproveita a variável 'device' configurada no início do capítulo
)

```

New <https://pypi.org/project/ultralytics/8.4.105> available Update with 'pip install -U ultralytics'  
 Ultralytics 8.4.87 Python-3.13.5 torch-2.12.1+cpu CPU (Intel Core i7-4870HQ 2.50GHz)  
 engine/trainer: agnostic\_nms=False, amp=True, angle=1.0, augment=False, auto\_augment=randaugument, batch=16  
 Overriding model.yaml nc=80 with nc=9

|    | from         | n | params | module                               | arguments                                          |
|----|--------------|---|--------|--------------------------------------|----------------------------------------------------|
| 0  | -1           | 1 | 464    | ultralytics.nn.modules.conv.Conv     | [3, 16, 3, 2]                                      |
| 1  | -1           | 1 | 4672   | ultralytics.nn.modules.conv.Conv     | [16, 32, 3, 2]                                     |
| 2  | -1           | 1 | 7360   | ultralytics.nn.modules.block.C2f     | [32, 32, 1, True]                                  |
| 3  | -1           | 1 | 18560  | ultralytics.nn.modules.conv.Conv     | [32, 64, 3, 2]                                     |
| 4  | -1           | 2 | 49664  | ultralytics.nn.modules.block.C2f     | [64, 64, 2, True]                                  |
| 5  | -1           | 1 | 73984  | ultralytics.nn.modules.conv.Conv     | [64, 128, 3, 2]                                    |
| 6  | -1           | 2 | 197632 | ultralytics.nn.modules.block.C2f     | [128, 128, 2, True]                                |
| 7  | -1           | 1 | 295424 | ultralytics.nn.modules.conv.Conv     | [128, 256, 3, 2]                                   |
| 8  | -1           | 1 | 460288 | ultralytics.nn.modules.block.C2f     | [256, 256, 1, True]                                |
| 9  | -1           | 1 | 164608 | ultralytics.nn.modules.block.SPPF    | [256, 256, 5]                                      |
| 10 | -1           | 1 | 0      | torch.nn.modules.upsampling.Upsample | [None, 2, 'nearest']                               |
| 11 | [-1, 6]      | 1 | 0      | ultralytics.nn.modules.conv.Concat   | [1]                                                |
| 12 | -1           | 1 | 148224 | ultralytics.nn.modules.block.C2f     | [384, 128, 1]                                      |
| 13 | -1           | 1 | 0      | torch.nn.modules.upsampling.Upsample | [None, 2, 'nearest']                               |
| 14 | [-1, 4]      | 1 | 0      | ultralytics.nn.modules.conv.Concat   | [1]                                                |
| 15 | -1           | 1 | 37248  | ultralytics.nn.modules.block.C2f     | [192, 64, 1]                                       |
| 16 | -1           | 1 | 36992  | ultralytics.nn.modules.conv.Conv     | [64, 64, 3, 2]                                     |
| 17 | [-1, 12]     | 1 | 0      | ultralytics.nn.modules.conv.Concat   | [1]                                                |
| 18 | -1           | 1 | 123648 | ultralytics.nn.modules.block.C2f     | [192, 128, 1]                                      |
| 19 | -1           | 1 | 147712 | ultralytics.nn.modules.conv.Conv     | [128, 128, 3, 2]                                   |
| 20 | [-1, 9]      | 1 | 0      | ultralytics.nn.modules.conv.Concat   | [1]                                                |
| 21 | -1           | 1 | 493056 | ultralytics.nn.modules.block.C2f     | [384, 256, 1]                                      |
| 22 | [15, 18, 21] | 1 | 753067 | ultralytics.nn.modules.head.Detect   | [9, 16, None, [64, 128, 160, 320, 640, 800, 1000]] |

Model summary: 130 layers, 3,012,603 parameters, 3,012,587 gradients, 8.2 GFLOPs

Transferred 319/355 items from pretrained weights

Freezing layer 'model.22.dfl.conv.weight'

train: Fast image access (ping: 0.0±0.0 ms, read: 201.6±67.4 MB/s, size: 3.3 KB)

train: Scanning /home/fz/fz/VSCode/pdi-vc/all/cap09/shapes\_dataset/labels/train.cache... 90 images, 0 backgrounds

val: Fast image access (ping: 0.0±0.0 ms, read: 181.3±101.4 MB/s, size: 2.9 KB)

val: Scanning /home/fz/fz/VSCode/pdi-vc/all/cap09/shapes\_dataset/labels/val.cache... 20 images, 0 backgrounds

optimizer: 'optimizer=auto' found, ignoring 'lr0=0.01' and 'momentum=0.937' and determining best 'optimizer'

optimizer: AdamW(lr=0.000769, momentum=0.9) with parameter groups 57 weight(decay=0.0), 64 weight(decay=0.01)

```

Plotting labels to /home/fz/fz/VSCoDe/pdi-vc/runs/detect/train-12/labels.jpg...
Image sizes 640 train, 640 val
Using 0 dataloader workers
Logging results to /home/fz/fz/VSCoDe/pdi-vc/runs/detect/train-12
Starting training for 4 epochs...

```

| Epoch | GPU_mem | box_loss | cls_loss  | df_l_loss | Instances | Size      |                 |         |
|-------|---------|----------|-----------|-----------|-----------|-----------|-----------------|---------|
| 1/4   | OG      | 0.8733   | 3.844     | 1.118     | 49        | 640: 100% | 6/6             | 4.7s/it |
|       | Class   | Images   | Instances | Box(P     | R         | mAP50     | mAP50-95): 100% | 1/      |
|       | all     | 20       | 42        | 0.0134    | 0.941     | 0.103     | 0.0785          |         |
| 2/4   | OG      | 0.7482   | 3.601     | 1.073     | 45        | 640: 100% | 6/6             | 4.3s/it |
|       | Class   | Images   | Instances | Box(P     | R         | mAP50     | mAP50-95): 100% | 1/      |
|       | all     | 20       | 42        | 0.0116    | 1         | 0.135     | 0.116           |         |
| 3/4   | OG      | 0.7126   | 3.38      | 1.08      | 38        | 640: 100% | 6/6             | 4.5s/it |
|       | Class   | Images   | Instances | Box(P     | R         | mAP50     | mAP50-95): 100% | 1/      |
|       | all     | 20       | 42        | 0.0107    | 1         | 0.186     | 0.163           |         |
| 4/4   | OG      | 0.6787   | 3.236     | 1.045     | 34        | 640: 100% | 6/6             | 4.4s/it |
|       | Class   | Images   | Instances | Box(P     | R         | mAP50     | mAP50-95): 100% | 1/      |
|       | all     | 20       | 42        | 0.0109    | 0.984     | 0.224     | 0.2             |         |

4 epochs completed in 0.033 hours.

Optimizer stripped from /home/fz/fz/VSCoDe/pdi-vc/runs/detect/train-12/weights/last.pt, 6.2MB

Optimizer stripped from /home/fz/fz/VSCoDe/pdi-vc/runs/detect/train-12/weights/best.pt, 6.2MB

Validating /home/fz/fz/VSCoDe/pdi-vc/runs/detect/train-12/weights/best.pt...

Ultralytics 8.4.87 Python-3.13.5 torch-2.12.1+cpu CPU (Intel Core i7-4870HQ 2.50GHz)

Model summary (fused): 73 layers, 3,007,403 parameters, 0 gradients, 8.1 GFLOPs

| Class    | Images | Instances | Box(P   | R     | mAP50  | mAP50-95): 100% |
|----------|--------|-----------|---------|-------|--------|-----------------|
| all      | 20     | 42        | 0.0109  | 0.984 | 0.227  | 0.203           |
| Triangle | 2      | 2         | 0.00971 | 1     | 0.133  | 0.109           |
| Square   | 6      | 6         | 0.00819 | 1     | 0.158  | 0.141           |
| Pentagon | 4      | 5         | 0.0025  | 1     | 0.429  | 0.413           |
| Hexagon  | 2      | 2         | 0.00213 | 1     | 0.0463 | 0.0274          |
| Heptagon | 1      | 1         | 0.0034  | 1     | 0.0415 | 0.0415          |
| Circle   | 7      | 7         | 0.0249  | 0.857 | 0.499  | 0.445           |
| Ellipse  | 2      | 2         | 0.00536 | 1     | 0.21   | 0.206           |
| Star     | 8      | 9         | 0.0335  | 1     | 0.248  | 0.191           |
| Cross    | 7      | 8         | 0.0085  | 1     | 0.282  | 0.255           |

Speed: 1.6ms preprocess, 80.7ms inference, 0.0ms loss, 20.5ms postprocess per image

Results saved to /home/fz/fz/VSCoDe/pdi-vc/runs/detect/train-12

```

# 5. Validação e Inferência em uma imagem de teste
# Exemplo de URL de teste enviada em exames: https://dropbox.com/s/ekjbzp14jt90bfq/00004.jpg
imagem_teste = "./shapes_dataset/images/val/0001.jpg"
predicoes = modelo_yolo(imagem_teste)

# Exibe o resultado visual com as caixas sobrepostas
predicoes[0].show()

```

image 1/1 /home/fz/fz/VSCoDe/pdi-vc/all/cap09/shapes\_dataset/images/val/0001.jpg: 640x640 (no detections)  
Speed: 4.2ms preprocess, 103.2ms inference, 0.6ms postprocess per image at shape (1, 3, 640, 640)

```
# --- 1. Instalação e Importação das Bibliotecas ---
# O Ultralytics YOLO é uma biblioteca popular para treino e inferência.
# !pip install ultralytics -q

from ultralytics import YOLO
import matplotlib.pyplot as plt
import cv2
import numpy as np
from pathlib import Path
import torch

# Verificar dispositivo
device = 'cuda' if torch.cuda.is_available() else 'cpu'
print(f"Dispositivo usado: {device}")

# --- 2. Carregar o Modelo YOLO Pré-treinado ---
# 'yolov8n.pt' é a versão "nano" (mais leve e rápida), pré-treinada no COCO.
# Usaremos seus pesos como ponto de partida (transferência de aprendizado).
modelo = YOLO('yolov8n.pt')
print("Modelo YOLOv8n carregado com sucesso!")

# --- 3. Preparar o Dataset de Objetos Geométricos ---
# Assumimos que você tem uma estrutura de pastas pronta para o YOLO:
# dataset_geometrico/
#   images/
#       00004.jpg, 00005.jpg, ...
#   labels/
#       00004.txt, 00005.txt, ...
#
# O arquivo de label deve estar no formato YOLO:
# <class_id> <x_center> <y_center> <width> <height>
# (todos normalizados entre 0 e 1)

# Exemplo de caminho para o dataset (substitua pelo seu caminho)
caminho_dataset = Path("./shapes_dataset")
caminho_imagens = caminho_dataset / "images"
caminho_rotulos = caminho_dataset / "labels"

# Crie um arquivo data.yaml para descrever o dataset
data_yaml_content = f"""
path: {caminho_dataset.resolve()}
train: imagens
val: imagens # Se você tiver uma pasta separada, use 'images/val'

nc: 9 # Número de classes
names: ['Triangle', 'Square', 'Pentagon', 'Hexagon', 'Heptagon', 'Circle', 'Ellipse', 'Star', 'Cross']
"""

# Cria o arquivo data.yaml (se não existir)
data_yaml_path = caminho_dataset / "data.yaml"
if not data_yaml_path.exists():
    data_yaml_path.write_text(data_yaml_content)
    print(f"Arquivo data.yaml criado em: {data_yaml_path}")
else:
    print("Arquivo data.yaml já existe.")

# --- 4. Treinamento com Transferência de Aprendizado ---
# A chave aqui é que os pesos da cabeça de detecção (camadas finais) serão
# re-inicializados, enquanto o extrator de características (backbone) é ajustado.
resultados = modelo.train()
```

```

data=str(data_yaml_path),      # Caminho para o arquivo data.yaml
epochs=5,                      # Número de épocas (ajuste fino com poucos dados)
imgsz=640,                     # Tamanho da imagem de entrada
batch=16,                      # Tamanho do lote
device=device,                 # 'cpu' ou 'cuda'
project='runs/detect',         # Pasta para salvar resultados
name='geometricos_yolov8n',    # Nome do experimento
exist_ok=True,                 # Sobrescreve se existir
pretrained=True,               # Usar pesos pré-treinados (já é padrão)
)

print("Treinamento concluído!")
melhor_modelo_path = Path(resultados.save_dir) / "weights" / "best.pt"

# --- 5. Avaliação e Inferência em uma Imagem de Exemplo ---
if melhor_modelo_path.exists():
    # Carrega o melhor modelo treinado
    melhor_modelo = YOLO(str(melhor_modelo_path))

    # Realiza inferência em uma imagem de teste (ex: '00004.jpg')
    caminho_teste = caminho_imagens / "00004.jpg"
    if caminho_teste.exists():
        resultados_pred = melhor_modelo(caminho_teste, conf=0.25)

        # Plota a imagem com as detecções
        for r in resultados_pred:
            # A imagem com as caixas é renderizada no OpenCV
            img_plot = r.plot() # Retorna um array BGR
            img_plot_rgb = cv2.cvtColor(img_plot, cv2.COLOR_BGR2RGB)

            plt.figure(figsize=(8, 8))
            plt.imshow(img_plot_rgb)
            plt.axis('off')
            plt.title("Detecções YOLO (Transferência)")
            plt.show()

            # Exibe as detecções como texto
            print("\nObjetos Detectados:")
            for box in r.bboxes:
                cls = int(box.cls[0])
                conf = float(box.conf[0])
                nome_classe = modelo.names[cls]
                print(f" - Classe: {nome_classe} (Confiança: {conf:.2f})")
        else:
            print(f"Imagem de teste '{caminho_teste}' não encontrada.")
    else:
        print("Modelo treinado não encontrado. Verifique o diretório de saída do treinamento.")

```

Dispositivo usado: cpu

Modelo YOLOv8n carregado com sucesso!

Arquivo data.yaml já existe.

New <https://pypi.org/project/ultralytics/8.4.105> available Update with 'pip install -U ultralytics'

Ultralytics 8.4.87 Python-3.13.5 torch-2.12.1+cpu CPU (Intel Core i7-4870HQ 2.50GHz)

engine/trainer: agnostic\_nms=False, amp=True, angle=1.0, augment=False, auto\_augment=randaugument, batch=

Overriding model.yaml nc=80 with nc=9

|   | from | n | params | module                           | arguments         |
|---|------|---|--------|----------------------------------|-------------------|
| 0 | -1   | 1 | 464    | ultralytics.nn.modules.conv.Conv | [3, 16, 3, 2]     |
| 1 | -1   | 1 | 4672   | ultralytics.nn.modules.conv.Conv | [16, 32, 3, 2]    |
| 2 | -1   | 1 | 7360   | ultralytics.nn.modules.block.C2f | [32, 32, 1, True] |



```

 3          -1  1      18560 ultralytics.nn.modules.conv.Conv      [32, 64, 3, 2]
 4          -1  2      49664 ultralytics.nn.modules.block.C2f      [64, 64, 2, True]
 5          -1  1      73984 ultralytics.nn.modules.conv.Conv      [64, 128, 3, 2]
 6          -1  2     197632 ultralytics.nn.modules.block.C2f      [128, 128, 2, True]
 7          -1  1     295424 ultralytics.nn.modules.conv.Conv      [128, 256, 3, 2]
 8          -1  1     460288 ultralytics.nn.modules.block.C2f      [256, 256, 1, True]
 9          -1  1     164608 ultralytics.nn.modules.block.SPPF      [256, 256, 5]
10          -1  1          0 torch.nn.modules.upsampling.Upsample      [None, 2, 'nearest']
11        [-1, 6]  1          0 ultralytics.nn.modules.conv.Concat      [1]
12          -1  1     148224 ultralytics.nn.modules.block.C2f      [384, 128, 1]
13          -1  1          0 torch.nn.modules.upsampling.Upsample      [None, 2, 'nearest']
14        [-1, 4]  1          0 ultralytics.nn.modules.conv.Concat      [1]
15          -1  1      37248 ultralytics.nn.modules.block.C2f      [192, 64, 1]
16          -1  1      36992 ultralytics.nn.modules.conv.Conv      [64, 64, 3, 2]
17        [-1, 12]  1          0 ultralytics.nn.modules.conv.Concat      [1]
18          -1  1     123648 ultralytics.nn.modules.block.C2f      [192, 128, 1]
19          -1  1     147712 ultralytics.nn.modules.conv.Conv      [128, 128, 3, 2]
20        [-1, 9]  1          0 ultralytics.nn.modules.conv.Concat      [1]
21          -1  1     493056 ultralytics.nn.modules.block.C2f      [384, 256, 1]
22       [15, 18, 21]  1     753067 ultralytics.nn.modules.head.Detect      [9, 16, None, [64, 128]]
Model summary: 130 layers, 3,012,603 parameters, 3,012,587 gradients, 8.2 GFLOPs

```

Transferred 319/355 items from pretrained weights

Freezing layer 'model.22.dfl.conv.weight'

train: Fast image access (ping: 0.0±0.0 ms, read: 181.5±63.9 MB/s, size: 3.3 KB)

train: Scanning /home/fz/fz/VSCode/pdi-vc/all/cap09/shapes\_dataset/labels/train.cache... 90 images, 0 backgrounds

val: Fast image access (ping: 0.0±0.0 ms, read: 167.2±82.1 MB/s, size: 2.9 KB)

val: Scanning /home/fz/fz/VSCode/pdi-vc/all/cap09/shapes\_dataset/labels/val.cache... 20 images, 0 backgrounds

optimizer: 'optimizer=auto' found, ignoring 'lr0=0.01' and 'momentum=0.937' and determining best 'optimizer'

optimizer: AdamW(lr=0.000769, momentum=0.9) with parameter groups 57 weight(decay=0.0), 64 weight(decay=0.0)

Plotting labels to /home/fz/fz/VSCode/pdi-vc/runs/detect/runs/detect/geometricos\_yolov8n/labels.jpg...

Image sizes 640 train, 640 val

Using 0 dataloader workers

Logging results to /home/fz/fz/VSCode/pdi-vc/runs/detect/runs/detect/geometricos\_yolov8n

Starting training for 5 epochs...

| Epoch | GPU_mem | box_loss | cls_loss  | dfl_loss | Instances | Size      |                 |         |   |
|-------|---------|----------|-----------|----------|-----------|-----------|-----------------|---------|---|
| 1/5   | OG      | 0.8733   | 3.844     | 1.118    | 49        | 640: 100% | 6/6             | 4.5s/it | 2 |
|       | Class   | Images   | Instances | Box(P    | R         | mAP50     | mAP50-95): 100% |         | 1 |
|       | all     | 20       | 42        | 0.0134   | 0.941     | 0.103     | 0.0785          |         |   |
| Epoch | GPU_mem | box_loss | cls_loss  | dfl_loss | Instances | Size      |                 |         |   |
| 2/5   | OG      | 0.7489   | 3.595     | 1.073    | 45        | 640: 100% | 6/6             | 4.4s/it | 2 |
|       | Class   | Images   | Instances | Box(P    | R         | mAP50     | mAP50-95): 100% |         | 1 |
|       | all     | 20       | 42        | 0.0111   | 1         | 0.139     | 0.12            |         |   |
| Epoch | GPU_mem | box_loss | cls_loss  | dfl_loss | Instances | Size      |                 |         |   |
| 3/5   | OG      | 0.7121   | 3.353     | 1.081    | 38        | 640: 100% | 6/6             | 4.4s/it | 2 |
|       | Class   | Images   | Instances | Box(P    | R         | mAP50     | mAP50-95): 100% |         | 1 |
|       | all     | 20       | 42        | 0.00979  | 0.984     | 0.186     | 0.163           |         |   |
| Epoch | GPU_mem | box_loss | cls_loss  | dfl_loss | Instances | Size      |                 |         |   |
| 4/5   | OG      | 0.6732   | 3.179     | 1.039    | 34        | 640: 100% | 6/6             | 4.4s/it | 2 |
|       | Class   | Images   | Instances | Box(P    | R         | mAP50     | mAP50-95): 100% |         | 1 |
|       | all     | 20       | 42        | 0.0104   | 0.984     | 0.211     | 0.188           |         |   |
| Epoch | GPU_mem | box_loss | cls_loss  | dfl_loss | Instances | Size      |                 |         |   |
| 5/5   | OG      | 0.6735   | 3.087     | 1.073    | 47        | 640: 100% | 6/6             | 4.9s/it | 2 |
|       | Class   | Images   | Instances | Box(P    | R         | mAP50     | mAP50-95): 100% |         | 1 |
|       | all     | 20       | 42        | 0.0106   | 0.984     | 0.213     | 0.192           |         |   |

5 epochs completed in 0.042 hours.

Optimizer stripped from /home/fz/fz/VSCode/pdi-vc/runs/detect/runs/detect/geometricos\_yolov8n/weights/la

Optimizer stripped from /home/fz/fz/VSCode/pdi-vc/runs/detect/runs/detect/geometricos\_yolov8n/weights/be

Validating /home/fz/fz/VSCode/pdi-vc/runs/detect/runs/detect/geometricos\_yolov8n/weights/best.pt...

Ultralytics 8.4.87 Python-3.13.5 torch-2.12.1+cpu CPU (Intel Core i7-4870HQ 2.50GHz)

Model summary (fused): 73 layers, 3,007,403 parameters, 0 gradients, 8.1 GFLOPs

| Class    | Images | Instances | Box(P   | R     | mAP50  | mAP50-95): 100% |
|----------|--------|-----------|---------|-------|--------|-----------------|
| all      | 20     | 42        | 0.0105  | 0.984 | 0.213  | 0.193           |
| Triangle | 2      | 2         | 0.00893 | 1     | 0.0796 | 0.0716          |
| Square   | 6      | 6         | 0.00842 | 1     | 0.175  | 0.168           |
| Pentagon | 4      | 5         | 0.00261 | 1     | 0.367  | 0.338           |
| Hexagon  | 2      | 2         | 0.00189 | 1     | 0.0394 | 0.0275          |
| Heptagon | 1      | 1         | 0.00342 | 1     | 0.0433 | 0.0433          |
| Circle   | 7      | 7         | 0.0224  | 0.857 | 0.501  | 0.456           |
| Ellipse  | 2      | 2         | 0.00464 | 1     | 0.171  | 0.167           |
| Star     | 8      | 9         | 0.0328  | 1     | 0.275  | 0.214           |
| Cross    | 7      | 8         | 0.00969 | 1     | 0.271  | 0.25            |

Speed: 2.0ms preprocess, 102.6ms inference, 0.0ms loss, 48.7ms postprocess per image

Results saved to /home/fz/fz/VSCode/pdi-vc/runs/detect/runs/detect/geometricos\_yolov8n

Treinamento concluído!

Imagem de teste 'shapes\_dataset/images/00004.jpg' não encontrada.

 Um domínio muito mais distante que o dos dígitos

No experimento de transferência de aprendizado entre dígitos manuscritos (domínios A e B), a tarefa de origem e a de destino compartilhavam estatísticas visuais muito próximas: ambas eram traços em tons de cinza sobre fundo uniforme. Aqui, a distância entre domínios é bem maior — o YOLO foi pré-treinado em **fotografias naturais coloridas** da COCO (pessoas, animais, veículos, objetos do cotidiano), e a tarefa de destino consiste em **formas geométricas sintéticas, de cor sólida e contorno bem definido**, sem textura, iluminação ou fundo complexo.

Ainda assim, a transferência de aprendizado tende a ajudar: as camadas iniciais de um detector treinado na COCO aprendem filtros muito genéricos — detectores de bordas, cantos e regiões de contraste — que continuam úteis para delimitar o contorno de um triângulo ou de uma estrela, mesmo que o conteúdo visual final seja muito diferente. É por isso que o congelamento (`freeze=10`) é aplicado apenas às primeiras camadas do backbone: as camadas mais profundas, que na COCO aprenderam a reconhecer partes de objetos complexos do mundo real (rodas, focinhos, faces), têm pouca serventia direta para formas geométricas simples e se beneficiam de serem reajustadas.

Este é o mesmo compromisso discutido no Exercício 3 deste capítulo — entre congelar totalmente o extrator, ajustar parcialmente algumas camadas, ou treinar tudo do zero — agora observado em uma tarefa de detecção, e com um domínio de origem e destino visivelmente mais distantes do que o observado entre os dois grupos de dígitos.

### 9.8.3 Usando um Conjunto de Dados Real

O pipeline acima foi construído inteiramente em torno do **formato de anotação YOLO** (classe,  $x_{centro}$ ,  $y_{centro}$ , largura, altura, normalizados pela largura e altura da imagem) exatamente para que ele possa ser reaproveitado sem alterações caso o leitor tenha acesso a um conjunto de imagens reais anotado da mesma forma — por exemplo, um conjunto de imagens de objetos geométricos fotografados ou renderizados, cada um com um arquivo `.txt` correspondente no mesmo formato usado aqui. Para isso, bastaria:

1. Organizar as imagens reais em `shapes_dataset/images/train` e `shapes_dataset/images/val`, e os arquivos `.txt` de anotação correspondentes nas pastas `labels/train` e `labels/val` (um arquivo de anotação por imagem, mesmo nome-base, extensão `.txt`);
2. Ajustar o arquivo `data.yaml` caso o número ou os nomes das classes sejam diferentes;
3. Executar as mesmas células de treinamento, ajuste fino e visualização já apresentadas, sem qualquer

outra modificação de código.

Essa separação entre **geração/organização dos dados** e **treinamento do modelo** é, na prática, o motivo pelo qual formatos de anotação padronizados (como o do YOLO) são tão amplamente adotados: eles permitem trocar o conjunto de dados de entrada — sintético por real, um domínio por outro — mantendo inalterado todo o restante do pipeline de transferência de aprendizado.

## 9.9 Projeto Prático 3: Segmentação Semântica com U-Net

A subseção “Segmentação Semântica” mostrou um modelo pré-treinado (DeepLabV3) produzindo diretamente um rótulo de classe por pixel. Esta seção completa a sequência de projetos práticos do capítulo — classificação (Projeto Prático 1) e detecção (Projeto Prático 2) — com a terceira tarefa fundamental da Table 9.1: a segmentação semântica, agora implementada e treinada do zero com a **U-Net**, a arquitetura de referência para essa tarefa, introduzida por Ronneberger, Fischer e Brox (2015) originalmente para imagens biomédicas.

A diferença estrutural em relação à CNN de classificação do Projeto Prático 1 é decisiva. Naquela rede, o mapa de características final era achatado (*flatten*) em um vetor, descartando toda a informação espacial em favor de um único rótulo por imagem. Uma U-Net, ao contrário, precisa produzir uma saída com a **mesma resolução espacial da entrada**: um mapa em que cada pixel recebe sua própria classificação. Essa exigência — preservar detalhe espacial de alta resolução até a última camada, ao mesmo tempo em que se constrói contexto semântico mais amplo em camadas intermediárias — motiva a arquitetura de codificador-decodificador descrita a seguir.

O cenário utilizado nesta seção é uma adaptação de um projeto de segmentação de nódulos em mamografias sintéticas: imagens em tons de cinza contêm uma região circular (o “nódulo”) sobreposta a um fundo, ambos contaminados pelo mesmo ruído gaussiano e com médias de intensidade próximas — um cenário deliberadamente pouco discriminável pixel a pixel, exatamente para tornar visível o ganho trazido pelo aprendizado de características espaciais, e não apenas locais.

### 9.9.1 Um Conjunto Sintético de Imagens com Nódulos

O gerador a seguir produz pares (imagem, máscara): a imagem contém uma região circular de intensidade média ligeiramente mais alta que o fundo, ambas as regiões contaminadas por ruído gaussiano de mesmo desvio-padrão — de forma que a distinção entre nódulo e fundo não é confiável pixel a pixel isoladamente, apenas quando se considera a vizinhança espacial em conjunto. A máscara binária correspondente delimita exatamente a região do nódulo e serve como alvo de treinamento.

```
TAM_IMG = 64

def gera_imagem_com_nodulo(tam=TAM_IMG, raio_min=7, raio_max=15, media_fundo=95,
                           media_nodulo=118, sigma_ruído=26, rng=None):
    # Fundo e nódulo compartilham o mesmo ruído gaussiano; apenas a média de
    # intensidade difere, e por pouco -- um cenário de baixo contraste,
    # propositalmente difícil para um método de limiarização simples.
    rng = rng or np.random.default_rng()
    fundo = rng.normal(media_fundo, sigma_ruído, (tam, tam))
    nodulo = rng.normal(media_nodulo, sigma_ruído, (tam, tam))
    mascara = np.zeros((tam, tam), dtype=np.uint8)
    raio = int(rng.integers(raio_min, raio_max))
    cx = int(rng.integers(raio + 4, tam - raio - 4))
    cy = int(rng.integers(raio + 4, tam - raio - 4))
    cv2.circle(mascara, (cx, cy), raio, 255, -1)
    imagem = np.clip(np.where(mascara > 0, nodulo, fundo), 0, 255).astype(np.uint8)
    return imagem, mascara

rng_dados = np.random.default_rng(42)
N_TREINO, N_VAL = 160, 40
```

```

imgs_treino, masks_treino = zip(*[gera_imagem_com_nodulo(rng=rng_dados) for _ in range(N_TREINO)])
imgs_val, masks_val = zip(*[gera_imagem_com_nodulo(rng=rng_dados) for _ in range(N_VAL)])

print(f"Conjunto de treino: {N_TREINO} imagens | Conjunto de validação: {N_VAL} imagens")

mm.show(
    [imgs_treino[0], masks_treino[0], imgs_treino[1], masks_treino[1]],
    titles=["Imagem 1", "Máscara 1", "Imagem 2", "Máscara 2"],
    cols=4, figsize=(11, 3)
)

```

Conjunto de treino: 160 imagens | Conjunto de validação: 40 imagens




Figura 9.16: Amostras do conjunto de dados sintético de nódulos: imagem em tons de cinza (fundo e nódulo com médias de intensidade próximas, sob o mesmo ruído) e máscara binária de referência.

### 9.9.2 Linha de Base Clássica: Limiarização com *Kernel* Fixo

Antes de recorrer ao aprendizado, cabe perguntar se um pipeline inteiramente clássico — construído com a biblioteca **morph**, como nos capítulos anteriores — já resolve a tarefa. A abordagem mais direta combina um **borrão gaussiano** (kernel fixo, no espírito do Capítulo 3) para estimar a intensidade local, uma **limiarização de Otsu** sobre essa estimativa e uma **abertura morfológica** para remover ruído residual isolado.

```

def iou_mascaras(predita, referencia):
    # Interseção sobre união entre duas máscaras binárias, pixel a pixel.
    p, r = predita > 0, referencia > 0
    intersecao = np.logical_and(p, r).sum()
    uniao = np.logical_or(p, r).sum()
    return intersecao / uniao if uniao else 1.0

def segmenta_classico(imagem, elemento_estrutural):
    suavizada = mm.blur(imagem, 7)
    binaria = mm.threshold(suavizada)
    return mm.open(binaria, elemento_estrutural)

elemento_estrutural = mm.sedisk(5)
ious_classico = [
    iou_mascaras(segmenta_classico(img, elemento_estrutural), mask)
    for img, mask in zip(imgs_val, masks_val)
]
iou_classico_medio = float(np.mean(ious_classico))
print(f"IoU médio (linha de base clássica) no conjunto de validação: {iou_classico_medio:.4f}")

predicao_classica_exemplo = segmenta_classico(imgs_val[0], elemento_estrutural)
mm.show(

```

```
[imgs_val[0], masks_val[0], predicao_classica_exemplo],
titles=["Imagem", "Máscara de referência", "Predição clássica"],
cols=3, figsize=(9, 3.2)
)
```

IoU médio (linha de base clássica) no conjunto de validação: 0.7516




Figura 9.17: Linha de base clássica de segmentação: borrão gaussiano, limiarização de Otsu e abertura morfológica, aplicados a uma imagem de validação.

### 9.9.3 Arquitetura U-Net: Codificador-Decodificador com Conexões de Atalho

O **codificador** repete a mesma lógica de convolução seguida de *pooling* já vista no Projeto Prático 1: cada estágio reduz a resolução espacial pela metade e dobra o número de canais, construindo progressivamente características mais abstratas. Na U-Net, porém, esse processo é espelhado por um **decodificador** simétrico, que reconstrói a resolução original por meio de convoluções transpostas (*upsampling* aprendido).

A diferença essencial em relação a um simples codificador-decodificador está nas **conexões de atalho** (*skip connections*): em cada estágio do decodificador, o mapa de características do codificador na mesma resolução — capturado *antes* do *pooling* correspondente — é concatenado ao resultado do *upsampling*. Isso reinjeta diretamente o detalhe espacial de fronteiras e contornos, que seria perdido pelas sucessivas reduções de resolução, permitindo que a rede combine o contexto semântico amplo construído na base (“existe um nódulo nesta região?”) com a precisão espacial fina das camadas iniciais (“exatamente onde está sua borda?”).

Entrada → Codificador (Conv→Conv→Pool) × 3 → Base  
 conexões de atalho reinjetam cada mapa do codificador  
 no estágio de mesma resolução do decodificador  
 Base → Decodificador (Upsample→Concat→Conv→Conv) × 3 → Saída 1×1 (máscara)

```
class BlocoConv(nn.Module):
    # Duas convoluções 3x3 + ReLU -- bloco básico repetido em cada estágio da U-Net.
    def __init__(self, canais_entrada, canais_saida):
        super().__init__()
        self.rede = nn.Sequential(
            nn.Conv2d(canais_entrada, canais_saida, kernel_size=3, padding=1), nn.ReLU(inplace=True),
            nn.Conv2d(canais_saida, canais_saida, kernel_size=3, padding=1), nn.ReLU(inplace=True),
        )

    def forward(self, x):
        return self.rede(x)
```

```

class UNetCompacta(nn.Module):
    # U-Net reduzida (profundidade 3, poucos canais) -- versão didática, que
    # treina em menos de um minuto em CPU, preservando a estrutura completa
    # de codificador, base e decodificador com conexões de atalho.
    def __init__(self, canais_entrada=1, base=8):
        super().__init__()
        self.enc1 = BlocoConv(canais_entrada, base)
        self.enc2 = BlocoConv(base, base * 2)
        self.enc3 = BlocoConv(base * 2, base * 4)
        self.pool = nn.MaxPool2d(2)

        self.fundo = BlocoConv(base * 4, base * 8)

        self.up3 = nn.ConvTranspose2d(base * 8, base * 4, kernel_size=2, stride=2)
        self.dec3 = BlocoConv(base * 8, base * 4)
        self.up2 = nn.ConvTranspose2d(base * 4, base * 2, kernel_size=2, stride=2)
        self.dec2 = BlocoConv(base * 4, base * 2)
        self.up1 = nn.ConvTranspose2d(base * 2, base, kernel_size=2, stride=2)
        self.dec1 = BlocoConv(base * 2, base)

        self.saida = nn.Conv2d(base, 1, kernel_size=1) # 1 canal: logit de "nódulo"

    def forward(self, x):
        e1 = self.enc1(x)
        e2 = self.enc2(self.pool(e1))
        e3 = self.enc3(self.pool(e2))
        f = self.fundo(self.pool(e3))
        d3 = self.dec3(torch.cat([self.up3(f), e3], dim=1)) # conexão de atalho com e3
        d2 = self.dec2(torch.cat([self.up2(d3), e2], dim=1)) # conexão de atalho com e2
        d1 = self.dec1(torch.cat([self.up1(d2), e1], dim=1)) # conexão de atalho com e1
        return self.saida(d1) # logits; sigmoid aplicado na perda e na predição

def para_tensores(imagens, mascaras):
    X = torch.tensor(np.stack(imagens), dtype=torch.float32).unsqueeze(1) / 255.0
    Y = torch.tensor(np.stack(mascaras), dtype=torch.float32).unsqueeze(1) / 255.0
    return X, Y

def perda_dice(logits, alvo, eps=1e-6):
    # 1 - coeficiente de Dice, a mesma métrica de sobreposição empregada na U-Net original.
    probs = torch.sigmoid(logits)
    intersecao = (probs * alvo).sum(dim=(1, 2, 3))
    uniao = probs.sum(dim=(1, 2, 3)) + alvo.sum(dim=(1, 2, 3))
    dice = (2 * intersecao + eps) / (uniao + eps)
    return 1 - dice.mean()

def perda_segmentacao(logits, alvo):
    return nn.functional.binary_cross_entropy_with_logits(logits, alvo) + perda_dice(logits, alvo)

modelo_unet = UNetCompacta()
print(f"Parâmetros treináveis da U-Net compacta: {sum(p.numel() for p in modelo_unet.parameters())}")

X_treino_unet, Y_treino_unet = para_tensores(imgs_treino, masks_treino)
X_val_unet, Y_val_unet = para_tensores(imgs_val, masks_val)

otimizador_unet = optim.Adam(modelo_unet.parameters(), lr=1e-3)
n = X_treino_unet.size(0)
tam_lote = 16
epocas_unet = 35
historico_perda_unet, historico_iou_unet = [], []

```



```

for epoca in range(epocas_unet):
    modelo_unet.train()
    perm = torch.randperm(n)
    perda_epoca = 0.0
    for i in range(0, n, tam_lote):
        idx = perm[i:i + tam_lote]
        otimizador_unet.zero_grad()
        logits = modelo_unet(X_treino_unet[idx])
        perda = perda_segmentacao(logits, Y_treino_unet[idx])
        perda.backward()
        otimizador_unet.step()
        perda_epoca += perda.item() * len(idx)

    modelo_unet.eval()
    with torch.no_grad():
        predicacao_val = (torch.sigmoid(modelo_unet(X_val_unet)) > 0.5).float()
        intersecao = (predicacao_val * Y_val_unet).sum(dim=(1, 2, 3))
        uniao = ((predicacao_val + Y_val_unet) > 0).float().sum(dim=(1, 2, 3))
        iou_epoca = (intersecao / uniao.clamp(min=1e-6)).mean().item()
    historico_perda_unet.append(perda_epoca / n)
    historico_iou_unet.append(iou_epoca)

iou_unet_final = historico_iou_unet[-1]
print(f"IoU médio da U-Net no conjunto de validação: {iou_unet_final:.4f}")

fig, ax1 = plt.subplots(figsize=(6, 4))
ax1.plot(historico_perda_unet, color="#dc2626", label="Perda (treino)")
ax1.set_xlabel("Época")
ax1.set_ylabel("Perda", color="#dc2626")
ax2 = ax1.twinx()
ax2.plot(historico_iou_unet, color="#2563eb", label="IoU (validação)")
ax2.set_ylabel("IoU (validação)", color="#2563eb")
plt.title("Treinamento da U-Net - Segmentação de Nódulos Sintéticos")
fig.tight_layout()

```

Parâmetros treináveis da U-Net compacta: 120681  
 IoU médio da U-Net no conjunto de validação: 0.8815




Figura 9.18: Curva de treinamento da U-Net compacta: perda de treinamento (entropia cruzada binária combinada à perda Dice) e IoU médio no conjunto de validação ao longo das épocas.

#### 9.9.4 Comparando com a Linha de Base Clássica


Com ambos os métodos avaliados no mesmo conjunto de validação, sob a mesma métrica, a comparação a seguir reproduz o formato já utilizado na comparação entre Capítulo 7 e a CNN de classificação: uma linha de base projetada manualmente contra o resultado aprendido a partir dos dados.

```
metodos_seg = ["Clássico\n(borrão + Otsu)", "U-Net\n(esteste capítulo)"]
ious_medios = [iou_classico_medio, iou_unet_final]


plt.figure(figsize=(4.5, 4))
plt.bar(metodos_seg, ious_medios, color=["#f97316", "#16a34a"])
plt.ylim(0, 1.0)
plt.ylabel("IoU médio (conjunto de validação)")
plt.title("Segmentação Clássica vs. U-Net")
for i, v in enumerate(ious_medios):
    plt.text(i, v + 0.02, f"{v:.3f}", ha="center")
plt.tight_layout()
plt.show()

# Predições lado a lado em três exemplos de validação
fig, axs = plt.subplots(3, 4, figsize=(10, 7.5))
for linha, i in enumerate([0, 1, 2]):
    with torch.no_grad():
        pred_unet = (torch.sigmoid(modelo_unet(X_val_unet[i:i+1])) > 0.5).float().squeeze().numpy() * 255
    pred_classico = segmenta_classico(imgs_val[i], elemento_estrutural)
    imagens_linha = [imgs_val[i], masks_val[i], pred_classico, pred_unet.astype(np.uint8)]
    titulos_linha = ["Imagem", "Referência", "Clássico", "U-Net"]
    for col in range(4):
        axs[linha, col].imshow(imagens_linha[col], cmap="gray", vmin=0, vmax=255)
        if linha == 0:
            axs[linha, col].set_title(titulos_linha[col])
        axs[linha, col].axis("off")
```

```
plt.tight_layout()
```



(a) Comparação entre a linha de base clássica (borrão + Otsu + abertura) e a U-Net treinada: IoU médio no conjunto de validação e predições lado a lado em três exemplos.



(b)

Figura 9.19

### Por que funciona? — Conexões de atalho e os limites de uma regra fixa

A vantagem da U-Net sobre a linha de base clássica não decorre de operações fundamentalmente diferentes — ambas combinam convolução (fixa, no caso do borrão; aprendida, no caso da U-Net) com uma regra de decisão por pixel — mas de **onde** essa decisão final é tomada. A limiarização de Otsu aplica um único valor de corte, global, sobre uma estimativa de intensidade local; quando a diferença de média entre nóculo e fundo é pequena diante do ruído — como neste conjunto de dados, construído deliberadamente para isso — essa regra única erra sistematicamente nas bordas e em regiões onde o ruído local se aproxima do nóculo.

As conexões de atalho atacam exatamente esse problema. A base da rede, após três reduções de resolução, enxerga um contexto espacial amplo, suficiente para localizar aproximadamente a região do nóculo mesmo sob ruído — mas com resolução baixa demais para desenhar seu contorno com precisão. Reinjetar, em cada estágio do decodificador, o mapa de características de resolução equivalente do codificador devolve exatamente o detalhe espacial necessário para refinar essa localização aproximada em uma máscara pixel a pixel — algo que nenhuma regra de limiar único, por mais bem ajustada, consegue replicar quando o sinal está distribuído de forma sutil pela vizinhança de cada pixel, e não concentrado no valor de um único pixel isolado.

## 9.9.5 Aplicando a Mesma Pipeline a um Conjunto de Dados Real: Roboflow

Assim como a subseção anterior mostrou, para a detecção com YOLO, que um conjunto de dados sintético pode ser substituído por imagens reais sem alterar o código de treinamento, o mesmo princípio se aplica à U-Net: a única exigência é organizar as imagens e suas máscaras nos mesmos tensores `X` e `Y` construídos por `para_tensores`.

A **Roboflow** é uma plataforma de anotação, versionamento e exportação de conjuntos de dados de Visão Computacional, com um catálogo público (Roboflow Universe) que reúne milhares de conjuntos já anotados para classificação, detecção e segmentação, exportáveis em diversos formatos — entre eles, o formato de anotação YOLO já utilizado no Projeto Prático 2 e o formato `png-mask-semantic`, com uma máscara por imagem, diretamente compatível com a U-Net treinada nesta seção. Alternativas com propósito semelhante incluem o Kaggle Datasets e o Hugging Face Hub, mais orientados à descoberta de conjuntos de dados já publicados do que à anotação de imagens próprias; a escolha entre essas plataformas depende, sobretudo, de o conjunto de interesse já existir publicamente ou precisar ser anotado do zero.

O exemplo a seguir baixa um conjunto de dados real de segmentação a partir de um projeto hospedado na Roboflow e o adapta ao mesmo formato de tensores utilizado no treinamento da U-Net compacta, permitindo reaproveitar — sem qualquer alteração de arquitetura — as mesmas funções `perda_segmentacao`, `UNetCompacta` e o laço de treinamento já definidos.

### Important

As células a seguir **não são executadas automaticamente** neste notebook: requerem uma chave de API gratuita, obtida em [app.roboflow.com](https://app.roboflow.com), e o identificador (`workspace/projeto/versão`) de um conjunto de dados de segmentação específico, além de conexão à internet para o download. O código é apresentado como um gabarito completo, pronto para ser adaptado a qualquer conjunto de dados de segmentação hospedado na plataforma — consulte a documentação oficial ([docs.roboflow.com/developer/export-data](https://docs.roboflow.com/developer/export-data)) para o formato exato de cada tipo de exportação.

```
# 1. Instalação do pacote oficial da Roboflow
!pip install roboflow > /dev/null

# 2. Autenticação e download do conjunto de dados no formato de máscaras semânticas
from roboflow import Roboflow

rf = Roboflow(api_key="SUA_CHAVE_DE_API") # chave gratuita, obtida em app.roboflow.com
```

```
projeto = rf.workspace("nome-do-workspace").project("nome-do-projeto")
dataset = projeto.version(1).download("png-mask-semantic")

# A exportação "png-mask-semantic" organiza o conjunto em pastas train/valid/test,
# cada uma com pares de arquivos <nome>.jpg e <nome>_mask.png
```

upload and label your dataset, and get an API KEY here: <https://app.roboflow.com/?model=undefined&ref=unloading>  
loading Roboflow workspace...

RoboflowError: {"error":{"message":"Unsupported get request. Workspace with ID \"nome-do-workspace\" is not found."}}

RoboflowError

Traceback (most recent call last)

Cell In[52], line 8

```
4 # 2. Autenticação e download do conjunto de dados no formato de máscaras semânticas
5 from roboflow import Roboflow
6
7 rf = Roboflow(api_key="SUA_CHAVE_DE_API") # chave gratuita, obtida em app.roboflow.com
----> 8 projeto = rf.workspace("nome-do-workspace").project("nome-do-projeto")
9 dataset = projeto.version(1).download("png-mask-semantic")
10
11 # A exportação "png-mask-semantic" organiza o conjunto em pastas train/valid/test,
File ~/fz/VSCode/pdi-vc/.venv/lib/python3.13/site-packages/roboflow/__init__.py:246, in Roboflow.__init__
244 if self.api_key: # Check if api_key was passed during __init__
245     api_key = self.api_key
--> 246     list_projects = rfapi.get_workspace(api_key, the_workspace)
247     return Workspace(list_projects, api_key, the_workspace, self.model_format)
249 elif self.api_key in DEMO_KEYS:
File ~/fz/VSCode/pdi-vc/.venv/lib/python3.13/site-packages/roboflow/adapters/rfapi.py:48, in get_workspace
46 response = requests.get(url)
47 if response.status_code != 200:
---> 48     raise RoboflowError(response.text)
49 result = response.json()
50 return result
```

RoboflowError: {"error":{"message":"Unsupported get request. Workspace with ID \"nome-do-workspace\" is not found."}}

```
import glob

def carrega_split_roboflow(pasta, tam=TAM_IMG):
    # Lê os pares imagem/máscara de uma pasta exportada pela Roboflow e os
    # redimensiona para o mesmo tamanho utilizado no treinamento da U-Net.
    imagens, mascaras = [], []
    for caminho_mascara in sorted(glob.glob(f"{pasta}/*_mask.png")):
        caminho_imagem = caminho_mascara.replace("_mask.png", ".jpg")
        if not os.path.exists(caminho_imagem):
            continue
        img = cv2.resize(cv2.imread(caminho_imagem, cv2.IMREAD_GRAYSCALE), (tam, tam))
        mask = cv2.resize(cv2.imread(caminho_mascara, cv2.IMREAD_GRAYSCALE), (tam, tam))
        imagens.append(img)
        mascaras.append((mask > 127).astype(np.uint8) * 255)
    return imagens, mascaras

imgs_treino_real, masks_treino_real = carrega_split_roboflow(f"{dataset.location}/train")
imgs_val_real, masks_val_real = carrega_split_roboflow(f"{dataset.location}/valid")

X_treino_real, Y_treino_real = para_tensores(imgs_treino_real, masks_treino_real)
X_val_real, Y_val_real = para_tensores(imgs_val_real, masks_val_real)
```



```
# 3. Reaproveita a MESMA arquitetura, função de perda e laço de treinamento já
# definidos para o conjunto sintético -- apenas os tensores de entrada mudam.
modelo_unet_real = UNetCompacta()
otimizador_real = optim.Adam(modelo_unet_real.parameters(), lr=1e-3)

for epoca in range(epocas_unet):
    modelo_unet_real.train()
    perm = torch.randperm(X_treino_real.size(0))
    for i in range(0, X_treino_real.size(0), tam_lote):
        idx = perm[i:i + tam_lote]
        otimizador_real.zero_grad()
        perda = perda_segmentacao(modelo_unet_real(X_treino_real[idx]), Y_treino_real[idx])
        perda.backward()
        otimizador_real.step()

print("Treinamento da U-Net no conjunto de dados real concluído.")
```

Conjuntos de dados reais tipicamente excedem a resolução  $64 \times 64$  usada no exemplo sintético desta seção. Ao adaptar a pipeline acima a um novo conjunto de dados, é recomendável aumentar TAM\_IMG proporcionalmente à resolução das imagens originais e, se as estruturas de interesse forem pequenas em relação à imagem, ampliar também o parâmetro **base** da **UNetCompacta** ou acrescentar um quarto estágio de profundidade — o mesmo compromisso entre capacidade do modelo e custo computacional já discutido a propósito do número de camadas da CNN de classificação, agora aplicado ao contexto da segmentação.

## 9.10 Integrando Geometria e Aprendizado Profundo

O livro se encerra retomando um fio condutor que atravessou toda a Parte II: a **geometria projetiva** (transformações de perspectiva e homografia, estudadas nos Capítulos 6 e 8) e, agora, o **aprendizado profundo**, combinam-se para resolver problemas de Visão Computacional com aplicação direta no mundo real. Três aplicações ilustram essa integração.

### 9.10.1 Realidade Aumentada

A realidade aumentada sobrepõe conteúdo virtual a uma cena real, alinhado geometricamente com ela. O princípio é exatamente a **homografia** do Capítulo 8: detecta-se um marcador (ou, em sistemas modernos, características naturais da cena, aprendidas por uma rede), estima-se a transformação de perspectiva entre suas coordenadas conhecidas e sua posição na imagem, e essa mesma transformação é usada para deformar e posicionar um conteúdo virtual sobre a cena.

**Nota:** sistemas modernos de realidade aumentada (como o ARKit da Apple ou o ARCore do Google) substituem marcadores explícitos por **odometria visual-inercial** baseada em aprendizado profundo, capaz de rastrear características naturais da cena (sem a necessidade de um marcador impresso) e estimar a pose da câmera em tempo real — mas o princípio geométrico subjacente de alinhar conteúdo virtual à cena real por meio de uma transformação estimada permanece o mesmo.

### 9.10.2 Fotogrametria e Referência de Escala

Uma pergunta recorrente em aplicações práticas é: dado um objeto medido apenas em pixels em uma fotografia, qual é seu tamanho real? A resposta clássica utiliza um **objeto de referência de tamanho conhecido** presente na mesma imagem, na mesma distância aproximada da câmera:

Essa é a base da **fotogrametria** clássica — a mesma lógica se estende, com maior sofisticação geométrica (calibração de câmera, correção de distorção de lente, múltiplas vistas), a aplicações como levantamento topográfico por drones e reconstrução 3D de objetos a partir de fotografias.

```
dic = cv2.aruco.getPredefinedDictionary(cv2.aruco.DICT_4X4_50)
aruco = cv2.cvtColor(cv2.aruco.generateImageMarker(dic, 7, 200), cv2.COLOR_GRAY2BGR)

src = np.float32([[0,0],[200,0],[200,200],[0,200]])
dst = np.float32([[150,120],[430,90],[460,350],[140,380]])

cena = np.full((480,640,3), 200, np.uint8)
H, _ = cv2.findHomography(src, dst)

mask = cv2.warpPerspective(np.full((200,200),255,np.uint8), H, (640,480))
cena[mask>0] = cv2.warpPerspective(aruco, H, (640,480))[mask>0]

det = cv2.aruco.ArucoDetector(dic, cv2.aruco.DetectorParameters())
corners, ids, _ = det.detectMarkers(cena)

virtual = cv2.resize(cv2.cvtColor(skdata.astronaut(), cv2.COLOR_RGB2BGR), (200,200))
H, _ = cv2.findHomography(src, corners[0][0])

ra = cena.copy()
mask = cv2.warpPerspective(np.full((200,200),255,np.uint8), H, (640,480))
ra[mask>0] = cv2.warpPerspective(virtual, H, (640,480))[mask>0]

mm.show(
    [cv2.cvtColor(cena, cv2.COLOR_BGR2RGB),
     cv2.cvtColor(ra, cv2.COLOR_BGR2RGB)],
    titles=["Marcador detectado", "Overlay via homografia"],
    cols=2, figsize=(9,4)
)
```

Figura 9.20

```

COR_REFERENCIA = (200, 200, 200) # cartão de referência: cinza claro
COR_OBJETO = (60, 60, 220)      # objeto a medir: vermelho

# Cena original: os objetos são desenhados PREENCHIDOS, como apareceriam de fato
# em uma foto -- e não apenas como contornos de caixa delimitadora.
cena_medicao = np.full((300, 500, 3), 255, dtype=np.uint8)

cv2.rectangle(cena_medicao, (30, 200), (30 + 140, 200 + 88), COR_REFERENCIA, -1) # referência conhecida
cv2.rectangle(cena_medicao, (250, 100), (250 + 220, 100 + 150), COR_OBJETO, -1)  # objeto a medir

def caixa_delimitadora_por_cor(imagem_bgr, cor_bgr, tolerancia=40):
    diferenca = np.abs(imagem_bgr.astype(int) - np.array(cor_bgr)).sum(axis=2)
    mascara = (diferenca < tolerancia).astype(np.uint8) * 255

    contornos, _ = cv2.findContours(mascara, cv2.RETR_EXTERNAL, cv2.CHAIN_APPROX_SIMPLE)
    maior_contorno = max(contornos, key=cv2.contourArea)
    return cv2.boundingRect(maior_contorno) # (x, y, largura, altura) em pixels

x_ref, y_ref, w_ref_px, h_ref_px = caixa_delimitadora_por_cor(cena_medicao, COR_REFERENCIA)
x_obj, y_obj, w_obj_px, h_obj_px = caixa_delimitadora_por_cor(cena_medicao, COR_OBJETO)

LARGURA_REFERENCIA_CM = 8.56 # largura padrão de um cartão (ISO/IEC 7810)
razao_cm_por_px = LARGURA_REFERENCIA_CM / w_ref_px
largura_obj_cm = w_obj_px * razao_cm_por_px
altura_obj_cm = h_obj_px * razao_cm_por_px

# Painel de resultado: a MESMA cena, agora com as caixas delimitadoras detectadas
# (em verde, obtidas por segmentação de cor) e as medições estimadas sobrepostas.
resultado = cena_medicao.copy()
cv2.rectangle(resultado, (x_ref, y_ref), (x_ref + w_ref_px, y_ref + h_ref_px), (0, 180, 0), 2)
cv2.rectangle(resultado, (x_obj, y_obj), (x_obj + w_obj_px, y_obj + h_obj_px), (0, 180, 0), 2)

cv2.putText(resultado, f"{LARGURA_REFERENCIA_CM:.2f} cm",
              (x_ref, y_ref - 8), cv2.FONT_HERSHEY_SIMPLEX, 0.55, (0, 120, 0), 2)

cv2.putText(resultado,
              f"{largura_obj_cm:.1f} x {altura_obj_cm:.1f} cm",
              (x_obj, y_obj - 8), cv2.FONT_HERSHEY_SIMPLEX, 0.6, (0, 120, 0), 2)

mm.show(
    [cv2.cvtColor(cena_medicao, cv2.COLOR_BGR2RGB),
     cv2.cvtColor(resultado, cv2.COLOR_BGR2RGB)],
    titles=[
        "Cena original",
        "Caixas delimitadoras detectadas + medição por referência de escala"
    ],
    cols=2, figsize=(9,4)
)

```

Figura 9.21

### 9.10.3 Visão Estereoscópica

Enquanto a fotogrametria acima assume uma única imagem e um objeto de referência conhecido, a **visão estereoscópica** estima profundidade diretamente a partir de **duas câmeras** (ou duas fotografias da mesma cena, tiradas de posições ligeiramente diferentes) — o mesmo princípio da visão binocular humana. A ideia central é a **disparidade**: um ponto próximo à câmera se desloca mais, entre as duas imagens, do que um ponto distante.

Formalmente, a profundidade  $Z$  de um ponto se relaciona à disparidade  $d$  (a diferença de posição horizontal do mesmo ponto nas duas imagens) por:

$$Z = \frac{f \cdot B}{d},$$

em que  $f$  é a distância focal da câmera e  $B$  é a **linha de base** (*baseline*) — a distância entre os dois pontos de captura. Quanto maior a disparidade, menor a profundidade (objeto mais próximo).

```
img_base = cv2.cvtColor(skdata.astronaut(), cv2.COLOR_RGB2GRAY)

DESLOC_FUNDO = 4      # pequeno deslocamento: objeto distante
DESLOC_OBJETO = 22    # grande deslocamento: objeto próximo à câmera

def deslocar(imagem, dx):
    M = np.float32([[1, 0, dx], [0, 1, 0]])
    return cv2.warpAffine(imagem, M, (imagem.shape[1], imagem.shape[0]))

img_esquerda = img_base.copy()
img_direita = deslocar(img_base, -DESLOC_FUNDO)

# Simula um objeto em primeiro plano com deslocamento (disparidade) maior
y0, y1, x0, x1 = 180, 340, 200, 360
img_direita[y0:y1, x0:x1] = deslocar(img_base, -DESLOC_OBJETO)[y0:y1, x0:x1]

correspondencia_estereo = cv2.StereoBM_create(numDisparities=32, blockSize=15)
mapa_disparidade = correspondencia_estereo.compute(img_esquerda, img_direita).astype(np.float32) / 16.0

disp_fundo = mapa_disparidade[:,150, :150].mean()
disp_objeto = mapa_disparidade[200:320, 220:340].mean()
print(f"Disparidade média no fundo: {disp_fundo:.2f} px")
print(f"Disparidade média no objeto em primeiro plano: {disp_objeto:.2f} px")
print("> Disparidade maior = objeto mais próximo da câmera, como previsto pela equação Z = f·B/d.")

mm.show(
    [img_esquerda, img_direita, mapa_disparidade],
    titles=["Imagem Esquerda", "Imagem Direita", "Mapa de Disparidade"],
    cols=3, figsize=(10, 3.5)
)
```

Figura 9.22

**Nota:** métodos clássicos de correspondência estéreo, como o utilizado acima, comparam diretamente blocos de pixels entre as duas imagens — uma tarefa que sofre em regiões de textura pouco distintiva (paredes lisas, céu). Redes neurais de **estimativa de profundidade monocular** (a partir de uma única imagem) e de **correspondência estéreo aprendida** superam essa limitação aprendendo priors visuais sobre a estrutura de cenas do mundo real a partir de grandes volumes de dados — um caso de uso direto das CNNs estudadas neste capítulo aplicado diretamente ao problema geométrico com o qual o livro se encerra.

## 9.11 Resumo

Este capítulo, que encerra a Parte II do livro, apresentou:

- **Convolução e pooling aprendidos:** a mesma operação matemática de convolução do Capítulo 3, mas com *kernels* tratados como parâmetros ajustados por treinamento, em vez de definidos manualmente;
- **Compartilhamento de pesos e hierarquia de características** como as propriedades que tornam as CNNs eficientes e capazes de aprender representações cada vez mais abstratas em camadas sucessivas;
- **Treinamento de uma CNN do zero**, com desempenho comparável — e não necessariamente superior — aos classificadores clássicos do Capítulo 7 em uma base pequena e simples, reforçando que a escolha do método deve ser proporcional à complexidade real do problema;
- **Transferência de aprendizado**, demonstrada experimentalmente como uma estratégia eficaz para tarefas com poucos dados rotulados, reaproveitando um extrator de características já treinado em uma tarefa relacionada — e suas limitações, na forma da transferência negativa entre domínios muito distintos;
- **Aplicações em larga escala** com modelos pré-treinados de classificação, detecção (Faster R-CNN) e segmentação (DeepLabV3), seguindo o mesmo princípio de transferência de aprendizado em escala industrial;
- **Transferência de aprendizado aplicada à detecção de objetos**, ajustando um YOLO pré-treinado na COCO para localizar e classificar objetos geométricos sintéticos, ilustrando o mesmo princípio de congelamento parcial em um domínio de origem e destino ainda mais distantes entre si;
- **Segmentação semântica com U-Net**, implementada e treinada do zero sobre um conjunto sintético de baixo contraste, superando uma linha de base clássica de limiarização graças às conexões de atalho entre codificador e decodificador — e reaproveitada, sem qualquer alteração de arquitetura, sobre um conjunto de dados real obtido via Roboflow;
- A integração de **geometria computacional** (homografia, calibração) e **aprendizado profundo** em três aplicações reais que encerram o livro: **realidade aumentada**, **fotogrametria** e **visão estereoscópica**.

## 9.12 Uso do Gemini Notebook como Tutor Complementar

Nesta edição, o uso do **Gemini Notebook** é incentivado como ferramenta complementar de aprendizagem. Baseado em inteligência artificial, o sistema utiliza exclusivamente os documentos fornecidos pelo autor como fonte de conhecimento, produzindo respostas alinhadas ao conteúdo e à abordagem adotada ao longo deste capítulo.

 Estude com o Tutor Inteligente

 [ACESSAR Gemini Notebook: CAPÍTULO 09](#)

 **Aviso sobre Conteúdo Gerado por IA**

Embora seja uma ferramenta valiosa de apoio aos estudos, o Gemini Notebook pode eventualmente produzir respostas incompletas, imprecisas ou incorretas. Recomenda-se validar as informações consultando o material do capítulo, livros, artigos científicos e outras fontes acadêmicas confiáveis. Sempre que possível, execute e experimente os exemplos práticos apresentados ao longo do texto para consolidar a compreensão dos conceitos.

## 9.13 Lista de Exercícios

Os exercícios a seguir consolidam os conceitos apresentados neste capítulo por meio de adaptações, experimentos e extensões dos algoritmos desenvolvidos ao longo do texto, utilizando as bibliotecas **PyTorch**, **ultralytics** e a biblioteca didática **morph**.

1. **(10%)** Investigue o impacto da profundidade em uma arquitetura convolucional. Partindo da rede de duas camadas do Projeto Prático 1, adicione uma terceira camada convolucional com 32 filtros antes das camadas totalmente conectadas. Treine a nova arquitetura mantendo o mesmo número de épocas e a mesma divisão dos dados. Compare a acurácia no conjunto de teste e o número total de parâmetros treináveis em relação à rede original, discutindo se o aumento de profundidade trouxe benefício mensurável para imagens de dimensão  $8 \times 8$ .
2. **(15%)** Avalie o limiar de dados necessários no domínio de destino para que o treinamento de uma CNN do zero se torne competitivo com a **transferência de aprendizado**. Variando o número de amostras de treino disponíveis no domínio B para  $\{5, 10, 20, 40, 80\}$ , meça a acurácia de teste para ambas as estratégias. Apresente os resultados em um gráfico de linhas e determine a partir de qual volume de dados o treinamento do zero atinge desempenho equivalente ao extrator pré-treinado.
3. **(15%)** Investigue a estratégia de **ajuste fino parcial** (*fine-tuning*) em comparação ao congelamento total de pesos. No cenário de transferência de aprendizado entre domínios de dígitos, descongele a segunda camada convolucional (**conv2**) do extrator para que ela seja atualizada juntamente com a cabeça de classificação durante o treinamento no domínio B. Compare a acurácia obtida com o congelamento total e com o treinamento do zero, discutindo o compromisso entre capacidade de adaptação e risco de sobreajuste (*overfitting*).
4. **(15%)** Analise a relação inversa entre **disparidade e profundidade em visão estereoscópica**. Utilizando a equação  $Z = (f \cdot B)/d$  com distância focal  $f = 700$  pixels e linha de base  $B = 6$  cm, calcule a profundidade estimada para o fundo e para o objeto em primeiro plano no experimento do capítulo. Em seguida, gere sinteticamente um terceiro objeto com um deslocamento intermediário de 12 pixels, recalcule sua profundidade e construa um gráfico mostrando a curva teórica  $Z(d)$  com os três pontos experimentais destacados.
5. **(15%)** Avalie a influência da profundidade do congelamento (*freeze*) no desempenho de detectores **YOLO** submetidos à transferência de aprendizado. Utilizando o conjunto de dados sintético de formas geométricas, execute o ajuste fino variando o parâmetro de congelamento do *backbone* para  $\{0, 5, 10, 15\}$ . Registre a métrica  $mAP_{50}$  no conjunto de validação para cada configuração, apresente os dados em uma tabela e discuta se o congelamento parcial é vantajoso quando os domínios de origem (COCO) e de destino (formas geométricas) são significativamente distantes.
6. **(15%)** Estude a importância das **conexões de atalho** (*skip connections*) na arquitetura **U-Net** para segmentação semântica. Implemente uma variação **UNetSemAtalhos** que funcione como um *autoencoder* convolucional tradicional, removendo as concatenações entre os estágios do codificador e do decodificador. Treine ambos os modelos sobre a mesma base de nódulos sintéticos, compare o IoU médio no conjunto de validação e apresente visualmente a diferença na precisão das bordas segmentadas por cada método.
7. **(15%)** Integre um *pipeline* completo de segmentação semântica utilizando dados do repositório público **Roboflow**. Baixe um conjunto de dados anotado no formato de máscaras semânticas, converta os pares de imagens e máscaras para os tensores do PyTorch e treine a **UNetCompacta**. Compare o IoU médio obtido pelo modelo profundo contra uma linha de base clássica baseada em limiarização de Otsu e filtros morfológicos da biblioteca **morph**, discutindo em quais cenários reais o aprendizado profundo justifica o custo computacional do treinamento.
8. **(Bônus – 10%)** Desenvolva um sistema interativo que combine **detecção de objetos (YOLO)** com **medição por referência de escala (fotogrametria)**. Treine o detector para identificar duas classes em uma cena: um “Cartão de Referência” (dimensão conhecida de  $8,56 \text{ cm} \times 5,39 \text{ cm}$ ) e um “Objeto Alvo”. Ao realizar a inferência em uma nova imagem, utilize a dimensão em pixels da *bounding box* do cartão detectado para converter as dimensões da caixa do objeto alvo em centímetros. Exiba a imagem processada com os rótulos de classe, a probabilidade de confiança e as dimensões físicas estimadas sobrepostas.

## 9.14 Encerramento da Parte II

Este capítulo conclui a Parte II do livro — e, com ela, a jornada que começou no Capítulo 6 com a formalização de “detectar, descrever e corresponder” características em imagens. Ao longo do caminho, um mesmo tema



conceitual se repetiu sob formas cada vez mais sofisticadas: a tensão entre **características projetadas manualmente** (Sobel, LBP, HOG, ORB, Haar Cascade) e **características aprendidas automaticamente** (as CNNs deste capítulo) — e a constatação experimental, repetida em três capítulos consecutivos, de que nenhuma das duas abordagens é universalmente superior: a escolha correta depende da complexidade real do problema, da quantidade de dados disponível e das restrições computacionais da aplicação.

Para o leitor interessado em aprofundar os tópicos aqui apresentados apenas em suas ideias centrais, algumas direções naturais de estudo incluem:

- **Arquiteturas modernas de CNN** (ResNet, EfficientNet, Vision Transformers) e as inovações que permitiram treinar redes cada vez mais profundas;
- **Detecção e segmentação em tempo real**, com foco nas famílias YOLO e nos modelos de segmentação promptable como o Segment Anything;
- **Reconstrução 3D e SLAM** (*Simultaneous Localization and Mapping*), que estendem a visão estereoscópica deste capítulo a cenários dinâmicos, com câmeras em movimento;
- **Modelos generativos** para imagens (GANs, modelos de difusão), capazes de sintetizar, e não apenas interpretar, conteúdo visual.

Os fundamentos consolidados nesta Parte II — desde a extração de características mais simples até as CNNs — são a base sobre a qual todas essas direções mais avançadas se apoiam.

## Referências do Capítulo

Os conceitos e algoritmos apresentados neste capítulo foram fundamentados em referências clássicas e contemporâneas da literatura de *Deep Learning* aplicado à Visão Computacional:

- Rosenblatt (1958), para a formulação original do **Perceptron**, modelo precursor do neurônio artificial utilizado nas arquiteturas modernas de aprendizado profundo.
- Goodfellow; Bengio; Courville (2016) e LeCun; Bengio; Hinton (2015), para os fundamentos de redes neurais, convolução, funções de ativação e treinamento de modelos profundos.
- Bishop (2006), para ...
- Ronneberger; Fischer; Brox (2015) para a arquitetura **U-Net**, utilizada na segmentação semântica com conexões de atalho entre codificador e decodificador.
- Redmon et al. (2016), para a arquitetura **YOLO** (*You Only Look Once*), utilizada nos experimentos de detecção de objetos com transferência de aprendizado.
- Ren et al. (2015), para a arquitetura **Faster R-CNN**, empregada como modelo pré-treinado de detecção de objetos.
- He et al. (2016), para a arquitetura **ResNet**, base de diversos extratores de características pré-treinados utilizados neste capítulo.
- Chen et al. (2018), para a arquitetura **DeepLabV3**, utilizada como modelo pré-treinado de segmentação semântica.
- Kirillov et al. (2023), para o modelo **Segment Anything (SAM)**, mencionado como direção de estudo para segmentação promptable.
- Google (2025), referente à ferramenta **Gemini Notebook**, utilizada na elaboração do infográfico de síntese do capítulo e disponibilizada como apoio complementar ao estudo.



### 9.15 Parte Prática com Exercícios de Programação

#### Em construção!

A presente lista de exercícios de programação (EP) consolida as formulações teóricas apresentadas ao longo do Capítulo 9 — *Deep Learning* para Visão Computacional — por meio de uma trilha prática aplicada.

Diferentemente do treinamento de redes neurais completas com PyTorch, que exige tempo de execução e, por vezes, GPU, os EPs deste capítulo isolam as **grandezas intermediárias** de um *pipeline* real de aprendizado profundo — a saída de uma única camada convolucional, o resultado de uma operação de *pooling*, a contagem de parâmetros treináveis de uma arquitetura, a sobreposição entre caixas delimitadoras candidatas e o filtro de supressão de não-máximos — permitindo validar manualmente cada etapa do raciocínio sem depender de bibliotecas de aprendizado de máquina nem de treinamento real.

O encadeamento dos exercícios reproduz o fluxo conceitual do capítulo: inicia-se com o cálculo manual da saída de uma **camada convolucional aprendida**, a partir de um *kernel* e um viés já treinados; avança-se para a operação de ***pooling*** (máximo e média), que reduz a resolução espacial entre blocos convolucionais; prossegue-se com a **contagem de parâmetros treináveis** de uma arquitetura CNN completa, evidenciando por que o compartilhamento de pesos torna essas redes tão mais econômicas que uma camada totalmente conectada equivalente; aprofunda-se no cálculo de **Interseção sobre União (IoU)** e na **Supressão de Não-Máximos (NMS)**, etapa de pós-processamento comum a detectores como o Faster R-CNN e o YOLO; e conclui-se com um ***pipeline* integrado**, unindo a saída de um detector de objetos (após NMS) a uma medição do mundo real por referência de escala — o mesmo princípio da fotogrametria estudada na integração final do capítulo.

### ! Diretrizes para a Resolução dos Exercícios de Programação

Em todos os exercícios deste capítulo, as etapas de discretização ou arredondamento numérico devem empregar o arredondamento padrão para o inteiro mais próximo (*round half away from zero*), mitigando ambiguidades em valores com fração exatamente igual a 0,5. Salvo indicação explícita em contrário: (i) a operação de “convolução” segue a convenção adotada pelos *frameworks* de aprendizado profundo — **correlação cruzada**, sem inversão espacial do *kernel*, exatamente como apresentado na Seção “Convolução como Camada Aprendida”; (ii) o preenchimento (*padding*) é feito com zeros; (iii) caixas delimitadoras são especificadas no formato canto-a-canto  $(x_1, y_1, x_2, y_2)$ , com  $x_1 < x_2$  e  $y_1 < y_2$ ; e (iv) vetores/matrizes seguem indexação a partir de 0, com a convenção [linha] [coluna] para estruturas bidimensionais.

## 🎯 Objetivo deste Caderno

O caderno permite desenvolver, validar, organizar e testar soluções de **Exercícios de Programação (EPs)** em ambientes interativos, como o Colab, com os mesmos casos de teste do Moodle, copiando para lá apenas na hora de registrar a nota oficial.

## Download

Baixe `morph.py` e `testsuite.py` executando a célula abaixo:

```
import os, sys, importlib, inspect, urllib.request

# URLs do repositório
BASE_URL = "https://raw.githubusercontent.com/fzampirolli/pdi-vc/master/morph"
for f in ["morph.py", "testsuite.py"]:
    if not os.path.exists(f):
        urllib.request.urlretrieve(f"{BASE_URL}/{f}", f)

import morph, testsuite
importlib.reload(morph); importlib.reload(testsuite)
from morph import mm
from testsuite import TestSuite

print(f" Ambiente pronto. Morph: {morph.__version__} | TestSuite: {testsuite.__version__}")
```

Ambiente pronto. Morph: 1.1.7 | TestSuite: 1.1.2

## Executando os Testes

Para avaliar os testes, execute `TestSuite("EP09_01.extensão").run()` numa nova célula, trocando a extensão pela da linguagem usada (.py, .java, .c, .cpp, .js ou .r). O sistema baixa os casos de teste do GitHub, executa o programa e calcula a nota automaticamente.

Para testar código Python diretamente, sem salvar arquivo, use `run_code(codigo)` passando o código como *string* numa variável `codigo`:

```
codigo = """
# ... seu código aqui ...
"""
TestSuite("EP09_01").run_code(codigo)
```

### 9.15.1 EP09\_01 ● Convolução 2D Manual (Forward de uma Camada Aprendida)

O PyTorch, apresentado neste capítulo, executa `nn.Conv2d(x)` em uma única chamada — mas por trás dessa chamada está apenas a operação de correlação cruzada entre um *kernel* (já treinado) e uma vizinhança da entrada, seguida da soma de um viés e de uma ativação, exatamente como formalizado na Seção “Convolução como Camada Aprendida”. A diferença essencial em relação à convolução fixa do Capítulo 3 é que, aqui, os valores do *kernel* e do viés **já vêm prontos** (como se tivessem sido aprendidos por gradiente), e cabe a você reproduzir manualmente a passagem direta (*forward pass*) que o *framework* executa internamente.

Antes de treinar uma CNN de verdade, você foi encarregado de implementar essa passagem direta do zero, para uma única camada convolucional com um único canal de entrada e um único filtro de saída, incluindo suporte a *padding* e *stride* arbitrários.

#### 9.15.1.1 📋 Diretrizes de Implementação

1. **Entrada:** Ler as dimensões  $H \times W$  do mapa de características de entrada e, em seguida, seus  $H \times W$  valores reais.
2. **Kernel e viés:** Ler as dimensões  $k_h \times k_w$  do *kernel* (já treinado), seus valores reais, e o viés  $b$  (real, escalar).
3. **Hiperparâmetros:** Ler o *padding*  $p$  (inteiro, número de zeros adicionados em cada borda) e o *stride*  $s$  (inteiro, passo do deslizamento).
4. **Preenchimento:** Adicionar  $p$  zeros em cada uma das quatro bordas do mapa de entrada antes da correlação.
5. **Correlação cruzada:** Para cada posição de saída  $(i, j)$ , calcular

$$z(i, j) = b + \sum_{u=0}^{k_h-1} \sum_{v=0}^{k_w-1} K(u, v) \cdot X_{pad}(i \cdot s + u, j \cdot s + v),$$

percorrendo a entrada **sem** inverter o *kernel* (convenção dos *frameworks* de aprendizado profundo, diferente da convolução matemática clássica).

6. **Ativação:** Aplicar ReLU a cada valor:  $a(i, j) = \max(0, z(i, j))$ .
7. **Dimensões de saída:**  $O_h = \lfloor (H + 2p - k_h) / s \rfloor + 1$  e  $O_w = \lfloor (W + 2p - k_w) / s \rfloor + 1$ .
8. **Saída:** Imprimir  $O_h$  e  $O_w$  na primeira linha, seguidos de  $O_h$  linhas com  $O_w$  valores reais cada (o mapa de características de saída, já com ReLU aplicada), formatados com 4 casas decimais.

#### 9.15.1.2 🚫 Restrições Computacionais

- **Um canal de entrada, um filtro de saída:** não é necessário lidar com múltiplos canais ou múltiplos filtros nesta versão simplificada.
- **Sem inversão do *kernel*:** implemente correlação cruzada, não a convolução matemática clássica com *kernel* invertido — é essa a operação que o PyTorch (e a maioria dos *frameworks*) chama de “convolução”.
- **Preenchimento por zeros:** os  $p$  pixels adicionados em cada borda valem sempre 0.

- **Formatação:** todos os valores de saída devem ter exatamente 4 casas decimais, mesmo quando o valor é inteiro (ex.: 2.0000).

### 9.15.1.3 Fundamentação Teórica

| Elemento           | Papel na camada convolucional                                                                                                  |
|--------------------|--------------------------------------------------------------------------------------------------------------------------------|
| <i>Kernel</i> $K$  | Parâmetros aprendidos por gradiente, análogos aos filtros de Sobel do Capítulo 3, mas ajustados a partir de dados              |
| Viés $b$           | Parâmetro aprendido, somado à saída de cada janela                                                                             |
| <i>Padding</i> $p$ | Controla a dimensão espacial da saída; $p = 0$ (“ <i>valid</i> ”) reduz a resolução, $p$ maior preserva-a                      |
| <i>Stride</i> $s$  | Passo do deslizamento; $s > 1$ sub-amostra a saída, reduzindo custo computacional                                              |
| ReLU               | Ativação não-linear aplicada após cada convolução, sem a qual camadas empilhadas colapsariam em uma única transformação linear |

### 9.15.1.4 Especificação de Entrada e Saída (VPL)

#### Entrada:

- Linha 1: Inteiros  $H$  e  $W$ .
- Próximas  $H$  linhas:  $W$  valores reais cada (mapa de entrada).
- Próxima linha: Inteiros  $k_h$  e  $k_w$ .
- Próximas  $k_h$  linhas:  $k_w$  valores reais cada (*kernel*).
- Próxima linha: Um valor real  $b$  (viés).
- Próxima linha: Inteiros  $p$  e  $s$  (*padding* e *stride*).

#### Saída:

- Linha 1: Inteiros  $O_h$  e  $O_w$ .
- Próximas  $O_h$  linhas:  $O_w$  valores reais cada, formatados com 4 casas decimais.

### 9.15.1.5 Exemplos

| Entrada | Saída         | Observação                                                               |
|---------|---------------|--------------------------------------------------------------------------|
| 3 3     | 2 2           | <i>Padding</i> 0, <i>stride</i> 1: saída $2 \times 2$ sem preenchimento. |
| 1 2 0   | 2.0000 3.0000 |                                                                          |
| 0 1 2   | 0.0000 2.0000 |                                                                          |
| 1 0 1   |               |                                                                          |
| 2 2     |               |                                                                          |
| 1 1     |               |                                                                          |
| 1 1     |               |                                                                          |
| -2      |               |                                                                          |
| 0 1     |               |                                                                          |

| Entrada | Saída         | Observação                                                                    |
|---------|---------------|-------------------------------------------------------------------------------|
| 3 3     | 2 2           | <i>Padding 1, stride 2:</i> entrada preenchida com zeros antes da correlação. |
| 1 2 0   | 1.0000 0.0000 |                                                                               |
| 0 1 2   | 1.0000 2.0000 |                                                                               |
| 1 0 1   |               |                                                                               |
| 2 2     |               |                                                                               |
| 1 0     |               |                                                                               |
| 0 1     |               |                                                                               |
| 0       |               |                                                                               |
| 1 2     |               |                                                                               |




Figura 9.23: Simulador: Convolução 2D Manual (correlação cruzada + viés + ReLU)

```
%%writefile EP09_01.py
# Código Python
```

```
Writing EP09_01.py
```

```
TestSuite("EP09_01.py").run()
```

### 9.15.2 EP09\_02 ● *Pooling* Manual (Máximo e Média)

Entre blocos convolucionais, a arquitetura típica de uma CNN intercala camadas de *pooling*, que reduzem a resolução espacial do mapa de características sem introduzir novos parâmetros treináveis — ao contrário da convolução, o *pooling* não tem pesos: ele apenas resume cada janela da entrada a um único valor, por um máximo ou por uma média.

Você foi encarregado de implementar essa operação a partir de uma janela deslizante quadrada, sem sobreposição parcial nas bordas (apenas janelas completas), suportando os dois tipos mais comuns: **max** (preserva o valor mais saliente, tipicamente usado para reter bordas e texturas fortes) e **avg** (suaviza a região, preservando informação de intensidade média).

### 9.15.2.1 Diretrizes de Implementação

1. **Entrada:** Ler as dimensões  $H \times W$  do mapa de características de entrada e seus  $H \times W$  valores reais.
2. **Janela:** Ler os inteiros  $k$  (tamanho da janela quadrada  $k \times k$ ) e  $s$  (*stride*).
3. **Tipo:** Ler uma *string*, **max** ou **avg**, indicando o tipo de *pooling*.
4. **Sem preenchimento:** Esta operação **não** utiliza *padding*; janelas que ultrapassariam a borda da entrada são descartadas.
5. **Cálculo:** Para cada posição de saída  $(i, j)$ , calcular o máximo ou a média dos  $k \times k$  valores da janela correspondente, iniciando em  $(i \cdot s, j \cdot s)$ .
6. **Dimensões de saída:**  $O_h = \lfloor (H - k)/s \rfloor + 1$  e  $O_w = \lfloor (W - k)/s \rfloor + 1$ .
7. **Saída:** Imprimir  $O_h$  e  $O_w$  na primeira linha, seguidos de  $O_h$  linhas com  $O_w$  valores reais cada, formatados com 4 casas decimais.

### 9.15.2.2 Restrições Computacionais

- **Janela quadrada:**  $k \times k$ , sem suporte a janelas retangulares nesta versão.
- **Sem *padding*:** apenas janelas inteiramente contidas na entrada são consideradas.
- **avg usa divisão real:** a média é sempre soma/ $k^2$ , mesmo quando o resultado tem muitas casas decimais — arredonde apenas na formatação final, conforme a diretriz geral do capítulo.
- **Formatação:** todos os valores de saída com exatamente 4 casas decimais.

### 9.15.2.3 Fundamentação Teórica

| Elemento               | Papel na arquitetura                                                                                               |
|------------------------|--------------------------------------------------------------------------------------------------------------------|
| <i>Pooling</i> máximo  | Preserva a ativação mais forte da janela; comum após camadas convolucionais para reter bordas e texturas salientes |
| <i>Pooling</i> médio   | Suaviza a região, preservando a intensidade média; comum em camadas finais ( <i>global average pooling</i> )       |
| Ausência de parâmetros | Diferencia o <i>pooling</i> da convolução: reduz resolução espacial sem custo adicional de treinamento             |
| Redução de resolução   | Contribui para a invariância a pequenas translações e para a redução do custo computacional das camadas seguintes  |

### 9.15.2.4 Especificação de Entrada e Saída (VPL)

#### Entrada:

- Linha 1: Inteiros  $H$  e  $W$ .
- Próximas  $H$  linhas:  $W$  valores reais cada.
- Próxima linha: Inteiros  $k$  e  $s$ .
- Próxima linha: **max** ou **avg**.

#### Saída:

- Linha 1: Inteiros  $O_h$  e  $O_w$ .
- Próximas  $O_h$  linhas:  $O_w$  valores reais cada, formatados com 4 casas decimais.

### 9.15.2.5 Exemplos



| Entrada | Saída         | Observação                                                    |
|---------|---------------|---------------------------------------------------------------|
| 4 4     | 2 2           | <i>Pooling</i> máximo, janela $2 \times 2$ , <i>stride</i> 2. |
| 1 3 2 4 | 6.0000 4.0000 |                                                               |
| 5 6 1 2 | 4.0000 5.0000 |                                                               |
| 2 1 0 3 |               |                                                               |
| 4 2 5 1 |               |                                                               |
| 2 2     |               |                                                               |
| max     |               |                                                               |
| 4 4     | 2 2           | <i>Pooling</i> médio sobre as mesmas janelas.                 |
| 1 3 2 4 | 3.7500 2.2500 |                                                               |
| 5 6 1 2 | 2.2500 2.2500 |                                                               |
| 2 1 0 3 |               |                                                               |
| 4 2 5 1 |               |                                                               |
| 2 2     |               |                                                               |
| avg     |               |                                                               |




Figura 9.24: Simulador: Pooling Manual (máximo vs. média)

```
%%writefile EP09_02.py
# Código Python

Writing EP09_02.py

TestSuite("EP09_02.py").run()
```

9.15.3 EP09\_03 ● Contagem de Parâmetros Treináveis de uma CNN

O Exercício 1 deste capítulo pediu para adicionar uma terceira camada convolucional à CNN do Projeto Prático 1 e comparar o número de parâmetros da rede resultante. Este EP formaliza esse cálculo: dada a

descrição textual de uma arquitetura — uma sequência de camadas convolucionais, de *pooling* e totalmente conectadas — determine, para cada camada, o número de parâmetros treináveis e o total da rede.

O ponto central deste exercício é notar que a contagem de parâmetros de uma camada convolucional depende **apenas** do tamanho do *kernel* e do número de canais de entrada/saída — **nunca** das dimensões espaciais ( $H \times W$ ) do mapa de características, graças ao **compartilhamento de pesos**: o mesmo *kernel* desliza por toda a imagem, seja ela  $28 \times 28$  ou  $280 \times 280$ . É exatamente esse compartilhamento que torna as CNNs muito mais econômicas em parâmetros do que uma camada totalmente conectada equivalente, na qual cada pixel de entrada tem uma conexão (e um peso) independente para cada neurônio de saída.

### 9.15.3.1 Diretrizes de Implementação

1. **Entrada:** Ler o inteiro  $L$  (número de camadas da arquitetura, na ordem em que são aplicadas).
2. **Camadas:** Ler  $L$  linhas, cada uma descrevendo uma camada em um dos três formatos:
  - CONV  $k_h$   $k_w$   $c_{in}$   $c_{out}$   $bias$  — camada convolucional com *kernel*  $k_h \times k_w$ ,  $c_{in}$  canais de entrada,  $c_{out}$  canais (filtros) de saída, e  $bias$  (0 ou 1) indicando se há viés por filtro;
  - POOL — camada de *pooling* (máximo ou médio; não possui parâmetros treináveis);
  - FC  $in$   $out$   $bias$  — camada totalmente conectada com  $in$  entradas,  $out$  saídas, e  $bias$  (0 ou 1) indicando se há viés por neurônio.
3. **Parâmetros de uma camada CONV:**  $k_h \cdot k_w \cdot c_{in} \cdot c_{out} + c_{out} \cdot bias$ .
4. **Parâmetros de uma camada FC:**  $in \cdot out + out \cdot bias$ .
5. **Parâmetros de uma camada POOL:** sempre 0.
6. **Saída:** Para cada camada, na ordem de leitura, imprimir **Camada  $i$ :**  $P$ , onde  $i$  começa em 1 e  $P$  é o número de parâmetros daquela camada. Ao final, imprimir **Total:**  $T$ , com  $T$  igual à soma de parâmetros de todas as camadas.

### 9.15.3.2 Restrições Computacionais

- **Independência da dimensão espacial:** a entrada **não** informa  $H \times W$  — a contagem de uma camada CONV não depende disso, apenas de  $k_h$   $k_w$   $c_{in}$   $c_{out}$ .
- **bias sempre 0 ou 1:** multiplique diretamente o termo de viés por esse valor, sem tratamento condicional especial.
- **Camadas POOL sem argumentos adicionais:** a linha contém apenas a palavra POOL.
- Todos os valores de entrada e saída são inteiros não-negativos.

### 9.15.3.3 Fundamentação Teórica

| Elemento                  | Papel na contagem de parâmetros                                                                                                                                   |
|---------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Compartilhamento de pesos | O mesmo <i>kernel</i> $k_h \times k_w$ é reutilizado em toda a extensão espacial da entrada — por isso a contagem independe de $H \times W$                       |
| Canais de entrada/saída   | Cada um dos $c_{out}$ filtros possui um conjunto de pesos por canal de entrada, daí o fator $c_{in} \cdot c_{out}$                                                |
| Viés                      | Um único escalar por filtro (CONV) ou por neurônio (FC), independente do tamanho do <i>kernel</i> ou da entrada                                                   |
| Camada FC                 | Cada uma das $in$ entradas conecta-se a cada uma das $out$ saídas — sem compartilhamento, o que explica seu custo tipicamente muito maior em número de parâmetros |

### 9.15.3.4 Especificação de Entrada e Saída (VPL)

**Entrada:**

- Linha 1: Inteiro  $L$ .
- Próximas  $L$  linhas: descrição de cada camada, no formato CONV  $kh\ kw\ cin\ cout\ bias$ , POOL, ou FC  $in\ out\ bias$ .

**Saída:**

- $L$  linhas no formato Camada  $i$ :  $P$ .
- Última linha: Total:  $T$ .

**9.15.3.5 Exemplos**

| Entrada         | Saída           | Observação                                                                                     |
|-----------------|-----------------|------------------------------------------------------------------------------------------------|
| 3               | Camada 1: 80    | Rede com uma convolução, um pooling e uma camada final.                                        |
| CONV 3 3 1 8 1  | Camada 2: 0     |                                                                                                |
| POOL            | Camada 3: 13530 |                                                                                                |
| FC 1352 10 1    | Total: 13610    |                                                                                                |
| 4               | Camada 1: 80    | Rede com duas convoluções empilhadas, como no Projeto Prático 1; a última camada não usa viés. |
| CONV 3 3 1 8 1  | Camada 2: 1168  |                                                                                                |
| CONV 3 3 8 16 1 | Camada 3: 0     |                                                                                                |
| POOL            | Camada 4: 2048  |                                                                                                |
| FC 64 32 0      | Total: 3296     |                                                                                                |

Simulador: Contagem de Parâmetros

compartilhamento de pesos

Ajuste o kernel e os canais de uma camada CONV e compare com uma camada FC equivalente, para uma entrada hipotética de 32×32 pixels.

kernel (k×k)

3×3

canais de entrada

1

canais de saída (filtros)

8

☒ usar viés

CONV:  $3 \times 3 \times 1 \times 8 + 8 \times 1 = 80$  parâmetros

FC equivalente (entrada 32×32×1 → 8 saídas): 8.200 parâmetros

↳ a camada FC teria 102.5× mais parâmetros que a CONV equivalente, apesar de "ver" a mesma entrada.

Figura 9.25: Simulador: Contagem de Parâmetros — Convolução vs. Camada Totalmente Conectada

```
%writefile EP09_03.py
# Código Python
```

```
Writing EP09_03.py
```

```
TestSuite("EP09_03.py").run()
```

**9.15.4 EP09\_04 Interseção sobre União (IoU) e Supressão de Não-Máximos (NMS)**

Tanto o Faster R-CNN quanto o YOLO, apresentados na seção “Aplicações em Larga Escala” e no Projeto Prático 2 deste capítulo, produzem internamente  **muito mais**  caixas delimitadoras candidatas do que objetos realmente existem na imagem — várias delas cobrindo, com pequenas variações, o mesmo objeto. A etapa de

pós-processamento responsável por eliminar essas redundâncias é a **Supressão de Não-Máximos (NMS)**, e sua peça fundamental é a métrica de **Interseção sobre União (IoU)**, que mede o quanto duas caixas se sobrepõem — a mesma métrica usada, por exemplo, para definir o limiar de acerto do mAP50 calculado no Projeto Prático 2 ( $\text{IoU} \geq 0,5$  com a caixa verdadeira).

Você foi encarregado de implementar o algoritmo de NMS do zero: dado um conjunto de caixas candidatas com suas pontuações de confiança, filtrar as redundantes e manter apenas as detecções mais confiáveis e suficientemente distintas entre si.

#### 9.15.4.1 Diretrizes de Implementação

1. **Entrada:** Ler o inteiro  $N$  (número de caixas candidatas) e o limiar real  $\tau$  (limiar de IoU para supressão).
2. **Caixas:** Ler  $N$  linhas, cada uma com cinco valores reais:  $x_1, y_1, x_2, y_2, \text{score}$  (canto superior-esquerdo, canto inferior-direito, pontuação de confiança).
3. **Interseção sobre União:** Para duas caixas  $A$  e  $B$ ,

$$\text{IoU}(A, B) = \frac{\text{área}(A \cap B)}{\text{área}(A) + \text{área}(B) - \text{área}(A \cap B)},$$

onde a área de interseção é calculada pela sobreposição dos intervalos em  $x$  e em  $y$  (zero se não houver sobreposição).

4. **Algoritmo guloso de NMS:**
  - a. Ordene as caixas por **score** decrescente (em caso de empate, mantenha a ordem de leitura original — ordenação estável).
  - b. Selecione a caixa de maior pontuação entre as restantes; adicione-a ao conjunto de saída e remova-a da lista.
  - c. Calcule o IoU dessa caixa selecionada com **todas** as caixas ainda restantes; remova (suprima) qualquer caixa com  $\text{IoU} > \tau$ .
  - d. Repita os passos (b)–(c) até que não restem caixas.
5. **Saída:** Para cada caixa mantida, na ordem em que foi selecionada, imprimir seu índice original (posição de leitura, começando em 0) e seu **score**, formatado com 4 casas decimais. Ao final, imprimir **Total mantidas: X**.

#### 9.15.4.2 Restrições Computacionais

- **Supressão estrita:** apenas caixas com  $\text{IoU} > \tau$  são suprimidas; caixas com IoU exatamente igual a  $\tau$  são **mantidas**.
- **Índices originais:** a saída referencia a posição em que cada caixa foi lida na entrada (começando em 0), não sua posição após a ordenação.
- **Retângulos alinhados aos eixos:** todas as caixas são especificadas por dois cantos, com  $x_1 < x_2$  e  $y_1 < y_2$  garantidos na entrada.

#### 9.15.4.3 Fundamentação Teórica

| Elemento                | Papel no pós-processamento de detecção                                                                                               |
|-------------------------|--------------------------------------------------------------------------------------------------------------------------------------|
| IoU                     | Quantifica a sobreposição espacial entre duas caixas; $\text{IoU} = 1$ para caixas idênticas, $\text{IoU} = 0$ para caixas disjuntas |
| Limiar $\tau$           | Controla a agressividade da supressão: $\tau$ baixo elimina até detecções pouco sobrepostas; $\tau$ alto preserva quase todas        |
| Ordenação por confiança | Garante que, entre caixas redundantes, sempre sobrevive a de maior pontuação                                                         |

| Elemento                  | Papel no pós-processamento de detecção                                                                    |
|---------------------------|-----------------------------------------------------------------------------------------------------------|
| mAP50 (Projeto Prático 2) | Usa exatamente o mesmo limiar de IoU (0,5) para decidir se uma detecção final “acerta” a caixa verdadeira |

9.15.4.4  Especificação de Entrada e Saída (VPL)

Entrada:

- Linha 1: Inteiro  $N$  e real  $\tau$ .
- Próximas  $N$  linhas: cinco reais  $x_1$   $y_1$   $x_2$   $y_2$  score.

Saída:

- Uma linha por caixa mantida, na ordem de seleção: `índice score` (score com 4 casas decimais).
- Última linha: `Total mantidas: X`.

9.15.4.5  Exemplos

| Entrada                                                     | Saída                                     | Observação                                                                                                                                     |
|-------------------------------------------------------------|-------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------|
| 3 0.5<br>0 0 10 10 0.9<br>1 1 11 11 0.75<br>50 50 60 60 0.8 | 0 0.9000<br>2 0.8000<br>Total mantidas: 2 | A caixa 1 é suprimida por sobrepor fortemente a caixa 0 (IoU 0,68 > 0,5).                                                                      |
| 2 0.5<br>0 0 10 10 0.9<br>0 0 10 6 0.95                     | 1 0.9500<br>Total mantidas: 1             | A caixa 0 é suprimida por sobrepor demais a vencedora (IoU=0,6 > 0,5), mesmo tendo menor score de origem que a caixa 1, aqui a de maior score. |



Figura 9.26: Simulador: IoU e Supressão de Não-Máximos

```
%%writefile EP09_04.py
# Código Python
```

```
Writing EP09_04.py
```

```
TestSuite("EP09_04.py").run()
```

### 9.15.5 EP09\_05 Pipeline Integrado: Da Detecção à Medição do Mundo Real

Este exercício final integra os dois exercícios anteriores ao princípio de **fotogrametria** apresentado na seção “Integrando Geometria e Aprendizado Profundo” — exatamente o mesmo cálculo implementado na figura de medição por referência de escala deste capítulo. O cenário reproduz uma situação realista: um detector (Faster R-CNN ou YOLO) gera **várias caixas candidatas sobrepostas** para o mesmo objeto de interesse; após filtrá-las por NMS, a caixa sobrevivente de maior confiança é usada, junto de uma caixa de referência de largura real conhecida (como o cartão de 8,56 cm), para estimar as dimensões reais do objeto detectado.

#### 9.15.5.1 Diretrizes de Implementação

1. **Referência conhecida:** Ler o valor real  $L_{ref}$  (largura real do objeto de referência, em cm) e, em seguida, os quatro reais  $x_1$   $y_1$   $x_2$   $y_2$  de sua caixa delimitadora em pixels (já conhecida, sem necessidade de detecção).
2. **Candidatas do objeto a medir:** Ler o inteiro  $N$  (número de caixas candidatas produzidas pelo detector para o objeto de interesse) e o limiar real  $\tau$ ; em seguida, ler as  $N$  linhas de caixas candidatas, cada uma com  $x_1$   $y_1$   $x_2$   $y_2$  score.
3. **Etapa 1 — NMS:** Aplique exatamente o algoritmo de Supressão de Não-Máximos do EP09\_04 às  $N$  caixas candidatas, usando o limiar  $\tau$ , para eliminar detecções redundantes do mesmo objeto.
4. **Etapa 2 — Seleção da caixa final:** Após o NMS, a caixa de maior score entre as mantidas é a detecção final do objeto (a entrada garante que todas as caixas candidatas correspondem a um único objeto físico, portanto a primeira caixa selecionada pelo NMS já é o resultado final).
5. **Etapa 3 — Medição por referência de escala:** Calcule a razão  $\text{cm/pixel} = L_{ref}/\text{largura da referência}$  em pixels e aplique-a tanto à largura quanto à altura (em pixels) da caixa final do objeto, obtendo suas dimensões reais estimadas em centímetros.
6. **Saída:** Primeiro, uma linha por caixa mantida após o NMS (mesmo formato do EP09\_04): **índice score**. Em seguida, a linha **Total mantidas**:  $X$ . Por fim, a linha **Objeto**:  $L \times A$  cm, onde  $L$  e  $A$  são a largura e a altura estimadas do objeto, cada uma com 2 casas decimais.

#### 9.15.5.2 Restrições Computacionais

- **Reaproveite o NMS do EP09\_04** integralmente — mesma regra de desempate, mesmo critério de supressão ( $\text{IoU} > \tau$ ).
- **A referência não passa por NMS:** sua caixa é dada diretamente, sem candidatas concorrentes.
- **Razão única para largura e altura:** assim como na figura de fotogrametria do capítulo, a mesma razão  $\text{cm/pixel}$  (derivada da largura da referência) é aplicada tanto à largura quanto à altura do objeto — não há calibração vertical separada.

#### 9.15.5.3 Fundamentação Teórica

| Etapa                          | Conceito do capítulo                                                                                  |
|--------------------------------|-------------------------------------------------------------------------------------------------------|
| Múltiplas caixas candidatas    | Saída bruta de um detector como o Faster R-CNN ou o YOLO, antes do pós-processamento                  |
| NMS (EP09_04)                  | Filtra a redundância, mantendo apenas a detecção mais confiável do objeto                             |
| Referência de escala conhecida | Mesmo princípio da fotogrametria: um objeto de dimensão real conhecida converte pixels em centímetros |



| Etapa          | Conceito do capítulo                                                                                                     |
|----------------|--------------------------------------------------------------------------------------------------------------------------|
| Razão cm/pixel | Fator de conversão único, assumindo que a câmera está aproximadamente perpendicular à cena (sem correção de perspectiva) |

9.15.5.4 🧱 Especificação de Entrada e Saída (VPL)

Entrada:

- Linha 1: Real  $L_{ref}$ .
- Linha 2: Quatro reais  $x_1\ y_1\ x_2\ y_2$  (caixa de referência).
- Linha 3: Inteiro  $N$  e real  $\tau$ .
- Próximas  $N$  linhas: cinco reais  $x_1\ y_1\ x_2\ y_2\ score$  (caixas candidatas do objeto).

Saída:

- Uma linha por caixa mantida após NMS: `índice score` (score com 4 casas decimais).
- Linha `Total mantidas: X`.
- Linha final: `Objeto: L x A cm` (2 casas decimais cada).

9.15.5.5 📌 Exemplos

| Entrada              | Saída                   | Observação                                                                                       |
|----------------------|-------------------------|--------------------------------------------------------------------------------------------------|
| 8.56                 | 0 0.9200                | A caixa 1 é suprimida por sobrepor fortemente a caixa 0; a detecção final do objeto é a caixa 0. |
| 30 200 170 288       | 2 0.4000                |                                                                                                  |
| 3 0.5                | Total mantidas: 2       |                                                                                                  |
| 250 100 470 250 0.92 | Objeto: 13.45 x 9.17 cm |                                                                                                  |
| 255 105 468 245 0.88 |                         |                                                                                                  |
| 600 600 650 650 0.40 |                         |                                                                                                  |




Figura 9.27: Simulador: Pipeline Integrado — NMS + Medição por Referência de Escala

```
%%writefile EP09_05.py  
# Código Python
```

```
Writing EP09_05.py
```

```
TestSuite("EP09_05.py").run()
```

---

# Referências

---

- BAHDANAU, Dzmitry; CHO, Kyunghyun; BENGIO, Yoshua. Neural Machine Translation by Jointly Learning to Align and Translate. *In*: 2015. Disponível em: <<https://arxiv.org/abs/1409.0473>>
- BARRERA, Junior *et al.* MMach: a mathematical morphology toolbox for the KHOROS system. **Journal of Electronic Imaging**, v. 7, n. 1, p. 174–210, 1998.
- BERGMANN, Paul *et al.* [MVTec AD – A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection](#). *In*: 2019.
- BISHOP, Christopher M. **Pattern Recognition and Machine Learning**. New York, NY, USA: Springer, 2006.
- BRADSKI, Gary; KAEHLER, Adrian. **Learning OpenCV: Computer vision with the OpenCV library**. [S.l.]: "O'Reilly Media, Inc.", 2008.
- CHEN, Liang-Chieh *et al.* Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation. *In*: FERRARI, Vittorio *et al.* (orgs.). Cham: Springer International Publishing, 2018.
- COVER, T.; HART, P. [Nearest neighbor pattern classification](#). **IEEE Transactions on Information Theory**, v. 13, n. 1, p. 21–27, 1967.
- DALAL, N.; TRIGGS, B. [Histograms of oriented gradients for human detection](#). *In*: 2005.
- DOUGHERTY, Edward R.; LOTUFO, Roberto A. **Hands-on morphological image processing**. [S.l.]: SPIE press, 2003. v. 59
- DUDA, Richard O.; HART, Peter E.; STORK, David G. **Pattern Classification**. 2nd. ed. New York: Wiley-Interscience, 2001.
- GONZALEZ, R. C.; WOODS, R. E. **Digital Image Processing**. 4th. ed. New York: Pearson, 2018.
- GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. **Deep Learning**. Cambridge, MA, USA: MIT Press, 2016.
- GOOGLE. **NotebookLM**. <https://notebooklm.google.com>, 2025.
- HE, Kaiming *et al.* [Deep Residual Learning for Image Recognition](#). *In*: 2016.
- ITU-R. **Recommendation BT.601: Studio encoding parameters of digital television for standard 4:3 and wide screen 16:9 aspect ratios**. <https://www.itu.int/rec/R-REC-BT.601/>, 2011.
- KINGMA, Diederik P.; BA, Jimmy. Adam: A Method for Stochastic Optimization. *In*: San Diego, CA, USA: 2015. Disponível em: <<https://arxiv.org/abs/1412.6980>>
- KIRILLOV, Alexander *et al.* [Segment Anything](#). *In*: 2023.

- KNUTH, Donald E. [Literate Programming](#). **The Computer Journal**, v. 27, n. 2, p. 97–111, 1984.
- LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. [Deep learning](#). **Nature**, v. 521, n. 7553, p. 436–444, 2015.
- LEWIS, Patrick *et al.* Retrieval-augmented generation for knowledge-intensive nlp tasks. **Advances in neural information processing systems**, v. 33, p. 9459–9474, 2020.
- LIENHART, Rainer; MAYDT, Jochen. [An Extended Set of Haar-like Features for Rapid Object Detection](#). *In*: 2002.
- LOTUFO, R. A.; ZAMPIROLI, F. A. [Fast multidimensional parallel Euclidean distance transform based on mathematical morphology](#). *In*: 2001.
- LOTUFO, Roberto A. *et al.* MMachLib functions and MMach operators. *In*: 1997.
- MALLAT, Stéphane. **A wavelet tour of signal processing**. *[S.l.]*: Elsevier, 1999.
- MATHERON, Georges. **Random Sets and Integral Geometry**. New York: John Wiley & Sons, 1975.
- OJALA, Timo; PIETIKÄINEN, Matti; MÄENPÄÄ, Topi. [Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns](#). **IEEE Trans. Pattern Anal. Mach. Intell.**, v. 24, n. 7, p. 971–987, jul. 2002.
- OPPENHEIM, Alan V.; SCHAFER, Ronald W. **Discrete-Time Signal Processing**. *[S.l.]*: Pearson, 2010.
- OTSU, Nobuyuki. [A Threshold Selection Method from Gray-Level Histograms](#). **IEEE Transactions on Systems, Man, and Cybernetics**, v. 9, n. 1, p. 62–66, 1979.
- PEDREGOSA, Fabian *et al.* Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.
- QUILICI-GONZALEZ, José Artur; ZAMPIROLI, Francisco de Assis. [Sistemas Inteligentes e Mineração de Dados](#). *[S.l.]*: Editora UFABC, 2014.
- QUILICI-GONZALEZ, José Artur; ZAMPIROLI, Francisco de Assis; SOUZA, Fábio Rezende de. **Sistemas Inteligentes e Mineração de Dados: Do Weka ao Python**. 2. ed. *[S.l.]*: <https://fzampiroli.github.io/simd2/>, 2026.
- REDMON, Joseph *et al.* [You Only Look Once: Unified, Real-Time Object Detection](#). *In*: 2016.
- REN, Shaoqing *et al.* Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. *In*: CORTES, C. *et al.* (orgs.). Curran Associates, Inc., 2015. Disponível em: <[https://proceedings.neurips.cc/paper\\_files/paper/2015/file/14bfa6bb14875e45bba028a21ed38046-Paper.pdf](https://proceedings.neurips.cc/paper_files/paper/2015/file/14bfa6bb14875e45bba028a21ed38046-Paper.pdf)>
- RONNEBERGER, Olaf; FISCHER, Philipp; BROX, Thomas. U-Net: Convolutional Networks for Biomedical Image Segmentation. *In*: NAVAB, Nassir *et al.* (orgs.). Cham: Springer International Publishing, 2015.
- ROSENBLATT, Frank. [The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain](#). **Psychological Review**, v. 65, n. 6, p. 386–408, 1958.
- SERRA, Jean. **Image Analysis and Mathematical Morphology**. London: Academic Press, 1982. v. 1

- SINGH, Himanshu. **Practical machine learning and image processing**. [S.l.]: Springer, 2019.
- SINGH, Shobhna; LLOYD, Jerome; FLICKER, Felix. [Hamiltonian Cycles on Ammann-Beenker Tilings](#). **Physical Review X**, v. 14, n. 3, p. 031005, 10 jul. 2024.
- SMITH, Ray. [An Overview of the Tesseract OCR Engine](#). In: IEEE Computer Society, 2007.
- SMITH, Ray. [History of the Tesseract OCR Engine: What Worked and What Didn't](#). In: 2013.
- SONG, Kechen; YAN, Yunhui. [A Noise Robust Method Based on Completed Local Binary Patterns for Hot-Rolled Steel Strip Surface Defects](#). **Applied Surface Science**, v. 285, p. 858–864, 2013.
- SZELISKI, Richard. **Computer Vision: Algorithms and Applications**. 2. ed. [S.l.]: Springer, 2022.
- TABERNIK, Domen *et al.* [Segmentation-Based Deep-Learning Approach for Surface-Defect Detection](#). **Journal of Intelligent Manufacturing**, v. 31, n. 3, p. 759–776, 2020.
- VASWANI, Ashish *et al.* Attention Is All You Need. In: 2017. Disponível em: <<https://arxiv.org/abs/1706.03762>>
- VIOLA, Paul; JONES, Michael. [Rapid Object Detection Using a Boosted Cascade of Simple Features](#). In: IEEE Computer Society, 2001.
- VIOLA, Paul; JONES, Michael J. [Robust Real-Time Face Detection](#). **International Journal of Computer Vision**, v. 57, n. 2, p. 137–154, 2004.
- WALLACE, Gregory K. [The JPEG Still Picture Compression Standard](#). **Communications of the ACM**, v. 34, n. 4, p. 30–44, 1991.
- ZAMPIROLI, Francisco A. **MCTest: Como Criar e Corrigir Exames Parametrizados**. [S.l.]: Independente, 2023.
- ZAMPIROLI, Francisco de Assis *et al.* A Practical Digital Image Processing Course with morph.py. In: Porto Alegre, RS, Brasil: Sociedade Brasileira de Computação (SBC), 2024. Disponível em: <<https://sol.sbc.org.br/index.php/educomp/article/view/28199>>
- ZAMPIROLI, Francisco de Assis *et al.* [Teaching Hands-On Digital Image Processing with morph.py: Methods and Comprehensive Results](#). **Revista Brasileira de Informática na Educação**, v. 33, p. 990–1026, 2025.